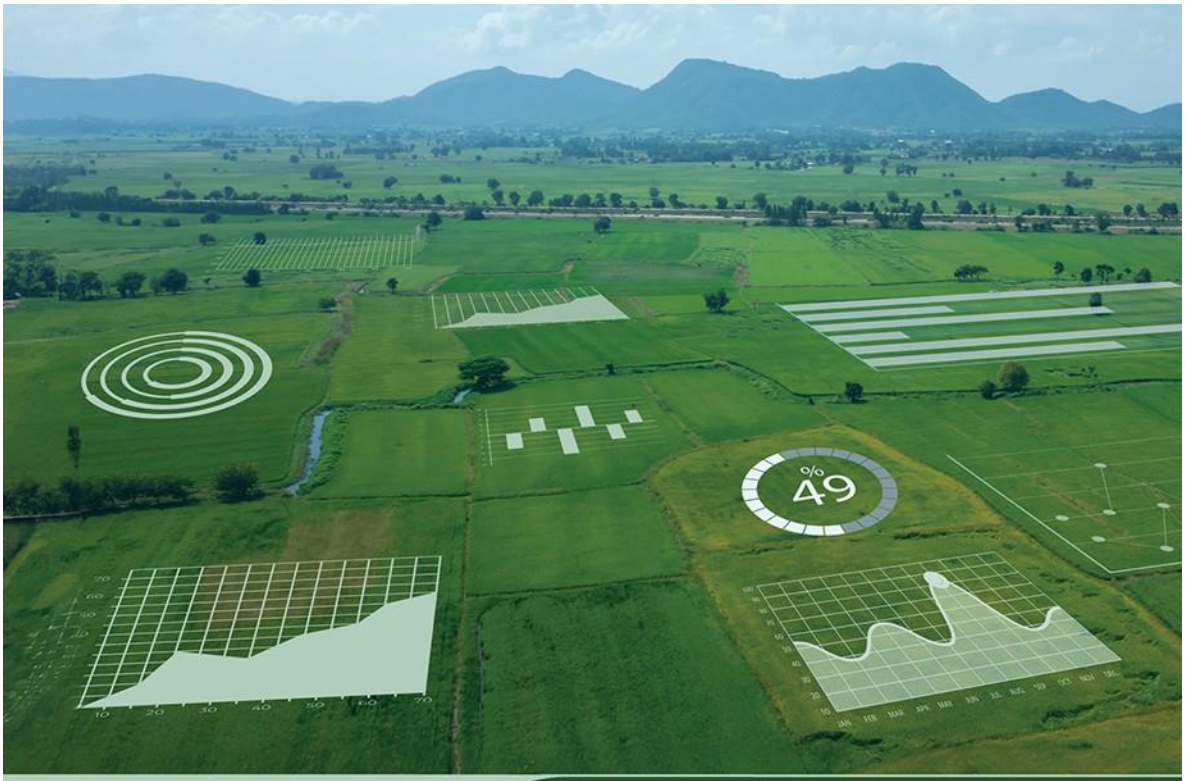


Data-Driven Farming

Harnessing the Power of AI and Machine Learning in Agriculture

Edited by

Dr. Syed Nisar Hussain Bukhari

An **Auerbach** Book

CRC Press
Taylor & Francis Group

Nông Nghiệp Định Hướng Dữ Liệu Khai Thác Sức Mạnh của Trí Tuệ Nhân Tạo và Máy Học trong Nông Nghiệp

Nông Nghiệp Định Hướng Dữ Liệu

Trong lĩnh vực nông nghiệp năng động, trí tuệ nhân tạo (AI) và máy học (ML) nổi lên như những chất xúc tác cho sự chuyển đổi và tăng trưởng chưa từng có. Sự xuất hiện của dữ liệu lớn, cảm biến Internet vạn vật (IoT) và phân tích nâng cao đã mở ra những khả năng mới cho nông dân để thu thập và phân tích dữ liệu trong thời gian thực, đưa ra quyết định sáng suốt và tăng hiệu quả. AI và ML là những yếu tố hỗ trợ chính cho nông nghiệp định hướng dữ liệu, cho phép nông dân sử dụng các thuật toán và mô hình dự đoán để có được cái nhìn sâu sắc về sức khỏe cây trồng, chất lượng đất, các kiểu thời tiết và hơn thế nữa. Nông nghiệp là một ngành công nghiệp có nền tảng sâu xa từ truyền thống, nhưng bối cảnh đang thay đổi nhanh chóng với sự xuất hiện của các công nghệ mới.

Nông Nghiệp Định Hướng Dữ Liệu: Khai Thác Sức Mạnh của Trí Tuệ Nhân Tạo và Máy Học trong Nông Nghiệp là một hướng dẫn toàn diện khám phá cách những tiến bộ công nghệ mới nhất có thể giúp nông dân đưa ra quyết định tốt hơn và tối đa hóa sản lượng. Nó cung cấp một cái nhìn tổng quan chi tiết về sự giao thoa giữa dữ liệu, AI và ML trong nông nghiệp và đưa ra các ví dụ thực tế và nghiên cứu điển hình chứng minh cách những công cụ này có thể giúp nông dân cải thiện hiệu quả, giảm lãng phí và tăng lợi nhuận. Khám phá cách AI và ML có thể được sử dụng để đạt được các phương pháp canh tác bền vững và có lợi nhuận, cuốn sách cung cấp phần giới thiệu về những điều cơ bản của nông nghiệp định hướng dữ liệu, bao gồm tổng quan về các khái niệm, công cụ và công nghệ chính. Nó cũng thảo luận về những thách thức và cơ hội mà nông dân phải đối mặt trong bối cảnh định hướng dữ liệu ngày nay. Bao gồm các chủ đề như giám sát cây trồng, dự báo thời tiết, quản lý dịch hại và quản lý sức khỏe đất, cuốn sách tập trung vào phân tích dữ liệu, dự đoán kết quả và tối ưu hóa việc ra quyết định trong một loạt các bối cảnh nông nghiệp.

Taylor & Francis

Taylor & Francis Group

http://taylorandfrancis.com

Nông Nghiệp Định Hướng Dữ Liệu

Khai Thác Sức Mạnh của Trí Tuệ Nhân Tạo và Máy Học trong Nông Nghiệp

Biên tập bởi

Tiến sĩ Syed Nisar Hussain Bukhari

CRC Press Taylor & Francis Group

Boca Raton London New York

CRC Press là một ấn hiệu của Taylor & Francis Group, một doanh nghiệp thuộc Informa

MỘT CUỐN SÁCH AUERBACH

Ấn bản đầu tiên xuất bản 2024 2385 NW Executive Center Drive, Suite 320, Boca Raton FL 33431

và bởi CRC Press 4 Park Square, Milton Park, Abingdon, Oxon, OX14 4RN

CRC Press là một ấn hiệu của Taylor & Francis Group, LLC

© 2024 Taylor & Francis Group, LLC

Những nỗ lực hợp lý đã được thực hiện để xuất bản dữ liệu và thông tin đáng tin cậy, nhưng tác giả và nhà xuất bản không thể chịu trách nhiệm về tính hợp lệ của tất cả các tài liệu hoặc hậu quả của việc sử dụng chúng. Các tác giả và nhà xuất bản đã cố gắng truy tìm những người nắm giữ bản quyền của tất cả tài liệu được sao chép trong ấn phẩm này và xin lỗi những người nắm giữ bản quyền nếu chưa được sự cho phép để xuất bản dưới dạng này. Nếu bất kỳ tài liệu có bản quyền nào chưa được ghi nhận, xin vui lòng viết thư và cho chúng tôi biết để chúng tôi có thể khắc phục trong bất kỳ lần tái bản nào trong tương lai.

Ngoại trừ những trường hợp được cho phép theo Luật Bản quyền Hoa Kỳ, không có phần nào của cuốn sách này có thể được tái bản, sao chép, truyền tải hoặc sử dụng dưới bất kỳ hình thức nào, bằng bất kỳ phương tiện điện tử, cơ khí hoặc phương tiện nào khác, hiện đã biết hoặc sau này được phát minh, bao gồm sao chụp, vi phim và ghi âm, hoặc trong bất kỳ hệ thống lưu trữ hoặc truy xuất thông tin nào, mà không có sự cho phép bằng văn bản của các nhà xuất bản.

Để được phép sao chụp hoặc sử dụng tài liệu điện tử từ tác phẩm này, hãy truy cập www.copyright.com hoặc liên hệ với Trung tâm Giải quyết Bản quyền, Inc. (CCC), 222

Rosewood Drive, Danvers, MA 01923, 978-750-8400. Đối với các tác phẩm không có sẵn trên CCC, vui lòng liên hệ mpkbookspermissions@tandf.co.uk

Thông báo nhãn hiệu: Tên sản phẩm hoặc tên tập đoàn có thể là nhãn hiệu hoặc nhãn hiệu đã đăng ký và chỉ được sử dụng để nhận dạng và giải thích mà không có ý định xâm phạm.

ISBN: 978-1-032-61892-0 (hbk) ISBN: 978-1-032-77872-3 (pbk) ISBN: 978-1-003-48517-9 (ebk)

DOI: 10.1201/9781003485179

Sắp chữ bằng Minion bởi SPI Technologies India Pvt Ltd (Straive)

Cuốn sách này được dành tặng cho người cha yêu quý của tôi, cố Syed Gulam Mohi ud Din Bukhari (Aba Jan) và người mẹ yêu thương, chăm sóc của tôi, cố Zareefa Syedah, sự khôn ngoan và tình yêu thương của họ tiếp tục truyền cảm hứng cho hành trình theo đuổi tri thức và đổi mới của tôi.

Taylor & Francis

Taylor & Francis Group

http://taylorandfrancis.com

Mục lục

Tiểu sử Biên tập viên ……x

Danh sách Cộng tác viên …… xii

Lời nói đầu …… xv

Lời cảm ơn …… xvii

Chương 1

Tận dụng IoT để Giám sát Sức khỏe Chính xác trong Chăn nuôi với Trí tuệ Nhân tạo ……1 *Devinder Kaur và Amandeep Kaur Virk*

Chương 2

Tầm quan trọng của Máy học trong Phát hiện Bệnh trên Cây Táo và Hàm ý ……19 *Saimul Bashir, Syed Nisar Hussain Bukhari, Faisal Firdous, và Gursimran Jeet Kour*

Chương 3

Đầu vào Thông minh Cách mạng hóa Nông nghiệp: Một Nghiên cứu Phân tích …… 42 *Nelofar Ara, Sani Mustapha Kura, VK Aswathy, và Mohammad Amin Wani*

Chương 4

Nghiên cứu Điển hình về các Sáng kiến và Câu chuyện Thành công của Hệ thống AI Biên cho Nông nghiệp …… 56 *Thamizhiniyan Natarajan và Shanmugavadivu Pichai*

Chương 5

Công cụ Đề xuất Cây trồng: Phương pháp Tính toán dựa trên Máy học để Đề xuất Cây trồng Tốt nhất Sử dụng các Đặc điểm Đất đai và Môi trường ……81 *Syed Nisar Hussain Bukhari, Jewiara Khursheed Wani, Ummer Iqbal, và Muneer Ahmad Dar*

Chương 6

Xem xét các Thuật toán Máy học trong Dự đoán Năng suất Cây trồng ……101 *Anshika Gupta, Mohit Soni, và Kalpana Katiyar*

Chương 7 Thu hoạch Thông minh: AI và ML Cách mạng hóa Nông nghiệp…… 126 *Arya Kumari, Muhammad Najeeb Khan, và Amit Kumar Sinha*

Chương 8 Sử dụng Học sâu để Phát hiện Bệnh trên Lá Táo……142 *Syed Nisar Hussain Bukhari, Rukaya Manzoor, Ummer Iqbal, và Muneer Ahmad Dar*

Chương 9 Dự đoán Năng suất Cây trồng Nông nghiệp: Phân tích So sánh Sử dụng các Mô hình Máy học……158 *Kukatlapalli Pradeep Kumar, S. Babu Kumar, Amarthya Dutta Gupta, Kevin Johnson, và Meghan Mary Michael*

Chương 10 Những Nguyên tắc Cơ bản về AI và Máy học với các Ví dụ Cụ thể về Ứng dụng trong Nông nghiệp……178 *Manoj Kumar Mahto, P. Laxmikanth, và V.S.S.P.L.N. Balaji Lanka*

Chương 11 Tương lai Canh tác: Tận dụng Ngôn ngữ Máy để Dự báo Bệnh Lá Khoai tây và Tối ưu hóa Năng suất……200 *A. Vijayalakshmi, A. Nidin, và Deepthi Das*

Chương 12 Phân loại Trang trại để Đề xuất Trồng lúa Sử dụng Naive Bayes và SVM: Một Nghiên cứu Điển hình……216 *Qurat-ul-ain, Uzma Hameed, và Hamira Mehraj*

Chương 13 Mạng Thần kinh cho Phát hiện Bệnh Cây trồng……227 *Mohammad Ubaidullah Bokhari, Gaurav Yadav, và Md. Zeyauddin*

Chương 14 Dự báo Thời tiết Ngắn hạn cho Nông nghiệp Chính xác ở Jammu và Kashmir: Một Phương pháp Tiếp cận Học sâu……243 *Syed Nisar Hussain Bukhari và Sana Farooq Pandit*

Chương 15 Học Tăng cường Sâu cho Tưới tiêu Thông minh ……259 *Aakansha Khanna và Inzimam Ul Hassan*

Tiểu sử Biên tập viên

Tiến sĩ Syed Nisar Hussain Bukhari là một chuyên gia có thành tích xuất sắc với nền tảng vững chắc trong lĩnh vực học thuật, nghiên cứu và quản lý. Ông hiện đang giữ chức vụ Nhà khoa học-D tại NIELIT Srinagar và đã có những đóng góp quan trọng cho lĩnh vực công nghệ thông tin (IT).

Tiến sĩ Bukhari nhận bằng cử nhân và thạc sĩ về ứng dụng máy tính từ Đại học Kashmir, Srinagar, Ấn Độ, và bằng Tiến sĩ trong lĩnh vực máy học, tin sinh học và tin miễn dịch từ Viện Máy tính, Đại học Chandigarh, Ấn Độ.

Mối quan tâm nghiên cứu của Tiến sĩ Bukhari bao gồm nhiều lĩnh vực tiên tiến, như máy học và học sâu, tin sinh học và tin miễn dịch. Công trình của ông đã được ghi nhận trên các tạp chí SCI uy tín như *Nature Scientific Reports*, *Springer*, *MDPI* và *Hindawi*, phản ánh tầm quan trọng và tác động của những đóng góp của ông đối với cộng đồng khoa học.

Cam kết của Tiến sĩ Bukhari trong việc truyền bá kiến thức được thể hiện rõ qua kinh nghiệm giảng dạy phong phú của ông. Ông đã giảng dạy nhiều môn học cốt lõi, bao gồm máy học, Python, cấu trúc dữ liệu, lập trình web sử dụng ASP.Net, và nhiều hơn nữa cho sinh viên sau đại học – cụ thể là MCA và MSc IT. Kiến thức và kỹ năng toàn diện của ông đã cho phép ông đào tạo và hướng dẫn thực tập về trí tuệ nhân tạo, máy học, học sâu và các công nghệ mới nổi khác cho sinh viên kỹ thuật.

Với niềm đam mê phổ biến kiến thức, Tiến sĩ Bukhari đã xuất bản nhiều bài báo trên các tạp chí và hội nghị uy tín. Thành tích học thuật của Tiến sĩ Bukhari không chỉ dừng lại ở các ấn phẩm nghiên cứu. Ông đã biên tập và viết sách và được công nhận là chuyên gia máy học được chứng nhận từ Đại học Stanford và Đại học Johns Hopkins. Ngoài ra, ông đã được mời làm diễn giả tại nhiều hội thảo, hội thảo trực tuyến và hội nghị khác nhau, cho thấy chuyên môn của ông trong lĩnh vực này. Cam kết xuất sắc của ông đã được ghi nhận với việc nhận được Giải thưởng Bài báo Xuất sắc tại nhiều hội nghị quốc tế.

Chuyên môn của ông đã được tìm kiếm bởi các tạp chí uy tín như *Briefings in Bioinformatics* của Oxford University Press, *Computers in Biology and *Medicine* của Elsevier, và *Scientific Reports* của Nature, nơi ông phục vụ với tư cách là người đánh giá được mời. Với tư cách là chủ tọa phiên họp, ông đã chủ trì nhiều phiên đặc biệt tại các hội nghị quốc tế được lập chỉ mục Scopus. Mối quan tâm nghiên cứu của ông bao gồm trí tuệ nhân tạo và máy học, học sâu, tin sinh học, tin miễn dịch, sinh học tính toán và an ninh mạng. Trong vai trò Trưởng khoa CNTT tại NIELIT Srinagar, Tiến sĩ Bukhari đã thể hiện khả năng lãnh đạo xuất sắc và đóng một vai trò quan trọng trong sự tăng trưởng và phát triển của khoa. Trong nhiệm kỳ của mình, ông đã đóng một vai trò then chốt trong sự tăng trưởng và phát triển của khoa, giám sát các khóa học MSc IT và BSc IT. Ông đã cung cấp dịch vụ tư vấn cho các ban ngành khác nhau của Chính phủ Jammu và Kashmir, Ấn Độ, cung cấp chuyên môn của mình trong việc triển khai các dự án liên

quan đến chính phủ điện tử. Tiến sĩ Bukhari là thành viên của Viện Kỹ sư Điện tử và Viễn thông (IETE) và Hiệp hội Kỹ sư Quốc tế (IAENG).

Danh sách Cộng tác viên

Nelofar Ara Đại học Lovely Professional Phagwara, Ấn Độ

VK Aswathy Đại học Lovely Professional Phagwara, Ấn Độ

Saimul Bashir Đại học Chandigarh Mohali, Ấn Độ

Mohammad Ubaidullah Bokhari Đại học Hồi giáo Aligarh Aligarh, Ấn Độ

Syed Nisar Hussain Bukhari Viện Công nghệ Điện tử và Thông tin Quốc gia (NIELIT) Srinagar, Ấn Độ

Muneer Ahmad Dar Viện Công nghệ Điện tử và Thông tin Quốc gia (NIELIT) Srinagar, Ấn Độ

Deepthi Das Đại học CHRIST (Được coi là Đại học) Bangalore, Ấn Độ

Faisal Firdous Đại học Công nghệ Thông tin Jaypee Solan, Ấn Độ

Anshika Gupta Viện Công nghệ Dr. Ambedkar dành cho Người khuyết tật Kanpur, Ấn Độ

Amarthya Dutta Gupta Đại học CHRIST (Được coi là Đại học), Cơ sở Kengeri Bangalore, Ấn Độ

Uzma Hameed Cao đẳng Chính phủ dành cho Phụ nữ, Đại học Cụm Srinagar, Ấn Độ

Inzimam Ul Hassan Đại học Toàn cầu Vivekananda Jaipur, Ấn Độ

Ummer Iqbal Viện Công nghệ Điện tử và Thông tin Quốc gia (NIELIT) Srinagar, Ấn Độ

Kevin Johnson Đại học CHRIST (Được coi là Đại học), Cơ sở Kengeri Bangalore, Ấn Độ

Kalpana Katiyar Viện Công nghệ Dr. Ambedkar dành cho Người khuyết tật Kanpur, Ấn Độ

Devinder Kaur

Đại học Thế giới Sri Guru Granth Sahib, Cao đẳng Mata Gujri Fatehgarh Sahib, Ấn Độ

Muhammad Najeeb Khan Đại học Shri Mata Vaishno Devi Katra, Ấn Độ

Aakansha Khanna Đại học Chandigarh Ludhiana, Ấn Độ

Gursimran Jeet Kour Đại học Chandigarh Mohali, Ấn Độ

S. Babu Kumar Đại học CHRIST (Được coi là Đại học), Cơ sở Kengeri Bangalore, Ấn Độ

Kukatlapalli Pradeep Kumar Đại học CHRIST (Được coi là Đại học), Cơ sở Kengeri Bangalore, Ấn Độ

Arya Kumari Đại học Shri Mata Vaishno Devi Katra, Ấn Độ

Sani Mustapha Kura Đại học Lovely Professional Phagwara, Ấn Độ

V.S.S.P.L.N. Balaji Lanka Viện Công nghệ và Khoa học Vignan Hyderabad, Ấn Độ

P. Laxmikanth Viện Công nghệ và Khoa học Vignan Hyderabad, Ấn Độ

Manoj Kumar Mahto Viện Công nghệ và Khoa học Vignan Hyderabad, Ấn Độ

Rukaya Manzoor Viện Công nghệ Điện tử và Thông tin Quốc gia (NIELIT) Srinagar, Ấn Độ

Hamira Mehraj Cao đẳng Chính phủ dành cho Phụ nữ, Đại học Cụm Srinagar, Ấn Độ

Meghan Mary Michael Đại học CHRIST (Được coi là Đại học), Cơ sở Kengeri Bangalore, Ấn Độ

Thamizhiniyan Natarajan Viện Nông thôn Gandhigram Chinnalapatti, Ấn Độ

A. Nidin Đại học CHRIST (Được coi là Đại học) Bangalore, Ấn Độ

Sana Farooq Pandit Viện Công nghệ Điện tử và Thông tin Quốc gia (NIELIT) Srinagar, Ấn Độ

Shanmugavadivu Pichai Viện Nông thôn Gandhigram Chinnalapatti, Ấn Độ Srinagar, Ấn Độ

Qurat-ul-ain Cao đẳng Chính phủ dành cho Phụ nữ, Đại học Cụm Srinagar, Ấn Độ

Amit Kumar Sinha Đại học Shri Mata Vaishno Devi Katra, Ấn Độ

Mohit Soni Viện Công nghệ Dr. Ambedkar dành cho Người khuyết tật Kanpur, Ấn Độ

A. Vijayalakshmi Đại học CHRIST (Được coi là Đại học) Bangalore, Ấn Độ

Amandeep Kaur Virk Đại học Thế giới Sri Guru Granth Sahib Fatehgarh Sahib, Ấn Độ

Mohammad Amin Wani Đại học Lovely Professional Phagwara, Ấn Độ

Jewiara Khursheed Wani Viện Công nghệ Điện tử và Thông tin Quốc gia (NIELIT) Srinagar, Ấn Độ

Gaurav Yadav Đại học Hồi giáo Aligarh Aligarh, Ấn Độ

Md. Zeyauddin Đại học Hồi giáo Aligarh Aligarh, Ấn Độ

Lời nói đầu

Tôi vô cùng vui mừng và nhiệt tình giới thiệu với quý vị cuốn sách *Nông Nghiệp Định Hướng Dữ Liệu: Khai Thác Sức Mạnh của Trí Tuệ Nhân Tạo và Máy Học trong Nông Nghiệp*. Cuốn sách này là một minh chứng cho sự giao thoa năng động giữa công nghệ và nông nghiệp, một sự tiến hóa đã thay đổi đáng kể cách chúng ta tiếp cận các phương pháp canh tác. Trong những năm gần đây, việc tích hợp trí tuệ nhân tạo (AI) và máy học (ML) vào bối cảnh nông nghiệp đã đánh dấu một kỷ nguyên mới—một sự chuyển dịch tiến bộ từ các phương pháp truyền thống sang các phương pháp tinh vi, hiệu quả và bền vững hơn.

Nguồn gốc của cuốn sách này bắt nguồn từ sự công nhận ngày càng tăng về vai trò then chốt của công nghệ trong việc giải quyết những thách thức phức tạp mà ngành nông nghiệp phải đối mặt. Nhu cầu tăng sản xuất lương thực để đáp ứng yêu cầu của dân số toàn cầu đang bùng nổ, cùng với mệnh lệnh phải quản lý tài nguyên bền vững hơn, đã thúc đẩy một cuộc cách mạng. Việc sử dụng AI và ML mang lại một giải pháp hấp dẫn, cho phép nông dân, nhà nghiên cứu và các bên liên quan tối ưu hóa sản xuất, hợp lý hóa quy trình và đưa ra các quyết định sáng suốt, rất quan trọng cho tương lai của nông nghiệp.

Cuốn sách này là một nỗ lực hợp tác, bao gồm chuyên môn và hiểu biết của nhiều cộng tác viên từ các lĩnh vực đa dạng—khoa học nông nghiệp, khoa học dữ liệu, công nghệ và hơn thế nữa. Trí tuệ và kinh nghiệm tập thể của họ đã được chắt lọc thành một hướng dẫn toàn diện khám phá các ứng dụng đa diện của AI và ML trong nông nghiệp. Độc giả sẽ khám phá một kho tàng kiến thức, ứng dụng thực tiễn và nghiên cứu điển hình minh họa tác động chuyển đổi của các phương pháp tiếp cận định hướng dữ liệu trong canh tác.

Các chương trong cuốn sách này cung cấp một cuộc khám phá chuyên sâu về mối quan hệ cộng sinh giữa AI, ML và nông nghiệp. Từ việc tận dụng Internet vạn vật (IoT) để giám sát sức khỏe chính xác trong chăn nuôi đến việc triển khai học sâu để phát hiện bệnh cây trồng, chiều sâu và bề rộng kiến thức được chia sẻ bởi các cộng tác viên của chúng tôi chứng minh tính linh hoạt và những hàm ý đầy hứa hẹn của các công nghệ này trong nông nghiệp.

Cuốn sách này dành cho nhiều đối tượng độc giả khác nhau—các nhà học thuật, nhà nghiên cứu, nông dân, những người đam mê công nghệ, các nhà hoạch định chính sách và bất kỳ ai quan tâm đến sức mạnh chuyển đổi của công nghệ trong nông nghiệp. Tôi hy vọng rằng những hiểu biết được trình bày trong những trang sách này sẽ phục vụ như một nguồn tài nguyên quý giá, thắp sáng sự tò mò, thúc đẩy đổi mới và định hướng sự tiến hóa của nông nghiệp hướng tới một tương lai bền vững và hiệu quả hơn.

Tôi xin bày tỏ lòng biết ơn chân thành đến tất cả các cộng tác viên, những người mà sự tận tâm và chuyên môn của họ đã biến cuốn sách này thành hiện thực. Tôi cũng bày tỏ sự đánh giá cao của mình với CRC Press, Taylor & Francis Group, vì sự hỗ trợ và cam kết của họ trong việc phổ biến kiến thức trong lĩnh vực không ngừng phát triển này.

Trân trọng, **Tiến sĩ Syed Nisar Hussain Bukhari**

Lời cảm ơn

Việc biên soạn cuốn sách *Nông Nghiệp Định Hướng Dữ Liệu: Khai Thác Sức Mạnh của Trí Tuệ Nhân Tạo và Máy Học trong Nông Nghiệp* đã là một hành trình tràn đầy sự hợp tác, hỗ trợ và cống hiến từ nhiều cá nhân và tổ chức. Việc hoàn thành cuốn sách này sẽ không thể thực hiện được nếu không có những đóng góp vô giá và sự hỗ trợ không ngừng từ nhiều nơi.

Trước hết, tôi muốn dâng mọi lời ca ngợi và cảm tạ lên **Đấng Allah Toàn năng**, Đấng nhân từ và khoan dung nhất, người đã ban cho tôi sức mạnh, sự bảo vệ và sự kiên nhẫn để vượt qua mọi trở ngại và làm cho công việc này thành hiện thực.

Tôi xin bày tỏ lòng biết ơn chân thành đến tất cả các cộng tác viên, những người mà chuyên môn, sự tận tâm và niềm đam mê đã định hình nên cuốn sách này. Mỗi chương sách là một minh chứng cho cam kết của họ trong việc thúc đẩy biên giới tri thức trong lĩnh vực nông nghiệp định hướng dữ liệu năng động. Những hiểu biết, nghiên cứu và kinh nghiệm thực tế của họ đã góp phần quan trọng trong việc xây dựng một nguồn tài nguyên toàn diện cho ngành công nghiệp, giới học thuật và tất cả các bên liên quan quan tâm đến sự giao thoa giữa công nghệ và nông nghiệp.

Tôi cũng xin bày tỏ sự đánh giá cao sâu sắc nhất đến CRC Press, Taylor & Francis Group, vì sự hỗ trợ liên tục, hướng dẫn và niềm tin của họ vào dự án này. Cam kết của họ trong việc phổ biến kiến thức và thúc đẩy xuất bản các tác phẩm đổi mới đã có ý nghĩa then chốt trong việc biến cuốn sách này thành hiện thực.

Ngoài ra, tôi vô cùng biết ơn các nhà đánh giá và biên tập viên đã dành thời gian và chuyên môn của họ để đảm bảo tính chặt chẽ học thuật và chất lượng của ấn phẩm này. Phản hồi sâu sắc và đánh giá tỉ mỉ của họ chắc chắn đã nâng cao tiêu chuẩn tổng thể của nội dung, làm phong phú thêm trải nghiệm của độc giả và uy tín của cuốn sách. Sự hỗ trợ và khuyến khích từ các cơ quan học thuật và nghiên cứu đã đóng một vai trò quan trọng trong việc định hình cuốn sách này. Tôi bày tỏ sự đánh giá cao của mình với tất cả các tổ chức đã nuôi dưỡng một môi trường thuận lợi cho nghiên cứu, đổi mới và khám phá các công nghệ tiên tiến trong nông nghiệp.

Tôi xin gửi lời cảm ơn chân thành đến những người nông dân, chuyên gia nông nghiệp và chuyên gia trong ngành, những người mà hiểu biết thực tế và kinh nghiệm của họ đã là xương sống của cuốn sách này. Kiến thức thực hành và sự sáng tạo của họ đã cung cấp những hiểu biết vô giá, làm phong phú thêm nội dung và đảm bảo rằng cuốn sách này vẫn gắn kết và có liên quan với những thách thức và cơ hội trong thế giới thực.

Cuối cùng, tôi muốn bày tỏ lòng biết ơn sâu sắc đến gia đình tôi vì sự hỗ trợ không ngừng, sự kiên nhẫn và hiểu biết của họ trong suốt quá trình này. Sự khích lệ và hy sinh của họ đã là nguồn động lực không ngừng, cho phép tôi hoàn toàn đắm mình vào việc biên soạn và hoàn thiện cuốn sách này.

Tôi cũng muốn gửi lời cảm ơn đến tất cả bạn bè, đồng nghiệp và các cá nhân khác đã đóng góp trực tiếp hoặc gián tiếp cho cuốn sách này. Sự hỗ trợ và khích lệ của họ đã có giá trị vô cùng trong suốt hành trình này.

Tôi hy vọng rằng cuốn sách này sẽ phục vụ như một nguồn cảm hứng và hướng dẫn cho tất cả những ai quan tâm đến việc khai thác sức mạnh của trí tuệ nhân tạo và máy học để định hình tương lai của nông nghiệp. Có thể nó thúc đẩy đổi mới, thúc đẩy hợp tác và đóng góp vào sự phát triển của các phương pháp canh tác bền vững và hiệu quả hơn.

Tiến sĩ Syed Nisar Hussain Bukhari

CHƯƠNG 1: TẬN DỤNG IOT ĐỂ GIÁM SÁT SỨC KHỎE CHÍNH XÁC TRONG CHĂN NUÔI VỚI TRÍ TUỆ NHÂN TẠO

Devinder Kaur Đại học Thế giới Sri Guru Granth Sahib, Cao đẳng Mata Gujri, Fatehgarh Sahib, Ấn Độ Cao đẳng Mata Gujri, Fatehgarh Sahib, Ấn Độ

Amandeep Kaur Virk Đại học Thế giới Sri Guru Granth Sahib, Fatehgarh Sahib, Ấn Độ

1.1 GIỚI THIỆU

Ấn Độ, một quốc gia đông dân cư, phụ thuộc đáng kể vào nông nghiệp và chăn nuôi bò sữa như một nguồn thu nhập chính, đặc biệt trong các cộng đồng nông thôn. Tốc độ tăng trưởng dân số nhanh chóng làm nổi bật sự cần thiết phải tăng sản xuất lương thực và sữa trong tương lai. Trước đây, hầu hết các bang của Ấn Độ đã tuân theo các phương pháp chăn nuôi gia súc truyền thống, với nông dân đưa ra quyết định chỉ dựa trên kinh nghiệm cá nhân của họ. Tuy nhiên, các xu hướng đương đại đang dịch chuyển khỏi những cách tiếp cận thông thường này khi công nghệ chăn nuôi bò sữa chính xác ngày càng nổi bật, thúc đẩy người chăn nuôi bò sữa tiến vào lĩnh vực chăn nuôi gia súc chính xác. Để đưa ra các lựa chọn sáng suốt trong quản lý chăn nuôi, việc có sẵn dữ liệu định lượng thời gian thực là rất quan trọng. Loại dữ liệu này được truy cập và nghiên cứu thông qua việc sử dụng Công nghệ Thông tin và Truyền thông (ICT), phân tích dữ liệu, máy học (ML) và các hệ thống điều khiển [1].

Vì con người dựa vào động vật để đáp ứng nhu cầu về các sản phẩm sữa, nên việc duy trì sức khỏe của những động vật này trở nên rất quan trọng. Do một số bệnh có thể lây truyền từ động vật sang người, nên việc dự đoán sớm tình trạng sức khỏe và bệnh tật của gia súc có ý nghĩa quan trọng [2]. Tuy nhiên, các khía cạnh khác nhau liên quan đến chăn nuôi bò sữa, bao gồm vắt sữa, cho ăn, sinh sản và sức khỏe, thường được coi là các thực thể riêng biệt. Do đó, đảm bảo một cuộc sống khỏe mạnh cho từng cá thể động vật đã trở thành một nhiệm vụ khó khăn. Trong kỷ nguyên hiện tại, đổi mới đóng một vai trò then chốt trong các hệ thống chăm sóc sức khỏe. Trong số các lĩnh vực có những tiến bộ đáng kể trong những năm gần đây, chăn nuôi bò sữa điện tử nổi bật là đặc biệt quan trọng [3]. Các công nghệ hiện đại, chẳng hạn như cảm biến, dữ liệu lớn và ML, mang đến một cơ hội mới cho nông dân. Thay vì chỉ phản ứng với bệnh tật khi chúng trở nên rõ ràng, các công nghệ này cho phép giám sát liên tục các chỉ số phúc lợi động vật quan trọng, bao gồm vận động, nhiệt độ, nhịp mạch và độ ẩm. Thông qua việc thu thập dữ liệu liên tục được hỗ trợ bởi cảm biến và khả năng dự đoán của ML, nông dân giờ đây có thể chủ động xác định, dự đoán và ngăn ngừa bệnh gia súc trước khi dịch bệnh bùng phát trên diện rộng và các tổn thất thảm khốc xảy ra.

Loại hệ thống này mang lại lợi ích kép cho nông dân. Thứ nhất, nó cho phép một số lượng ít nông dân hơn quản lý hiệu quả một số lượng động vật lớn hơn, dẫn đến giảm chi phí sản xuất. Thứ hai, hệ thống có khả năng thông báo cho nông dân về các bệnh tiềm ẩn ngay cả

trước khi chúng đến giai đoạn lâm sàng. Cảnh báo sớm này trao quyền cho nông dân thực hiện các biện pháp kịp thời [4]. Những kỹ thuật sáng tạo được áp dụng trong lĩnh vực chăn nuôi bò sữa này giới thiệu các phương pháp tiếp cận mới có thể nâng cao và cải thiện các quy trình ra quyết định trong tương lai.

Bất chấp những tiến bộ trong nghiên cứu, việc ứng dụng thực tế các công nghệ này vẫn chưa được hiện thực hóa đầy đủ. Hiện tại, các bác sĩ thú y chủ yếu đánh giá các thông số vật lý của động vật thông qua các phương pháp thủ công. Người chăn nuôi gia súc phải đối mặt với những thách thức đáng kể khi giám sát sức khỏe gia súc. Điều này nhấn mạnh sự cần thiết quan trọng của việc chuyển đổi kiến thức lý thuyết thành các hệ thống thực tế hoạt động được.

1.2 KHÁI NIỆM VỀ CHĂN NUÔI GIA SÚC CHÍNH XÁC

Chăn nuôi gia súc chính xác (PLF) là một cách tiếp cận năng động để giám sát, liên quan đến việc quan sát liên tục động vật thông qua nhiều phương pháp khác nhau, chẳng hạn như giám sát hành vi, phân tích thành phần và sản lượng sữa, phân tích video, đánh giá hồ sơ và giám sát sinh lý [5]. PLF liên quan đến việc giám sát sức khỏe liên tục cho động vật bằng các phương pháp như phân tích camera và hình ảnh, phân tích âm thanh và cảm biến. Những công cụ này có thể là thiết bị đeo được, tích hợp với máy vắt sữa, độc lập hoặc là một phần của phần mềm quản lý, tất cả đều nhằm mục đích nâng cao sức khỏe động vật trong công nghệ chăn nuôi bò sữa chính xác [6].

Sự khởi đầu của PLF có thể được bắt nguồn từ việc giới thiệu đồng hồ đo sữa điện tử cá nhân cho bò sữa vào những năm 1970 và đầu những năm 1980. Tiếp theo đó là việc triển khai phát hiện động dục dựa trên hành vi, thẻ ghi nhận nhai lại và máy phân tích sữa trực tuyến thời gian thực [7]. Nhiều phát triển tiên phong trong PLF bắt nguồn từ châu Âu, đặc biệt là các quốc gia như Vương quốc Anh, Bỉ, Đức, Đan Mạch, Hà Lan, Phần Lan và Israel [1].

PLF mở ra một con đường đầy hứa hẹn để đạt được sản xuất chăn nuôi bền vững, đòi hỏi sự hợp tác xuyên suốt các ngành nghiên cứu đa dạng. Mục tiêu là chuyển đổi những tiến bộ công nghệ thành những hiểu biết thực tế, có thể hành động được cho nông dân, trang bị cho họ khả năng đưa ra những lựa chọn sáng suốt [8].

Hiện tại, PLF chủ yếu mang lại lợi ích cho các động vật lớn hơn, chẳng hạn như bò sữa, bò thịt và ngựa, nơi lợi nhuận kinh tế biện minh cho khoản đầu tư vào các thẻ giám sát [7]. Các giải pháp PLF đáng tin cậy có thể nâng cao phúc lợi và năng suất động vật, thúc đẩy những tiến bộ trong lĩnh vực này vì lợi ích của cả gia súc và sức khỏe tổng thể của chúng [9]. Khi công nghệ PLF trở nên tiết kiệm chi phí hơn, tiềm năng mang lại giá trị gia tăng cho các bên liên quan, đặc biệt là nông dân, trở nên rõ ràng. Nó tạo điều kiện thuận lợi cho những cải thiện về phúc lợi động vật, sức khỏe, hiệu quả và tác động môi trường [10]. Bằng cách kết hợp phần cứng và phần mềm thông minh, những hiểu biết có giá trị được trích xuất từ các nguồn dữ liệu đa dạng, trao quyền cho nông dân cải thiện sức khỏe, phúc lợi, năng suất và đóng góp vào môi trường của động vật [11]. Một trong những mục tiêu quan

trọng nhất của PLF là hướng tới sự sung túc của động vật [12]. Do đó, các công nghệ PLF mang đến cơ hội để phát triển hơn nữa hiệu quả và nhận biết các vấn đề y tế ở giai đoạn đầu.

Những "công nghệ thông minh" này được thiết kế để hỗ trợ người chăn nuôi gia súc giám sát phúc lợi động vật hiện đang là chủ đề nghiên cứu nổi bật. Nhiều quốc gia đã và đang phân bổ nguồn lực đáng kể cho sự phát triển của chúng, với mục tiêu chuyển đổi sang các phương pháp bền vững hơn trong chăn nuôi gia súc.

1.3 TẦM QUAN TRỌNG CỦA MÁY HỌC TRONG CHĂN NUÔI GIA SÚC CHÍNH XÁC

Trong nghiên cứu về bò sữa, ML nổi lên như một kỹ thuật đầy hứa hẹn với tiềm năng hỗ trợ nông dân cải thiện việc ra quyết định. Các thuật toán ML có khả năng phân tích các tập dữ liệu tích hợp, do đó tạo điều kiện cho việc quản lý chăn nuôi toàn diện, bao gồm các yếu tố ảnh hưởng thiết yếu trong hệ thống phức tạp của gia súc, bao gồm cả bò cái [13]. Bằng cách sử dụng các thuật toán ML, khả thi để dự đoán hành vi tiêu chuẩn của động vật và đưa ra cảnh báo khi hành vi quan sát được lệch khỏi các ngưỡng được xác định trước.

Trong lĩnh vực chăn nuôi gia súc, ML đã được sử dụng hiệu quả để dự đoán các kết quả như kết quả sinh sản, số lượng tế bào soma cao và thời điểm đẻ. Việc sử dụng "dữ liệu lớn" trong y học động vật nuôi đã được mở rộng, và việc chuyển đổi nó thành "dữ liệu thông minh" đang được quan tâm, cho phép tối đa hóa các nguồn tài nguyên dữ liệu hiện có. Ngoài ra, các chuyên gia hiện đầu tư thời gian đáng kể vào việc phân tích và diễn giải dữ liệu để đưa ra chẩn đoán lâm sàng. Trong khi một người có thể cần 30–60 phút để phân tích toàn diện tất cả dữ liệu có sẵn và xác định các bệnh như viêm vú, thì một hệ thống ML có thể hoàn thành nhiệm vụ này trong vòng vài giây. Quy trình chẩn đoán nhanh chóng, đơn giản này có thể được thực hiện thường xuyên, dẫn đến các báo cáo chẩn đoán nhất quán hơn [14]. Các thuật toán ML có thể lưu trữ dữ liệu danh mục và phân tích các tập dữ liệu khổng lồ mà khó có thể đánh giá bằng các phương pháp thống kê truyền thống. Do đó, các nhà thống kê cho rằng các thuật toán ML tạo ra kết quả tốt hơn vì chúng học từ dữ liệu được trình bày, trong khi các phương pháp phân tích truyền thống bị lệch bởi giả thuyết của nhà nghiên cứu [13].

Do đó, ML nắm giữ tiềm năng đáng kể như một công cụ giá trị cho PLF, hỗ trợ nông dân bảo vệ phúc lợi động vật của họ.

1.4 TỔNG QUAN TÀI LIỆU

Trong phần này, chúng tôi sẽ trình bày tổng quan tài liệu để khám phá sự kết hợp giữa Internet vạn vật (IoT) và ML trong lĩnh vực chăn nuôi gia súc. Bằng cách phân tích nhiều tác phẩm học thuật, bài tổng quan này nhằm làm sáng tỏ bối cảnh nghiên cứu, những tiến bộ và ứng dụng hiện tại tại giao điểm đổi mới này. Mục tiêu của chúng tôi là nhấn mạnh tầm quan trọng của IoT và ML trong việc nâng cao quản lý chăn nuôi, giám sát sức khỏe và năng suất. Thông qua việc xem xét này, chúng tôi xác định các xu hướng, thách thức và

triển vọng mới nổi trong lĩnh vực đang phát triển này, đưa ra những hiểu biết sâu sắc về các hướng đi tiềm năng cho nghiên cứu và phát triển trong tương lai.

Swain và cộng sự. [15] đã giới thiệu một thiết bị ứng dụng thời gian thực cho phép nông dân theo dõi và đánh giá các chỉ số sức khỏe hiện tại của gia súc bằng cách so sánh chúng với các thông số khỏe mạnh đã được thiết lập, đóng vai trò là đường cơ sở để xác định tình trạng suy giảm tiềm ẩn trong phúc lợi động vật. Hệ thống sử dụng nhiều loại cảm biến khác nhau, bao gồm cảm biến độ ẩm và nhiệt độ, cảm biến mạch và cảm biến nhai lại, cùng với mô-đun Xbee và phần mềm Arduino 1.0.6. Kết quả thành công, đạt tỷ lệ chính xác 72%–75% trong việc phát hiện tình trạng sức khỏe của bò.

Trong một nghiên cứu được thực hiện bởi Borchers và cộng sự. [16], các thiết bị giám sát hoạt động, nằm và nhai lại tự động đã được sử dụng để đánh giá hành vi trước khi sinh và dự đoán thời điểm đẻ ở bò sữa. Nghiên cứu đánh giá tính hữu ích của các phương pháp tiếp cận ML như phân tích biệt thức tuyến tính, Random Forest và mạng nơ-ron trong việc dự đoán thời điểm đẻ. Thông qua việc sử dụng kỹ thuật mạng nơ-ron, một sự kết hợp của các biến số về hoạt động, thời gian nhai lại và hành vi nằm đã được phân tích, dẫn đến việc tạo ra các cảnh báo chính xác và nhạy cảm.

Liakos và cộng sự. [17] đã trình bày một phân tích tính toán tích hợp mới để dự đoán tình trạng què ở gia súc bằng kỹ thuật ML. Nghiên cứu kết hợp các yếu tố như số bước mỗi ngày, tổng quãng đường đi bộ mỗi ngày, thời gian nằm mỗi ngày và tần suất ăn mỗi ngày như các yếu tố đóng góp. Thuật toán mới được phát triển đã được thử nghiệm trên các tập dữ liệu chứa cả mẫu gia súc khỏe mạnh và không khỏe mạnh. Mục tiêu chính của việc sử dụng bốn tính năng này là để phân biệt và tách các mẫu một cách hiệu quả. Trong số các phương pháp ML được sử dụng, Random Forest mang lại kết quả hứa hẹn nhất.

Cowton và cộng sự. [18] đã nghĩ ra và đánh giá một phương pháp học sâu sử dụng Tối ưu hóa Bầy đàn (PSO) để giám sát sức khỏe gia súc. Phương pháp luận này đã được sử dụng cụ thể bằng cách tận dụng dữ liệu cảm biến môi trường để cho phép xác định sớm bệnh hô hấp ở lợn đang phát triển. Một mô hình tự mã hóa được xây dựng bằng cách sử dụng hai mạng nơ-ron hồi tiếp (RNN). Kết quả của nghiên cứu nhấn mạnh rằng những thay đổi trong môi trường có thể gây ra các dấu hiệu của bệnh hô hấp ở lợn trong một khoảng thời gian ngắn đáng kinh ngạc từ 1–7 ngày.

Kumari và Yadav [19] đã sử dụng Raspberry Pi 3 model làm bộ điều khiển trung tâm để điều tra các chỉ số quan trọng ảnh hưởng đến sức khỏe gia súc, bao gồm nhiệt độ cơ thể, nhịp tim và nhai lại. Thông qua việc sử dụng IoT, một cơ sở dữ liệu dựa trên đám mây đã được thiết lập, cho phép dữ liệu được chụp có thể truy cập trực tuyến từ bất kỳ đâu. Dữ liệu này có thể được truy cập bởi một nông dân hoặc chủ trang trại bò sữa bằng ứng dụng Android trên điện thoại thông minh của họ, hoặc thay vào đó, họ có thể nhận thông báo qua email để dễ dàng truy cập theo dõi sức khỏe động vật của mình.

Pratama và cộng sự. [20] đã đề xuất việc phát triển một thiết bị vòng cổ có khả năng ghi lại nhiệt độ cơ thể, nhịp tim và chuyển động của gia súc. Ngoài ra, họ đã thiết kế một trạm

cơ sở để quản lý máy chủ cục bộ và một ứng dụng web để hiển thị dữ liệu, tạo điều kiện thuận lợi cho việc phân tích các vấn đề sức khỏe gia súc. Để phân loại kết quả sức khỏe thành các danh mục bình thường, hơi bất thường và bất thường nghiêm trọng bằng cách sử dụng dữ liệu thu thập từ các cảm biến, các thuật toán ML đã được sử dụng.

Benjamin và Yik [21] đã giải thích các thuật toán ML khác nhau, cung cấp một cái nhìn tổng quan toàn diện về tài liệu hiện có và thảo luận về các ứng dụng tiềm năng của các công nghệ này để nâng cao sức khỏe lợn. Trọng tâm của họ tập trung vào các cảm biến thiết yếu và hệ thống mạng cảm biến có thể đóng góp vào những tiến bộ trong lĩnh vực này. Vyas và cộng sự. [22] đã sử dụng IoT để phát hiện bệnh lở mồm long móng và viêm vú ở bò. Các kỹ thuật ML đã được sử dụng để phát hiện các rối loạn này bằng cách sử dụng một loạt các cảm biến để phân biệt nhiều yếu tố ở động vật, chẳng hạn như nhiệt độ, chuyển động và âm thanh.

Xu và cộng sự. [23] nhằm mục đích điều tra tính khả thi của việc phân cụm trạng thái trao đổi chất của từng con bò trong giai đoạn đầu cho con bú dựa trên giá trị huyết tương. Họ cũng đánh giá hiệu quả của các thuật toán ML trong việc dự đoán tình trạng trao đổi chất bằng cách sử dụng dữ liệu bò tại trang trại. Nghiên cứu đã phân tích tám thuật toán ML thường được sử dụng, bao gồm K-Nearest Neighbor, Support Vector Machine, Decision Tree, Naive Bayes, Bayesian Network, Mạng nơ-ron nhân tạo (ANN), Bootstrap Aggregation và Random Forest. Từ phân tích của họ, hai thuật toán thành công nhất trong việc dự đoán tình trạng trao đổi chất bằng cách sử dụng dữ liệu tại trang trại là Support Vector Machine và Random Forest.

Chaudhry và cộng sự. [2] đã tiến hành một nghiên cứu liên quan đến việc so sánh các tính năng do các hệ thống khác nhau cung cấp cùng với các hạn chế của chúng. Nghiên cứu cũng bao gồm một đánh giá về các giải pháp dựa trên công nghệ hiện có và các thiết bị liên quan. Hơn nữa, nghiên cứu đã giới thiệu một hệ thống giám sát sức khỏe động vật thời gian thực dựa trên IoT. Garcia và cộng sự. [24] đã tiến hành một đánh giá tài liệu có hệ thống tập trung vào những tiến bộ gần đây trong việc sử dụng ML trong bối cảnh PLF, với trọng tâm cụ thể vào các phương pháp chăn thả và sức khỏe động vật. Bài đánh giá nhấn mạnh các ứng dụng tiềm năng của ML trong ngành chăn nuôi, phác thảo các cảm biến, phần mềm và kỹ thuật phân tích dữ liệu phổ biến, và giải thích về khả năng tiếp cận ngày càng tăng của các nguồn dữ liệu đa dạng.

Wagner và cộng sự. [25] đã thực hiện nghiên cứu khám phá ứng dụng của ML để xác định hành vi bất thường thông qua giám sát liên tục, sử dụng một viên bolus dạ cỏ để đo pH và dự đoán sự xuất hiện của Nhiễm toan Dạ cỏ Bán cấp (SARA) ở bò. Trong nghiên cứu của họ, họ đã sử dụng các kỹ thuật ML, bao gồm Cây quyết định cho Hồi quy (DTR), Perceptron đa lớp (MLP), K-Nearest Neighbors cho Hồi quy (KNNR) và Bộ nhớ Ngắn hạn Dài (LSTM). Kết quả chỉ ra rằng KNNR đạt hiệu suất cao nhất, phát hiện thành công 83% các sự cố SARA.

Unold và cộng sự. [26] đã giới thiệu Hệ thống Giám sát Sức khỏe Bò tập trung vào phân loại hành vi của bò sữa, cụ thể nhắm vào việc phát hiện động dục. Nghiên cứu sử dụng Hệ

thống Giám sát Sức khỏe Bò bao gồm các thành phần phần cứng, một hệ thống đám mây và một ứng dụng cho người dùng cuối. Sử dụng phân tích cây phân loại, các đặc điểm quan trọng đã được xác định, và thuật toán học cây quyết định C4.5 được áp dụng để phát hiện các hành vi thiết yếu của bò sữa. Hệ thống được phát triển đã chứng minh tính hiệu quả và độ chính xác trong việc giám sát hành vi bò sữa để xác định các trạng thái sinh lý cụ thể như động dục hoặc các vấn đề sức khỏe như viêm vú.

Contla Hernández và cộng sự. [27] đã sử dụng phép đo phổ hồng ngoại trung (MIR) để phân tích thành phần sữa bò. Nghiên cứu khám phá tính khả thi của việc xác định bệnh bò bằng cách sử dụng Random Forest, Support Vector Machine, Mạng nơ-ron tích chập, Mạng nơ-ron và các mô hình ensemble. Kết quả tiết lộ rằng việc sử dụng mạng nơ-ron mang lại mức độ chính xác đáng hài lòng trong việc phát hiện các mối quan tâm về sức khỏe.

Sussendran và Balaganesh [28] đã phát triển một Hệ thống Giám sát Sức khỏe Gia súc Thông minh sử dụng cảm biến IoT để dự đoán hiệu quả bệnh gia súc trước thời hạn. Để đảm bảo truyền dữ liệu đáng tin cậy giữa cổng và vòng cổ bò, nghiên cứu đã giới thiệu một mô-đun giám sát sức khỏe dựa trên logic mờ. Hệ thống mà họ đề xuất đã thể hiện hiệu suất vượt trội so với các hệ thống hiện có, thể hiện mức cải thiện 4% về tỷ lệ gửi gói, cải thiện 12% về năng lượng dư và giảm 14% về độ trễ, theo dữ liệu thực nghiệm.

Khi lĩnh vực hệ thống giám sát sức khỏe gia súc dựa trên IoT tiếp tục thu hút sự chú ý, một cái nhìn tổng quan hợp nhất về các bài báo nghiên cứu có liên quan trở nên quan trọng. Trong nỗ lực chắt lọc những tiến bộ, phương pháp luận và phát hiện trong lĩnh vực này, một bản tóm tắt dạng bảng về các công trình nghiên cứu chính đã được biên soạn trong Bảng 1.1 [29]. Sự trình bày dạng bảng này không chỉ nhấn mạnh phổ quan điểm mà còn làm sáng tỏ bối cảnh đang phát triển của việc giám sát sức khỏe gia súc được hỗ trợ bởi IoT.

Tóm lại, bản tóm tắt dạng bảng được trình bày trong Bảng 1.1 chứa đựng một loạt các bài báo nghiên cứu đa dạng, là phần không thể thiếu trong lĩnh vực hệ thống giám sát sức khỏe gia súc dựa trên IoT. Sự tổng hợp này không chỉ làm nổi bật chiều rộng của các phương pháp nghiên cứu được sử dụng mà còn nhấn mạnh vai trò then chốt của công nghệ IoT trong chăn nuôi gia súc hiện đại. Sự kết hợp của những hiểu biết sâu sắc này không chỉ làm giàu thêm sự hiểu biết của chúng ta về các ứng dụng IoT trong sức khỏe gia súc mà còn đặt nền móng cho những tìm hiểu sâu sắc hơn trong lĩnh vực mới nổi này.

BẢNG 1.1

Tóm tắt các Bài báo Nghiên cứu về Ứng dụng IoT để Giám sát Sức khỏe Vật nuôi

Tài liệu tham khảo	Mục tiêu Nghiên cứu	Các Thông số Quan sát	Phần cứng Được sử dụng	Quan sát
Swain và cộng sự. [15]	Giới thiệu một thiết bị để giám sát các thông số	Nhịp tim, nhiệt độ, nhai lại và độ ẩm cơ thể	Arduino NANO, mô-đun Xbee và sự	Độ chính xác (72%-75%) không cao do

Tài liệu tham khảo	Mục tiêu Nghiên cứu	Các Thông số Quan sát	Phần cứng Được sử dụng	Quan sát
	sức khỏe của gia súc để phát hiện bất kỳ sự suy giảm nào trong sức khỏe gia súc		kết hợp của các cảm biến	sự đơn giản của hệ thống được phát triển.
Benjamin và Yik [21]	Giới thiệu các thuật toán ML và tài liệu về các cảm biến liên quan dựa trên các tiêu chí kiểm tra phúc lợi lợn trong ngành và giải thích cách các ứng dụng này có thể được sử dụng để cải thiện phúc lợi lợn	Âm thanh, nhiệt và chuyển động	Cảm biến từ xa như camera, micro, nhiệt kế và gia tốc kế	PLF có thể cung cấp cho nhà sản xuất thông tin về phúc lợi của toàn bộ đàn cũng như từng cá thể động vật bằng cách thu thập và phân tích một lượng lớn dữ liệu.
Eckelkamp [5]	Trình bày vai trò của công nghệ chăn nuôi bò sữa chính xác có thể đeo được (WPDT) trong việc phát hiện tình trạng què, viêm vú, rối loạn chuyển hóa và viêm niêm mạc tử cung	Máy ăn, thời gian nhai lại, thời gian ăn, thời gian nằm, thời gian đứng, thời gian đi bộ, hoạt động, chuyển đổi từ nằm sang đứng, nhiệt độ và pH dạ cỏ	Công nghệ chính xác có thể đeo như vòng cổ, dây đeo thân và thẻ chân	Một số công nghệ có thể đeo có sẵn để phát hiện bệnh ở động vật, nhưng cần độ nhạy và độ đặc hiệu mạnh hơn.
Pratama và cộng sự. [20]	Tạo ra các kết quả phân loại sức khỏe bình thường, ít bình thường và bất thường dựa trên	Nhiệt độ cơ thể, nhịp tim và chuyển động	Thiết bị vòng cổ để đọc nhiệt độ cơ thể, cảm biến nhịp tim và cảm biến chuyển động,	Hệ thống dự đoán được tạo ra có thể làm cho sức khỏe của nhịp tim và nhiệt độ cơ thể

Tài liệu tham khảo	Mục tiêu Nghiên cứu	Các Thông số Quan sát	Phần cứng Được sử dụng	Quan sát
	dữ liệu thu thập bằng cảm biến và phân loại bằng ML		Raspberry Pi, trạm cơ sở để quản lý máy chủ cục bộ và ứng dụng web để trực quan hóa dữ liệu và điều kiện sức khỏe phân tích	trở nên bình thường, ít bình thường và bất thường, với độ chính xác 84% khi sử dụng Support Vector Machine (SVM) và 91% độ chính xác khi sử dụng Cây quyết định (DT).
Priya và Jayaram [3]	Mô tả các cảm biến độc đáo liên quan đến mạng cảm biến không dây để giám sát tình trạng sức khỏe của gia súc	Nhiệt độ, chuyển động và nhịp tim	Mô-đun cảm biến, RL78, GSM và ứng dụng Android	Một khuôn khổ để giám sát sức khỏe động vật đã được đề xuất.
Vyas và cộng sự. [22]	Phản ánh về việc phát hiện bệnh lở mồm long móng và bệnh viêm vú ở bò sử dụng Internet vạn vật (IoT)	Nhiệt độ, chuyển động, âm thanh, v.v.	Cảm biến nhai lại, cảm biến chuyển động, cảm biến nhiệt độ và bộ điều khiển Raspberry Pi3	Việc sử dụng IoT trong việc phát hiện viêm vú và FMD làm giảm chất lượng sữa kém và vô sinh ở bò.
Chaudhry và cộng sự. [2]	Đánh giá các giải pháp dựa trên công nghệ hiện có và thiết bị liên quan và cung cấp sự so sánh các tính năng do các hệ thống này cung cấp và các hạn chế của chúng	Nhiệt độ da, thời gian nhai lại và nhịp tim, tính biến thiên của nó	Đơn vị cảm biến dựa trên IoT để đo lường các thông số liên quan đến sức khỏe khác nhau	ML có thể được áp dụng để phát hiện tình trạng què ở gia súc, Mô hình Hồi quy Tuyến tính để dự đoán sản lượng sữa, và thị giác máy tính và học sâu có thể được sử

Tài liệu tham khảo	Mục tiêu Nghiên cứu	Các Thông số Quan sát	Phần cứng Được sử dụng	Quan sát
				dụng để phân tích các yếu tố sức khỏe.
Unold và cộng sự. [26]	Trình bày một hệ thống giám sát vật nuôi dựa trên IoT để tự động hóa việc đo lường tình trạng sức khỏe bò sữa	Cho ăn, nhai lại, nghỉ ngơi và di chuyển	Thiết bị bò bao gồm cảm biến, trung tâm, điểm truy cập Wi-Fi và bộ định tuyến, cơ sở dữ liệu và máy chủ ứng dụng	Giám sát chính xác hành vi của bò sữa và phát hiện một số vấn đề sức khỏe (ví dụ: viêm vú, động dục).
Neethirajan [4]	Khám phá vai trò của cảm biến, dữ liệu lớn, trí tuệ nhân tạo (AI) và ML để giảm chi phí sản xuất, tăng hiệu quả, nâng cao phúc lợi động vật	Tín hiệu giọng nói của động vật, dữ liệu trực quan về các chuyển động khác nhau của động vật và dữ liệu hành vi động vật khác như vậy	Cảm biến phần cứng như cảm biến camera hoặc thị giác, cảm biến hình ảnh nhiệt hồng ngoại, cảm biến nhiệt độ, thẻ RFID, gia tốc kế, cảm biến chuyển động, máy đếm bước chân, cảm biến thị giác máy nhận dạng khuôn mặt và micro	Các thuật toán AI và ML tiên tiến có thể được áp dụng để phát hiện bệnh và giám sát động vật.
Sussendran và Balaganesh [28]	Dự đoán chính xác bệnh của gia súc bằng cách sử dụng Hệ thống Giám sát Sức khỏe Gia súc Thông minh dựa trên logic mờ sử dụng cảm biến IoT	Nhịp tim, nhiệt độ cơ thể, nhịp mạch, nhai lại và thông tin hô hấp	Cảm biến, mô-đun Wi-Fi, Arduino	Hệ thống đề xuất đạt tỷ lệ gửi gói cao hơn 4%, độ trễ ít hơn 14% và năng lượng dư cao hơn 12% so với các hệ thống hiện có.

Tóm lại, bản tóm tắt dạng bảng được trình bày trong Bảng 1.1 tổng hợp một loạt các bài báo nghiên cứu đa dạng, là phần không thể thiếu trong lĩnh vực hệ thống giám sát sức khỏe gia súc dựa trên IoT. Sự tổng hợp này không chỉ làm nổi bật chiều rộng của các phương pháp nghiên cứu được sử dụng mà còn nhấn mạnh vai trò then chốt của công nghệ IoT trong chăn nuôi gia súc hiện đại. Sự kết hợp của những hiểu biết sâu sắc này không chỉ làm giàu thêm sự hiểu biết của chúng ta về các ứng dụng IoT trong sức khỏe gia súc mà còn đặt nền móng cho những tìm hiểu sâu sắc hơn trong lĩnh vực mới nổi này.

1.5 KHOẢNG TRỐNG NGHIÊN CỨU

Tổng quan tài liệu đã phát hiện ra những khoảng trống nghiên cứu sau trong các hệ thống hiện tại:

i. *Thiếu nhận thức của nông dân về gia súc bị bệnh:* Do không có thông báo kịp thời về những thay đổi bất thường trong sức khỏe gia súc, nông dân thường không biết về bất kỳ bệnh tật tiềm ẩn nào. Sự thiếu nhận thức này cản trở khả năng điều trị kịp thời của họ, có khả năng làm trầm trọng thêm mức độ nghiêm trọng của bệnh.

ii. *Nhu cầu về các tập dữ liệu toàn diện:* Một khoảng trống nghiên cứu đáng chú ý khác liên quan đến nhu cầu về các tập dữ liệu đáng kể. Việc sử dụng các kỹ thuật ML để dự đoán dữ liệu trên các khía cạnh khác nhau của chăn nuôi bò sữa đã được quan sát thấy trong các hệ thống hiện có. Tuy nhiên, độ chính xác của các thuật toán được tạo ra phụ thuộc vào sự sẵn có của các tập dữ liệu tích hợp rộng lớn. Bằng cách phân tích các tập dữ liệu toàn diện, có quy mô lớn, có thể tăng cường các hệ thống hỗ trợ ra quyết định cho nông dân, từ đó cho phép họ nâng cao phúc lợi và năng suất của đàn gia súc.

iii. *Nâng cao hiệu suất phân loại của thuật toán ML:* Một khoảng trống nghiên cứu quan trọng liên quan đến nhu cầu nâng cao hiệu suất phân loại của các thuật toán ML. Các cảm biến thương mại có khả năng theo dõi sức khỏe và sinh lý của bò sữa đang tồn tại. Tuy nhiên, vẫn còn sự mơ hồ về hiệu quả của việc hỗ trợ quyết định có được từ các cảm biến này do sự sẵn có hạn chế của các nghiên cứu tập trung vào hiệu quả của các thuật toán cơ bản. Điều này nhấn mạnh thách thức trong việc cải thiện và dự đoán hiệu suất phân loại của các thuật toán trong lĩnh vực PLF. Mặc dù tiềm năng của ML đã được các nhà nghiên cứu công nhận rộng rãi, nhưng vẫn cần thiết phải sử dụng hợp tác các công cụ mạnh mẽ này cùng với các nhà khoa học dữ liệu và ngành công nghiệp sữa để nắm bắt đầy đủ ý nghĩa thực sự của chúng.

1.6 PHÂN TÍCH SO SÁNH

Trong lĩnh vực hệ thống giám sát sức khỏe gia súc dựa trên IoT, một loạt các nghiên cứu đa dạng đã xuất hiện, mỗi nghiên cứu đóng góp những hiểu biết và tiến bộ độc đáo của riêng mình. Để chắt lọc sự giàu có kiến thức này và cung cấp một đánh giá có cấu trúc về các nghiên cứu này, chúng tôi trình bày một phân tích so sánh toàn diện. Mục đích của phân tích này là cung cấp cho người đọc một cái nhìn tổng quan có hệ thống về các bài báo

nghiên cứu chính, làm sáng tỏ những điểm mạnh và hạn chế riêng của chúng trong nhiệm vụ nâng cao sức khỏe gia súc thông qua công nghệ IoT. Mục tiêu của chúng tôi là tổng hợp những phát hiện này, giúp người đọc hiểu sâu hơn về bối cảnh đang phát triển của việc giám sát sức khỏe gia súc được hỗ trợ bởi IoT và xác định các hướng đi đầy hứa hẹn cho nghiên cứu và phát triển trong tương lai. Trong Bảng 1.2, chúng tôi trình bày bản tóm tắt dạng bảng về các công trình nghiên cứu này để tiện tham khảo và đánh giá.

BẢNG 1.2 Phân tích So sánh các Bài báo Nghiên cứu về Hệ thống Giám sát Sức khỏe Vật nuôi dựa trên IoT

Bài báo Nghiên cứu	Điểm mạnh	Điểm yếu
Swain và cộng sự. [15]	• Sử dụng cảm biến toàn diện (độ ẩm, nhiệt độ, mạch, nhai lại) • Đạt độ chính xác 72%–75% trong việc phát hiện sức khỏe bò	• Sử dụng phần mềm cũ (Arduino 1.0.6) • Khám phá hạn chế về kỹ thuật ML
Borchers và cộng sự. [16]	• Máy giám sát hoạt động, nằm, nhai lại tự động • Khám phá ML (phân tích biệt thức tuyến tính, Random Forest, mạng nơ-ron)	• Tập trung chủ yếu vào dự đoán thời điểm đẻ • Thảo luận hạn chế về khả năng tiếp cận và quản lý dữ liệu
Liakos và cộng sự. [17]	• Cách tiếp cận toàn diện với các chỉ số sức khỏe khác nhau • Kết quả hứa hẹn với Random Forest	• Tập trung chủ yếu vào dự đoán tình trạng què • Thảo luận hạn chế về xử lý dữ liệu thời gian thực và khả năng tiếp cận dữ liệu
Cowton và cộng sự. [18]	• Sử dụng học sâu để phát hiện bệnh hô hấp • Phản ứng nhanh, phát hiện bệnh trong vòng 1–7 ngày	• Chỉ tập trung vào lợn • Thiếu nhấn mạnh vào khả năng tiếp cận và quản lý dữ liệu
Kumari và Yadav [19]	• Cơ sở dữ liệu dựa trên đám mây để truy cập dữ liệu từ xa • Điều tra các chỉ số sức khỏe gia súc quan trọng	• Thảo luận hạn chế về ML để phân tích dữ liệu • Khả năng mở rộng bị ảnh hưởng bởi Raspberry Pi 3 làm bộ điều khiển trung tâm
Pratama và cộng sự. [20]	• Thiết bị vòng cổ và ML để phân loại sức khỏe • Ứng dụng web để hiển thị và phân tích dữ liệu	• Thiếu chi tiết về kỹ thuật ML và tỷ lệ chính xác • Khám phá hạn chế về các loại cảm biến
Benjamin và Yik [21]	• Tổng quan tài liệu toàn diện về sức khỏe lợn với IoT • Thảo luận về các	• Không có nghiên cứu hoặc thí nghiệm ban đầu được thực hiện • Không tập trung

Bài báo Nghiên cứu	Điểm mạnh	Điểm yếu
	ứng dụng tiềm năng để nâng cao sức khỏe động vật	vào các công nghệ cảm biến hoặc kỹ thuật ML cụ thể
Vyas và cộng sự. [22]	• Ứng dụng thực tế với IoT để phát hiện bệnh ở bò • Sử dụng ML để phát hiện rối loạn	• Thảo luận hạn chế về quản lý và khả năng tiếp cận dữ liệu • Tập trung chủ yếu vào các bệnh cụ thể, có thể bỏ lỡ các ứng dụng giám sát sức khỏe rộng hơn

1.7 ĐỊNH HƯỚNG NGHIÊN CỨU TƯƠNG LAI

Sau tổng quan tài liệu toàn diện nêu trên, rõ ràng là bối cảnh của hệ thống giám sát sức khỏe gia súc dựa trên IoT mang lại tiềm năng to lớn đồng thời tiết lộ các lĩnh vực đòi hỏi phải được khám phá và đổi mới thêm. Phần này phác thảo các hướng nghiên cứu trong tương lai trong lĩnh vực hệ thống giám sát sức khỏe gia súc dựa trên IoT.

i. *Tích hợp các cảm biến tiên tiến:* Một hướng đi đầy hứa hẹn cho nghiên cứu trong tương lai liên quan đến việc kết hợp các cảm biến và công nghệ tiên tiến để nâng cao độ chính xác và phạm vi thu thập dữ liệu liên quan đến sức khỏe gia súc. Đi sâu vào việc tích hợp các thiết bị đeo được, vòng cổ thông minh và cảm biến có thể nuốt được hứa hẹn mang lại sự hiểu biết toàn diện hơn về sức khỏe của từng cá thể động vật.

ii. *Phân tích dự đoán và ML:* Việc phát triển và ứng dụng các thuật toán ML cho phân tích dự đoán trong giám sát sức khỏe gia súc đại diện cho một hướng đi then chốt. Tận dụng dữ liệu lịch sử, các thuật toán này có thể dự báo các vấn đề sức khỏe, cho phép can thiệp chủ động. Tuy nhiên, việc cải tiến các mô hình này để cải thiện độ chính xác và khả năng thích ứng trên các giống gia súc và điều kiện môi trường đa dạng vẫn là một thách thức đáng kể đòi hỏi sự quan tâm.

iii. *Khả năng mở rộng và hiệu quả chi phí:* Khả năng mở rộng vẫn là mối quan tâm tối quan trọng, đặc biệt là đối với nông dân quy mô nhỏ. Quỹ đạo nghiên cứu trong tương lai nên tập trung vào việc khám phá các giải pháp hiệu quả về chi phí có thể được áp dụng liên tục trên các hoạt động chăn nuôi đa dạng. Điều này có thể bao gồm việc điều tra các lựa chọn cảm biến chi phí thấp, các giao thức truyền thông hiệu quả hoặc các giải pháp dựa trên đám mây phù hợp với các ràng buộc tài nguyên khác nhau.

iv. *Giao diện thân thiện với người dùng và ứng dụng di động:* Việc người dùng chấp nhận và tham gia là yếu tố then chốt cho sự thành công của hệ thống giám sát sức khỏe gia súc dựa trên IoT. Bối cảnh nghiên cứu nên ưu tiên nâng cao giao diện người dùng và phát triển các ứng dụng di động tạo điều kiện thuận lợi cho việc giám sát

từ xa và quản lý dữ liệu. Những nỗ lực này nhằm mục đích làm cho hệ thống trở nên dễ tiếp cận và thân thiện với người dùng cho nông dân và bác sĩ thú y.

Tóm lại, các hướng đi trong tương lai đánh dấu cơ hội để thúc đẩy lĩnh vực hệ thống giám sát sức khỏe gia súc dựa trên IoT. Khám phá các lĩnh vực nghiên cứu này sẽ không chỉ đóng góp vào phúc lợi vật nuôi và tính bền vững của các phương pháp chăn nuôi gia súc mà còn thúc đẩy việc tích hợp công nghệ tiên tiến vào nông nghiệp, làm cho ngành công nghiệp này hiệu quả và năng suất hơn.

1.8 THẢO LUẬN

Thông qua một đánh giá toàn diện về các nỗ lực nghiên cứu trước đây trong lĩnh vực này, rõ ràng là có một nhu cầu cấp thiết về một hệ thống tự động có khả năng giám sát sức khỏe động vật theo thời gian thực. Để đáp ứng nhu cầu này, chúng tôi đề xuất một mô hình giải pháp dựa trên IoT nhằm phát hiện bệnh ở bò trong bối cảnh PLF. Hệ thống được đề xuất này được thiết kế để cung cấp cho người chăn nuôi bò sữa các cảnh báo hoặc thông báo kịp thời về bệnh bò, được tạo điều kiện thuận lợi bởi việc thu thập dữ liệu hành vi thông qua giám sát cảm biến thời gian thực. Cách tiếp cận chủ động này không chỉ giúp ngăn chặn sự bùng phát dịch bệnh mà còn giảm thiểu các tổn thất tiềm ẩn phát sinh.

Để sử dụng hiệu quả các mô hình cơ chế trong chăn nuôi bò sữa, việc thu thập các tập dữ liệu rộng lớn và đa dạng trở nên cần thiết. Những tập dữ liệu này có thể được thu thập hiệu quả thông qua việc sử dụng các cảm biến khác nhau. Dự đoán bệnh ở bò sữa có thể đạt được bằng cách triển khai một thiết bị phần cứng dựa trên IoT và tận dụng các thuật toán ML để phân biệt tình trạng sức khỏe của bò. Các bước cần thiết cho quá trình này được phác thảo ngắn gọn như sau:

i. *Thu thập dữ liệu bằng cảm biến:* Dữ liệu thời gian thực từ động vật, chẳng hạn như bò, được thu thập bằng cách sử dụng một loạt các cảm biến phần cứng. Những cảm biến này bao gồm gia tốc kế, cảm biến chuyển động, cảm biến nhịp mạch, cảm biến nhiệt độ và micro. Bộ cảm biến đa dạng này giúp thu thập thông tin toàn diện về hành vi, chuyển động, chỉ số sức khỏe và điều kiện môi trường của động vật.

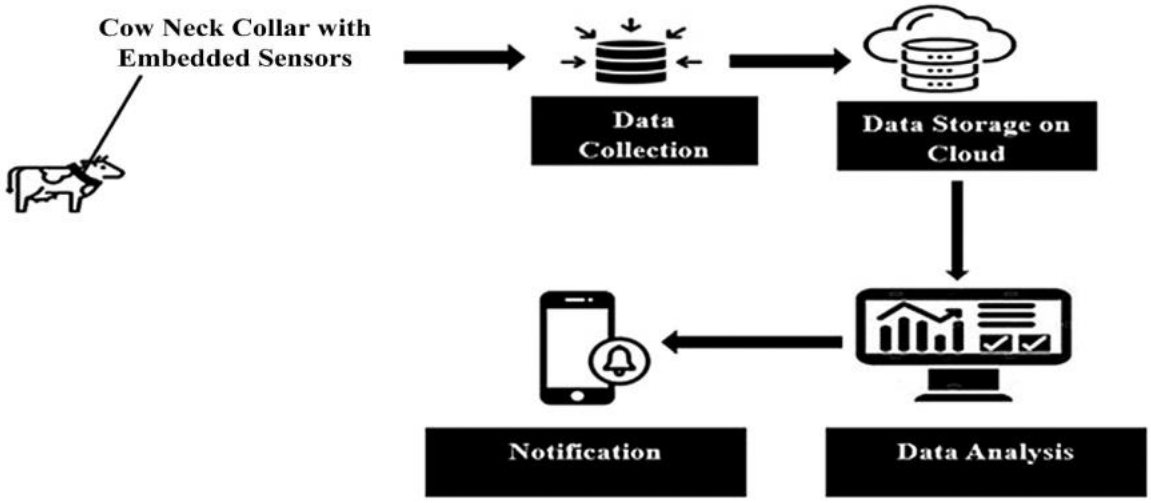
ii. *Truyền dữ liệu đến Raspberry Pi:* Dữ liệu được thu thập bởi các cảm biến sau đó được truyền đến một vi điều khiển Raspberry Pi. Vi điều khiển này được trang bị một mô-đun Wi-Fi tích hợp cho phép chuyển dữ liệu cảm nhận được đến một nền tảng dựa trên đám mây hoặc một máy chủ được chỉ định để phân tích thêm.

iii. *Phân tích ML nâng cao:* Tập dữ liệu rộng thu được từ các cảm biến sau đó được phân tích bằng các thuật toán ML nâng cao. Các thuật toán này tận dụng thông tin thu thập được để phân tích, dự đoán và cung cấp cảnh báo cho nông dân trong trường hợp phát hiện bất kỳ bất thường hoặc mẫu hình bất thường nào. Các thuật toán có thể thực hiện các tác vụ như phân cụm, phân loại và nhận dạng mẫu, điều này rất quan trọng để giám sát và xác định các bệnh tiềm ẩn ở động vật thông qua các kỹ thuật phân tích dữ liệu tinh vi.

iv. *Cảnh báo qua Ứng dụng Di động:* Tình trạng sức khỏe được xác định của bò được thông báo cho nông dân thông qua các cảnh báo được gửi qua một ứng dụng di động chuyên dụng. Những cảnh báo này thông báo cho nông dân về các tình trạng được phát hiện của bò, cho phép can thiệp kịp thời và các hành động cần thiết để đảm bảo phúc lợi động vật.

Về bản chất, quá trình này liên quan đến sự tích hợp của cảm biến, truyền dữ liệu, ML nâng cao và cảnh báo thời gian thực để trao quyền cho nông dân có các phương tiện để quản lý chủ động sức khỏe và phúc lợi của vật nuôi của họ.

Do đó, khi nói đến chăn nuôi gia súc, cảm biến, dữ liệu lớn, AI nâng cao và ML đều đan xen với nhau để cung cấp một giải pháp toàn diện.



HÌNH 1.1 Kiến trúc hệ thống đề xuất để dự đoán bệnh ở bò sữa.

Hình 1.1 biểu diễn bằng sơ đồ kiến trúc hệ thống được đề xuất.

1.9 KẾT LUẬN

Dựa trên phân tích các nghiên cứu hiện có về phát hiện bệnh ở vật nuôi, một số kết luận chính có thể được rút ra. Thứ nhất, gia súc dễ mắc nhiều loại bệnh khác nhau. Thật không may, việc không có thông báo khi có sự biến đổi sức khỏe bất thường có nghĩa là nông dân vẫn không biết về các bệnh tiềm ẩn ảnh hưởng đến gia súc của họ. Do đó, nông dân có thể không điều trị kịp thời, dẫn đến khả năng làm trầm trọng thêm mức độ nghiêm trọng của bệnh. Xem xét bối cảnh của các hệ thống hiện tại cho thấy rằng các phương pháp luận ML thể hiện khả năng dự đoán trên các lĩnh vực khác nhau trong chăn nuôi bò sữa. Tuy nhiên, độ tin cậy của các thuật toán này phụ thuộc vào sự sẵn có của các tập dữ liệu tích hợp rộng lớn. Tiềm năng cho nông dân cải thiện hệ thống hỗ trợ ra quyết định của họ thông qua việc phân tích các tập dữ liệu toàn diện này có thể cải thiện đáng kể sự sung túc và hiệu quả của đàn gia súc của họ. Sự sẵn có của các cảm biến thương mại được thiết kế để giám sát sinh

lý và chỉ số sức khỏe của bò sữa là đáng chú ý. Tuy nhiên, hiệu quả của sự hỗ trợ quyết định được cung cấp bởi các cảm biến này vẫn chưa rõ ràng do sự khan hiếm của dữ liệu được công bố liên quan đến hiệu suất thuật toán cơ bản. Một thách thức quan trọng liên quan đến mệnh lệnh cần dự báo và nâng cao hiệu suất của các thuật toán được sử dụng trong PLF. Mặc dù tiềm năng của ML đã được công nhận rộng rãi, nhưng điều cần thiết là phải triển khai hợp tác các công cụ mạnh mẽ này cùng với nông dân chăn nuôi bò sữa và các nhà khoa học dữ liệu để mở khóa đầy đủ lợi thế của chúng. Nỗ lực tập thể này là rất quan trọng để hiện thực hóa đầy đủ các lợi ích tiềm năng của những cách tiếp cận đổi mới này.

Tài liệu tham khảo

[1] T. M. Banhazi, H. Lehr, J. L. Black, H. Crabtree, P. Schofield, M. Tscharke, and D. Berckmans (2012) Precision livestock farming: an international review of scientific and commercial aspects. International Journal of Agricultural and Biological Engineering 5 (3), 1-9.

[2] A. A. Chaudhry, R. Mumtaz, S. M. H. Zaidi, M. A. Tahir, and S. H. M. School (2020, December). Internet of Things (IoT) and machine learning (ML) enabled livestock monitoring. In 2020 IEEE 17th International Conference on Smart Communities: Improving Quality of Life Using ICT, IoT and AI (HONET), 151-155.

[3] M. K. Priya and B. G. Jayaram (2019) WSN-based electronic livestock of dairy cattle and physical parameters monitoring. In Emerging Research in Electronics, Computer Science and Technology, 37-45.

[4] S. Neethirajan (2020) The role of sensors, big data and machine learning in modern animal farming. Sensing and Bio-Sensing Research 37, 100367.

[5] E. A. Eckelkamp (2019) Invited review: current state of wearable precision dairy technologies in disease detection. Applied Animal Science 35 (2), 209-220.

[6] J. M. Bewley, M. R. Borchers, K. A. Dolecheck, A. R. Lee, A. E. Stone, and C. M. Truman (2017) Precision dairy monitoring technology implementation opportunities and challenges. Large Dairy Herd Management 3, 1251-1264.

[7] I. Halachmi, M. Guarino, J. Bewley, and M. Pastell (2019) Smart animal agriculture: application of real-time sensors to improve animal well-being and production. Annual Review of Animal Biosciences 7, 403-425.

[8] E. Vranken and D. Berckmans (2017) Precision livestock farming for pigs. Animal Frontiers 7 (1), 32-37.

[9] D. Berckmans (2017) General introduction to precision livestock farming. Animal Frontiers 7 (1), 6-11.

[10] J. Schillings, R. Bennett, and D. C. Rose (2021) Exploring the potential of precision livestock farming technologies to help address farm animal welfare. Frontiers in Animal Science 2.

[11] D. Berckmans (2014) Precision livestock farming technologies for welfare management in intensive livestock systems. Revue scientifique et technique 33 (1), 189-196.

[12] J. Pomar, V. Lopez, and C. Pomar (2011) Agent-based simulation framework for virtual prototyping of advanced livestock precision feeding systems. Computers and Electronics in Agriculture 78 (1), 88-97.

[13] Cockburn, M. (2020). Application and prospective discussion of machine learning for the management of dairy farms. *Animals*, 10(9), 1690.

[14] Hyde, R. M., Down, P. M., Bradley, A. J., Breen, J. E., Hudson, C., Leach, K. A., & Green, M. J. (2020). Automated prediction of mastitis infection patterns in dairy herds using machine learning. *Scientific Reports*, 10(1), 1-8.

[15] Swain, K. B., Mahato, S., Patro, M., & Pattnayak, S. K. (2017, May). Cattle health monitoring system using Arduino and LabVIEW for early detection of diseases. In *2017 Third International Conference on Sensing, Signal Processing and Security (ICSSS)* (pp. 79-82). IEEE.

[16] Borchers, M. R., Chang, Y. M., Proudfoot, K. L., Wadsworth, B. A., Stone, A. E., & Bewley, J. M. (2017). Machine-learning-based calving prediction from activity, lying, and ruminating behaviors in dairy cattle. *Journal of Dairy Science*, 100(7), 5664-5674.

[17] Liakos, K., Moustakidis, S. P., Tsiotra, G., Bartzanas, T., Bochtis, D., & Parisses, C. (2017). Machine Learning based computational analysis method for cattle lameness prediction. In *HAICTA* (pp. 128-139).

[18] Cowton, J., Kyriazakis, I., Plotz, T., & Bacardit, J. (2018). A combined deep learning gru-autoencoder for the early detection of respiratory disease in pigs using multiple environmental sensors. *Sensors*, 18(8), 2521.

[19] Kumari, S., & Yadav, S. K. (2018). Development of IoT based smart animal health monitoring system using Raspberry Pi. *International Journal of Advanced Studies of Scientific Research*, 3(8), 24-31.

[20] Pratama, Y. P., Basuki, D. K., Sukaridhoto, S., Yusuf, A. A., Yulianus, H., Faruq, F., & Putra, F. B. (2019, September). Designing of a smart collar for dairy cow behavior monitoring with application monitoring in microservices and internet of things-based systems. In *2019 International Electronics Symposium (IES)* (pp. 527-533). IEEE.

[21] Benjamin, M., & Yik, S. (2019). Precision livestock farming in swine welfare: a review for swine practitioners. *Animals*, 9(4), 133.

[22] Vyas, S., Shukla, V., & Doshi, N. (2019). FMD and mastitis disease detection in cows using Internet of Things (IOT). *Procedia Computer Science*, 160, 728-733.

[23] Xu, W., van Knegsel, A. T., Vervoort, J. J., Bruckmaier, R. M., van Hoeij, R. J., Kemp, B., & Saccenti, E. (2019). Prediction of metabolic status of dairy cows in early lactation with on-farm cow data and machine learning algorithms. *Journal of Dairy Science*, 102(11), 10186-10201.

[24] Garcia, R., Aguilar, J., Toro, M., Pinto, A., & Rodriguez, P. (2020). A systematic literature review on the use of machine learning in precision livestock farming. *Computers and Electronics in Agriculture*, 179, 105826.

[25] Wagner, N., Antoine, V., Mialon, M. M., Lardy, R., Silberberg, M., Koko, J

CHƯƠNG 2: TẦM QUAN TRỌNG CỦA HỌC MÁY TRONG PHÁT HIỆN BỆNH TÁO VÀ NHỮNG ẨN Ý

- **Tác giả:** Saimul Bashir
- **Tổ chức:** Chandigarh University, Mohali, India
- **Đồng tác giả:** Syed Nisar Hussain Bukhari
- **Tổ chức:** National Institute of Electronics and Information Technology (NIELIT), Srinagar, India
- **Đồng tác giả:** Faisal Firdous
- **Tổ chức:** Jaypee University of Information and Technology, Solan, India
- **Đồng tác giả:** Gursimran Jeet Kour
- **Tổ chức:** Chandigarh University, Mohali, India

2.1 GIỚI THIỆU

Táo là một trong những loại trái cây phổ biến nhất trên toàn thế giới, với sản lượng toàn cầu vượt quá 80 triệu tấn vào năm 2020. Tuy nhiên, cây táo dễ bị tổn thương bởi nhiều loại bệnh khác nhau, điều này có thể dẫn đến những tổn thất kinh tế đáng kể cho người trồng. Các bệnh táo phổ biến bao gồm ghẻ táo, bệnh phấn trắng, bệnh cháy lá và bệnh rỉ sét táo tuyết tùng, do nấm, vi khuẩn và vi-rút gây ra. Những bệnh này có thể ảnh hưởng đến chất lượng và số lượng quả được sản xuất, dẫn đến năng suất thấp hơn, tăng chi phí cho người trồng và giảm nhu cầu của người tiêu dùng.

2.1.1 Mô tả tóm tắt các Phương pháp Phát hiện Bệnh Truyền thống

Theo truyền thống, việc phát hiện bệnh táo dựa vào việc chuyên gia kiểm tra trực quan cây trồng, điều này có thể tốn thời gian và chi phí. Phương pháp này cũng mang tính chủ quan và có thể dẫn đến kết quả không nhất quán. Các phương pháp khác, như xét nghiệm trong phòng thí nghiệm và phun hóa chất, cũng được sử dụng nhưng có những hạn chế riêng. Ví dụ, xét nghiệm trong phòng thí nghiệm có thể tốn kém và mất thời gian, trong khi phun hóa chất có thể gây hại cho môi trường và sức khỏe con người.



HÌNH 2.1 Các loại bệnh trên lá táo.

2.1.2 Tầm quan trọng của Học máy trong Phát hiện Bệnh

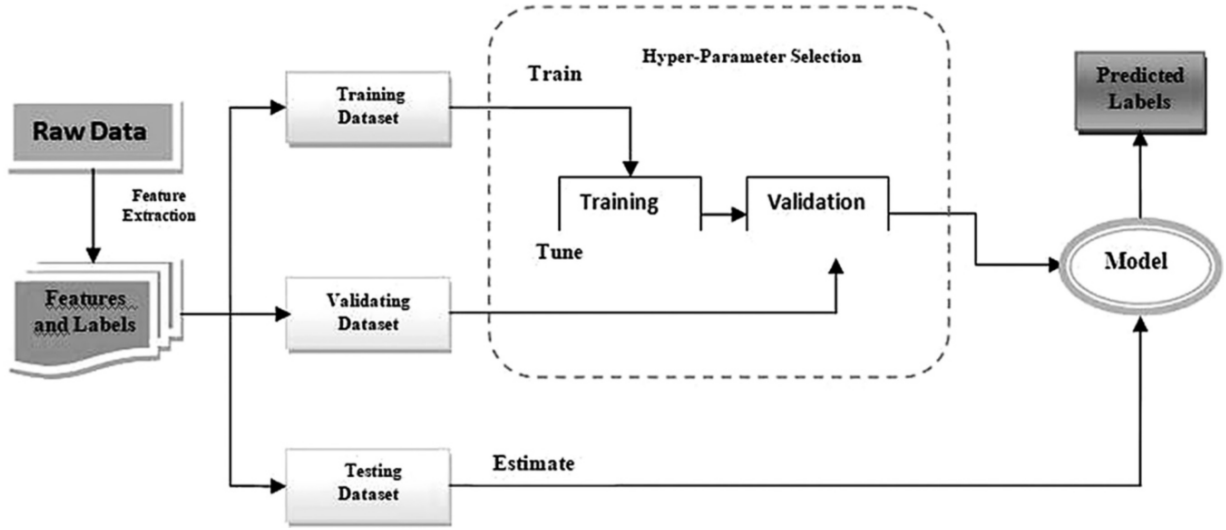
Trong một số ngành công nghiệp, bao gồm chăm sóc sức khỏe, tài chính và quản lý tài nguyên, học máy (ML) đã trở thành một công cụ mạnh mẽ để nhận dạng và quản lý bệnh tật. Công nghệ này sử dụng các thuật toán tiên tiến và mô hình thống kê để phân tích các bộ dữ liệu lớn và xác định các mẫu và mối tương quan mà phân tích thủ công sẽ khó hoặc không thể phát hiện được. Bằng cách này, ML có thể giúp cải thiện độ chính xác và hiệu quả của việc phát hiện bệnh, giảm nguy cơ chẩn đoán sai và điều trị không cần thiết, và cuối cùng là cải thiện kết quả điều trị cho bệnh nhân.

ML có thể được áp dụng trong nông nghiệp để tăng cường hiệu quả và năng suất phát hiện và quản lý bệnh, đồng thời giảm tác động môi trường của các hoạt động nông nghiệp và nâng cao tính bền vững và lợi nhuận của hoạt động canh tác. Cụ thể, các mô hình ML có thể được đào tạo để phân tích các bộ dữ liệu lớn về hình ảnh, kết quả đo cảm biến và các loại dữ liệu khác nhằm xác định sự hiện diện và mức độ nghiêm trọng của bệnh ở các loại cây trồng như táo.

Khả năng học hỏi và thích ứng theo thời gian của ML làm cho nó trở thành một trong những tính năng hữu ích nhất cho chẩn đoán bệnh. Khi thuật toán tiếp xúc với nhiều dữ liệu hơn, nó có thể cải thiện độ chính xác và trở nên hiệu quả hơn trong việc xác định các mẫu và mối tương quan tinh vi. Điều này đặc biệt hữu ích trong bối cảnh phát hiện bệnh táo, nơi các bệnh mới và đang nổi lên có thể khó xác định bằng các phương pháp truyền thống. Bằng cách tận dụng sức mạnh của ML, chúng ta có thể nâng cao năng lực xác định và ứng phó với những mối nguy hiểm mới này, từ đó bảo vệ sức khỏe và sản lượng thu hoạch táo.

Một lợi thế quan trọng khác là khả năng của ML trong việc phân tích khối lượng dữ liệu khổng lồ một cách chính xác và nhanh chóng. Trong bối cảnh nông nghiệp, điều này có thể đặc biệt quan trọng, vì việc phát hiện và quản lý bệnh kịp thời có thể có tác động đáng kể đến năng suất cây trồng và lợi nhuận. Bằng cách sử dụng các mô hình ML để phân tích các bộ dữ liệu lớn về hình ảnh, kết quả đo cảm biến và các loại dữ liệu khác, chúng ta có thể nhanh chóng và chính xác xác định sự hiện diện và mức độ nghiêm trọng của bệnh ở các loại cây trồng như táo, cho phép đưa ra các chiến lược quản lý kịp thời và hiệu quả hơn.

Hơn nữa, ML cũng có thể giúp giảm nhu cầu lao động thủ công trong việc phát hiện (Hình 2.2) và quản lý bệnh, giảm chi phí và tăng hiệu quả. Bằng cách tự động hóa quy trình phát hiện bệnh, chúng ta có thể giảm nhu cầu lao động thủ công và giải phóng tài nguyên cho các tác vụ khác. Điều này đặc biệt có lợi trong bối cảnh các cộng đồng nông nghiệp ở nông thôn và vùng sâu vùng xa, nơi lao động thường khan hiếm và tốn kém.



HÌNH 2.2 Sơ đồ tổng quát của ML để phát hiện bệnh.

- **Dữ liệu thô → Trích xuất Đặc trưng → Đặc trưng và Nhãn → Tập dữ liệu Đào tạo → Train → Đào tạo → Điều chỉnh → Mô hình → Nhãn Dự đoán**
- **Đặc trưng và Nhãn → Tập dữ liệu Xác thực → Xác thực → Điều chỉnh**
- **Đặc trưng và Nhãn → Tập dữ liệu Kiểm tra → Ước tính → Mô hình**
- Trong quá trình Train (Đào tạo) có **Chọn Siêu tham số**

2.1.3 Mục tiêu của Chương

Các mục tiêu chính của chương này là trình bày tổng quan về ứng dụng của ML trong chẩn đoán bệnh táo, xem xét các tài liệu về chủ đề này, và thảo luận về những điểm mạnh và hạn chế của ML trong bối cảnh này. Chương này cũng sẽ đề cập đến việc chuẩn bị bộ dữ

liệu, lựa chọn mô hình ML và các kỹ thuật đánh giá được sử dụng trong phát hiện bệnh táo, cũng như các hướng nghiên cứu trong tương lai trong lĩnh vực này.

Trong những năm gần đây, ngày càng có nhiều sự quan tâm đến việc sử dụng ML để phát hiện bệnh trong nông nghiệp. Các thuật toán ML đã cho thấy nhiều triển vọng trong việc phát hiện bệnh ở các loại cây trồng như khoai tây, lúa mì và nho. Tuy nhiên, việc sử dụng ML để phát hiện bệnh táo vẫn đang ở giai đoạn đầu. Điều này một phần là do tính chất phức tạp của các bệnh táo, vốn có thể do nhiều yếu tố gây ra, bao gồm điều kiện môi trường, yếu tố di truyền và mầm bệnh.

Chương này được tổ chức như sau:

1. Công trình Liên quan Trong phần này, chúng tôi sẽ cung cấp một bài đánh giá tóm tắt về tình trạng hiện tại của việc phát hiện bệnh táo bằng cách sử dụng một số kỹ thuật ML. Chúng tôi sẽ cố gắng làm nổi bật hiệu suất và những hạn chế của các kỹ thuật hiện có trong phần này.

2. Chuẩn bị Bộ dữ liệu Ý nghĩa của việc chuẩn bị bộ dữ liệu trong ML để phát hiện bệnh táo sẽ được đề cập trong phần này. Chúng tôi sẽ đề cập đến các chủ đề như thu thập dữ liệu, làm sạch dữ liệu và tăng cường dữ liệu, đồng thời thảo luận về các phương pháp hay nhất để chuẩn bị bộ dữ liệu cho ML.

3. Lựa chọn Mô hình Học máy Chúng tôi sẽ xem xét nghiên cứu về các mô hình ML để phát hiện bệnh táo trong phần này. Chúng tôi sẽ đề cập đến các chủ đề như mô hình học sâu, máy vector hỗ trợ và rừng ngẫu nhiên, đồng thời thảo luận về những điểm mạnh và điểm yếu của từng phương pháp.

4. Kỹ thuật Đánh giá Trong phần này, chúng tôi sẽ thảo luận về các kỹ thuật đánh giá cho các mô hình ML trong phát hiện bệnh táo. Chúng tôi sẽ đề cập đến các chủ đề như kiểm chứng chéo, đường cong độ chính xác-độ thu hồi và ma trận nhầm lẫn, đồng thời thảo luận về các phương pháp hay nhất để đánh giá các mô hình ML trong bối cảnh này.

5. Các Ẩn ý/Cân nhắc về Đạo đức, Thực tế và Kỹ thuật Trong phần này, chúng tôi sẽ thảo luận về một số ẩn ý quan trọng về mặt đạo đức, thực tế và kỹ thuật của việc sử dụng các mô hình ML để phát hiện bệnh táo. Cũng như bất kỳ công nghệ nào, luôn có nguy cơ xảy ra hậu quả ngoài ý muốn khi phát triển các mô hình này.

6. Điểm mạnh và Hạn chế của Học máy Phần này sẽ thảo luận về những ưu điểm và nhược điểm của ML trong việc xác định các bệnh táo. Chúng tôi sẽ nói về những điều như nguy cơ trùng khớp quá mức (overfitting), giá trị của các bộ dữ liệu chất lượng cao, và khả năng sai lệch dữ liệu.

7. Hướng Nghiên cứu Tương lai Trong phần này, chúng tôi sẽ xác định các hướng nghiên cứu trong tương lai trong ML để phát hiện bệnh táo. Chúng tôi sẽ thảo luận

về các chủ đề như việc sử dụng dữ liệu đa phương thức, phát triển các mô hình học chuyển giao (transfer learning), và việc sử dụng các kỹ thuật học không giám sát.

8. Kết luận Chúng tôi sẽ nêu bật các ý chính của chương và nói về những ẩn ý của ML đối với việc xác định các bệnh táo trong phần này. Chúng tôi sẽ xem xét các tác động có thể có của ML đối với ngành công nghiệp táo cũng như các lĩnh vực cần nghiên cứu thêm.

2.2 CÔNG TRÌNH LIÊN QUAN

Một kỹ thuật máy vector hỗ trợ đa lớp (SVM) đã được Soarov Chakraborty et al. đề xuất để phân loại lá táo thành ba nhóm: khỏe mạnh, bị ghẻ và bị phấn trắng. Bài báo mô tả chi tiết bộ dữ liệu được sử dụng để đào tạo và kiểm tra hệ thống, cùng với các phương pháp được sử dụng để thu thập hình ảnh, tiền xử lý chúng và trích xuất đặc trưng của chúng. Các tác giả sau đó mô tả việc triển khai thuật toán SVM và các biện pháp đánh giá hiệu suất được sử dụng để đánh giá phương pháp. Kết quả chứng minh rằng thuật toán SVM đa lớp được đề xuất đã phân loại lá táo thành các lớp khỏe mạnh, ghẻ và phấn trắng với tỷ lệ chính xác tốt. Những hạn chế của kỹ thuật được đề xuất được thảo luận trong phần kết luận của bài báo, cùng với các ý tưởng nghiên cứu thêm.

Một mô hình mạng nơ-ron tích chập (CNN) của Swati et al. đã được báo cáo có thể chia hình ảnh lá táo thành bốn loại: khỏe mạnh, ghẻ, rỉ sét và phấn trắng. Tác giả mô tả việc triển khai mô hình CNN và các biện pháp đánh giá hiệu suất được sử dụng để đánh giá tính chính xác của mô hình. Kết quả chứng minh rằng mô hình CNN được đề xuất đã phân loại hình ảnh lá táo thành các nhóm bệnh khác nhau với tỷ lệ chính xác tốt. Những hạn chế của kỹ thuật được đề xuất được thảo luận trong phần kết luận của bài báo, cùng với các ý tưởng nghiên cứu thêm. Nhìn chung, nghiên cứu đề xuất một phương pháp được thiết kế tốt để sử dụng học sâu nhằm tự động phát hiện các bệnh trên lá táo. Việc sử dụng mô hình CNN để phân loại các bức ảnh thành nhiều nhóm bệnh khác nhau là một phương pháp thú vị có tiềm năng mở rộng sang các loài thực vật khác và có thể có những ẩn ý thực tế cho nông nghiệp.

Xin li et al. đề xuất một phương pháp học sâu để phát hiện và phân loại các bệnh trên lá táo. Các tác giả sử dụng các mô hình mạng nơ-ron dư (ResNet) để phân loại hình ảnh lá táo thành một trong ba lớp: khỏe mạnh, ghẻ và phấn trắng. Bài báo cũng cung cấp một lời giải thích kỹ lưỡng về bộ dữ liệu, bao gồm các bức ảnh được thu thập từ nhiều nguồn khác nhau và được sử dụng để đào tạo và kiểm tra các mô hình ResNet. Các tác giả cũng đi sâu vào cách các mô hình ResNet được đưa vào thực tế và các chỉ số hiệu suất nào được sử dụng để đánh giá độ chính xác của mô hình. Kết quả chứng minh rằng các mô hình ResNet được đề xuất đã phân loại thành công hình ảnh lá táo thành các lớp bệnh khác nhau với tỷ lệ chính xác cao. Những hạn chế của kỹ thuật được đề xuất được thảo luận trong phần kết luận của bài báo, cùng với các ý tưởng nghiên cứu thêm. Việc sử dụng các mô hình ResNet để phân loại các bức ảnh thành nhiều nhóm bệnh khác nhau là một phương pháp thú vị có tiềm năng mở rộng sang các loài thực vật khác và có thể có những ẩn ý thực tế cho nông nghiệp.

Saraansh Baranwal et al. đề xuất một phương pháp học sâu để phát hiện các bệnh trên lá táo bằng cách sử dụng CNN. Tác giả trình bày một mô hình có thể phân loại hình ảnh lá táo thành một trong bốn lớp: khỏe mạnh, ghẻ, rỉ sét và phấn trắng. Tác giả mô tả việc triển khai mô hình CNN và các biện pháp đánh giá hiệu suất được sử dụng để đánh giá tính chính xác của mô hình. Kết quả chứng minh rằng mô hình CNN được đề xuất đã phân loại hình ảnh lá táo thành các nhóm bệnh khác nhau với tỷ lệ chính xác tốt.

Một chiến lược lai được Mohammed Khalid Kaleem et al. đề xuất để tự động nhận dạng các bệnh trên lá. Tác giả sử dụng các bộ phân loại SVM để phân loại các bức ảnh là khỏe mạnh hoặc bị bệnh sau khi sử dụng các kỹ thuật xử lý hình ảnh để tiền xử lý hình ảnh và trích xuất đặc trưng. Bộ phân loại SVM đã được đào tạo và kiểm tra trên các bức ảnh của nhiều loài thực vật được thu thập từ các nguồn đa dạng. Tác giả cũng thảo luận về việc triển khai bộ phân loại SVM và các biện pháp đánh giá hiệu suất được sử dụng để đánh giá độ chính xác của mô hình. Kết quả chứng minh rằng phương pháp được đề xuất đã phân loại thành công hình ảnh lá cây thành khỏe mạnh và bị bệnh với tỷ lệ chính xác cao.

Với việc cài đặt mô hình CNN và các biện pháp đánh giá hiệu suất được sử dụng để đánh giá tính chính xác của mô hình, Srinidhi et al. đã phân loại hình ảnh lá táo thành một trong bốn lớp: khỏe mạnh, ghẻ táo, rỉ sét táo tuyết tùng và rỉ sét quince. Kết quả chứng minh rằng mô hình CNN được đề xuất đã phân loại thành công hình ảnh lá táo thành các lớp bệnh khác nhau với tỷ lệ chính xác cao. Những hạn chế của kỹ thuật được đề xuất được thảo luận trong phần kết luận của bài báo, cùng với các ý tưởng nghiên cứu thêm. Nhìn chung, nghiên cứu đề xuất một phương pháp được thiết kế tốt để sử dụng học sâu nhằm tự động phát hiện các bệnh trên lá táo. Việc sử dụng mô hình CNN để phân loại hình ảnh thành các lớp bệnh khác nhau là một phương pháp đầy hứa hẹn có tiềm năng áp dụng cho các loài thực vật khác và có thể có những ẩn ý thực tế trong lĩnh vực nông nghiệp.

Hình ảnh siêu phổ được Mubarakat Shuaibu et al. đề xuất như một phương pháp để tự động nhận dạng bệnh đốm lá Marssonina ở cây táo. Các dải phổ phù hợp nhất để chẩn đoán tình trạng này được tác giả xác định bằng cách sử dụng phương pháp chọn lọc đặc trưng dựa trên thông tin tương hỗ. Bộ dữ liệu siêu phổ được sử dụng để chọn lọc đặc trưng và việc thực hiện chiến lược không giám sát được mô tả kỹ lưỡng trong bài báo. Các phát hiện chứng minh rằng phương pháp được đề xuất đã phát hiện thành công bệnh đốm lá Marssonina ở cây táo với tỷ lệ chính xác cao. Nhìn chung, bài báo trình bày một cách tiếp cận mới để tự động phát hiện bệnh đốm lá Marssonina ở cây táo bằng cách sử dụng hình ảnh siêu phổ và kỹ thuật chọn lọc đặc trưng không giám sát. Việc sử dụng hình ảnh siêu phổ có thể cung cấp một cách không xâm lấn và hiệu quả để phát hiện các bệnh thực vật, và phương pháp được đề xuất có tiềm năng áp dụng cho các loài thực vật khác và có thể có những ẩn ý thực tế trong lĩnh vực nông nghiệp.

CNN được Prakhar Bansal et al. đề xuất để tự động hóa việc nhận dạng các bệnh trên lá táo. Tác giả đưa ra một phương pháp luận có thể phân loại hình ảnh lá táo thành ba nhóm: khỏe mạnh, bị ghẻ và bị rỉ sét. Nghiên cứu đưa ra một phương pháp khả thi để áp dụng học sâu nhằm tự động phát hiện các bệnh trên lá táo. Việc sử dụng mô hình CNN để phân loại

các bức ảnh thành nhiều nhóm bệnh khác nhau là một phương pháp mạnh mẽ có tiềm năng mở rộng sang các loài thực vật khác và có thể có những ẩn ý thực tế cho nông nghiệp.

SVM là một kỹ thuật ML được S. Manimegalai et al. đề xuất để phát hiện bệnh trên lá táo. Tác giả cũng thảo luận về việc triển khai mô hình SVM và các biện pháp đánh giá hiệu suất được sử dụng để đánh giá độ chính xác của mô hình. Kết quả chứng minh rằng mô hình SVM được đề xuất đã phân loại hình ảnh lá táo thành các lớp bệnh khác nhau với tỷ lệ chính xác tốt. Việc sử dụng mô hình SVM để phân loại các bức ảnh thành các phân loại bệnh khác nhau là một phương pháp hiệu quả có tiềm năng mở rộng sang các loài thực vật khác và có thể có những ẩn ý thực tế cho nông nghiệp.

Một phương pháp xử lý hình ảnh được Sara Alqethami et al. đề xuất để tự động nhận dạng các bệnh trên lá táo. Tác giả mô tả một cách tiếp cận bắt đầu bằng tiền xử lý, phân đoạn và trích xuất đặc trưng hình ảnh, sau đó sử dụng các thuật toán ML để phân loại hình ảnh. Bộ dữ liệu được sử dụng để đào tạo và đánh giá mô hình phân loại, bao gồm các bức ảnh được thu thập từ một số vườn cây ăn quả ở Ả Rập Xê Út, được mô tả chi tiết trong bài báo. Tác giả cũng thảo luận về ứng dụng của mô hình phân loại bằng cách sử dụng các kỹ thuật ML cây quyết định, SVM và láng giềng gần nhất k. Kết quả chứng minh rằng phương pháp được đề xuất đã phân loại hình ảnh lá táo thành các nhóm bệnh khác nhau với tỷ lệ chính xác tốt.

2.3 CHUẨN BỊ BỘ DỮ LIỆU

Trong ML, chất lượng của bộ dữ liệu là rất quan trọng đối với hiệu suất của mô hình. Do đó, chuẩn bị dữ liệu là một bước quan trọng trong quy trình ML. Trong bối cảnh phát hiện bệnh táo, chuẩn bị dữ liệu bao gồm thu thập dữ liệu, làm sạch dữ liệu và tăng cường dữ liệu để tăng tính đa dạng của bộ dữ liệu.

2.3.1 Thu thập Dữ liệu

Thu thập dữ liệu chất lượng cao là bước đầu tiên trong việc chuẩn bị bộ dữ liệu cho ML. Trong bối cảnh phát hiện bệnh táo, dữ liệu có thể được thu thập bằng cách sử dụng các kỹ thuật khác nhau như lấy mẫu thủ công, viễn thám và máy bay không người lái. Lấy mẫu thủ công bao gồm việc kiểm tra vật lý cây táo và ghi lại các triệu chứng của bất kỳ bệnh nào được quan sát. Viễn thám bao gồm việc sử dụng hình ảnh trên không hoặc hình ảnh vệ tinh để phát hiện những thay đổi trong thảm thực vật của vườn cây ăn quả, điều này có thể là dấu hiệu của bệnh tật. Máy bay không người lái cũng có thể được sử dụng để thu thập hình ảnh độ phân giải cao của vườn cây ăn quả và phát hiện những thay đổi trong thảm thực vật.

2.3.2 Làm sạch Dữ liệu

Sau khi thu thập dữ liệu, bước tiếp theo là làm sạch nó. Làm sạch dữ liệu bao gồm việc loại bỏ các giá trị ngoại lai, sửa lỗi và xử lý các giá trị bị thiếu. Trong bối cảnh phát hiện bệnh táo, điều này có thể liên quan đến việc loại bỏ các hình ảnh chất lượng kém hoặc chứa các đối tượng không liên quan đến nhiệm vụ, chẳng hạn như hình ảnh chim hoặc mây. Nó cũng

có thể liên quan đến việc sửa lỗi ghi nhãn, chẳng hạn như dán nhãn sai cây khỏe mạnh là bị bệnh, và xử lý các giá trị bị thiếu, chẳng hạn như thiếu chú thích cho một số hình ảnh nhất định.

2.3.3 Tăng cường Dữ liệu

Tăng cường dữ liệu là quá trình tăng tính đa dạng của bộ dữ liệu một cách nhân tạo bằng cách áp dụng các phép biến đổi như xoay, lật và cắt xén cho các hình ảnh gốc. Tăng cường dữ liệu có thể giúp cải thiện tính mạnh mẽ của mô hình bằng cách cho nó tiếp xúc với các biến thể trong dữ liệu đầu vào. Trong bối cảnh phát hiện bệnh táo, tăng cường dữ liệu có thể liên quan đến việc áp dụng các phép biến đổi cho các hình ảnh gốc, chẳng hạn như xoay chúng hoặc lật chúng, và thêm nhiễu hoặc hiệu ứng làm mờ.

2.4 LỰA CHỌN MÔ HÌNH HỌC MÁY

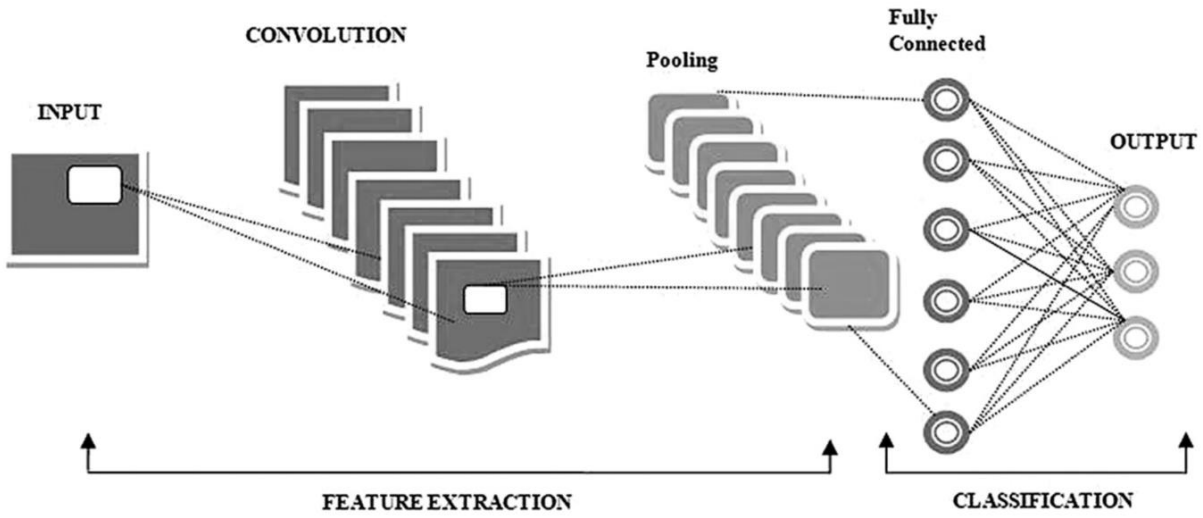
Chúng tôi sẽ xem xét nghiên cứu về các mô hình ML để phát hiện bệnh táo trong phần này. Các mô hình học sâu, SVM và rừng ngẫu nhiên chỉ là một vài trong số các chủ đề chúng tôi sẽ khám phá, cùng với những ưu điểm và nhược điểm của mỗi phương pháp.

2.4.1 Mô hình Học sâu

Các mô hình học sâu đã đạt được hiệu suất hiện đại trong nhiều ứng dụng thị giác máy tính, bao gồm phân đoạn, nhận dạng đối tượng và phân loại hình ảnh. Các mô hình học sâu đã chứng minh kết quả xuất sắc trong lĩnh vực phát hiện bệnh táo, đạt độ chính xác cao trong việc nhận dạng các bệnh khác nhau. Một trong những mô hình học sâu được sử dụng phổ biến nhất để phát hiện bệnh táo là CNN (Hình 2.3).

CNN là một loại mạng nơ-ron được thiết kế để xử lý hình ảnh và chúng đã đạt được hiệu suất tiên tiến trong nhiều tác vụ thị giác máy tính. Trong bối cảnh phát hiện bệnh táo, CNN đã được sử dụng để phát hiện các bệnh như ghẻ táo, bệnh phấn trắng và bệnh cháy lá.

Một loại mô hình học sâu khác đã được sử dụng để phát hiện bệnh táo là mạng nơ-ron hồi quy (RNN). RNN là một loại mạng nơ-ron được thiết kế để xử lý dữ liệu tuần tự, chẳng hạn như chuỗi thời gian hoặc văn bản. Trong bối cảnh phát hiện bệnh táo, RNN đã được sử dụng để phát hiện bệnh dựa trên các mẫu triệu chứng theo thời gian, chẳng hạn như thay đổi màu sắc hoặc kết cấu.



HÌNH 2.3 Cách hoạt động của CNN.

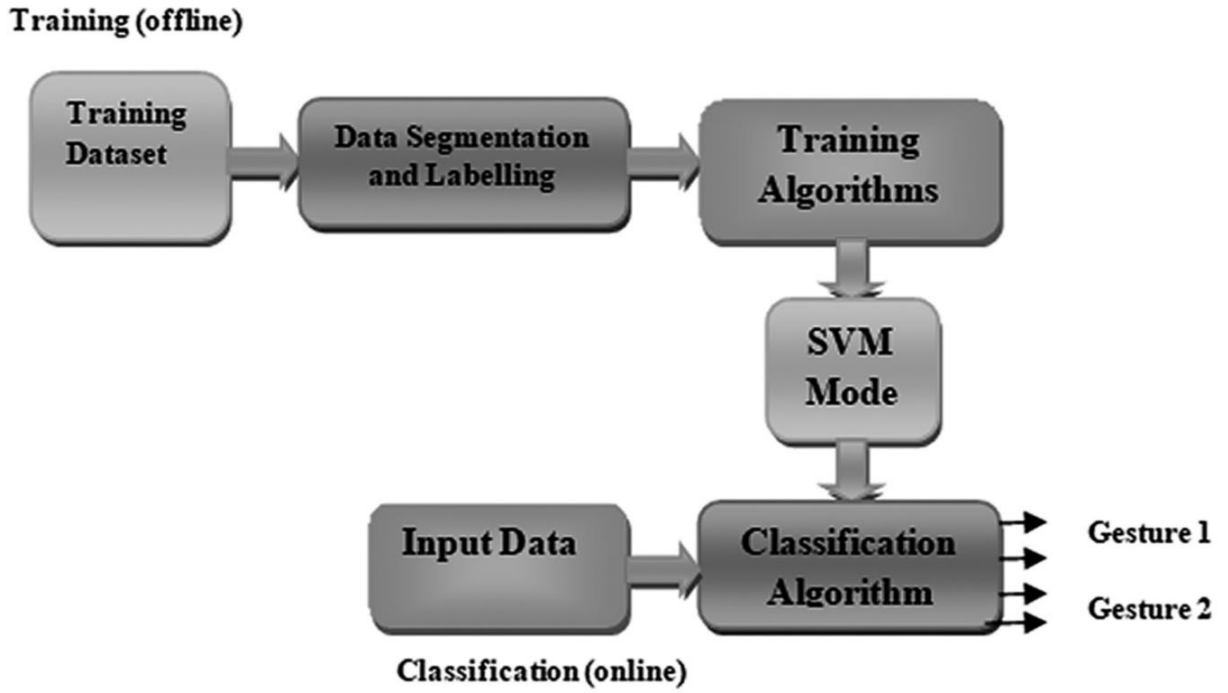
- **ĐẦU VÀO → TÍCH CHẬP → GỘP (Pooling) → KẾT NỐI ĐẦY ĐỦ → ĐẦU RA**
- **TRÍCH XUẤT ĐẶC TRƯNG** (bao gồm Tích chập và Gộp)
- **PHÂN LOẠI** (bao gồm Kết nối đầy đủ)

2.4.2 Máy Vector Hỗ trợ (SVM)

SVM (Hình 2.4) là một loại thuật toán học có giám sát có thể được sử dụng cho cả nhiệm vụ phân loại và hồi quy. SVM đặc biệt phù hợp với các nhiệm vụ phân loại trong đó dữ liệu không thể phân tách tuyến tính, vì chúng có thể ánh xạ dữ liệu đến một không gian chiều cao hơn, nơi nó có thể phân tách tuyến tính. SVM đã được sử dụng để phân loại hình ảnh lá táo khỏe mạnh và bị bệnh trong bối cảnh phát hiện bệnh táo. SVM siêu phổ cũng đã được sử dụng để tìm ghẻ táo và bệnh phấn trắng.

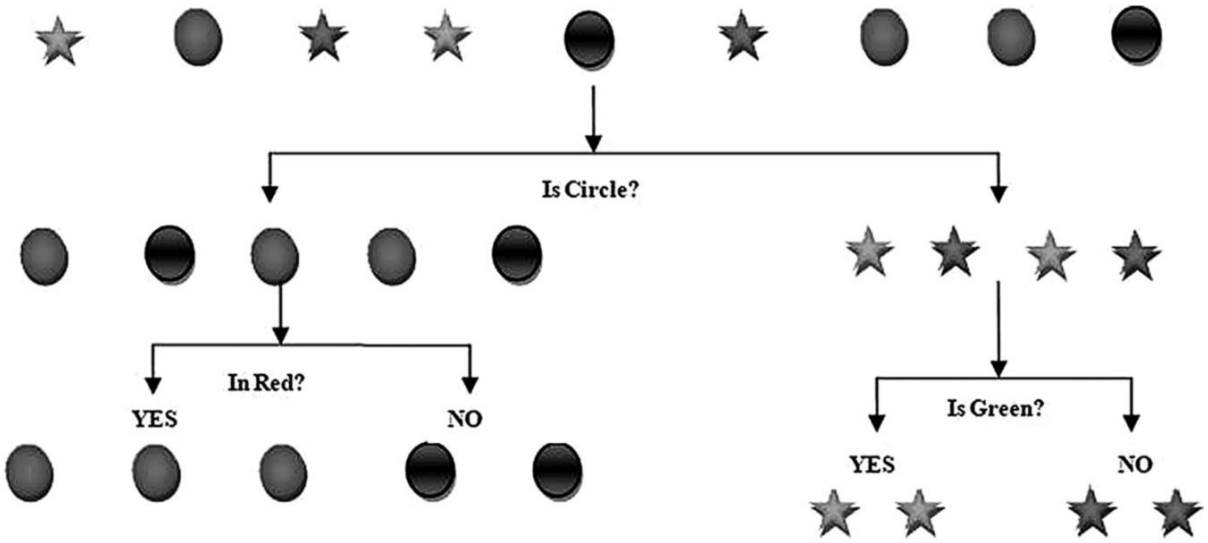
2.4.3 Rừng Ngẫu nhiên (Random Forests)

Rừng ngẫu nhiên là một kỹ thuật học tập kết hợp, kết hợp nhiều cây quyết định để tăng tính mạnh mẽ và độ chính xác của mô hình. Khi đưa ra dự đoán, rừng ngẫu nhiên (Hình 2.5) kết hợp kết quả của tất cả các cây quyết định mà chúng tạo ra bằng cách sử dụng các tập hợp con ngẫu nhiên khác nhau của các đặc trưng và dữ liệu. Trong bối cảnh phát hiện bệnh táo, rừng ngẫu nhiên đã được sử dụng để phân loại hình ảnh lá táo khỏe mạnh và bị bệnh. Rừng ngẫu nhiên cũng đã được sử dụng để phát hiện các bệnh như ghẻ táo và bệnh phấn trắng bằng cách sử dụng dữ liệu phổ.



HÌNH 2.4 Cách hoạt động của SVM.

- **Đào tạo (ngoại tuyến)**
  - **Tập dữ liệu Đào tạo → Phân đoạn và Ghi nhãn Dữ liệu → Thuật toán Đào tạo → Chế độ SVM**
- **Phân loại (trực tuyến)**
  - **Dữ liệu Đầu vào → Thuật toán Phân loại → Cử chỉ 1 , Cử chỉ 2**, …



HÌNH 2.5 Sơ đồ rừng ngẫu nhiên.

2.4.4 Các Mô hình Học máy Khác

Ngoài các mô hình học sâu, SVM và rừng ngẫu nhiên, còn có nhiều mô hình ML khác có thể được sử dụng để phát hiện bệnh táo. Chúng bao gồm cây quyết định, Naive Bayes, láng giềng gần nhất k và hồi quy logistic.

Mỗi mô hình này đều có điểm mạnh và điểm yếu riêng, và việc lựa chọn mô hình nào để sử dụng sẽ phụ thuộc vào các yêu cầu cụ thể của ứng dụng. Ví dụ, cây quyết định dễ diễn giải và có thể xử lý cả dữ liệu phân loại và số, nhưng chúng có thể trùng khớp quá mức dữ liệu. Naive Bayes là một mô hình đơn giản và nhanh chóng hoạt động tốt với các bộ dữ liệu nhỏ; tuy nhiên, nó đưa ra giả định không thực tế rằng tất cả các đặc trưng là độc lập.

2.5 ĐÀO TẠO VÀ ĐÁNH GIÁ MÔ HÌNH

Trong phần này, chúng tôi sẽ thảo luận về quá trình đào tạo và đánh giá các mô hình ML để phát hiện bệnh táo. Chúng tôi sẽ đề cập đến các chủ đề như chia tách dữ liệu, điều chỉnh siêu tham số và các số liệu đánh giá mô hình.

2.5.1 Chia tách Dữ liệu

Trước khi một mô hình ML được đào tạo trên bộ dữ liệu, nó phải được chia thành các tập đào tạo, xác thực và kiểm tra. Tập đào tạo dùng để đào tạo mô hình, tập kiểm tra đánh giá hiệu suất cuối cùng của mô hình, và tập xác thực được sử dụng để tinh chỉnh các siêu tham số của mô hình. Tỷ lệ chia tách của bộ dữ liệu có thể thay đổi tùy thuộc vào kích thước của bộ dữ liệu và độ phức tạp của mô hình. Nói chung, một mô hình phức tạp hơn đòi hỏi một tập xác thực lớn hơn, trong khi một bộ dữ liệu lớn hơn đòi hỏi một tập xác thực nhỏ hơn.

2.5.2 Điều chỉnh Siêu tham số

Các mô hình ML có các siêu tham số cần được đặt trước khi đào tạo, chẳng hạn như tốc độ học, cường độ điều chỉnh và số lớp. Điều chỉnh siêu tham số bao gồm việc tìm kiếm các giá trị tối ưu cho các siêu tham số này để cải thiện hiệu suất của mô hình.

Có nhiều phương pháp khác nhau để điều chỉnh siêu tham số, chẳng hạn như tìm kiếm lưới, tìm kiếm ngẫu nhiên và tối ưu hóa Bayesian. Tìm kiếm lưới bao gồm việc đánh giá mô hình cho tất cả các kết hợp siêu tham số có thể có , trong khi tìm kiếm ngẫu nhiên bao gồm việc chọn ngẫu nhiên các siêu tham số để đánh giá. Tối ưu hóa Bayesian sử dụng mô hình xác suất để chọn tập hợp siêu tham số tiếp theo để đánh giá dựa trên các kết quả trước đó.

2.5.3 Các Số liệu Đánh giá Mô hình

Các số liệu để đo lường hiệu suất của mô hình được sử dụng (Bảng 2.1). Độ chính xác, độ đúng, độ thu hồi , và điểm F1 là các tiêu chí đánh giá điển hình trong bối cảnh phát hiện bệnh táo.

Phần trăm các mẫu trong tập kiểm tra được phân loại đúng được coi là độ chính xác. Độ đúng là tỷ lệ dương tính thật trên tất cả các mẫu được dự đoán là dương tính. Độ thu hồi định lượng tỷ lệ các mẫu dương tính thật trong số tất cả các mẫu dương tính. Điểm F1, cung cấp một con số duy nhất để đánh giá hiệu quả tổng thể của mô hình, là trung bình điều hòa của độ chính xác và độ thu hồi.

BẢNG 2.1 Các Số liệu Đánh giá Hiệu suất Khác nhau

Số liệu Đánh giá Mô hình	Công thức
Độ chính xác (Accuracy)	$(TP + TN)/(TP + TN + FP + FN)$ [cite: 271, 15]
Độ đúng (Precision)	$TP/(TP + FP)$ [cite: 271, 15]
Độ thu hồi (Recall)	$TP/(TP + FN)$ [cite: 271, 15]
Điểm F1 (F1 Score)	$2 \times (Precision \times Recall)/(Precision + Recall)$ [cite: 271, 30]
Điểm FB (FB Score)	$(1 + \beta^2) \times (Precision \times Recall)/(\beta^2 \times Precision + Recall)$ [cite: 271, 30]
Điểm ROC-AUC (ROC-AUC Score)	diện tích dưới đường cong ROC [cite: 271, 16]
Tổn thất Log (Log Loss)	$-\frac{1}{n}\sum i\sum jyijlog(pij)$ [cite: 271, 16]
Sai số Bình phương Trung bình (Mean Squared Error)	$-\frac{1}{n}\Sigma i(yi - \hat{y}i)^2$ [cite: 271]

2.6 CÁC CÂN NHẮC/ẨN Ý VỀ ĐẠO ĐỨC, THỰC TẾ VÀ KỸ THUẬT

Điều quan trọng là phải tính đến những hàm ý đạo đức của việc sử dụng các thuật toán ML để xác định các bệnh táo. Dữ liệu và thuật toán được sử dụng để tạo ra các mô hình này có những rủi ro giống như bất kỳ công nghệ nào khác về mặt hậu quả ngoài ý muốn hoặc sai lệch.

Ví dụ, nếu các mô hình ML được phát triển dựa trên dữ liệu thu thập từ một khu vực hoặc khí hậu duy nhất, chúng có thể không hoạt động tốt khi được triển khai ở các khu vực khác nhau hoặc trong các điều kiện môi trường khác nhau. Điều này có thể dẫn đến các chiến lược quản lý dịch bệnh không hiệu quả hoặc tăng cường sử dụng thuốc trừ sâu, có thể có tác động tiêu cực đến môi trường và sức khỏe. Hơn nữa, cũng có nguy cơ sai lệch trong dữ liệu được sử dụng để phát triển các mô hình này. Nếu dữ liệu được sử dụng để đào tạo mô hình bị sai lệch đối với một số nhân khẩu học hoặc khu vực địa lý nhất định, điều này có thể dẫn đến các dự đoán sai lệch và các kết quả có khả năng phân biệt đối xử. Do đó, điều quan trọng là phải đảm bảo rằng dữ liệu được sử dụng để phát triển các mô hình này là đa dạng và đại diện cho các quần thể và môi trường mà chúng sẽ được triển khai.

Một cân nhắc đạo đức khác là tác động tiềm tàng của các mô hình ML đối với sinh kế của nông dân và các công nhân nông nghiệp khác. Nếu các mô hình ML được sử dụng để tự động hóa các nhiệm vụ phát hiện và quản lý bệnh, điều này có thể dẫn đến mất việc làm hoặc giảm an ninh việc làm cho những người lao động này. Do đó, điều quan trọng là phải xem xét tác động tiềm tàng của các công nghệ này đối với sinh kế của những người làm việc trong ngành nông nghiệp.

Tóm lại, mặc dù các kỹ thuật ML cho thấy tiềm năng to lớn trong việc nâng cao hiệu quả và năng suất quản lý bệnh táo, điều quan trọng là phải suy nghĩ về những ẩn ý đạo đức của việc sử dụng chúng. Điều quan trọng là phải đảm bảo rằng các mô hình này được tạo ra và triển khai một cách công bằng, minh bạch và bình đẳng, và không vô tình gây hại cho môi trường, sức khỏe cộng đồng hoặc người lao động nông nghiệp. Bằng cách vượt qua những trở ngại này, chúng ta có thể tận dụng toàn bộ ML để chẩn đoán các bệnh táo và đóng góp vào việc tạo ra một hệ thống nông nghiệp công bằng và bền vững hơn.

2.6.1 Cân nhắc Thực tế

Cuối cùng, điều quan trọng là phải xem xét các cân nhắc thực tế của việc triển khai các mô hình ML để phát hiện bệnh táo trong môi trường thực tế. Một cân nhắc quan trọng là nhu cầu về thiết bị và chuyên môn chuyên biệt để thu thập và phân tích dữ liệu. Điều này có thể đòi hỏi đào tạo thêm hoặc đầu tư vào thiết bị và tài nguyên, điều này có thể là rào cản đối với những nông dân nhỏ hơn hoặc những người có nguồn lực hạn chế. Một cân nhắc thực tế khác là nhu cầu bảo trì và cập nhật liên tục cho các mô hình ML. Khi các chủng bệnh mới xuất hiện hoặc điều kiện môi trường thay đổi, có thể cần phải cập nhật các mô hình để đảm bảo độ chính xác và hiệu quả của chúng. Điều này đòi hỏi đầu tư liên tục vào nghiên cứu và phát triển, cũng như cam kết theo dõi và đánh giá liên tục các mô hình trong môi trường thực tế.

Hơn nữa, điều quan trọng là phải xem xét các chi phí và lợi ích tiềm năng của việc triển khai các mô hình ML để phát hiện bệnh táo. Mặc dù các mô hình này có thể cải thiện hiệu quả và độ chính xác của việc phát hiện và quản lý bệnh, chúng cũng có thể yêu cầu chi phí trả trước đáng kể cho việc thu thập và phân tích dữ liệu, cũng như đầu tư liên tục vào bảo trì và cập nhật. Do đó, điều quan trọng là phải xem xét cẩn thận các lợi ích và chi phí tiềm năng của các công nghệ này trước khi triển khai chúng trên quy mô lớn.

Tóm lại, việc phát triển và triển khai các mô hình ML để phát hiện bệnh táo đại diện cho một bước tiến đáng kể trong lĩnh vực bệnh học thực vật và nông nghiệp. Các mô hình này có tiềm năng cải thiện hiệu quả và độ chính xác của việc phát hiện và quản lý bệnh, đồng thời cung cấp những hiểu biết mới về sinh học cơ bản của các bệnh thực vật. Tuy nhiên, cũng có những thách thức đáng kể đối với việc phát triển và triển khai các mô hình này, bao gồm nhu cầu về các bộ dữ liệu lớn và đa dạng, khả năng diễn giải trong các mô hình ML và các cân nhắc đạo đức liên quan đến sai lệch và hậu quả ngoài ý muốn. Với sự nghiên cứu và phát triển liên tục, chúng ta có thể hy vọng thấy những tiến bộ đáng kể trong lĩnh vực này và tiềm năng của ML để thay đổi cách chúng ta quản lý các bệnh thực vật trong ngành nông nghiệp.

2.6.2 Cân nhắc Kỹ thuật

Ngoài những thách thức và cân nhắc đạo đức đã thảo luận trước đó, cũng có một số cân nhắc kỹ thuật phải được tính đến khi phát triển các mô hình ML để phát hiện bệnh táo. Một cân nhắc quan trọng là nhu cầu về dữ liệu chất lượng cao và đa dạng để đào tạo các mô hình này. Điều này đòi hỏi phải thu thập một lượng lớn dữ liệu từ các vị trí địa lý, mùa và giống táo khác nhau, cũng như bao gồm dữ liệu về các yếu tố môi trường khác nhau, chẳng hạn như nhiệt độ, độ ẩm và lượng mưa.

Một cân nhắc kỹ thuật khác là việc lựa chọn và tối ưu hóa các thuật toán ML để phát hiện bệnh táo. Có nhiều thuật toán khác nhau có sẵn để sử dụng trong ML, mỗi thuật toán có điểm mạnh và điểm yếu riêng. Do đó, điều quan trọng là phải đánh giá và so sánh cẩn thận các thuật toán khác nhau để xác định những thuật toán nào hiệu quả nhất cho việc phát hiện bệnh táo và tối ưu hóa các thuật toán này để đạt độ chính xác và hiệu quả tối đa.

Khi tạo các mô hình ML để chẩn đoán bệnh táo, khả năng diễn giải là một yếu tố quan trọng khác cần tính đến. Mặc dù các mô hình này có thể đạt được mức độ chính xác cao, nhưng có thể khó hiểu được cách chúng đưa ra dự đoán, đặc biệt là khi các kỹ thuật học sâu được sử dụng. Sự thiếu khả năng diễn giải này có thể khiến việc xác định các nguyên nhân cơ bản của các đợt bùng phát dịch bệnh và phát triển các chiến lược quản lý hiệu quả trở nên khó khăn.

Một yếu tố quan trọng khác là đảm bảo rằng các mô hình này là đáng tin cậy và linh hoạt. Các mô hình ML dễ mắc lỗi, đặc biệt nếu chúng được đào tạo trên dữ liệu sai lệch hoặc không đáng tin cậy. Do đó, điều quan trọng là phải đảm bảo dữ liệu được sử dụng để đào tạo các mô hình này là không thiên vị và đại diện, và sử dụng các công cụ như kiểm chứng chéo và phân tích lỗi để phát hiện và khắc phục mọi lỗi có thể xảy ra.

Cuối cùng, cũng có nhu cầu đảm bảo rằng các mô hình này có thể mở rộng và thích ứng với các bối cảnh nông nghiệp và địa lý khác nhau. Điều này đòi hỏi sự phát triển của các mô hình có thể chuyển giao qua các khu vực và giống táo khác nhau, cũng như việc kết hợp kiến thức và chuyên môn địa phương để đảm bảo rằng các mô hình này có liên quan và hiệu quả trong các bối cảnh nông nghiệp cụ thể.

Một con đường đầy hứa hẹn cho việc tiếp tục phát triển và triển khai các mô hình ML để phát hiện và quản lý bệnh táo là thông qua việc sử dụng các sáng kiến nghiên cứu và phát triển hợp tác. Những sáng kiến như vậy quy tụ các nhà nghiên cứu, nông dân, đối tác công nghiệp và các bên liên quan khác để chia sẻ kiến thức, tài nguyên và chuyên môn, và cộng tác trong việc phát triển các giải pháp sáng tạo cho những thách thức mà ngành nông nghiệp phải đối mặt.

Một sáng kiến như vậy là Trung tâm Nghiên cứu Hình ảnh và Tạo kiểu hình Thực vật (P2IRC) tại Đại học Saskatchewan, tập trung vào việc phát triển các công nghệ hình ảnh và ML tiên tiến để tạo kiểu hình cây trồng, phát hiện bệnh và nông nghiệp chính xác. Một ví dụ khác là Sáng kiến Nông nghiệp và Thực phẩm Kỹ thuật số (IDAF) tại Đại học Guelph,

tập trung vào việc phát triển và triển khai các công nghệ kỹ thuật số, bao gồm ML, cho các hệ thống nông nghiệp và thực phẩm bền vững.

Ngoài những sáng kiến nghiên cứu này, cũng có một số lượng ngày càng tăng các quan hệ đối tác và hợp tác trong ngành tập trung vào việc phát triển và triển khai các mô hình ML để phát hiện và quản lý bệnh táo. Những quan hệ đối tác này quy tụ các công ty công nghệ, nông dân và các bên liên quan khác để phát triển các giải pháp sáng tạo có thể được mở rộng và triển khai trên các bối cảnh nông nghiệp khác nhau. Ví dụ, công ty công nghệ nông nghiệp CropX đã phát triển một hệ thống giám sát độ ẩm đất sử dụng các thuật toán ML để dự đoán mức độ ẩm đất và giúp nông dân tối ưu hóa việc tưới tiêu và sử dụng phân bón. Tương tự, công ty khởi nghiệp AgShift đã phát triển một nền tảng ML có thể phân tích chất lượng và độ tươi của trái cây và rau quả theo thời gian thực, giúp giảm lãng phí thực phẩm và cải thiện hiệu quả chuỗi cung ứng.

Nhìn chung, việc tiếp tục phát triển và triển khai các mô hình ML để phát hiện và quản lý bệnh táo đại diện cho một cơ hội đáng kể để giải quyết những thách thức mà ngành nông nghiệp phải đối mặt ngày nay. Bằng cách tận dụng sức mạnh của dữ liệu và các thuật toán tiên tiến, chúng ta có thể cải thiện độ chính xác và hiệu quả của việc phát hiện và quản lý bệnh, giảm tác động môi trường của các hoạt động nông nghiệp, và cuối cùng là cải thiện tính bền vững và lợi nhuận của hoạt động canh tác. Tuy nhiên, việc nhận ra toàn bộ tiềm năng của các công nghệ này sẽ đòi hỏi đầu tư liên tục vào nghiên cứu và phát triển, cũng như cam kết giải quyết các cân nhắc kỹ thuật, đạo đức và thực tế phát sinh khi sử dụng chúng. Bằng cách làm như vậy, chúng ta có thể xây dựng một hệ thống nông nghiệp bền vững và linh hoạt hơn cho tương lai và đảm bảo sự sẵn có của thực phẩm lành mạnh và bổ dưỡng cho các thế hệ mai sau.

2.7 THÁCH THỨC VÀ HƯỚNG ĐI TƯƠNG LAI

Trong phần này, chúng tôi sẽ thảo luận về một số thách thức và hướng đi tương lai cho việc phát hiện bệnh táo bằng cách sử dụng các kỹ thuật ML.

2.7.1 Tính sẵn có của Bộ dữ liệu Bị hạn chế

Một trong những thách thức chính trong việc phát hiện bệnh táo bằng cách sử dụng ML là tính sẵn có bị hạn chế của các bộ dữ liệu chất lượng cao. Thu thập và chú thích dữ liệu có thể tốn thời gian và chi phí, và có nhu cầu về nhiều bộ dữ liệu công khai hơn để đào tạo và đánh giá các mô hình ML.

2.7.2 Khả năng Tổng quát hóa cho Môi trường Mới

Khả năng của mô hình để tổng quát hóa cho các bối cảnh khác nhau là một khó khăn khác trong việc phát hiện bệnh táo bằng cách sử dụng ML. Các mô hình ML được đào tạo trên một bộ dữ liệu cụ thể có thể không hoạt động hiệu quả trên các bộ dữ liệu mới được thu thập từ những nơi khác hoặc trong các điều kiện tăng trưởng khác nhau. Do đó, cần có các mô hình có thể thích ứng với các tình huống thay đổi.

2.7.3 Mô hình Có thể Diễn giải

Các mô hình ML có thể diễn giải là quan trọng trong bối cảnh phát hiện bệnh táo, vì chúng có thể cung cấp những hiểu biết sâu sắc về các cơ chế cơ bản của bệnh. Tuy nhiên, nhiều mô hình học sâu không dễ diễn giải, và có nhu cầu về các mô hình có thể cung cấp kết quả có thể diễn giải.

2.7.4 Kết hợp Kiến thức Chuyên môn

Kết hợp kiến thức chuyên môn vào các mô hình ML có thể cải thiện độ chính xác và tính mạnh mẽ của chúng. Ví dụ, các mô hình kết hợp kiến thức về sinh học của cây táo và các triệu chứng bệnh có thể cải thiện độ chính xác của việc phát hiện bệnh.

2.7.5 Tích hợp với Nông nghiệp Chính xác

Các mô hình ML để phát hiện bệnh táo có thể được tích hợp với các kỹ thuật nông nghiệp chính xác để cải thiện hiệu quả và năng suất của việc quản lý bệnh. Ví dụ, các mô hình có thể được sử dụng để xác định thời điểm tối ưu để phun thuốc trừ sâu hoặc để theo dõi sự tiến triển của bệnh theo thời gian thực.

Tuy nhiên, việc tạo ra và sử dụng các mô hình ML để chẩn đoán bệnh táo không phải là không có khó khăn. Việc thiếu các bộ dữ liệu chất lượng cao, quy mô lớn là một vấn đề đáng kể. Các mô hình ML phải được đào tạo trên các bộ dữ liệu lớn, đa dạng, nắm bắt toàn bộ phổ triệu chứng bệnh và các biến môi trường nếu chúng muốn hoạt động hiệu quả.

Nhu cầu về khả năng diễn giải trong các mô hình ML đặt ra một khó khăn khác. Các mô hình học sâu có thể có độ chính xác cao, nhưng vì tính chất "hộp đen" của chúng, việc tìm hiểu các nguyên tắc cơ bản nằm dưới các dự đoán của chúng là một thách thức. Các mô hình có thể diễn giải có thể cung cấp thông tin về sinh học của cây trồng và bệnh tật, điều này rất quan trọng trong bối cảnh phát hiện bệnh.

Mặc dù có những thách thức này, việc phát triển và triển khai các mô hình ML để phát hiện bệnh táo đã cho thấy những kết quả đầy hứa hẹn. Đặc biệt, việc sử dụng CNN và các mô hình học sâu khác đã cho thấy những cải thiện đáng kể về độ chính xác phát hiện bệnh so với các kỹ thuật xử lý hình ảnh truyền thống.

2.8 KẾT LUẬN

Trong chương này, chúng tôi đã thảo luận về việc sử dụng các kỹ thuật ML để phát hiện bệnh táo. Chúng tôi đã đề cập đến các loại mô hình ML khác nhau đã được sử dụng cho ứng dụng này, quy trình đào tạo và đánh giá mô hình, cũng như các thách thức và hướng đi tương lai cho lĩnh vực này. Nhìn chung, ML có tiềm năng thay đổi cách chúng ta xác định và điều trị các bệnh táo, và cần có nghiên cứu và phát triển thêm trong lĩnh vực này.

Trong những năm sắp tới, chúng ta có thể dự đoán những gia tăng lớn về độ chính xác và hiệu quả của việc phát hiện bệnh táo do tính sẵn có ngày càng tăng của các bộ dữ liệu chất lượng cao và sự phát triển của các mô hình ML ngày càng tiên tiến. Hơn nữa, việc tích hợp

các mô hình ML với các kỹ thuật nông nghiệp chính xác có thể dẫn đến các chiến lược quản lý bệnh có mục tiêu và hiệu quả hơn, giảm việc sử dụng thuốc trừ sâu và cải thiện sức khỏe tổng thể của các vườn táo.

Tóm lại, lĩnh vực ML để phát hiện bệnh táo là một lĩnh vực đang phát triển nhanh chóng với tiềm năng đáng kể để cải thiện hiệu quả và năng suất quản lý bệnh trong các vườn táo. Nghiên cứu và phát triển liên tục trong lĩnh vực này, cùng với việc tích hợp các mô hình ML với các kỹ thuật nông nghiệp chính xác, sẽ giúp giải quyết các thách thức và mang lại những tiến bộ đáng kể trong lĩnh vực này.

TÀI LIỆU THAM KHẢO

1. Arshleen Kaur, và Raman Chadha, "Classification Techniques for Disease Detection in Plants: A Systematic Review" (Các Kỹ thuật Phân loại để Phát hiện Bệnh ở Thực vật: Tổng quan Hệ thống), 2023 International Conference on Artificial Intelligence and Smart Communication (AISC), trang 1459–1463, 2023.
2. Vibhor Kumar Vishnoi, Krishan Kumar, Rajesh Kumar, Shashank Mohan, và Arfat Ahmad Khan, "Detection of Apple Plant Diseases Using Leaf Images through Convolutional Neural Network" (Phát hiện Bệnh Thực vật Táo bằng Hình ảnh Lá cây thông qua Mạng Nơ-ron Tích chập), IEEE Access, tập 11, trang 6594–6609, 2023.
3. Satish Kumar, Rakesh Kumar, và Meenu Gupta, "Analysis of Apple Plant Leaf Diseases Detection and Classification: A Review" (Phân tích Phát hiện và Phân loại Bệnh Lá cây Táo: Tổng quan), 2022 Seventh International Conference on Parallel, Distributed and Grid Computing (PDGC), trang 361–365, 2022.
4. Kamepalli Sujatha, Ketepalli Gayatri, M. Srikanth Yadav, N. Chandra Sekhara Rao, và Bandaru Srinivasa Rao, "Customized Deep CNN for Foliar Disease Prediction Based on Features Extracted from Apple Tree Leaves Images" (CNN Sâu Tùy chỉnh để Dự đoán Bệnh Lá dựa trên Đặc trưng Trích xuất từ Hình ảnh Lá cây Táo), 2022 International Interdisciplinary Humanitarian Conference for Sustainability (IIHC), trang 193–197, 2022.
5. Harshit Singh, Kumud Saxena, và Ankit Kumar Jaiswal, "Apple Disease Classification Built on Deep Learning" (Phân loại Bệnh Táo Xây dựng trên Học Sâu), 2022 3rd International Conference on Intelligent Engineering and Management (ICIEM), trang 978–982, 2022.
6. Anupam Bonkra, Pramod Kumar Bhatt, Amandeep Kaur, và Sushil Kamboj, "Scientific Landscape and the Road Ahead for Deep Learning: Apple Leaves Disease Detection" (Bức tranh Khoa học và Con đường phía trước cho Học Sâu: Phát hiện Bệnh Lá táo), 2023 International Conference on Artificial Intelligence and Smart Communication (AISC), trang 869–873, 2023.
7. Astha Sharma, và Ashwini Kumar, "A Review: Classification and Detection of Plants Diseases Using Machine Learning and Soft Computing Techniques" (Tổng

quan: Phân loại và Phát hiện Bệnh Thực vật bằng Học máy và các Kỹ thuật Tính toán Mềm), 2022 4th International Conference on Artificial Intelligence and Speech Technology (AIST), trang 1–6, 2022.

8. Kamepalli Sujatha, Ketepalli Gayatri, M. Srikanth Yadav, N. Chandra Sekhara Rao, và Bandaru Srinivasa Rao, "Customized Deep CNN for Foliar Disease Prediction Based on Features Extracted from Apple Tree Leaves Images" (CNN Sâu Tùy chỉnh để Dự đoán Bệnh Lá dựa trên Đặc trưng Trích xuất từ Hình ảnh Lá cây Táo), 2022 International Interdisciplinary Humanitarian Conference for Sustainability (IIHC), trang 193–197, 2022.
9. Fatimah Al Heeti, và Muhammad Ilyas, "Performance Comparison of Convolutional Neural Network Models for Plant Leaf Disease Classification" (So sánh Hiệu suất của các Mô hình Mạng Nơ-ron Tích chập để Phân loại Bệnh Lá cây), 2022 International Symposium on Multidisciplinary Studies and Innovative Technologies (ISMSIT), trang 386–391, 2022.
10. Dishan Sharma, Nitika Kapoor, và Parminder Singh, "Voting Classification Method with Clustering Method for the Plant Disease Detection" (Phương pháp Phân loại Bỏ phiếu với Phương pháp Gom cụm để Phát hiện Bệnh Thực vật), 2022 International Conference on Computational Intelligence and Sustainable Engineering Solutions (CISES), trang 477–485, 2022.
11. S. Chakraborty, S. Paul, và M. Rahat-uz Zaman, "Prediction of Apple Leaf Diseases Using Multiclass Support Vector Machine" (Dự đoán Bệnh Lá Táo bằng Máy Vector Hỗ trợ Đa lớp), 2021 2nd International Conference on Robotics, Electrical and Signal Processing Techniques (ICREST), trang 147–151, IEEE, 2021.
12. Swati Singh, et al. "Deep Learning Based Automated Detection of Diseases from Apple Leaf Images" (Phát hiện Bệnh Tự động Dựa trên Học Sâu từ Hình ảnh Lá Táo), CMC-Computers, Materials & Continua, tập 71, số 1, trang 1849–1866, 2022.
13. L. Li, S. Zhang, và B. Wang, "Apple Leaf Disease Identification with a Small and Imbalanced Dataset Based on Lightweight Convolutional Networks" (Nhận dạng Bệnh Lá Táo với Bộ dữ liệu Nhỏ và Mất cân bằng Dựa trên Mạng Tích chập Hạng nhẹ), Sensors, tập 22, số 1, trang 173, 2022.
14. S. Baranwal, S. Khandelwal, và A. Arora, "Deep Learning Convolutional Neural Network for Apple Leaves Disease Detection" (Mạng Nơ-ron Tích chập Học Sâu để Phát hiện Bệnh Lá Táo), Proceedings of International Conference on Sustainable Computing in Science, Technology and Management (SUSCOM), Amity University Rajasthan, Jaipur-India, 2019.
15. M. K. Kaleem, et al., "A Modern Approach for Detection of Leaf Diseases Using Image Processing and ML Based SVM Classifier" (Phương pháp Hiện đại để Phát hiện Bệnh Lá bằng Xử lý Hình ảnh và Bộ phân loại SVM Dựa trên ML), Turkish Journal of Computer and Mathematics Education (TURCOMAT), tập 12, số 13, trang 3340–3347, 2021.
16. V. Srinidhi, A. Sahay, và K. Deeba, "Plant Pathology Disease Detection in Apple Leaves Using Deep Convolutional Neural Networks: Apple Leaves Disease

Detection Using Efficientnet and Densenet" (Phát hiện Bệnh Bệnh học Thực vật ở Lá Táo bằng Mạng Nơ-ron Tích chập Sâu: Phát hiện Bệnh Lá Táo bằng Efficientnet và Densenet), 2021 5th International Conference on Computing Methodologies and Communication (ICCMC), trang 1119–1127, IEEE, 2021.

17. M. Shuaibu, W. S. Lee, J. Schueller, P. Gader, Y. K. Hong, và S. Kim, "Unsupervised Hyperspectral Band Selection for Apple Marssonina Blotch Detection" (Chọn Dải Siêu phổ Không giám sát để Phát hiện Bệnh Đốm Lá Marssonina ở Táo), Computers and Electronics in Agriculture, tập 148, trang 45–53, 2018.
18. P. Bansal, R. Kumar, và S. Kumar, "Disease Detection in Apple Leaves Using Deep Convolutional Neural Network" (Phát hiện Bệnh ở Lá Táo bằng Mạng Nơ-ron Tích chập Sâu), Agriculture, tập 11, số 7, 2021 . https://doi.org/10.3390/agriculture11070617
19. S. Manimegalai, và G. Sivakamasundari, "Apple Leaf Disease Identification Using Support Vector Machine" (Nhận dạng Bệnh Lá Táo bằng Máy Vector Hỗ trợ), Proceedings of the International Conference on Emerging Trends in Applications of Computing (ICETAC), trang 1–4, 2017.
20. S. Alqethami, B. Almtanni, W. Alzhrani, và M. Alghamdi, "Disease Detection in Apple Leaves Using Image Processing Techniques" (Phát hiện Bệnh ở Lá Táo bằng Kỹ thuật Xử lý Hình ảnh), Engineering, Technology & Applied Science Research, tập 12, số 2, trang 8335–8341, 2022.
21. K. P. Ferentinos, "Deep Learning Models for Plant Disease Detection and Diagnosis" (Các Mô hình Học Sâu để Phát hiện và Chẩn đoán Bệnh Thực vật), Computers and Electronics in Agriculture, tập 145, trang 311–318, 2018.
22. S. P. Mohanty, D. P. Hughes, và M. Salathé, "Using Deep Learning for Image-Based Plant Disease Detection" (Sử dụng Học Sâu để Phát hiện Bệnh Thực vật Dựa trên Hình ảnh), Frontiers in Plant Science, tập 7, 1419, 2016.
23. S. Sladojevic, M. Arsenovic, A. Anderla, D. Culibrk, và D. Stefanovic, "Deep Neural Networks Based Recognition of Plant Diseases by Leaf Image Classification" (Nhận dạng Bệnh Thực vật Dựa trên Mạng Nơ-ron Sâu bằng Phân loại Hình ảnh Lá cây), Computational Intelligence and Neuroscience, 2016 . https://doi.org/10.1155/2016/3289801
24. G. Saradhambal, R. Dhivya, S. Latha, và R. Rajesh, "Plant Disease Detection and Its Solution Using Image Classification" (Phát hiện Bệnh Thực vật và Giải pháp của nó bằng Phân loại Hình ảnh), International Journal of Pure and Applied Mathematics, tập 119, trang 879–883, Thg 1 2018.
25. N. Ganatra, và A. Patel, "A Multiclass Plant Leaf Disease Detection Using Image Processing and Machine Learning Techniques" (Phát hiện Bệnh Lá Thực vật Đa lớp bằng Xử lý Hình ảnh và Kỹ thuật Học máy), International Journal on Emerging Technologies, tập 11, số 2, trang 1082–1086, 2020.
26. X. E. Pantazi, D. Moshou, và A. A. Tamouridou, "Automated Leaf Disease Detection in Different Crop Species through Image Features Analysis and One Class

Classifiers" (Phát hiện Bệnh Lá Tự động ở các Loài Cây trồng Khác nhau thông qua Phân tích Đặc trưng Hình ảnh và Bộ phân loại Một lớp), Computers and Electronics in Agriculture, tập 156, trang 96–104, Thg 1 2019 . https://doi.org/10.1016/j.compag.2018.11.005

27. V. K. Vishnoi, K. Kumar, và B. Kumar, "Plant Disease Detection Using Computational Intelligence and Image Processing" (Phát hiện Bệnh Thực vật bằng Tính toán Thông minh và Xử lý Hình ảnh), Journal of Plant Diseases and Protection, tập 128, số 1, trang 19–53, Thg 10 2021 . https://doi.org/10.1007/s41348-020-00368-0
28. S. Ramesh et al., "Plant Disease Detection Using Machine Learning" (Phát hiện Bệnh Thực vật bằng Học máy), 2018 International Conference on Design Innovations for 3Cs Compute Communicate Control (ICDI3C), trang 41–45, Thg 4 2018 . https://doi.org/10.1109/ICDI3C.2018.00017
29. T. Fang, P. Chen, J. Zhang, và B. Wang, "Identification of Apple Leaf Diseases Based on Convolutional Neural Network" (Nhận dạng Bệnh Lá Táo Dựa trên Mạng Nơ-ron Tích chập), Intelligent Computing Theories and Application, trang 553–564, 2019 . https://doi.org/10.1007/978-3-030-26763-6 _53
30. P. Jiang, Y. Chen, B. Liu, D. He, và C. Liang, "Real-Time Detection of Apple Leaf Diseases Using Deep Learning Approach Based on Improved Convolutional Neural Networks" (Phát hiện Bệnh Lá Táo Thời gian Thực bằng Phương pháp Học Sâu Dựa trên Mạng Nơ-ron Tích chập Cải tiến), IEEE Access, tập 7, trang 59069–59080, 2019 . https://doi.org/10.1109/ACCESS.2019.2914929
31. B. Liu, Y. Zhang, D. He, và Y. Li, "Identification of Apple Leaf Diseases Based on Deep Convolutional Neural Networks" (Nhận dạng Bệnh Lá Táo Dựa trên Mạng Nơ-ron Tích chập Sâu), Symmetry, tập 10, số 1, Thg 1 2018 . https://doi.org/10.3390/sym10010011
32. F. Mohameth, C. Bingcai, và K. A. Sada, "Plant Disease Detection with Deep Learning and Feature Extraction Using Plant Village" (Phát hiện Bệnh Thực vật bằng Học Sâu và Trích xuất Đặc trưng bằng Plant Village), Journal of Computer and Communications, tập 8, số 6, trang 10–22, Thg 6 2020 . https://doi.org/10.4236/jcc.2020.86002
33. M. H. Saleem, J. Potgieter, và K. M. Arif, "Plant Disease Detection and Classification by Deep Learning" (Phát hiện và Phân loại Bệnh Thực vật bằng Học Sâu), Plants, tập 8, số 11, Thg 11 2019, Bài báo số 468 . https://doi.org/10.3390/plants8110468
34. P. Kulkarni, A. Karwande, T. Kolhe, S. Kamble, A. Joshi, và M. Wyawahare, "Plant Disease Detection Using Image Processing and Machine Learning" (Phát hiện Bệnh Thực vật bằng Xử lý Hình ảnh và Học máy), arXiv:2106.10698 [cs], Thg 11 2021.
35. S. Singh, và S. Gupta, "Apple Scab and Marsonina Coronaria Diseases Detection in Apple Leaves Using Machine Learning" (Phát hiện Bệnh Ghẻ Táo và Đốm lá Marsonina Coronaria ở Lá Táo bằng Học máy), International Journal of Pure and Applied Mathematics, tập 118, trang 1151–1166, Thg 1 2018.

36. T. Talaviya, D. Shah, N. Patel, H. Yagnik, và M. Shah, “Implementation of Artificial Intelligence in Agriculture for Optimisation of Irrigation and Application of Pesticides and Herbicides” (Triển khai Trí tuệ Nhân tạo trong Nông nghiệp để Tối ưu hóa Thủy lợi và Ứng dụng Thuốc trừ sâu và Thuốc diệt cỏ), Artificial Intelligence in Agriculture, tập 4, trang 58–73, 2020 . https://doi.org/10.1016/j.aiia.2020.04.002
37. R. A. Bahn, A. A. K. Yehya, và R. Zurayk, “Digitalization for Sustainable Agri-Food Systems: Potential, Status, and Risks for the MENA Region” (Số hóa cho Hệ thống Nông nghiệp-Thực phẩm Bền vững: Tiềm năng, Tình trạng và Rủi ro cho Khu vực MENA), Sustainability, tập 13, số 6, 3223, 2021 . https://doi.org/10.3390/su13063223
38. S. N. H. Bukhari, J. Webber, và A. Mehbodniya, “Decision Tree Based Ensemble Machine Learning Model for the Prediction of Zika Virus T-cell Epitopes as Potential Vaccine Candidates” (Mô hình Học máy Tập hợp Dựa trên Cây Quyết định để Dự đoán Epitope Tế bào T của Virus Zika làm Ứng viên Vắc-xin Tiềm năng), Scitific Reports, tập 12, 7810, 2022 . https://doi.org/10.1038/s41598-022-11731-6
39. G. S. Raghavendra, S. Shyni Carmel Mary, Purnendu Bikash Acharjee, V. L. Varun, Syed Nisar Hussain Bukhari, Chiranjit Dutta, và Issah Abubakari Samori, “An Empirical Investigation in Analysing the Critical Factors of Artificial Intelligence in Influencing the Food Processing Industry: A Multivariate Analysis of Variance (MANOVA) Approach” (Một Điều tra Thực nghiệm trong Phân tích các Yếu tố Quan trọng của Trí tuệ Nhân tạo trong việc Ảnh hưởng đến Ngành Công nghiệp Chế biến Thực phẩm: Phương pháp Phân tích Phương sai Đa biến (MANOVA)), Journal of Food Quality, tập 2022, Bài báo ID 2197717, 7 trang, 2022 . https://doi.org/10.1155/2022/2197717
40. S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, và J. Webber, “Ensemble Machine Learning Model to Predict SARS-CoV-2 T-Cell Epitopes as Potential Vaccine Targets” (Mô hình Học máy Tập hợp để Dự đoán Epitope Tế bào T của SARS-CoV-2 làm Mục tiêu Vắc-xin Tiềm năng), Diagnostics, tập 11, số 11, trang 1990, 2021. MDPI AG . https://doi.org/10.3390/diagnostics11111990
41. Sunil L. Bangare, Deepali Virmani, Girija Rani Karetla, Pankaj Chaudhary, Harveen Kaur, Syed Nisar Hussain Bukhari, và Shahajan Miah, “Forecasting the Applied Deep Learning Tools in Enhancing Food Quality for Heart Related Diseases Effectively: A Study Using Structural Equation Model Analysis” (Dự báo các Công cụ Học Sâu Ứng dụng trong việc Nâng cao Chất lượng Thực phẩm cho các Bệnh Liên quan đến Tim một cách Hiệu quả: Một Nghiên cứu sử dụng Phân tích Mô hình Phương trình Cấu trúc), Journal of Food Quality, tập 2022, Bài báo ID 6987569, 8 trang, 2022 . https://doi.org/10.1155/2022/6987569
42. C. M. Anoruo, S. N. H. Bukhari, và O. K. Nwofor, “Modeling and Spatial Characterization of Aerosols at Middle East AERONET Stations” (Mô hình hóa và Đặc trưng hóa Không gian của Khí dung tại các Trạm AERONET ở Trung Đông),

Theoretical and Applied Climatology, tập 152, trang 617–625, 2023 . https://doi.org/10.1007/s00704-023-04384-6

43. F. Masoodi, M. Quasim, S. Bukhari, S. Dixit, và S. Alam, Applications of Machine Learning and Deep Learning on Biological Data (Các Ứng dụng của Học máy và Học Sâu trên Dữ liệu Sinh học), CRC Press, 2023.
44. S. N. H. Bukhari, A. Jain, và E. Haq, "A Novel Ensemble Machine Learning Model for Prediction of Zika Virus T-Cell Epitopes" (Một Mô hình Học máy Tập hợp Mới để Dự đoán Epitope Tế bào T của Virus Zika), trong Gupta, D., Polkowski, Z., Khanna, A., Bhattacharyya, S., và Castillo, O. (chủ biên) Proceedings of Data Analytics and Management (Kỷ yếu Phân tích và Quản lý Dữ liệu). Lecture Notes on Data Engineering and Communications Technologies, tập 91. Springer, Singapore, 2022 . https://doi.org/10.1007/978-981-16-6285-0 _23
45. S. N. H. Bukhari, F. Masoodi, M. A. Dar, N. I. Wani, A. Sajad, và G. Hussain, "Prediction of Erythemato-Squamous Diseases Using Machine Learning" (Dự đoán Bệnh Đỏ da-Có vảy bằng Học máy), trong Auerbach Publications eBooks, 2023, trang 87–96 . http://doi.org/10.1201/9781003328780-6
46. S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, và J. Webber, "Machine Learning Techniques for the Prediction of B-Cell and T-Cell Epitopes as Potential Vaccine Targets with a Specific Focus on SARS-CoV-2 Pathogen: A Review" (Các Kỹ thuật Học máy để Dự đoán Epitope Tế bào B và Tế bào T làm Mục tiêu Vắc-xin Tiềm năng với Trọng tâm Cụ thể vào Tác nhân Gây bệnh SARS-CoV-2: Một Tổng quan), Pathogens, tập 11, số 2, trang 146, 2022. MDPIAG . http://doi.org/10.3390/pathogens11020146
47. S. Nisar, H. Bukhari, và M. A. Dar, "Using Random Forest to Predict T-Cell Epitopes of Dengue Virus" (Sử dụng Rừng Ngẫu nhiên để Dự đoán Epitope Tế bào T của Virus Dengue), Advances and Applications in Mathematical Sciences, tập 20, số 11, trang 2543–2547, 2021.

CHƯƠNG 3: ĐẦU VÀO THÔNG MINH CÁCH MẠNG HÓA NÔNG NGHIỆP: MỘT NGHIÊN CỨU PHÂN TÍCH

Nelofar Ara, Sani Mustapha Kura, VK Aswathy, và Mohammad Amin Wani Đại học Lovely Professional, Phagwara, Ấn Độ

3.1 GIỚI THIỆU

Nông nghiệp đóng vai trò trung tâm trong nền kinh tế của mọi quốc gia. Nhu cầu về lương thực đang gia tăng mỗi ngày, cùng với sự gia tăng dân số thế giới [1]. Hiện tại, các kỹ thuật truyền thống của nông dân không thể đáp ứng được nhu cầu. Nhiều phương pháp sáng tạo về tự động hóa đã được tạo ra để đáp ứng những nhu cầu này, mang lại cơ hội nghề nghiệp tuyệt vời cho nhiều người trong lĩnh vực này. Trong suốt lịch sử loài người, công nghệ từ lâu đã được sử dụng trong nông nghiệp để nâng cao hiệu quả và giảm cường độ lao động của nông nghiệp. Kể từ khi phát minh ra trồng trọt, con người và nông nghiệp đã phát triển từ các luồng dẫn nước tốt hơn đến hệ thống tưới tiêu, máy kéo và trí tuệ nhân tạo (AI) hiện đại [2]. Khả năng sẵn có ngày càng tăng và dễ tiếp cận hơn của thị giác máy tính có thể là một bước tiến lớn trong lĩnh vực này. Khi những thay đổi toàn cầu quan trọng xảy ra trong khí hậu, sinh thái và nhu cầu lương thực của chúng ta, AI có thể biến đổi nền nông nghiệp của thế kỷ 21 theo những cách sau:

- Cải thiện hiệu quả thời gian, lao động và tài nguyên
- Tăng tính bền vững của môi trường
- Phân bổ tài nguyên nhỏ hơn
- Cung cấp giám sát thời gian thực để khuyến khích cải thiện chất lượng và sức khỏe sản phẩm.

Để AI đạt được điều này, lĩnh vực nông nghiệp phải thay đổi. Điều này đòi hỏi nhiều đầu tư hơn về mặt kỹ thuật và sư phạm vào lĩnh vực nông nghiệp để chuyển đổi kiến thức của nông dân về "lĩnh vực" của họ thành đào tạo AI. Tuy nhiên, sự khéo léo và khả năng thích ứng trong nông nghiệp là không có gì mới mẻ. Đối với nông dân, thị giác máy tính và robot nông nghiệp là những cách mới nhất để sử dụng công nghệ mới nhằm đáp ứng nhu cầu lương thực toàn cầu và cải thiện an ninh lương thực. Không còn nghi ngờ gì nữa, các phương pháp làm việc, năng suất và chất lượng nông nghiệp ngày nay vượt xa 500 hay thậm chí 50 năm trước. Tuy nhiên, vẫn còn rất nhiều chỗ để cải thiện. Đến năm 2050, hành tinh sẽ là nhà của 9,9 tỷ người, sau đó nhu cầu lương thực dự kiến sẽ tăng từ 35% lên 56%. Chưa kể đến việc biến đổi khí hậu đang làm cạn kiệt tài nguyên thiên nhiên, chẳng hạn như nước và đất nông nghiệp. May mắn thay, công nghệ mang đến cho chúng ta một nguồn tài nguyên khác: AI. Lĩnh vực nông nghiệp đang phát triển với một tốc độ hoàn toàn mới khi những tiến bộ trong phát hiện bệnh, phân tích dự đoán và công nghệ thị giác máy tính được sử dụng để giám sát cây trồng và đất đai. Bên cạnh tiềm năng, còn có sự quan tâm và đầu tư ngày càng tăng nhanh chóng: Theo *Forbes*, nông nghiệp "thông

minh" toàn cầu, bao gồm học máy và AI, dự kiến sẽ tăng gấp ba lần lên 15,3 tỷ USD vào năm 2025. Các nhà nghiên cứu dự đoán thị trường AI trong nông nghiệp sẽ tăng trưởng với tốc độ tăng trưởng kép hàng năm (CAGR) là 20% để đạt 2,5 tỷ USD vào năm 2026. Và đó mới chỉ là sự khởi đầu! Chương này xem xét các ứng dụng sáng tạo nhất của AI đang định hình lại ngành công nghiệp nông nghiệp, bao gồm những điều sau.

3.1.1 Giám Sát Cây Trồng và Đất Đai

Thành phần vi lượng và đa lượng của đất ảnh hưởng trực tiếp đến số lượng, chất lượng và sức khỏe chung của cây trồng [3]. Để nông dân tối đa hóa hiệu quả sản xuất, điều quan trọng là kiểm soát các giai đoạn phát triển của cây sau khi trồng chúng xuống đất. Hiểu mối quan hệ giữa sự phát triển của cây trồng và môi trường là rất quan trọng để thực hiện các thay đổi nhằm cải thiện sức khỏe cây trồng. Trước đây, các quan sát và đánh giá của con người đã được sử dụng để đánh giá sức khỏe của đất và cây trồng. Tuy nhiên, cách tiếp cận này không chính xác và cũng không cập nhật. Thay vào đó, máy bay không người lái (UAV) hiện được sử dụng để chụp ảnh trên không và huấn luyện các mô hình thị giác máy tính có thể được sử dụng để giám sát thông minh tình trạng cây trồng và đất đai. Nông dân có thể hành động nhanh chóng bằng cách tìm hiểu các khu vực có vấn đề cụ thể thông qua việc sử dụng các mô hình AI.

3.1.2 Quan Sát Độ Chín Của Cây Trồng

Một nhiệm vụ đòi hỏi nhiều lao động như vậy, liên quan đến việc giám sát thủ công giai đoạn tăng trưởng của bông lúa mì, có thể được AI hỗ trợ trong độ chính xác của nông nghiệp. Các nhà nghiên cứu đã có thể xây dựng một "cơ chế phát hiện tai lúa mì hai giai đoạn từ thô đến tinh" bằng cách thu thập ảnh chụp lúa mì ở các giai đoạn "định hướng" khác nhau trong ba năm và trong các điều kiện ánh sáng khác nhau. Nông dân không còn phải ra đồng mỗi ngày để kiểm tra cây trồng của mình vì mô hình thị giác máy tính này đã xác định các giai đoạn tăng trưởng của lúa mì chính xác hơn so với quan sát của con người. Một nghiên cứu khác đã xem xét độ chính xác của việc phát hiện độ chín của cà chua bằng thị giác máy tính. Các nhà nghiên cứu đã phát triển một thuật toán kiểm tra màu sắc của năm thành phần cà chua khác nhau và sử dụng kết quả để xác định mức độ chín của quả cà chua. Phương pháp này đạt được tỷ lệ phát hiện và phân loại thành công là 99,31%. Việc chăm sóc quá mức và đánh giá quá cao sự phát triển và độ chín của cây trồng đòi hỏi rất nhiều công sức từ nông dân. Tuy nhiên, AI cho thấy khả năng xử lý một phần đáng kể công việc một cách dễ dàng và hoàn hảo.

3.1.3 Tiếp Đất Với Thị Giác Máy Tính

Quay trở lại với tầm quan trọng của đất, một nghiên cứu riêng biệt đã kiểm tra độ chính xác của hình ảnh thị giác máy tính về cấu trúc đất và chất hữu cơ trong đất (SOM). Thông thường, nông dân phải thu thập mẫu đất từ đồng ruộng và mang chúng đến phòng thí nghiệm để đánh giá tốn nhiều công sức và thời gian [4]. Thay vào đó, các nhà nghiên cứu quyết định xem liệu họ có thể đào tạo một thuật toán để thực hiện cùng một nhiệm vụ bằng cách sử dụng dữ liệu hình ảnh từ một kính hiển vi cầm tay giá rẻ hay không. Mô

hình thị giác máy tính đã có thể cung cấp các ước tính về SOM và hàm lượng cát chính xác như quy trình xử lý trong phòng thí nghiệm đắt tiền. Kết quả là, thị giác máy tính không chỉ có thể loại bỏ một phần đáng kể lao động thủ công tốn nhiều công sức trong giám sát cây trồng và đất đai mà còn thường làm điều đó hiệu quả hơn con người.

3.1.4 Phát Hiện Côn Trùng Và Bệnh Thực Vật

Chúng ta đã thấy hình ảnh máy tính được hỗ trợ bởi AI có thể xác định và đánh giá độ chín của cây trồng và chất lượng đất, nhưng còn những tình huống nông nghiệp khó dự đoán hơn thì sao? Sử dụng công nghệ nhận dạng hình ảnh dựa trên học sâu, giờ đây có thể tự động phát hiện bệnh thực vật và sâu bệnh. Nó hoạt động bằng cách tạo ra các mô hình có thể giám sát sức khỏe của cây trồng bằng cách sử dụng các kỹ thuật phân loại, nhận dạng và phân đoạn hình ảnh.

3.1.5 Loại Bỏ Những Quả Táo Xấu (Chẩn Đoán Mức Độ Nghiêm Trọng Của Bệnh)

Một nghiên cứu về bệnh thối đen trên táo – thứ mà tất cả chúng ta chắc chắn không muốn thấy trên những quả táo của mình! – đưa ra một ví dụ điển hình trong thực tế. Mạng nơ-ron tích chập sâu (Deep Convolutional Neural Network) đã được huấn luyện bằng cách sử các bức ảnh chụp táo bị thối, mà các nhà thực vật học đã phân loại thành bốn mức độ nghiêm trọng. Giải pháp thay thế bằng thị giác máy tính, như trong các trường hợp trước đây của chúng ta, đòi hỏi quá trình tìm kiếm và đánh giá thủ công tốn nhiều công sức. May mắn cho các nhà nông nghiệp, mô hình AI được sử dụng trong nghiên cứu này có độ chính xác 90,4% trong việc phát hiện và chẩn đoán mức độ nghiêm trọng của bệnh! Trong một nghiên cứu bổ sung, các nhà nghiên cứu đã tiến xa hơn bằng cách sử dụng thuật toán YOLO v3 tiên tiến để phát hiện nhiều bệnh và sâu bệnh trên cây cà chua. Sử dụng máy ảnh kỹ thuật số và điện thoại thông minh, các nhà nghiên cứu đã chụp ảnh sự hiện diện của 12 loại bệnh hoặc sâu bệnh khác nhau trong các nhà kính trồng cà chua lân cận. Mô hình được huấn luyện với các hình ảnh có độ phân giải và kích thước đối tượng khác nhau, sau đó nó có thể xác định bệnh và sâu bệnh với độ chính xác 92,39% trong vòng chưa đến 20,39 mili giây.

3.1.6 Tìm Bọ Bằng Mã

Trước tiên, các nhà phân tích đặt một bẫy dính để bắt sáu loại côn trùng bay khác nhau và chụp ảnh thời gian thực. Họ sử dụng nhận dạng đối tượng YOLO để phát hiện đối tượng và các phép tính thô, đồng thời sử dụng máy vectơ hỗ trợ (SVM) với các đặc trưng toàn cục để phân loại đối tượng và các phép tính tinh. Khi mọi thứ hoàn tất, mô hình thị giác máy tính của họ đã có thể đếm chúng với độ chính xác 92,5% và phân biệt giữa ong, ruồi, muỗi, bướm đêm, ong bắp cày và ruồi giấm với độ chính xác 90,18%. Theo nghiên cứu này, AI dựa trên thị giác máy tính có tiềm năng giám sát sức khỏe của các hệ thống lương thực của chúng ta. Ngoài ra, nó làm giảm sự kém hiệu quả trong lao động trong khi vẫn duy trì độ chính xác của các quan sát.

3.1.7 Giám Sát Sức Khỏe Vật Nuôi

Cho đến nay, chúng ta chủ yếu nói về cây trồng, nhưng nông nghiệp bao gồm nhiều thứ hơn lúa mì, cà chua và táo. Hệ thống nông nghiệp của chúng ta cũng phụ thuộc rất nhiều vào động vật, những loài đòi hỏi sự quản lý nhiều hơn một chút so với thực vật. Liệu thị giác máy tính có thể theo kịp lợn, bò và gà? Cattle-Eye là một ví dụ tuyệt vời về AI trong nông nghiệp. Họ sử dụng camera trên không và các thuật toán thị giác máy tính để giám sát sức khỏe và hành vi của vật nuôi. Điều này có nghĩa là người nông dân không nhất thiết phải đứng cạnh con bò để nhìn thấy vấn đề. Bằng cách giám sát và theo dõi đàn từ xa theo thời gian thực, người nông dân có thể được cảnh báo ngay khi phát hiện ra vấn đề. Vật nuôi không phải là đối tượng duy nhất. Ngoài ra, thị giác máy tính cho phép thực hiện những việc sau:

- Đếm động vật, tìm kiếm bệnh tật, phát hiện hành vi bất thường và theo dõi các hoạt động quan trọng, chẳng hạn như sinh đẻ.
- Thu thập thông tin bằng máy bay không người lái và camera.
- Kết hợp điều này với các công nghệ khác để hướng dẫn nông dân về sức khỏe và thức ăn cho động vật, cũng như tình trạng sẵn có của nước.

3.1.8 Phun Thuốc Thông Minh

UAV được trang bị thị giác máy tính. AI cho phép áp dụng thuốc trừ sâu hoặc phân bón tự động và nhất quán trên toàn bộ cánh đồng. Việc phát hiện khu vực phun mục tiêu theo thời gian thực cho phép máy phun UAV hoạt động với độ chính xác cao về khu vực phun và khối lượng phun. Kết quả là, khả năng gây ô nhiễm cây trồng, vật nuôi, con người và hệ thống nước ít hơn đáng kể. Mặc dù nơi này có rất nhiều tiềm năng, nhưng vẫn còn những thách thức. Ví dụ, sử dụng nhiều UAV để phun một khu vực rộng lớn hiệu quả hơn nhiều, nhưng có thể khó xác định các chu kỳ nhiệm vụ và đường bay cụ thể cho từng phương tiện. Tuy nhiên, điều này không có nghĩa là phun thuốc thông minh không còn là một lựa chọn [5]. Các nhà nghiên cứu tại Virginia Tech đã phát triển một hệ thống phun thông minh dựa trên máy phun dẫn động bằng servo sử dụng thị giác máy tính để xác định cỏ dại. Một camera gắn trên máy phun ghi lại vị trí địa lý của cỏ dại và đánh giá kích thước, hình dạng và màu sắc của từng cây khó nắm bắt để cung cấp chính xác lượng thuốc diệt cỏ đến mục tiêu. Nói cách khác, nó hoạt động như một loại thuốc diệt cỏ. Không giống như Kẻ Hủy Diệt (Terminator), hệ thống thị giác máy tính có thể bắn chính xác đến mức ngăn chặn thiệt hại thêm cho con mồi hoặc môi trường.

3.1.9 Làm Cỏ Tự Động

Việc sử dụng AI mở rộng ra ngoài các vòi phun kiểm soát cỏ dại. Các robot thị giác máy tính khác, trực tiếp hơn, sẽ loại bỏ các cây không mong muốn. Trong khi thị giác máy tính có thể phát hiện một con côn trùng hoặc một con gà có hành vi kỳ lạ, thì việc phát hiện cỏ dại không giúp người nông dân tiết kiệm nhiều công sức. Để AI trở nên hữu ích hơn, nó cần phải tìm và loại bỏ cỏ dại. Khả năng loại bỏ cỏ dại bằng tay không chỉ giúp

tiết kiệm công sức cho người nông dân mà còn giảm nhu cầu sử dụng thuốc trừ sâu, làm cho toàn bộ quá trình canh tác trở nên thân thiện với môi trường và bền vững hơn nhiều.

3.1.10 Robot Giữa Đám Cỏ

Với việc phát hiện mục tiêu, cỏ dại và cây trồng có thể dễ dàng phân biệt với nhau. Nhưng sức mạnh thực sự được thấy khi kỹ thuật thị giác máy tính và học máy được áp dụng để chế tạo robot làm cỏ. Tất cả những điều này là một phần giới thiệu tuyệt vời về BoniRob, một robot nông nghiệp sử dụng camera và công nghệ nhận dạng hình ảnh để tìm kiếm cỏ dại và sau đó đuổi chúng ra khỏi mặt đất. Nó có được khả năng phân biệt giữa cỏ dại và cây trồng thông qua đào tạo trực quan dựa trên kích thước, hình dạng và màu sắc của lá. Bằng cách này, BoniRob có thể loại bỏ các cây không mong muốn khỏi cánh đồng mà không phải lo lắng về việc phá hủy bất cứ thứ gì không thể thay thế được. Để đạt được điều này, các nhà nghiên cứu đang tạo ra robot nông nghiệp để phát hiện cỏ dại và độ ẩm của đất. Bằng cách này, nó có thể di chuyển xung quanh cánh đồng, loại bỏ cây cối và tưới đẫm đất với lượng nước vừa đủ. Theo kết quả kiểm tra, tỷ lệ phân loại và tiêu diệt thực vật của công nghệ này là 90% trở lên, trong khi hàm lượng ẩm của đất sâu được duy trì ở mức 80%–10%.

3.1.11 Khảo Sát và Chụp Ảnh Trên Không

Không có gì ngạc nhiên khi thị giác máy tính có những ứng dụng tuyệt vời cho việc lập bản đồ đất đai và giám sát cây trồng, vật nuôi. Tuy nhiên, điều này không làm giảm tầm quan trọng của nó đối với nông nghiệp thông minh. AI có thể phân tích cảnh quay từ vệ tinh và máy bay không người lái để giúp nông dân giám sát vật nuôi và cây trồng của họ. Họ sẽ được thông báo ngay khi có điều gì đó bất thường xuất hiện, vì vậy họ không phải liên tục kiểm tra đồng ruộng trực tiếp. Chụp ảnh trên không cải thiện độ chính xác và hiệu quả của việc áp dụng thuốc trừ sâu. Như đã đề cập trước đây, đảm bảo rằng thuốc trừ sâu đến được đích đến dự định của chúng giúp tiết kiệm chi phí và có lợi cho môi trường.

3.1.12 Phân Loại và Sắp Xếp Sản Phẩm

Thị giác máy tính dựa trên AI có thể tiếp tục hỗ trợ nông dân sau thu hoạch. Với sự trợ giúp của các thuật toán hình ảnh, các khuyết tật, bệnh tật và sâu bệnh có thể được phát hiện trong quá trình sinh trưởng của cây, và các sản phẩm "tốt" có thể được phân biệt với các sản phẩm bị lỗi hoặc không đạt yêu cầu. Thị giác máy tính có thể tự động hóa việc phân loại và sắp xếp bằng cách phân tích kích thước, hình dạng, màu sắc và số lượng của trái cây và rau quả với độ chính xác và tốc độ cao hơn nhiều so với các chuyên gia có trình độ.

3.1.13 Sản Phẩm Hoàn Hảo Trong Hình Ảnh

Để phân biệt giữa cà rốt có khuyết tật bề mặt hoặc cà rốt không đúng kích thước và hình dạng, các nhà nghiên cứu đã tạo ra một phương pháp tự động để phân loại chúng. Do đó, một củ cà rốt "tốt" phải có hình dạng chính xác ("đa giác lồi") và không được có rễ sợi

hoặc vết nứt trên bề mặt. Phun thuốc thông minh không còn là một lựa chọn [5]. Các nhà nghiên cứu tại Virginia Tech đã phát triển một hệ thống phun thông minh dựa trên máy phun dẫn động bằng servo sử dụng thị giác máy tính để xác định cỏ dại. Một camera gắn trên máy phun ghi lại vị trí địa lý của cỏ dại và đánh giá kích thước, hình dạng và màu sắc của từng cây khó nắm bắt để cung cấp chính xác lượng thuốc diệt cỏ đến mục tiêu. Nói cách khác, nó hoạt động như một loại thuốc diệt cỏ. Trong cả hai trường hợp, một lượng lớn lao động chân tay tốn nhiều công sức đã được tiết kiệm. Hình 3.1 cho thấy điều này một cách rõ ràng:

Ở phía bên trái: - Hình ảnh một cánh đồng có cỏ dại - Camera gắn trên máy phun dẫn động bằng servo - Các mũi tên chỉ việc thu thập dữ liệu (vị trí, kích thước, hình dạng, màu sắc) - Hành động phun thuốc diệt cỏ

Ở phía bên phải: - Robot nông nghiệp (được mô tả là robot với các công cụ khác nhau) - Giám sát đất trồng trọt (được mô tả là đất có cảm biến) - Chẩn đoán bệnh (được mô tả là một cây với kính lúp)

Hệ thống phun thông minh của Virginia Tech sử dụng thị giác máy tính để phát hiện cỏ dại, tối ưu hóa việc sử dụng thuốc diệt cỏ và giảm lao động. Sự đổi mới này được tích hợp với các công nghệ nông nghiệp khác để quản lý trang trại toàn diện.



HÌNH 3.1 Hệ thống phun thông minh của Virginia Tech - Nông nghiệp môi trường có kiểm soát nhà kính.

Nguồn: https://www.bing.com/images/search/yield-gruetzmacher-ai-automation-greenhouse-controlled-environment-agriculture

3.2 PHÂN TÍCH DỮ LIỆU TRANG TRẠI SỬ DỤNG AI

Thật tuyệt vời khi giờ đây nông dân có thể thu thập và phân tích dữ liệu từ đồng ruộng của họ nhờ AI; thời tiết, nhiệt độ, lượng nước tiêu thụ, điều kiện đất đai, v.v., cũng có thể được ghi lại theo thời gian thực. Mỗi ngày, hàng nghìn điểm dữ liệu đồng ruộng được ghi nhận trên đồng ruộng. Công nghệ AI đang giúp nông dân cải thiện năng suất thông qua nông nghiệp chính xác, giúp cải thiện việc lựa chọn cây trồng, lựa chọn hạt giống lai, sử dụng tài nguyên, chất lượng cây trồng và độ chính xác của cây trồng [6]. Nông nghiệp

chính xác sử dụng công nghệ AI để phát hiện bệnh, sâu bệnh và suy dinh dưỡng trên đồng ruộng. Cảm biến AI có thể phát hiện cỏ dại, nhắm mục tiêu vào chúng và chọn loại thuốc trừ sâu và thuốc diệt cỏ nào để áp dụng trong một vùng đệm được xác định [7]. Điều này giúp nông dân tối đa hóa số lượng thuốc trừ sâu và thuốc diệt cỏ họ sử dụng. Ngoài ra, AI giúp nông dân tạo ra các mô hình dự báo theo mùa để tăng sản xuất và độ chính xác của cây trồng. Sử dụng công nghệ để dự đoán xu hướng thời tiết trong những tháng tới cũng có thể giúp nông dân đưa ra quyết định thông minh hơn. Các trang trại nhỏ ở các nước kém phát triển là mục tiêu chính cho dự báo theo mùa, vì thông tin và dữ liệu có thể khan hiếm. Những nông dân nhỏ này phải sản xuất ra những vụ mùa tốt nhất vì họ sản xuất 70% sản lượng cây trồng của thế giới. Nông dân sử dụng camera trên máy bay không người lái được hỗ trợ bởi AI cùng với dữ liệu địa hình để chụp ảnh sản phẩm của họ tốt hơn và phân tích ảnh hiện trường theo thời gian thực để xác định các vấn đề tiềm ẩn và các khu vực cần cải thiện. Máy bay không người lái giám sát sản phẩm hiệu quả hơn và có thể bao phủ một khu vực rộng lớn hơn con người. Việc sử dụng các kỹ thuật nhận dạng hình ảnh dựa trên AI để chẩn đoán bệnh, phát hiện sự xâm nhập của côn trùng và nhận dạng thực vật cũng đang ngày càng trở nên phổ biến. Một chương trình dựa trên sự hiểu biết X-Fito đã được tạo ra bởi Cruz et al. (2017) để xác định các dấu hiệu của Hội chứng Suy giảm Nhanh trên cây Ô liu (OQDS) [8]. Hệ thống sử dụng mạng nơ-ron tập trung vào phép biến đổi (DP-CNN) và các kỹ thuật hợp nhất cấp độ trừu tượng mới để cải thiện độ chính xác chẩn đoán. Hệ thống PCA (Phân tích Thành phần Chính) của Crus cho các ứng dụng công nghiệp được nông dân sử dụng theo cách tương tự để đưa ra quyết định quản lý nhanh chóng và giảm thiểu bệnh tật (Ibid).

3.2.1 Quản Lý Năng Suất Sử Dụng AI

AI, công nghệ đám mây, hình ảnh vệ tinh và phân tích tiên tiến đã tạo ra một hệ sinh thái canh tác thông minh hiện đại. Bằng cách kết hợp các công nghệ này, nông dân có thể tăng năng suất trung bình và kiểm soát giá cả tốt hơn. Cortana Intelligence Suite và học máy là hai dịch vụ tư vấn mà Microsoft hiện đang cung cấp cho nông dân ở Andhra Pradesh. Dự án thí điểm này đã sử dụng các ứng dụng AI trong nông nghiệp để cung cấp dữ liệu, chuẩn bị đất, bón phân dựa trên kiểm tra đất, xử lý hạt giống, độ sâu gieo hạt lý tưởng, v.v. Robot di động và cảm biến hiện trường hỗ trợ robot canh tác kỹ thuật số, camera đa chức năng và máy quét laser trong các điểm mù và khu vực không dây.

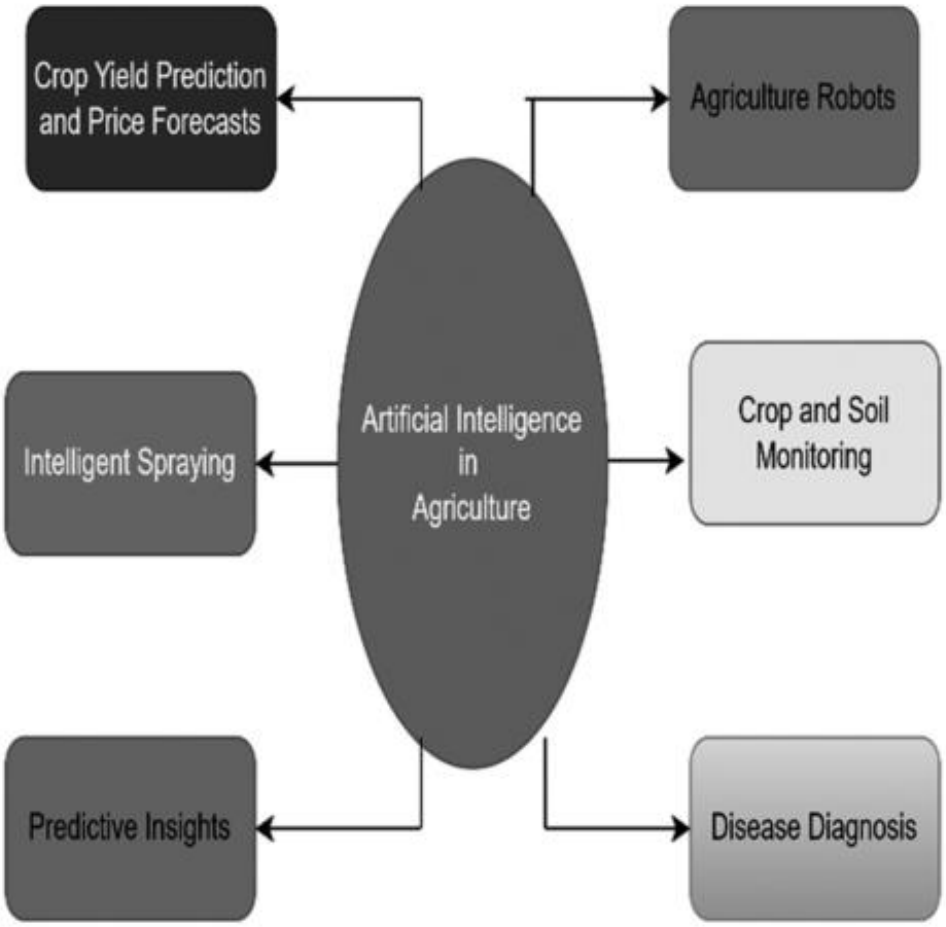
3.2.1.1 Giải Quyết Thách Thức Về Lao Động

Do sự di cư ồ ạt của lao động đến thành phố, các hoạt động trang trại hiện đang bị đình trệ. Robot được trang bị AI cải thiện năng suất của nhân viên theo một số cách khác nhau. Những robot này có thể thu hoạch nhanh hơn và phát hiện cũng như loại bỏ cỏ dại chính xác hơn, làm giảm chi phí vận hành và lao động. Hiện nay, người nông dân đang tìm hiểu về chatbot để được trợ giúp [9]. Chatbot hỗ trợ nông dân bằng cách trả lời câu hỏi của họ và đưa ra lời khuyên, hướng dẫn về các vấn đề nông nghiệp cụ thể.

3.2.1.1.1 Ứng Dụng Của AI Trong Nông Nghiệp

Trong hình trên, các công nghệ AI được mô tả ở phía bên trái, thể hiện vai trò của chúng trong các khía cạnh khác nhau của nông nghiệp, bao gồm dự báo sản lượng cây trồng và giá cả, phun thuốc thông minh và cung cấp thông tin chi tiết mang tính sản xuất. Ở phía bên phải, AI được cho thấy là tạo điều kiện kết nối với robot nông nghiệp, giám sát đất trồng trọt và chẩn đoán bệnh. Điều này minh họa tác động toàn diện của AI trong việc tối ưu hóa các quy trình nông nghiệp, từ nâng cao năng suất đến cho phép các phương pháp quản lý chính xác và kiểm soát bệnh chủ động.

Giống như với các phương pháp canh tác truyền thống, nông dân phải đối mặt với nhiều thách thức. Trong lĩnh vực này, AI thường được sử dụng để giải quyết những vấn đề này (Hình 3.2). AI là một công nghệ tiên phong trong nông nghiệp ngày nay. Điều này mang lại lợi ích trong việc sản xuất cây trồng khỏe mạnh hơn, kiểm soát dịch hại, giám sát đất đai và hơn thế nữa [10].



HÌNH 3.2 Các ứng dụng của AI trong nông nghiệp.

Nguồn: Được chuẩn bị bởi các nhà nghiên cứu

3.3 CÁC CÔNG TY KHỞI NGHIỆP AI TRONG NÔNG NGHIỆP

Dựa trên các đầu vào dữ liệu, nhiều nỗ lực đang được thực hiện trên toàn cầu để tự động hóa hoạt động của các doanh nghiệp nông nghiệp và sử dụng AI cùng các công nghệ liên quan để hợp lý hóa nông nghiệp [8]. Điều này đã dẫn đến sự ra đời của vô số công ty khởi nghiệp.

- **Prospera:** Công ty khởi nghiệp này đã phát triển một ứng dụng dựa trên đám mây tích hợp tất cả dữ liệu có sẵn cho nông dân, bao gồm dữ liệu cảm biến nước và đất, ảnh chụp trên không, v.v. Sau đó, nó kết nối với các thiết bị hiện trường phân tích dữ liệu và đề xuất kết quả mong muốn. Thường được sử dụng trong nhà kính và ngoài trời, Prospera hoạt động với nhiều loại cảm biến và công nghệ khác nhau, bao gồm cả thị giác máy tính. Đầu vào từ các cảm biến này được sử dụng để thiết lập mối quan hệ giữa các thẻ dữ liệu khác nhau và dự đoán của chúng.
- **Blue River Technology:** Robot, AI và thị giác máy tính đang được kết hợp để giảm chi phí và sử dụng thuốc trừ sâu. Thị giác máy tính xác định từng cây riêng lẻ, và học máy xác định cách phân tích đặc điểm của từng cây. Bằng cách này, robot có thể sử dụng máy móc nông nghiệp một cách thông minh và đưa ra các quyết định cần thiết.
- **FarmBot:** Kể từ khi thành lập vào năm 2011, tổ chức này đã thúc đẩy các kỹ thuật canh tác chính xác cho các hộ nông dân nhỏ và thu hút cộng đồng tham gia vào nghiên cứu độ chính xác. Nó cho phép nông dân thực hiện nhiều nhiệm vụ khác nhau, bao gồm phát hiện cỏ dại, kiểm tra đất và tưới cây, bằng cách sử dụng robot chạy trên nền tảng phần mềm mã nguồn mở [11].
- **Harvest CROO Robotics:** Hệ thống hái dâu tây bằng robot này sử dụng AI và thị giác máy tính để tìm và xác định những quả dâu chín để có thể thu hoạch. Những người trồng dâu tây phải đối mặt với tình trạng thiếu lao động nghiêm trọng, làm tăng chi phí sản xuất và tăng khả năng thu hoạch thấp. Kết quả của việc sử dụng bổ sung AI và phát triển hệ thống thu hoạch bằng robot, nhu cầu lao động thủ công cho nhà sản xuất sẽ giảm, chi phí khai thác sẽ giảm và khả năng cạnh tranh tổng thể sẽ tăng lên.
- **Gramophone (Agstack Technologies):** Sử dụng kỹ năng nhận dạng hình ảnh, thông tin, phương pháp và thành phần phù hợp có sẵn vào đúng thời điểm để nông dân có được vụ thu hoạch tốt nhất có thể. Công ty dự đoán sâu bệnh, dự đoán thời điểm giá lương thực sẽ tăng sản lượng và đề xuất sản phẩm cho nông dân bằng cách sử dụng AI và học máy.
- **Iivabhumi:** Tạo ra một thị trường nông nghiệp "thông minh" để cân bằng cung và cầu sản phẩm nông nghiệp thường không ổn định [12]. Một hệ thống tổng hợp thực phẩm mang tính cách mạng kết hợp các sản phẩm nông nghiệp, dịch vụ tiếp thị điện tử và đổi mới. Các công nghệ như blockchain được sử dụng để thu thập thông tin về sản phẩm tại các điểm khác nhau trong chuỗi cung ứng.

3.4 THÁCH THỨC TRONG VIỆC ÁP DỤNG AI

Mặc dù có nhiều hứa hẹn to lớn của AI trong nông nghiệp, nhưng vẫn còn nhiều trang trại không có quyền truy cập vào các kỹ thuật học máy tiên tiến. Tính dễ bị tổn thương của nông nghiệp trước các tác động bên ngoài như thời tiết, chất lượng đất và sâu bệnh cũng rất quan trọng. Do những thay đổi trong hoàn cảnh bên ngoài, một quyết định có vẻ sáng suốt trong giai đoạn lập kế hoạch không nhất thiết trở thành quyết định tốt nhất. Các hệ thống AI yêu cầu một lượng lớn dữ liệu để đào tạo các thuật toán đưa ra dự đoán chính xác. Việc tìm kiếm dữ liệu theo thời gian cho các khu vực nông nghiệp rộng lớn là khó khăn, trong khi việc thu thập dữ liệu địa lý thì dễ dàng. Khi cơ sở hạ tầng dữ liệu phát triển, việc xây dựng một mô hình học máy mạnh mẽ cần có thời gian. Đây là một lý do tại sao AI không được sử dụng trong các giải pháp đồng ruộng mà trong các sản phẩm nông nghiệp, chẳng hạn như hạt giống, phân bón và thuốc trừ sâu. Khi nói đến những nông dân tự kiểm soát quyết định của mình và có thể tự đưa ra quyết định và dự đoán tùy thuộc vào hoàn cảnh, nông nghiệp vẫn đang ở giai đoạn cực kỳ sớm.

3.5 KẾT LUẬN

Tóm tắt nghiên cứu/khảo sát nêu trên, chúng tôi kết luận rằng trong tất cả các ngành công nghiệp, bao gồm giáo dục, ngân hàng, robot, nông nghiệp, v.v., sự phát triển của AI được coi là một trong những công nghệ quan trọng nhất. Điều này đang thay đổi lĩnh vực nông nghiệp và có tác động lớn đến nó. AI bảo vệ ngành nông nghiệp khỏi một số thách thức, chẳng hạn như an ninh lương thực, tăng dân số, biến đổi khí hậu và các vấn đề về lao động [13]. Nông nghiệp hiện đại và AI đều đã vươn lên đến những tầm cao chưa từng có. AI đã cải thiện sản xuất cây trồng, giám sát thời gian thực, thu hoạch, chế biến và tiếp thị. Nhiều hệ thống máy tính công nghệ cao được phát triển để phát hiện một số tiêu chí quan trọng, bao gồm phát hiện cỏ dại, phát hiện cây trồng, chất lượng cây trồng và nhiều tiêu chí khác [14]. Để các ứng dụng tiến bộ, chúng phải linh hoạt để khám phá nhiều ứng dụng của AI trong nông nghiệp. Nó phải có khả năng thích ứng với các môi trường thay đổi, hỗ trợ ra quyết định theo thời gian thực và thu thập thông tin liên quan bằng cách sử dụng các nền tảng/cấu trúc phù hợp. Một nhược điểm lớn khác là chi phí của nhiều lựa chọn trong lĩnh vực nông nghiệp là rất cao. Để công nghệ có sẵn ở cấp độ trang trại, các giải pháp phải có chi phí hiệu quả hơn. Một nền tảng mã nguồn mở tạo ra một giải pháp có tổ chức hơn cho phép nông dân triển khai nhanh hơn và tốt hơn. Sự phát triển của các kỹ thuật AI dựa trên thị giác máy tính đòi hỏi một cách tiếp cận học (chuẩn bị) yêu cầu thu thập và kiểm tra một đống hình ảnh minh họa trong các tình huống bình thường và năng động, mô phỏng chính xác các điều kiện tại chỗ. Công nghệ AI thường tiến bộ bằng cách tạo ra dữ liệu chất lượng cao hơn, cho phép bộ xử lý giải quyết nhiều vấn đề về hình ảnh, chẳng hạn như ánh sáng không đầy đủ, cắt xén không phù hợp và các đối tượng bị lệch [15]. Thiết bị di động có thể được kết hợp với các thuật toán và công nghệ AI này để cung cấp một nền tảng hiệu quả cho việc phát hiện sâu bệnh và lập bản đồ thuốc trừ sâu. Việc sử dụng và chi phí thuốc trừ sâu có thể được giảm đáng kể, do đó giảm tác động

môi trường của chúng, bằng cách sử dụng hóa chất nông nghiệp với lượng vừa đủ và chỉ sử dụng thuốc trừ sâu khi cần thiết.

LỜI CẢM ƠN Công trình này đã được viết bằng cách xem xét các nghiên cứu trước đây (đã xuất bản/chưa xuất bản) của tác giả liên hệ (Nelofar Ara) và các đồng tác giả hỗ trợ (Sani Mustapha Kura, Tiến sĩ Aswathy VK, và Tiến sĩ Mohmmad Amin Wani).

TÀI LIỆU THAM KHẢO

1. Parr, C. S., Lemay, D. G., Owen, C. L., Woodward Greene, M. J., & Sun, J. (n.d.). Multi-modal AI to improve agriculture. IT Professional, 23, 53–57.

2. Kant, A., Ajay, S., Vivek, G., Jayesh, R., & Jeremy, J. (March 2021). Artificial intelligence for agriculture innovation. Retrieved from https://www3.weforum.org/docs/WEF_Artificial_Intelligence_for_Agriculture_Innovation_2021

3. Pandey, N., & Kamboj, N. (2022). Consequences of soil quality on crop yield: An update. Indian Journal of Ecology, 49(4), 1406-1416.

4. Islam, M. R., Singh, B., & Dijkstra, F. A. (2022). Stabilisation of soil organic matter: Interactions between clay and microbes. Biogeochemistry, 160(2), 145-158.

5. Alex, N., Sobin, C. C., & Ali, J. (2023). A comprehensive study on smart agriculture applications in India. Wireless Personal Communications, 129(4), 2345-2385.

6. Javaid, M., Haleem, A., Khan, I. H., & Suman, R. (2023). Understanding the potential applications of artificial intelligence in agriculture sector. Advanced Agrochem, 2(1), 15-30.

7. Talaviya, T., Shah, D., Patel, N., Yagnik, H., & Shah, M. (2020). Implementation of artificial intelligence in agriculture for optimization of irrigation and application of pesticides and herbicides. Artificial Intelligence in Agriculture, 4, 58-73.

8. Cruz, J., Florez, J., Torres, R., Urquiza, M., Gutierrez, J. A., Guzmán, F., & Ortiz, C. C. (2017). Antimicrobial activity of a new synthetic peptide loaded in polylactic acid or poly (lactic-co-glycolic) acid nanoparticles against Pseudomonas aeruginosa, Escherichia coli O157: H7 and methicillin resistant Staphylococcus aureus (MRSA). Nanotechnology, 28(13), 135102.

9. Deng, L., Du, H., & Han, Z. (2017). A carrot sorting system using machine vision technique. Applied Engineering in Agriculture, 33(2), 149-156.

10. Ramos-Giraldo, P., Reberg-Horton, C., Locke, A. M., Mirsky, S., & Lobaton, E. (May/Jun. 2020). Drought stress detection using low-cost computer vision system and machine learning techniques. IT Professional, 22(3), 27-29.

11. Subeesh, A., & Mehta, C. R. (2021). Automation and digitization of agriculture using artificial intelligence and Internet of Things. Artificial Intelligence in Agriculture, 5, 278-291.

12. Maheswari, R., Ashok, K. R., & Prahadeeswaran, M. (2008). Precision farming technology, adoption decisions and productivity of vegetables in resource-poor environments. Agricultural Economics Research Review, 21, 415-424.

13. Revathi, A., & Poonguzhali, S. (2023). The role of AIoT-based automation systems using UAVs in smart agriculture. In Divya Mishra, & Shanu Sharma (Eds.), Revolutionizing industrial automation through the convergence of artificial intelligence and the Internet of Things (pp. 100-117). IGI Global.

14. Hatfield, J. L., Cryder, M., & Basso, B. (May/Jun. 2020). Remote sensing: Advancing the science and the applications to transform agriculture. IT Professional, 22(3), 42-45.

15. Peters, D. P. C., Savoy, H. M., Ramirez, G. A., & Huang, H. H. (May/Jun. 2020). AI with ML recommender systems for agricultural research. IT Professional, 22(3), 30-32.

CHƯƠNG 4: CÁC NGHIÊN CỨU ĐIỂN HÌNH VỀ SÁNG KIẾN VÀ CÂU CHUYỆN THÀNH CÔNG CỦA HỆ THỐNG AI BIÊN CHO NÔNG NGHIỆP

Thamizhiniyan Natarajan và Shammugavadivu Pichai Viện Nông thôn Gandhigram, Chinnalapatti, Ấn Độ

4.1 GIỚI THIỆU

Một kỷ nguyên chuyển đổi chưa từng có đang được mở ra trong lĩnh vực nông nghiệp, được thúc đẩy bởi sự kết hợp giữa công nghệ tiên tiến với các phương pháp canh tác lâu đời, dẫn đầu bởi sự xuất hiện của AI Biên (Trí tuệ Nhân tạo tại Biên). Trong bối cảnh năng động này, AI Biên được định vị như một chất xúc tác cho cuộc cách mạng hóa nông nghiệp, mang lại nhiều giải pháp để giải quyết những thách thức lâu nay và mở ra một kỷ nguyên mới về canh tác thông minh.

Trong hàng thiên niên kỷ, nông nghiệp đã phục vụ như nền tảng cho sự tồn tại của con người, cung cấp lương thực, sinh kế và thịnh vượng kinh tế cho các quốc gia trên toàn cầu. Tuy nhiên, những đòi hỏi đối với lĩnh vực quan trọng này chưa bao giờ lớn hơn thế. Với dân số thế giới gia tăng và biến đổi khí hậu làm gián đoạn các kiểu thời tiết truyền thống, nông nghiệp phải đối mặt với áp lực ngày càng lớn để đáp ứng nhu cầu sản xuất lương thực ngày càng tăng, đồng thời phải đối phó với tài nguyên hạn chế và suy thoái môi trường.

Vai trò của AI Biên trong nông nghiệp trở nên rõ ràng khi sự hội tụ của trí tuệ nhân tạo và Internet vạn vật (IoT) trao quyền cho các trang trại với thông tin chi tiết theo thời gian thực, tạo điều kiện cho các phản ứng tức thời với các điều kiện thay đổi và cho phép nông nghiệp chính xác dựa trên dữ liệu.

Vai trò then chốt của AI Biên trong nông nghiệp được làm nổi bật thông qua việc khám phá toàn diện một bộ sưu tập các nghiên cứu điển hình được chọn lọc từ các bài báo nghiên cứu đa dạng. Các nghiên cứu điển hình này bao hàm tiềm năng chuyển đổi của AI Biên, cho thấy khả năng định hình lại bối cảnh canh tác theo nhiều cách khác nhau.

Từ việc sử dụng camera được hỗ trợ bởi AI để phát hiện bệnh thực vật trên đồng ruộng đến giám sát sức khỏe vật nuôi từ xa thông qua các thiết bị biên, từ các hệ thống tưới tiêu chính xác điều chỉnh phân phối nước dựa trên dữ liệu thời gian thực đến các giải pháp canh tác tự động giảm thiểu lao động thủ công trong khi tối đa hóa năng suất, một loạt các ứng dụng nông nghiệp được đề cập. Các tính năng chức năng và lợi ích của hệ thống AI Biên được làm sáng tỏ, và tác động kinh tế xã hội, việc áp dụng cũng như hàm ý đối với cộng đồng nông nghiệp và môi trường được đi sâu tìm hiểu.

Khi bắt đầu hành trình xuyên qua lĩnh vực AI Biên trong nông nghiệp, rõ ràng là chúng ta đang chứng kiến nhiều hơn một sự tiến hóa về công nghệ. Một sự thay đổi cơ bản đang diễn ra, một sự thay đổi hứa hẹn sẽ định nghĩa lại chính bản chất của canh tác. Trao quyền cho nông dân với các công cụ ra quyết định sáng suốt, tối ưu hóa phân bổ tài

nguyên, giảm thiểu dấu chân môi trường và nắm giữ chìa khóa cho an ninh lương thực toàn cầu trong một thế giới đầy bất ổn là những lời hứa của AI Biên.

Trong mỗi nghiên cứu điển hình, những câu chuyện về đổi mới, khả năng phục hồi và chuyển đổi được tiết lộ. Những câu chuyện này nhấn mạnh ảnh hưởng sâu sắc của AI Biên đối với nông nghiệp, củng cố vị thế của nó như một lực lượng then chốt trong việc định hình tương lai của sản xuất lương thực, thúc đẩy tính bền vững, nuôi dưỡng đổi mới và đảm bảo an ninh lương thực trong một thế giới ngày càng phức tạp và kết nối. Khi đi sâu vào chi tiết của từng nghiên cứu điển hình, chúng tôi mời bạn chứng kiến tận mắt cách AI Biên biến hoạt động canh tác lâu đời trở thành một khoa học tiên tiến.

Cấu trúc của chương được trình bày như sau: Mục 4.2 khám phá các công trình liên quan về AI Biên trong nông nghiệp, cung cấp cái nhìn sâu sắc về nghiên cứu hiện có trong lĩnh vực này. Trong Mục 4.3, một cuộc kiểm tra chuyên sâu về các nghiên cứu điển hình được trình bày, mang lại sự hiểu biết sâu hơn về các ứng dụng thực tế. Mục 4.4 giải quyết toàn diện việc sử dụng, lợi ích, tác động kinh tế xã hội và việc áp dụng AI Biên trong nông nghiệp. Cuối cùng, Mục 4.5 đóng vai trò là phần kết luận, tóm tắt những phát hiện và hiểu biết chính của chương.

4.2 CÁC CÔNG TRÌNH LIÊN QUAN

Trong một thế giới được thúc đẩy bởi dữ liệu và đổi mới không ngừng, sự kết hợp giữa trí tuệ nhân tạo (AI) với tiềm năng chưa được khai thác của điện toán biên và IoT được công nhận là một lực lượng cách mạng sẵn sàng biến đổi các ngành công nghiệp, xã hội và cuộc sống hàng ngày của chúng ta. AI, được biết đến với khả năng khám phá các mẫu hình, dự đoán kết quả và tự động hóa các tác vụ, đã trở thành một phần không thể thiếu trong đời sống hiện đại. Từ các thuật toán đề xuất hướng dẫn lựa chọn giải trí của chúng ta đến các phương tiện tự lái điều hướng trên những con đường đông đúc, AI âm thầm sắp đặt những kỳ quan của thời đại chúng ta.

Tuy nhiên, khi ảnh hưởng của AI lan rộng, một thách thức vốn có đã hiện ra. Các hệ thống AI truyền thống, chủ yếu được đặt trong các trung tâm dữ liệu từ xa và cơ sở hạ tầng đám mây, gây ấn tượng với khả năng của chúng nhưng bị cản trở bởi các vấn đề về độ trễ. Sự chậm trễ giữa việc tạo dữ liệu và phân tích sau đó, mặc dù không đáng kể đối với các trường hợp sử dụng cụ thể, đã nổi lên như một yếu tố quan trọng trong các tình huống đòi hỏi ra quyết định ngay lập tức. Đây là nơi khái niệm “biên” trở nên phù hợp [1, 2].

4.2.1 Lợi Thế Của AI Biên

AI Biên đánh dấu một sự khác biệt căn bản so với mô hình AI tập trung. Nó định vị việc tính toán, lưu trữ dữ liệu và xử lý ở rìa rất xa của mạng - ngay tại nơi hành động diễn ra. Bằng cách đó, nó loại bỏ độ trễ thời gian giữa việc tạo dữ liệu và phân tích, mở ra một kỷ nguyên mới về tính tức thời và khả năng phản hồi [1]. Những lợi thế của AI Biên như sau:

- **Ra Quyết Định Thời Gian Thực:** Một trong những lợi thế quan trọng nhất của AI Biên là khả năng ra quyết định thời gian thực. Các thiết bị được trang bị AI Biên có thể xử lý dữ liệu ngay lập tức, cho phép phản hồi trong tích tắc. Khả năng này là yếu tố thay đổi cuộc chơi cho các ứng dụng như xe tự hành, tự động hóa công nghiệp và giám sát chăm sóc sức khỏe, nơi ngay cả sự chậm trễ ngắn nhất cũng có thể gây ra hậu quả nghiêm trọng [3].
- **Tăng Cường Quyền Riêng Tư và Bảo Mật:** AI Biên cũng củng cố quyền riêng tư và bảo mật dữ liệu. Vì dữ liệu được xử lý cục bộ trên thiết bị, thông tin nhạy cảm không cần phải truyền qua mạng, giảm nguy cơ bị lộ. Điều này đặc biệt quan trọng trong các ứng dụng như chăm sóc sức khỏe, nơi dữ liệu bệnh nhân phải được xử lý với sự bảo mật tối đa [4].
- **Hiệu Quả Băng Thông:** AI Biên tối ưu hóa việc sử dụng băng thông bằng cách xử lý dữ liệu cục bộ. Điều này làm giảm áp lực lên cơ sở hạ tầng mạng, làm cho nó phù hợp cho các triển khai IoT trong môi trường từ xa hoặc bị hạn chế băng thông [5].
- **Khả Năng Mở Rộng:** AI Biên thể hiện khả năng mở rộng đáng kể, làm cho nó phù hợp với một loạt rộng các thiết bị và kịch bản sử dụng. Nó có thể được tùy chỉnh để phù hợp với các yêu cầu riêng biệt của các ứng dụng khác nhau, trải dài từ các cảm biến nhỏ đến máy móc công nghiệp mạnh mẽ [6].

4.2.2 Sự Phát Triển Của AI Biên

Khái niệm AI Biên không xuất hiện một sớm một chiều mà đã phát triển trong nhiều năm như một phản ứng với nhu cầu ngày càng tăng về điện toán phân phối, thời gian thực.

Theo lịch sử, AI dựa vào các tài nguyên tính toán tập trung, với dữ liệu được gửi đến các máy chủ từ xa để xử lý. Tuy nhiên, khi các ứng dụng AI mở rộng sang các lĩnh vực như xe tự hành, tự động hóa công nghiệp và IoT, những hạn chế của cách tiếp cận này trở nên rõ ràng. Độ trễ do việc chuyển dữ liệu khứ hồi đến các trung tâm dữ liệu từ xa gây ra là không thể chấp nhận được trong các kịch bản mà các quyết định ngay lập tức là rất quan trọng.

Khái niệm "điện toán biên" xuất hiện để định nghĩa một cách tiếp cận mới mẻ nơi các tài nguyên tính toán được đặt gần hơn với nguồn dữ liệu trong mạng. Sự chuyển đổi này đặt nền móng cho sự ra đời của AI Biên [1]. Tận dụng các tiến bộ về khả năng phần cứng, các thiết bị AI Biên đã có khả năng thực thi các phép tính AI phức tạp tại chỗ.

Trong nông nghiệp, ví dụ, AI Biên cho phép máy kéo và máy bay không người lái phân tích dữ liệu đồng ruộng theo thời gian thực, tối ưu hóa các quyết định trồng trọt và thu hoạch. Trong chăm sóc sức khỏe, các thiết bị đeo được trang bị AI Biên trở nên có khả năng theo dõi các dấu hiệu quan trọng và cảnh báo người dùng về các vấn đề sức khỏe tiềm ẩn mà không yêu cầu kết nối đám mây liên tục.

4.2.3 AI Biên và IoT Trong Nông Nghiệp

Tác động của AI Biên mở rộng sang lĩnh vực nông nghiệp, mở ra một kỷ nguyên mới về canh tác chính xác và các phương pháp bền vững.

- ***Nông Nghiệp Chính Xác*:** AI Biên trao quyền cho máy móc nông nghiệp với khả năng đưa ra quyết định ngay lập tức về việc trồng trọt, thu hoạch và tưới tiêu. Thông qua các cảm biến và camera được lắp đặt trên máy kéo và máy bay không người lái, dữ liệu liên quan đến điều kiện đất đai, sức khỏe cây trồng và các kiểu thời tiết được thu thập. Thông tin này được xử lý ngay lập tức bởi AI Biên, cho phép nông dân nâng cao hoạt động của họ, giảm thiểu việc sử dụng tài nguyên và tăng năng suất cây trồng [7].
- **Giám Sát Cây Trồng:** Camera được hỗ trợ bởi AI Biên được đặt xuyên suốt các cánh đồng có thể giám sát sức khỏe cây trồng, xác định các dấu hiệu của bệnh, sự xâm nhiễm của sâu bệnh hoặc thiếu hụt chất dinh dưỡng. Dữ liệu này có thể được sử dụng để kích hoạt các phản ứng tự động, chẳng hạn như áp dụng thuốc trừ sâu mục tiêu, do đó giảm nhu cầu xử lý phổ rộng và giảm thiểu tác động môi trường [8].
- **Quản Lý Vật Nuôi:** Trong chăn nuôi, AI Biên có thể theo dõi sức khỏe và hành vi của động vật theo thời gian thực. Các cảm biến đeo được và camera có thể phát hiện các dấu hiệu đau khổ hoặc bệnh tật, cho phép can thiệp sớm. Ngoài ra, các máy cho ăn được hỗ trợ bởi AI có thể phân phối chính xác lượng thức ăn, giảm lãng phí và tối ưu hóa dinh dưỡng [9].

4.2.4 Thách Thức và Cân Nhắc

Mặc dù AI Biên mang lại tiềm năng to lớn trong nông nghiệp, nó đi kèm với một loạt thách thức riêng:

- ***Kết Nối*:** Ở các khu vực nông nghiệp xa xôi, kết nối có thể bị hạn chế. Cơ sở hạ tầng mạng đáng tin cậy là điều cần thiết để đảm bảo truyền dữ liệu liền mạch giữa các thiết bị biên và hệ thống trung tâm [1].
- ***Quyền Riêng Tư Dữ Liệu*:** AI Biên thu thập một lượng lớn dữ liệu, bao gồm thông tin về điều kiện cây trồng và hoạt động trang trại. Đảm bảo quyền riêng tư và bảo mật của dữ liệu này là tối quan trọng [10].
- ***Khả Năng Mở Rộng*:** Lĩnh vực nông nghiệp bao gồm một loạt các hoạt động, từ các trang trại gia đình nhỏ đến các doanh nghiệp thương mại lớn. Các giải pháp AI Biên phải có khả năng mở rộng và thích ứng để đáp ứng nhu cầu của các môi trường nông nghiệp đa dạng [10].

Trong thế giới của AI Biên, có vô số cơ hội cho đổi mới. Đó là một không gian nơi trí thông minh hoạt động ngay tại rìa của những gì có thể, nơi dữ liệu nhanh chóng biến thành thông tin hữu ích, và nơi lịch sử và tương lai của AI Biên được đan xen chặt chẽ với nhau.

4.3 NHỮNG CÂU CHUYỆN CHUYỂN ĐỔI: CÁC NGHIÊN CỨU ĐIỂN HÌNH GIỚI THIỆU AI BIÊN TRONG NÔNG NGHIỆP

Trong phần này, trọng tâm chuyển hướng sang các ứng dụng thực tế của AI Biên trong lĩnh vực nông nghiệp. Một loạt các nghiên cứu điển hình được đi sâu vào, chứng minh cách các hệ thống AI Biên đã được đưa vào hoạt động hiệu quả để giải quyết các thách thức cấp bách và thúc đẩy đổi mới trong các phương pháp canh tác. Các nghiên cứu điển hình này bao gồm cả bối cảnh trong nước và quốc tế, nhấn mạnh tính linh hoạt và tiềm năng chuyển đổi của AI Biên trong nông nghiệp. Trong mỗi trường hợp, sự chú ý được thu hút đến các cách tiếp cận độc đáo được thực hiện để tận dụng các công nghệ AI Biên nhằm tối ưu hóa hoạt động, nâng cao năng suất cây trồng, cải thiện quản lý tài nguyên, và cuối cùng, đóng góp vào một cảnh quan nông nghiệp bền vững và hiệu quả hơn. Những nghiên cứu điển hình này đứng như những ví dụ cụ thể về khả năng của AI Biên trong việc cách mạng hóa nông nghiệp, qua đó mở đường cho một tương lai nông nghiệp thông minh hơn, thân thiện với môi trường hơn và hiệu quả cao.

4.3.1 Nâng Cao Phân Loại Bệnh Thực Vật Với AI Biên Trên Thiết Bị IoT

Trong nỗ lực theo đuổi các phương pháp canh tác hiệu quả và bền vững hơn, Trong-Minh Hoàng và nhóm của họ [11] đã giới thiệu một cách tiếp cận đột phá để phân loại bệnh thực vật bằng cách sử dụng mạng nơ-ron tích chập sâu (DCNN) trên các thiết bị biên IoT. Các phương pháp truyền thống để phát hiện bệnh trong nông nghiệp thường bị hạn chế về phạm vi và hiệu quả. Để giải quyết những hạn chế này, các nhà nghiên cứu đã phát triển một mô hình DCNN nhẹ và hiệu quả cao, phù hợp để triển khai trên các thiết bị IoT có tài nguyên hạn chế. Nghiên cứu điển hình này nhấn mạnh vai trò then chốt của điện toán biên và các giải pháp AI trong lĩnh vực nông nghiệp chính xác, làm sáng tỏ cách các thuật toán học máy có thể nâng cao đáng kể việc phát hiện bệnh kịp thời và chính xác trong canh tác thông minh.

4.3.1.1 Các Thách Thức Được Giải Quyết

- **Hạn Chế Tài Nguyên:** Các thiết bị biên, thường được sử dụng ở các khu vực canh tác xa xôi, thường có tài nguyên tính toán hạn chế. Hạn chế này cản trở việc sử dụng các mô hình học máy phức tạp, vốn cần thiết cho việc xác định bệnh chính xác.
- **Kích Thước Mô Hình:** Thu nhỏ các mô hình học máy để vừa với các thiết bị biên mà không hy sinh độ chính xác là một vấn đề phức tạp. Thu nhỏ mô hình quá mạnh tay có thể dẫn đến mất thông tin quan trọng và giảm độ chính xác nhận dạng.
- **Khả Năng Ứng Dụng Thực Tế:** Các mô hình phải hoạt động tốt không chỉ trong điều kiện phòng thí nghiệm mà còn trong các môi trường nông nghiệp thực tế, nơi các yếu tố môi trường có thể tạo ra sự biến đổi đáng kể.

4.3.1.2 Lợi Ích Chính

- **Thông Tin Chi Tiết Thời Gian Thực:** AI Biên cho phép nông dân nhận được cập nhật thời gian thực về sức khỏe cây trồng của họ, cho phép can thiệp ngay lập tức khi bùng phát dịch bệnh.
- **Quản Lý Bệnh Chủ Động:** Với việc phát hiện kịp thời, nông dân có thể thực hiện các biện pháp chủ động để ngăn chặn sự lây lan của bệnh, giảm thiểu thiệt hại mùa màng.
- **Cải Thiện Năng Suất:** Bằng cách giải quyết bệnh kịp thời, nông dân có thể tối ưu hóa hoạt động nông nghiệp của họ và nâng cao năng suất cây trồng tổng thể.
- **Hiệu Quả Tài Nguyên:** Hiệu quả của mô hình DCNN đảm bảo rằng nó có thể hoạt động hiệu quả trên các thiết bị IoT có tài nguyên hạn chế, biến nó thành một giải pháp thực tế cho các ứng dụng trong thế giới thực trong nông nghiệp chính xác.

4.3.1.3 Kết Quả và Hàm Ý

Mô hình DCNN được phát triển bởi Trong-Minh Hoàng và nhóm của họ đã chứng minh độ chính xác đáng kể trong phân loại bệnh thực vật, vượt trội hơn các mô hình học máy khác trong khi vẫn duy trì hiệu suất cao. Nghiên cứu điển hình này phục vụ như một minh chứng cho tiềm năng của các thuật toán học máy trong việc đạt được phát hiện bệnh kịp thời và chính xác trên các thiết bị biên IoT. Hơn nữa, nó làm nổi bật tác động chuyển đổi của AI Biên trong việc cách mạng hóa ngành nông nghiệp và củng cố an ninh lương thực toàn cầu.

4.3.2 Bảo Mật Nông Nghiệp Khí Hậu Thông Minh Với Tích Hợp AI Biên và Blockchain

Trong thời đại hiện đại, công nghệ đóng một vai trò then chốt trong việc thúc đẩy các lĩnh vực khác nhau, bao gồm nông nghiệp. Để giải quyết những thách thức đặc thù mà nông nghiệp phải đối mặt, đặc biệt là ở các nước như Ấn Độ, nhu cầu hiện đại hóa công nghệ ngày càng tăng. Nghiên cứu điển hình này, lấy cảm hứng từ công trình của Li Ting và cộng sự [12], khám phá sự phát triển của một hệ thống nông nghiệp thông minh tận dụng công nghệ tiên tiến để giám sát và tối ưu hóa các thông số khí hậu và môi trường thiết yếu. Bằng cách tích hợp IoT và công nghệ blockchain, hệ thống này cung cấp khả năng ra quyết định hiệu quả và an toàn, cuối cùng nâng cao sức khỏe cây trồng và năng suất nông nghiệp.

4.3.2.1 Các Thách Thức Được Giải Quyết

- **Quyền Riêng Tư và Bảo Mật Dữ Liệu:** Với số lượng ngày càng tăng của các thiết bị IoT kết nối với hệ thống nông nghiệp, nghiên cứu điển hình này ưu tiên quyền riêng tư và bảo mật dữ liệu. Nó đạt được điều này bằng cách triển khai công nghệ blockchain để đảm bảo việc truyền tải và lưu trữ dữ liệu nhạy cảm một cách an toàn.
- **Giám Sát Thời Gian Thực:** Nông nghiệp thành công đòi hỏi sự giám sát liên tục các thông số quan trọng, bao gồm nhiệt độ, độ ẩm, độ ẩm đất và cường độ ánh

sáng. Hệ thống được đề xuất tích hợp các cảm biến IoT để thu thập và truyền dữ liệu này theo thời gian thực, cho phép phân tích và ra quyết định kịp thời.

- **Quản Lý Nước:** Bảo tồn nước là điều cần thiết trong nông nghiệp. Hệ thống sử dụng logic mờ thông minh để đưa ra các quyết định sáng suốt về thời điểm và lượng nước tưới, đảm bảo sử dụng nước hiệu quả và sức khỏe cây trồng tối ưu.

4.3.2.2 Lợi Ích Chính

- **Ra Quyết Định Thời Gian Thực:** Hệ thống tích hợp trao quyền cho nông dân với thông tin chi tiết theo thời gian thực về các thông số môi trường quan trọng. Bằng cách phân tích dữ liệu này và áp dụng logic mờ thông minh, hệ thống có thể đưa ra quyết định sáng suốt để đáp ứng kịp thời các yêu cầu tưới nước của cây trồng.
- **Tăng Cường Bảo Mật:** Công nghệ blockchain được sử dụng để nâng cao bảo mật cho hệ thống được kích hoạt bởi IoT. Điều này đảm bảo rằng chỉ các thiết bị đáng tin cậy mới có quyền truy cập vào mạng, giảm thiểu các mối đe dọa bảo mật tiềm ẩn.
- **Giám Sát Từ Xa:** Nhiều người dùng có thể giám sát và tương tác với hệ thống từ xa đồng thời bằng cách sử dụng một ứng dụng Android. Khả năng truy cập từ xa này cho phép quản lý hiệu quả các hoạt động nông nghiệp.
- **Hiệu Quả Sử Dụng Nước:** Hệ thống không chỉ thông báo cho người dùng về yêu cầu tưới nước mà còn cung cấp cảnh báo để bật và tắt động cơ nước. Tính năng này góp phần quản lý hiệu quả tài nguyên nước.

4.3.2.3 Kết Quả và Hàm Ý

Kết quả thử nghiệm của hệ thống được đề xuất, như được chứng minh bởi nghiên cứu của Li Ting và cộng sự, cho thấy khả năng mở rộng, hiệu quả và bảo mật của nó. Nó giám sát và tối ưu hóa hiệu quả các thông số khí hậu và môi trường, góp phần vào sức khỏe cây trồng và tăng năng suất nông nghiệp. Mặc dù hệ thống hiện tại tập trung vào tám loại cây trồng, các hướng phát triển trong tương lai có thể liên quan đến việc triển khai các kỹ thuật tiên tiến như thuật toán di truyền hoặc mạng nơ-ron để cung cấp các khuyến nghị chính xác và chính xác hơn. Nghiên cứu điển hình này làm nổi bật tiềm năng chuyển đổi của việc tích hợp AI Biên và blockchain trong nông nghiệp, cho thấy cách các công nghệ hiện đại có thể nâng cao hiệu quả, năng suất và tính bền vững trong lĩnh vực quan trọng này.

4.3.3 Nâng Cao Hiệu Quả Thu Thập Dữ Liệu Trong Nông Nghiệp Thông Minh Thông Qua Điện Toán Biên

Việc sử dụng mạng cảm biến không dây (WSN) trong nông nghiệp đã mang lại những tiến bộ đáng kể trong các kỹ thuật canh tác dựa trên dữ liệu. Tuy nhiên, các WSN nông nghiệp truyền thống thường phải vật lộn với các vấn đề như dữ liệu trùng lặp và thời gian phản hồi kéo dài khi đối mặt với các sự kiện quan trọng (CE). Những trở ngại này dẫn đến việc sử dụng thời gian và năng lượng tăng lên, cản trở những lợi ích tiềm năng của nông nghiệp chính xác. Để giải quyết những vấn đề này, một kỹ thuật thu thập dữ liệu sáng tạo, được thúc đẩy bởi điện toán biên (EC), đã được giới thiệu bởi Xiaomin Li và

cộng sự [13] để giải quyết các CE trong lĩnh vực nông nghiệp thông minh. Nghiên cứu điển hình này đi sâu vào phương pháp luận và kết quả của cách tiếp cận sáng tạo này.

4.3.3.1 Các Thách Thức Được Giải Quyết

- **Dư Thừa Dữ Liệu:** Các WSN truyền thống tạo ra khối lượng lớn dữ liệu dư thừa, dẫn đến sự kém hiệu quả trong việc thu thập, lưu trữ và phân tích dữ liệu.
- **Độ Trễ Cao:** Các CE trong nông nghiệp đòi hỏi thu thập dữ liệu và ra quyết định thời gian thực. Độ trễ cao trong truyền dữ liệu có thể cản trở các phản ứng kịp thời, ảnh hưởng đến sức khỏe và năng suất cây trồng.

4.3.3.2 Lợi Ích Chính

Cách tiếp cận được đề xuất mang lại một số lợi ích chính:

- **Giảm Dữ Liệu:** Bằng cách trích xuất và ưu tiên các loại dữ liệu đặc trưng chính (KFDT) từ các tập dữ liệu lịch sử, cách tiếp cận này giảm thiểu dữ liệu dư thừa, tối ưu hóa hiệu quả thu thập dữ liệu.
- **Độ Trễ Thấp:** Thông qua EC, các loại sự kiện được xác định nhanh chóng dựa trên phương sai trung bình tối thiểu, cho phép thu thập dữ liệu nhanh chóng bởi các nút cảm biến trong các ràng buộc về độ trễ.
- **Hiệu Quả Tài Nguyên:** Bằng cách giảm số lượng cảm biến cần thiết, giảm thiểu thời gian cảm biến, tối ưu hóa khối lượng thu thập dữ liệu và hợp lý hóa thời gian truyền thông, cách tiếp cận này nâng cao hiệu quả sử dụng tài nguyên.

4.3.3.3 Kết Quả và Hàm Ý

Một bộ thử nghiệm trong thế giới thực trong một nhà kính thông minh đã được thiết lập để xác thực cách tiếp cận được đề xuất bởi Xiaomin Li và cộng sự. Kết quả nhấn mạnh hiệu quả của nó trong việc giảm dư thừa dữ liệu, đạt được thu thập dữ liệu độ trễ thấp và tối ưu hóa việc sử dụng tài nguyên. So với các phương pháp thông thường, chiến lược được đề xuất đã nâng cao đáng kể sự cân bằng giữa tính hợp lệ của dữ liệu, mức tiêu thụ năng lượng và độ trễ.

4.3.4 Nâng Cao Nông Nghiệp Chính Xác Với AI Biên Công Suất Thấp

Trong lĩnh vực nông nghiệp chính xác, được đặc trưng bởi tầm quan trọng tối cao của việc sử dụng tài nguyên hiệu quả và tối ưu hóa cây trồng, sự kết hợp của AI đã nổi lên như một con đường đầy hứa hẹn để nâng cao các phương pháp canh tác. Nghiên cứu điển hình này khám phá công trình tiên phong được trình bày bởi Dmitrii Shadrin và cộng sự [14] tập trung vào việc phát hiện sự nảy mầm của hạt giống bằng cách sử dụng AI trong một hệ thống nhúng công suất thấp, cung cấp cái nhìn sâu sắc về tiềm năng chuyển đổi của AI Biên trong nông nghiệp.

4.3.4.1 Các Thách Thức Được Giải Quyết

- **Tích Hợp AI Công Suất Thấp:** Việc tích hợp AI vào các hệ thống nhúng bị hạn chế tài nguyên là một thách thức, và nghiên cứu này nhằm chứng minh tính khả thi và lợi ích của việc tích hợp như vậy trong bối cảnh nông nghiệp.
- **Phát Hiện Sự Nảy Mầm Của Hạt Giống Hiệu Quả:** Các phương pháp giám sát sự nảy mầm của hạt giống truyền thống có thể thiếu hiệu quả và độ chính xác. Bài báo giải quyết nhu cầu về một cách tiếp cận hiệu quả hơn bằng cách sử dụng AI và thị giác máy tính.

4.3.4.2 Lợi Ích Chính

- **AI Tiết Kiệm Tài Nguyên:** Nghiên cứu cho thấy sự phát triển của một hệ thống cảm biến công suất thấp được trang bị khả năng AI. Sự đổi mới này cho phép xử lý AI tại biên, giảm sự phụ thuộc vào các giải pháp dựa trên đám mây và giảm thiểu các yêu cầu truyền dữ liệu.
- **Cải Thiện Phát Hiện Nảy Mầm:** Bằng cách triển khai Mạng nơ-ron tích chập (CNN), hệ thống được trình bày trong nghiên cứu này đạt được kết quả ấn tượng, với điểm Giao trên Hợp (IoU) trung bình là 83% trên tập dữ liệu kiểm tra và độ chính xác 97% trong nhận dạng hạt giống trên tập dữ liệu xác thực. Mức độ chính xác cao như vậy góp phần đáng kể vào việc phát hiện sự nảy mầm của hạt giống.

4.3.4.3 Kết Quả và Hàm Ý

Trong thực tế, hệ thống nhúng công suất thấp được trang bị khả năng AI có thể tự động phát hiện động lực nảy mầm của hạt giống mà không cần dựa vào việc truyền dữ liệu rộng rãi đến các máy chủ đám mây. Điều này không chỉ cắt giảm chi phí liên quan đến dữ liệu mà còn đảm bảo giám sát và ra quyết định thời gian thực.

Hơn nữa, khả năng mở rộng của cách tiếp cận này mở ra cánh cửa cho các ứng dụng rộng rãi trong nông nghiệp chính xác. Nó cho phép đánh giá hiệu suất của các hệ thống sinh trưởng, dự đoán về thời kỳ thu hoạch và các cơ hội tối ưu hóa tài nguyên trong giai đoạn đầu tăng trưởng của cây. Sự tối ưu hóa này, được thúc đẩy bởi thông tin chi tiết từ AI, góp phần quản lý tài nguyên hiệu quả hơn trong nông nghiệp chính xác.

So sánh thử nghiệm của nghiên cứu giữa hệ thống nhúng công suất thấp và máy tính để bàn làm nổi bật những lợi thế của AI Biên. Mặc dù máy tính để bàn có thể nhanh hơn đáng kể, nhưng khả năng hoạt động bằng nguồn pin của hệ thống nhúng công suất thấp làm cho nó phù hợp cho các ứng dụng IoT từ xa và tự trị, phù hợp hoàn hảo với các xu hướng mới nổi trong nông nghiệp thông minh.

4.3.5 Cách Mạng Hóa Nông Nghiệp Chính Xác Với Ảo Hóa Cảm Biến AI Biên

Trong lĩnh vực luôn thay đổi của nông nghiệp chính xác, quản lý tài nguyên hiệu quả là điều tối quan trọng. Sự hợp nhất của AI và EC đã mở ra các con đường cho các giải pháp sáng tạo để giải quyết các vấn đề gặp phải trong các hệ thống cảm biến-đám mây nông nghiệp truyền thống. Nghiên cứu điển hình này khám phá công trình tiên phong được trình bày bởi Rituparna Saha và cộng sự [15]. Nghiên cứu giới thiệu một kiến trúc cảm

biến-đám mây đổi mới được nâng cao bởi EC và một sơ đồ cảm biến ảo tinh vi có tên DLSense, nhằm mục đích chuyển đổi nông nghiệp chính xác.

4.3.5.1 Các Thách Thức Được Giải Quyết

- **Độ Trễ và Tiêu Thụ Tài Nguyên:** Các hệ thống cảm biến-đám mây nông nghiệp truyền thống phải chịu độ trễ cao và tiêu thụ năng lượng và băng thông đáng kể do việc truyền dữ liệu cảm biến thô định kỳ lên đám mây.
- **Cảm Biến Không Đáng Tin Cậy:** Sự phụ thuộc vào các nút cảm biến đang hoạt động đặt ra những hạn chế, đặc biệt là ở các khu vực có cảm biến bị hư hỏng hoặc không hoạt động.
- **Lo Ngại Về Quyền Riêng Tư:** Việc chia sẻ dữ liệu canh tác nhạy cảm với các nhà cung cấp dịch vụ bên thứ ba làm dấy lên các vấn đề về quyền riêng tư.

4.3.5.2 Lợi Ích Chính

- **Trao Quyền Cho Thiết Bị Biên:** Nghiên cứu giới thiệu một kiến trúc cảm biến-đám mây được sửa đổi khai thác khả năng của các thiết bị biên như một lớp trung gian để ảo hóa cảm biến. Cách tiếp cận này làm giảm độ trễ trong việc cung cấp dịch vụ và giảm việc sử dụng tài nguyên.
- **Cảm Biến Ảo DLSense:** DLSense, một sơ đồ ảo hóa thông minh, sử dụng lý thuyết tương quan và học tập phân tán trong các thiết bị biên để dự báo dữ liệu cảm biến. Điều này cho phép trao đổi các mô hình đã được đào tạo thay vì dữ liệu thô, đảm bảo quyền riêng tư dữ liệu trong khi nâng cao khả năng tiếp cận dịch vụ.

4.3.5.3 Kết Quả và Hàm Ý

Hiệu suất của sơ đồ DLSense được đánh giá thông qua các mô phỏng kỹ lưỡng và một nghiên cứu điển hình thử nghiệm trong nông nghiệp chính xác. Các phát hiện nhấn mạnh một số lợi thế đáng chú ý:

- **Giảm Độ Trễ và Chi Phí:** DLSense đạt được mức giảm 81% về độ trễ và 66% về chi phí dịch vụ so với các phương pháp tiên tiến nhất. Điều này dẫn đến xử lý và phân tích dữ liệu nhanh hơn và hiệu quả hơn về chi phí.
- **Tăng Tính Khả Dụng Của Dịch Vụ:** DLSense nâng cao tính khả dụng của dịch vụ lên 39%, đảm bảo rằng các hệ thống nông nghiệp chính xác tiếp tục hoạt động hiệu quả, ngay cả ở các khu vực có cảm biến bị lỗi.

Nghiên cứu điển hình này làm sáng tỏ tiềm năng của ảo hóa cảm biến AI Biên trong việc cách mạng hóa nông nghiệp chính xác. Việc tích hợp các thiết bị biên, AI và DLSense không chỉ giải quyết các thách thức về độ trễ, tiêu thụ tài nguyên và độ tin cậy của cảm biến mà còn đảm bảo quyền riêng tư dữ liệu. Các kết quả đầy hứa hẹn về việc giảm tiêu thụ năng lượng, độ trễ và chi phí dịch vụ, cùng với việc tăng tính khả dụng của dịch vụ, cho thấy tác động chuyển đổi của cách tiếp cận này.

4.3.6 Nâng Cao Dự Đoán Năng Suất Cây Trồng Trong Nông Trại Thông Minh Với AI Biên

Dự đoán năng suất cây trồng là một kỹ thuật quan trọng trong nông nghiệp, và sự ra đời của các nông trại thông minh, được trao quyền bởi IoT, đã mang lại một sự giàu có về dữ liệu môi trường thời gian thực như nhiệt độ và độ ẩm. Tuy nhiên, các thách thức nảy sinh khi xử lý dữ liệu nhạy cảm hoặc riêng tư không thể truyền qua internet. Nghiên cứu điển hình này khám phá công việc sáng tạo được trình bày bởi Junyong Park và cộng sự [16]. Nghiên cứu giới thiệu một khuôn khổ phân tích dữ liệu có thể mở rộng tận dụng EC để tiền xử lý và phân tích dữ liệu riêng tư, cuối cùng cải thiện ước tính năng suất cây trồng.

4.3.6.1 Các Thách Thức Được Giải Quyết

- **Xử Lý Dữ Liệu Riêng Tư:** Bảo vệ dữ liệu trang trại nhạy cảm trong khi vẫn cho phép phân tích hiệu quả là một thách thức đáng kể, đặc biệt khi kết nối internet bị hạn chế.
- **Tách Dữ Liệu:** Tách quy trình phân tích dữ liệu thành phân tích biên cục bộ và phân tích máy chủ tập trung trong khi vẫn duy trì độ chính xác đặt ra những thách thức kỹ thuật.

4.3.6.2 Lợi Ích Chính

- **Phân Tích Dữ Liệu Có Thể Mở Rộng:** Khuôn khổ được đề xuất áp dụng cách tiếp cận phân lớp nơi các thiết bị biên tiền xử lý và phân tích dữ liệu cục bộ, bao gồm dữ liệu tăng trưởng từ cảm biến môi trường. Phân tích cục bộ này giúp ước tính tiềm năng cây trồng hiện tại dựa trên trạng thái tăng trưởng.
- **Truyền Dữ Liệu Hiệu Quả:** Bằng cách chỉ truyền thông tin tỷ lệ thu hoạch sớm đến máy chủ trung tâm, khuôn khổ giảm độ phức tạp của việc truyền dữ liệu trong khi cho phép máy chủ dự đoán xu hướng năng suất thu hoạch trong tương lai.

4.3.6.3 Kết Quả và Hàm Ý

Nghiên cứu đã tiến hành các thí nghiệm trong thế giới thực tại một trang trại cà chua, chứng minh hiệu quả của khuôn khổ phân tích dữ liệu phân lớp:

- **Độ Chính Xác Tương Đương Với Phân Tích Máy Chủ:** Kết quả cho thấy tỷ lệ lỗi đạt được bởi phân tích biên có thể so sánh với phân tích chỉ trên máy chủ, ngay cả với các tập đặc trưng được giảm đáng kể.
- **Cải Thiện Độ Phức Tạp:** Khuôn khổ được đề xuất giảm đáng kể độ phức tạp trong khi vẫn duy trì kết quả chính xác, biến nó thành một giải pháp thực tế cho các nông trại thông minh có kết nối internet hạn chế.

Phương pháp phân tích dữ liệu phân lớp được giới thiệu trong nghiên cứu điển hình này cung cấp một giải pháp đầy hứa hẹn để nâng cao dự đoán năng suất cây trồng trong các nông trại thông minh. Bằng cách tận dụng EC cho phân tích dữ liệu cục bộ và chỉ truyền thông tin thiết yếu đến máy chủ trung tâm, dữ liệu nhạy cảm có thể được bảo vệ khỏi internet trong khi vẫn đóng góp vào các ước tính năng suất chính xác.

4.3.7 Nâng Cao Cảm Biến Dữ Liệu Trong Nông Nghiệp Thông Minh Thông Qua EC

Một khuôn khổ cảm biến dữ liệu tận dụng sự cộng hưởng của EC và IoT đã được phát triển để giải quyết các thách thức của việc thu thập dữ liệu có giá trị trong suốt vòng đời cây trồng một cách hiệu quả về chi phí. Nghiên cứu điển hình này xem xét nghiên cứu sáng tạo được thực hiện bởi Rihong Zhang và Xiaomin Li [17], với trọng tâm cụ thể vào một chiến lược cảm biến dữ liệu mới nhằm nâng cao hiệu quả và tính hiệu quả về chi phí của việc thu thập dữ liệu trong các giai đoạn tăng trưởng cây trồng khác nhau.

4.3.7.1 Các Thách Thức Được Giải Quyết

- **Giá Trị Dữ Liệu Hạn Chế:** Các phương pháp hiện có gặp khó khăn trong việc nắm bắt dữ liệu giá trị cao tương quan với các giai đoạn tăng trưởng cây trồng cụ thể.
- **Tương Quan Dữ Liệu:** Tương quan dữ liệu yếu cản trở khả năng rút ra những hiểu biết có ý nghĩa từ dữ liệu thu thập được.
- **Chi Phí Thu Thập Dữ Liệu Cao:** Các cách tiếp cận thu thập dữ liệu truyền thống tốn nhiều tài nguyên và chi phí cao.

4.3.7.2 Lợi Ích Chính

- **Chiến Lược Cảm Biến Dữ Liệu:** Chiến lược được đề xuất bao gồm bốn giai đoạn riêng biệt:
    - o Chia giai đoạn tăng trưởng cây trồng bằng cách sử dụng phân cụm mờ Gath-Geva (GG).
    - o Dự đoán các giai đoạn tăng trưởng cây trồng hiện tại bằng cách sử dụng mạng nơ-ron mờ Tkagi-Sugneo (T-S).
    - o Tối ưu hóa các thông số cảm biến môi trường dựa trên phân tích quan hệ màu xám của Deng.
    - o Một phương pháp cảm biến thích ứng đã được thiết kế để phù hợp với các nút cảm biến có các ràng buộc về khu vực cảm biến hiệu quả của chúng.
- **Cải Thiện Giá Trị Dữ Liệu:** Chiến lược này nâng cao đáng kể giá trị của dữ liệu cảm biến thu thập được bằng cách liên kết nó với các giai đoạn tăng trưởng cây trồng cụ thể.

4.3.7.3 Kết Quả và Hàm Ý

Nghiên cứu đã tiến hành các thí nghiệm rộng rãi để đánh giá hiệu suất của chiến lược cảm biến dữ liệu được đề xuất:

- **Độ Chính Xác Cao:** Kết quả chứng minh rằng chiến lược có thể chia và dự đoán hiệu quả các giai đoạn tăng trưởng cây trồng với độ chính xác cao.
- **Lợi Ích Hiệu Suất:** Chiến lược giảm đáng kể thời gian cảm biến và thu thập dữ liệu, dẫn đến giảm tiêu thụ năng lượng và chi phí thu thập dữ liệu thấp hơn.

- **Giá Trị Dữ Liệu Được Nâng Cao:** Bằng cách cải thiện sự liên kết của dữ liệu thu thập được với các giai đoạn tăng trưởng cây trồng, chiến lược nâng cao giá trị tổng thể của dữ liệu cảm biến.

Nông nghiệp thông minh đòi hỏi một hệ thống giám sát dữ liệu mạnh mẽ có khả năng thu thập dữ liệu có giá trị một cách hiệu quả về chi phí trong suốt toàn bộ vòng đời cây trồng. Nghiên cứu điển hình này giới thiệu một khuôn khổ thu thập dữ liệu tích hợp cảm biến, EC và IoT. Nó trình bày một chiến lược cảm biến dữ liệu dựa trên các nguyên tắc EC, bao gồm bốn giai đoạn. Chiến lược này nhằm mục đích vượt qua các thách thức liên quan đến giá trị dữ liệu, tương quan và chi phí thu thập, cuối cùng mang lại dữ liệu hiệu quả và có giá trị hơn.

4.3.8 Thúc Đẩy Quản Lý Vườn Nho Thông Qua AI Biên

Những năm gần đây đã chứng kiến một sự thay đổi đáng kể trong nông nghiệp, với sự công nhận ngày càng tăng về những lợi ích tiềm năng của các công cụ và kỹ thuật Công nghệ Thông tin và Truyền thông (ICT). Các báo cáo chính thức ủng hộ việc cải thiện chất lượng, số lượng sản phẩm và điều kiện kinh tế đã nhấn mạnh sự cần thiết của ngành nông nghiệp phải nắm lấy những đổi mới này. Do đó, việc triển khai các thiết bị cảm biến trong nông nghiệp đã tăng mạnh, mở đường cho sự xuất hiện của nông nghiệp thông minh. Khái niệm đang phát triển này bao gồm nhiều hoạt động khác nhau, đáng chú ý nhất là giám sát đồng ruộng, cung cấp hỗ trợ ra quyết định cho các hành động như tưới tiêu và bón phân.

Ngoài các thiết bị cảm biến thông thường sử dụng giao thức internet để chuyển dữ liệu, lĩnh vực nông nghiệp thông minh kết hợp các mô hình cây trồng. Các mô hình này khai thác dữ liệu cảm biến để cung cấp thông tin chi tiết và khuyến nghị nâng cao cho nông dân, cuối cùng nâng cao chất lượng và số lượng sản xuất nông nghiệp.

Nghiên cứu điển hình này đi sâu vào công trình sáng tạo được trình bày bởi Sergio Trilles và nhóm của ông [18]. Nghiên cứu tập trung vào sự phát triển của một nền tảng cảm biến hóa chi phí thấp phù hợp với mô hình IoT. Nền tảng tập trung vào việc giám sát các điều kiện khí tượng, chủ yếu để hỗ trợ phát hiện bệnh phấn trắng trong các vườn nho. Tận dụng EC và lấy cảm hứng từ những tiến bộ trong Khoa học Thông tin Địa lý (GIScience), nền tảng này đã được triển khai tại một vườn nho ở Vilafamés, Tây Ban Nha.

4.3.8.1 Các Thách Thức Được Giải Quyết

- **Giảm Chi Phí:** Nền tảng nhằm mục đích tối ưu hóa thời gian của các phương pháp xử lý kiểm soát bệnh phấn trắng, do đó giảm thiểu chi phí liên quan đến việc sử dụng hóa chất không cần thiết.
- **Tác Động Môi Trường:** Bằng cách xác định chính xác thời điểm áp dụng phương pháp xử lý, nền tảng góp phần giảm dấu chân sinh thái bằng cách hạn chế việc sử dụng hóa chất và ô nhiễm đất.
- **Hiệu Quả Lao Động:** Hệ thống nâng cao hiệu quả lao động bằng cách loại bỏ nhu cầu đến thăm vườn nho và xử lý không cần thiết.

4.3.8.2 Lợi Ích Chính

- **Tiết Kiệm Chi Phí:** Nền tảng xác định các thời điểm tối ưu để áp dụng các phương pháp xử lý kiểm soát bệnh phấn trắng, dẫn đến giảm đáng kể chi phí hóa chất.
- **Tính Bền Vững Môi Trường:** Bằng cách hạn chế việc sử dụng hóa chất, nền tảng thúc đẩy một môi trường lành mạnh hơn và các phương pháp nông nghiệp bền vững hơn.
- **Tối Ưu Hóa Lao Động:** Lao động nông trại được sử dụng hiệu quả hơn, vì các phương pháp xử lý chỉ được thực hiện khi cần thiết, giải phóng thời gian làm việc cho các nhiệm vụ thiết yếu khác.

4.3.8.3 Kết Quả và Hàm Ý

Nền tảng cảm biến hóa, được gọi là SEnviro, đã chứng minh hiệu quả trong việc giám sát các vườn nho. Bằng cách khai thác các mô hình IoT và EC, một phiên bản nâng cao của nền tảng này xử lý dữ liệu cục bộ, cho phép tính toán thông tin ngay lập tức khi thu thập dữ liệu. Cách tiếp cận này không chỉ giảm thời gian truyền dữ liệu và tiêu thụ năng lượng mà còn nâng cao độ chính xác của việc ra quyết định.

Trọng tâm chính của ứng dụng nền tảng là việc phát hiện kịp thời các cơ hội điều trị bệnh phấn trắng. Thông qua phân tích dữ liệu khí tượng thời gian thực, hệ thống cung cấp những hiểu biết có giá trị cho việc kiểm soát bệnh. Mặc dù nghiên cứu điển hình này chủ yếu kiểm tra chức năng của nền tảng IoT và không nhằm mục đích xác thực các mô hình bệnh, nhưng kết quả rất hứa hẹn.

4.3.9 Chuyển Đổi Giám Sát Phúc Lợi Động Vật Trong Nông Nghiệp Với Điện Toán AI Biên

Những năm gần đây đã chứng kiến một sự thay đổi đáng kể trong nông nghiệp, được thúc đẩy bởi sự xuất hiện của các công nghệ cảm biến và điện toán thông minh. Các hệ thống nông nghiệp thông minh, mặc dù vẫn còn tương đối non trẻ, nắm giữ tiềm năng to lớn để cách mạng hóa các phương pháp canh tác cây trồng và vật nuôi. Nghiên cứu điển hình này, lấy cảm hứng từ nghiên cứu được thực hiện bởi Marcel Caria và nhóm của ông [19], tập trung vào sự phát triển của một hệ thống điện toán nông trại thông minh mở và hiệu quả về chi phí để giám sát phúc lợi động vật. Hệ thống tận dụng EC, điện toán sương mù và kết nối đám mây để tạo ra một giải pháp toàn diện giải quyết các khía cạnh phức tạp và đa diện của phúc lợi động vật.

4.3.9.1 Các Thách Thức Được Giải Quyết

- **Khả Năng Tiếp Cận Hạn Chế:** Nhiều hệ thống nông nghiệp thông minh hiện có bị đóng cho việc thử nghiệm, hạn chế cơ hội đổi mới và tùy chỉnh, đặc biệt là trong lĩnh vực giám sát phúc lợi động vật.
- **Giám Sát Toàn Diện:** Phúc lợi động vật bao gồm một loạt các thông số và yếu tố rộng, gây khó khăn cho việc phát triển một giải pháp giám sát toàn diện đáp ứng nhu cầu đa dạng của các bên liên quan.

- **Hiệu Quả Chi Phí:** Giữ chi phí thấp trong khi đảm bảo giám sát hiệu quả phúc lợi động vật là một cân nhắc quan trọng cho ngành nông nghiệp.

4.3.9.2 Lợi Ích Chính

Hệ thống điện toán nông trại thông minh được đề xuất mang lại một số lợi thế chính:

- **Mở và Chi Phí Thấp:** Bằng cách áp dụng các nguyên tắc mã nguồn mở và sử dụng các thiết bị Raspberry Pi hiệu quả về chi phí làm các nút biên, hệ thống cung cấp các giải pháp có thể truy cập và tùy chỉnh được cho việc giám sát phúc lợi động vật.
- **Lớp Điện Toán Sương Mù:** Việc tạo ra khái niệm một lớp điện toán sương mù cho phép xử lý dữ liệu thời gian thực tại biên, giảm độ trễ và tăng cường khả năng phản hồi trong việc giám sát các thông số khác nhau.
- **Kết Nối Đám Mây:** Tích hợp liền mạch với các hệ thống điện toán đám mây cho phép lưu trữ dữ liệu tập trung, phân tích và truy cập từ xa, cung cấp một cái nhìn tổng quan toàn diện về phúc lợi động vật.
- **Giám Sát Đa Thông Số:** Hệ thống giám sát và thu thập dữ liệu hiệu quả về nhiều thông số liên quan đến phúc lợi động vật, cung cấp thông tin chi tiết có giá trị cho các bên liên quan.

4.3.9.3 Kết Quả và Hàm Ý

Hệ thống điện toán nông trại thông minh được đề xuất, kết hợp EC với kết nối đám mây, chứng minh hiệu quả của nó trong việc giám sát các thông số đa dạng liên quan đến phúc lợi động vật. Bằng cách tận dụng các thiết bị Raspberry Pi làm thiết bị biên, hệ thống tạo ra một lớp điện toán sương mù xử lý dữ liệu cục bộ, đảm bảo khả năng phản hồi thời gian thực.

Cách tiếp cận đổi mới này đối với giám sát phúc lợi động vật không chỉ giải quyết các nhu cầu trước mắt của nông dân và người chăn nuôi mà còn mang lại khả năng cho sự tham gia rộng rãi hơn của các bên liên quan. Phúc lợi động vật, một khái niệm đa diện, có thể được đo lường, thu thập, đánh giá và chia sẻ, tạo ra cơ hội để cải thiện phúc lợi của động vật và thúc đẩy các đổi mới công nghệ cao trong lĩnh vực nông nghiệp.

Nghiên cứu điển hình này cho thấy tiềm năng chuyển đổi của điện toán AI Biên trong bối cảnh nông nghiệp thông minh, cụ thể là trong việc giám sát và nâng cao phúc lợi động vật. Bằng cách cung cấp các giải pháp có thể tiếp cận, hiệu quả về chi phí và mở, nó mở ra những con đường mới để cải thiện các phương pháp nông nghiệp, thúc đẩy phúc lợi động vật và thúc đẩy các tiến bộ công nghệ trong ngành.

4.3.10 Canh Tác Với CareBro: Một Trợ Lý Canh Tác IoT Được Hỗ Trợ Bởi AI Biên

Trong bối cảnh hậu COVID-19, nông nghiệp phải đối mặt với một sự chuyển đổi then chốt. Mệnh lệnh mới nằm ở việc nâng cao năng suất và đảm bảo an toàn của sản phẩm nông nghiệp, đồng thời giảm sự phụ thuộc vào các phương pháp thâm dụng lao động

truyền thống. Công nghệ nổi lên như một ngọn hải đăng hy vọng, và một cách tiếp cận không tiếp xúc, đáng tin cậy và an toàn là nhu cầu cấp thiết. “CareBro” là một giải pháp đột phá được thiết kế để định nghĩa lại và cách mạng hóa các phương pháp canh tác. Hệ thống nông nghiệp thông minh dựa trên IoT này, được cung cấp bởi EC, nắm quyền quản lý trang trại, làm cho nó tự động và từ xa. Nó tích hợp liền mạch với các cảm biến nông trại thông minh, điều phối các hoạt động như tối ưu hóa năng suất cây trồng, quản lý dịch hại có đạo đức và tưới tiêu chính xác. CareBro hoạt động như một giải pháp tiên tiến, kết nối với nông dân thông qua đám mây, cung cấp giám sát thời gian thực và ra quyết định thông minh. Sự đổi mới này, được tạo ra bởi Atharv Tendolkar và Ramya [20], đại diện cho một giải pháp quản lý trang trại sáng tạo, có thể áp dụng trên nhiều cảnh quan canh tác khác nhau, từ các môi trường đô thị và nông thôn đến các hoạt động quy mô lớn và quy mô nhỏ.

4.3.10.1 Các Thách Thức Được Giải Quyết

- **Thiếu Hụt Lao Động:** CareBro bước vào như một giải pháp cho các thách thức canh tác trầm trọng hơn do tình trạng thiếu lao động, đảm bảo tính liên tục của hoạt động trang trại ngay cả trong khủng hoảng.
- **Nâng Cao Năng Suất:** Hệ thống nhằm mục đích tăng đáng kể năng suất cây trồng trong khi đảm bảo các phương pháp canh tác bền vững và có đạo đức.
- **Nông Nghiệp Chính Xác:** CareBro giải quyết nhu cầu về độ chính xác trong quản lý dịch hại và tưới tiêu, tối ưu hóa việc sử dụng tài nguyên và giảm thiểu tác động môi trường.
- **Giám Sát Từ Xa:** Với khả năng giám sát thời gian thực và điều khiển từ xa, nó thu hẹp khoảng cách giữa nông dân và đồng ruộng của họ, mang lại một lớp tiện lợi và kiểm soát.

4.3.10.2 Lợi Ích Chính

- **Năng Suất Tối Đa:** CareBro trao quyền cho nông dân để tối đa hóa năng suất cây trồng trong khi cung cấp thông tin chi tiết có giá trị về các thách thức và chiến lược giảm thiểu, tất cả được quản lý từ xa và an toàn.
- **Khả Năng Thích Ứng:** Hệ thống được thiết kế để thích ứng, với các cảm biến được hiệu chuẩn thông qua thử nghiệm beta để phản ứng hiệu quả với các điều kiện môi trường thay đổi.
- **Đa Chức Năng:** Tiềm năng của CareBro mở rộng ra ngoài quản lý trang trại; nó có thể phục vụ như một trung tâm cho các dịch vụ canh tác khác nhau, bao gồm các nhiệm vụ tự động như thu hoạch kết hợp, phun chất dinh dưỡng và tưới tiêu.
- **Điện Toán Biên:** Với lưới mạng IoT và khả năng EC cục bộ, CareBro nâng cao trí thông minh tại mọi nút trên toàn bộ trang trại.

4.3.10.3 Kết Quả và Hàm Ý

Sự phát triển của CareBro đã cho thấy tiềm năng cách mạng hóa các phương pháp canh tác. Thử nghiệm beta và hiệu chuẩn cảm biến đã đảm bảo khả năng thích ứng của thiết bị với các môi trường năng động. Việc tích hợp nhiều mô-đun và nâng cao kết nối thông

qua một khung vật lý giống như bù nhìn đã là một bước quan trọng. Khả năng mở rộng và đa chức năng của CareBro, có khả năng phục vụ như một trung tâm cho các dịch vụ trang trại khác nhau, nắm giữ triển vọng đáng kể cho tương lai. Với khả năng ứng dụng rộng rãi, tính khả thi về kinh tế và tiềm năng mở rộng, CareBro nổi lên như một trợ lý trang trại tiêu biểu cho cảnh quan canh tác hiện đại, được thúc đẩy bởi IoT.

CareBro hoạt động bền vững, cung cấp sự tiện lợi và độ chính xác trong quản lý trang trại, thúc đẩy niềm tin vào công nghệ. Khi công nghệ tiếp tục phát triển, với sự ra đời của 5G và những tiến bộ trong EC, CareBro được kỳ vọng sẽ đáp ứng các nhu cầu và kỳ vọng đang phát triển của nông dân. Nó đứng như một minh chứng cho sự tập trung vào khách hàng, các phương pháp canh tác bền vững, nguyên tắc đạo đức và an toàn.

4.4 THẢO LUẬN

Các nghiên cứu điển hình được trình bày trong chương này cung cấp một tấm thảm phong phú về những hiểu biết vào thế giới ứng dụng AI Biên trong nông nghiệp. Những hệ thống sáng tạo này đưa lên hàng đầu nhiều tính năng chức năng, kịch bản sử dụng, lợi ích, tác động kinh tế xã hội và các cân nhắc về việc áp dụng mà cùng nhau định nghĩa ý nghĩa sâu sắc của chúng đối với các bên liên quan trong lĩnh vực nông nghiệp.

4.4.1 Tính Năng Chức Năng và Sử Dụng

- **Giám Sát Thời Gian Thực:** Các hệ thống AI Biên xuất sắc trong việc giám sát thời gian thực các thông số nông nghiệp quan trọng. Tính năng này là không thể thiếu trong canh tác hiện đại, vì nó cho phép nông dân có được thông tin cập nhật từng phút về điều kiện đất đai, kiểu thời tiết và sức khỏe cây trồng. Việc sử dụng cảm biến, camera và phân tích dữ liệu cho phép thu thập và diễn giải dữ liệu liên tục. Kết quả là, nông dân có thể đưa ra quyết định kịp thời về tưới tiêu, kiểm soát dịch hại và quản lý bệnh.
- **Ra Quyết Định Dựa Trên Dữ Liệu:** Các hệ thống này tận dụng phân tích tiên tiến và các thuật toán học máy để tạo ra các khuyến nghị dựa trên dữ liệu. Bằng cách phân tích các tập dữ liệu lớn được thu thập từ các trang trại, chúng cung cấp những hiểu biết có thể hành động cho việc phân bổ tài nguyên chính xác. Ví dụ, chúng có thể xác định chính xác lượng nước cần thiết cho tưới tiêu, thời điểm tối ưu để áp dụng thuốc trừ sâu hoặc nhu cầu về các chất dinh dưỡng cụ thể. Việc ra quyết định dựa trên dữ liệu này không chỉ nâng cao năng suất cây trồng mà còn giảm thiểu tác động môi trường của các hoạt động canh tác.
- **Khả Năng Kết Nối Lẫn Nhau:** Khả năng tiếp cận là nền tảng của các hệ thống AI Biên. Chúng được thiết kế để kết nối liền mạch, cho phép nông dân giám sát và quản lý trang trại của họ từ xa. Các ứng dụng di động và giao diện web cung cấp quyền truy cập thân thiện với người dùng vào dữ liệu thời gian thực và khả năng kiểm soát. Nông dân có thể nhận cảnh báo và thông báo, xem báo cáo và điều chỉnh cài đặt thông qua các giao diện này, bất kể vị trí vật lý của họ. Chức năng này nâng cao sự tiện lợi và hiệu quả trong quản lý trang trại.

- **Bảo Mật và Quyền Riêng Tư:** Bảo mật dữ liệu và quyền riêng tư là tối quan trọng. Để giải quyết những lo ngại này, một số hệ thống kết hợp công nghệ blockchain. Blockchain đảm bảo tính toàn vẹn và bảo mật của dữ liệu bằng cách tạo ra các bản ghi không thể giả mạo. Hơn nữa, các hệ thống này thường ưu tiên xử lý dữ liệu cục bộ tại biên, có nghĩa là thông tin nhạy cảm được xử lý tại chỗ thay vì được truyền đến các máy chủ tập trung. Cách tiếp cận này làm giảm nguy cơ vi phạm dữ liệu trong quá trình truyền tải.

4.4.2 Lợi Ích

- **Hiệu Quả Tài Nguyên:** Các hệ thống AI Biên là những nhà vô địch về hiệu quả tài nguyên. Bằng cách liên tục giám sát độ ẩm đất, nhiệt độ, độ ẩm và các thông số khác, chúng tối ưu hóa việc sử dụng tài nguyên. Sự tối ưu hóa này mở rộng sang nước, phân bón, thuốc trừ sâu và năng lượng. Ví dụ, việc kiểm soát chính xác hệ thống tưới tiêu làm giảm lãng phí nước, điều đặc biệt quan trọng ở các khu vực khan hiếm nước. Tương tự, việc bón phân và quản lý dịch hại được điều chỉnh làm giảm lượng hóa chất chảy tràn, góp phần vào tính bền vững môi trường. Những lợi ích hiệu quả này dẫn đến tiết kiệm chi phí cho nông dân.
- **Tăng Năng Suất Cây Trồng:** Các can thiệp kịp thời được tạo điều kiện bởi các hệ thống AI Biên chuyển thành năng suất cây trồng tăng lên. Bằng cách phát hiện bệnh, sâu bệnh hoặc căng thẳng nước ở giai đoạn đầu, các hệ thống này cho phép nông dân thực hiện các hành động khắc phục nhanh chóng. Ví dụ, chúng có thể kích hoạt tưới tiêu khi độ ẩm đất giảm xuống dưới một ngưỡng nhất định, ngăn ngừa cây héo. Hơn nữa, chúng có thể xác định sự hiện diện của sâu bệnh hoặc bệnh thông qua nhận dạng hình ảnh, cho phép điều trị mục tiêu. Hiệu ứng tích lũy của các biện pháp này là năng suất cây trồng cao hơn, cuối cùng mang lại lợi ích cho cả an ninh lương thực và lợi nhuận trang trại.
- **Thông Tin Chi Tiết Dựa Trên Dữ Liệu:** Các hệ thống AI Biên cung cấp cho nông dân những hiểu biết có giá trị dựa trên dữ liệu. Khi các kiểu khí hậu trở nên khó dự đoán hơn và các phương pháp canh tác phát triển, những hiểu biết này là rất quan trọng để đưa ra quyết định sáng suốt. Nông dân có quyền truy cập vào dữ liệu lịch sử và thời gian thực, cho phép họ thích ứng với các điều kiện thay đổi. Ví dụ, họ có thể điều chỉnh lịch trình trồng trọt dựa trên dự báo thời tiết hoặc tối ưu hóa chế độ tưới tiêu theo mức độ ẩm của đất. Cách tiếp cận dựa trên dữ liệu này nuôi dưỡng khả năng phục hồi trong nông nghiệp, cho phép nông dân điều hướng các thách thức một cách hiệu quả.

4.4.3 Tác Động Kinh Tế Xã Hội

- **Trao Quyền Cho Nông Hộ Nhỏ:** Ở các khu vực có tỷ lệ nông hộ nhỏ cao, các hệ thống AI Biên đóng một vai trò then chốt trong việc san bằng sân chơi. Các công nghệ này cung cấp quyền truy cập vào các phương pháp và công cụ canh tác tiên tiến mà trước đây vượt quá tầm với của nhiều nông dân quy mô nhỏ. Kết quả là, các cộng đồng nông thôn được hưởng lợi từ năng suất nông nghiệp được nâng cao

và sinh kế được cải thiện. Tác động kinh tế xã hội đặc biệt quan trọng ở các nước đang phát triển, nơi nông nghiệp là nguồn thu nhập chính.

- **Tính Bền Vững Môi Trường:** Các thực hành tiết kiệm tài nguyên được thúc đẩy bởi các hệ thống AI Biên góp phần vào tính bền vững môi trường. Việc sử dụng nước giảm, lượng hóa chất chảy tràn được giảm thiểu và mức tiêu thụ năng lượng thấp hơn cùng nhau giảm thiểu tác động môi trường của nông nghiệp. Các hệ thống này phù hợp với các mục tiêu bền vững toàn cầu bằng cách thúc đẩy các phương pháp canh tác thân thiện với môi trường. Các hàm ý kinh tế xã hội mở rộng sang môi trường sạch hơn, hệ sinh thái lành mạnh hơn và dấu chân carbon giảm.

4.4.4 Việc Áp Dụng và Triển Vọng Tương Lai

- **Khả Năng Mở Rộng:** Một trong những động lực chính của việc áp dụng là khả năng mở rộng của các hệ thống AI Biên. Chúng được thiết kế để phục vụ nhiều người dùng và trang trại đồng thời. Khả năng mở rộng này làm cho chúng có thể tiếp cận được với một loạt các bên liên quan, từ nông dân cá nhân đến các doanh nghiệp nông nghiệp lớn. Khi càng nhiều trang trại áp dụng các công nghệ này, tác động tập thể lên nông nghiệp ngày càng trở nên quan trọng.
- **Tích Hợp Liên Ngành:** Các hệ thống AI Biên thể hiện tính linh hoạt thông qua tích hợp liên ngành. Chúng kết hợp nhiều công nghệ khác nhau, bao gồm IoT, blockchain và camera để giám sát sức khỏe dịch hại và cây trồng. Khả năng thích ứng này định vị chúng cho sự phát triển hơn nữa và thích ứng với các thách thức nông nghiệp đang phát triển. Ví dụ, việc tích hợp camera để phát hiện dịch hại và giám sát sức khỏe cây trồng mở rộng tính hữu ích của chúng ngoài quản lý tài nguyên để bao gồm kiểm soát dịch hại chủ động.

4.5 KẾT LUẬN

Trong chương này, chúng ta đã bắt đầu một hành trình xuyên qua cảnh quan năng động của AI Biên trong nông nghiệp. Khái niệm cơ bản của AI Biên đã được khám phá, tiềm năng của nó đã được giải mã, và vai trò then chốt của nó trong việc định hình lại nông nghiệp hiện đại đã được công nhận. Một kỷ nguyên mới về tính tức thời, khả năng phản hồi và hiệu quả trong các phương pháp canh tác được báo trước bởi sự tích hợp của AI với EC và IoT.

Khi đi sâu vào một loạt các nghiên cứu điển hình, chúng ta đã chứng kiến cách AI Biên đã được áp dụng để giải quyết những thách thức cấp bách nhất trong nông nghiệp, trải dài cả bối cảnh trong nước và quốc tế. Tiềm năng chuyển đổi của AI Biên đã được chứng minh bởi các ví dụ thực tế này, cho thấy tính linh hoạt và khả năng thích ứng của nó. Từ nông nghiệp chính xác và tối ưu hóa tài nguyên đến quản lý vật nuôi và giám sát cây trồng, AI Biên đã được chứng minh là một chất xúc tác cho đổi mới, cho phép nông dân và các bên liên quan đưa ra quyết định dựa trên dữ liệu, giảm lãng phí và nâng cao năng suất.

Việc áp dụng AI Biên trong nông nghiệp không phải là không có thách thức, bao gồm các vấn đề liên quan đến kết nối, quyền riêng tư dữ liệu và khả năng mở rộng. Tuy nhiên, các giải pháp được đưa ra để đảm bảo tích hợp liền mạch và bảo vệ dữ liệu nông nghiệp nhạy cảm.

Tóm lại, AI Biên là một đồng minh mạnh mẽ trong việc theo đuổi các phương pháp canh tác bền vững và hiệu quả. Các bên liên quan được trao quyền với thông tin chi tiết thời gian thực, cho phép đưa ra quyết định sáng suốt mang lại lợi ích cho cả ngành nông nghiệp và môi trường. Khi chúng ta tiến lên phía trước, tiềm năng cho đổi mới trong AI Biên vẫn không giới hạn, hứa hẹn một tương lai nơi nông nghiệp trở nên thông minh hơn, xanh hơn và kiên cường hơn.

Tài liệu tham khảo

- [1] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, "Edge computing: Vision and challenges," *IEEE Internet Things J.*, vol. 3, no. 5, pp. 637-646, 2016.
- [2] Y. Mao, C. You, J. Zhang, K. Huang, and K. B. Letaief, "A survey on mobile edge computing: The communication perspective," *IEEE Commun. Surv. Tutor.*, vol. 19, no. 4, pp. 2322-2358, 2017.
- [3] D. Situnayake and J. Plunkett, *AI at the edge: Solving real-world problems with embedded machine learning*. Sebastopol, CA: O'Reilly Media, 2023.
- [4] Z. Zhou, X. Chen, E. Li, L. Zeng, K. Luo, and J. Zhang, "Edge intelligence: Paving the last mile of artificial intelligence with edge computing," *Proc. IEEE Inst. Electr. Electron. Eng.*, vol. 107, no. 8, pp. 1738-1762, 2019.
- [5] T. H. Luan, L. Gao, Z. Li, Y. Xiang, G. Wei, and L. Sun, "Fog computing: Focusing on mobile users at the edge," *arXiv* [cs.NI], 2015.
- [6] J. Wang, Z. Feng, S. George, R. Iyengar, P. Pillai, and M. Satyanarayanan, "Towards scalable edge-native applications," in *Proceedings of the 4th ACM/IEEE Symposium on Edge Computing*, 2019.
- [7] F. J. Ferrandez-Pastor, J. M. Garcia-Chamizo, M. Nieto-Hidalgo, J. Mora-Pascual, and J. Mora-Martinez, "Developing Ubiquitous Sensor Network platform using Internet of Things: Application in precision agriculture," *Sensors (Basel)*, vol. 16, no. 7, p. 1141, 2016.
- [8] S. T. Oliver, A. Gonzalez-Perez, and J. H. Guijarro, "An IoT proposal for monitoring vineyards called SEnviro for agriculture," in *Proceedings of the 8th International Conference on the Internet of Things*, 2018.
- [9] D. Berckmans, "General introduction to precision livestock farming," *Anim. Front.*, vol. 7, no. 1, pp. 6-11, 2017.
- [10] X. Zhang, Z. Cao, and W. Dong, "Overview of edge computing in the agricultural internet of things: Key technologies, applications, challenges," *IEEE Access*, vol. 8, pp. 141748-141761, 2020.

- [11] H. T. Minh, T. P. Anh, and V. N. Nhan, “A novel light-weight DCNN model for classifying plant diseases on internet of things edge devices,” *Mendel*, vol. 28, no. 2, pp. 41-48, 2022.
- [12] L. Ting, M. Khan, A. Sharma, and M. D. Ansari, “A secure framework for IoT-based smart climate agriculture system: Toward blockchain and edge computing,” *J. Intell. Syst.*, vol. 31, no. 1, pp. 221-236, 2022.
- [13] X. Li, Z. Ma, J. Zheng, Y. Liu, L. Zhu, and N. Zhou, “An effective edge-assisted data collection approach for critical events in the SDWSN-based agricultural internet of things,” *Electronics (Basel)*, vol. 9, no. 6, p. 907, 2020.
- [14] D. Shadrin, A. Menshchikov, D. Ermilov, and A. Somov, “Designing future precision agriculture: Detection of seeds germination using artificial intelligence on a low-power embedded system,” *IEEE Sens. J.*, vol. 19, no. 23, pp. 11573-11582, 2019.
- [15] R. Saha, A. Chakraborty, S. Misra, S. K. Das, and C. Chatterjee, “DLSense: Distributed learning-based smart virtual sensing for precision agriculture,” *IEEE Sens. J.*, vol. 21, no. 16, pp. 17556-17563, 2021.
- [16] J. Park, J.-H. Choi, Y.-J. Lee, and O. Min, “A layered features analysis in smart farm environments,” in *Proceedings of the International Conference on Big Data and Internet of Thing*, 2017.
- [17] R. Zhang and X. Li, “Edge computing driven data sensing strategy in the entire crop lifecycle for smart agriculture,” *Sensors (Basel)*, vol. 21, no. 22, p. 7502, 2021.
- [18] S. Trilles, J. Torres-Sospedra, O. Belmonte, F. J. Zarazaga-Soria, A. Gonzalez-Perez, and J. Huerta, “Development of an open sensorized platform in a smart agriculture context: A vineyard support system for monitoring mildew disease,” *Sustain. Comput. Inform. Syst.*, vol. 28, no. 100309, p. 100309, 2020.
- [19] M. Caria, J. Schudrowitz, A. Jukan, and N. Kemper, “Smart farm computing systems for animal welfare monitoring,” in *2017 40th International Convention on Information and Communication Technology, Electronics and Microelectronics (MIPRO)*, 2017.
- [20] A. Tendolkar and S. Ramya, “CareBro (personal farm assistant): An IoT based smart agriculture with edge computing,” in *2020 Third International Conference on Multimedia Processing, Communication & Information Technology (MPCIT)*, 2020.

Chương 5: Hệ khuyến nghị cây trồng: Phương pháp tính toán dựa trên học máy để đề xuất cây trồng phù hợp nhất bằng cách sử dụng các đặc điểm của đất và môi trường

Syed Nisar Hussain Bukhari, Jewiara Khursheed Wani, Ummer Iqbal, và Muneer Ahmad Dar *Viện Quốc gia về Điện tử và Công nghệ Thông tin (NIELIT), Srinagar, Ấn Độ*

5.1 GIỚI THIỆU

Ở nước ta, nông nghiệp là một trong những ngành kinh tế chính mà một số lượng lớn người dân phụ thuộc vào [1]. Mặc dù có sự đa dạng lớn về đặc điểm địa hình, địa mạo và các vùng khí hậu hỗ trợ nhiều loại hình canh tác khác nhau, năng suất thu được vẫn còn thấp do quản lý đồng ruộng kém và lựa chọn cây trồng sai lầm [2]. Để nuôi sống đầy đủ dân số đang tăng nhanh, điều quan trọng là phải ưu tiên tăng năng suất cây trồng một cách tương xứng. Điều này có thể được thực hiện bằng cách giải quyết các nguyên nhân cơ bản làm giảm sản lượng cây trồng, bao gồm lập kế hoạch không đầy đủ, quản lý vật nuôi yếu kém và tính chất không thể đoán trước của điều kiện thời tiết. Do hiện tượng phức tạp của sản xuất cây trồng bị ảnh hưởng bởi các thông số đầu vào khí hậu nông nghiệp, do đó các yêu cầu kỹ thuật đối với đầu vào nông nghiệp thay đổi tùy theo người nông dân và đồng ruộng [3].

Ngoài các yếu tố khác nhau ảnh hưởng đến sản xuất cây trồng, một vấn đề lớn khác mà các nhà nông học đang phải đối mặt là sự gia tăng của hiện tượng nóng lên toàn cầu. Nóng lên toàn cầu đang ở mức cao điểm dẫn đến hạn hán và các điều kiện khí hậu không thể dự đoán trước. Hơn nữa, những người nông dân làm việc theo cách truyền thống dẫn đến vấn đề quản lý đồng ruộng yếu kém và do đó ảnh hưởng đến năng suất. Theo các báo cáo, do điều kiện khí hậu không thể đoán trước trong nhiều năm, thu nhập của nông dân đã giảm 20,25% [4].

Nông nghiệp giữ một vị trí quan trọng trong tổng sản phẩm quốc nội (GDP) của Ấn Độ. Yếu tố quan trọng để đạt được năng suất cây trồng cao là lựa chọn đúng các loại cây trồng thích hợp vào đúng thời điểm trong năm. Tuy nhiên, nông dân thường dựa vào xu hướng thị trường và bản năng kế thừa từ tổ tiên, vốn đã được chứng minh là những phương pháp không hiệu quả [5]. Việc áp dụng phương pháp luận được đề xuất sẽ giúp nông dân khắc phục vấnn đề năng suất khó định lượng và đóng góp ngày càng nhiều hơn vào GDP của đất nước [6]. Việc sử dụng các thuật toán cũng sẽ hỗ trợ đạt được giải pháp hiệu quả, tiết kiệm chi phí cho những khó khăn mà nông dân phải đối mặt.

Các thuật toán được huấn luyện và kiểm tra sẽ được sử dụng để khuyến nghị cây trồng dựa trên các đầu vào khác nhau như hàm lượng Nitơ, Phốt pho, Kali (NPK) và độ pH của đất, nhiệt độ và độ ẩm của khu vực. Các loại cây trồng được dự đoán trong phương pháp luận này bao gồm ngô, bông, lúa, cà phê, đậu triều, đậu mắt đen, đay, đậu gà, dừa, đu đủ, cam, táo, dưa lưới, dưa hấu, nho, đậu thận, chuối, lựu, đậu lăng, đậu đen, đậu xanh, và xoài.

Một số đóng góp mới chính của chương này như sau:

- Trong nghiên cứu này, một hệ thống đã được đề xuất cho phép các nhà nông học lựa chọn cây trồng chính xác dựa trên các yếu…
- Hệ thống được đề xuất có thể làm giảm các phương pháp sai lầm được áp dụng trong quá trình lựa chọn cây trồng, từ đó có thể chứng minh là hữu ích trong việc cải thiện năng suất cây trồng.
- Một hệ khuyến nghị cây trồng (CR) được thiết kế để cung cấp các khuyến nghị về loại cây trồng phù hợp nhất để trồng sẽ được phát triển.

Chương này bao gồm bốn phần. Trong phần đầu tiên, phần giới thiệu đã được trình bày, và các vấn đề khác nhau liên quan đến giảm năng suất cây trồng đã được thảo luận. Phần thứ hai trình bày các công trình liên quan đã được thực hiện trong lĩnh vực này. Kịch bản thực nghiệm đã được đề cập trong phần thứ ba, bao gồm bộ dữ liệu được sử dụng và các phương pháp được sử dụng. Kết quả đã được cung cấp trong phần thứ tư. Cuối cùng, một kết luận của nghiên cứu đã được rút ra.

5.2 CÁC CÔNG TRÌNH LIÊN QUAN

Các công trình đã hoàn thành trong lĩnh vực khuyến nghị cây trồng của các nhà nghiên cứu khác nhau được bao gồm trong phần này. Mô tả kỹ lưỡng về dự án nghiên cứu được cung cấp trong phần còn lại của mục này, và tóm tắt của mục này được đưa ra trong Bảng 5.1.

Doshi và cộng sự [1] đã phát triển Agro Consultant, một hệ thống xem xét tất cả các thuộc tính liên quan - tức là nhiệt độ, vị trí, lượng mưa và tình trạng đất - để dự đoán sự phù hợp của cây trồng bằng cách sử dụng bốn thuật toán là Cây quyết định (DT), Rừng ngẫu nhiên (RF), Mạng nơ-ron (NN) và K-láng giềng gần nhất (KNN). Nghiên cứu này cũng trình bày một trình dự đoán lượng mưa (một hệ thống thứ cấp) cho phép dự đoán sớm về lượng mưa [1]. Kumar và cộng sự [7] đã xây dựng một mô hình gọi là lựa chọn cây trồng, dựa trên các thông số như thời tiết, loại đất, mật độ nước và loại cây trồng. Phương pháp này sử dụng các mô hình như RF, máy véc-tơ hỗ trợ (SVM), DT, KNN và Rừng tham lam chính quy hóa (RGF) [7]. Kumar Rajak và cộng sự [8] đã sử dụng một phương pháp được huấn luyện trên cơ sở dữ liệu đất thu được từ một trang trại.

BẢNG 5.1: Các công trình liên quan

Tác giả	Năm	Mô tả	Thuật toán
Doshi và cộng sự	2018	Dự đoán sự phù hợp của cây trồng bằng cách sử dụng tất cả các thuộc tính liên quan (tức là nhiệt độ, lượng mưa và tình trạng đất)	Cây quyết định, NN, RF, và KNN
Kumar và cộng sự	2015	Lựa chọn cây trồng sử dụng các	RF, SVM, Cây

Tác giả	Năm	Mô tả	Thuật toán
		thông số loại đất, mật độ nước và loại cây trồng	quyết định, KNN, và RGF
Kumar Rajak và cộng sự	2017	Khuyến nghị cây trồng sử dụng bộ dữ liệu đã được xác thực để tối đa hóa năng suất cây trồng	Bagging ANN, SVM, Naive Bayes, RF
Savla và cộng sự	2015	Phân tích so sánh bằng cách sử dụng các thuật toán phân loại khác nhau, đặc biệt là trên cây đậu nành	SVM, NN, RF, Cây REP
Shakil Ahamed và cộng sự	2015	Các kỹ thuật khai phá dữ liệu đã được tiến hành cho các loại cây ngũ cốc	KNN, Hồi quy tuyến tính, ANN
Suresh và cộng sự	2021	Đã phát triển một hệ thống gọi là năng suất cây trồng hiệu quả, dự đoán sự phù hợp của cây trồng bằng cách sử dụng hai bộ dữ liệu (tức là bộ dữ liệu về cây trồng và vị trí cụ thể)	SVM

Dữ liệu được lấy sau khi thử nghiệm từ phòng thí nghiệm sau đó được cung cấp cho một hệ thống khuyến nghị dựa trên mô hình ensemble của Mạng nơ-ron nhân tạo (ANN) và SVM [8]. Savla và cộng sự [9] đã thực hiện một phân tích tương đối về các thuật toán phân loại và phân tích tỷ lệ dự đoán trong nông nghiệp chính xác. Các thuật toán được sử dụng trong nghiên cứu là RF, NN, SVM, Cây cắt tỉa lỗi giảm (REP Tree), Bagging và Bayes. Trong số các thuật toán nói trên, thuật toán bagging đã cho kết quả tốt nhất để dự đoán năng suất [9]. Shakil và cộng sự [10] đã chỉ định việc sử dụng các kỹ thuật khai phá dữ liệu có thể giúp các tổ chức chính phủ và các nhà nông học rút ra thông tin cần thiết để đưa ra kết luận tốt hơn. Điều này cuối cùng dẫn đến tăng mức sản xuất. Những kỹ thuật này được áp dụng đặc biệt để ước tính cây ngũ cốc ở Bangladesh. Các thuật toán được sử dụng trong nghiên cứu của họ bao gồm phân cụm và phân loại bằng KNN, Hồi quy tuyến tính và ANN [10]. Suresh và cộng sự [11] đã phát triển một "Hệ thống khuyến nghị năng suất cây trồng hiệu quả" dựa trên SVM nhằm nhận diện một loại cây trồng cụ thể phù hợp với dữ liệu đã cho. Hệ thống khuyến nghị một loại cây trồng cụ thể phù hợp với các giá trị thông số (NPK và pH) [11].

5.3 DỮ LIỆU VÀ PHƯƠNG PHÁP

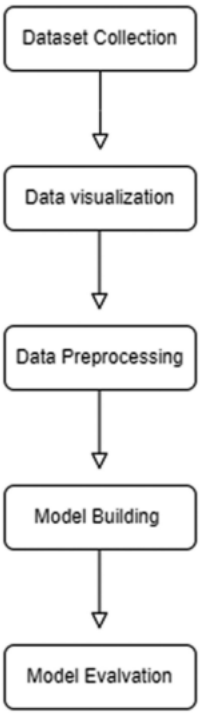
5.3.1 Kịch bản thực nghiệm

Để thử nghiệm, môi trường lập trình python được áp dụng. Các mô hình bagging đã được sử dụng để thử nghiệm. Các bước của thử nghiệm được liệt kê trong Hình 5.1. Các bước được thực hiện trong nghiên cứu này như sau: thu thập bộ dữ liệu liên quan, tiền xử lý bộ

dữ liệu thu được, trực quan hóa bộ dữ liệu, xây dựng mô hình ML và đánh giá mô hình đó. Dữ liệu được tiền xử lý và sau đó được đưa vào các mô hình để phân loại. Cuối cùng, phân tích so sánh giữa ensemble của các bộ phân loại đồng nhất và các bộ phân loại đơn lẻ được tiến hành.

5.3.2 Thu thập bộ dữ liệu

Dữ liệu được sử dụng cho nghiên cứu là sự kết hợp của hai bộ dữ liệu được thu thập từ Kaggle [12] là bộ dữ liệu khuyến nghị cây trồng và bộ dữ liệu agric, bao gồm 2.202 và 4.100 mẫu tương ứng. Sau khi hợp nhất các mẫu, bộ dữ liệu kết quả được chia thành các phần 7:3 để huấn luyện và kiểm tra.



HÌNH 5.1: Các bước thực nghiệm. *(Sơ đồ quy trình)*

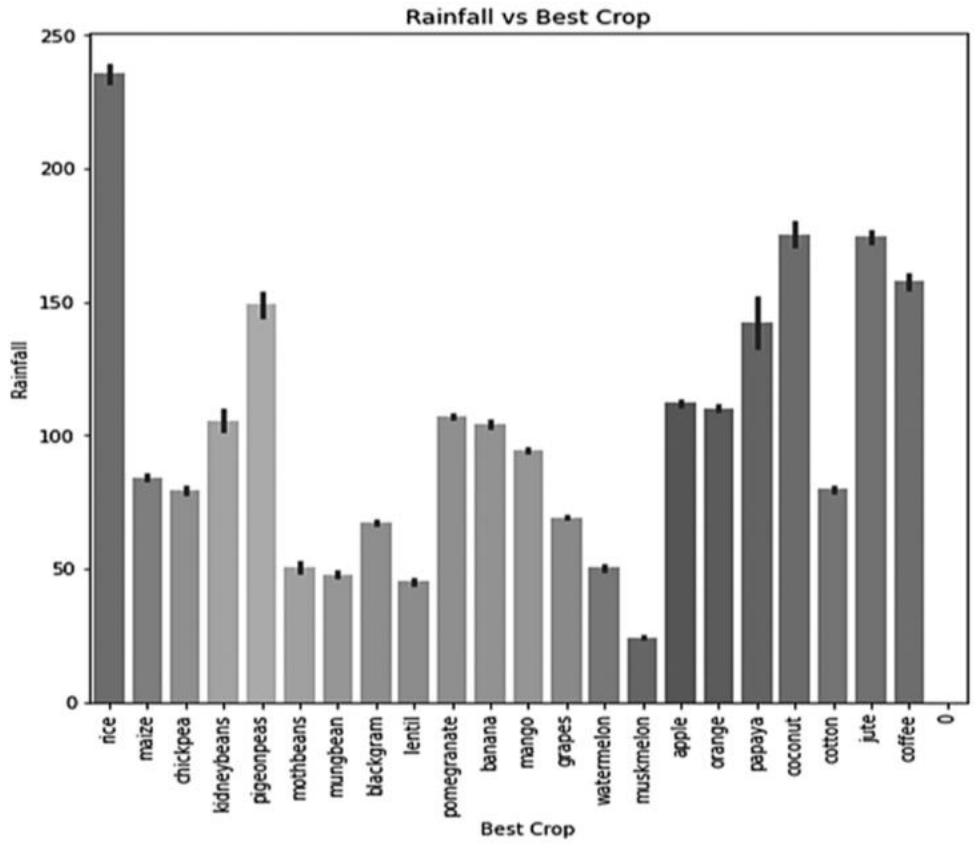
1. Thu thập dữ liệu (Dataset Collection)
2. Trực quan hóa dữ liệu (Data visualization)
3. Tiền xử lý dữ liệu (Data Preprocessing)
4. Xây dựng mô hình (Model Building)
5. Đánh giá mô hình (Model Evaluation)

5.3.3 Trực quan hóa dữ liệu

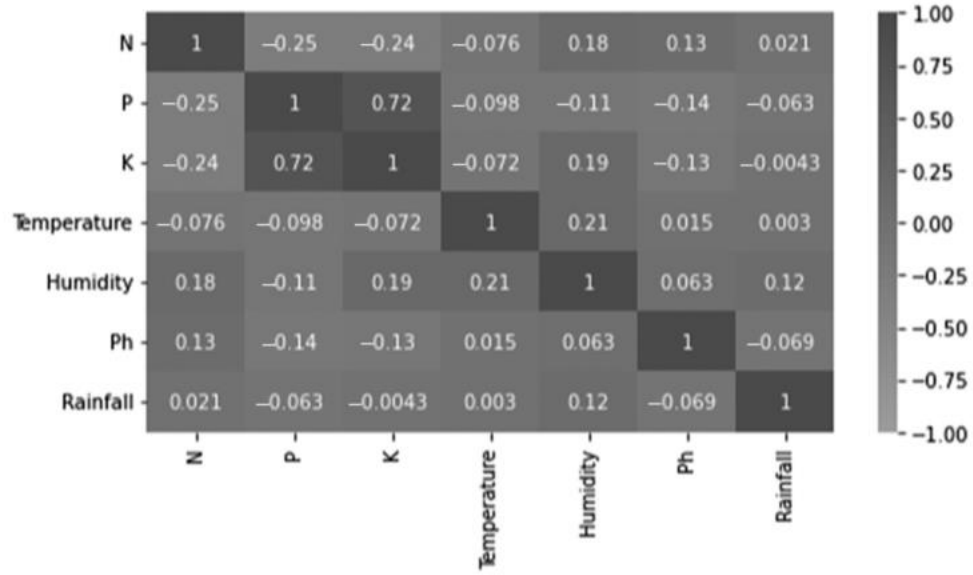
Trực quan hóa dữ liệu đóng một vai trò quan trọng trong việc đơn giản hóa thông tin phức tạp và làm cho nó dễ hiểu. Để đánh giá mối tương quan giữa các đặc trưng khác nhau, một biểu đồ nhiệt đã được sử dụng. Biểu đồ nhiệt chỉ ra mối tương quan dương đáng kể giữa phốt pho (P) và kali (K) đồng thời tiết lộ mối tương quan âm giữa phốt pho

(P) và lượng mưa, độ pH và kali (K), và nitơ (N) và nhiệt độ, như được trình bày trong Hình 5.2. [Ghi chú của người dịch: Có sự nhầm lẫn trong văn bản gốc. Văn bản nói "Figure 5.2" cho biểu đồ nhiệt, nhưng chú thích Hình 5.2 là biểu đồ cột. Chú thích Hình 5.3 là "Heat map". Tôi sẽ dịch theo chú thích của hình ảnh.]

"Phân tích đơn biến." Sau khi hiểu được các mối tương quan giữa các đặc trưng, dữ liệu này trở thành công cụ để đưa ra các quyết định sáng suốt để lựa chọn loại cây trồng phù hợp nhất. Tiếp theo phân tích đơn biến bằng biểu đồ cột giúp xác định các thông số cụ thể cần thiết cho loại cây trồng cụ thể, như được mô tả trong Hình 5.3. [Ghi chú của người dịch: Văn bản lại tham chiếu Hình 5.3 cho biểu đồ cột. Tôi sẽ dịch theo chú thích của hình ảnh.]



HÌNH 5.2: Lượng mưa so với Cây trồng tốt nhất. *(Biểu đồ cột thể hiện yêu cầu về lượng mưa cho các loại cây trồng khác nhau)*



HÌNH 5.3: Biểu đồ nhiệt. *(Ma trận tương quan cho thấy mối quan hệ giữa các đặc trưng: N, P, K, Nhiệt độ, Độ ẩm, Ph, Lượng mưa)*

5.3.4 Làm sạch dữ liệu

Trong lĩnh vực ML, làm sạch dữ liệu (DC) là một bước thiết yếu và cần thiết trước quá trình lập mô hình. Phương pháp này liên quan đến việc xác định và sửa chữa các lỗi, sự khác biệt và không chính xác có trong bộ dữ liệu. Quá trình này bao gồm các nhiệm vụ khác nhau, bao gồm giải quyết các giá trị bị thiếu, loại bỏ các bản sao, chuẩn hóa các định dạng dữ liệu và xử lý các giá trị ngoại lai. Tuân thủ bước này là điều cần thiết; nếu không, nó có thể dẫn đến việc tạo ra một mô hình không chính xác [13]. Cho phép mô hình học hỏi từ dữ liệu thích hợp hoặc có liên quan cuối cùng dẫn đến kết quả phân loại tốt hơn [14]. Sau khi hợp nhất các bộ dữ liệu [12], một vài mục nhập null có trong dữ liệu đã được loại bỏ.

5.3.4.1 Xử lý ngoại lai

Một trong những phần chính của tiền xử lý dữ liệu là xử lý ngoại lai và nhiễu: lỗi trong thu thập dữ liệu, lỗi trong quá trình nhập dữ liệu, mã hóa không xác định, dữ liệu không nhất quán, định dạng không nhất quán, v.v., tương ứng với các loại nhiễu và ngoại lai khác nhau [15]. Điều rất quan trọng là phải xử lý nó trước khi lập mô hình, vì nó ảnh hưởng đến phân tích thống kê và quá trình huấn luyện của các thuật toán ML, dẫn đến độ chính xác thấp hơn. Có nhiều kỹ thuật trực quan và toán học khác nhau mà chúng ta có thể phát hiện và loại bỏ các giá trị ngoại lai, chẳng hạn như biểu đồ hộp (boxplots), điểm z (z-scores), và khoảng tứ phân vị (IQR). Trong mô hình được đề xuất, các giá trị ngoại lai đã được phát hiện bằng IQR và được xử lý bằng kỹ thuật giới hạn (capping).

5.3.4.2 Co giãn đặc trưng (Feature Scaling)

Trong quá trình tiền xử lý, co giãn đặc trưng (FS) cũng được coi là một trong những bước quan trọng. Điều quan trọng là đưa tất cả các đặc trưng về cùng một thang đo để cho phép mô hình học hỏi từ tất cả các đặc trưng một cách bình đẳng mà không dẫn đến thiên vị (bias). FS cũng giúp các thuật toán đạt được hàm chi phí tối thiểu. Co giãn đóng một vai trò rất quan trọng trong việc làm cho mô hình ML trở thành một mô hình yếu hoặc một mô hình tốt hơn [16]. FS đạt được bằng cách áp dụng các phương pháp như chuẩn hóa (normalization) và tiêu chuẩn hóa (standardization). Trong nghiên cứu này, FS được thực hiện bằng phương pháp chuẩn hóa, như được mô tả trong Phương trình (5.1) [16].

$$X_{nom} = \frac{X - min(X)}{max(X) - min(X)} \quad (5.1)$$

5.3.5 Xây dựng mô hình

Các bước cơ bản của việc xây dựng một mô hình ML như sau:

i. Lựa chọn mô hình ML ii. Khớp (Fitting) mô hình ML iii. Xác thực (Validating) mô hình ML

Lựa chọn một mô hình ML là quá trình trong đó một mô hình ML duy nhất được chọn ra từ các ứng cử viên khả dĩ khác nhau để huấn luyện một bộ dữ liệu [17]. Khớp một mô hình ML liên quan đến việc huấn luyện nó trên một bộ dữ liệu để tìm ra các tham số tốt nhất nắm bắt được các mẫu trong dữ liệu. Các tham số của mô hình được điều chỉnh để giảm thiểu sự khác biệt giữa các giá trị dự đoán và giá trị thực tế, nhằm tạo ra một công cụ dự đoán chính xác cho dữ liệu mới. Chức năng của một mô hình ML để dự đoán các giá trị và thực hiện phân loại đạt được bằng cách tổng quát hóa mô hình cho các bộ dữ liệu mới [18].

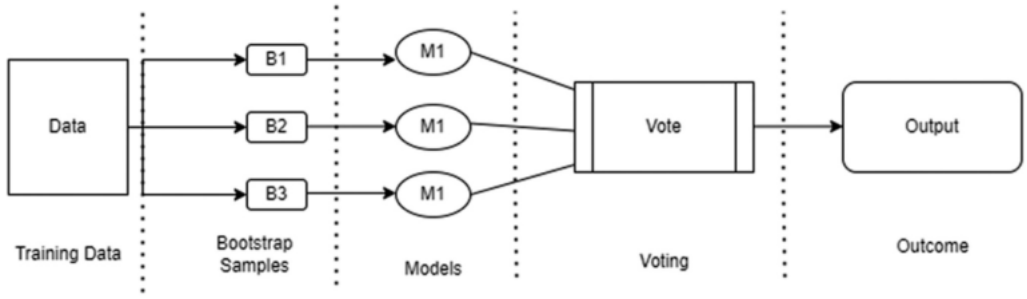
Xác thực một mô hình ML là một quá trình quan trọng và cần thiết được thực hiện sau khi huấn luyện một mô hình, nơi mô hình đã được huấn luyện được đánh giá bằng dữ liệu kiểm tra. Xác thực kết quả của mô hình ML là cần thiết để đảm bảo độ chính xác của nó [18].

5.3.5.1 Các phương pháp

Kỹ thuật được đề xuất trong nghiên cứu này là kỹ thuật ensemble (ET). Mục đích chính của việc sử dụng ET trong nghiên cứu này là để khắc phục các vấn đề của mô hình hóa đơn giản của một bộ phân loại và để đạt được độ chính xác tốt hơn [17]. ET liên quan đến việc tích hợp nhiều bộ học cơ sở, trong đó mỗi bộ học cơ sở đóng góp vào kết quả dẫn đến mức độ chính xác cao nhất và giảm lỗi dự đoán. ET đặc biệt được sử dụng để giúp giải quyết các vấn đề ra quyết định.

Một loại ET là bagging, tuân theo quy trình lấy mẫu con dữ liệu huấn luyện để cải thiện kết quả của một loại bộ phân loại duy nhất. Phương pháp được sử dụng để lấy mẫu con dữ liệu là bootstrapping. Quá trình bootstrapping liên quan đến việc lấy các mẫu có thay

thế từ một bộ dữ liệu và tính toán một thống kê (trung bình, trung vị) cho mỗi mẫu. Vì vậy, quá trình này giúp có được sự phân phối kết quả cho các thống kê quan tâm mà chúng ta có thể ước tính các sai số chuẩn và khoảng tin cậy, điều này cuối cùng dẫn đến việc có được một ước tính ít thiên vị hơn. Đầu ra tập hợp dự đoán của mọi bộ học, và với sự trợ giúp của bỏ phiếu theo đa số, đầu ra mong muốn đạt được [19]. Hình 5.4 mô tả kỹ thuật ET được sử dụng.



HÌNH 5.4: Kỹ thuật Bagging. *(Sơ đồ quy trình: Dữ liệu (Data) -> Các mẫu Bootstrap (Bootstrap Samples) -> Các mô hình (Models) -> Bỏ phiếu (Voting) -> Đầu ra (Output))*

5.3.5.2 Kỹ thuật

Mô hình đầu tiên được sử dụng trong nghiên cứu này là DT (Cây quyết định). Lý do chính để chọn thuật toán này là nó có thể xử lý các loại dữ liệu khác nhau và không yêu cầu nhiều tiền xử lý dữ liệu [20]. Hầu hết, DT được sử dụng cho các tác vụ phân loại vì DT mô phỏng tư duy cấp độ con người, cung cấp một cách đơn giản để phân tích dữ liệu và rút ra các diễn giải có ý nghĩa. Mô hình này liên quan đến việc xây dựng một cấu trúc giống như cây cho toàn bộ bộ dữ liệu và xử lý một kết quả duy nhất tại mỗi nút lá [21]. Các vấn đề liên quan đến việc chỉ huấn luyện một DT có thể được giải quyết bằng cách sử dụng mô hình bagging của DT, dẫn đến đạt được độ chính xác tốt hơn.

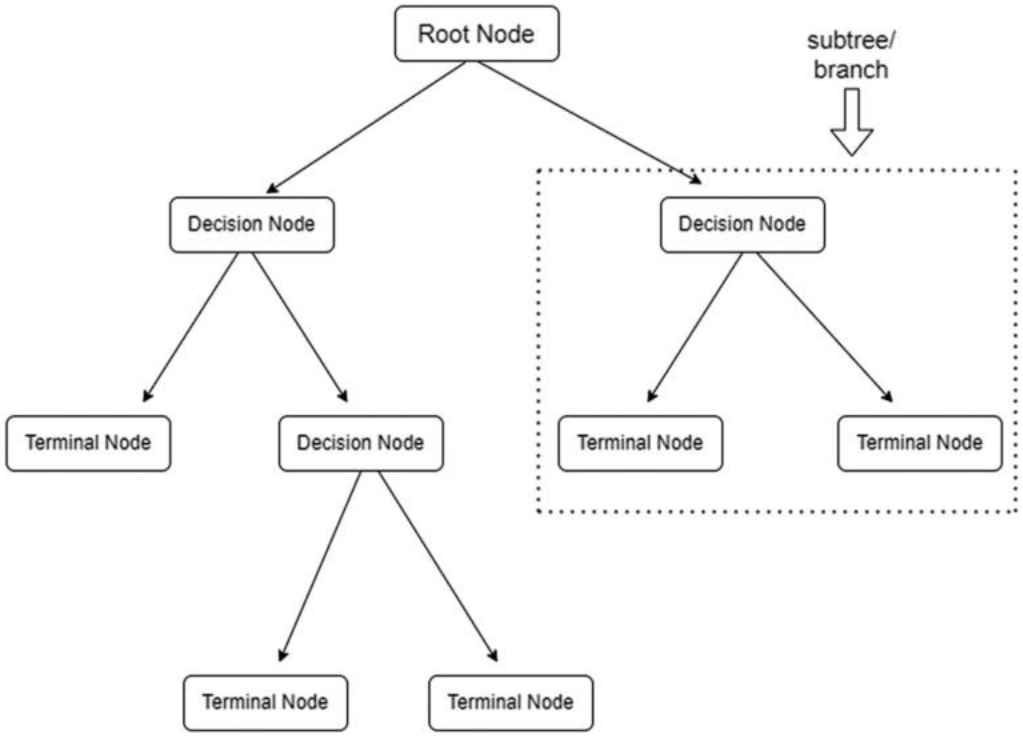
Học sâu được sử dụng rộng rãi trong các hệ thống khuyến nghị để tăng cường dữ liệu thưa thớt và khả năng mở rộng của phương pháp. Điều này đo lường sự cải thiện về chất lượng của kết quả khuyến nghị.

Mô hình thứ hai được huấn luyện trong nghiên cứu này là Mạng nơ-ron (NN). Tiêu chí chính để chọn thuật toán này là nó thực hiện một công việc kỳ diệu là làm cho máy móc có thể đưa ra quyết định tương tự như não người và do đó dẫn đến các dự đoán tốt hơn bằng cách hiểu mối quan hệ phức tạp giữa dữ liệu đầu vào và đầu ra [22]. Trong nghiên cứu này, một mô hình bagging đồng nhất đã được xây dựng.

5.3.5.2.1 Cây quyết định

Thuật toán DT là một phương pháp học có giám sát đơn giản cũng như đầy đủ, trong đó các điểm mẫu được phân chia liên tục tùy thuộc vào một số tham số. Các thành phần của DT bao gồm nút gốc, một số nhánh và các nút lá. Các nút bên trong trong cây cấu trúc cung cấp các mô tả liên quan đến các kịch bản kiểm tra khác nhau. Thuật toán này có thể

được hình dung như một cấu trúc đồ họa giống như cây dự đoán đầu ra bằng cách sử dụng một loạt các yếu tố chuyên biệt [21].



HÌNH 5.5: Cây quyết định. *(Sơ đồ cấu trúc của một cây quyết định, bao gồm Nút gốc (Root Node), Nút quyết định (Decision Node), và Nút cuối/Lá (Terminal Node))*

Hình 5.5 mô tả kỹ thuật đầu tiên. Hoạt động của DT được minh họa trong Thuật toán 5.1.

Giả sử S là một tập hợp các mẫu huấn luyện, mỗi mẫu đều có nhãn lớp đã biết. Một đặc trưng được sử dụng để quyết định lớp của các mẫu huấn luyện. Giả sử có n lớp. Đối với $I = 1, \dots n$ giả sử S bao gồm các mẫu s_i của lớp C_i cho $I = 1, \dots n$. Một mẫu ngẫu nhiên có xác suất là s_i/s rằng nó thuộc về lớp C_i , trong đó s là số lượng tổng số mẫu trong tập hợp S. Thông tin dự kiến cần thiết để phân loại một mẫu đã cho [3] được biểu diễn trong Phương trình (5.2) [3].

$$I(S, S, \dots, S_n) = -\sum_{i=1}^{n} \frac{S_i}{s} log \frac{S_i}{s} \text{ (5.2)}$$

Đặc trưng B với các giá trị $\left{b_{1},b_{2},...,b_{v}\right}$ có thể được sử dụng để chia S thành các tập con $\left{S_{1},S_{2},...,S_{v}\right}$, trong đó S_j bao gồm các mẫu trong S có giá trị b_j của B. Giả sử S_j bao gồm s_{ij} ví dụ của lớp C_i . Entropy của B là thông tin dự kiến dựa trên phép chia này bởi B. Nó là trung bình có trọng số được biểu diễn trong Phương trình (5.3) [3]:

THUẬT TOÁN 5.1: CÂY QUYẾT ĐỊNH

Đầu vào - Dữ liệu có giám sát của N trường hợp Với mỗi mẫu trong bộ dữ liệu: 1: Kiểm tra từng kịch bản cơ sở. 2: Đối với mỗi đặc trưng b: đánh giá thông tin chuẩn hóa 3: thu được từ việc phân chia trên b. 4: Đặt b_best là đặc trưng có lợi ích thông tin chuẩn hóa cao hơn. 5: Xây dựng một nút quyết định phân chia trên b_best. 6: Đệ quy trên cây con thu được bằng cách phân chia trên b_best, và thêm 7: các nút đó làm nút lá. **Trả về** Bộ phân loại

$$E(B) = \sum_{j=1}^{v} \frac{S^1 j + \ldots + S_n j}{S} I(Sj + \ldots + S_n j) \text{ (5.3)}$$

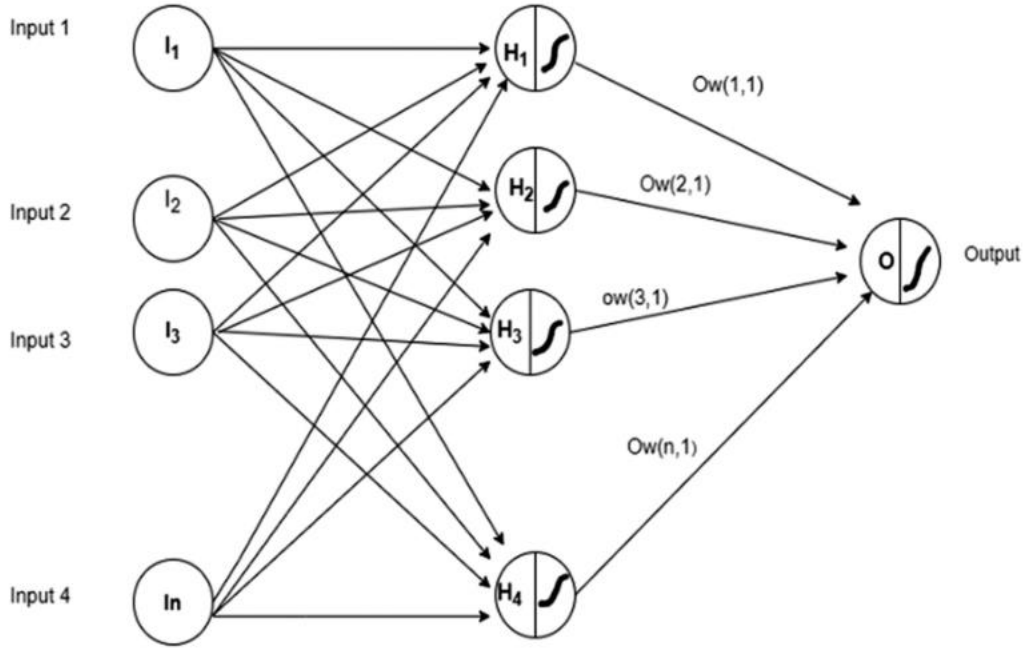
Việc phân vùng trên B này dẫn đến một lợi ích thông tin được biểu diễn trong Phương trình (5.4) [3].

$$Gain(B) = I(s, s, \ldots, S_n) - E(B) \text{ (5.4)}$$

Để phân tích mức độ liên quan, lợi ích thông tin được tính toán cho mọi thuộc tính có trong mẫu S. Thuộc tính thể hiện lợi ích thông tin lớn nhất được coi là đặc trưng phân biệt nhất trong tập hợp. Bằng cách tính toán lợi ích thông tin cho mỗi thuộc tính, một bảng xếp hạng các thuộc tính đạt được, có thể được sử dụng để phân tích mức độ liên quan để chọn các thuộc tính sẽ được sử dụng trong mô tả khái niệm.

5.3.5.2.2 Mạng nơ-ron

Mô hình toán học phi tuyến được tạo ra bằng cách mô phỏng bộ não sinh học được gọi là NN hoặc ANN. ANN có khả năng xử lý các bộ dữ liệu phi tuyến và ánh xạ chúng tới kết quả. ANN phổ biến nhất để giải quyết các bộ dữ liệu phi tuyến là perceptron đa lớp (MLP). ANN bao gồm ba lớp chính: lớp đầu vào, lớp ẩn và lớp đầu ra.



HÌNH 5.6: Mạng nơ-ron. *(Sơ đồ một mạng nơ-ron nhân tạo với các Lớp đầu vào (Input), Lớp ẩn (H1-H4), và Lớp đầu ra (Output))*

Chúng được xây dựng trên một mạng lưới các nút liên kết được gọi là nơ-ron. Sau đó, các kết nối giữa các nơ-ron này được sử dụng để gửi tín hiệu. Khi quá trình học tập tiến triển, các trọng số được gán cho các nơ-ron và kết nối được cập nhật và sửa đổi, điều này giúp tăng hiệu suất của chúng [23], như thể hiện trong Hình 5.6. NN trình bày kỹ thuật thứ hai. Hoạt động của DT [Ghi chú của người dịch: Văn bản gốc ghi là DT, nhưng đây là mục NN. Đây có thể là lỗi copy-paste] được minh họa trong Thuật toán 5.2.

Mỗi nơ-ron trong lớp nhận (lớp đầu vào) truyền thông tin và được truyền đến các nơ-ron được kết nối trong lớp ẩn. Mỗi đơn vị lớp ẩn tính toán đầu ra bằng cách cộng các tín hiệu đầu vào bị ảnh hưởng được sử dụng trong hàm kích hoạt (AF) bằng cách áp dụng Phương trình (5.5) [24].

$$h(t) = f(\Sigma x(t)W_H + B_H) \text{ (5.5)}$$

Tín hiệu đầu ra được tính bằng cách cộng tín hiệu đầu vào và AF của nó bằng Phương trình (5.6) [24].

$$O(t) = f(\Sigma h(t)Wo + Bo) \text{ (5.6)}$$

AF được sử dụng cho mỗi nơ-ron có trong mạng. Nó là một "cổng" toán học giữa lớp nhận phục vụ nơ-ron hiện tại và kết quả của nó chuyển sang lớp tiếp theo. AF có thể là tuyến tính và phi tuyến.

THUẬT TOÁN 5.2: NN (MẠNG NƠ-RON)

Đầu vào - Dữ liệu có giám sát của N trường hợp Với mỗi mẫu trong bộ dữ liệu: 1: **Khởi tạo:** Nhập mỗi hàng quan sát vào lớp đầu vào và mọi đặc trưng tại mỗi nút đầu vào. Khởi tạo các giá trị trọng số một cách ngẫu nhiên nhưng không phải là 0. 2: **Truyền xuôi:** Từ trái sang phải, tính toán và kích hoạt mỗi nút của các lớp với các trọng số kiểm soát tác động của các nơ-ron tương ứng. 3: **Tính toán chi phí:** Đo lường lỗi với giá trị dự đoán và giá trị thực tế. 4: **Lan truyền ngược và Cập nhật:** Từ phải sang trái, cập nhật các trọng số bằng thuật toán xuống dốc gradient (gradient descent) để giảm lỗi cho đến khi tối ưu hóa. 5: **Dự đoán:** Dự đoán giá trị cho dữ liệu kiểm tra. **Trả về** Bộ phân loại

Các AF phi tuyến được sử dụng trong trường hợp dữ liệu phức tạp để dự đoán kết quả. Trong số các AF, ReLU (Đơn vị tuyến tính chỉnh lưu) là một hàm kích hoạt được sử dụng đa dạng. Các đầu vào có giá trị nhỏ hơn 0 được ánh xạ thành 0 và sau đó được ánh xạ thành 1 cho các đầu vào có giá trị lớn hơn 0. Lựa chọn tốt nhất cho phân loại đa lớp là hàm Softmax, vì nó biến đổi kết quả thành một phân phối xác suất chuẩn hóa. Các kết quả của NN chuyển qua Softmax (AF) biến đổi kết quả thành các giá trị xác suất, cuối cùng được tổng hợp lại thành một. Hàm đầu ra Softmax có thể được biểu diễn trong Phương trình (5.7) [24]:

$\sigma = \frac{e^{z_k}}{\sum_{j=1} e^{z_j}}$ (5.7)

Trong NN truyền thẳng, lan truyền ngược là thuật toán được sử dụng thường xuyên nhất để huấn luyện NN đa lớp, trong đó các tín hiệu từ lớp đầu vào được truyền về phía trước, và các lỗi được truyền ngược lại để thay đổi các trọng số sao cho giảm thiểu lỗi đầu ra. Quá trình này được sao chép trong quá trình huấn luyện, và mỗi lần lặp được gọi là một epoch.

Việc tính toán lỗi trong một thuật toán lan truyền ngược được trình bày trong Phương trình (5.8) [24].

$E = \frac{1}{2}\Sigma(t_k - O_k)^2$ (5.8)

Mỗi trọng số được điều kiện hóa lại như được biểu diễn trong Phương trình (5.9) [25]:

$wi = wi + \Delta wi,$ (5.9)

trong đó Δwi là yếu tố điều chỉnh được tính toán như được biểu diễn trong Phương trình (5.10) [25].

$\Delta wi = \eta \delta j x_{ij}$ (5.10)

5.3.6 Đánh giá mô hình

Quá trình đánh giá hiệu suất của một mô hình được gọi là đánh giá mô hình. Vì dự đoán cây trồng tốt nhất là một công việc liên quan đến phân loại đa lớp, có bốn kết quả có thể xảy ra, tức là, Âm tính thật (TN), Dương tính thật (TP), Âm tính giả (FN), và Dương tính giả (FP) [25].

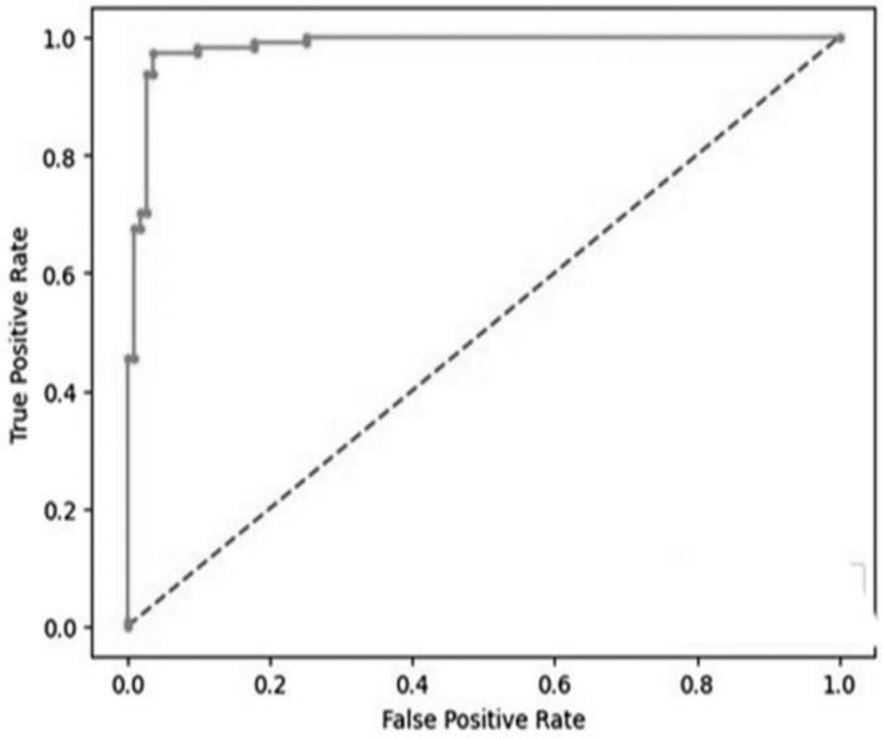
Để đánh giá hiệu suất của một mô hình, các số liệu khác nhau đã được sử dụng - tức là, độ chính xác (accuracy), độ đặc hiệu (specificity), độ nhạy (sensitivity), và diện tích dưới đường cong đặc trưng hoạt động của máy thu (AUROC) [26]. Các số liệu này được định nghĩa theo các kết quả nói trên. Để đánh giá sự ổn định và tính linh hoạt của hệ thống được đề xuất, một phương pháp đã được sử dụng để xác thực mô hình, được gọi là kiểm định chéo K-lần (KFCV). Các thước đo được sử dụng được định nghĩa như sau.

- Độ chính xác (Acc) = $\frac{TP+TN}{TP+TN+FP+FN}$
- Độ nhạy (Sens) = $\frac{TP}{TP+FP}$
- Độ đặc hiệu (Spec) = $\frac{TP}{TP+FN}$
- Điểm F1 = $\frac{2*Precision*Recall}{Precision+Recall}$

5.3.6.1 Đường cong AUROC

Một thống kê đánh giá thiết yếu cho các vấn đề phân loại là đường cong AUROC. Đường cong AUROC là một số liệu đánh giá quan trọng được sử dụng để đánh giá hiệu suất của

một vấn đề phân loại đa lớp. Nó được sử dụng rộng rãi để kiểm tra và trực quan hóa mức độ hoạt động tốt của một mô hình phân loại. Đường cong phân biệt thành công giữa nhiễu và tín hiệu bằng cách vẽ Tỷ lệ dương tính thật (TPR) so với Tỷ lệ dương tính giả (FPR) ở các mức khác nhau. Trong số các giá trị, giá trị hiện diện ở phía trên bên trái của đường cong được coi là giá trị tối ưu. Hình 5.7 cho thấy đường cong AUROC [26].



HÌNH 5.7: Đường cong AUROC. *(Biểu đồ đường cong AUROC, với Tỷ lệ dương tính thật (True Positive Rate) trên trục y và Tỷ lệ dương tính giả (False Positive Rate) trên trục x)*

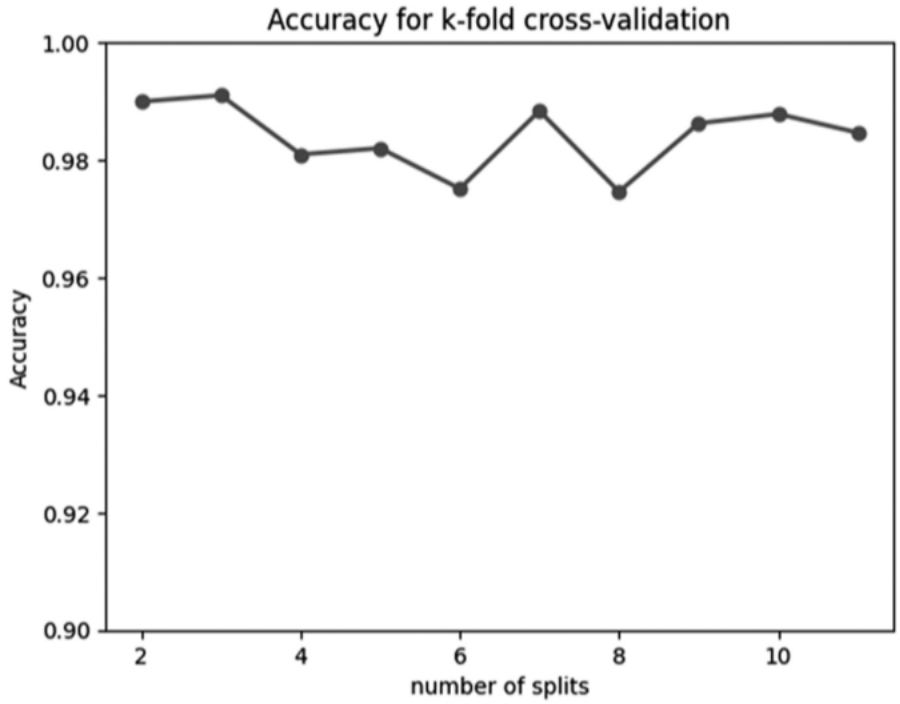
5.3.6.2 Kiểm định chéo K-lần

Quá trình đánh giá các mô hình ML trên các mẫu dữ liệu nhỏ được gọi là kiểm định chéo. Kỹ thuật này sử dụng một tham số gọi là k, xác định số lượng nhóm mà dữ liệu đã được chia. Đối với mỗi lần lặp, k-1 mẫu con được sử dụng để huấn luyện mô hình, và phần còn lại được sử dụng để đánh giá hiệu suất của mô hình. Cuối cùng, các kết quả từ k-lần lặp được cộng lại, và độ chính xác trung bình của mô hình được tạo ra từ kết quả trung bình, như thể hiện trong Bảng 5.2 [27].

BẢNG 5.2: Các thông số đánh giá

Thuật toán phân loại	Độ chính xác (%)	Độ chuẩn xác (Precision)	Độ phủ (Recall)	Điểm F1
Cây quyết định	0.98	0.96	0.98	0.96

Thuật toán phân loại	Độ chính xác (%)	Độ chuẩn xác (Precision)	Độ phủ (Recall)	Điểm F1
Cây quyết định Bagging	0.99	0.98	0.98	0.98
Mạng nơ-ron	0.96	0.97	0.97	0.97
Mạng nơ-ron Bagging	0.99	0.98	0.98	0.98



HÌNH 5.8: KFCV (Kiểm định chéo K-lần). *(Biểu đồ đường thể hiện Độ chính xác (Accuracy) so với số lần chia (number of splits) trong kiểm định chéo k-lần)*

Hình 5.8 mô tả độ chính xác đạt được trong mỗi lần lặp của kỹ thuật KFCV.

5.4 KẾT QUẢ

Trong hệ thống được đề xuất, kết quả của mô hình được giải thích liên quan đến các tham số đánh giá. Để phân tích hiệu quả của hệ thống, dữ liệu KFCV cũng được cung cấp [28-32]. Mô hình đạt được độ chính xác, độ nhạy và độ đặc hiệu lần lượt là 0,99, 0,98 và 0,98, và giá trị AUROC là 0,998, được coi là một trong những kết quả tốt. Một thước đo khác để kiểm tra tính xác thực của mô hình, kiểm định chéo chín lần, đã được thực hiện. Bộ dữ liệu được chia thành chín phần, tám trong số đó được sử dụng để huấn luyện mô hình ML, và phần còn lại được dành để đánh giá mô hình.

5.5 KẾT LUẬN

Cho đến nay, năng suất thu được từ sản xuất cây trồng là không đủ do hiểu biết không đầy đủ về các yếu tố ảnh hưởng đến sản xuất và sự phụ thuộc vào các phương pháp canh tác truyền thống. Hệ thống khuyến nghị dựa trên học ensemble sẽ giúp cộng đồng nông nghiệp khắc phục những thách thức tương ứng liên quan. Cuối cùng, điều này sẽ góp phần tăng sản lượng cây trồng, dẫn đến năng suất cao hơn. Mô hình được đề xuất đạt được độ nhạy, độ đặc hiệu, độ chính xác và AUROC lần lượt là 0,98, 0,98, 0,99 và 0,998. Trong số các mô hình được đề xuất, các mô hình ensemble hoạt động tốt hơn hai mô hình phân loại đơn lẻ khác [33-37]. Mô hình được đề xuất sẽ tiết kiệm công sức của các nhà nông học cần thiết để chọn cây trồng tốt nhất, tự động dẫn đến năng suất cao hơn. Tuy nhiên, điều liên quan là chỉ ra rằng mô hình này dựa trên các tham số hữu hạn. Tuy nhiên, có một số vấn đề có thể được giải quyết trong tương lai, chẳng hạn như xem xét các tham số khác để huấn luyện mô hình và tinh chỉnh các tham số khác của các mô hình được đề xuất.

TÀI LIỆU THAM KHẢO

[1] Z. Doshi, S. Nadkarni, R. Agrawal and N. Shah, “AgroConsultant: Intelligent Crop Recommendation System Using Machine Learning Algorithms,” 2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA), Pune, India, 2018, pp. 1-6. doi: 10.1109/ICCUBEA.2018.8697349

[2] Why is topography important in agriculture. n.d. Retrieved January 23, 2023, from https://geopard.tech/blog/topography-and-nutrition-content-in-soil-and-yield/

[3] S. Veenadhari, B. Misra and C. Singh, “Machine Learning Approach for Forecasting Crop Yield Based on Climatic Parameters,” 2014 International Conference on Computer Communication and Informatics, Coimbatore, India, 2014, pp. 1-5. doi: 10.1109/ICCCI.2014.6921718

[4] A. Sharma, A. Jain, P. Gupta and V. Chowdary, “Machine Learning Applications for Precision Agriculture: A Comprehensive Review,” IEEE Access, vol. 9, pp. 4843-4873, 2021. doi: 10.1109/ACCESS.2020.3048415

[5] 2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA). n.d.

[6] S. M. Pande, P. K. Ramesh, A. Anmol, B. R. Aishwarya, K. Rohilla and K. Shaurya, “Crop Recommender System Using Machine Learning Approach,” 2021 5th International Conference on Computing Methodologies and Communication (ICCMC), Erode, India, 2021, pp. 1066-1071. doi: 10.1109/ICCMC51019.2021.9418351

[7] R. Kumar, M. P. Singh, P. Kumar and J. P. Singh, “Crop Selection Method to Maximize Crop Yield Rate Using Machine Learning Technique, 2015 International Conference on Smart Technologies and Management for Computing, Communication,

Controls, Energy and Materials (ICSTM), Avadi, India, 2015, pp. 138-145. doi: 10.1109/ICSTM. 2015.7225403

[8] R. K. Rajak, A. Pawar, M. Pendke, P. Shinde, S. Rathod and A. Devare,"Crop Recommendation System to Maximize Crop Yield using Machine Learning Technique" International Research Journal of Engineering and Technology, vol. 4, 2017. Retrieved from www.irjet.net

[9] A. Savla, P. Dhawan, H. Bhadada, N. Israni, A. Mandholia and S. Bhardwaj, "Survey of Classification Algorithms for Formulating Yield Prediction Accuracy in Precision Agriculture," Innovations in Information, Embedded and Communication systems (ICIIECS), 2015.

[10] A. T. M. Shakil Ahamed, N. T. Mahmood, N. Hossain, M. T. Kabir, K. Das, F. Rahman and R. M. Rahman, "Applying Data Mining Techniques to Predict Annual Yield of Major Crops and Recommend Planting Different Crops in Different Districts in Bangladesh," (SNPD) IEEE/ACIS International, 2015.

[11] G. Suresh, A. Senthil Kumar, S. Lekashri and R. Manikandan, "Efficient Crop Yield Recommendation System Using Machine Learning For Digital Farming" International Journal of Modern Agriculture, vol. 10, no. 1, pp. 906-914, 2021.

[12] Crop Recommendation Dataset Kaggle. n.d. Retrieved January 23, 2023, from https://www.kaggle.com/datasets/atharvaingle/crop-recommendation-dataset

[13] S. Krishnan, M. J. Franklin, K. Goldberg, J. Wang and E. Wu, "ActiveClean: An Interact Data Cleaning Framework for Modern Machine Learning," Proceedings of the ACM SIGMOD International Conference on Management of Data, 26-June-2016, pp. 2117-2120. doi: 10.1145/2882903.2899409

[14] P. Li, X. Rao, J. Blase, Y. Zhang, X. Chu and C. Zhang, "CleanML: A Study for Evaluating the Impact of Data Cleaning on ML Classification Tasks," Proceedings International Conference on Data Engineering, April-2021, pp. 13-24. doi: 10.1109/ ICDE51399.2021.00009

[15] C. M. Salgado, C. Azevedo, H. Proença and S. M. Vieira, "Noise versus Outliers," in MIT Critical Data (ed) Secondary Analysis of Electronic Health Records, Springer, Cham (CH), 2016. PMID: 31314268.

[16] I. Izonin, R. Tkachenko, N. Shakhovska, B. Ilchyshyn and K. K. Singh, "A Two-Step Data Normalization Approach for Improving Classification Accuracy in the Medical Diagnosis Domain," Mathematics, vol. 10, no. 11, 1942, 2022.

[17] Why Use Ensemble Learning? - Machine LearningMastery.com. n.d. Retrieved October 5, 2023, from https://machinelearningmastery.com/why-use-ensemble-learning/

[18] Ensemble Learning Methods: Bagging, Boosting and Stacking. n.d. Retrieved October 5, 2023, from https://www.analyticsvidhya.com/blog/2023/01/ensemble-learning-methods-bagging-boosting-and-stacking/

[19] I. D. Mienye and Y. Sun, "A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects," IEEE Access, vol. 10, pp. 99129-99149, 2022.

[20] P. Yadav, Decision Tree in Machine Learning. Towards Data Science. n.d. Retrieved March 1, 2023, from https://towardsdatascience.com/decision-tree-in-machine-learning-e380942a4c96

[21] H. H. Patel and P. Prajapati, "Study and Analysis of Decision Tree Based Classification Algorithms," International Journal of Computer Sciences and Engineering, vol. 6, no. 10, pp. 74-78, 2018.

[22] P. Picton and P. Picton, What Is a Neural Network? Macmillan Education UK, pp. 1-12, 1994.

[23] A. D. Dongare, R. R. Kharde and A. D. Kachare, "Introduction to Artificial Neural Network," International Journal of Engineering and Innovative Technology (IJEIT), vol. 2, no. 1, pp. 189-194, 2012.

[24] J. Madhuri and M. Indiramma, "Artificial Neural Networks Based Integrated Crop Recommendation System Using Soil and Climatic Parameters," Indian Journal of Science And Technology Conference, 2021. doi: 10.17485/IJST/v14i19.64

[25] Domino Data Science Dictionary. What Is Model Evaluation? n.d. Retrieved March 4, 2023, from https://www.dominodatalab.com/data-science-dictionary/model-evaluation

[26] S. Narkhede, "Understanding AUC-ROC Curve," Towards Data Science, vol. 26, no. 1, pp. 220-227, 2018.

[27] A Gentle Introduction to k-Fold Cross-Validation Machine LearningMastery.com. n.d. Retrieved March 4, 2023, from https://machinelearningmastery.com/k-fold-cross-validation/

[28] S. N. H. Bukhari, J. Webber and A. Mehbodniya, "Decision Tree Based Ensemble Machine Learning Model for the Prediction of Zika Virus T-Cell Epitopes as Potential Vaccine Candidates," Scientific Reports, vol. 12, 7810, 2022, doi: 10.1038/ s41598-022-11731-6

[29] G. S. Raghavendra, S. S. C. Mary, P. B. Acharjee, V. L. Varun, S. N. H. Bukhari, C. Dutta and I. A. Samori, "An Empirical Investigation in Analysing the Critical Factors of Artificial Intelligence in Influencing the Food Processing Industry: A Multivariate Analysis of Variance (MANOVA) Approach," Journal of Food Quality, vol. 2022, Article ID 2197717, 7 pages, 2022. doi: 10.1155/2022/2197717

[30] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya and J. Webber, “Ensemble Machine Learning Model to Predict SARS-CoV-2 T-Cell Epitopes as Potential Vaccine Targets,” Diagnostics, vol. 11, no. 11, p. 1990, 2021. MDPI AG. doi: 10.3390/diagnostics11111990

[31] S. L. Bangare, D. Virmani, G. R. Karetla, P. Chaudhary, H. Kaur, S. N. H. Bukhari and S. Miah, “Forecasting the Applied Deep Learning Tools in Enhancing Food Quality for Heart Related Diseases Effectively: A Study Using Structural Equation Model Analysis,” Journal of Food Quality, vol. 2022, Article ID 6987569, 8 pages, 2022. doi: 10.1155/2022/6987569

[32] C. M. Anoruo, S. N. H. Bukhari and O. K. Nwofor, “Modeling and Spatial Characterization of Aerosols at Middle East AERONET Stations,” Theoretical and Applied Climatology, vol. 152, pp. 617-625, 2023. doi: 10.1007/s00704-023-04384-6

[33] F. Masoodi, M. Quasim, S. Bukhari, S. Dixit and S. Alam, Applications of Machine Learning and Deep Learning on Biological Data. CRC Press, 2023.

[34] S. N. H. Bukhari, A. Jain and E. Haq, “A Novel Ensemble Machine Learning Model for Prediction of Zika Virus T-Cell Epitopes,” in Gupta, D., Polkowski, Z., Khanna, A., Bhattacharyya, S., and Castillo, O. (eds) Proceedings of Data Analytics and Management. Lecture Notes on Data Engineering and Communications Technologies, vol. 91. Springer, Singapore. doi: 10.1007/978-981-16-6285-0_23

[35] S. N. H. Bukhari, F. Masoodi, M. A. Dar, N. I. Wani, A. Sajad and G. Hussain, “Prediction of Erythemato-Squamous Diseases Using Machine Learning,” in Auerbach Publications eBooks, pp. 87-96, 2023. doi: 10.1201/9781003328780-6

[36] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya and J. Webber, “Machine Learning Techniques for the Prediction of B-Cell and T-Cell Epitopes as Potential Vaccine Targets with a Specific Focus on SARS-CoV-2 Pathogen: A Review,” Pathogens, vol. 11, no. 2, p. 146, 2022. MDPI AG. doi: 10.3390/pathogens11020146

[37] S. Nisar, H. Bukhari and M. A. Dar, “Using Random Forest to Predict T-Cell Epitopes of Dengue Virus,” Advances and Applications in Mathematical Sciences, vol. 20, no. 11, pp. 2543-2547, 2021.

CHƯƠNG 5: HỆ KHUYẾN NGHỊ CÂY TRỒNG: PHƯƠNG PHÁP TÍNH TOÁN DỰA TRÊN HỌC MÁY ĐỂ ĐỀ XUẤT CÂY TRỒNG PHÙ HỢP NHẤT BẰNG CÁCH SỬ DỤNG CÁC ĐẶC ĐIỂM CỦA ĐẤT VÀ MÔI TRƯỜNG

Syed Nisar Hussain Bukhari, Jewiara Khursheed Wani, Ummer Iqbal, và Muneer Ahmad Dar *Viện Quốc gia về Điện tử và Công nghệ Thông tin (NIELIT), Srinagar, Ấn Độ*

5.1 GIỚI THIỆU

Ở nước ta, nông nghiệp là một trong những ngành kinh tế chính mà một số lượng lớn người dân phụ thuộc vào [1]. Mặc dù có sự đa dạng lớn về đặc điểm địa hình, địa mạo và các vùng khí hậu hỗ trợ nhiều loại hình canh tác khác nhau, năng suất thu được vẫn còn thấp do quản lý đồng ruộng kém và lựa chọn cây trồng sai lầm [2]. Để nuôi sống đầy đủ dân số đang tăng nhanh, điều quan trọng là phải ưu tiên tăng năng suất cây trồng một cách tương xứng. Điều này có thể được thực hiện bằng cách giải quyết các nguyên nhân cơ bản làm giảm sản lượng cây trồng, bao gồm lập kế hoạch không đầy đủ, quản lý vật nuôi yếu kém và tính chất không thể đoán trước của điều kiện thời tiết. Do hiện tượng phức tạp của sản xuất cây trồng bị ảnh hưởng bởi các thông số đầu vào khí hậu nông nghiệp, do đó các yêu cầu kỹ thuật đối với đầu vào nông nghiệp thay đổi tùy theo người nông dân và đồng ruộng [3].

Ngoài các yếu tố khác nhau ảnh hưởng đến sản xuất cây trồng, một vấn đề lớn khác mà các nhà nông học đang phải đối mặt là sự gia tăng của hiện tượng nóng lên toàn cầu. Nóng lên toàn cầu đang ở mức cao điểm dẫn đến hạn hán và các điều kiện khí hậu không thể dự đoán trước. Hơn nữa, những người nông dân làm việc theo cách truyền thống dẫn đến vấn đề quản lý đồng ruộng yếu kém và do đó ảnh hưởng đến năng suất. Theo các báo cáo, do điều kiện khí hậu không thể đoán trước trong nhiều năm, thu nhập của nông dân đã giảm 20,25% [4].

Nông nghiệp giữ một vị trí quan trọng trong tổng sản phẩm quốc nội (GDP) của Ấn Độ. Yếu tố quan trọng để đạt được năng suất cây trồng cao là lựa chọn đúng các loại cây trồng thích hợp vào đúng thời điểm trong năm. Tuy nhiên, nông dân thường dựa vào xu hướng thị trường và bản năng kế thừa từ tổ tiên, vốn đã được chứng minh là những phương pháp không hiệu quả [5]. Việc áp dụng phương pháp luận được đề xuất sẽ giúp nông dân khắc phục vấnn đề năng suất khó định lượng và đóng góp ngày càng nhiều hơn vào GDP của đất nước [6]. Việc sử dụng các thuật toán cũng sẽ hỗ trợ đạt được giải pháp hiệu quả, tiết kiệm chi phí cho những khó khăn mà nông dân phải đối mặt.

Các thuật toán được huấn luyện và kiểm tra sẽ được sử dụng để khuyến nghị cây trồng dựa trên các đầu vào khác nhau như hàm lượng Nitơ, Phốt pho, Kali (NPK) và độ pH của đất, nhiệt độ và độ ẩm của khu vực. Các loại cây trồng được dự đoán trong phương pháp luận này bao gồm ngô, bông, lúa, cà phê, đậu triều, đậu mắt đen, đay, đậu gà, dừa, đu đủ,

cam, táo, dưa lưới, dưa hấu, nho, đậu thận, chuối, lựu, đậu lăng, đậu đen, đậu xanh, và xoài.

Một số đóng góp mới chính của chương này như sau:

- Trong nghiên cứu này, một hệ thống đã được đề xuất cho phép các nhà nông học lựa chọn cây trồng chính xác dựa trên các yếu…
- Hệ thống được đề xuất có thể làm giảm các phương pháp sai lầm được áp dụng trong quá trình lựa chọn cây trồng, từ đó có thể chứng minh là hữu ích trong việc cải thiện năng suất cây trồng.
- Một hệ khuyến nghị cây trồng (CR) được thiết kế để cung cấp các khuyến nghị về loại cây trồng phù hợp nhất để trồng sẽ được phát triển.

Chương này bao gồm bốn phần. Trong phần đầu tiên, phần giới thiệu đã được trình bày, và các vấn đề khác nhau liên quan đến giảm năng suất cây trồng đã được thảo luận. Phần thứ hai trình bày các công trình liên quan đã được thực hiện trong lĩnh vực này. Kịch bản thực nghiệm đã được đề cập trong phần thứ ba, bao gồm bộ dữ liệu được sử dụng và các phương pháp được sử dụng. Kết quả đã được cung cấp trong phần thứ tư. Cuối cùng, một kết luận của nghiên cứu đã được rút ra.

5.2 CÁC CÔNG TRÌNH LIÊN QUAN

Các công trình đã hoàn thành trong lĩnh vực khuyến nghị cây trồng của các nhà nghiên cứu khác nhau được bao gồm trong phần này. Mô tả kỹ lưỡng về dự án nghiên cứu được cung cấp trong phần còn lại của mục này, và tóm tắt của mục này được đưa ra trong Bảng 5.1.

Doshi và cộng sự [1] đã phát triển Agro Consultant, một hệ thống xem xét tất cả các thuộc tính liên quan - tức là nhiệt độ, vị trí, lượng mưa và tình trạng đất - để dự đoán sự phù hợp của cây trồng bằng cách sử dụng bốn thuật toán là Cây quyết định (DT), Rừng ngẫu nhiên (RF), Mạng nơ-ron (NN) và K-láng giềng gần nhất (KNN). Nghiên cứu này cũng trình bày một trình dự đoán lượng mưa (một hệ thống thứ cấp) cho phép dự đoán sớm về lượng mưa [1]. Kumar và cộng sự [7] đã xây dựng một mô hình gọi là lựa chọn cây trồng, dựa trên các thông số như thời tiết, loại đất, mật độ nước và loại cây trồng. Phương pháp này sử dụng các mô hình như RF, máy véc-tơ hỗ trợ (SVM), DT, KNN và Rừng tham lam chính quy hóa (RGF) [7]. Kumar Rajak và cộng sự [8] đã sử dụng một phương pháp được huấn luyện trên cơ sở dữ liệu đất thu được từ một trang trại.

BẢNG 5.1: Các công trình liên quan

Tác giả	Năm	Mô tả	Thuật toán
Doshi và cộng sự	2018	Dự đoán sự phù hợp của cây trồng bằng cách sử dụng tất cả các thuộc tính liên quan (tức là nhiệt độ, lượng mưa và tình trạng	Cây quyết định, NN, RF, và KNN

Tác giả	Năm	Mô tả	Thuật toán
		đất)	
Kumar và cộng sự	2015	Lựa chọn cây trồng sử dụng các thông số loại đất, mật độ nước và loại cây trồng	RF, SVM, Cây quyết định, KNN, và RGF
Kumar Rajak và cộng sự	2017	Khuyến nghị cây trồng sử dụng bộ dữ liệu đã được xác thực để tối đa hóa năng suất cây trồng	Bagging ANN, SVM, Naive Bayes, RF
Savla và cộng sự	2015	Phân tích so sánh bằng cách sử dụng các thuật toán phân loại khác nhau, đặc biệt là trên cây đậu nành	SVM, NN, RF, Cây REP
Shakil Ahamed và cộng sự	2015	Các kỹ thuật khai phá dữ liệu đã được tiến hành cho các loại cây ngũ cốc	KNN, Hồi quy tuyến tính, ANN
Suresh và cộng sự	2021	Đã phát triển một hệ thống gọi là năng suất cây trồng hiệu quả, dự đoán sự phù hợp của cây trồng bằng cách sử dụng hai bộ dữ liệu (tức là bộ dữ liệu về cây trồng và vị trí cụ thể)	SVM

Dữ liệu được lấy sau khi thử nghiệm từ phòng thí nghiệm sau đó được cung cấp cho một hệ thống khuyến nghị dựa trên mô hình ensemble của Mạng nơ-ron nhân tạo (ANN) và SVM [8]. Savla và cộng sự [9] đã thực hiện một phân tích tương đối về các thuật toán phân loại và phân tích tỷ lệ dự đoán trong nông nghiệp chính xác. Các thuật toán được sử dụng trong nghiên cứu là RF, NN, SVM, Cây cắt tỉa lỗi giảm (REP Tree), Bagging và Bayes. Trong số các thuật toán nói trên, thuật toán bagging đã cho kết quả tốt nhất để dự đoán năng suất [9]. Shakil và cộng sự [10] đã chỉ định việc sử dụng các kỹ thuật khai phá dữ liệu có thể giúp các tổ chức chính phủ và các nhà nông học rút ra thông tin cần thiết để đưa ra kết luận tốt hơn. Điều này cuối cùng dẫn đến tăng mức sản xuất. Những kỹ thuật này được áp dụng đặc biệt để ước tính cây ngũ cốc ở Bangladesh. Các thuật toán được sử dụng trong nghiên cứu của họ bao gồm phân cụm và phân loại bằng KNN, Hồi quy tuyến tính và ANN [10]. Suresh và cộng sự [11] đã phát triển một "Hệ thống khuyến nghị năng suất cây trồng hiệu quả" dựa trên SVM nhằm nhận diện một loại cây trồng cụ thể phù hợp với dữ liệu đã cho. Hệ thống khuyến nghị một loại cây trồng cụ thể phù hợp với các giá trị thông số (NPK và pH) [11].

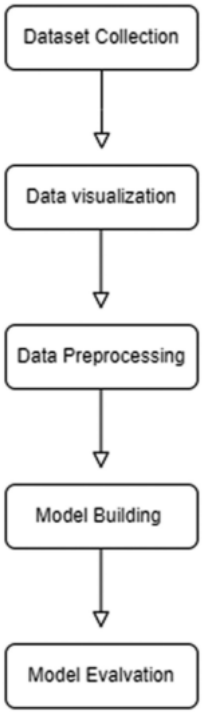
5.3 DỮ LIỆU VÀ PHƯƠNG PHÁP

5.3.1 Kịch bản thực nghiệm

Để thử nghiệm, môi trường lập trình python được áp dụng. Các mô hình bagging đã được sử dụng để thử nghiệm. Các bước của thử nghiệm được liệt kê trong Hình 5.1. Các bước được thực hiện trong nghiên cứu này như sau: thu thập bộ dữ liệu liên quan, tiền xử lý bộ dữ liệu thu được, trực quan hóa bộ dữ liệu, xây dựng mô hình ML và đánh giá mô hình đó. Dữ liệu được tiền xử lý và sau đó được đưa vào các mô hình để phân loại. Cuối cùng, phân tích so sánh giữa ensemble của các bộ phân loại đồng nhất và các bộ phân loại đơn lẻ được tiến hành.

5.3.2 Thu thập bộ dữ liệu

Dữ liệu được sử dụng cho nghiên cứu là sự kết hợp của hai bộ dữ liệu được thu thập từ Kaggle [12] là bộ dữ liệu khuyến nghị cây trồng và bộ dữ liệu agric, bao gồm 2.202 và 4.100 mẫu tương ứng. Sau khi hợp nhất các mẫu, bộ dữ liệu kết quả được chia thành các phần 7:3 để huấn luyện và kiểm tra.



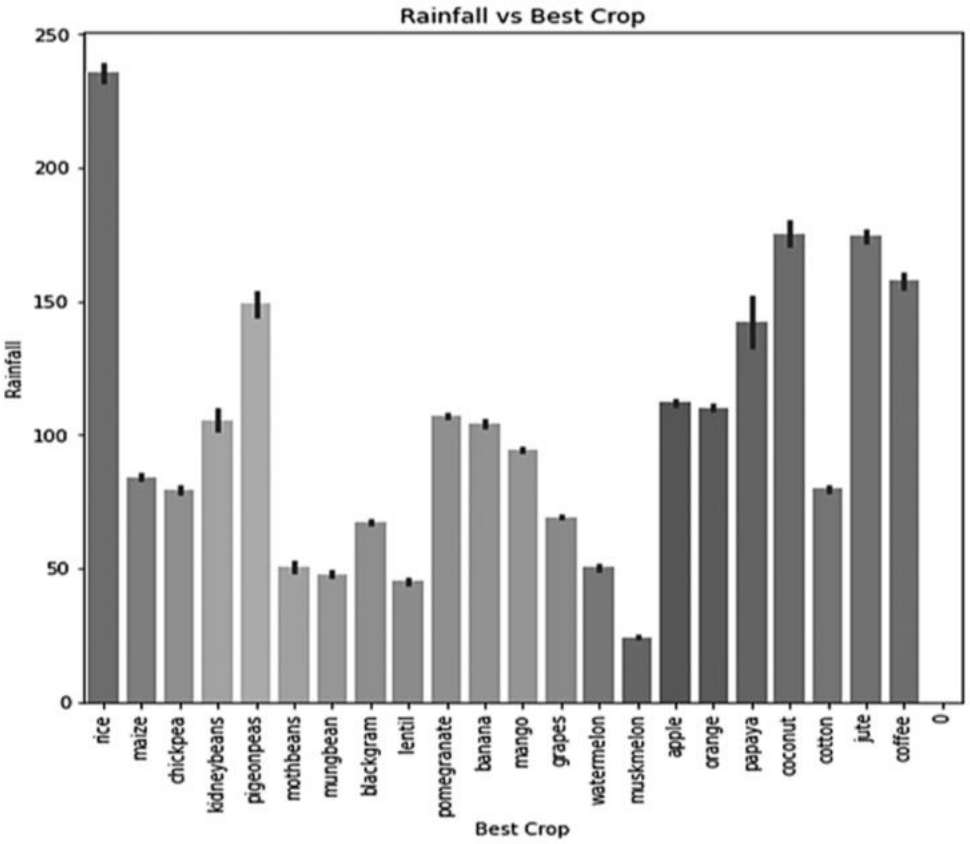
HÌNH 5.1: Các bước thực nghiệm. *(Sơ đồ quy trình)*

1. Thu thập dữ liệu (Dataset Collection)
2. Trực quan hóa dữ liệu (Data visualization)
3. Tiền xử lý dữ liệu (Data Preprocessing)
4. Xây dựng mô hình (Model Building)
5. Đánh giá mô hình (Model Evaluation)

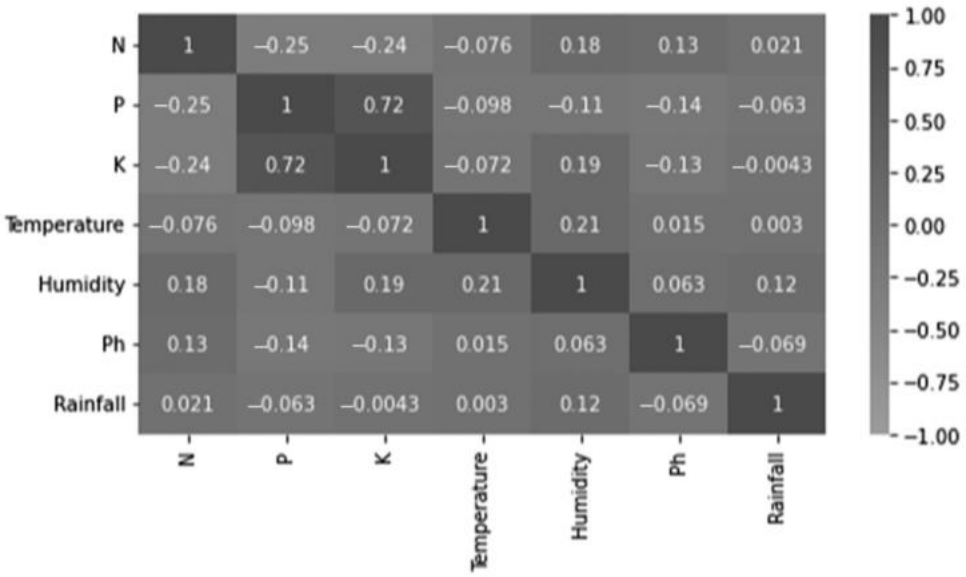
5.3.3 Trực quan hóa dữ liệu

Trực quan hóa dữ liệu đóng một vai trò quan trọng trong việc đơn giản hóa thông tin phức tạp và làm cho nó dễ hiểu. Để đánh giá mối tương quan giữa các đặc trưng khác nhau, một biểu đồ nhiệt đã được sử dụng. Biểu đồ nhiệt chỉ ra mối tương quan dương đáng kể giữa phốt pho (P) và kali (K) đồng thời tiết lộ mối tương quan âm giữa phốt pho (P) và lượng mưa, độ pH và kali (K), và nitơ (N) và nhiệt độ, như được trình bày trong Hình 5.2. [Ghi chú của người dịch: Có sự nhầm lẫn trong văn bản gốc. Văn bản nói "Figure 5.2" cho biểu đồ nhiệt, nhưng chú thích Hình 5.2 là biểu đồ cột. Chú thích Hình 5.3 là "Heat map". Tôi sẽ dịch theo chú thích của hình ảnh.]

"Phân tích đơn biến." Sau khi hiểu được các mối tương quan giữa các đặc trưng, dữ liệu này trở thành công cụ để đưa ra các quyết định sáng suốt để lựa chọn loại cây trồng phù hợp nhất. Tiếp theo phân tích đơn biến bằng biểu đồ cột giúp xác định các thông số cụ thể cần thiết cho loại cây trồng cụ thể, như được mô tả trong Hình 5.3. [Ghi chú của người dịch: Văn bản lại tham chiếu Hình 5.3 cho biểu đồ cột. Tôi sẽ dịch theo chú thích của hình ảnh.]



HÌNH 5.2: Lượng mưa so với Cây trồng tốt nhất. *(Biểu đồ cột thể hiện yêu cầu về lượng mưa cho các loại cây trồng khác nhau)*



HÌNH 5.3: Biểu đồ nhiệt. *(Ma trận tương quan cho thấy mối quan hệ giữa các đặc trưng: N, P, K, Nhiệt độ, Độ ẩm, Ph, Lượng mưa)*

5.3.4 Làm sạch dữ liệu

Trong lĩnh vực ML, làm sạch dữ liệu (DC) là một bước thiết yếu và cần thiết trước quá trình lập mô hình. Phương pháp này liên quan đến việc xác định và sửa chữa các lỗi, sự khác biệt và không chính xác có trong bộ dữ liệu. Quá trình này bao gồm các nhiệm vụ khác nhau, bao gồm giải quyết các giá trị bị thiếu, loại bỏ các bản sao, chuẩn hóa các định dạng dữ liệu và xử lý các giá trị ngoại lai. Tuân thủ bước này là điều cần thiết; nếu không, nó có thể dẫn đến việc tạo ra một mô hình không chính xác [13]. Cho phép mô hình học hỏi từ dữ liệu thích hợp hoặc có liên quan cuối cùng dẫn đến kết quả phân loại tốt hơn [14]. Sau khi hợp nhất các bộ dữ liệu [12], một vài mục nhập null có trong dữ liệu đã được loại bỏ.

5.3.4.1 Xử lý ngoại lai

Một trong những phần chính của tiền xử lý dữ liệu là xử lý ngoại lai và nhiễu: lỗi trong thu thập dữ liệu, lỗi trong quá trình nhập dữ liệu, mã hóa không xác định, dữ liệu không nhất quán, định dạng không nhất quán, v.v., tương ứng với các loại nhiễu và ngoại lai khác nhau [15]. Điều rất quan trọng là phải xử lý nó trước khi lập mô hình, vì nó ảnh hưởng đến phân tích thống kê và quá trình huấn luyện của các thuật toán ML, dẫn đến độ chính xác thấp hơn. Có nhiều kỹ thuật trực quan và toán học khác nhau mà chúng ta có thể phát hiện và loại bỏ các giá trị ngoại lai, chẳng hạn như biểu đồ hộp (boxplots), điểm z (z-scores), và khoảng tứ phân vị (IQR). Trong mô hình được đề xuất, các giá trị ngoại lai đã được phát hiện bằng IQR và được xử lý bằng kỹ thuật giới hạn (capping).

5.3.4.2 Co giãn đặc trưng (Feature Scaling)

Trong quá trình tiền xử lý, co giãn đặc trưng (FS) cũng được coi là một trong những bước quan trọng. Điều quan trọng là đưa tất cả các đặc trưng về cùng một thang đo để cho phép mô hình học hỏi từ tất cả các đặc trưng một cách bình đẳng mà không dẫn đến thiên vị (bias). FS cũng giúp các thuật toán đạt được hàm chi phí tối thiểu. Co giãn đóng một vai trò rất quan trọng trong việc làm cho mô hình ML trở thành một mô hình yếu hoặc một mô hình tốt hơn [16]. FS đạt được bằng cách áp dụng các phương pháp như chuẩn hóa (normalization) và tiêu chuẩn hóa (standardization). Trong nghiên cứu này, FS được thực hiện bằng phương pháp chuẩn hóa, như được mô tả trong Phương trình (5.1) [16].

$$X_{nom} = \frac{X - min(X)}{max(X) - min(X)} \quad (5.1)$$

5.3.5 Xây dựng mô hình

Các bước cơ bản của việc xây dựng một mô hình ML như sau:

i. Lựa chọn mô hình ML ii. Khớp (Fitting) mô hình ML iii. Xác thực (Validating) mô hình ML

Lựa chọn một mô hình ML là quá trình trong đó một mô hình ML duy nhất được chọn ra từ các ứng cử viên khả dĩ khác nhau để huấn luyện một bộ dữ liệu [17]. Khớp một mô hình ML liên quan đến việc huấn luyện nó trên một bộ dữ liệu để tìm ra các tham số tốt nhất nắm bắt được các mẫu trong dữ liệu. Các tham số của mô hình được điều chỉnh để giảm thiểu sự khác biệt giữa các giá trị dự đoán và giá trị thực tế, nhằm tạo ra một công cụ dự đoán chính xác cho dữ liệu mới. Chức năng của một mô hình ML để dự đoán các giá trị và thực hiện phân loại đạt được bằng cách tổng quát hóa mô hình cho các bộ dữ liệu mới [18].

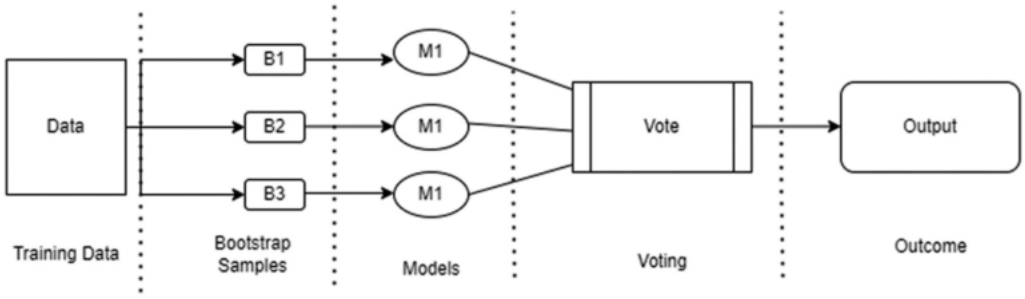
Xác thực một mô hình ML là một quá trình quan trọng và cần thiết được thực hiện sau khi huấn luyện một mô hình, nơi mô hình đã được huấn luyện được đánh giá bằng dữ liệu kiểm tra. Xác thực kết quả của mô hình ML là cần thiết để đảm bảo độ chính xác của nó [18].

5.3.5.1 Các phương pháp

Kỹ thuật được đề xuất trong nghiên cứu này là kỹ thuật ensemble (ET). Mục đích chính của việc sử dụng ET trong nghiên cứu này là để khắc phục các vấn đề của mô hình hóa đơn giản của một bộ phân loại và để đạt được độ chính xác tốt hơn [17]. ET liên quan đến việc tích hợp nhiều bộ học cơ sở, trong đó mỗi bộ học cơ sở đóng góp vào kết quả dẫn đến mức độ chính xác cao nhất và giảm lỗi dự đoán. ET đặc biệt được sử dụng để giúp giải quyết các vấn đề ra quyết định.

Một loại ET là bagging, tuân theo quy trình lấy mẫu con dữ liệu huấn luyện để cải thiện kết quả của một loại bộ phân loại duy nhất. Phương pháp được sử dụng để lấy mẫu con dữ liệu là bootstrapping. Quá trình bootstrapping liên quan đến việc lấy các mẫu có thay

thế từ một bộ dữ liệu và tính toán một thống kê (trung bình, trung vị) cho mỗi mẫu. Vì vậy, quá trình này giúp có được sự phân phối kết quả cho các thống kê quan tâm mà chúng ta có thể ước tính các sai số chuẩn và khoảng tin cậy, điều này cuối cùng dẫn đến việc có được một ước tính ít thiên vị hơn. Đầu ra tập hợp dự đoán của mọi bộ học, và với sự trợ giúp của bỏ phiếu theo đa số, đầu ra mong muốn đạt được [19]. Hình 5.4 mô tả kỹ thuật ET được sử dụng.



HÌNH 5.4: Kỹ thuật Bagging. *(Sơ đồ quy trình: Dữ liệu (Data) -> Các mẫu Bootstrap (Bootstrap Samples) -> Các mô hình (Models) -> Bỏ phiếu (Voting) -> Đầu ra (Output))*

5.3.5.2 Kỹ thuật

Mô hình đầu tiên được sử dụng trong nghiên cứu này là DT (Cây quyết định). Lý do chính để chọn thuật toán này là nó có thể xử lý các loại dữ liệu khác nhau và không yêu cầu nhiều tiền xử lý dữ liệu [20]. Hầu hết, DT được sử dụng cho các tác vụ phân loại vì DT mô phỏng tư duy cấp độ con người, cung cấp một cách đơn giản để phân tích dữ liệu và rút ra các diễn giải có ý nghĩa. Mô hình này liên quan đến việc xây dựng một cấu trúc giống như cây cho toàn bộ bộ dữ liệu và xử lý một kết quả duy nhất tại mỗi nút lá [21]. Các vấn đề liên quan đến việc chỉ huấn luyện một DT có thể được giải quyết bằng cách sử dụng mô hình bagging của DT, dẫn đến đạt được độ chính xác tốt hơn.

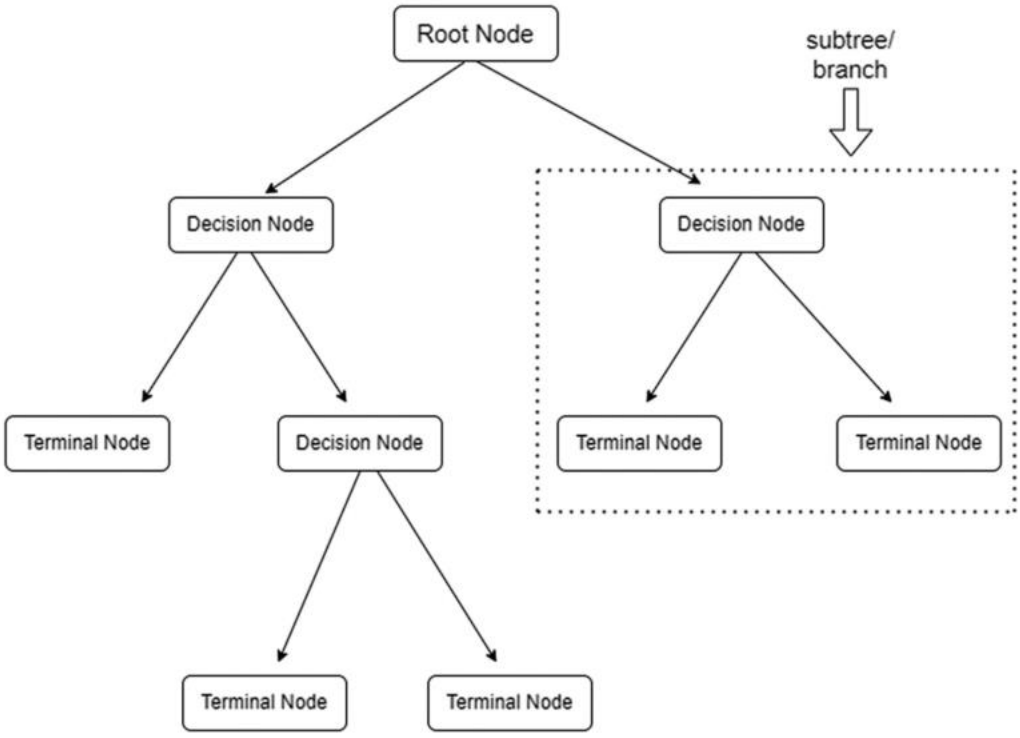
Học sâu được sử dụng rộng rãi trong các hệ thống khuyến nghị để tăng cường dữ liệu thưa thớt và khả năng mở rộng của phương pháp. Điều này đo lường sự cải thiện về chất lượng của kết quả khuyến nghị.

Mô hình thứ hai được huấn luyện trong nghiên cứu này là Mạng nơ-ron (NN). Tiêu chí chính để chọn thuật toán này là nó thực hiện một công việc kỳ diệu là làm cho máy móc có thể đưa ra quyết định tương tự như não người và do đó dẫn đến các dự đoán tốt hơn bằng cách hiểu mối quan hệ phức tạp giữa dữ liệu đầu vào và đầu ra [22]. Trong nghiên cứu này, một mô hình bagging đồng nhất đã được xây dựng.

5.3.5.2.1 Cây quyết định

Thuật toán DT là một phương pháp học có giám sát đơn giản cũng như đầy đủ, trong đó các điểm mẫu được phân chia liên tục tùy thuộc vào một số tham số. Các thành phần của DT bao gồm nút gốc, một số nhánh và các nút lá. Các nút bên trong trong cây cấu trúc cung cấp các mô tả liên quan đến các kịch bản kiểm tra khác nhau. Thuật toán này có thể

được hình dung như một cấu trúc đồ họa giống như cây dự đoán đầu ra bằng cách sử dụng một loạt các yếu tố chuyên biệt [21].



HÌNH 5.5: Cây quyết định. *(Sơ đồ cấu trúc của một cây quyết định, bao gồm Nút gốc (Root Node), Nút quyết định (Decision Node), và Nút cuối/Lá (Terminal Node))*

Hình 5.5 mô tả kỹ thuật đầu tiên. Hoạt động của DT được minh họa trong Thuật toán 5.1.

Giả sử S là một tập hợp các mẫu huấn luyện, mỗi mẫu đều có nhãn lớp đã biết. Một đặc trưng được sử dụng để quyết định lớp của các mẫu huấn luyện. Giả sử có n lớp. Đối với $I = 1, \dots n$ giả sử S bao gồm các mẫu s_i của lớp C_i cho $I = 1, \dots n$. Một mẫu ngẫu nhiên có xác suất là s_i/s rằng nó thuộc về lớp C_i , trong đó s là số lượng tổng số mẫu trong tập hợp S. Thông tin dự kiến cần thiết để phân loại một mẫu đã cho [3] được biểu diễn trong Phương trình (5.2) [3].

$$I(S, S, \dots, S_n) = -\sum_{i=1}^{n} \frac{S_i}{S} log \frac{S_i}{S} \quad (5.2)$$

Đặc trưng B với các giá trị $\left{b_{1},b_{2},...,b_{v}\right}$ có thể được sử dụng để chia S thành các tập con $\left{S_{1},S_{2},...,S_{v}\right}$, trong đó S_j bao gồm các mẫu trong S có giá trị b_j của B. Giả sử S_j bao gồm s_{ij} ví dụ của lớp C_i . Entropy của B là thông tin dự kiến dựa trên phép chia này bởi B. Nó là trung bình có trọng số được biểu diễn trong Phương trình (5.3) [3]:

THUẬT TOÁN 5.1: CÂY QUYẾT ĐỊNH

Đầu vào - Dữ liệu có giám sát của N trường hợp Với mỗi mẫu trong bộ dữ liệu: 1: Kiểm tra từng kịch bản cơ sở. 2: Đối với mỗi đặc trưng b: đánh giá thông tin chuẩn hóa 3: thu được từ việc phân chia trên b. 4: Đặt b_best là đặc trưng có lợi ích thông tin chuẩn hóa cao hơn. 5: Xây dựng một nút quyết định phân chia trên b_best. 6: Đệ quy trên cây con thu được bằng cách phân chia trên b_best, và thêm 7: các nút đó làm nút lá. **Trả về** Bộ phân loại

$$E(B) = \sum_{j=1}^{v} \frac{S^1 j + \ldots + S_n j}{S} I(Sj + \ldots + S_n j) \text{ (5.3)}$$

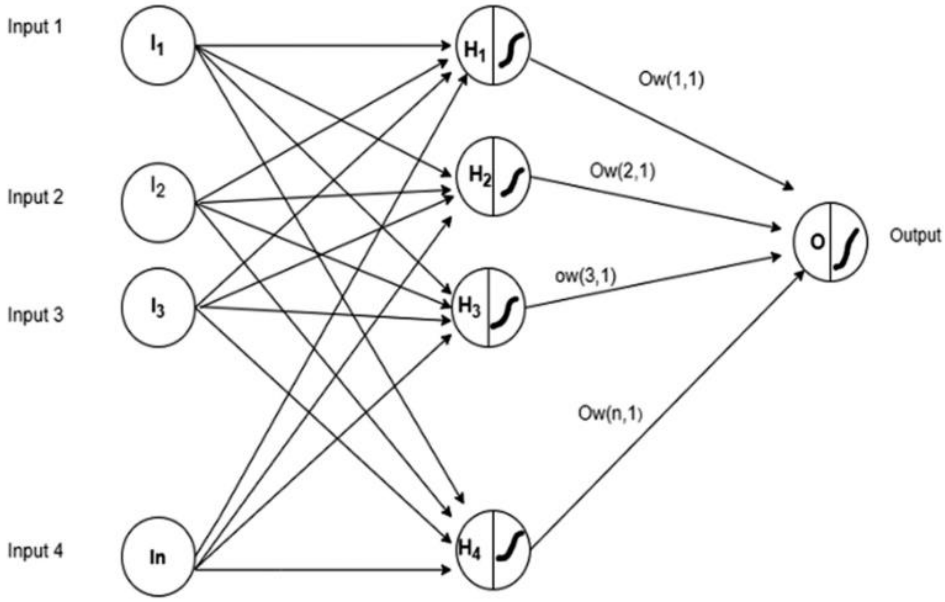
Việc phân vùng trên B này dẫn đến một lợi ích thông tin được biểu diễn trong Phương trình (5.4) [3].

$$Gain(B) = I(s, s, \ldots, S_n) - E(B) \text{ (5.4)}$$

Để phân tích mức độ liên quan, lợi ích thông tin được tính toán cho mọi thuộc tính có trong mẫu S. Thuộc tính thể hiện lợi ích thông tin lớn nhất được coi là đặc trưng phân biệt nhất trong tập hợp. Bằng cách tính toán lợi ích thông tin cho mỗi thuộc tính, một bảng xếp hạng các thuộc tính đạt được, có thể được sử dụng để phân tích mức độ liên quan để chọn các thuộc tính sẽ được sử dụng trong mô tả khái niệm.

5.3.5.2.2 Mạng nơ-ron

Mô hình toán học phi tuyến được tạo ra bằng cách mô phỏng bộ não sinh học được gọi là NN hoặc ANN. ANN có khả năng xử lý các bộ dữ liệu phi tuyến và ánh xạ chúng tới kết quả. ANN phổ biến nhất để giải quyết các bộ dữ liệu phi tuyến là perceptron đa lớp (MLP). ANN bao gồm ba lớp chính: lớp đầu vào, lớp ẩn và lớp đầu ra.



HÌNH 5.6: Mạng nơ-ron. *(Sơ đồ một mạng nơ-ron nhân tạo với các Lớp đầu vào (Input), Lớp ẩn (H1-H4), và Lớp đầu ra (Output))*

Chúng được xây dựng trên một mạng lưới các nút liên kết được gọi là nơ-ron. Sau đó, các kết nối giữa các nơ-ron này được sử dụng để gửi tín hiệu. Khi quá trình học tập tiến triển, các trọng số được gán cho các nơ-ron và kết nối được cập nhật và sửa đổi, điều này giúp tăng hiệu suất của chúng [23], như thể hiện trong Hình 5.6. NN trình bày kỹ thuật thứ hai. Hoạt động của DT [Ghi chú của người dịch: Văn bản gốc ghi là DT, nhưng đây là mục NN. Đây có thể là lỗi copy-paste] được minh họa trong Thuật toán 5.2.

Mỗi nơ-ron trong lớp nhận (lớp đầu vào) truyền thông tin và được truyền đến các nơ-ron được kết nối trong lớp ẩn. Mỗi đơn vị lớp ẩn tính toán đầu ra bằng cách cộng các tín hiệu đầu vào bị ảnh hưởng được sử dụng trong hàm kích hoạt (AF) bằng cách áp dụng Phương trình (5.5) [24].

$$h(t) = f(\Sigma x(t)W_H + B_H) \text{ (5.5)}$$

Tín hiệu đầu ra được tính bằng cách cộng tín hiệu đầu vào và AF của nó bằng Phương trình (5.6) [24].

$$O(t) = f(\Sigma h(t)Wo + Bo) \text{ (5.6)}$$

AF được sử dụng cho mỗi nơ-ron có trong mạng. Nó là một "cổng" toán học giữa lớp nhận phục vụ nơ-ron hiện tại và kết quả của nó chuyển sang lớp tiếp theo. AF có thể là tuyến tính và phi tuyến.

THUẬT TOÁN 5.2: NN (MẠNG NƠ-RON)

Đầu vào - Dữ liệu có giám sát của N trường hợp Với mỗi mẫu trong bộ dữ liệu: 1: **Khởi tạo:** Nhập mỗi hàng quan sát vào lớp đầu vào và mọi đặc trưng tại mỗi nút đầu vào. Khởi tạo các giá trị trọng số một cách ngẫu nhiên nhưng không phải là 0. 2: **Truyền xuôi:** Từ trái sang phải, tính toán và kích hoạt mỗi nút của các lớp với các trọng số kiểm soát tác động của các nơ-ron tương ứng. 3: **Tính toán chi phí:** Đo lường lỗi với giá trị dự đoán và giá trị thực tế. 4: **Lan truyền ngược và Cập nhật:** Từ phải sang trái, cập nhật các trọng số bằng thuật toán xuống dốc gradient (gradient descent) để giảm lỗi cho đến khi tối ưu hóa. 5: **Dự đoán:** Dự đoán giá trị cho dữ liệu kiểm tra. **Trả về** Bộ phân loại

Các AF phi tuyến được sử dụng trong trường hợp dữ liệu phức tạp để dự đoán kết quả. Trong số các AF, ReLU (Đơn vị tuyến tính chỉnh lưu) là một hàm kích hoạt được sử dụng đa dạng. Các đầu vào có giá trị nhỏ hơn 0 được ánh xạ thành 0 và sau đó được ánh xạ thành 1 cho các đầu vào có giá trị lớn hơn 0. Lựa chọn tốt nhất cho phân loại đa lớp là hàm Softmax, vì nó biến đổi kết quả thành một phân phối xác suất chuẩn hóa. Các kết quả của NN chuyển qua Softmax (AF) biến đổi kết quả thành các giá trị xác suất, cuối cùng được tổng hợp lại thành một. Hàm đầu ra Softmax có thể được biểu diễn trong Phương trình (5.7) [24]:

$$\sigma = \frac{e^{z_k}}{\sum_{j=1} e^{z_j}} \text{ (5.7)}$$

Trong NN truyền thẳng, lan truyền ngược là thuật toán được sử dụng thường xuyên nhất để huấn luyện NN đa lớp, trong đó các tín hiệu từ lớp đầu vào được truyền về phía trước, và các lỗi được truyền ngược lại để thay đổi các trọng số sao cho giảm thiểu lỗi đầu ra. Quá trình này được sao chép trong quá trình huấn luyện, và mỗi lần lặp được gọi là một epoch.

Việc tính toán lỗi trong một thuật toán lan truyền ngược được trình bày trong Phương trình (5.8) [24].

$$E = \frac{1}{2}\Sigma(t_k - O_k)^2 \text{ (5.8)}$$

Mỗi trọng số được điều kiện hóa lại như được biểu diễn trong Phương trình (5.9) [25]:

$$wi = wi + \Delta wi, \text{ (5.9)}$$

trong đó Δwi là yếu tố điều chỉnh được tính toán như được biểu diễn trong Phương trình (5.10) [25].

$$\Delta wi = \eta \delta j x_{ij} \text{ (5.10)}$$

5.3.6 Đánh giá mô hình

Quá trình đánh giá hiệu suất của một mô hình được gọi là đánh giá mô hình. Vì dự đoán cây trồng tốt nhất là một công việc liên quan đến phân loại đa lớp, có bốn kết quả có thể xảy ra, tức là, Âm tính thật (TN), Dương tính thật (TP), Âm tính giả (FN), và Dương tính giả (FP) [25].

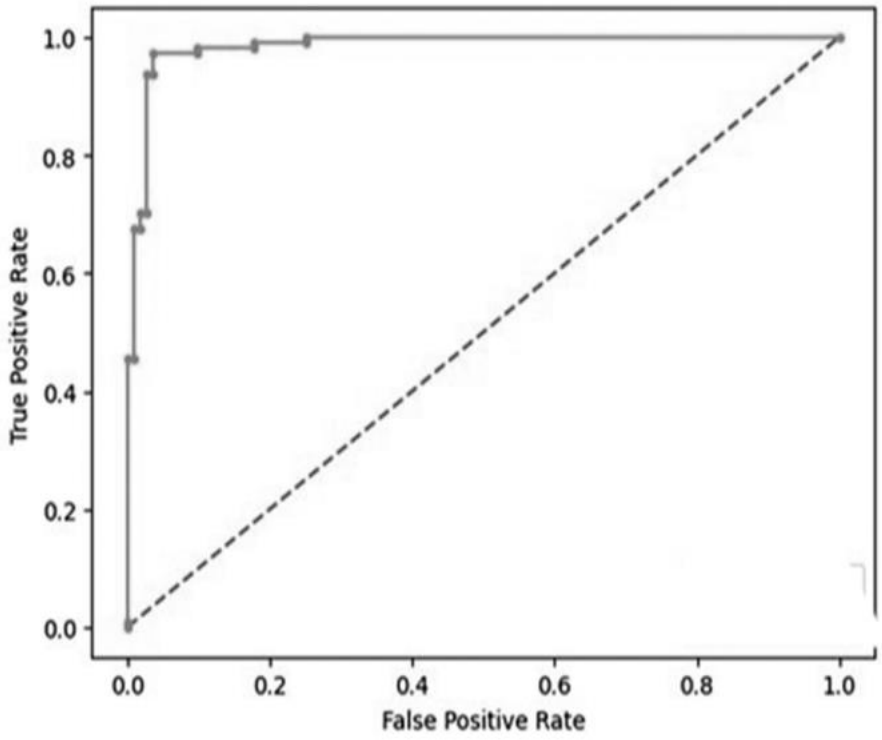
Để đánh giá hiệu suất của một mô hình, các số liệu khác nhau đã được sử dụng - tức là, độ chính xác (accuracy), độ đặc hiệu (specificity), độ nhạy (sensitivity), và diện tích dưới đường cong đặc trưng hoạt động của máy thu (AUROC) [26]. Các số liệu này được định nghĩa theo các kết quả nói trên. Để đánh giá sự ổn định và tính linh hoạt của hệ thống được đề xuất, một phương pháp đã được sử dụng để xác thực mô hình, được gọi là kiểm định chéo K-lần (KFCV). Các thước đo được sử dụng được định nghĩa như sau.

- Độ chính xác (Acc) = $\frac{TP+TN}{TP+TN+FP+FN}$
- Độ nhạy (Sens) = $\frac{TP}{TP+FP}$
- Độ đặc hiệu (Spec) = $\frac{TP}{TP+FN}$
- Điểm F1 = $\frac{2*Precision*Recall}{Precision+Recall}$

5.3.6.1 Đường cong AUROC

Một thống kê đánh giá thiết yếu cho các vấn đề phân loại là đường cong AUROC. Đường cong AUROC là một số liệu đánh giá quan trọng được sử dụng để đánh giá hiệu suất của một vấn đề phân loại đa lớp. Nó được sử dụng rộng rãi để kiểm tra và trực quan hóa mức độ hoạt động tốt của một mô hình phân loại. Đường cong phân biệt thành công giữa

nhiễu và tín hiệu bằng cách vẽ Tỷ lệ dương tính thật (TPR) so với Tỷ lệ dương tính giả (FPR) ở các mức khác nhau. Trong số các giá trị, giá trị hiện diện ở phía trên bên trái của đường cong được coi là giá trị tối ưu. Hình 5.7 cho thấy đường cong AUROC [26].



HÌNH 5.7: Đường cong AUROC. *(Biểu đồ đường cong AUROC, với Tỷ lệ dương tính thật (True Positive Rate) trên trục y và Tỷ lệ dương tính giả (False Positive Rate) trên trục x)*

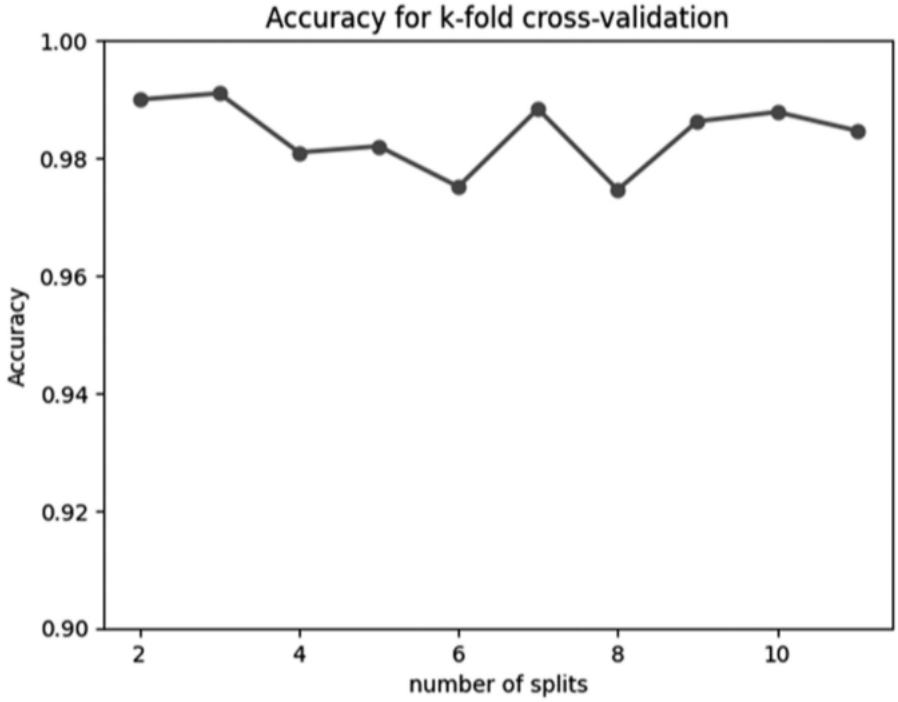
5.3.6.2 Kiểm định chéo K-lần

Quá trình đánh giá các mô hình ML trên các mẫu dữ liệu nhỏ được gọi là kiểm định chéo. Kỹ thuật này sử dụng một tham số gọi là k, xác định số lượng nhóm mà dữ liệu đã được chia. Đối với mỗi lần lặp, k-1 mẫu con được sử dụng để huấn luyện mô hình, và phần còn lại được sử dụng để đánh giá hiệu suất của mô hình. Cuối cùng, các kết quả từ k-lần lặp được cộng lại, và độ chính xác trung bình của mô hình được tạo ra từ kết quả trung bình, như thể hiện trong Bảng 5.2 [27].

BẢNG 5.2: Các thông số đánh giá

Thuật toán phân loại	Độ chính xác (%)	Độ chuẩn xác (Precision)	Độ phủ (Recall)	Điểm F1
Cây quyết định	0.98	0.96	0.98	0.96
Cây quyết định Bagging	0.99	0.98	0.98	0.98

Thuật toán phân loại	Độ chính xác (%)	Độ chuẩn xác (Precision)	Độ phủ (Recall)	Điểm F1
Mạng nơ-ron	0.96	0.97	0.97	0.97
Mạng nơ-ron Bagging	0.99	0.98	0.98	0.98



HÌNH 5.8: KFCV (Kiểm định chéo K-lần). *(Biểu đồ đường thể hiện Độ chính xác (Accuracy) so với số lần chia (number of splits) trong kiểm định chéo k-lần)*

Hình 5.8 mô tả độ chính xác đạt được trong mỗi lần lặp của kỹ thuật KFCV.

5.4 KẾT QUẢ

Trong hệ thống được đề xuất, kết quả của mô hình được giải thích liên quan đến các tham số đánh giá. Để phân tích hiệu quả của hệ thống, dữ liệu KFCV cũng được cung cấp [28-32]. Mô hình đạt được độ chính xác, độ nhạy và độ đặc hiệu lần lượt là 0,99, 0,98 và 0,98, và giá trị AUROC là 0,998, được coi là một trong những kết quả tốt. Một thước đo khác để kiểm tra tính xác thực của mô hình, kiểm định chéo chín lần, đã được thực hiện. Bộ dữ liệu được chia thành chín phần, tám trong số đó được sử dụng để huấn luyện mô hình ML, và phần còn lại được dành để đánh giá mô hình.

5.5 KẾT LUẬN

Cho đến nay, năng suất thu được từ sản xuất cây trồng là không đủ do hiểu biết không đầy đủ về các yếu tố ảnh hưởng đến sản xuất và sự phụ thuộc vào các phương pháp canh tác truyền thống. Hệ thống khuyến nghị dựa trên học ensemble sẽ giúp cộng đồng nông

nghiệp khắc phục những thách thức tương ứng liên quan. Cuối cùng, điều này sẽ góp phần tăng sản lượng cây trồng, dẫn đến năng suất cao hơn. Mô hình được đề xuất đạt được độ nhạy, độ đặc hiệu, độ chính xác và AUROC lần lượt là 0,98, 0,98, 0,99 và 0,998. Trong số các mô hình được đề xuất, các mô hình ensemble hoạt động tốt hơn hai mô hình phân loại đơn lẻ khác [33-37]. Mô hình được đề xuất sẽ tiết kiệm công sức của các nhà nông học cần thiết để chọn cây trồng tốt nhất, tự động dẫn đến năng suất cao hơn. Tuy nhiên, điều liên quan là chỉ ra rằng mô hình này dựa trên các tham số hữu hạn. Tuy nhiên, có một số vấn đề có thể được giải quyết trong tương lai, chẳng hạn như xem xét các tham số khác để huấn luyện mô hình và tinh chỉnh các tham số khác của các mô hình được đề xuất.

TÀI LIỆU THAM KHẢO

[1] Z. Doshi, S. Nadkarni, R. Agrawal and N. Shah, "AgroConsultant: Intelligent Crop Recommendation System Using Machine Learning Algorithms," 2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA), Pune, India, 2018, pp. 1-6. doi: 10.1109/ICCUBEA.2018.8697349

[2] Why is topography important in agriculture. n.d. Retrieved January 23, 2023, from https://geopard.tech/blog/topography-and-nutrition-content-in-soil-and-yield/

[3] S. Veenadhari, B. Misra and C. Singh, "Machine Learning Approach for Forecasting Crop Yield Based on Climatic Parameters," 2014 International Conference on Computer Communication and Informatics, Coimbatore, India, 2014, pp. 1-5. doi: 10.1109/ICCCI.2014.6921718

[4] A. Sharma, A. Jain, P. Gupta and V. Chowdary, "Machine Learning Applications for Precision Agriculture: A Comprehensive Review," IEEE Access, vol. 9, pp. 4843-4873, 2021. doi: 10.1109/ACCESS.2020.3048415

[5] 2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA). n.d.

[6] S. M. Pande, P. K. Ramesh, A. Anmol, B. R. Aishwarya, K. Rohilla and K. Shaurya, "Crop Recommender System Using Machine Learning Approach," 2021 5th International Conference on Computing Methodologies and Communication (ICCMC), Erode, India, 2021, pp. 1066-1071. doi: 10.1109/ICCMC51019.2021.9418351

[7] R. Kumar, M. P. Singh, P. Kumar and J. P. Singh, "Crop Selection Method to Maximize Crop Yield Rate Using Machine Learning Technique, 2015 International Conference on Smart Technologies and Management for Computing, Communication, Controls, Energy and Materials (ICSTM), Avadi, India, 2015, pp. 138-145. doi: 10.1109/ICSTM. 2015.7225403

[8] R. K. Rajak, A. Pawar, M. Pendke, P. Shinde, S. Rathod and A. Devare,"Crop Recommendation System to Maximize Crop Yield using Machine Learning Technique"

International Research Journal of Engineering and Technology, vol. 4, 2017. Retrieved from www.irjet.net

[9] A. Savla, P. Dhawan, H. Bhadada, N. Israni, A. Mandholia and S. Bhardwaj, "Survey of Classification Algorithms for Formulating Yield Prediction Accuracy in Precision Agriculture," Innovations in Information, Embedded and Communication systems (ICIIECS), 2015.

[10] A. T. M. Shakil Ahamed, N. T. Mahmood, N. Hossain, M. T. Kabir, K. Das, F. Rahman and R. M. Rahman, "Applying Data Mining Techniques to Predict Annual Yield of Major Crops and Recommend Planting Different Crops in Different Districts in Bangladesh," (SNPD) IEEE/ACIS International, 2015.

[11] G. Suresh, A. Senthil Kumar, S. Lekashri and R. Manikandan, "Efficient Crop Yield Recommendation System Using Machine Learning For Digital Farming" International Journal of Modern Agriculture, vol. 10, no. 1, pp. 906-914, 2021.

[12] Crop Recommendation Dataset Kaggle. n.d. Retrieved January 23, 2023, from https://www.kaggle.com/datasets/atharvaingle/crop-recommendation-dataset

[13] S. Krishnan, M. J. Franklin, K. Goldberg, J. Wang and E. Wu, "ActiveClean: An Interact Data Cleaning Framework for Modern Machine Learning," Proceedings of the ACM SIGMOD International Conference on Management of Data, 26-June-2016, pp. 2117-2120. doi: 10.1145/2882903.2899409

[14] P. Li, X. Rao, J. Blase, Y. Zhang, X. Chu and C. Zhang, "CleanML: A Study for Evaluating the Impact of Data Cleaning on ML Classification Tasks," Proceedings International Conference on Data Engineering, April-2021, pp. 13-24. doi: 10.1109/ICDE51399.2021.00009

[15] C. M. Salgado, C. Azevedo, H. Proença and S. M. Vieira, "Noise versus Outliers," in MIT Critical Data (ed) Secondary Analysis of Electronic Health Records, Springer, Cham (CH), 2016. PMID: 31314268.

[16] I. Izonin, R. Tkachenko, N. Shakhovska, B. Ilchyshyn and K. K. Singh, "A Two-Step Data Normalization Approach for Improving Classification Accuracy in the Medical Diagnosis Domain," Mathematics, vol. 10, no. 11, 1942, 2022.

[17] Why Use Ensemble Learning? - Machine LearningMastery.com. n.d. Retrieved October 5, 2023, from https://machinelearningmastery.com/why-use-ensemble-learning/

[18] Ensemble Learning Methods: Bagging, Boosting and Stacking. n.d. Retrieved October 5, 2023, from https://www.analyticsvidhya.com/blog/2023/01/ensemble-learning-methods-bagging-boosting-and-stacking/

[19] I. D. Mienye and Y. Sun, "A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects," IEEE Access, vol. 10, pp. 99129-99149, 2022.

[20] P. Yadav, Decision Tree in Machine Learning. Towards Data Science. n.d. Retrieved March 1, 2023, from https://towardsdatascience.com/decision-tree-in-machine-learning-e380942a4c96

[21] H. H. Patel and P. Prajapati, "Study and Analysis of Decision Tree Based Classification Algorithms," International Journal of Computer Sciences and Engineering, vol. 6, no. 10, pp. 74-78, 2018.

[22] P. Picton and P. Picton, What Is a Neural Network? Macmillan Education UK, pp. 1-12, 1994.

[23] A. D. Dongare, R. R. Kharde and A. D. Kachare, "Introduction to Artificial Neural Network," International Journal of Engineering and Innovative Technology (IJEIT), vol. 2, no. 1, pp. 189-194, 2012.

[24] J. Madhuri and M. Indiramma, "Artificial Neural Networks Based Integrated Crop Recommendation System Using Soil and Climatic Parameters," Indian Journal of Science And Technology Conference, 2021. doi: 10.17485/IJST/v14i19.64

[25] Domino Data Science Dictionary. What Is Model Evaluation? n.d. Retrieved March 4, 2023, from https://www.dominodatalab.com/data-science-dictionary/model-evaluation

[26] S. Narkhede, "Understanding AUC-ROC Curve," Towards Data Science, vol. 26, no. 1, pp. 220-227, 2018.

[27] A Gentle Introduction to k-Fold Cross-Validation Machine LearningMastery.com. n.d. Retrieved March 4, 2023, from https://machinelearningmastery.com/k-fold-cross-validation/

[28] S. N. H. Bukhari, J. Webber and A. Mehbodniya, "Decision Tree Based Ensemble Machine Learning Model for the Prediction of Zika Virus T-Cell Epitopes as Potential Vaccine Candidates," Scientific Reports, vol. 12, 7810, 2022, doi: 10.1038/ s41598-022-11731-6

[29] G. S. Raghavendra, S. S. C. Mary, P. B. Acharjee, V. L. Varun, S. N. H. Bukhari, C. Dutta and I. A. Samori, "An Empirical Investigation in Analysing the Critical Factors of Artificial Intelligence in Influencing the Food Processing Industry: A Multivariate Analysis of Variance (MANOVA) Approach," Journal of Food Quality, vol. 2022, Article ID 2197717, 7 pages, 2022. doi: 10.1155/2022/2197717

[30] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya and J. Webber, "Ensemble Machine Learning Model to Predict SARS-CoV-2 T-Cell Epitopes as Potential Vaccine Targets," Diagnostics, vol. 11, no. 11, p. 1990, 2021. MDPI AG. doi: 10.3390/ diagnostics11111990

[31] S. L. Bangare, D. Virmani, G. R. Karetla, P. Chaudhary, H. Kaur, S. N. H. Bukhari and S. Miah, "Forecasting the Applied Deep Learning Tools in Enhancing Food Quality

for Heart Related Diseases Effectively: A Study Using Structural Equation Model Analysis," Journal of Food Quality, vol. 2022, Article ID 6987569, 8 pages, 2022. doi: 10.1155/2022/6987569

[32] C. M. Anoruo, S. N. H. Bukhari and O. K. Nwofor, "Modeling and Spatial Characterization of Aerosols at Middle East AERONET Stations," Theoretical and Applied Climatology, vol. 152, pp. 617-625, 2023. doi: 10.1007/s00704-023-04384-6

[33] F. Masoodi, M. Quasim, S. Bukhari, S. Dixit and S. Alam, Applications of Machine Learning and Deep Learning on Biological Data. CRC Press, 2023.

[34] S. N. H. Bukhari, A. Jain and E. Haq, "A Novel Ensemble Machine Learning Model for Prediction of Zika Virus T-Cell Epitopes," in Gupta, D., Polkowski, Z., Khanna, A., Bhattacharyya, S., and Castillo, O. (eds) Proceedings of Data Analytics and Management. Lecture Notes on Data Engineering and Communications Technologies, vol. 91. Springer, Singapore. doi: 10.1007/978-981-16-6285-0_23

[35] S. N. H. Bukhari, F. Masoodi, M. A. Dar, N. I. Wani, A. Sajad and G. Hussain, "Prediction of Erythemato-Squamous Diseases Using Machine Learning," in Auerbach Publications eBooks, pp. 87-96, 2023. doi: 10.1201/9781003328780-6

[36] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya and J. Webber, "Machine Learning Techniques for the Prediction of B-Cell and T-Cell Epitopes as Potential Vaccine Targets with a Specific Focus on SARS-CoV-2 Pathogen: A Review," Pathogens, vol. 11, no. 2, p. 146, 2022. MDPI AG. doi: 10.3390/pathogens11020146

[37] S. Nisar, H. Bukhari and M. A. Dar, "Using Random Forest to Predict T-Cell Epitopes of Dengue Virus," Advances and Applications in Mathematical Sciences, vol. 20, no. 11, pp. 2543-2547, 2021.

CHƯƠNG 6: KHẢO SÁT CÁC THUẬT TOÁN HỌC MÁY TRONG DỰ ĐOÁN NĂNG SUẤT CÂY TRỒNG

Anshika Gupta, Mohit Soni, và Kalpana Katiyar Viện Công nghệ Dr. Ambedkar dành cho Người khuyết tật, Kanpur, Ấn Độ

6.1 GIỚI THIỆU

Nông nghiệp đóng vai trò quan trọng trong việc giải quyết các vấn đề xã hội cấp bách, đặc biệt trong bối cảnh cung cấp lương thực. Hiện tại, một bộ phận đáng kể dân số thế giới đang phải chịu nạn đói, chủ yếu do tình trạng thiếu lương thực và không đủ lương thực, vốn đang trở nên trầm trọng hơn bởi dân số không ngừng gia tăng [1]. Những hậu quả của việc gia tăng dân số, biến đổi nhiệt độ tự nhiên, xói mòn đất và nhu cầu liên quan đến khí hậu thay đổi đòi hỏi các kỹ thuật mới để đảm bảo việc canh tác và sản xuất lương thực ổn định và kịp thời. Hơn nữa, có một nhu cầu cấp thiết phải thúc đẩy tính bền vững trong sản xuất lương thực nông nghiệp [2]. Những yêu cầu này làm nổi bật nhu cầu quan trọng về đánh giá đất đai, bảo vệ cây trồng và dự báo năng suất cây trồng chính xác trong việc tăng sản lượng lương thực toàn cầu [3]. Năng suất cây trồng có mối liên hệ chặt chẽ với một loạt các yếu tố, bao gồm địa hình, chất lượng đất, áp lực côn trùng, đặc tính di truyền, khả năng tiếp cận nước, kiểu thời tiết và kế hoạch thu hoạch [4]. Các quy trình và phương pháp ước tính năng suất cây trồng vừa mang tính chất cụ thể theo thời gian và vừa mang tính phi tuyến cơ bản. Việc tích hợp một loạt các khía cạnh phụ thuộc lẫn nhau, nhiều khía cạnh trong số đó bị chi phối bởi các lực lượng bên ngoài không thể kiểm soát, làm tăng thêm tính phức tạp [5].

Nông dân từ lâu đã dựa vào kinh nghiệm cá nhân và dữ liệu lịch sử để dự đoán năng suất cây trồng và đưa ra các quyết định sản xuất quan trọng dựa trên những dự báo này. Tuy nhiên, trong những năm gần đây, các công nghệ mới như mô phỏng mô hình cây trồng và học máy (Machine Learning - ML) đã xuất hiện, với tiềm năng cho các ước tính năng suất chính xác hơn và khả năng phân tích

các tập dữ liệu khổng lồ bằng cách sử dụng máy tính hiệu suất cao. Một số nghiên cứu hiện nay đang tiết lộ tiềm năng lớn hơn của các thuật toán ML trong lĩnh vực này so với các kỹ thuật thống kê truyền thống [6].

ML, một tập hợp con của trí tuệ nhân tạo (Artificial Intelligence - AI), cho phép máy tính học mà không cần lập trình rõ ràng. Những chiến lược này vượt qua các giới hạn của cả hệ thống nông nghiệp tuyến tính và phi tuyến, cải thiện khả năng dự đoán. Các mô hình ML học bằng cách được tiếp xúc với các nhiệm vụ và mẫu hình cụ thể trong dữ liệu huấn luyện. Sau đó, các mô hình này áp dụng thông tin đã học được vào dữ liệu mới, với giả định rằng kiến thức thu được trong giai đoạn đào tạo có thể chuyển giao và có liên quan. Một loạt các nghiên cứu mang tính hướng dẫn và độc đáo, cũng như các bài tổng quan, đã được công bố trong lĩnh vực đánh giá sản lượng nông nghiệp trong 15 năm qua [7] và

đã thực hiện một đánh giá toàn diện về các ứng dụng viễn thám thực tiễn trong canh tác dầu cọ, xác định các khoảng trống nghiên cứu và đưa ra các giải pháp khả thi. Tuy nhiên, cần lưu ý rằng nghiên cứu của họ không tập trung chủ yếu vào các kỹ thuật dự đoán cho sản xuất dầu cọ. Các nhà nghiên cứu [8] đã điều tra những phát triển đương đại trong việc tạo ra số liệu thống kê chính thức, bao gồm viễn thám, khảo sát và tích hợp nhiều nguồn dữ liệu, chẳng hạn như dữ liệu khí tượng và dữ liệu hành chính. Mặc dù nghiên cứu của họ xác định tiềm năng cải thiện các phương pháp dự báo sản xuất cây trồng hiện tại, nhưng nó cũng thừa nhận sự không chắc chắn vốn có liên quan đến các dự báo như vậy. Tuy nhiên, bài báo của họ, mặc dù xem xét các chiến lược năng suất nông nghiệp [9], đã cung cấp một bài tổng quan có cấu trúc tốt, đi sâu vào nhiều đặc điểm và kỹ thuật dự đoán khác nhau. Trọng tâm của bài báo của họ, tuy nhiên, là vào việc trích xuất thông tin hơn là xác định khoảng trống nghiên cứu, đưa ra khuyến nghị hoặc phân tích phê bình các công trình trước đây. Nghiên cứu của họ khuyến nghị một cuộc điều tra kỹ lưỡng về các tham số mới để dự báo sản xuất nông nghiệp. Một nghiên cứu khác [10] đã xem xét năng suất dầu cọ dựa trên các biến số sinh lý thực vật, với mục tiêu cung cấp thông tin chi tiết về các nguyên nhân gây ra khoảng cách sản lượng dầu cọ. Các nhà nghiên cứu [11] tập trung vào việc sử dụng thực tiễn của ML trong nông nghiệp. Trong khuôn khổ này, họ đã xem xét các nghiên cứu về quản lý vật nuôi, cây trồng, nước và đất đai. Một nghiên cứu khác [12] đã cố gắng xác định độ chín của trái cây để tối ưu hóa lịch trình thu hoạch và dự báo sản lượng.

ML là một tập hợp con của AI tập trung vào việc phát triển các phương pháp tiếp cận hiệu quả để dự đoán năng suất dựa trên một loạt các yếu tố ảnh hưởng. ML trích xuất những thông tin chi tiết quan trọng từ các tập dữ liệu bằng cách xác định các mẫu hình và mối quan hệ có thể quan sát được trong dữ liệu [13]. Các hệ thống ML này yêu cầu được đào tạo với



HÌNH 6.1 Một kỹ thuật ML. (Hình minh họa quy trình của một kỹ thuật Học máy, thường bao gồm các bước như Thu thập dữ liệu, Tiền xử lý, Xây dựng mô hình, Đào tạo, Đánh giá và Dự đoán)

các tập dữ liệu chứa kết quả từ những kinh nghiệm trong quá khứ để phát triển các mô hình dự đoán. Việc xây dựng hệ thống dự đoán đòi hỏi phải sử dụng một số đặc tính, và các tham số của hệ thống được xác định bằng cách sử dụng dữ liệu lịch sử trong giai đoạn đào tạo [14]. Sau đó, trong giai đoạn kiểm tra, một tập hợp con của dữ liệu trong quá khứ

không được sử dụng trong quá trình đào tạo sẽ được sử dụng để đánh giá sự phát triển của hệ thống. Hình 6.1 mô tả một kỹ thuật ML.

6.2 TỔNG QUAN TÀI LIỆU

6.2.1 Các Phương pháp Dự đoán Năng suất Cây trồng: Truyền thống so với Học máy

Trong quá khứ, dự đoán năng suất cây trồng dựa nhiều hơn vào các phương pháp thủ công thay vì các phương pháp dựa trên công nghệ. Các kỹ thuật truyền thống này bao gồm các hoạt động như tham khảo dữ liệu lịch sử, theo dõi điều kiện thời tiết, phân tích đất và thực hiện kiểm tra hiện trường, trong số những hoạt động khác. Tuy nhiên, một nhược điểm đáng chú ý của các phương pháp thông thường này là chúng chậm chạp, độ chính xác hạn chế và tốn thời gian. Nhiều lĩnh vực sử dụng các kỹ thuật ML, bao gồm các siêu thị sử dụng ML để dự báo việc sử dụng điện thoại của khách hàng và phân tích hành vi người tiêu dùng. Trong lĩnh vực nông nghiệp, ML từ lâu đã là một công cụ. Một trong những thách thức phức tạp trong nông nghiệp chính xác xoay quanh việc dự đoán sản xuất cây trồng, và các mô hình khác nhau đã được phát triển và chứng minh hiệu quả của chúng trong việc giải quyết thách thức này. Xét đến vô số các yếu tố ảnh hưởng đến sản xuất nông nghiệp, chẳng hạn như khí hậu, thời tiết, điều kiện đất đai [15], việc bón phân và các giống cây trồng, việc giải quyết vấn đề này đòi hỏi phải sử dụng nhiều bộ dữ liệu. Điều này nhấn mạnh rằng việc dự đoán năng suất nông nghiệp đòi hỏi một quá trình đa diện và phức tạp, chứ không phải là một nhiệm vụ đơn giản [16]. Các mô hình dự đoán năng suất cây trồng ngày nay

có khả năng dự đoán năng suất thực tế một cách tương đối chính xác, mặc dù vẫn còn sự theo đuổi không ngừng để đạt được hiệu suất dự đoán cao hơn [17]. Chúng tôi đã thực hiện một phân tích toàn diện về tài liệu hiện có thông qua một tổng quan tài liệu có hệ thống (Systematic Literature Review - SLR) để có được sự hiểu biết toàn diện về các nghiên cứu được thực hiện về việc sử dụng ML [18] trong dự đoán sản xuất nông nghiệp. Một nghiên cứu SLR nghiêm ngặt như vậy [19] không chỉ mang lại những quan điểm mới mẻ mà còn nâng cao sự hiểu biết về tình trạng hiện tại của lĩnh vực, điều này đặc biệt có lợi cho những người mới bước vào lĩnh vực nghiên cứu.

6.2.2 Những Thách thức Chính trong Dự đoán Năng suất Cây trồng

Mặc dù ML có tiềm năng đáng kể trong việc nâng cao phân tích và dự đoán cây trồng, nhưng điều cần thiết là phải tính đến các thách thức khác nhau cần được giải quyết.

i. **Khối lượng Dữ liệu**: Một lượng dữ liệu đáng kể thường được yêu cầu để các mô hình ML được đào tạo hiệu quả. Việc quản lý và thu thập tập dữ liệu lớn có thể là một thách thức trong ngành nông nghiệp, đặc biệt là đối với các trang trại nhỏ [20].

ii. **Chất lượng Dữ liệu**: Độ chính xác và độ tin cậy của các mô hình ML được quyết định bởi chất lượng của dữ liệu đào tạo. Do sự thay đổi về đất đai, khí hậu, địa lý và các yếu tố môi trường khác, việc thu thập dữ liệu chất lượng cao trong nông

nghiệp có thể khó khăn. Kết quả là, việc thu thập và xử lý dữ liệu có thể tốn nhiều công sức. Những khó khăn chính với việc nhận dạng và nhận biết trái cây bằng học sâu được thảo luận trong tài liệu tham khảo [21]. Họ phát hiện ra rằng một số vấn đề, bao gồm sự khan hiếm các bộ dữ liệu trái cây chất lượng cao, việc phát hiện các mục tiêu trái cây nhỏ, nhận dạng trái cây trong môi trường bị che khuất và mật độ dày đặc, việc phát hiện trái cây có kích thước và loài khác nhau, và việc phát triển các mô hình phát hiện trái cây nhẹ là nguyên nhân dẫn đến độ chính xác thấp, tốc độ xử lý chậm và tính mạnh mẽ hạn chế trong việc phát hiện và nhận dạng trái cây.

iii. **Độ phức tạp của Mô hình**: Xét đến tính phức tạp của hệ thống nông nghiệp, việc xây dựng các mô hình ML xem xét toàn diện tất cả các biến số quan trọng ảnh hưởng đến sự phát triển và năng suất của cây trồng có thể là một nhiệm vụ khó khăn. Trong số các phương pháp tiếp cận thường được sử dụng nhất có mạng nơ-ron (Neural Networks - NN), rừng ngẫu nhiên (Random Forests - RF), máy vectơ hỗ trợ (Support Vector Machines - SVM), cây quyết định (Decision Trees - DT) và các thuật toán Naive Bayes.

Các thuật toán này có những trở ngại đáng kể, đáng chú ý nhất là xử lý các tập dữ liệu lớn, làm tăng độ phức tạp về thời gian đào tạo và nhu cầu xử lý, đặc biệt là trong trường hợp của SVM. Hơn nữa, việc sửa đổi thuật toán cho từng tình huống là khó khăn trong bối cảnh của RF [22]. Việc tạo ra một kiến trúc dữ liệu lớn vững chắc là một trong những thách thức khó khăn nhất, đòi hỏi cả tính linh hoạt và khả năng mở rộng lớn; các nhà nghiên cứu [23] đã kiểm tra các tham số kiểm soát nhiệt độ đất và xác định rằng mối liên hệ giữa các yếu tố ảnh hưởng đến nhiệt độ đất là phức tạp và đòi hỏi cao.

iv. **Khả năng Tiếp cận**: Việc đảm bảo cơ sở hạ tầng phần cứng và phần mềm cần thiết cho việc phát triển và triển khai các mô hình ML có thể gặp khó khăn khi nguồn lực bị hạn chế.
v. **Yếu tố Con người**: Nông dân và các bên liên quan khác có thể cần thêm thời gian để chuẩn bị cho việc áp dụng các kỹ thuật và công nghệ mới, chẳng hạn như các hệ thống dựa trên ML. Để khuyến khích việc áp dụng rộng rãi hơn, công nghệ nên được thiết kế để thân thiện hơn với người dùng, dễ tiếp cận và có khả năng mang lại lợi ích hữu hình.

6.3 THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU

6.3.1 Nguồn Dữ liệu: Viễn thám, Internet vạn vật, Trạm thời tiết, v.v.

Việc thu thập dữ liệu có hệ thống và đo lường thông tin liên quan đến các biến số quan tâm là những gì mà thu thập dữ liệu bao gồm. Quy trình này cho phép các nhà nghiên cứu giải quyết các câu hỏi nghiên cứu cụ thể, kiểm tra giả thuyết và đánh giá kết quả. Hành động thu thập dữ liệu là một phần quan trọng của nghiên cứu xuyên suốt các lĩnh vực học thuật như khoa học tự nhiên và xã hội, nhân văn và kinh doanh. Mặc dù các phương pháp

cụ thể được sử dụng khác nhau tùy theo lĩnh vực, nhưng mục tiêu tối cao của việc đảm bảo thu thập dữ liệu chính xác và đúng đắn vẫn không thay đổi.

i. **Thu thập Dữ liệu Sử dụng Viễn thám**

Đánh giá tình trạng sức khỏe của cây trồng trong suốt các giai đoạn tăng trưởng của chúng: đưa ra dự đoán về năng suất của chúng. Viễn thám đóng vai trò giám sát sức khỏe của cây trồng trong một cánh đồng cụ thể một cách liên tục. Mục đích chính của nó là phát hiện bất kỳ mối đe dọa nào và thực hiện các biện pháp trước khi chúng gây ra bất kỳ thiệt hại nào. Ngoài ra [11], nó phục vụ như một phương pháp để ước tính năng suất của chu kỳ canh tác và xác định thời điểm thu hoạch dựa trên điều kiện thời tiết. SmartRisk của Cropln là một ví dụ về sản phẩm sử dụng công nghệ cảm biến dựa trên vệ tinh kết hợp với khả năng xử lý để cung cấp thông tin dự đoán chính xác về toàn bộ khu vực canh tác. Viễn thám có lợi thế to lớn là cho phép người trồng liên tục giám sát cánh đồng của họ bất kể vị trí vật lý của họ. Điều này đặc biệt có lợi cho các doanh nghiệp nông nghiệp lớn có các trang trại nằm rải rác trên khắp đất nước vì tất cả các trang trại phải sản xuất sản phẩm có chất lượng đồng nhất [24]. Viễn thám cho phép tất cả các bên liên quan làm việc cùng nhau để theo dõi tiến trình của cây trồng qua các giai đoạn khác nhau, đảm bảo rằng nó đáp ứng các yêu cầu của doanh nghiệp và duy trì chất lượng đồng đều. Phần mềm quản lý cây trồng, chẳng hạn như SmartFarm của Cropln, sử dụng công nghệ viễn thám để cung cấp thông tin chi tiết về sự phát triển và hiệu suất của cây trồng trong suốt mùa vụ. Các nhà nghiên cứu [25] cung cấp thêm thông tin về viễn thám và ứng dụng của nó trong nông nghiệp.

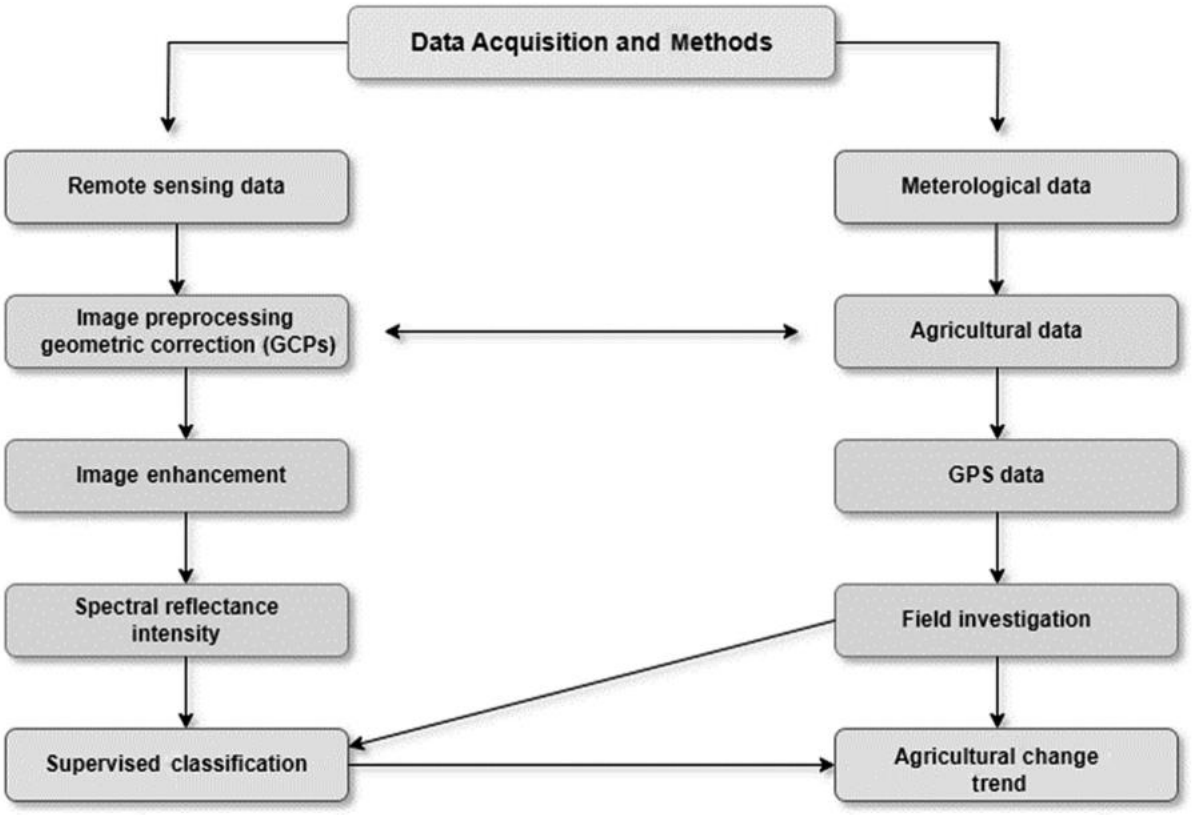
ii. **Thu thập Dữ liệu Sử dụng Internet vạn vật**

Thu thập dữ liệu Internet vạn vật (Internet of Things - IoT) liên quan đến việc sử dụng các cảm biến để giám sát hoạt động của các thiết bị được kết nối IoT. Những cảm biến này liên tục quan sát trạng thái của mạng IoT, thu thập và truyền dữ liệu thời gian thực có thể được lưu trữ và truy xuất bất cứ khi cần thiết. Có các loại dữ liệu IoT khác nhau. Các loại dữ liệu IoT khác nhau được đề cập tiếp theo: • **Dữ liệu Đồng hồ phụ (Submeter Data)**: Chủ sở hữu tài sản có thể sử dụng đồng hồ phụ để đo lường việc sử dụng tiện ích riêng lẻ trong môi trường nhiều người dùng. Đồng hồ phụ có thể thu thập dữ liệu trong các tòa nhà có nhiều người thuê sử dụng tài nguyên nước, điện, khí đốt hoặc cáp. • **Dữ liệu Môi trường (Environmental Data)**: Cảm biến IoT có thể đo lường và giám sát dữ liệu môi trường như độ ẩm, nhiệt độ, chuyển động và chất lượng không khí. • **Dữ liệu Thiết bị (Equipment Data)**: Nó bao gồm dữ liệu liên quan đến trạng thái của thiết bị IoT. Dữ liệu thiết bị được thu thập trong thời gian thực để cho phép các tác vụ bảo trì dự đoán. • Các ứng dụng hiện tại cung cấp cái nhìn sâu sắc về tác động của IoT và các thực hành mới. Tuy nhiên, với sự tiến bộ của công nghệ [26], các công nghệ IoT có thể đóng một phần quan trọng trong nhiều nhiệm vụ canh tác. Chúng bao gồm sử dụng cơ sở hạ tầng truyền thông, thu thập dữ liệu, các đối tượng và cảm biến thông minh, thiết bị di động, khai thác thông tin thông minh dựa trên đám mây, hỗ trợ ra quyết định và tự động hóa các hoạt động nông nghiệp. Công nghệ IoT giám sát việc theo dõi từ xa cây trồng và vật nuôi trong khi thu thập dữ liệu từ điện thoại di động và các thiết bị [27]. Các nhà nghiên cứu đã đưa ra các phương pháp tiếp cận đa dạng, các giải pháp kiến trúc và một

loạt các thiết bị để giám sát và truyền thông tin liên quan đến cây trồng qua các giai đoạn tăng trưởng khác nhau được điều chỉnh cho các loại cây trồng và điều kiện đồng ruộng khác nhau. Nhiều nhà sản xuất cung cấp thiết bị truyền thông, nhiều loại cảm biến, hệ thống robot, máy móc hạng nặng và máy bay không người lái được thiết kế cho mục đích thu thập và phổ biến dữ liệu. Ngoài ra, các tổ chức lương thực và nông nghiệp, phối hợp với các cơ quan chính phủ, đang tích cực xây dựng hướng dẫn và chính sách để quản lý việc sử dụng các công nghệ này, nhằm đảm bảo an toàn thực phẩm và bảo tồn môi trường [28].

iii. **Thu thập Dữ liệu Sử dụng Trạm thời tiết**

Các trạm thời tiết là các công trình hoặc vật thể với nhiều thiết bị và cảm biến khác nhau để thu thập và đo lường thông tin khí tượng và các biến môi trường địa phương. Các trạm này được định vị một cách cẩn thận để theo dõi các biến số, bao gồm nhiệt độ, độ ẩm, áp suất khí quyển, hướng gió, tốc độ, lượng mưa (mưa và tuyết) và đôi khi thậm chí nhiều thông số hơn như bức xạ mặt trời và độ ẩm đất. Các trạm thời tiết gia đình đơn giản cho mục đích sử dụng cá nhân có thể có phạm vi phức tạp từ các hệ thống tự động tinh vi cao được sử dụng bởi các cơ quan khí tượng và viện nghiên cứu. Dữ liệu thời tiết thường được cung cấp công khai để sử dụng trong nhiều ứng dụng và quy trình ra quyết định khác nhau bởi các trạm thời tiết hiện đại thường xuyên gửi dữ liệu theo thời gian thực đến các cơ sở dữ liệu tập trung. Nông dân cần học cách giám sát các điều kiện môi trường một cách hợp lý và hiệu quả, đặc biệt là đối với những loại cây trồng đặc biệt nhạy cảm với thời tiết, để giảm thiểu tác động của biến đổi khí hậu lên các loại cây trồng khác nhau. Hai kỹ thuật phổ biến để thu thập thông tin và theo dõi điều kiện thời tiết là cảm biến tại chỗ và các trạm thời tiết. Mặc dù cảm biến có thể thu thập dữ liệu khí tượng chính xác tại địa phương, nhưng việc lắp đặt và bảo trì chúng có thể tốn kém và mất thời gian. Sử dụng các trạm thời tiết trực tuyến, thường do chính phủ quản lý và mọi người đều có thể tiếp cận, là một lựa chọn; tuy nhiên, độ chính xác của chúng còn gây tranh cãi vì tần suất chúng thường được đặt xa [29] nhà kính của nông dân. Kết quả là, chúng tôi đã so sánh độ chính xác của các bộ ước lượng kriging sử dụng dữ liệu từ cảm biến cục bộ và dữ liệu trạm thời tiết do Cục Khí tượng Trung ương thu thập. Dữ liệu nhiệt độ được nội suy bằng kỹ thuật kriging không-thời gian. Để so sánh, giá trị thực tế ở trung tâm nhà kính đã được sử dụng. Phát hiện của chúng tôi cho thấy rằng bộ ước lượng cảm biến cục bộ có độ chính xác cao hơn một chút so với bộ ước lượng trạm thời tiết. Cảm biến tại chỗ có thể cung cấp cho nông dân các ước tính chính xác về dữ liệu môi trường, nhưng nếu chúng không có sẵn, việc sử dụng ước tính từ một trạm thời tiết gần đó cũng có thể chấp nhận được (Hình 6.2) [30].



HÌNH 6.2 Các phương pháp thu thập dữ liệu khác nhau. (Hình minh họa các nguồn và phương pháp thu thập dữ liệu như Viễn thám, Dữ liệu Khí tượng, Dữ liệu Nông nghiệp, Dữ liệu GPS, v.v. và quy trình xử lý như Tiền xử lý ảnh, Hiệu chỉnh hình học, Phân loại có giám sát, v.v.)

6.3.2 Làm sạch, Biến đổi và Tích hợp Dữ liệu

Chuẩn bị dữ liệu thô cho phân tích và đào tạo mô hình bằng cách làm sạch và tiền xử lý nó là các giai đoạn quan trọng trong quy trình ML. Các giai đoạn này là thiết yếu vì tính ứng dụng và chất lượng dữ liệu của bạn có ảnh hưởng lớn đến hiệu quả và độ chính xác của các mô hình ML của bạn.

i. **Làm sạch Dữ liệu**: Tìm và sửa chữa các lỗi hoặc sự không nhất quán trong tập dữ liệu của bạn được gọi là làm sạch dữ liệu. Nó nhằm đảm bảo tính chính xác và độ tin cậy của dữ liệu của bạn. Các hoạt động làm sạch dữ liệu thường bao gồm những việc sau:

- **Xử lý Giá trị Thiếu (Handling Missing Values)**: Loại bỏ các hàng có giá trị bị thiếu, điền thay thế các giá trị bị thiếu bằng một giá trị mặc định hoặc một thước đo thống kê (chẳng hạn như giá trị trung bình hoặc trung vị), hoặc sử dụng các kỹ thuật điền thay thế tinh vi hơn.

- **Phát hiện và Xử lý Ngoại lai (Outlier Detection and Treatment)**: Xác định xem có nên loại bỏ, biến đổi hoặc để nguyên các giá trị ngoại lai (các điểm dữ liệu khác biệt đáng kể so với phần lớn) dựa trên ngữ cảnh.

- **Định dạng Dữ liệu (Data Formatting)**: Định dạng dữ liệu bao gồm đảm bảo rằng các kiểu dữ liệu là phù hợp và nhất quán, chuyển đổi chúng nếu cần thiết và định dạng dữ liệu theo yêu cầu của thuật toán ML.

- **Xử lý Trùng lặp (Handling Duplicates)**: Phát hiện và loại bỏ các mục nhập trùng lặp sẽ ngăn ngừa sự thiên vị và dư thừa trong tập dữ liệu.

- **Giảm Nhiễu (Noise Reduction)**: Các kỹ thuật làm mịn hoặc lọc dữ liệu được sử dụng để giảm nhiễu, đặc biệt là trong dữ liệu chuỗi thời gian hoặc dữ liệu cảm biến. Các nhà nghiên cứu [31] sử dụng dữ liệu lớn với các khối mẫu ngẫu nhiên để giải thích quy trình làm sạch và tiền xử lý dữ liệu.

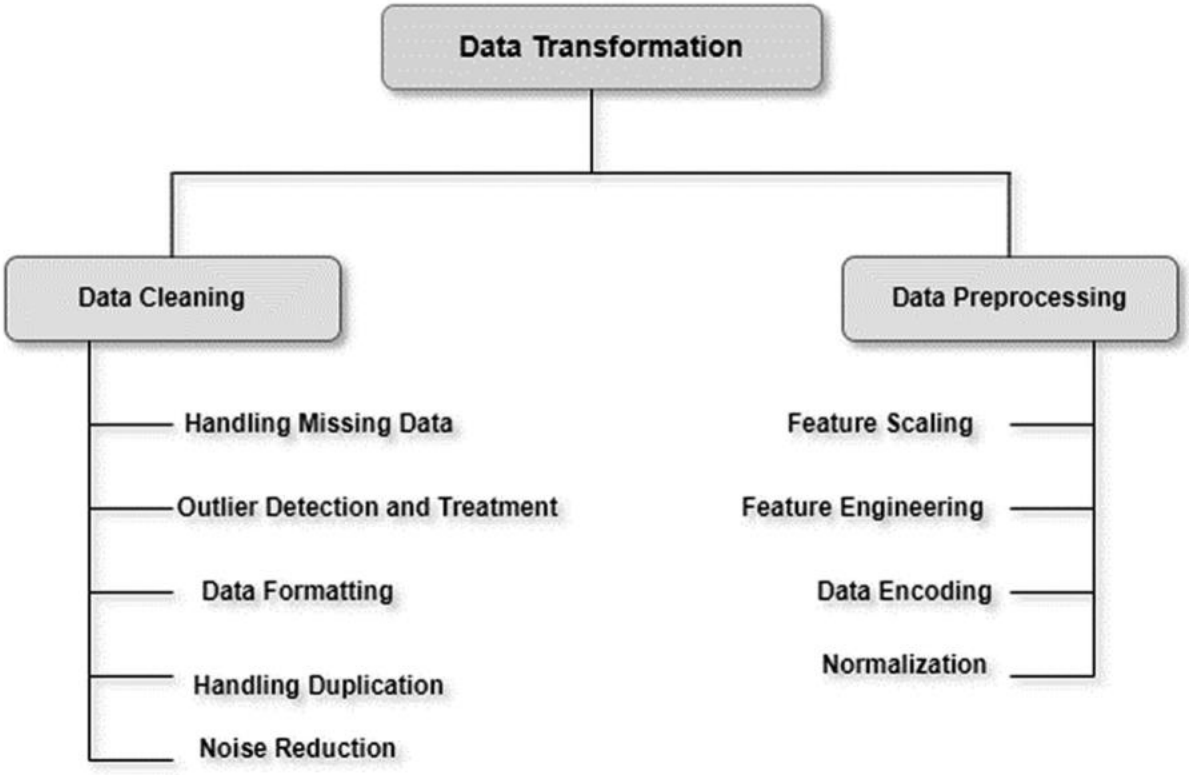
ii. **Tiền xử lý Dữ liệu (Data Preprocessing)**: Việc chuyển đổi dữ liệu đã được làm sạch thành một định dạng phù hợp cho các thuật toán ML được gọi là chuẩn bị dữ liệu. Các nhà nghiên cứu [32] giải thích quy trình kết hợp tiền xử lý dữ liệu để cải thiện hiệu suất phân loại chất lượng trong quy trình sản xuất. Một số nhiệm vụ được bao gồm trong quá trình này, bao gồm những việc sau:

- **Chuẩn hóa Đặc trưng (Feature Scaling)**: Chuẩn hóa đặc trưng là quá trình giảm các đặc tính số về một phạm vi chung (ví dụ: chuẩn hóa hoặc chuẩn hóa tiêu chuẩn) để ngăn các đặc trưng chi phối các đặc trưng khác trong quá trình đào tạo mô hình.

- **Kỹ thuật Đặc trưng (Feature Engineering)**: Đây là quá trình phát triển các đặc trưng mới hoặc sửa đổi các đặc trưng hiện có để trích xuất thông tin hữu ích hoặc nâng cao hiệu suất mô hình. Điều này bao gồm mã hóa một lần (one-hot encoding) các biến phân loại, tạo ra các đặc trưng tương tác và trích xuất các đặc trưng ngày/giờ.

- **Mã hóa Dữ liệu (Data Encoding)**: Chuyển đổi các biến phân loại thành định dạng số bằng các kỹ thuật như mã hóa one-hot hoặc mã hóa nhãn (label encoding).

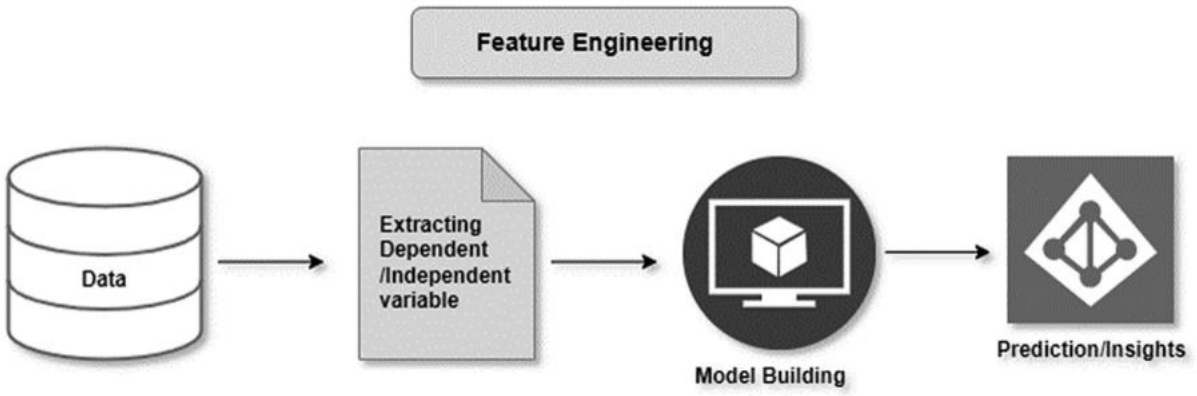
- **Chuẩn hóa (Normalization)**: Chuẩn hóa là quá trình chia tỷ lệ các đặc trưng để có giá trị trung bình bằng 0 và phương sai đơn vị để các thuật toán ML có thể hội tụ nhanh hơn [33] (Hình 6.3).



HÌNH 6.3 Các phương pháp làm sạch và tiền xử lý dữ liệu. (Hình minh họa các bước trong Biến đổi Dữ liệu, chia thành hai nhánh chính: Làm sạch Dữ liệu (với các bước như Xử lý Dữ liệu Thiếu, Phát hiện & Xử lý Ngoại lai, Định dạng Dữ liệu, Xử lý Trùng lặp, Giảm Nhiễu) và Tiền xử lý Dữ liệu (với các bước như Chuẩn hóa Đặc trưng, Kỹ thuật Đặc trưng, Mã hóa Dữ liệu, Chuẩn hóa))

6.3.3 Dự đoán Năng suất Cây trồng Sử dụng Kỹ thuật Đặc trưng

Thiết kế hoặc kỹ thuật đặc trưng (Feature engineering) là một giai đoạn quan trọng trong việc chuẩn bị dữ liệu cho các thuật toán ML. Nó bao gồm việc tạo ra các đặc trưng mới (còn được gọi là biến số hoặc thuộc tính) từ dữ liệu hiện tại để nâng cao hiệu suất của một mô hình ML [34]. Mục đích của kỹ thuật đặc trưng là trích xuất thông tin hữu ích từ dữ liệu thô và biểu diễn nó theo cách mà thuật toán ML có thể học từ nó một cách hiệu quả. Kỹ thuật đặc trưng giúp chúng ta trích xuất biến phụ thuộc và biến độc lập phù hợp với mô hình ML và giúp chúng ta điều chỉnh thêm các niềm tin và xác suất định kiến trước đó. Các nhà nghiên cứu [35] sử dụng dữ liệu thời tiết và dữ liệu lịch sử về ngô và khoai tây Ireland để dự đoán năng suất trong tương lai của khoai tây Ireland và ngô (Hình 6.4).



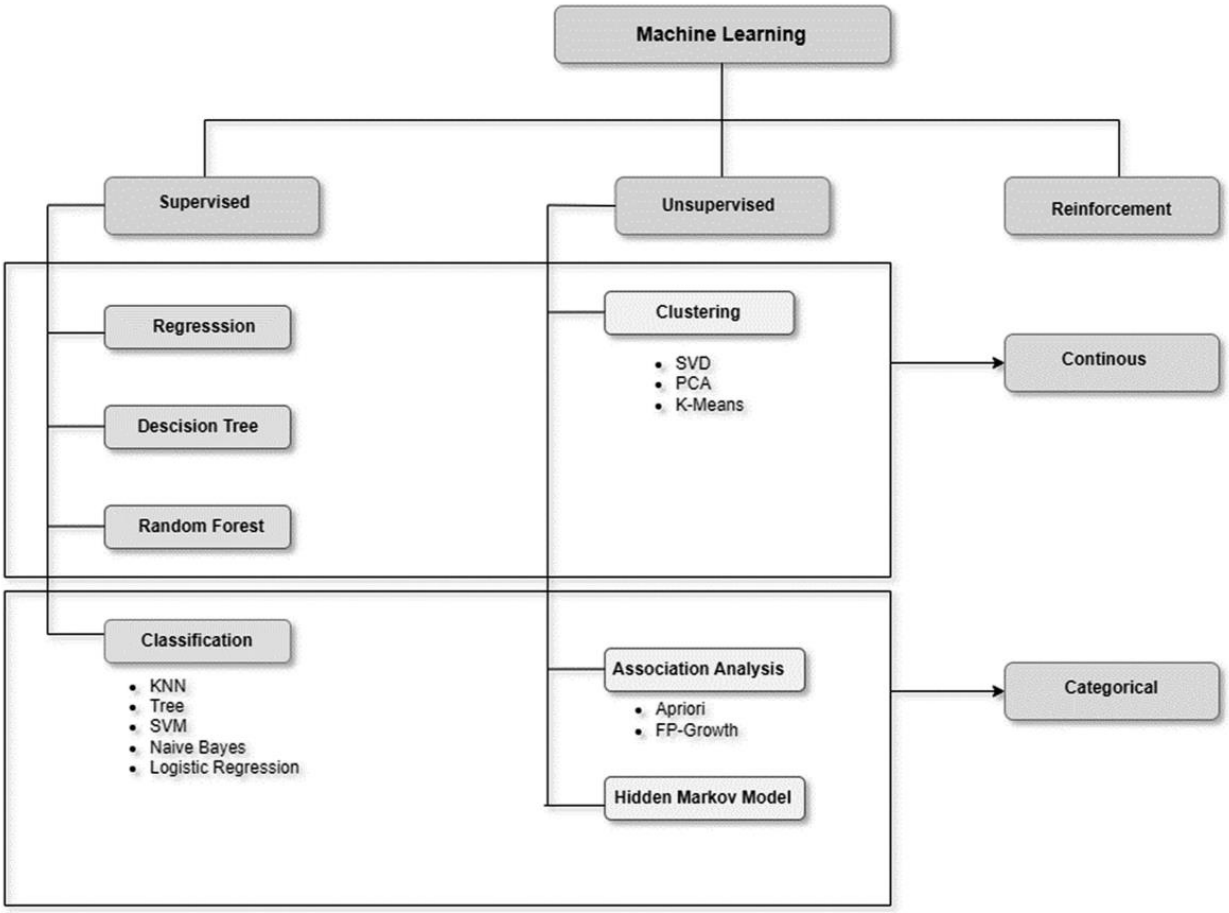
HÌNH 6.4 Kỹ thuật Đặc trưng (Feature Engineering). (Hình minh họa quy trình: Kỹ thuật Đặc trưng -> Trích xuất Biến Phụ thuộc/Độc lập -> Xây dựng Mô hình -> Dự đoán/Thông tin chi tiết)

6.4 CÁC THUẬT TOÁN HỌC MÁY CHO DỰ ĐOÁN NĂNG SUẤT CÂY TRỒNG

Các thuật toán ML là các chương trình phần mềm có thể phát hiện các mẫu hình ẩn trong dữ liệu, đưa ra dự đoán và cải thiện hiệu suất của chúng bằng cách tự học

từ kinh nghiệm. ML sử dụng nhiều thuật toán khác nhau, mỗi thuật toán được điều chỉnh cho một mục đích cụ thể [36]. Ví dụ, hồi quy tuyến tính đơn giản phù hợp cho các nhiệm vụ dự đoán như dự đoán biến động thị trường chứng khoán, nhưng phương pháp K-láng giềng gần nhất (K-nearest neighbors - KNN) lại phù hợp cho các thách thức phân loại. Các nhiệm vụ ML chủ yếu được chia thành nhiệm vụ phân loại và nhiệm vụ hồi quy.

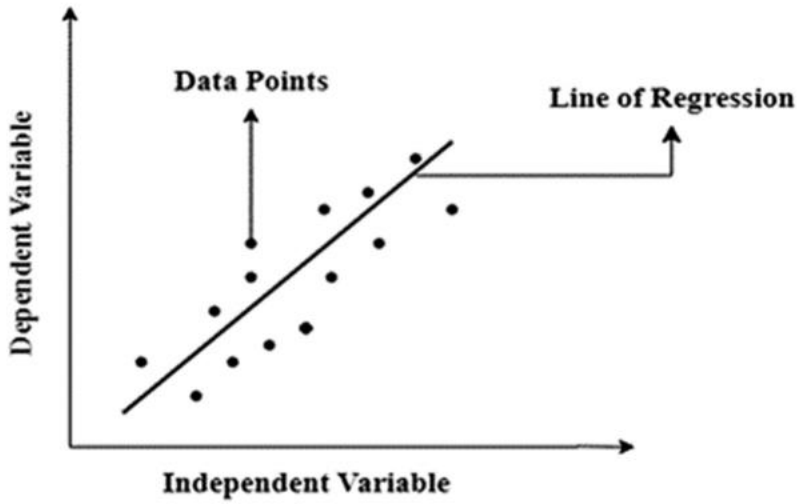
a. **Nhiệm vụ Phân loại (Classification Task)**: Các nhiệm vụ phân loại là những nhiệm vụ đòi hỏi ứng dụng các thuật toán ML để học cách gán một nhãn lớp cho các thể hiện trong miền vấn đề [37]. Một ví dụ đơn giản là phân loại email là "thư rác" hoặc "không phải thư rác". Các thuật toán phân loại phổ biến nhất là hồi quy logistic, Naive Bayes, KNN và SVM.
b. **Nhiệm vụ Hồi quy (Regression Task)**: Hồi quy đại diện cho một phương pháp ML có giám sát để dự báo các giá trị liên tục. Mục đích cuối cùng của thuật toán hồi quy là vẽ đường hoặc đường cong phù hợp nhất giữa các dữ liệu. Phương sai, độ chệch và lỗi là ba số liệu chính được sử dụng để đánh giá mô hình hồi quy đã được đào tạo [38]. Các thuật toán hồi quy phổ biến nhất là Hồi quy tuyến tính, Hồi quy Ridge, Hồi quy Lasso, Hồi quy đa thức và Hồi quy tuyến tính Bayes. Một cách rộng hơn, ML được chia thành các loại sau: Thuật toán học có giám sát (Supervised learning), Thuật toán học không giám sát (Unsupervised learning algorithms) và Thuật toán học tăng cường (Reinforcement learning algorithms) (Hình 6.5).



HÌNH 6.5 Các loại thuật toán ML khác nhau. (Hình minh họa sơ đồ phân loại các thuật toán Học máy thành Học có giám sát (Supervised) - bao gồm Hồi quy (Regression) và Phân loại (Classification) với các thuật toán cụ thể; Học không giám sát (Unsupervised) - bao gồm Phân cụm (Clustering) và Phân tích Liên kết (Association Analysis) với các thuật toán cụ thể; và Học tăng cường (Reinforcement) - được đánh dấu là Liên tục (Continous))

6.4.1 Mô hình Hồi quy Tuyến tính

Kỹ thuật hồi quy tuyến tính là một trong những phương pháp ML cơ bản và được sử dụng rộng rãi nhất. Đây là một phương pháp thống kê để thực hiện phân tích dự đoán. Hồi quy tuyến tính dự báo các biến liên tục/thực hoặc biến định lượng

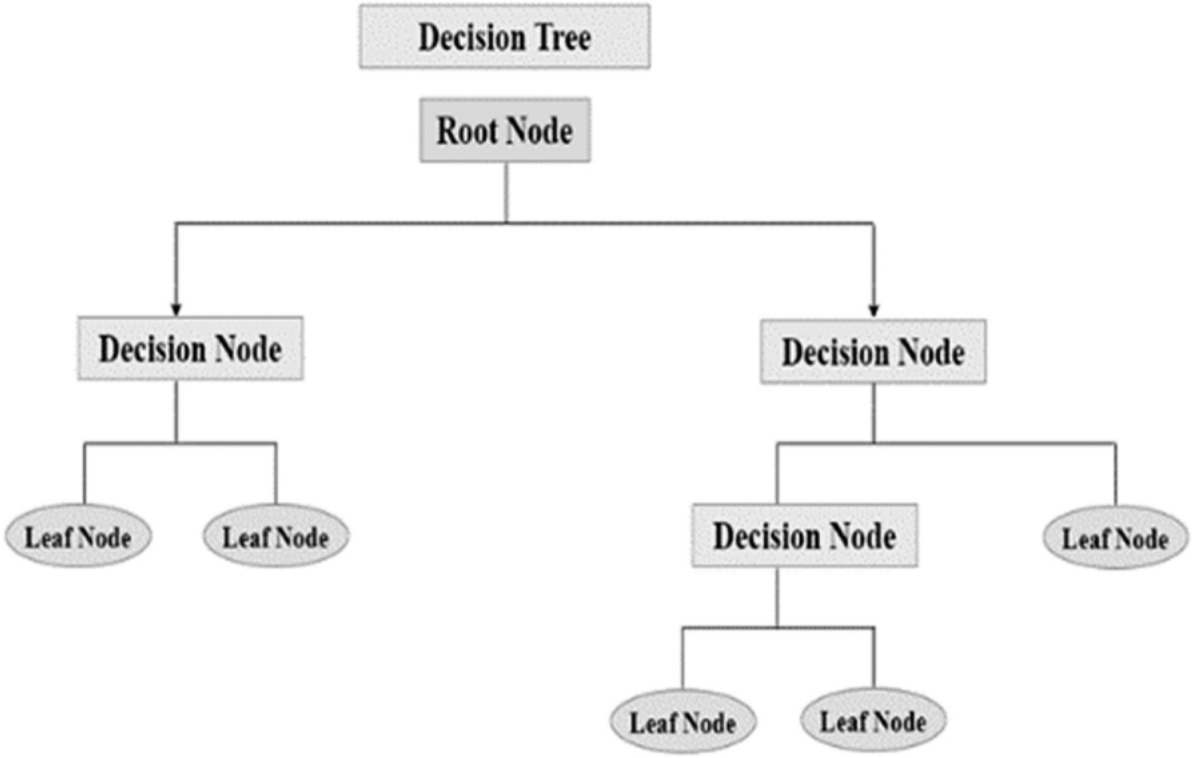


HÌNH 6.6 Hồi quy tuyến tính (Hình minh họa một tập hợp điểm dữ liệu và một đường thẳng phù hợp nhất thể hiện mối quan hệ tuyến tính giữa biến độc lập X và biến phụ thuộc Y)

như doanh số, lương, tuổi, giá sản phẩm, v.v. Kỹ thuật hồi quy tuyến tính chứng minh mối quan hệ tuyến tính giữa một biến phụ thuộc ( ) và một hoặc nhiều biến độc lập ((X_1)), do đó có tên như vậy. Bởi vì hồi quy tuyến tính thể hiện một mối quan hệ tuyến tính, nó xác định giá trị của biến phụ thuộc thay đổi như thế nào liên quan đến giá trị của biến độc lập [38]. Mô hình hồi quy tuyến tính biểu diễn mối liên hệ giữa các biến bằng cách sử dụng một đường thẳng nghiêng. Về mặt toán học, hồi quy tuyến tính có thể được biểu diễn như: (= b_0 + b_1 X_1), trong đó (=) Biến Phụ thuộc; (b_0 =) Điểm cắt Y (Y-Intercept); (b_1 =) Hệ số Độ dốc (Slope Coefficient); (X_1 =) Biến Độc lập (Hình 6.6).

6.4.2 Mô hình Cây quyết định và Rừng ngẫu nhiên

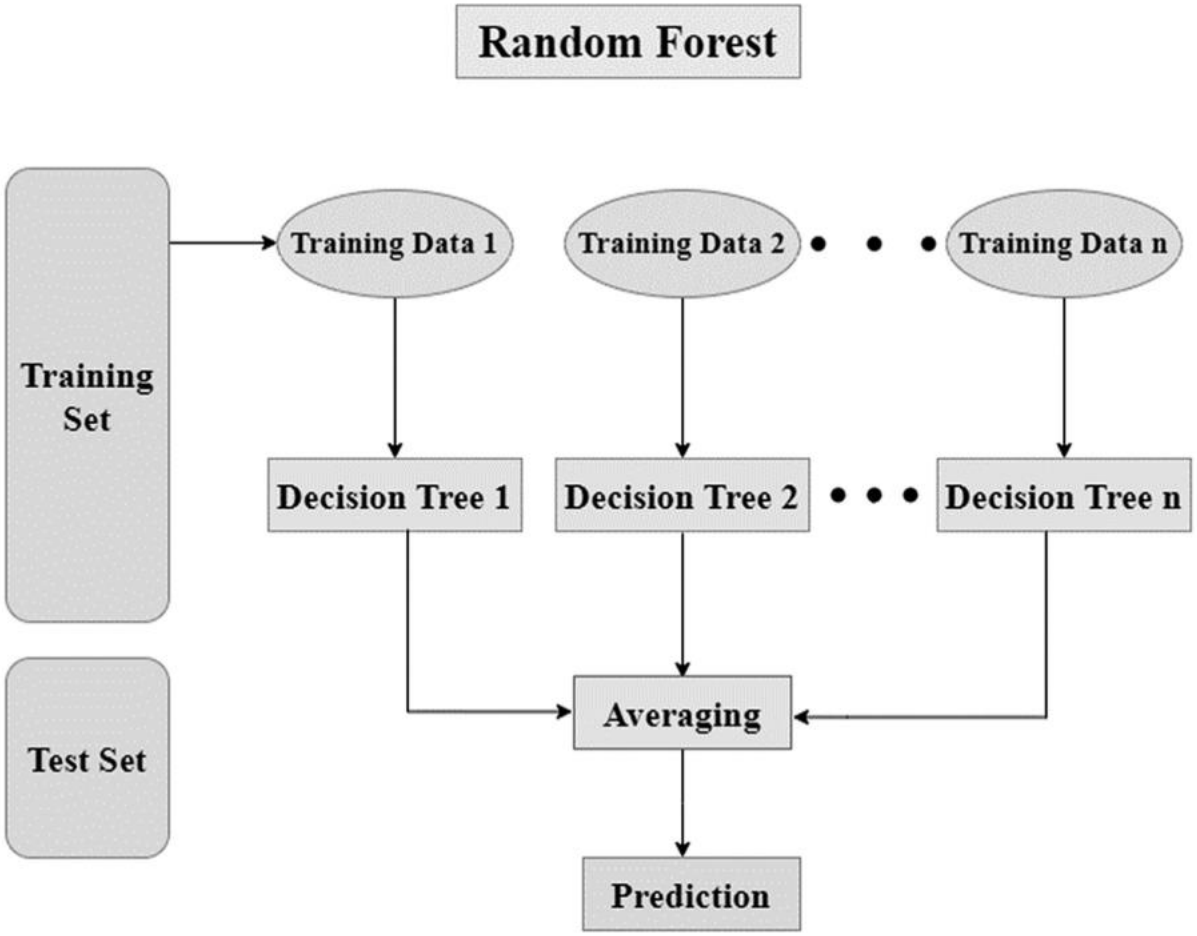
Cây quyết định (Decision Tree): Một CT là một phương pháp học có giám sát có thể được sử dụng để giải quyết các vấn đề phân loại và hồi quy, mặc dù nó chủ yếu được sử dụng để giải quyết các vấn đề phân loại. Nó hoạt động như một bộ phân loại dạng cây, với các nút lõi đại diện cho các thuộc tính tập dữ liệu, các nhánh đại diện cho các quy tắc quyết định và mỗi nút lá đại diện cho một kết quả (Rokach & Maimon, n.d.). Có hai loại nút trong một CT: nút quyết định và nút lá. Các nút quyết định được sử dụng để đưa ra quyết định và có nhiều nhánh, trong khi các nút lá biểu thị kết quả của những quyết định đó và không phân nhánh thêm nữa. Bên trong một CT, thuật toán bắt đầu quá trình của nó tại nút gốc, tiến tới việc dự đoán lớp cho một tập dữ liệu được cung cấp. Quy trình này bao gồm việc kiểm tra các giá trị thuộc tính của nút gốc so với các thuộc tính của bản ghi tập dữ liệu thực tế, xác định nhánh thích hợp để theo dõi và tiến đến nút tiếp theo dựa trên kết quả của sự so sánh này.



HÌNH 6.7 Cây quyết định. (Hình minh họa cấu trúc cây với Nút gốc (Root Node), các Nút quyết định (Decision Node) và các Nút lá (Leaf Node))

Thuật toán CART, viết tắt của thuật toán cây phân loại và hồi quy (classification and regression tree algorithm), được sử dụng để hình thành một cây (Hình 6.7).

Mô hình Rừng ngẫu nhiên (Random Forest Model): RF là một thuật toán ML nổi tiếng có nền tảng vững chắc trong lĩnh vực học có giám sát. Nó hữu ích trong lĩnh vực ML cho cả các ứng dụng phân loại và hồi quy. Phương pháp tiếp cận này dựa trên khái niệm học tập tập hợp (ensemble learning), một chiến lược bao gồm việc kết hợp nhiều bộ phân loại để giải quyết các vấn đề phức tạp và cải thiện hiệu suất của mô hình. Một bộ phân loại "RF", như tên gọi cho thấy, là một bộ phân loại bao gồm nhiều CT được xây dựng trên các tập hợp con khác nhau của tập dữ liệu được cung cấp và nó sử dụng tiềm năng dự đoán tổng hợp của chúng để cải thiện độ chính xác của tập dữ liệu. Thay vì chỉ dựa vào một CT duy nhất, RF tổng hợp các dự đoán từ mỗi cây và sau đó tạo ra một dự đoán cuối cùng dựa trên biểu quyết đa số của các phép chiếu này. Sự hiện diện của số lượng cây lớn hơn bên trong rừng góp phần cải thiện độ chính xác và bảo vệ chống lại việc trang bị quá mức (overfitting). Bởi vì RF kết hợp nhiều cây để dự đoán lớp/đầu ra của tập dữ liệu, một số CT có thể dự đoán đầu ra chính xác trong khi những cây khác có thể không (Hình 6.8).



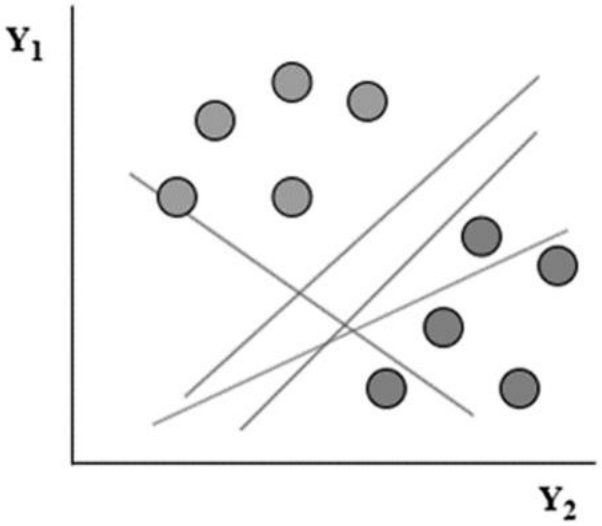
HÌNH 6.8 Bộ phân loại Rừng ngẫu nhiên (RF classifier). (Hình minh họa quy trình: Tập Huấn luyện (Training Set) -> được lấy mẫu thành Dữ liệu Huấn luyện 1, 2, … n -> mỗi tập dữ liệu con được dùng để xây dựng Cây Quyết định 1, 2, … n -> Tập Kiểm tra (Test Set) được đưa qua từng cây -> Kết quả dự đoán từ các cây được Tổng hợp (Averaging) hoặc Biểu quyết (Voting) để ra Dự đoán cuối cùng (Prediction))

6.4.3 Máy vectơ hỗ trợ

Máy vectơ hỗ trợ (Support Vector Machine - SVM) là một thuật toán ML có giám sát có thể được sử dụng cho cả các tác vụ phân loại cũng như hồi quy. Trong khi SVM có thể xử lý các vấn đề hồi quy,

nó phù hợp nhất cho các công việc phân loại. Mục đích chính của nó là tìm siêu phẳng (hyperplane) tối ưu bên trong một không gian N chiều có khả năng phân loại chính xác các điểm dữ liệu trong không gian đặc trưng. Kích thước của siêu phẳng được xác định bởi số lượng đặc trưng đầu vào và được thiết kế để tối đa hóa khoảng cách giữa các điểm gần nhất của các lớp riêng biệt. Khi số lượng đặc trưng vượt quá ba, việc hình dung siêu phẳng trở nên khó khăn. SVM là một kỹ thuật ML mạnh mẽ được sử dụng cho các ứng dụng như phân loại tuyến tính hoặc phi tuyến, hồi quy và thậm chí cả xác định ngoại lai.

Phân loại văn bản, phân loại hình ảnh, phát hiện thư rác, nhận dạng chữ viết tay, phân tích biểu hiện gen, phát hiện khuôn mặt và phát hiện bất thường chỉ là một số ít các tác vụ mà SVM được sử dụng. Do khả năng xử lý dữ liệu chiều cao và tính đến các tương tác phi tuyến, tính linh hoạt và hiệu quả của chúng thể hiện qua một loạt các ứng dụng. Khi cố gắng khám phá siêu phẳng phân tách lớn nhất trong số nhiều lớp trong đặc trưng mục tiêu, hiệu quả của các thuật toán SVM là rõ ràng. Hãy xem xét hai biến độc lập (Y_1) và (Y_2), và một biến phụ thuộc, đó là một vòng tròn màu xanh lá cây hoặc một vòng tròn màu vàng.



HÌNH 6.9 Các điểm dữ liệu có thể phân tách tuyến tính. (Hình minh họa một biểu đồ phân tán với hai nhóm điểm dữ liệu (ví dụ: hình tròn màu xanh và vàng) có thể được phân tách bằng một đường thẳng (siêu phẳng))

Như thấy trong Hình 6.9, tồn tại vô số đường (siêu phẳng của chúng ta trong trường hợp này là một đường thẳng vì chúng ta chỉ có hai đặc trưng đầu vào, (Y_1) và (Y_2)), do đó chia các điểm dữ liệu của chúng ta và thực hiện phân loại giữa các vòng tròn màu đỏ và xanh dương. Mekni et al. sử dụng thuật toán SVM như một phương pháp học có giám sát để ưu tiên hóa tiềm năng mới của chất ức chế protease chính của SARS-CoV-2 và giải thích cách thức hoạt động của SVM [39].

6.4.4 Mô hình Mạng nơ-ron

Một mạng nơ-ron (Neural Network - NN) là một công nghệ AI cho phép máy tính diễn giải dữ liệu giống như bộ não con người. Nó được phân loại trong ML, đặc biệt là một nhánh được gọi là học sâu (deep learning). Phương pháp này sắp xếp các nút hoặc nơ-ron được kết nối thành các cấu trúc lớp giống như bộ não con người. Thiết kế này tạo ra một hệ thống thích ứng trong đó máy tính có thể học từ các lỗi sai và dần dần cải thiện hiệu suất của chúng. Kết quả là, các mạng nơ-ron nhân tạo (Artificial Neural Networks - ANN) cố gắng thực hiện các nhiệm vụ phức tạp với độ chính xác cao hơn, chẳng hạn như

tóm tắt tài liệu hoặc nhận dạng khuôn mặt. Có nhiều ứng dụng của NN, một vài ứng dụng trong số đó được liệt kê tiếp theo:

Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing - NLP): NLP là khả năng phân tích văn bản do con người tạo ra theo cách bắt chước sự hiểu biết ngôn ngữ của con người. Để máy tính trích xuất thông tin chi tiết và sự hiểu biết từ dữ liệu văn bản và văn bản, NN đóng một vai trò quan trọng. NLP có nhiều ứng dụng thực tiễn, chẳng hạn như sau:

- Tăng cường sức mạnh cho các đại lý ảo tự động và chatbot.
- Tổ chức và phân loại nội dung văn bản tự động.
- Cho phép phân tích tình báo kinh doanh đối với các tài liệu lớn như email và biểu mẫu.
- Lập chỉ mục các thuật ngữ chính thể hiện thái độ, chẳng hạn như các bình luận tích cực và tiêu cực trên mạng xã hội.
- Tạo bản tóm tắt tài liệu và các bài luận về các chủ đề nhất định.

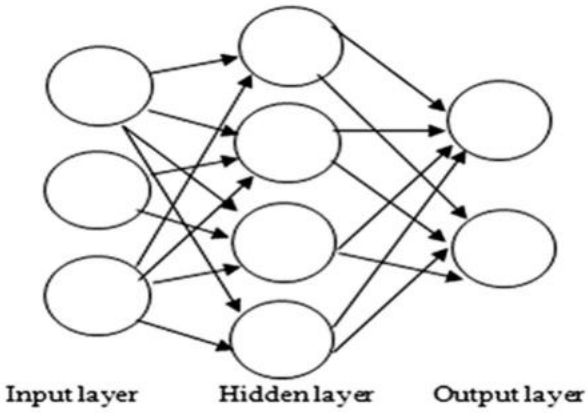
Thị giác Máy tính (Computer Vision): Thị giác máy tính đề cập đến khả năng của máy tính để trích xuất thông tin và hiểu nội dung trực quan từ hình ảnh và video. Sử dụng NN, máy tính hiện có khả năng phân biệt và phân loại hình ảnh theo cách giống như con người. Thị giác máy tính có các ứng dụng thực tiễn trong nhiều lĩnh vực khác nhau, bao gồm những lĩnh vực sau:

- Nhận dạng hình ảnh trong các phương tiện tự lái cho phép chúng nhận ra biển báo đường bộ và các phương tiện khác trên đường
- Kiểm duyệt nội dung, liên quan đến việc tự động hóa việc xác định và loại bỏ nội dung có khả năng nguy hiểm hoặc không phù hợp khỏi bộ sưu tập hình ảnh và video
- Nhận dạng khuôn mặt để nhận ra các đặc điểm khuôn mặt cụ thể như mắt mở, đeo kính hoặc có râu
- Gắn nhãn hình ảnh cho các đặc điểm, chẳng hạn như logo công ty, quần áo, thiết bị an toàn và các thông tin hình ảnh khác

Mạng nơ-ron Tích chập (Convolutional Neural Networks - CNN): CNN là một loại mạng nơ-ron nhiều lớp được thiết kế đặc biệt để xử lý đầu vào hai chiều, chẳng hạn như hình ảnh và video. CNN được lấy cảm hứng từ các công trình trước đây về mạng nơ-ron trễ thời gian (time-delay neural networks - TDNN), các mạng này tối ưu hóa tính toán học bằng cách chia sẻ trọng số trong chiều thời gian và đặc biệt phù hợp cho các ứng dụng xử lý dữ liệu giọng nói và chuỗi thời gian [40]. CNN là một cột mốc quan trọng trong lĩnh vực học sâu bằng cách đào tạo hiệu quả và mạnh mẽ các hệ thống phân cấp lớp sâu. Các mạng này sử dụng một phương pháp tiếp cận kiến trúc tận dụng các tương quan

không gian và thời gian, giảm thiểu số lượng tham số cần học và dẫn đến hiệu suất tốt hơn so với đào tạo lan truyền ngược truyền thống (traditional feed-forward back-propagation training) [41].

CNN được phân biệt bởi nhu cầu tiền xử lý dữ liệu thấp của chúng. Hình ảnh được chia thành các phần nhỏ trong CNN, các phần này đóng vai trò là đầu vào cho lớp thấp nhất của cấu trúc phân cấp. Thông tin đi qua nhiều cấp độ mạng, với mỗi lớp sử dụng các kỹ thuật lọc kỹ thuật số để trích xuất các thuộc tính dữ liệu quan trọng. Phương pháp này cung cấp cho mạng một số khả năng kháng cự với sự dịch chuyển, thu phóng và xoay, nhờ vào trường tiếp nhận cục bộ (local receptive field), cung cấp cho các nơ-ron hoặc đơn vị xử lý quyền truy cập vào các thuộc tính cơ bản, chẳng hạn như các cạnh và góc được căn chỉnh.



HÌNH 6.10 Một mô hình Mạng nơ-ron nhân tạo (ANN model). (Hình minh họa kiến trúc của một ANN với Lớp đầu vào (Input Layer), một hoặc nhiều Lớp ẩn (Hidden Layers) và Lớp đầu ra (Output Layer), các nơ-ron được kết nối giữa các lớp)

Mạng nơ-ron nhân tạo (Artificial Neural Network - ANN): Một ANN là một mạng lưới các nút được kết nối từ xa, giống như mạng lưới khổng lồ các nơ-ron trong não, như được thấy trong Hình 6.10. Mỗi nút hình tròn đại diện cho một nơ-ron nhân tạo [42] và mỗi mũi tên tượng trưng cho một liên kết từ đầu ra của nơ-ron này đến đầu vào của nơ-ron khác, (hy vọng rằng) nên có khả năng xử lý điều này. Một ANN được tạo thành từ ba loại lớp: đầu vào, ẩn và đầu ra. Lớp ẩn kết nối lớp đầu vào và lớp đầu ra.

6.4.5 Các Mô hình Tập hợp (Ensemble Models)

Học tập tập hợp (Ensemble learning) là một siêu chiến lược toàn diện trong ML nhằm mục đích cải thiện độ chính xác dự đoán bằng cách kết hợp các dự đoán từ nhiều mô hình. Mặc dù có vẻ như có vô số các mô hình tập hợp có thể được xây dựng cho mô hình hóa dự đoán, ba phương pháp tiếp cận thống trị lĩnh vực học tập tập hợp. Trên thực tế, các quy trình này đã phát triển thành toàn bộ các ngành nghiên cứu, làm nảy sinh vô số các kỹ thuật chuyên biệt trong mỗi ngành. Bagging, stacking và boosting là ba lớp chính

của các phương pháp học tập tập hợp, và điều cốt yếu là phải hiểu từng phương pháp tiếp cận và bao gồm nó trong dự án mô hình hóa dự đoán.

6.5 NGHIÊN CỨU TÌNH HUỐNG

6.5.1 Dự đoán Năng suất Cây trồng cho một Loại Cây trồng Cụ thể

Shahram Rezapour [18] và phần còn lại của nhóm của ông đã hoàn thành một nghiên cứu tập trung vào việc sử dụng các phương pháp tiếp cận ML để dự đoán năng suất nông nghiệp ở các vùng khô cằn và bán khô cằn. Mục tiêu chính của họ là giải quyết các thách thức về an ninh lương thực

đặc biệt liên quan đến tác động của biến đổi khí hậu đối với sản xuất lương thực. Nghiên cứu tình huống trong vấn đề này là về ước tính sản lượng cây chickpea ở tỉnh Kermanshah [43], nằm ở Iran. Các nhà nghiên cứu đã sử dụng dữ liệu viễn thám và thông tin khí tượng từ các trạm quan trắc để xây dựng các mô hình dự đoán như là các đầu vào quan trọng trong kỹ thuật của họ. Họ đã sử dụng các kỹ thuật ML như hồi quy vectơ hỗ trợ (Support Vector Regression - SVR) [44], RF [45] và cây cực kỳ ngẫu nhiên (Extreme Randomized Trees - ERT) để phân tích dữ liệu và đưa ra các ước tính chính xác về năng suất nông nghiệp nhờ nước mưa (rainfed agricultural productivity).

Các phát hiện nghiên cứu chứng minh rằng, khi đánh giá kịch bản kết hợp tối ưu (Optimum Combination - OC), chiến lược RF tạo ra ít lỗi nhất trong số nhiều phương pháp tiếp cận được nghiên cứu. Hơn nữa, trong tình huống này, kỹ thuật RF chỉ ra độ ẩm bề mặt, độ ẩm không khí tối thiểu và độ ẩm dưới bề mặt là các thông số quan trọng nhất cho các dự báo chính xác vào tháng Ba, tháng Một và tháng Một, tương ứng. Hơn nữa, các nhà nghiên cứu đề nghị rằng các nghiên cứu trong tương lai nên xem xét các loại cây trồng khác nhau, hệ thống dự đoán và các khu vực địa lý khác ngoài cây chickpea, mở rộng phạm vi để bao gồm các sản phẩm nông nghiệp khác. Tóm lại, công trình của Rezapour và các đồng nghiệp của ông chứng minh hiệu quả của các thuật toán ML để dự đoán sản lượng nông nghiệp nhờ nước mưa. Nghiên cứu của họ cung cấp những hiểu biết hữu ích về việc dự đoán sản lượng cây chickpea ở tỉnh Kermanshah, Iran, đồng thời nhấn mạnh sự cần thiết của việc thu thập và phân tích dữ liệu chính xác trong việc đưa ra các quyết định nông nghiệp sáng suốt [46]. Những phát hiện này đóng góp đáng kể vào các chương trình liên tục nhằm đảm bảo an ninh lương thực ở các nước khô cằn và bán khô cằn.

6.5.2 Đối phó với Các Sự kiện Thời tiết Cực đoan

Nghiên cứu của [47] là về đánh giá và dự báo tình trạng hạn hán ở Jaisalmer, Ấn Độ, sử dụng các phương pháp tiếp cận dựa trên dữ liệu. Nó sử dụng các kỹ thuật ML, đặc biệt là phương pháp không gian con ngẫu nhiên (Random Subspace - RSS), để tính toán chỉ số chuẩn hóa lượng mưa (Standardized Precipitation Index - SPI) trong các khoảng thời gian khác nhau. Dữ liệu minh họa tính hữu ích của mô hình RSS-M5P trong việc nắm bắt xu hướng SPI hàng tháng và cung cấp các dự đoán SPI chính xác ở một số quy mô, bao gồm 3, 6 và 9 tháng.

Những phát hiện của nghiên cứu này có ý nghĩa thực tiễn đáng kể cho nhiều ngành công nghiệp, bao gồm nông nghiệp, thủy văn và khí tượng. Các mô hình dự báo hạn hán do các nhà nghiên cứu tạo ra rất hữu ích cho các hoạt động như tối ưu hóa lịch trình tưới tiêu, mô hình hóa hành vi cây trồng, quản lý tài nguyên nước, vận hành hồ chứa và cải thiện dự báo thời tiết. Nó nhấn mạnh tầm quan trọng của việc phát triển các chính sách quản lý hạn hán toàn diện. Tóm lại, nghiên cứu tình huống này tập trung vào việc sử dụng các mô hình dựa trên dữ liệu để phân tích và dự đoán hạn hán ở Jaisalmer, Ấn Độ [48]. Nó tính toán SPI trên nhiều thang đo thời gian bằng cách sử dụng ML và phương pháp RSS. Những mô hình này có ý nghĩa thực tiễn trong nhiều ngành công nghiệp và có thể hỗ trợ phát triển các thực hành nông nghiệp thông minh thích ứng với khí hậu.

6.6 THẢO LUẬN

Việc sử dụng các thuật toán ML trong dự đoán sản xuất cây trồng có những tác động sâu rộng đến môi trường nông nghiệp. Chúng ta giải phóng tiềm năng cho các dự báo sản xuất chính xác và kịp thời hơn bằng cách khai thác các phương pháp tính toán tiên tiến này, cung cấp cho nông dân và các bên liên quan thông tin thiết yếu về hiệu suất cây trồng của họ. Điều này dẫn đến việc ra quyết định tốt hơn, tối ưu hóa tài nguyên và giảm thiểu rủi ro. Hơn nữa, khả năng dự báo được cải thiện do thời tiết, sâu bệnh hoặc bệnh tật giúp tăng cường an ninh lương thực và ổn định kinh tế [49]. Khi các mô hình ML cải thiện độ chính xác dự báo của chúng, ngành nông nghiệp sẽ trở nên kiên cường và bền vững hơn, ảnh hưởng đến sản xuất lương thực toàn cầu và đảm bảo nguồn cung cấp lương thực an toàn hơn cho dân số ngày càng tăng của chúng ta.

Một số trở ngại và hạn chế phải được xem xét khi đi sâu vào lĩnh vực các thuật toán ML cho các dự báo năng suất nông nghiệp. Một trong những vấn đề quan trọng nhất là chất lượng và tính sẵn có của dữ liệu [50], vì các dự báo thành công phụ thuộc phần lớn vào các tập dữ liệu đầy đủ bao gồm các thông số như thời tiết, điều kiện đất đai và năng suất lịch sử. Hơn nữa, khả năng diễn giải mô hình vẫn là một thách thức, thúc đẩy các nỗ lực nghiên cứu để làm cho các thuật toán này trở nên dễ hiểu và dễ tiếp cận hơn cho nông dân và các bên liên quan. Một vấn đề khác cần xem xét là khả năng mở rộng, điều này đặc biệt quan trọng trong các môi trường bị hạn chế tài nguyên. Để giải quyết những vấn đề này, nghiên cứu trong tương lai nên tập trung vào tích hợp dữ liệu đa nguồn, các hệ thống giám sát thời gian thực có thể thích ứng với các điều kiện thay đổi và các giải pháp ML được điều chỉnh cho các bối cảnh tài nguyên thấp. ML trong các dự báo năng suất cây trồng có các ứng dụng thực tiễn trong nông nghiệp chính xác, nơi nông dân có thể tối ưu hóa phân bổ tài nguyên, bảo hiểm và đánh giá rủi ro, lập kế hoạch tài chính và quản lý chuỗi cung ứng, cải thiện hậu cần và giảm thiểu lãng phí. Khi lĩnh vực này phát triển, nó có tiềm năng cách mạng hóa các hoạt động nông nghiệp và đóng góp đáng kể vào an ninh lương thực toàn cầu. Nghiên cứu trong tương lai nên tập trung vào giao diện của ML và thích ứng với biến đổi khí hậu, cho phép nông nghiệp điều chỉnh theo các kiểu thời tiết và hoàn cảnh môi trường đang thay đổi. Các mô hình AI dễ diễn giải hơn

sẽ thúc đẩy sự tin tưởng và tính hữu ích, trong khi những tiến bộ liên tục trong các phương pháp thu thập dữ liệu, công nghệ cảm biến và các công cụ nông nghiệp chính xác sẽ rất quan trọng. Cuối cùng, những nỗ lực này sẽ định hình tương lai của nông nghiệp bằng cách thúc đẩy các thực hành bền vững và duy trì an ninh lương thực trong một thế giới không ngừng thay đổi.

6.7 KẾT LUẬN

Ngành nông nghiệp phải áp dụng công nghệ mới để đáp ứng nhu cầu của dân số toàn cầu ngày càng tăng. Hơn nữa, lời khuyên kịp thời cho các dự báo sản lượng cây trồng là rất quan trọng đối với nông dân trong việc lập kế hoạch sản xuất hiệu quả. Các khuôn khổ ML cung cấp những hiểu biết đáng kể bằng cách xử lý các tập dữ liệu lớn và phân tích dữ liệu kết quả. Những công cụ này tạo điều kiện thuận lợi cho việc tạo ra các mô hình đại diện cho các tương tác giữa nhiều yếu tố và hoạt động. Hơn nữa, chúng cho phép dự đoán các sự kiện trong tương lai trong các bối cảnh nhất định. Nghiên cứu hiện tại tập trung vào một loạt các tiêu chí được sử dụng trong các nghiên cứu được lựa chọn, với sự nhấn mạnh đặc biệt vào tính sẵn có của dữ liệu và phạm vi nghiên cứu. Phần lớn các tác phẩm được trích dẫn khám phá các dự đoán sản xuất nông nghiệp bằng cách sử dụng các thuật toán ML; tuy nhiên, chúng khác nhau về mặt sự đa dạng rộng lớn của các đặc trưng được sử dụng. Những cuộc điều tra này cũng tiết lộ sự khác biệt về loại cây trồng, khu vực địa lý và cường độ. Các đặc trưng được sử dụng được xác định bởi khả năng tiếp cận của tập dữ liệu và các mục tiêu nghiên cứu. Mặc dù khó có thể xác định kỹ thuật tốt nhất cuối cùng dựa trên dữ liệu hiện tại, nhưng việc sử dụng rộng rãi một số thuật toán ML và hiệu suất đầy hứa hẹn của chúng là đáng chú ý. Cụ thể, các kiến trúc ML truyền thống như hồi quy tuyến tính, RF và NN cho thấy tiềm năng. Một số mô hình học sâu, chẳng hạn như mạng nơ-ron sâu (Deep Neural Networks - DNN), CNN và bộ nhớ ngắn hạn dài (Long Short-Term Memory - LSTM), được sử dụng trong các ước tính năng suất cây trồng ngoài các kỹ thuật này. Các nghiên cứu trong tương lai nên khám phá các thuật toán lựa chọn đặc trưng kết hợp với các mô hình hiệu suất cao hiện có để đưa ra kết luận rõ ràng về mô hình hoạt động tốt nhất.

TÀI LIỆU THAM KHẢO

[1] D. Elavarasan and P. M. D. Vincent, “Crop yield prediction using deep reinforcement learning model for sustainable agrarian applications,” , vol. 8, pp. 86886–86901, 2020.

[2] J. Huang et al., “Assimilation of remote sensing into crop growth models: Current status and perspectives,” *Agric. For. Meteorol.*, vol. 276, p. 107609, 2019.

[3] S. Li, S. Peng, W. Chen, and X. Lu, “INCOME: Practical land monitoring in precision agriculture with sensor networks,” *Comput. Commun.*, vol. 36, no. 4, pp. 459-467, 2013.

[4] A. Singh, B. Ganapathysubramanian, A. K. Singh, and S. Sarkar, “Machine learning for high-throughput stress phenotyping in plants,” *Trends Plant Sci.*, vol. 21, no. 2, pp. 110-124, 2016.

[5] A. Chlingaryan, S. Sukkarieh, and B. Whelan, “Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture: A review,” *Comput. Electron. Agric.*, vol. 151, pp. 61-69, 2018.

[6] D. Elavarasan, D. R. Vincent, V. Sharma, A. Y. Zomaya, and K. Srinivasan, “Forecasting yield by integrating agrarian factors and machine learning models: A survey,” *Comput. Electron. Agric.*, vol. 155, pp. 257-282, 2018.

[7] K. L. Chong, K. D. Kanniah, C. Pohl, and K. P. Tan, “A review of remote sensing applications for oil palm studies,” *Geo-Spatial Inf. Sci.*, vol. 20, no. 2, pp. 184-200, 2017.

[8] L. J. Young, “Agricultural crop forecasting for large geographical areas,” *Annu. Rev. Stat. its Appl.*, vol. 6, pp. 173-196, 2019.

[9] T. Van Klompenburg, A. Kassahun, and C. Catal, “Crop yield prediction using machine learning: A systematic literature review,” *Comput. Electron. Agric.*, vol. 177, p. 105709, 2020.

[10] L. S. Woittiez, M. T. Van Wijk, M. Slingerland, M. Van Noordwijk, and K. E. Giller, “Yield gaps in oil palm: A quantitative review of contributing factors,” *Eur. J. Agron.*, vol. 83, pp. 57-77, 2017.

[11] K. G. Liakos, P. Busato, D. Moshou, S. Pearson, and D. Bochtis, “Machine learning in agriculture: A review,” *Sensors*, vol. 18, no. 8, p. 2674, 2018.

[12] B. Li, J. Lecourt, and G. Bishop, “Advances in non-destructive early assessment of fruit ripeness towards defining optimal time of harvest and yield prediction–A review,” *Plants*, vol. 7, no. 1, p. 3, 2018.

[13] G. Nemomsa, “Comparative analytics and predictive modeling of student performance through data mining techniques,” *IUP J. Comput. Sci. Forthcom.*, 2018. doi: 10.2139/ssrn.3382511

[14] S. Venkatakrishnan, A. Kaushik, and J. K. Verma, “Sentiment analysis on Google Play Store data using deep learning,” in Johri, P., Verma, J., and Paul, S. (eds) *Applications of Machine Learning. Algorithms for Intelligent Systems*. Springer, Singapore, 2020. doi: 10.1007/978-981-15-3357-0_2

[15] X. Wang, W. Hu, K. Li, L. Song, and L. Song, “Modeling of soft sensor based on DBN-ELM and its application in measurement of nutrient solution composition for soil-less culture,” in *2018 IEEE International Conference of Safety Produce Informatization (IICSPI)*, 2018, pp. 93-97.

[16] S. K. Sharma, D. P. Sharma, and J. K. Verma, “Study on machine-learning algorithms in crop yield predictions specific to indian agricultural contexts,” *2021 Int. Conf. Comput. Perform. Eval. ComPE 2021*, no. April 2022, pp. 155-166, 2021. doi: 10.1109/ComPE53109.2021.9752260

[17] P. Muruganantham, S. Wibowo, S. Grandhi, N. H. Samrat, and N. Islam, "A systematic literature review on crop yield prediction with deep learning and remote sensing," *Remote Sens.*, vol. 14, no. 9, p. 1990, 2022.

[18] S. Rezapour et al., "Forecasting rainfed agricultural production in arid and semi-arid lands using learning machine methods: A case study," *Sustainability*, vol. 13, no. 9, 2021. doi: 10.3390/su13094607

[19] M. Chinlampianga, "Traditional knowledge, weather prediction and bioindicators: A case study in Mizoram, Northeastern India," *Indian J. Tradit. Knowl.*, vol. 10, no. 1, pp. 207-211, 2011.

[20] A. Cravero, S. Pardo, S. Sepulveda, and L. Munoz, "Challenges to use machine learning in agricultural big data: A systematic literature review," *Agronomy*, vol. 12, no. 3, p. 748, 2022.

[21] F. Xiao, H. Wang, Y. Xu, and R. Zhang, "Fruit detection and recognition based on deep learning for automatic harvesting: An overview and review," *Agronomy*, vol. 13, no. 6, p. 1625, 2023.

[22] S. Del Rio, V. Lopez, J. M. Benitez, and F. Herrera, "On the use of mapreduce for imbalanced big data using random forest," *Inf. Sci. (Ny).*, vol. 285, pp. 112-137, 2014.

[23] C. A. Salma, B. Tekinerdogan, and I. N. Athanasiadis, "Domain-driven design of big data systems based on a reference architecture," in Ivan Mistrik (ed) *Software Architecture for Big Data and the Cloud*. Elsevier, 2017, pp. 49-68.

[24] P. Johri, J. K. Verma, and S. Paul, *Applications of Machine Learning*. Springer, 2020.

[25] M. J. M. Cheema, T. Iqbal, A. Daccache, S. Hussain, and M. Awais, "Precision agriculture technologies: Present adoption and future strategies," in *Precision Agriculture*. Elsevier, 2023, pp. 231-250.

[26] J. Sun, W. Gan, H.-C. Chao, and P. S. Yu, "Metaverse: Survey, applications, security, and opportunities," vol. 1, no. 1, pp. 1-35, 2022, [Online]. Available: http://arxiv.org/abs/2210.07990

[27] S. Agarwal and S. Tara; "A hybrid approach for crop yield prediction using machine learning and deep learning algorithms," *J. Phys. Conf. Ser.*, vol. 1714, no. 1, p. 12012, 2021.

[28] M. Dhanaraju, P. Chenniappan, K. Ramalingam, S. Pazhanivelan, and R. Kaliaperumal, "Smart farming: Internet of Things (IoT)-based sustainable agriculture," *Agriculture*, vol. 12, no. 10, p. 1745, 2022.

[29] A. Haghverdi, R. A. Washington-Allen, and B. G. Leib, “Prediction of cotton lint yield from phenology of crop indices using artificial neural networks,” *Comput. Electron. Agric.*, vol. 152, pp. 186-197, 2018.

[30] P.-F. Kuo, T.-E. Huang, and I. G. B. Putra, “Comparing kriging estimators using weather station data and local greenhouse sensors,” *Sensors*, vol. 21, no. 5, p. 1853, 2021.

[31] S. Salloum, J. Z. Huang, and Y. He, “Exploring and cleaning big data with random sample data blocks,” *J. Big Data*, vol. 6, pp. 1-28, 2019.

[32] E. Cho, T.-W. Chang, and G. Hwang, “Data preprocessing combination to improve the performance of quality classification in the manufacturing process,” *Electronics*, vol. 11, no. 3, p. 477, 2022.

[33] P. Nevavuori, N. Narra, and T. Lipping, “Crop yield prediction with deep convolutional neural networks,” *Comput. Electron. Agric.*, vol. 163, p. 104859, 2019.

[34] M. Rashid, B. S. Bari, Y. Yusup, M. A. Kamaruddin, and N. Khan, “A comprehensive review of crop yield prediction using machine learning approaches with special

[35] M. Kuradusenge et al.,”Crop yield prediction using machine learning models: Case of Irish potato and maize,” *Agriculture*, vol. 13, no. 1, p. 225, 2023.

[36] A. K. Tiwari, “Introduction to machine learning,” in Arvind Tiwari and Pradeep Kumar (eds) *Ubiquitous Machine Learning and Its Applications*. IGI Global, 2017, pp. 1-14.

[37] M. Yuvali, B. Yaman, and O. Tosun, “Classification comparison of machine learning algorithms using two independent CAD datasets,” *Mathematics*, vol. 10, no. 3, p. 311, 2022.

[38] S.-J. Kim, S.-J. Bae, and M.-W. Jang, “Linear regression machine learning algorithms for estimating reference evapotranspiration using limited climate data,” *Sustainability*, vol. 14, no. 18, p. 11674, 2022.

[39] N. Mekni, C. Coronnello, T. Langer, M. De Rosa, and U. Perricone, “Support vector machine as a supervised learning for the prioritization of novel potential sars-cov-2 main protease inhibitors,” *Int. J. Mol. Sci.*, vol. 22, no. 14, p. 7714, 2021.

[40] F. Nurahmadi, F. Lubis, and P. I. Nainggolan, “Analysis of deep learning architecture in classifying SNI masks,” *J. Informatics Telecommun. Eng.*, vol. 5, no. 2, pp. 473-482, 2022.

[41] I. L. Rahmatullah, “Pengenalan suara menggunakan algoritma convolutional neural network pada gim pembelajaran bahasa arab.” Fakultas Sains dan Teknologi UIN Syarif Hidayatullah Jakarta.

[42] B. K. Zaied et al., “Prediction and optimization of biogas production from POME co-digestion in solar bioreactor using artificial neural network coupled with particle swarm optimization (ANN-PSO),” *Biomass Convers. Biorefinery*, pp. 1-16, 2020. doi: 10.1007/s13399-020-01057-6

[43] A. Mostafaelpour and E. Jooyandeh, “Prioritizing the locations for hydrogen production using a hybrid wind-solar system: A case study,” *Adv. Energy Res.*, vol. 5, no. 2, p. 107, 2017.

[44] M. Yousefi et al., “RETRACTED ARTICLE: Support vector regression methodology for prediction of output energy in rice production,” *Stoch. Environ. Res. Risk Assess.*, vol. 29, pp. 2115-2126, 2015.

[45] V. Rodriguez-Galiano, M. Sanchez-Castillo, M. Chica-Olmo, and M. Chica-Rivas, “Machine learning predictive models for mineral prospectivity: An evaluation of neural networks, random forest, regression trees and support vector machines,” *Ore Geol. Rev.*, vol. 71, pp. 804-818, 2015.

[46] A. Sharifi, “Yield prediction with machine learning algorithms and satellite images,” *J. Sci. Food Agric.*, vol. 101, no. 3, pp. 891-896, 2021.

[47] A. Elbeltagi et al., “Drought indicator analysis and forecasting using data driven models: Case study in Jaisalmer, India,” *Stoch. Environ. Res. Risk Assess.*, vol. 37, no. 1, pp. 113-131, 2023. doi: 10.1007/s00477-022-02277-0

[48] B. T. Pham, I. Prakash, and D. T. Bui, “Spatial prediction of landslides using a hybrid machine learning approach based on random subspace and classification and regression trees,” *Geomorphology*, vol. 303, pp. 256-270, 2018.

[49] K. B. Banakara, N. Sharma, S. Sahoo, S. K. Dubey, and V. M. Chowdary, “Evaluation of weather parameter-based pre-harvest yield forecast models for wheat crop: A case study in Saurashtra region of Gujarat,” *Environ. Monit. Assess.*, vol. 195, no. 1, 2023. doi: 10.1007/s10661-022-10552-4

[50] N. Kim, K. J. Ha, N. W. Park, J. Cho, S. Hong, and Y. W. Lee, “A comparison between major artificial intelligence models for crop yield prediction: Case study of the midwestern United States, 2006-2015,” *ISPRS Int. J. Geo-Information*, vol. 8, no. 5, 2019. doi: 10.3390/ijgi8050240

CHƯƠNG 7 THU HOẠCH TRÍ TUỆ: AI VÀ ML CÁCH MẠNG HÓA NÔNG NGHIỆP

Arya Kumari, Muhammad Najeeb Khan, và Amit Kumar Sinha Đại học Shri Mata Vaishno Devi, Katra, Ấn Độ

7.1 GIỚI THIỆU

Nông nghiệp đã là xương sống của văn minh nhân loại hàng thiên niên kỷ, và với sự ra đời của công nghệ, nó đang trải qua một sự thay đổi đáng kể. Học máy (ML), với khả năng xử lý lượng lớn dữ liệu và trích xuất những hiểu biết có ý nghĩa, đang đóng một vai trò then chốt trong việc cách mạng hóa ngành nông nghiệp. Trong chương này, chúng ta sẽ khám phá các ứng dụng đa dạng của ML trong nông nghiệp và cách nó đang nâng cao năng suất, tính bền vững và hiệu quả tổng thể.

7.2 NÔNG NGHIỆP CHÍNH XÁC VÀ QUẢN LÝ CÂY TRỒNG

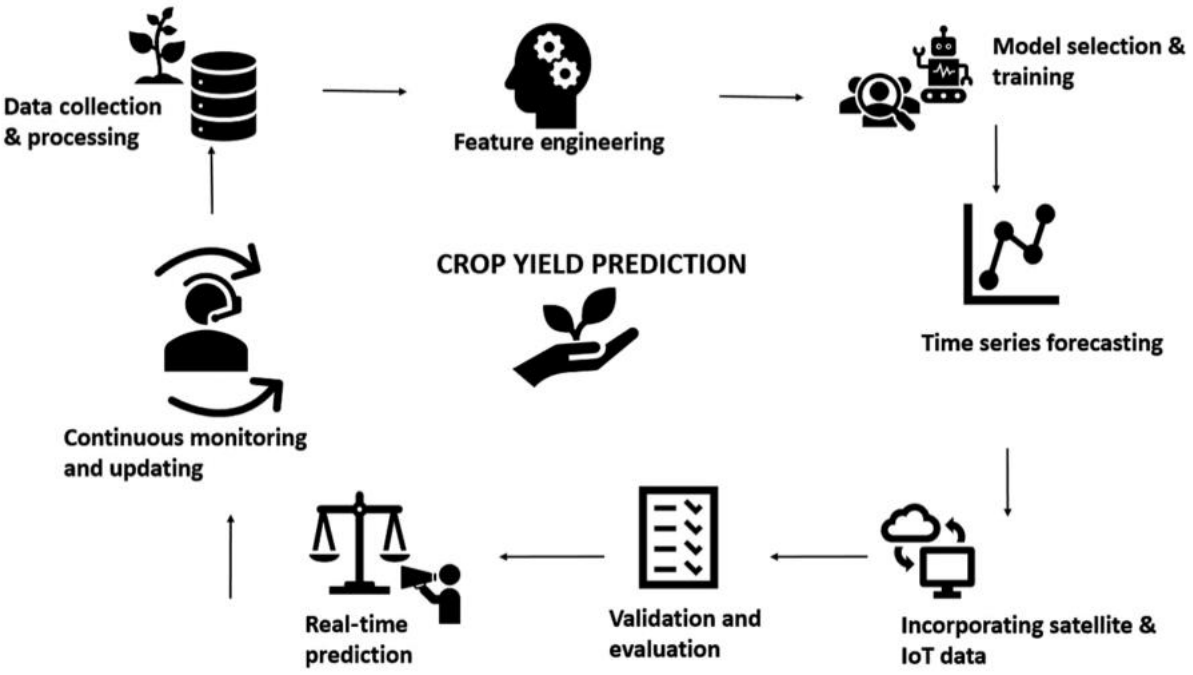
7.2.1 Dự đoán năng suất cây trồng

ML đóng một vai trò quan trọng trong dự đoán năng suất cây trồng, vì nó có thể tận dụng dữ liệu lịch sử và thời gian thực để xây dựng các mô hình dự đoán ước tính chính xác năng suất cây trồng trong tương lai. Đây là biểu diễn bằng hình ảnh (Hình 7.1) về cách ML có thể được sử dụng trong dự đoán năng suất cây trồng:

Bây giờ chúng ta hãy xem giải thích ngắn gọn về từng bước, như thể hiện trong Hình 7.1:

1. Thu thập và Tiền xử lý dữ liệu:

- Làm sạch và tiền xử lý dữ liệu để xử lý các giá trị bị thiếu và các giá trị ngoại lai, và đảm bảo tính nhất quán của dữ liệu.



HÌNH 7.1: Dự đoán năng suất cây trồng với sự trợ giúp của ML. *(Sơ đồ quy trình: Thu thập & xử lý dữ liệu -> Kỹ thuật đặc trưng -> Lựa chọn & huấn luyện mô hình -> Dự báo chuỗi thời gian -> Kết hợp dữ liệu vệ tinh & IoT -> Xác thực và đánh giá -> Dự đoán thời gian thực -> Giám sát và cập nhật liên tục)*

2. Kỹ thuật đặc trưng:

- Chọn và thiết kế các đặc trưng liên quan từ dữ liệu đã thu thập có thể ảnh hưởng đến năng suất cây trồng, chẳng hạn như nhiệt độ, lượng mưa, độ ẩm của đất và các phương pháp bón phân.

3. Lựa chọn mô hình:

- Bằng cách chọn một thuật toán ML thích hợp dựa trên bản chất của vấn đề (một số thuật toán thường được sử dụng là hồi quy tuyến tính, cây quyết định, rừng ngẫu nhiên, máy véc-tơ hỗ trợ (SVM), mạng nơ-ron, dự báo chuỗi thời gian, và nhiều thuật toán khác) và kích thước của bộ dữ liệu, chúng ta có thể dự đoán năng suất cây trồng.

4. Huấn luyện mô hình:

- Bằng cách chia bộ dữ liệu thành các tập huấn luyện và tập xác thực, chúng ta đánh giá hiệu suất của mô hình và huấn luyện mô hình ML đã chọn trên tập huấn luyện, điều chỉnh các tham số của mô hình để giảm thiểu lỗi dự đoán.

5. Dự báo chuỗi thời gian:

- Đối với dự đoán năng suất cây trồng liên quan đến dữ liệu chuỗi thời gian, hãy chọn các mô hình được thiết kế đặc biệt cho các mẫu phụ thuộc vào thời gian, chẳng hạn như mô hình trung bình động tích hợp tự hồi quy (ARIMA), phân rã chuỗi thời gian theo mùa (STL), hoặc mạng bộ nhớ dài-ngắn hạn (LSTM).

6. Kết hợp dữ liệu vệ tinh và IoT:

- Tích hợp dữ liệu hình ảnh vệ tinh và dữ liệu cảm biến IoT, chẳng hạn như cảm biến độ ẩm của đất và các trạm thời tiết, để thu thập thông tin thời gian thực về sức khỏe cây trồng và điều kiện môi trường.
- Dữ liệu vệ tinh có thể cung cấp thông tin chi tiết về các chỉ số thảm thực vật và sự phát triển của cây trồng, trong khi dữ liệu IoT có thể cung cấp thông tin chi tiết về các biến môi trường địa phương.

7. Xác thực và Đánh giá mô hình:

- Xác thực hiệu suất của mô hình trên tập xác thực và sử dụng các số liệu đánh giá thích hợp, chẳng hạn như sai số bình phương trung bình (MSE) hoặc căn bậc hai của sai số bình phương trung bình (RMSE); sau đó, tinh chỉnh mô hình nếu cần và thực hiện kiểm định chéo để đảm bảo khả năng tổng quát hóa của nó.

8. Dự đoán thời gian thực:

- Khi mô hình được huấn luyện và xác thực, nó có thể được sử dụng để dự đoán năng suất cây trồng theo thời gian thực (bằng cách sử dụng các thuật toán như thuật toán học có giám sát) dựa trên điều kiện thời tiết hiện tại và các biến đầu vào khác.

9. Giám sát và Cập nhật liên tục:

- Giám sát liên tục hiệu suất của mô hình dự đoán năng suất cây trồng và cập nhật thường xuyên bằng dữ liệu mới.

7.2.2 Phát hiện bệnh và Quản lý dịch hại

Tận dụng thị giác máy tính và phân tích hình ảnh để phát hiện bệnh trên cây trồng đã trở thành một yếu tố thay đổi cuộc chơi trong nông nghiệp hiện đại. Bằng cách khai thác sức mạnh của ML và các kỹ thuật xử lý hình ảnh, nông dân có thể nhanh chóng và chính xác xác định các bệnh và sâu bệnh ảnh hưởng đến cây trồng của họ, cho phép họ thực hiện các hành động kịp thời và có mục tiêu để quản lý bệnh. Dưới đây là giải thích ngắn gọn về cách thị giác máy tính và phân tích hình ảnh được sử dụng để phát hiện bệnh trên cây trồng:

1. Thu thập và Tiền xử lý hình ảnh:

- Hình ảnh có độ phân giải cao của cây trồng được chụp bằng nhiều nguồn khác nhau, chẳng hạn như máy bay không người lái, vệ tinh hoặc máy ảnh gắn cố định.
- Các kỹ thuật tiền xử lý được áp dụng để nâng cao chất lượng hình ảnh, loại bỏ nhiễu và điều chỉnh bất kỳ biến dạng hoặc tạo tác hình ảnh nào.

2. Phân đoạn vùng thực vật:

- Các thuật toán thị giác máy tính được sử dụng để phân đoạn các vùng thực vật quan tâm khỏi nền trong hình ảnh.
- Bước này đảm bảo rằng chỉ các phần liên quan của hình ảnh được phân tích, tập trung vào lá hoặc các khu vực bị ảnh hưởng.

3. Trích xuất đặc trưng:

- Các đặc trưng liên quan, chẳng hạn như màu sắc, kết cấu, hình dạng và kích thước của các vùng thực vật, được trích xuất từ các hình ảnh đã được phân đoạn.
- Các đặc trưng này đóng vai trò là đầu vào thiết yếu cho các mô hình phân loại bệnh.

4. Phân loại bệnh:

- Các thuật toán ML, chẳng hạn như SVM, mạng nơ-ron tích chập (CNN), hoặc cây quyết định, được huấn luyện bằng cách sử dụng các bộ dữ liệu được gán nhãn của cây trồng khỏe mạnh và bị bệnh.
- Các mô hình học cách phân biệt giữa cây trồng khỏe mạnh và bị nhiễm bệnh dựa trên các đặc trưng đã trích xuất.

5. Nhận dạng và Chẩn đoán bệnh:

- Khi mô hình được huấn luyện, nó được triển khai để dự đoán sự hiện diện của bệnh trong các hình ảnh mới, chưa từng thấy của cây trồng.
- Mô hình phân loại cây trồng là khỏe mạnh hoặc xác định loại bệnh hoặc sâu bệnh cụ thể đang ảnh hưởng đến nó.

6. Phát hiện và Giám sát sớm:

- Giám sát liên tục cây trồng bằng thị giác máy tính cho phép phát hiện sớm các bệnh trước khi chúng lây lan rộng rãi.

7.3 SỨC KHỎE ĐẤT VÀ QUẢN LÝ DINH DƯỠNG

7.3.1 Phân tích độ phì nhiêu của đất

Phân tích độ phì nhiêu của đất bằng ML bao gồm một loạt các bước để xử lý và phân tích dữ liệu đất, xây dựng các mô hình dự đoán và diễn giải kết quả. Dưới đây là quy trình từng bước để phân tích độ phì nhiêu của đất bằng ML:

1. Thu thập dữ liệu:

- Thu thập các mẫu đất từ nhiều vị trí khác nhau trên đồng ruộng, đảm bảo chúng đại diện cho toàn bộ khu vực, cung cấp thông tin liên quan về mỗi mẫu, chẳng hạn như loại đất, độ pH, hàm lượng chất hữu cơ, mức độ dinh dưỡng (nitơ, phốt pho, kali, v.v.), và các đặc tính khác của đất.

2. Tiền xử lý dữ liệu:

- Làm sạch dữ liệu bằng cách xử lý các giá trị bị thiếu và loại bỏ bất kỳ giá trị ngoại lai nào.
- Chuẩn hóa các đặc trưng số để đảm bảo rằng chúng có tác động như nhau đến mô hình.

3. Lựa chọn đặc trưng:

- Sử dụng các kỹ thuật như phân tích tương quan hoặc tầm quan trọng của đặc trưng từ các mô hình ML để chọn các đặc trưng liên quan.

4. Xây dựng mô hình ML:

- Chọn một thuật toán ML phù hợp để dự đoán độ phì nhiêu của đất.
- Các thuật toán phổ biến bao gồm hồi quy tuyến tính, cây quyết định, rừng ngẫu nhiên, SVM, và máy tăng cường độ dốc (GBM).
- Chúng ta có thể chia dữ liệu thành các tập huấn luyện và tập kiểm tra để đánh giá hiệu suất của mô hình.

5. Huấn luyện mô hình:

- Điều chỉnh các siêu tham số để tối ưu hóa hiệu suất của mô hình. Chúng ta có thể sử dụng các kỹ thuật như tìm kiếm lưới (grid search) hoặc tìm kiếm ngẫu nhiên (random search) để tinh chỉnh siêu tham số.

6. Đánh giá mô hình:

- Đánh giá hiệu suất của mô hình trên tập kiểm tra bằng cách sử dụng các số liệu đánh giá thích hợp như Sai số tuyệt đối trung bình (MAE), RMSE, hoặc R-squared.
- So sánh kết quả với các ngưỡng cụ thể của miền để xác định độ chính xác của mô hình.

7. Diễn giải kết quả:

- Phân tích các hệ số của mô hình hoặc tầm quan trọng của đặc trưng để hiểu các đặc tính nào của đất có ảnh hưởng đáng kể nhất đến độ phì nhiêu của đất.
- Và diễn giải các dự đoán để xác định các khu vực có độ phì nhiêu của đất thấp hoặc cao.

8. Xác thực và Tinh chỉnh:

- Xác thực hiệu suất của mô hình bằng cách sử dụng các mẫu đất mới được thu thập độc lập từ các tập huấn luyện và kiểm tra.

9. Triển khai mô hình:

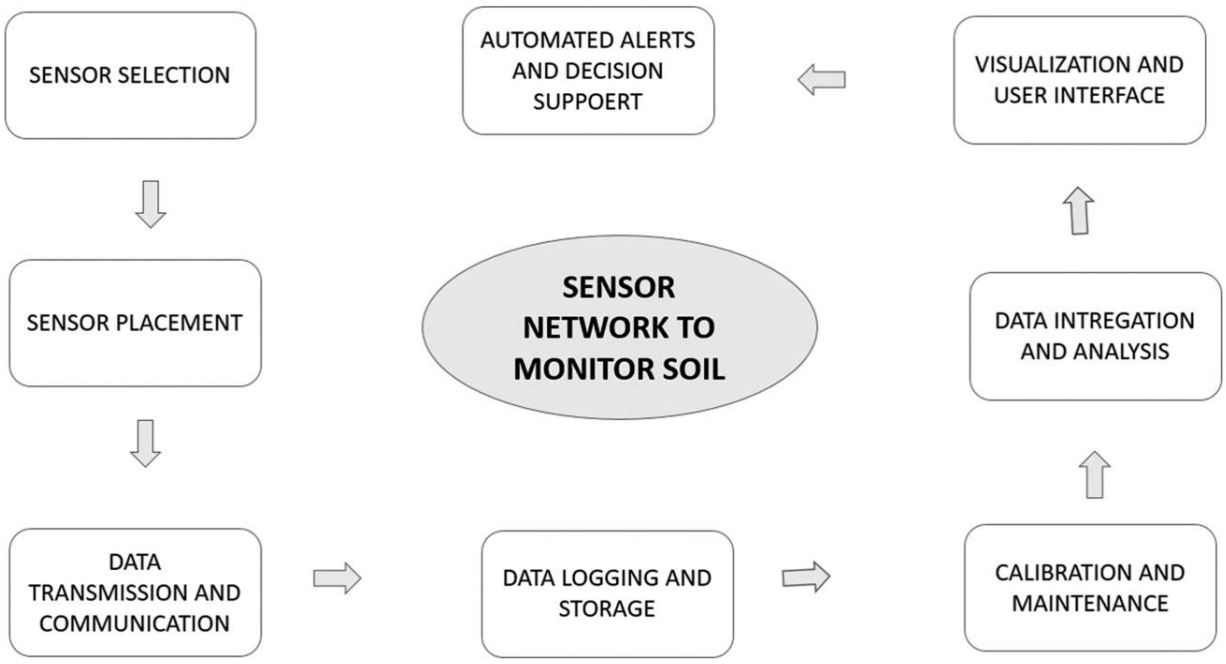
- Tích hợp mô hình vào một ứng dụng hoặc hệ thống cho phép người dùng nhập dữ liệu đất và nhận dự đoán về độ phì nhiêu.

10. Giám sát và Cập nhật liên tục:

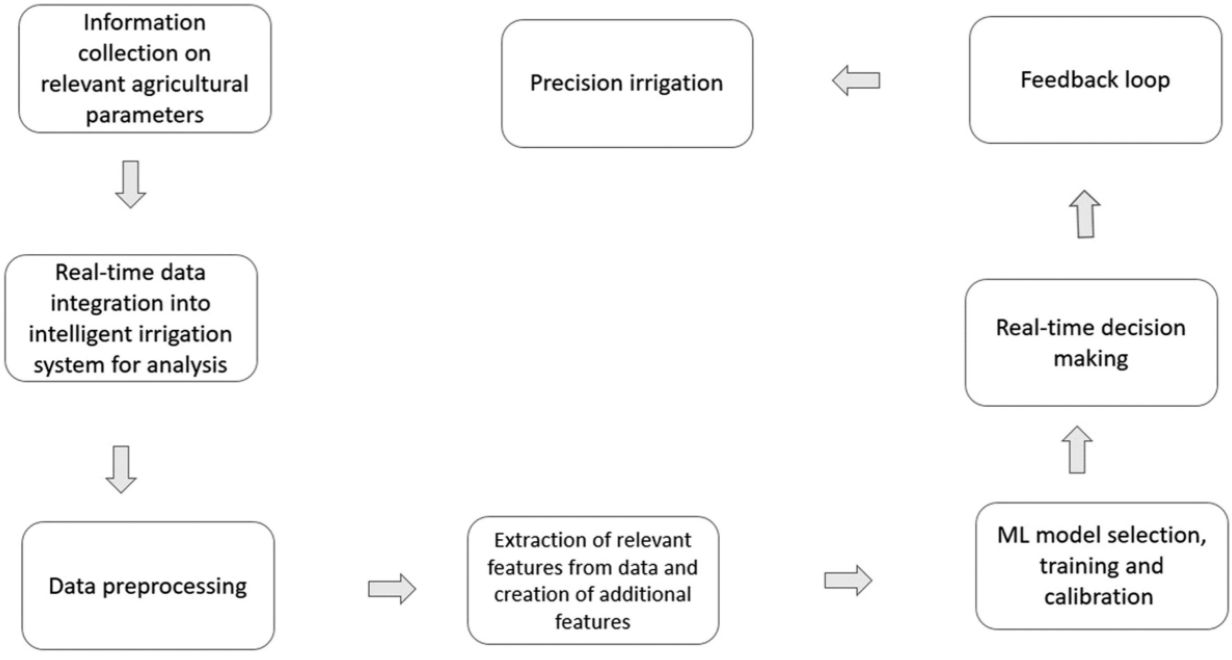
- Giám sát liên tục hiệu suất của mô hình và cập nhật thường xuyên bằng dữ liệu mới để cải thiện độ chính xác và thích ứng với các điều kiện đất thay đổi.

7.3.2 Tối ưu hóa tưới tiêu

- Việc triển khai các mạng cảm biến để giám sát mức độ ẩm của đất và điều kiện thời tiết được trình bày trong Hình 7.2.
- Sử dụng các thuật toán ML để tạo ra các hệ thống tưới tiêu thông minh, như thể hiện trong Hình 7.3.
- Giảm lãng phí nước và đảm bảo cung cấp đủ nước cho cây trồng, như được đề cập trong Hình 7.4.
- Vai trò của học tăng cường trong việc tự động điều chỉnh lịch trình tưới tiêu được thể hiện trong Hình 7.5.

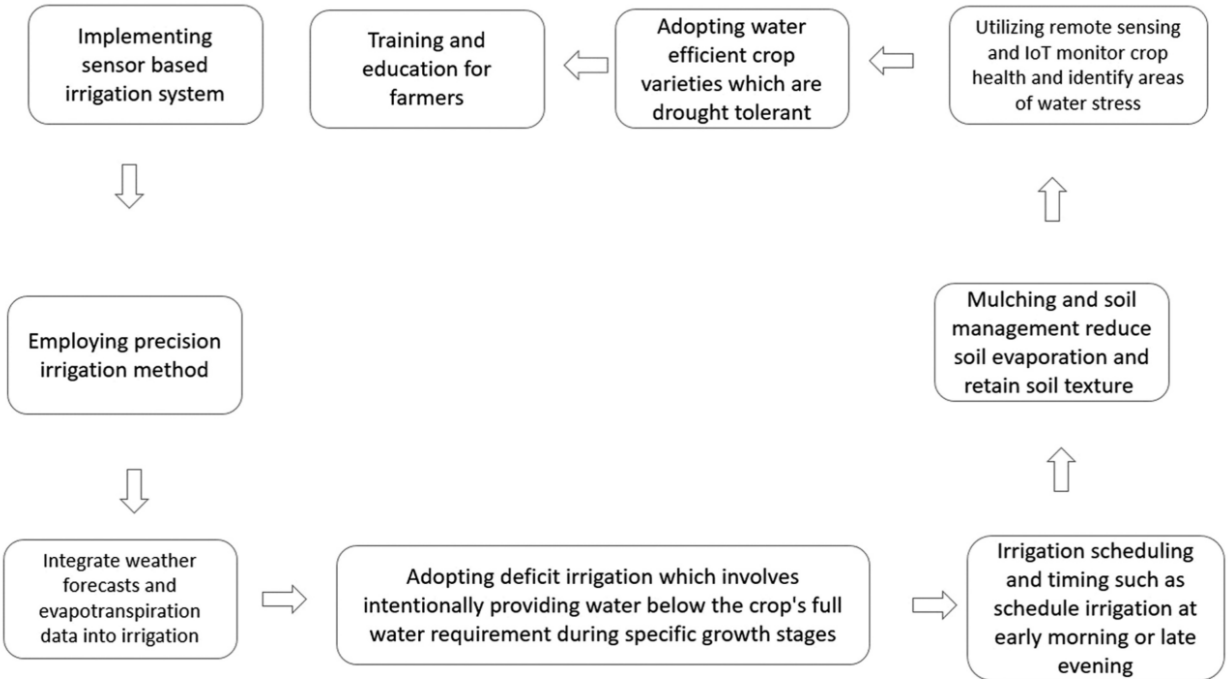


HÌNH 7.2: Triển khai mạng cảm biến. *(Sơ đồ mạng cảm biến để giám sát đất, bao gồm: lựa chọn cảm biến, bố trí cảm biến, truyền và giao tiếp dữ liệu, ghi và lưu trữ dữ liệu, hiệu chỉnh và bảo trì, tích hợp và phân tích dữ liệu, trực quan hóa và giao diện người dùng, cảnh báo tự động và hỗ trợ quyết định.)*

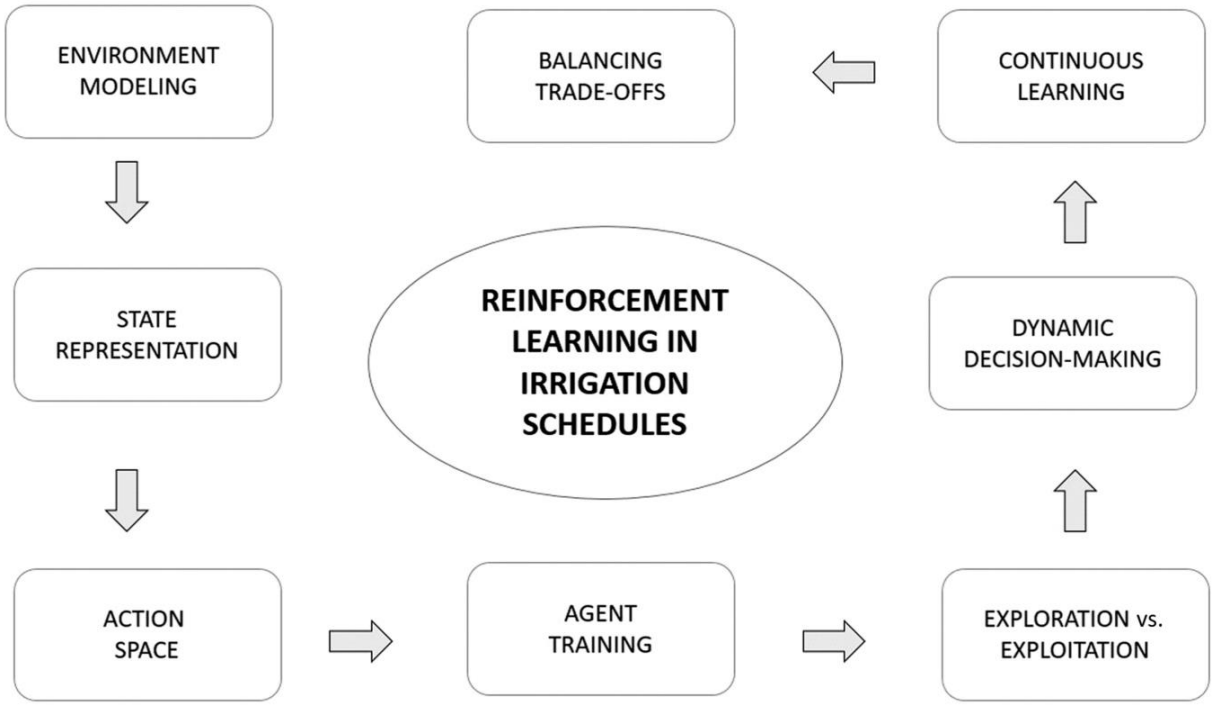


HÌNH 7.3: Các hệ thống tưới tiêu thông minh. *(Sơ đồ quy trình: Thu thập thông tin về các thông số nông nghiệp liên quan -> Tích hợp dữ liệu thời gian thực vào hệ thống tưới tiêu thông minh để phân tích -> Tiền xử lý dữ liệu -> Trích xuất các đặc trưng liên quan*

từ dữ liệu và tạo thêm các đặc trưng bổ sung -> Lựa chọn, huấn luyện và hiệu chỉnh mô hình ML -> Ra quyết định thời gian thực -> Vòng lặp phản hồi -> Tưới tiêu chính xác.)



HÌNH 7.4: Cung cấp đủ nước cho cây trồng. *(Sơ đồ quy trình: Triển khai hệ thống tưới tiêu dựa trên cảm biến -> Sử dụng phương pháp tưới tiêu chính xác -> Tích hợp dự báo thời tiết và dữ liệu thoát hơi nước vào tưới tiêu -> Áp dụng tưới tiêu thiếu hụt… -> Lập lịch và thời điểm tưới tiêu… -> Phủ lớp phủ và quản lý đất… -> Sử dụng viễn thám và IoT… -> Áp dụng các giống cây trồng sử dụng nước hiệu quả… -> Đào tạo và giáo dục cho nông dân.)*



HÌNH 7.5: Điều chỉnh tự động lịch trình tưới tiêu. *(Sơ đồ học tăng cường trong lịch trình tưới tiêu, bao gồm: mô hình hóa môi trường, biểu diễn trạng thái, không gian hành động, huấn luyện tác nhân, thăm dò vs. khai thác, ra quyết định động, học tập liên tục, cân bằng các đánh đổi.)*

7.4 QUẢN LÝ VẬT NUÔI

7.4.1 Giám sát vật nuôi tự động

Giám sát vật nuôi tự động là một phương pháp dựa trên công nghệ bao gồm việc sử dụng các cảm biến, thiết bị và phân tích dữ liệu khác nhau để liên tục giám sát và theo dõi sức khỏe, hành vi và phúc lợi của vật nuôi trong các môi trường nông nghiệp. Hệ thống giám sát tiên tiến này có thể cung cấp thông tin thời gian thực cho nông dân, cho phép họ xác định và giải quyết các vấn đề tiềm ẩn kịp thời. Dưới đây là cách thức hoạt động của giám sát vật nuôi tự động (Hình 7.6):

1. Thiết bị đeo và Cảm biến:

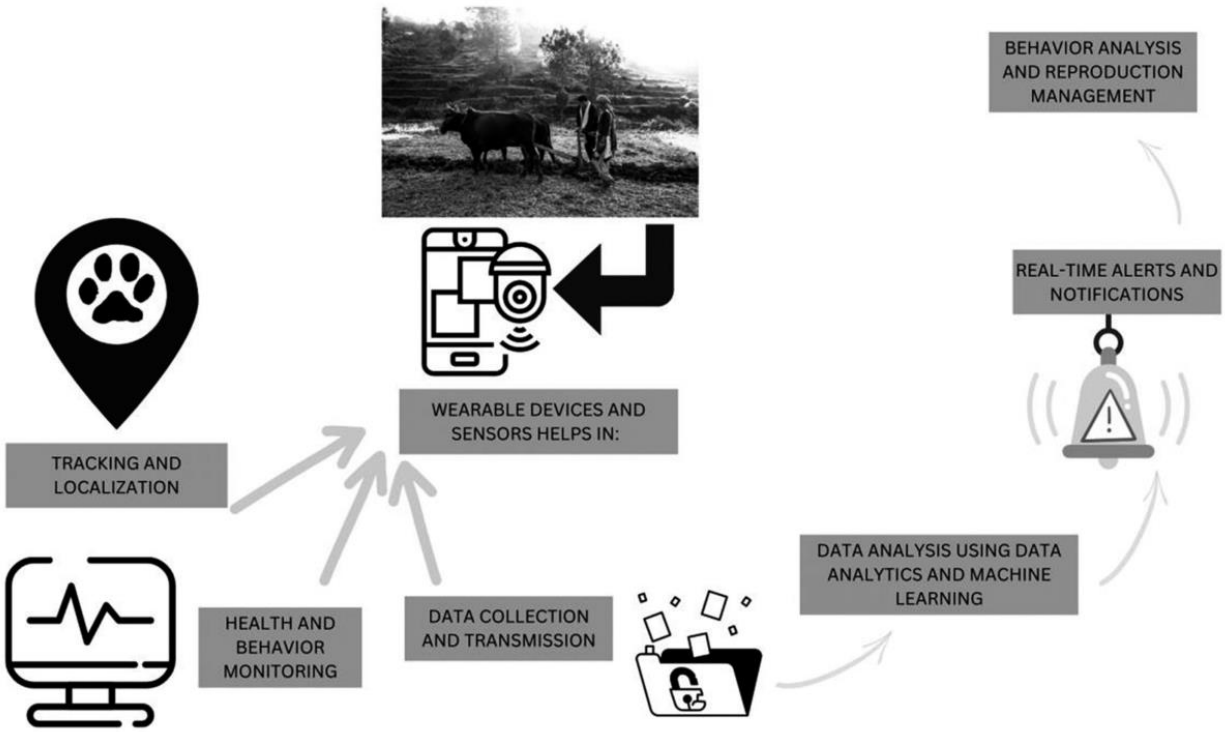
- Vật nuôi đeo các thiết bị như vòng cổ có GPS, thẻ tai hoặc vòng chân có chứa cảm biến.
- Các cảm biến này có thể theo dõi các dấu hiệu sinh tồn như nhiệt độ cơ thể, nhịp tim, nhịp thở và mức độ hoạt động của động vật.

2. Theo dõi và Định vị:

- Các thiết bị hỗ trợ GPS theo dõi vị trí và chuyển động của vật nuôi trên đồng hoặc khu vực chăn thả.
- Điều này giúp nông dân theo dõi nơi ở của động vật, ngăn chặn đi lạc và đảm bảo quản lý chăn thả hiệu quả.

3. Giám sát sức khỏe và Hành vi:

- Cảm biến liên tục theo dõi sức khỏe và hành vi của động vật.
- Hành vi bất thường, chẳng hạn như giảm hoạt động hoặc thay đổi thói quen ăn uống, có thể chỉ ra các vấn đề sức khỏe hoặc căng thẳng.



HÌNH 7.6: Giám sát tự động bằng cảm biến, thiết bị và phân tích dữ liệu. *(Sơ đồ quy trình: thiết bị đeo và cảm biến giúp trong việc: theo dõi và định vị, giám sát sức khỏe và hành vi, thu thập và truyền dữ liệu -> phân tích dữ liệu sử dụng phân tích dữ liệu và học máy -> cảnh báo và thông báo thời gian thực -> phân tích hành vi và quản lý sinh sản.)*

4. Thu thập và Truyền dữ liệu:

- Các thiết bị cảm biến thu thập dữ liệu từ vật nuôi, và thông tin được truyền không dây đến một hệ thống thu thập dữ liệu trung tâm.
- Dữ liệu có thể được gửi đến các nền tảng dựa trên đám mây hoặc máy chủ cục bộ để lưu trữ và phân tích.

5. Phân tích dữ liệu và ML:

- Dữ liệu từ nhiều vật nuôi được phân tích bằng các thuật toán phân tích dữ liệu và ML.
- Các thuật toán này có thể xác định các mẫu và xu hướng có thể chỉ ra các tình trạng sức khỏe cụ thể hoặc các yếu tố gây căng thẳng.

6. Cảnh báo và Thông báo thời gian thực:

- Khi phát hiện dữ liệu bất thường hoặc các ngưỡng được xác định trước, hệ thống sẽ tạo ra các cảnh báo hoặc thông báo theo thời gian thực.
- Nông dân nhận được các cảnh báo này trên điện thoại thông minh hoặc máy tính của họ, cho phép họ hành động ngay lập tức.

7. Giám sát và Quản lý từ xa:

- Nông dân có thể truy cập hệ thống giám sát từ xa để kiểm tra tình trạng sức khỏe và vị trí của vật nuôi.
- Tính năng này đặc biệt hữu ích cho các hoạt động chăn nuôi quy mô lớn hoặc khi động vật đang chăn thả ở các khu vực xa.

8. Phân tích hành vi và Quản lý sinh sản:

- Giám sát tự động có thể giúp phát hiện hành vi động dục ở động vật cái, hỗ trợ thời điểm thích hợp để nhân giống.
- Phân tích hành vi cũng có thể xác định sớm các dấu hiệu của sự đau khổ hoặc bệnh tật, cho phép can thiệp kịp thời.

7.5 TỐI ƯU HÓA THỨC ĂN CHĂN NUÔI

Tối ưu hóa thức ăn chăn nuôi bằng ML là một cách tiếp cận sáng tạo trong nông nghiệp để quản lý hiệu quả dinh dưỡng động vật và giảm chi phí thức ăn đồng thời tối đa hóa sức khỏe và năng suất của động vật. Các thuật toán ML có thể phân tích một lượng lớn dữ liệu để tạo ra các kế hoạch cho ăn được cá nhân hóa và tối ưu hóa cho vật nuôi. Dưới đây là cách thức hoạt động của tối ưu hóa thức ăn chăn nuôi bằng ML:

1. Thu thập dữ liệu:

- Thu thập dữ liệu về các đặc điểm của động vật, chẳng hạn như loài, giống, tuổi, cân nặng và tình trạng sinh lý (ví dụ: đang cho con bú, đang mang thai).
- Thu thập thông tin dinh dưỡng về các thành phần thức ăn khác nhau, bao gồm thành phần dinh dưỡng và khả năng tiêu hóa.

2. Yêu cầu dinh dưỡng:

- Xác định các yêu cầu dinh dưỡng cho các nhóm động vật khác nhau, xem xét các giai đoạn tăng trưởng, tình trạng sinh sản và mục tiêu sản xuất của chúng.
- Các yêu cầu dinh dưỡng thường dựa trên các hướng dẫn khoa học và các tiêu chuẩn cho ăn đã được thiết lập.

3. Công thức hóa vấn đề:

- Chuyển đổi vấn đề tối ưu hóa thức ăn thành một vấn đề ML bằng cách công thức hóa nó như một nhiệm vụ tối ưu hóa.
- Xác định hàm mục tiêu, có thể là tối đa hóa năng suất động vật (ví dụ: sản lượng sữa, tăng trọng) trong khi giảm thiểu chi phí thức ăn.

4. Tiền xử lý dữ liệu:

- Làm sạch và tiền xử lý dữ liệu, xử lý các giá trị bị thiếu và các giá trị ngoại lai để đảm bảo chất lượng dữ liệu.

5. Kỹ thuật đặc trưng:

- Trích xuất các đặc trưng liên quan từ dữ liệu, chẳng hạn như đặc điểm động vật và thành phần dinh dưỡng của các thành phần thức ăn.
- Tạo các đặc trưng tổng hợp hoặc tỷ lệ đại diện cho sự cân bằng dinh dưỡng cần thiết cho các nhóm động vật cụ thể.

6. Lựa chọn mô hình:

- Chọn các thuật toán ML thích hợp dựa trên các vấn đề tối ưu hóa thức ăn cụ thể như hồi quy, lập trình tuyến tính và thuật toán di truyền, thường được sử dụng cho các nhiệm vụ tối ưu hóa thức ăn.

7. Huấn luyện mô hình:

- Huấn luyện mô hình ML trên dữ liệu cho ăn lịch sử, bao gồm các công thức thức ăn và dữ liệu hiệu suất động vật tương ứng, mô hình học cách xác định các kết hợp thức ăn tối ưu đáp ứng yêu cầu dinh dưỡng của động vật.

8. Xác thực và Đánh giá mô hình:

- Xác thực hiệu suất của mô hình ML trên một bộ dữ liệu riêng biệt hoặc thông qua kiểm định chéo, chúng ta có thể đánh giá khả năng của mô hình trong việc tạo ra các công thức thức ăn tiết kiệm chi phí đồng thời đáp ứng nhu cầu dinh dưỡng của động vật.

9. Công thức hóa thức ăn thời gian thực:

- Triển khai mô hình ML đã được huấn luyện trong một hệ thống công thức hóa thức ăn tự động, dựa trên dữ liệu thời gian thực về động vật và các thành phần thức ăn có sẵn và tạo ra các kế hoạch thức ăn được cá nhân hóa và tối ưu hóa.

10. Học tập và Cập nhật liên tục:

- Giám sát liên tục hiệu suất của động vật và chi phí thức ăn để thu thập dữ liệu mới, giúp cập nhật thường xuyên mô hình ML để cải thiện độ chính xác và thích ứng với sự thay đổi về tính sẵn có của thành phần thức ăn hoặc yêu cầu dinh dưỡng.

7.6 KẾT LUẬN

ML đang thay đổi nông nghiệp bằng cách cung cấp những hiểu biết dựa trên dữ liệu và khả năng ra quyết định. Nông nghiệp chính xác, quản lý cây trồng, phân tích sức khỏe của đất và quản lý vật nuôi chỉ là một vài lĩnh vực mà các ứng dụng ML đang tạo ra tác động đáng kể.

Khi công nghệ tiếp tục phát triển, ngành nông nghiệp sẽ còn được hưởng lợi nhiều hơn từ những đổi mới này, dẫn đến các phương thức canh tác bền vững, tăng năng suất và cải thiện an ninh lương thực. Tuy nhiên, những thách thức như quyền riêng tư dữ liệu, các rào cản trong việc áp dụng và khoảng cách số phải được giải quyết để đảm bảo việc áp dụng rộng rãi các công nghệ mang tính chuyển đổi này. Bằng cách kết hợp chuyên môn trong lĩnh vực với khả năng của ML, nông nghiệp sẵn sàng đón nhận một kỷ nguyên mới về năng suất và tính bền vững.

DANH MỤC TÀI LIỆU

- Ahmad, Latief, and Firasath Nabi. Agriculture 5.0: Artificial Intelligence, IoT and Machine Learning. CRC Press, 2021.
- Alreshidi, E. Smart sustainable agriculture (SSA) solution underpinned by internet of things (IoT) and artificial intelligence (AI). (2019). arXiv preprint arXiv:1906.03106. Anitha Mary, X., Popov, V., Raimond, K., Johnson, I., and Vijay, S. J. Scope and recent trends of artificial intelligence in Indian agriculture. The digital agricultural revolution: Innovations and challenges in agriculture through technology disruptions. 1–24, Wiley, 2022.
- Dakir, A., F. Barramou, and O. B. Alami. Opportunities for artificial intelligence in preci- sion agriculture using satellite remote sensing. Geospatial Intelligence: Applications and Future Trends. 107–117, 2022. https://doi.org/10.1007/978-3-030-80458-9_8

- Javaid, M.A. Haleem, I. H. Khan, and R. Suman. Understanding the potential applications of artificial intelligence in agriculture sector. Advanced Agrochem 2.1. (2023): 15–30.
- Jung, J., M. Maeda, A. Chang, M. Bhandari, A. Ashapure, and J. Landivar-Bowles. The potential of remote sensing and artificial intelligence as tools to improve the resil- ience of agriculture production systems. Current Opinion in Biotechnology 70 (2021): 15–22.
- Khan, Yusuf Mustafa, and Sandeep Kumar. Applications of artificial intelligence in agricul- ture. International Research Journal of Modernization in Engineering Technology and Science 3 (2021): 1398–1402.
- Khandelwal, Paras M., and Himanshu Chavhan. Artificial intelligence in agriculture: An emerging era of research. ResearchGate Publication, 2019.
- Linaza, M. T., J Posada, J. Bund, P. Eisert, M. Quartulli, J. Döllner, A. Pagani, I. G. Olaizola, Barriguinha, T. Moysiadis, and L. Lucat. Data-driven artificial intelligence applica- tions for sustainable precision agriculture. Agronomy 11 (2021): 1227.
- Megeto, G. A. S., A. G. D. Silva,R. F. Bulgarelli, C. F. Bublitz, A. C. Valente, and D. A. G. D. Costa. Artificial intelligence applications in the agriculture 4.0. Revista Ciência Agronômica 51 (2021): e20207701.
- Mekonnen, Y., S. Namuduri, L. Burton, A. Sarwat, and S. Bhansali. Machine learning techniques in wireless sensor network based precision agriculture. Journal of the Electrochemical Society 167.3 (2019): 037522.
- Misra, N. N., Yash Dixit, Ahmad Al-Mallahi, Manreet Singh Bhullar, Rohit Upadhyay, and Alex Martynenko. IoT, big data, and artificial intelligence in agriculture and food industry. IEEE Internet of Things Journal 9 (2020): 6305–6324.
- Mitra, Alakananda, Sukrutha L. T. Vangipuram, Anand K. Bapatla, Venkata K. V. V. Bathalapalli, Saraju P. Mohanty, Elias Kougianos, and Chittaranjan Ray. “Everything you wanted to know about smart agriculture.” (2022). arXiv preprint arXiv:2201.04754.
- Panpatte, D. G. Artificial intelligence in agriculture: An emerging era of research. Anand Agricultural University, 2018.
- Sarkar, M. R.S. R. Masud, M. I. Hossen, and M. Goh. A comprehensive study on the emerg- ing effect of artificial intelligence in agriculture automation. In 2022 IEEE 18th International Colloquium on Signal Processing & Applications (CSPA), 2022 May 12, pp. 419–424). IEEE.

- Shadrin, D., A. Menshchikov, D. Ermilov, and A. Somov. Designing future precision agri- culture: Detection of seeds germination using artificial intelligence on a low-power embedded system. IEEE Sensors Journal 19.23. (2019): 11573–11582.
- Sharma, A., M. Georgi, M. Tregubenko, A. Tselykh, and A. Tselykh Enabling smart agri- culture by implementing artificial intelligence and embedded sensing. Computers & Industrial Engineering 165 (2022): 107936.
- Singh, Garima, Anamika Singh, and Gurjit Kaur. Role of artificial intelligence and the internet of things in agriculture. In Artificial Intelligence to Solve Pervasive Internet of Things Issues, pp. 317–330. Academic Press, 2021a.
- Singh, P., and A. Kaur. A systematic review of artificial intelligence in agriculture. Deep Learning for Sustainable Agriculture. 57–80, 2022. https://doi.org/10.1016/B978-0-323-85214-2.00011-2
- Singh, Rajesh, and Anita Gehlot, Mahesh Kumar Prajapat, and Bhupendra Singh. Artificial Intelligence in Agriculture. CRC Press, 2021b.
- Singh, Ritesh Kumar, Rafael Berkvens, and Maarten Weyn. AgriFusion: An architecture for IoT and emerging technologies based on a precision agriculture survey. IEEE Access 9 (2021c): 136253–136283.
- Siregar, R. R. A., K. B. Seminar, S. Wahjuni, and E. Santosa. Vertical farming perspectives in support of precision agriculture using artificial intelligence: A review. Computers 11.9. (2022): 135.
- Sishodia, R. P. R. L. Ray, and S. K. Singh. Applications of remote sensing in precision agri- culture: A review. Remote Sensing 12 (2020):3136.
- Skvortsov, E. A. Prospects of applying artificial intelligence technologies in the regional agriculture. Ekonomika Regiona= Economy of Regions 2 (2020): 563.
- Sood, Amit, Rajendra Kumar Sharma, and Amit Kumar Bhardwaj. Artificial intelligence research in agriculture: A review. Online Information Review 46.6 (2022): 1054–1075. Subeesh, A., and C. R. Mehta. Automation and digitization of agriculture using artificial intelligence and internet of things. Artificial Intelligence in Agriculture 5 (2021): 278–291. Tzachor, Asaf, Medha Devare, Brian King, Shahar Avin, and Seán Ó hÉigeartaigh.
- Responsible artificial intelligence in agriculture requires systemic understanding of risks and externalities. Nature Machine Intelligence 4.2 (2022): 104–109.
- Yousaf, A., V. Kayvanfar, A. Mazzoni, and A. Elomri. Artificial intelligence-based decision support systems in smart agriculture: Bibliometric analysis for

operational insights and future directions. Frontiers in Sustainable Food Systems. 6 (2023): 1053921.

CHƯƠNG 8: SỬ DỤNG HỌC SÂU ĐỂ PHÁT HIỆN BỆNH TRÊN LÁ TÁO

Syed Nisar Hussain Bukhari, Rukaya Manzoor, Ummer Iqbal, và Muneer Ahmad Dar
Viện Công nghệ Thông tin và Điện tử Quốc gia (NIELIT), Srinagar, Ấn Độ

8.1 GIỚI THIỆU

Kashmir, vùng đất giàu văn hóa và ngôn ngữ, cũng rất phong phú về thảm thực vật. Đất đai ở đây hỗ trợ sự phát triển của nhiều loại trái cây, trong đó táo là loại nổi tiếng nhất. Sản xuất táo mang lại rất nhiều của cải. Cây táo có nguồn gốc từ Trung Á và hiện được trồng trên toàn thế giới. Tên thực vật của nó là *malus domestica*. Ở Kashmir, có rất nhiều loại táo được trồng, ví dụ như Delicious, Golden, Ambri, Chamboora, v.v. Táo được trồng ở hầu hết mọi quận của Kashmir và tạo ra doanh thu hàng năm 1500 crores Rupi.

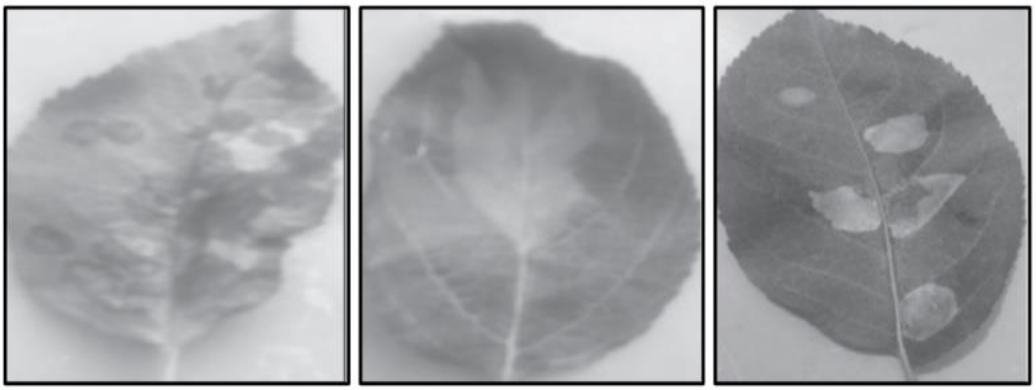
Tuy nhiên, cây táo dễ bị mắc một số loại bệnh, ảnh hưởng đến lá của nó. Các bệnh lá táo điển hình được tìm thấy ở Kashmir là bệnh đốm lá Alternaria, bệnh ghẻ táo, và bệnh thối táo, như thể hiện trong Hình 8.1. Những bệnh này khiến cả vườn cây bị tàn phá, đó là một thách thức lớn đối với nông dân. Những bệnh này làm hỏng chất lượng và giảm số lượng cây trồng. Các phương pháp truyền thống để chẩn đoán bệnh gây ra thiệt hại lớn hơn, vì các phương pháp này chậm, tốn nhiều công sức và không đáng tin cậy. Các phương pháp này cần các chuyên gia có kiến thức và kinh nghiệm sâu rộng và thường không chính xác. Thuốc trừ sâu sau đó được sử dụng cũng không phù hợp và trở thành gánh nặng kinh tế và môi trường.

Bây giờ, đã đến lúc cần thay đổi các phương pháp truyền thống tốn thời gian sang các phương pháp dựa trên công nghệ mới. Công nghệ tiên tiến đã đưa học máy vào sử dụng, giúp tự động phát hiện và phân loại bệnh trên lá táo. Tuy nhiên, phương pháp này có một nhược điểm, vì nó không thể áp dụng cho dữ liệu thô và đòi hỏi tiền xử lý. Học sâu hiện đã nổi lên như một giải pháp thay thế tốt hơn, vì nó có thể được áp dụng cho dữ liệu thô, và không cần thêm bước tiền xử lý.

Những tiến bộ hơn nữa trong học sâu đã dẫn đến ý tưởng về mạng nơ-ron tích chập (CNN). Nó đặc biệt được sử dụng để phân loại hình ảnh. CNN bao gồm hai thành phần - viz, tích chập (convolution) và gộp (pooling) được sử dụng để trích xuất đặc trưng, và thành phần phân loại (classifier), dự đoán đầu ra.

Trong nghiên cứu này, các phiên bản khác nhau của thuật toán CNN đã được sử dụng để dự đoán và phân loại các loại bệnh khác nhau trên lá táo.

Chương này bao gồm bốn phần. Phần đầu tiên là về các công trình liên quan đã được thực hiện trong các lĩnh vực liên quan. Phần thứ hai nói về các chi tiết thực nghiệm. Phần này bao gồm các phương pháp, xây dựng mô hình, bộ dữ liệu và môi trường thực nghiệm. Phần thứ ba là về phân tích kết quả bằng cách sử dụng các chỉ số đánh giá hiệu suất khác nhau. Phần cuối cùng tổng kết kết luận của nghiên cứu.



Hình 8.1 Các bệnh táo điển hình: (a) Bệnh đốm lá Alternaria, (b) bệnh ghẻ táo và (c) bệnh thối táo.

8.2 CÁC CÔNG TRÌNH LIÊN QUAN

Các kỹ thuật học sâu và học máy đã được thực hành trên các dự đoán bệnh khác nhau trên các loại nông sản khác nhau. Nghiên cứu liên quan đến việc xác định và phân loại các bệnh trên lá thực vật được trình bày trong phần này. Phần còn lại của mục này đưa ra giải thích chi tiết về các nghiên cứu đã được thực hiện trong lĩnh vực này. Tóm tắt của phần này được đưa ra trong Bảng 8.1.

Zhang và cộng sự [3] đã giới thiệu một phương pháp mới để xác định bệnh trên lá táo. Mô hình này dựa trên bộ phân loại máy vector hỗ trợ (SVM). Bộ dữ liệu để xác định lá táo bị bệnh chứa 90 hình ảnh của lá táo khỏe mạnh, lá bị bệnh khảm, lá bị bệnh phấn trắng, và lá bị bệnh gỉ sắt. Phương pháp này đã đạt được độ chính xác nhận dạng hơn 90%.

S. R. Dubey và cộng sự [4] đã phát triển một hệ thống để phát hiện và phân loại bệnh trên quả táo. Trong hệ thống này, việc phân đoạn hình ảnh được thực hiện bằng cách sử dụng phân cụm K-means. Các hình ảnh đã được phân đoạn sau đó được sử dụng để thu được các đặc trưng nghệ thuật (art features). Cuối cùng, các hình ảnh được phân loại thành bệnh đốm táo (apple blotch), bệnh thối táo (apple rot), và bệnh ghẻ táo (apple scab) bằng cách sử dụng SVM đa lớp. Mô hình này đã đạt được độ chính xác 93%.

Arivazhagan và cộng sự [5] đã phát triển một phần mềm dựa trên nhận dạng tự động và phân loại bệnh trên lá thực vật. Đối với phần xử lý, chuyển đổi màu và phân đoạn đã được áp dụng cho hình ảnh. Hệ thống đã sử dụng bộ phân loại SVM để nhận dạng và phân loại. Đã đạt được độ chính xác 94%.

Brahimi và cộng sự [6] cũng đã áp dụng một mô hình học sâu (thuật toán CNN) cho một nghiên cứu tương tự phân loại bệnh trên cà chua. Mô hình đã sử dụng hình ảnh lá và đạt được độ chính xác phân loại là 99%.

Khan và cộng sự [7] đã sử dụng khái niệm CNN để thực hiện trích xuất đặc trưng từ hình ảnh lá. Mô hình CNN hoạt động để dự đoán các lá bị bệnh và đạt được độ chính xác khoảng 97%.

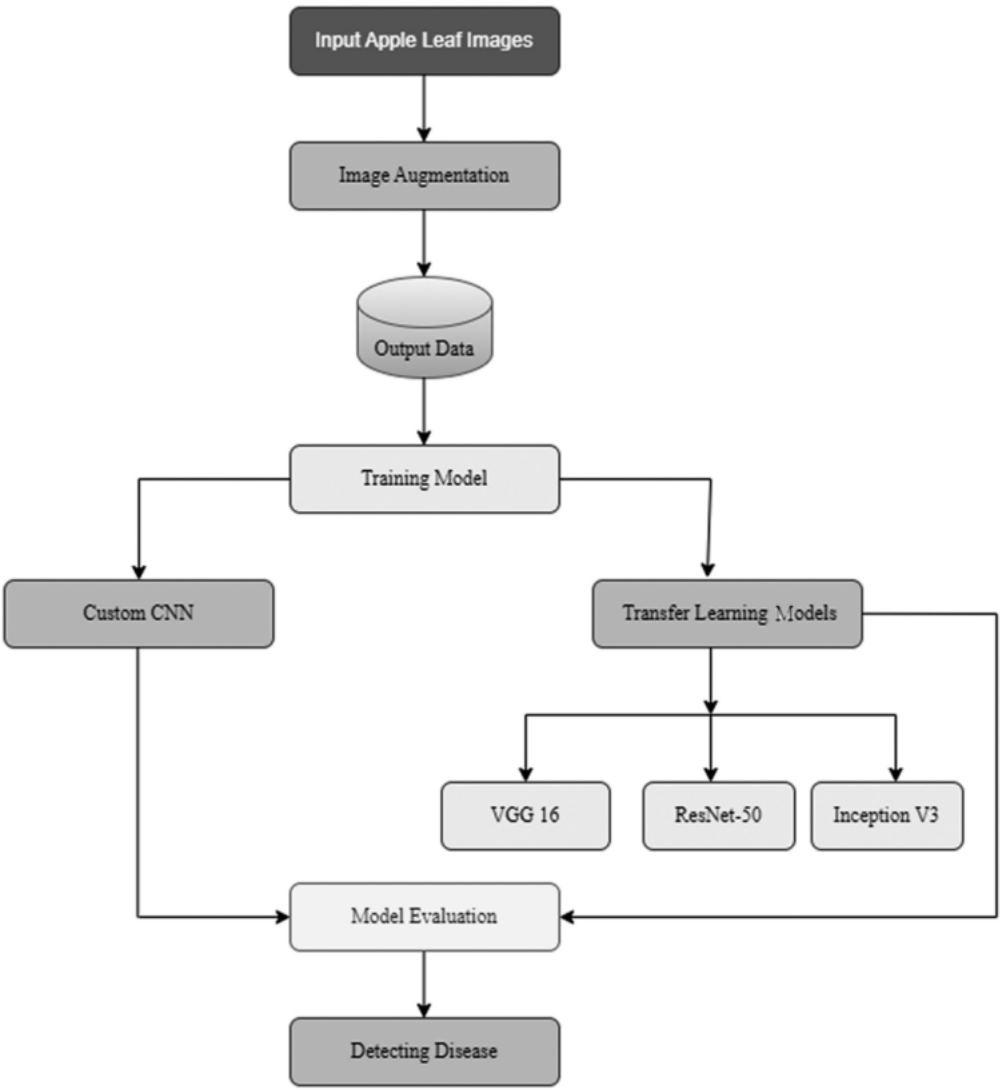
Jan và cộng sự [8] đã phát triển một hệ thống nhận dạng bệnh táo nổi bật để nhận dạng bệnh bạc lá/đốm lá và bệnh ghẻ táo. Hệ thống được đề xuất đã sử dụng các đặc trưng dựa trên hình dạng và các đặc trưng cấp thấp của lá để huấn luyện mô hình perceptron đa lớp (MLP). Mô hình đạt được độ chính xác 99.1%.

BẢNG 8.1: Các Công trình Liên quan Đã được Thực hiện trong Các Lĩnh vực Liên quan

Tác giả	Năm	Mô tả	Thuật toán	Độ chính xác Phân loại (%)
Zhang và cộng sự [3]	2017	Nhận dạng bệnh lá táo	SVM	90
Dubey và cộng sự [4]	2012	Nhận dạng và phân loại bệnh trên quả táo	SVM	93
Arivazhagan và cộng sự [5]	2013	Phát hiện và phân loại bệnh trên lá	SVM	94
Brahimi và cộng sự [6]	2017	Nhận dạng bệnh lá cà chua	CNN	99
Khan và cộng sự [7]	2021	Phân loại và nhận dạng bệnh táo	CNN	97.18
Jan và cộng sự [8]	2020	Chẩn đoán bệnh táo để dự đoán bệnh ghẻ táo và bệnh bạc lá/đốm lá	MLP	99.1

8.3 PHƯƠNG PHÁP LUẬN ĐỀ XUẤT

Phương pháp luận được sử dụng trong nghiên cứu này là một cách tiếp cận có cấu trúc được thiết kế để giải quyết một cách toàn diện các thách thức trong việc dự đoán và phân loại các bệnh trên lá táo. Các bước này bao gồm thu thập bộ dữ liệu hình ảnh, thực hiện tiền xử lý hình ảnh, xây dựng mô hình dự đoán, đánh giá hiệu suất của mô hình và phân tích kết quả. Phương pháp luận được thể hiện trong lưu đồ sau (Hình 8.2).



Hình 8.2 Các bước phương pháp luận.

8.3.1 Phương pháp

Nghiên cứu đã được tiến hành bằng cách sử dụng một CNN tùy chỉnh (Custom CNN), VGG 16, ResNet-50 và Inception V3. Các mạng được đào tạo trước VGG 16, ResNet-50 và Inception V3 đều được cung cấp bởi các kỹ thuật nơ-ron tích chập. Hoạt động của CNN, cùng với mô hình toán học của nó, được giải thích tiếp theo.

CNN là một loại thuật toán học sâu chủ yếu được sử dụng để phân loại hình ảnh. Kiến trúc của CNN chứa nhiều lớp, và mỗi lớp thực hiện một chức năng khác nhau. Các lớp của CNN được kết nối với nhau, và đầu ra của một lớp là đầu vào cho lớp tiếp theo. Về cơ bản, có ba lớp trong CNN - cụ thể là, lớp tích chập, lớp gộp, và lớp kết nối đầy đủ.

8.3.1.1 Lớp Tích chập

Lớp tích chập (convolution layer) là một lớp quan trọng trong CNN, có chức năng trích xuất đặc trưng. Việc trích xuất đặc trưng được thực hiện bằng cách sử dụng một

bộ lọc (filter) hoặc hạt nhân (kernel). Trong lớp tích chập, một bản đồ kích hoạt/đặc trưng (activation/feature map) được hình thành bởi phép toán tích chập giữa hình ảnh đầu vào và hạt nhân. Phương trình 8.1 biểu thị phép toán tích chập về mặt toán học.

$$O_j = f\left(\sum_{i=1}^{n} a_i * k_{i,j} + b_j\right) \text{ (8.1)}$$

Trước hết, hình ảnh đầu vào a_i được tích chập với hạt nhân $k_{i,j}$ sau đó tổng của phép toán tích chập được tính toán, và một độ lệch (bias) b_j được cộng vào kết quả. Cuối cùng, một hàm kích hoạt (activation function) f được áp dụng cho kết quả, và bản đồ đặc trưng O_j được tạo ra.

Độ lệch là một giá trị không đổi được sử dụng trong một hàm kích hoạt để dịch chuyển vị trí của đường cong sang trái hoặc phải để trì hoãn hoặc tăng tốc việc kích hoạt của một nơ-ron. Chức năng của hàm kích hoạt là quyết định xem nơ-ron có được kích hoạt hay không. Hàm kích hoạt được sử dụng rộng rãi nhất là Đơn vị Tuyến tính Chỉnh lưu (ReLU). Ưu điểm của hàm ReLU là nó không kích hoạt tất cả các nơ-ron cùng một lúc. Hàm ReLU không kích hoạt nơ-ron nếu các giá trị đầu vào là âm. Phương trình 8.12 (sic) biểu thị hàm ReLU về mặt toán học.

$$g(x) = max(0, x) \text{ (8.2)}$$

8.3.1.2 Lớp Gộp

Lớp gộp (pooling layer) xuất hiện sau lớp tích chập trong CNN. Chức năng của lớp gộp là giảm kích thước của bản đồ đặc trưng. Trong gộp, các yếu tố lân cận của đầu ra tích chập được kết hợp lại. Gộp trung bình (Average pooling) và gộp cực đại (max pooling) là các hoạt động gộp chính.

Gộp trung bình là một hoạt động gộp lọc bản đồ đặc trưng và chọn giá trị trung bình từ mảng (patch) được lọc , được biểu thị bằng toán học trong Phương trình 8.3.

$$f_{avg}(x) = \frac{1}{n}\sum_{i=1}^{n} x_i \text{ (8.3)}$$

Gộp cực đại là một hoạt động gộp lọc bản đồ đặc trưng và chọn giá trị lớn nhất từ mảng được lọc. Phương trình 8.4 đưa ra biểu diễn toán học của điều này.

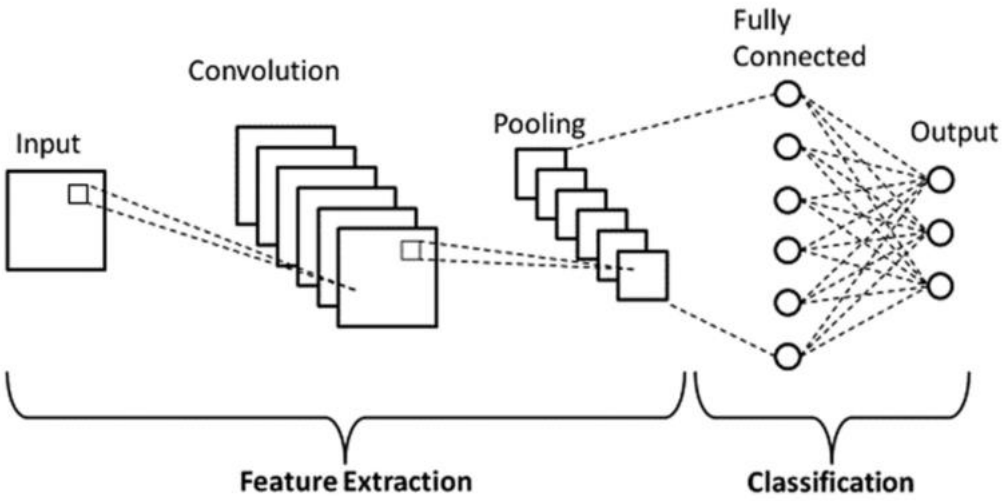
$$f_{max}(x) = max(x_i) \text{ (8.4)}$$

8.3.1.3 Lớp Kết nối Đầy đủ

Sau một số lớp tích chập và gộp, có một số lớp kết nối đầy đủ (fully connected layers). Đầu ra (bản đồ đặc trưng) từ các lớp tích chập và gộp được nối với nhau để tạo thành một bản đồ đặc trưng lớn hơn. Theo một cách khác, một lớp kết nối đầy đủ làm phẳng (flatten) hình ảnh đầu vào để nó chuyển đổi hình ảnh đầu vào đa chiều thành một mảng một chiều (vector).

Mỗi lớp kết nối đầy đủ có một hàm kích hoạt. Hầu hết đối với phân loại hình ảnh đa lớp, hàm kích hoạt Softmax được sử dụng cho lớp kết nối đầy đủ cuối cùng. Hàm Softmax chuyển đổi mảng một chiều thành phân phối xác suất có tổng bằng 1. Phương trình 8.5 biểu thị hàm kích hoạt Softmax về mặt toán học.

$$S = \frac{exp^{zj}}{\sum_{j=1}^{k} exp^{zj}} (8.5)$$



Hình 8.3 Kiến trúc của CNN tùy chỉnh.

8.3.2 Xây dựng Mô hình

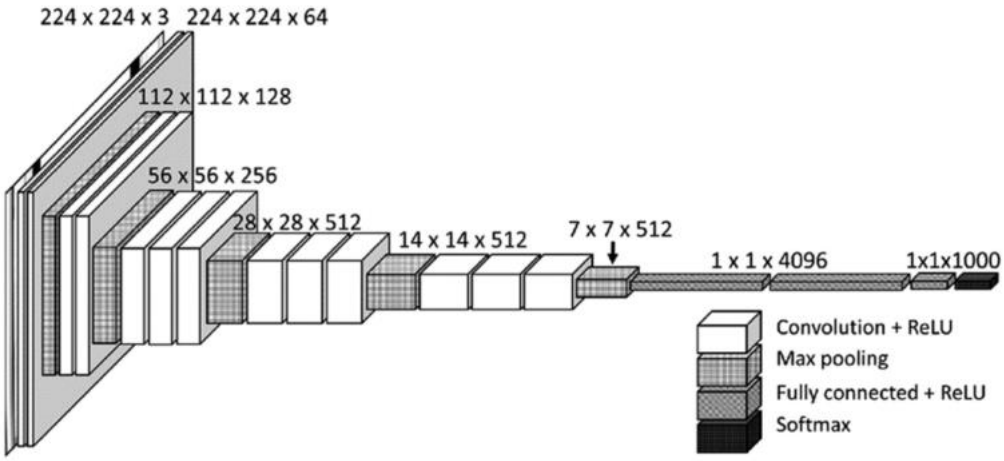
Các thuật toán CNN được sử dụng trong nghiên cứu này để xây dựng mô hình được đưa ra trong phần tiếp theo:

8.3.2.1 CNN Tùy chỉnh

CNN tùy chỉnh (Custom CNN) được đề xuất là một CNN 11 lớp chứa 4 lớp tích chập, 4 lớp gộp cực đại (max-pool), và 3 lớp dày đặc (dense). Kích thước đầu vào 150×150 được truyền qua 11 lớp của mạng. Mô hình này sử dụng hàm kích hoạt ReLU cho các lớp ẩn và hàm kích hoạt Softmax cho lớp đầu ra. Hình 8.3 cho thấy kiến trúc của mô hình.

8.3.2.2 VGG16

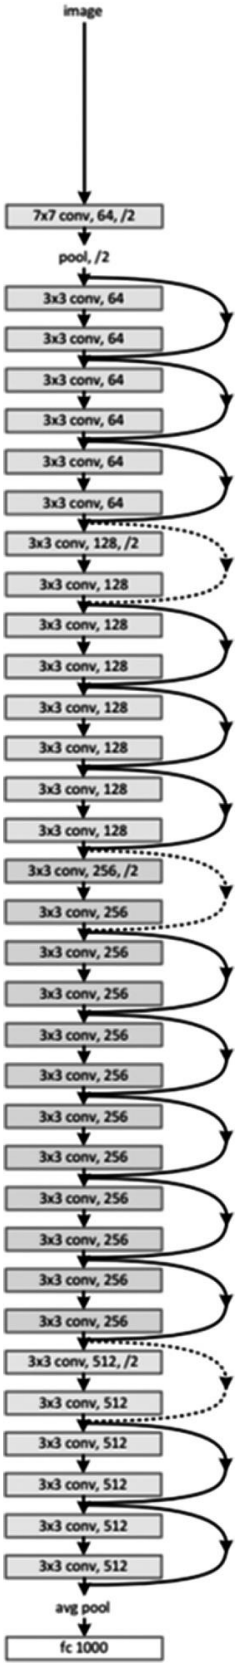
VGG (visual geometric group), được đề xuất bởi Zisserman và cộng sự vào năm 2014, là một CNN 16 lớp hoạt động trên 13 lớp tích chập, 5 lớp gộp cực đại, và 3 lớp dày đặc, tổng cộng là 21 lớp, trong đó chỉ có 16 lớp có trọng số. Kiến trúc được thể hiện trong Hình 8.4. Kích thước đầu vào 224×224 được truyền qua 16 lớp của mạng.



Hình 8.4 Kiến trúc của VGG16.

8.3.2.3 ResNet-50

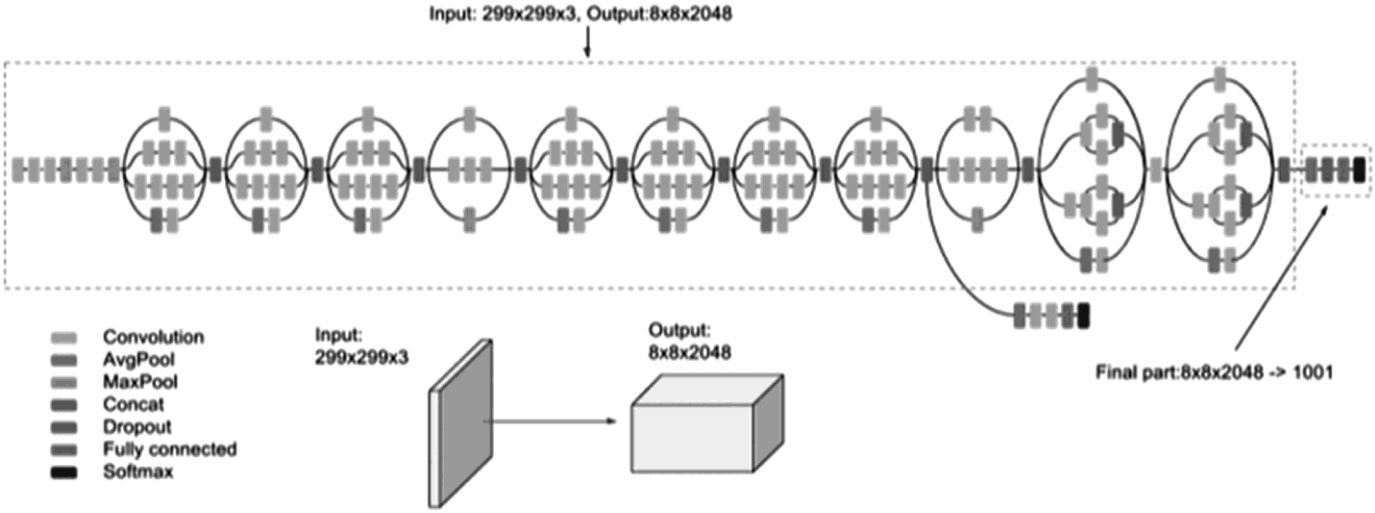
ResNet (residual network), được đề xuất bởi Kaiming và cộng sự vào năm 2015, là một CNN 50 lớp với 48 lớp tích chập, 1 lớp gộp cực đại, và 1 lớp gộp trung bình (average pool). Kiến trúc của Resnet-50 được thể hiện trong Hình 8.5. Kích thước đầu vào 180×180 được truyền qua 50 lớp của mạng.



Hình 8.5 Kiến trúc ResNet-50.

8.3.2.4 Inception V3

Inception v3 được đề xuất bởi Szegedy và cộng sự vào năm 2015. Inception V3 chứa 5 lớp tích chập, 2 lớp gộp cực đại, 11 mô-đun inception, 1 lớp gộp trung bình, và 1 lớp dày đặc. Kiến trúc của Inception V3 được thể hiện trong Hình 8.6. Kích thước đầu vào 229×229 được truyền qua 48 lớp của mạng.



Hình 8.6 Kiến trúc của Inception V3.

8.3.3 Bộ dữ liệu

Bộ dữ liệu cho nghiên cứu này được thu thập từ kho lưu trữ bộ dữ liệu Kaggle với tiêu đề "Kashmir Apple Leaf Disease". Bộ dữ liệu chứa 419 hình ảnh của lá bị nhiễm bệnh và lá khỏe mạnh. Bảng 8.2 chứa số lượng hình ảnh cho các lớp riêng lẻ.

BẢNG 8.2: Số lượng Bản ghi trong Bộ dữ liệu

Lớp	Tổng số Hình ảnh
Khỏe mạnh	46
Bệnh thối táo	103
Bệnh đốm lá Alternaria	111
Bệnh ghẻ táo	159

8.3.4 Tăng cường Dữ liệu

Tăng cường dữ liệu (Data augmentation) là một kỹ thuật mà qua đó dữ liệu nhân tạo được tạo ra từ bộ dữ liệu để giảm thiểu hiện tượng quá khớp (overfitting) trong quá trình huấn luyện mô hình. Trong tăng cường, các phép biến đổi không gian hình học và không gian màu (lật, thay đổi kích thước, cắt, độ sáng, và độ tương phản) được sử dụng. Trong nghiên cứu này, 419 tệp hình ảnh của bộ dữ liệu đã được tăng cường để tạo ra 2.000 tệp.

8.3.5 Môi trường Thực nghiệm

Việc viết mã cho thực nghiệm được thực hiện trong một môi trường Python gọi là Google Colab - một sản phẩm được phát triển bởi Google Research. Nó cho phép viết và thực thi mã trực tiếp thông qua một trình duyệt web.

8.4 ĐÁNH GIÁ MÔ HÌNH

Đánh giá mô hình đề cập đến phương pháp đánh giá hiệu suất của mô hình. Một số tham số đánh giá được sử dụng cho mục đích đó, tất cả đều dựa trên các kết quả sau đây của dự đoán phân loại: Âm tính Đúng (TN), Dương tính Đúng (TP), Dương tính Sai (FP), và Âm tính Sai (FN).

Các tham số đánh giá hiệu suất thông thường là độ chính xác (accuracy), độ chuẩn xác (precision), độ phủ (recall), và điểm F1 (F1-score).

- **Độ chính xác (Accuracy):** Tỷ lệ các dự đoán được phân loại chính xác bởi mô hình.

$$Acc = \frac{TN+TP}{TN+TP+FP+FN} \quad (8.6)$$

- **Độ chuẩn xác (Precision):** Tỷ lệ của các giá trị dương được phân loại chính xác trên tất cả các giá trị dương.

$$Precision = \frac{TP}{TP+FP} \quad (8.7)$$

- **Độ phủ (Recall):** Tỷ lệ của các giá trị dương được phân loại chính xác trên tổng số các giá trị dương trong một lớp.

$$Recall = \frac{TP}{TP+FN} \quad (8.8)$$

- **Điểm F1 (F1-score):** Trung bình điều hòa (trung bình có trọng số) của các giá trị được trả về bởi độ phủ và độ chuẩn xác.

$$F1 - score = \frac{2*(Precision*Recall)}{Precision+Recall} \quad (8.9)$$

Các giá trị của các tham số đánh giá hiệu suất cho tất cả các mô hình được trình bày trong Bảng 8.3.

BẢNG 8.3: Các tham số Đánh giá

Thuật toán	Độ chính xác Phân loại (%)	Độ chuẩn xác	Độ phủ	Điểm F1
Custom CNN	80	0.78	0.77	0.77
VGG16	85	0.82	0.81	0.81
ResNet-50	81	0.79	0.77	0.78
InceptionV3	0.83	0.80	0.78	0.79

8.5 KẾT QUẢ

Trong nghiên cứu hiện tại, bốn mô hình khác nhau - CNN tùy chỉnh, VGG16, ResNet-50, và InceptionV3 - đã được sử dụng để dự đoán và phân loại các bệnh trên lá táo. Các chỉ số hiệu suất, bao gồm độ chính xác phân loại, độ chuẩn xác, độ phủ, và điểm F1, đã được sử dụng để đánh giá các mô hình.

Trong số các mô hình này, VGG16 nổi lên là mô hình hoạt động tốt nhất, thể hiện độ chính xác ấn tượng là 85%. Độ chuẩn xác, độ phủ, và điểm F1 cho VGG16 cũng rất đáng khen ngợi, với các giá trị lần lượt là 0.82, 0.81, và 0.81. Các giá trị của các tham số hiệu suất của tất cả các mô hình được thể hiện trong Bảng 8.3. Điều này cho thấy VGG16 vượt trội trong việc xác định và phân loại chính xác các bệnh trên lá táo, cho thấy tiềm năng của nó trong việc triển khai thực tế trong các hệ thống phát hiện bệnh cho các vườn táo.

Hơn nữa, phân tích so sánh của các mô hình làm nổi bật tầm quan trọng của việc chọn một kiến trúc học sâu phù hợp. Mặc dù CNN tùy chỉnh, ResNet-50, và InceptionV3 đã chứng minh hiệu suất đáng nể, VGG16 liên tục vượt trội hơn chúng trên tất cả các chỉ số đánh giá. Sự mạnh mẽ của VGG16 trong việc xử lý sự phức tạp của hình ảnh lá táo và dự đoán chính xác các bệnh nhấn mạnh sự phù hợp của nó cho các ứng dụng trong thế giới thực. Những kết quả này không chỉ xác nhận hiệu quả của học sâu trong dự đoán bệnh mà còn nhấn mạnh tầm quan trọng của việc lựa chọn mô hình, với VGG16 nổi bật là lựa chọn đáng tin cậy và chính xác nhất để phát hiện các bệnh trên lá táo trong bối cảnh các vườn cây ăn quả của Kashmir.

8.6 KẾT LUẬN

Vào đầu chương này, những tiến bộ của học máy và học sâu cũng như mục đích của nghiên cứu này đã được thảo luận. Phân đoạn tiếp theo là về công việc đã được thực hiện trong lĩnh vực này. Sau đó, thiết lập thực nghiệm đã được thảo luận, bao gồm bộ dữ liệu, các bước được tuân thủ, và các mô hình. Phần cuối cùng là về kết quả của các mô hình được thực hiện bằng cách sử dụng các tham số đánh giá hiệu suất khác nhau.

Nghiên cứu này trình bày một tiến bộ đáng kể trong lĩnh vực nông nghiệp, đặc biệt là giải quyết những thách thức mà những người trồng táo ở Kashmir phải đối mặt. Hệ thống dựa trên học sâu được đề xuất, sử dụng các mô hình CNN tùy chỉnh, VGG16, ResNet-50, và InceptionV3, thể hiện độ chính xác đáng khen ngợi là 85%, với VGG16 dẫn đầu về hiệu suất. Việc phân loại lá táo thành các loại riêng biệt - khỏe mạnh, bệnh thối táo, bệnh đốm lá Alternaria, và bệnh ghẻ táo - chứng tỏ là một đóng góp vô giá cho cộng đồng nông dân.

Nghiên cứu không chỉ cung cấp một giải pháp thay thế hiệu quả và tiết kiệm chi phí cho các phương pháp dự đoán bệnh truyền thống mà còn biểu thị một sự thay đổi mô hình hướng tới việc tận dụng các công nghệ tiên tiến vì sự bền vững của nông nghiệp.

Nhìn về phía trước, tương lai của nghiên cứu này nằm ở việc tinh chỉnh và mở rộng liên tục. Tối ưu hóa các mô hình hiện có, khám phá các kỹ thuật học tập tổ hợp (ensemble techniques), và kết hợp các nguồn dữ liệu thời gian thực có thể nâng cao hơn nữa độ chính xác và khả năng áp dụng của hệ thống dự đoán. Mở rộng phạm vi

vượt ra ngoài lá táo để bao gồm một loạt các loại cây trồng rộng lớn hơn sẽ khuếch đại tác động của các mô hình này trong các bối cảnh nông nghiệp đa dạng.

Các nỗ lực hợp tác liên quan đến các chuyên gia trong lĩnh vực nông nghiệp, khoa học dữ liệu, và đổi mới công nghệ có thể thúc đẩy nghiên cứu liên ngành, thúc đẩy các giải pháp sáng tạo để quản lý bệnh cây trồng. Việc tích hợp các thiết bị Internet vạn vật (IoT), cảm biến, và phân tích dữ liệu lớn hứa hẹn các chiến lược kiểm soát bệnh chủ động, đảm bảo khả năng phục hồi và thịnh vượng của các cộng đồng nông nghiệp. Nghiên cứu này đánh dấu một bước quan trọng hướng tới việc tích hợp các công nghệ tiên tiến trong nông nghiệp, với những tác động sâu rộng cho tương lai của các thực hành canh tác bền vững và dựa trên công nghệ.

TÀI LIỆU THAM KHẢO

[1] A. Cornille, P. Gladieux, M. J. M. Smulders, I. Roldán-Ruiz, F. Laurens, B. le Cam, A. Nersesyan, J. Clavel, M. Olonova, L. Feugey, I. Gabrielyan, X. G. Zhang, M. I. Tenaillon, and T. Giraud. New Insight into the History of Domesticated Apple: Secondary Contribution of the European Wild Apple to the Genome of Cultivated Varieties. *PLoS Genetics*, *8*(5): e1002703, 2012. doi: 10.1371/journal.pgen.1002703

[2] *Apple Industry in J&K A Tumbling Sector – The Kashmir Horizon*. (n.d.). Retrieved January 22, 2023, from https://thekashmirhorizon.com/2022/09/27/apple-industry- in-jk-a-tumbling-sector/

[3] Z. Chuanlei, Z. Shanwen, Y. Jucheng, S. Yancui, and C. Jia. Apple Leaf Disease Identification Using Genetic Algorithm and Correlation Based Feature Selection Method. *International Journal of Agricultural and Biological Engineering*, *10*(2): 74–83, 2017.

[4] S. R. Dubey and A. S. Jalal. Detection and Classification of Apple Fruit Diseases Using Complete Local Binary Patterns. In *2012 Third International Conference on Computer and Communication Technology*, Allahabad, India, 2012, pp. 346–351. doi: 10.1109/ ICCCT.2012.76

[5] S. Arivazhagan, R. N. Shebiah, S. Ananthi, and S. V. Varthini. Detection of Unhealthy Region of Plant Leaves and Classification of Plant Leaf Diseases Using Texture Features. *Agricultural Engineering International: CIGR Journal*, *15*(1): 211–217, 2013.

[6] M. Brahimi, K. Boukhalfa, and A. Moussaoui. Deep Learning for Tomato Diseases: Classification and Symptoms Visualization. *Applied Artificial Intelligence*, *31*(4): 299–315, 2017. doi: 10.1080/08839514.2017.1315516

[7] A. I. Khan, S. M. K. Quadri, and S. Banday. Deep Learning for Apple Diseases: Classification and Identification. *International Journal of Computational Intelligence Studies*, *10*(1): 1–12, 2021.

[8] M. Jan and H. Ahmad. Image Features Based Intelligent Apple Disease Prediction System: Machine Learning Based Apple Disease Prediction System. *International Journal of Agricultural and Environmental Information Systems (IJAEIS)*, *11*(3): 31– 47, 2020.

[9] V. A. Kherdekar Convolution Neural Network Model for Recognition of Speech

for Words used in Mathematical Expression. *Turkish Journal of Computer And Mathematics Education*, *12*(6): 4034–4042, 2021.

[10] R. Prasath, M. Anand, and S. Hariharan. Image Classification Using Convolutional Neural Networks. (n.d.). Retrieved from http://www.acadpubl.eu/hub/

[11] Q. Li, W. Cai, X. Wang, Y. Zhou, D. D. Feng, and M. Chen. Medical Image Classification with Convolutional Neural Network. In *2014 13th International Conference on Control Automation Robotics and Vision, ICARCV 2014*, 2014, pp. 844–848. doi: 10.1109/ICARCV.2014.7064414

[12] *Importance of Neural Network Bias and How to Add It*. n.d. Retrieved March 3, 2023, from https://www.turing.com/kb/necessity-of-bias-in-neural-networks

[13] *ReLU Activation Function Explained | Built In*. n.d. Retrieved March 3, 2023, from https://builtin.com/machine-learning/relu-activation-function

[14] *Comprehensive Guide to Different Pooling Layers in Deep Learning*. n.d. Retrieved March 3, 2023, from https://analyticsindiamag.com/comprehensive-guide-to- different-pooling-layers-in-deep-learning/

[15] *Softmax Activation Function: Everything You Need to Know|Pinecone*. n.d. Retrieved March 3, 2023, from https://www.pinecone.io/learn/softmax-activation/

[16] *Understanding VGG16: Concepts, Architecture, and Performance*. n.d. Retrieved January 24, 2023, from https://datagen.tech/guides/computer-vision/vgg16/

[17] *The Architecture of the VGG-16 CNN Model [26].|Download Scientific Diagram*.
n.d. Retrieved January 24, 2023, from https://www.researchgate.net/figure/The-architecture-of-the-VGG-16-CNN-model-26_fig5_326349019

[18] *ResNet-50: The Basics and a Quick Tutorial*. n.d. Retrieved January 24, 2023, from https://datagen.tech/guides/computer-vision/resnet-50/

[19] *ResNet50_From_Scratch_Tensorflow | This Repository Implements the Basic Building Blocks of Deep Residual Networks Which Is Trained on SIGNS Dataset to Detect Numbers On Hand] Images*. n.d. Retrieved January 24, 2023, from https://jananisbabu. github.io/ResNet50_From_Scratch_Tensorflow/

[20] *Inception-v3 Explained|Papers with Code*. n.d. Retrieved January 24, 2023, from https://paperswithcode.com/method/inception-v3

[21] C. Szegedy, V. Vanhoucke, S. Ioffe, and J. Shlens.*Rethinking the Inception Architecture for Computer Vision*. n.d.

[22] *Kashmiri Apple Plant Disease Dataset | Kaggle*. n.d. Retrieved January 23, 2023, from https://www.kaggle.com/datasets/hsmcaju/d-kap

[23] Johnson, M. n.d. *What Is Data Augmentation in a CNN? Python Examples*. Retrieved March 3, 2023, from https://nnart.org/what-is-data-augmentation-in-a-cnn/

[24] *Welcome to Colaboratory - Colaboratory*. n.d. Retrieved January 23, 2023, from https://colab.research.google.com/

[25] M. Hossin, and M. N. Sulaiman. A Review on Evaluation Metrics for Data Classification Evaluations. *International Journal of Data Mining & Knowledge Management Process*, *5*(2): 01–11, 2015. doi: 10.5121/ijdkp.2015.5201

[26] S. N. H. Bukhari, J. Webber, and A. Mehbodniya. Decision Tree Based Ensemble Machine Learning Model for the Prediction of Zika Virus T-Cell Epitopes as Potential Vaccine Candidates. *Scientific Reports*, *12*: 7810, 2022. doi: 10.1038/

s41598-022-11731-6

[27] G. S. Raghavendra, S. Shyni Carmel Mary, P. B. Acharjee, V. L. Varun, S. N. H. Bukhari, C. Dutta, and I. A. Samori. An Empirical Investigation in Analysing the Critical Factors of Artificial Intelligence in Influencing the Food Processing Industry: A Multivariate Analysis of Variance (MANOVA) Approach. *Journal of Food Quality*, *2022*, Article ID 2197717, 7 pages, 2022. doi: 10.1155/2022/2197717

[28] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, and J. Webber. Ensemble Machine Learning Model to Predict SARS-CoV-2 T-Cell Epitopes as Potential Vaccine Targets. *Diagnostics*, *11*(11): 1990, 2021. MDPI AG. doi: 10.3390/diagnostics11111990

[29] S. L. Bangare, D. Virmani, G. R. Karetla, P. Chaudhary, H. Kaur, S. N. H. Bukhari, and S. Miah. Forecasting the Applied Deep Learning Tools in Enhancing Food Quality for Heart Related Diseases Effectively: A Study Using Structural Equation Model Analysis. *Journal of Food Quality*, *2022*, Article ID 6987569, 8 pages, 2022. doi: 10.1155/2022/6987569

[30] C. M. Anoruo, S. N. H. Bukhari, and O. K. Nwofor. Modeling and Spatial Characterization of Aerosols at Middle East AERONET Stations. *Theoretical and Applied Climatology*, *152*: 617–625, 2023. doi: 10.1007/s00704-023-04384-6

[31] F. Masoodi, M. Quasim, S. Bukhari, S. Dixit, and S. Alam. *Applications of Machine Learning and Deep Learning on Biological Data*. CRC Press, 2023.

[32] S. N. H. Bukhari, A. Jain, and E. Haq. A Novel Ensemble Machine Learning Model for Prediction of Zika Virus T-Cell Epitopes. In Gupta, D., Polkowski, Z., Khanna, A., Bhattacharyya, S., and Castillo, O. (eds) *Proceedings of Data Analytics and Management. Lecture Notes on Data Engineering and Communications Technologies*, vol. 91. Springer, Singapore, 2022. doi: 10.1007/978-981-16-6285-0_23

[33] S. N. H. Bukhari, F. Masoodi, M. A. Dar, N. I. Wani, A. Sajad, and G. Hussain. Prediction of Erythemato-Squamous Diseases Using Machine Learning. In *Auerbach Publications eBooks*, pp. 87–96, 2023. doi: 10.1201/9781003328780-6

[34] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, and J. Webber. Machine Learning Techniques for the Prediction of B-Cell and T-Cell Epitopes as Potential Vaccine Targets with a Specific Focus on SARS-CoV-2 Pathogen: A Review. *Pathogens*, *11*(2): 146, 2022. MDPI AG. doi: 10.3390/pathogens11020146

[35] S. Nisar, H. Bukhari, and M. A. Dar. Using Random Forest to Predict T-Cell Epitopes of Dengue Virus. *Adv. Appl. Math. Sci*.. *20*(11): 2543–2547, 2021.

CHƯƠNG 9: DỰ ĐOÁN NĂNG SUẤT CÂY TRỒNG NÔNG NGHIỆP: PHÂN TÍCH SO SÁNH SỬ DỤNG CÁC MÔ HÌNH HỌC MÁY

Kukatlapalli Pradeep Kumar, S. Babu Kumar, Amarthya Dutta Gupta, Kevin Johnson, và Meghan Mary Michael

CHRIST (Đại học được công nhận), Cơ sở Kengeri, Bangalore, Ấn Độ

9.1 GIỚI THIỆU

Nền kinh tế của các quốc gia mới nổi như Ấn Độ được hưởng lợi rất lớn từ nông nghiệp, một trong những hình thức cư trú phổ biến nhất. Khoảng **200.2 triệu ha** đất được sử dụng cho nông nghiệp ở Ấn Độ, là một nguồn thu nhập đáng kể. Ở Ấn Độ, **70%** dân số sống dựa vào nông nghiệp. Nền kinh tế của chúng ta đang chịu áp lực phải tăng sản lượng lương thực do dân số quá đông. Trong những năm gần đây, đã có một mong muốn rộng rãi về sự phát triển trong nhiều ngành công nghiệp do sự phát triển nhanh chóng của công nghệ thông tin. Nông nghiệp là một trong những lĩnh vực có nhiều không gian để phát triển.

Hạn chế này chủ yếu là do thiếu một mô hình nông nghiệp đáng tin cậy và sự hướng dẫn đầy đủ cho nông dân. Việc thực hiện các ứng dụng nông nghiệp thông minh ở các làng biệt lập của Ấn Độ là vô cùng khó khăn, đặc biệt là khi nói đến việc đáp ứng nhu cầu cộng đồng. Ví dụ, những người dân thất học và nghèo khó trồng lúa bằng các phương pháp truyền thống. Nông dân sẽ thấy dễ đưa ra quyết định hơn nếu có một cơ chế có thể **tự động hóa việc tưới tiêu**, **xác định chất lượng đất**, và **dự báo điều kiện thời tiết** cũng như **giá cả**. Nông nghiệp phải được phát triển mạnh mẽ thông qua các đổi mới trong kỷ nguyên số hóa này nếu muốn tiếp cận với những nông dân nhỏ lẻ và bị **thiệt thòi**.

Nhiều vụ mùa bị thất thu hàng năm do chuyên môn kỹ thuật không đầy đủ và các mô hình thời tiết không lường trước được, như **biến động nhiệt độ** và **lượng mưa**, có ảnh hưởng đáng kể đến **năng suất nông nghiệp** và **doanh thu**.

Dự đoán năng suất cây trồng (CYP) là một trách nhiệm quan trọng đối với các yếu tố nông nghiệp. Việc quản lý các yếu tố nông nghiệp và đảm bảo sản lượng cao nhất phụ thuộc rất nhiều vào dự đoán năng suất cây trồng (CYP). CYP chủ yếu tập trung vào hai bộ tính năng quan trọng nhất.

Theo nông dân, một bộ dữ liệu bao gồm các phương pháp được sử dụng để:

- **tưới tiêu**
- **bón phân**
- **chuẩn bị đồng ruộng**

Một bộ dữ liệu khác bao gồm các biến môi trường được chi phối bởi thiên nhiên, chẳng hạn như:

- **bức xạ mặt trời**
- **nhiệt độ**
- **lượng mưa**

Sự giao tiếp với các phương pháp quản lý đồng ruộng và các yếu tố môi trường ảnh hưởng đến cách hành xử của các **marker di truyền**. Số lượng biến số tuyệt đối phải được xem xét làm cho việc dự đoán năng suất cây trồng với bất kỳ mức độ chính xác nào trở nên gần như không thể.

Nông nghiệp chính xác, bao gồm dự đoán năng suất nông nghiệp, có một số lợi thế, bao gồm:

- **tăng cường sản lượng và chất lượng cây trồng**
- **giảm thiểu tác động môi trường**

Việc sử dụng các mô phỏng năng suất cây trồng giúp dễ dàng hiểu được các tác động tổng hợp của **thiếu hụt chất dinh dưỡng và nước, bệnh tật, sâu bệnh, và các biến số khác** trong đồng ruộng trong suốt mùa sinh trưởng. Điều này có thể dẫn đến các phương pháp nông nghiệp có ý thức về môi trường mà còn mang lại lợi ích cho xã hội nói chung.

Năng suất cây trồng có thể khó dự báo hơn do **tương tác giữa kiểu gen và các biến môi trường**. Rất khó để dự đoán chính xác **ảnh hưởng phi tuyến phức tạp** của các tác động bên ngoài, bao gồm cả thời tiết. Ngoài ra, khi đưa ra các quyết định tài chính, nông dân và người trồng trọt đều tính đến **dự báo cây trồng**. Hai trở ngại lớn nhất trong kỷ nguyên nông nghiệp số hiện tại là **thu thập dữ liệu** và **tích hợp dữ liệu**.

Học máy (ML), một tập hợp con của AI, tập trung vào học hỏi, và đó là một quá trình tự phát cung cấp CYP tốt nhất, tùy thuộc vào một số yếu tố. Phương pháp ML phân tích một bộ dữ liệu để tìm thông tin, mô hình và các mối liên hệ. Bộ dữ liệu nên được sử dụng để đào tạo thuật toán để kết quả có thể được dự đoán dựa trên kiến thức trước đó. Kỹ thuật dự đoán được xây dựng bằng cách sử dụng nhiều đặc điểm khác nhau; ví dụ, các tham số mô hình có thể được xác nhận bằng cách sử dụng dữ liệu từ việc học. Dựa trên các tính năng được trình bày, ML là một kỹ thuật thực tế giúp cải thiện dự báo sản lượng nông nghiệp.

Nhiều nghiên cứu đã sử dụng các kỹ thuật ML để phân loại CYP, bao gồm:

- **rừng ngẫu nhiên (random forests)**
- **cây hồi quy (regression trees)**
- **hồi quy đa biến (multivariate regression)**

Bằng cách phân tích dữ liệu trong quá khứ, chúng ta có thể chọn các tham số của mô hình dự đoán trong giai đoạn đào tạo sau. Việc đánh giá tính đến một phần dữ liệu trước đó.

Nhiều kỹ thuật, bao gồm **phân loại** và **phân cụm**, được sử dụng cho dự đoán. Thông tin được lấy ra từ dữ liệu.

Các doanh nghiệp nông nghiệp có thể quản lý các lựa chọn chuỗi cung ứng như **lập kế hoạch sản xuất** bằng cách sử dụng các dự báo sản xuất cây trồng và rủi ro chính xác. Dự báo sản lượng cây trồng đóng vai trò là nền tảng cho **tiếp thị**. Nhận dạng và lập bản đồ cây trồng được hưởng lợi từ việc sử dụng **hình ảnh đa thời gian**, điều này giúp có thể phân loại chi phí bằng cách tính đến sự khác biệt trong **độ phản xạ loại cây trồng**. Sử dụng các chỉ số năng suất nông nghiệp để xác định các vấn đề sớm và áp dụng các giải pháp có thể **tăng sản lượng cây trồng và lợi nhuận**. Một phát triển mới là việc sử dụng **mô hình lai (hybrid models)**, kết hợp nhiều phương pháp ML để **tăng độ chính xác**.

Học sâu (Deep learning), một nhánh của ML, sử dụng **mạng nơ-ron nhân tạo (ANNs)** với nghiên cứu về các biểu diễn. Trong sự hiện diện của dữ liệu phức tạp, chẳng hạn như **các nhóm và vùng trưởng thành, chi tiết di truyền, và các điều kiện khí tượng khác nhau**, các phương pháp học sâu có thể cung cấp câu trả lời. Kỹ thuật này có thể học hỏi cực kỳ hiệu quả các **mối quan hệ phi tuyến** giữa năng suất dự kiến cùng với dữ liệu đa biến được nhập vào (**thông tin cụm, yếu tố khí tượng, và nhóm trưởng thành**). **Mạng Bộ nhớ Ngắn-Dài Hạn (LSTM)**, rất hữu ích cho mô hình hóa chuỗi thời gian, có thể nắm bắt **sự phụ thuộc tạm thời dài hạn** trong các chuỗi đa biến đầy thách thức. Tiềm năng dự đoán của các mô hình ML cũng có thể được tăng lên bằng cách **kết hợp dữ liệu từ các nguồn khác**, chẳng hạn như **lập bản đồ 3D, dữ liệu điều kiện xã hội dựa trên cảm biến, và dữ liệu màu đất dựa trên drone**.

9.2 ĐÁNH GIÁ TÀI LIỆU

Năng suất cây trồng là một chủ đề có tầm quan trọng lớn về kinh tế và toàn cầu. Nó có thể giúp quản lý tài nguyên nông nghiệp một cách hiệu quả và đảm bảo an ninh lương thực. Những tiến bộ trong CYP có thể thúc đẩy nền kinh tế của một quốc gia và giúp ích trong quá trình ra quyết định của nông dân đối với việc **trồng trọt, thu hoạch và phân bổ nguồn lực**. Các bài báo văn học này đóng vai trò là nền tảng cho chương này, nhằm mục đích đưa ra một mô hình có thể phát triển thêm các kết quả và quan sát từ các nghiên cứu này. Phần này của chương trình bày các nghiên cứu đã tồn tại được thực hiện trên CYP bằng cách sử dụng các mô hình khác nhau như **học sâu, mạng nơ-ron (NN), và mô hình ML**.

9.2.1 Mạng Nơ-ron

Inam Ali và cộng sự [6] tìm thấy **mối tương quan giữa các thuộc tính từ dữ liệu lúa hiện có** và triển khai các phương pháp dựa trên **ML và phân tích** cho CYP. Nghiên cứu tập trung vào dữ liệu thu được từ **quận Larkana ở Pakistan**, nơi chưa từng được nghiên cứu trước đây từ khía cạnh năng suất nông nghiệp. Khu vực nông nghiệp ở Pakistan đóng góp đáng kể vào nền kinh tế của đất nước. Nghiên cứu cho thấy rằng bằng cách sử dụng **thuật toán Apriori** trên bộ dữ liệu cây lúa của Larkana, các nhà nghiên cứu đã có thể

chia sẻ các dự đoán năng suất quan trọng, có thể được mở rộng rộng rãi sang các cây trồng khác bằng cách thay đổi các thuộc tính cụ thể. Dữ liệu được sử dụng cho nghiên cứu được thu thập từ các phòng ban liên quan tại địa phương khác nhau. Bộ dữ liệu năng suất lúa cuối cùng chứa các tham số mục tiêu: **năm, năng suất, độ ẩm, tốc độ gió, nhiệt độ lượng mưa và diện tích**. Dữ liệu thu thập chứa dữ liệu cho các tham số đã đề cập trong khoảng thời gian **sáu năm**. Phương pháp **NN** đã được sử dụng để tối ưu hóa dữ liệu năng suất lúa, vì nó rất quan trọng và được ưa chuộng do mức độ chính xác của nó được chấp nhận. NNs đã được sử dụng để **tối ưu hóa kết quả dự đoán năng suất lúa**, cung cấp năng suất giá trị cao sẽ mang lại lợi ích cho nông dân, các nhà nông học địa phương và các quan chức chính phủ để đưa ra quyết định dựa trên cây lúa. Họ có thể đánh giá các giá trị dự báo của các biến được kết nối được nêu trong nghiên cứu và sử dụng dữ liệu này, cùng với các mô hình lịch sử, để đưa ra các quyết định dựa trên dữ liệu tốt hơn. Kết quả của nghiên cứu có thể củng cố nền kinh tế của đất nước bằng cách **tăng sản xuất lúa** và cũng hỗ trợ **ngăn ngừa tổn thất tiền tệ** phát sinh bởi nông dân.

Trong nghiên cứu của Gopi và cộng sự [7], **NNs**, cụ thể là một **mạng nơ-ron hồi quy tổ hợp (ERNN)**, được sử dụng với kỹ thuật **Tối ưu hóa Cáo Đỏ (RFO)** cho lời khuyên về cây trồng và dự báo năng suất. Canh tác chính xác được hưởng lợi từ việc **tăng chất lượng và năng suất cây trồng** mà **không có tác động tiêu cực đến môi trường**. Nó tập trung vào **giám sát các phản ứng đối với sự biến đổi giữa và trong nội bộ** trong các hệ thống nông nghiệp, hệ thống thông tin quản lý, công nghệ tỷ lệ biến đổi, và những thứ khác. Nông dân sử dụng các mô hình canh tác truyền thống để đưa ra các quyết định liên quan đến sản xuất và trồng trọt cây trồng, nhưng để hỗ trợ tạo ra các đánh giá dựa trên dữ liệu sau khi tính đến các khía cạnh biến đổi, **một hệ thống khuyến nghị cây trồng tự động** là cần thiết. Một bộ dữ liệu dự báo năng suất và lời khuyên cây trồng từ kho lưu trữ Kaggle đã được sử dụng để xác nhận kỹ thuật **RFOERNN-CRYP** bằng thực nghiệm. Kỹ thuật này sẽ giúp nông dân bằng cách hỗ trợ họ trong quá trình ra quyết định bằng cách tính đến các tham số nông nghiệp liên quan khác nhau. Phương pháp **RFO** được sử dụng trong quy trình **lựa chọn siêu tham số**, giúp **cải thiện hiệu suất** của quy trình học tổ hợp. Điều này cũng đảm bảo rằng **độ chính xác của mô hình được duy trì từ gốc**. Thông qua việc thực hiện nhiều phân tích thử nghiệm, người ta thấy rằng kết quả của **RFOERNN-CRYP là lạc quan**, với **điểm R^2 tối đa là 0.9988** và **độ chính xác là 98.45%**. Mô hình được đề xuất trong nghiên cứu có thể được thử nghiệm trên các bộ dữ liệu thực tế, lớn hơn trong tương lai. Ngoài ra, phạm vi sử dụng **học sâu và mô hình phát hiện kiểu hình cây trồng dựa trên công nghệ thị giác máy tính** sẽ trở nên khả thi.

Muthukumaran và cộng sự [8] tìm cách **cải thiện năng suất lúa** bằng cách sử dụng các **kỹ thuật tính toán tiến hóa** để dự đoán bản chất của các yếu tố ảnh hưởng đến tốc độ tăng trưởng với ý định **cải thiện an ninh lương thực**. Các nhà nghiên cứu tập trung vào **phân tích tác động thực tế, hàng ngày của các hiện tượng khí tượng, tốc độ gió, hướng gió và độ ẩm tương đối** thay vì dựa vào hồ sơ lịch sử. Một **Thuật toán ROANN** đã được sử dụng để dự đoán, và **Thuật toán Tối ưu hóa Đàn hạt Đa mục tiêu** và **Thuật toán Di truyền** đã được sử dụng để **tối ưu hóa các tham số đầu vào và tái cấu trúc cơ sở dữ liệu**. Người ta quan sát thấy rằng thuật toán ROANN được đề xuất dự đoán các yếu

tố mà nông dân cần tập trung vào trong khi **tương quan các hiện tượng khí tượng khác nhau**. Các kỹ thuật tối ưu hóa đã thành công trong việc **xác định các tham số đầu vào** từ bộ dữ liệu thời gian thực. Độ chính xác tối đa và tỷ lệ lỗi tối thiểu đã được quan sát khi **điều chỉnh các tham số NN** với các lớp ẩn và tốc độ học.

Một bài báo của Vignesh và cộng sự [9] nhằm mục đích dự đoán năng suất cây trồng bằng cách sử dụng **Visual Geometry Group (VGG)** và **Discrete Deep Belief Network** với phương pháp phân loại mạng để tạo ra các hệ thống CYP để kết nối dữ liệu thô với dự đoán năng suất cây trồng. Để đạt được điều này, các nhà nghiên cứu đã thu thập **các tham số dữ liệu từ trang web nông nghiệp nhà nước của Ấn Độ**, đóng vai trò là nền tảng cho mô hình dự đoán của họ. Các tham số dữ liệu được thu thập từ trang web nông nghiệp đã được đưa vào mạng, bao gồm nhiều lớp xếp chồng lên nhau. Các lớp này xử lý các tham số đầu vào một cách tuần tự, cuối cùng hình thành một **khuôn khổ toàn diện** cho dự đoán sản lượng cây trồng. Để tối ưu hóa dữ liệu đầu vào cho kết quả hiệu quả nhất, các nhà nghiên cứu đã sử dụng một kỹ thuật gọi là **"tối ưu hóa đàn gà con tinh chỉnh (tweak chick swarm optimization)"**. Phương pháp tối ưu hóa này **tinh chỉnh và tiền xử lý dữ liệu đầu vào**, đảm bảo rằng các đặc điểm liên quan và có giá trị nhất được trích xuất. Dữ liệu tinh chỉnh thu được sau đó được đưa vào quy trình phân loại như là đầu vào. Để thực hiện phân loại thực tế và dự đoán năng suất nông nghiệp, các nhà nghiên cứu đã sử dụng cả **Discrete Deep Belief Network** và **VGG Net Classifier**. Kết quả của phương pháp của họ rất ấn tượng, **vượt qua các phương pháp trước đó về độ chính xác dự đoán**. Cụ thể, mô hình này đạt được **tỷ lệ chính xác ấn tượng là 97%**, nhấn mạnh sự thành thạo của nó trong việc **chọn các loại cây trồng có khả năng mang lại lợi nhuận cao nhất**.

9.2.2 Thuật toán Tối ưu hóa

Nghiên cứu của Mohsen Yoosefzadeh và cộng sự [10] nhằm mục đích **cải thiện tiềm năng năng suất di truyền** trong cây đậu nành, một loại cây trồng cấp thực phẩm chính có thể là giải pháp bền vững nhất để giải quyết các mối lo ngại về an ninh lương thực ngày càng tăng và nhu cầu toàn cầu. Năm đặc điểm đầu tiên được xác định là các thuộc tính thành phần năng suất đậu nành quan trọng nhất đã được đánh giá. **Các thuật toán ML** đã được sử dụng cả riêng lẻ và cùng nhau trên dữ liệu được chọn thông qua **phương pháp tổ hợp** sử dụng **thuật toán Random Forest (RF), Multilayer Perceptron (MLP) và Radial Basis Function (RBF)**. Trong số các kỹ thuật này, **thuật toán RBF là hiệu quả nhất** với **hệ số xác định** (R^2) **là 0.81** và **sai số tuyệt đối trung bình (MAE) thấp hơn là** $148.61 kg.ha^{-1}$ cùng **giá trị lỗi căn bậc hai trung bình (RMSE) là** $185.31 kg.ha^{-1}$. RBF đã được chọn làm bộ phân loại phụ cho thuật toán E-B. Các phương pháp lai tạo có thể được sửa đổi để **cải thiện triển vọng di truyền của các đặc điểm phức tạp**, chẳng hạn như năng suất dựa trên các thuộc tính thứ cấp chi phối hiệu quả và kết quả cuối cùng. Mặc dù kết quả của nghiên cứu là hứa hẹn, việc đo lường các thành phần năng suất **tốn nhiều công sức** và, do đó, **không thể áp dụng cho các triển khai quy mô lớn** và do đó **hạn chế việc sử dụng chiến lược này cho các sáng kiến phát triển giống cây trồng**. Nghiên cứu sẽ giúp các nhà lai tạo **chọn dòng bố mẹ và**

thực hiện các phép lai tạo hiệu quả, hai quy trình quan trọng đối với các nhà lai tạo đang tìm cách phát triển các giống cây trồng có tiềm năng sản xuất di truyền cao hơn.

Dự đoán năng suất xem xét các loại tưới tiêu khác nhau là lý tưởng để **tối ưu hóa tài nguyên**. CYP đóng một vai trò không thể thiếu trong việc đạt được **lịch trình tưới tiêu và đánh giá các yêu cầu lao động cho việc lưu trữ và thu hoạch**. Độ chính xác của CYP đòi hỏi một sự hiểu biết logic chi tiết về **tính tương đối giữa năng suất và các yếu tố hợp tác**. Để đạt được kết nối này, **các bộ dữ liệu lớn và một mô hình hiệu quả** là cần thiết. Học sâu đã được sử dụng trong nghiên cứu này [11] để **đánh giá và phân tích dữ liệu phức tạp** như kiểu gen, các tham số thời tiết, các nhóm trưởng thành, v.v.. Một **Dự đoán Năng suất Cây trồng Tự động (ACYP)** sử dụng **Mô hình Tối ưu hóa Chính trị Hỗn loạn với Học sâu (CPODL)** được đề xuất. Các bước liên quan trong kỹ thuật ACYP-CPODL là **tiền xử lý và tối ưu hóa tham số**. Đối với mô hình này, việc **điều chỉnh siêu tham số** là bằng **thuật toán CPO**. Kỹ thuật này đã có thể đạt được và tạo ra các kết quả thành công hợp lý với **sai số trung bình bình phương (MSE) là 0.031** và **điểm R^2 là 0.936**. Tuy nhiên, cần lưu ý rằng **mô hình Bidirectional Long Short-Term Memory (BLSTM)** cũng đã có thể tạo ra các kết quả phản ánh mô hình đã đề cập ở mức độ tốt. Một loạt các mô phỏng rộng hơn trên các bộ dữ liệu chuẩn đã cho thấy rằng trong một nghiên cứu so sánh, **sự cải thiện trong các dự đoán được thực hiện bởi mô hình ACYP-CPODL được xác nhận và xác minh là đúng**. Nó đã chứng minh thành công như một kỹ thuật để **ước tính năng suất nông nghiệp**. Việc thiết kế **các mô hình dự đoán dựa trên kết hợp** sẽ cải thiện kết quả dự đoán trong tương lai.

Bài báo được tham chiếu là [12] tìm cách khai thác **dữ liệu rộng lớn được thu thập bởi các cơ sở quan sát Trái đất (EO)** để phát triển một mô hình có thể **nâng cao dự đoán năng suất cây trồng**. Để đạt được điều này, nghiên cứu tận dụng **dữ liệu EO có nguồn gốc từ vệ tinh Sentinal-2 và Landsat-8** để **tinh chỉnh các tham số của mô hình APSIM-Maize**. Để giải quyết các **sự không chắc chắn cố hữu** liên quan đến **các thuộc tính đất, các biến khí tượng và các thực hành quản lý không rõ**, một **phương pháp lấy mẫu Monte-Carlo** đã được sử dụng. Cách tiếp cận này cho phép các nhà nghiên cứu **tính đến và truyền bá các sự không chắc chắn này một cách hiệu quả**. Cụ thể, sử dụng cả **giá trị trung bình và các biện pháp không chắc chắn** được lấy từ bộ dữ liệu lưới đất, nghiên cứu đã tạo ra **25 biểu diễn hoặc tổ hợp thay thế của hồ sơ đất** cho mỗi địa điểm, do đó nắm bắt được **sự biến đổi trong các thuộc tính đất**. Nghiên cứu đã sử dụng dữ liệu được thu thập từ **hai vệ tinh EO chính, Sentinel-2 và Landsat-8, cho mục đích hiệu chuẩn**. Sentinel-2 cung cấp các quan sát có giá trị về **Chỉ số Diện tích Lá (LAI)**, trong khi Landsat-8 đóng góp dữ liệu liên quan đến **Chỉ số Thực vật Khác biệt Chuẩn hóa (NDVI)**. Các biến cụ thể này đã được chọn vì nghiên cứu trước đây đã chứng minh **sức mạnh dự đoán mạnh mẽ** của chúng liên quan đến năng suất cây trồng. Phân tích này rất quan trọng trong việc **xác định các tham số trong mô hình APSIM** mà gây ra **ảnh hưởng đáng kể nhất** đến dự đoán LAI ngô. Bằng cách đánh giá một cách có hệ thống **độ nhạy của các tham số này**, nghiên cứu tìm cách **tăng cường độ chính xác và độ tin cậy** của CYP trong mô hình APSIM-Maize.

Theo tác giả [13], việc sản xuất nông nghiệp liên quan đến một lượng **sự không chắc chắn đáng kể**; do đó, **không có cách tiếp cận nào có thể dự đoán đầy đủ kết quả cuối cùng**. Hạn chế này có thể được khắc phục bằng cách **tích hợp tối ưu hóa trí tuệ bầy đàn** với **hàm ảnh hưởng của phân bón** để trình bày nhiều khả năng về kết quả xác nhận trong các cài đặt ngẫu nhiên khác nhau. Phương pháp này **thực tế hơn các phương pháp thông thường như hồi quy**. Người ta nhấn mạnh rằng các **hạn chế cần thiết cho phương pháp [13] này sẽ mở rộng** khi thuật toán được áp dụng trong một **cài đặt thế giới thực**, có lẽ làm cho kết quả **lệch lạc** nhưng không đủ để ảnh hưởng đến ứng dụng của phương pháp. Để đáp ứng các mục tiêu của quản lý khoa học, công việc tiếp theo về phương pháp sẽ tập trung vào việc **nghiên cứu một bộ các mô hình bón phân được xác định trước**. Người ta lưu ý rằng thuật toán **hoạt động tốt trong việc giải hệ số phương trình, khớp và giải pháp năng suất tối đa**. Các phát hiện đã chứng minh một **mức độ khớp tăng lên** trong phương trình tác động của phân bón có khả năng **dự báo hợp lý tỷ lệ bón phân chính xác và cải thiện năng suất**.

Tầm quan trọng của dự đoán sản lượng cây trồng trong ngành nông nghiệp được thừa nhận trong bài báo này [147]. Nó dự định sử dụng các **phương pháp ML nổi tiếng**, bao gồm **bộ nhớ ngắn hạn dài (LSTM)** và **mạng nơ-ron tích chập (CNN)**. Để ước tính năng suất cho các cây trồng nhất định, nó **kết hợp cả hai mô hình đó**. Bộ dữ liệu được sử dụng trong nghiên cứu này bao gồm thông tin về **lượng mưa từ năm 1901 đến năm 2020**, cũng như thông tin năng suất nông nghiệp cho **bông, ngô, kê, lúa và mía**. Các bộ dữ liệu này được thu thập từ trang web của chính phủ Ấn Độ. Để sử dụng tất cả dữ liệu này một cách hiệu quả trong nghiên cứu này, nó đã được **tích hợp và tiền xử lý**. **Hàm tối ưu hóa cải tiến (IOF)** làm **giảm lỗi** và **hội tụ nhanh** tùy thuộc vào sự lan truyền ngược được sử dụng. Sau khi chạy các mô hình, các **số liệu hiệu suất** sau đây đã được sử dụng để đánh giá:

- **Sai số phần trăm tuyệt đối trung bình (MAPE)** - 0.836 đến 1.245
- **MAE** - 0.054 đến 2.321
- **RMSE** - 0.071 đến 2.321
- ** *R* -squared điều chỉnh** - 0.964 đến 0.977

9.2.3 Viễn thám và Hình ảnh

Bài báo này [16] đề cập đến việc sử dụng **Hình ảnh Đa phổ của Hệ thống Máy bay Không người lái (UAS)** để **dự đoán năng suất** và **tối ưu hóa tài nguyên đầu vào** cho cây ngô. Một UAS không người lái có thể được sử dụng để có được hình ảnh chứa **thông tin không gian và thời gian**, sẽ được sử dụng để phát triển một **mô hình thống kê để dự đoán năng suất** dựa trên các giai đoạn phát triển khác nhau. Nghiên cứu [16] đã được thực hiện tại **Trại Nghiên cứu Hệ thống Nông nghiệp W. B. Andrews ở Mississippi State, Mississippi, Hoa Kỳ**. Dữ liệu được sử dụng là từ **Trung tâm Thời tiết Nông nghiệp Delta**. Cánh đồng được chia thành các lô phụ, mỗi lô có các xử lý khác nhau để xác định lô nào là lý tưởng nhất cho cây ngô.

Bài báo này nhận ra **tầm quan trọng của CYP** trong lĩnh vực nông nghiệp. Nó nhằm mục đích sử dụng các **kỹ thuật ML phổ biến** như **mạng nơ-ron tích chập** và **bộ nhớ ngắn hạn dài**. Nó **kết hợp cả hai mô hình đó** để ước tính năng suất cho các cây trồng nhất định. Dữ liệu thu thập cho nghiên cứu này là một bộ dữ liệu chứa **dữ liệu lượng mưa từ năm 1901 đến năm 2020** và **dữ liệu năng suất cây trồng lúa, ngô, kê, mía và bông**. Các bộ dữ liệu này được thu thập từ **trang web của chính phủ Ấn Độ**. Tất cả dữ liệu này đã được **kết hợp và tiền xử lý** để được sử dụng hiệu quả trong nghiên cứu này. Bài báo đề xuất một **hàm tối ưu hóa nâng cao**, tức là **IOF**, để **giảm lỗi trong CYP**. Hàm IOF **giảm lỗi và hội tụ nhanh** tùy thuộc vào sự lan truyền ngược được sử dụng. Sau khi chạy các mô hình, các **số liệu hiệu suất** sau đây đã được sử dụng để đánh giá:

- **MAPE** - 0.836 đến 1.245
- **MAE** - 0.054 đến 2.321
- **RMSE** - 0.071 đến 2.321
- R -squared điều chỉnh - 0.964 đến 0.977

9.2.4 Lựa chọn Tính năng

Bài báo này [17] đề cập đến khía cạnh **lựa chọn tính năng** để **tối ưu hóa CYP**. Vì có nhiều yếu tố liên quan đến việc dự đoán năng suất cây trồng, việc **chọn những yếu tố cần thiết là quan trọng**, vì nhiều yếu tố ảnh hưởng đến năng suất cây trồng khác nhau.

Các thuật toán lựa chọn tính năng đã được sử dụng và các tính năng được chọn là:

- **Thuật toán Lựa chọn Tính năng Loại bỏ Lùi Tuần tự**: AH, CL, TK, OW, và Tmax
- **Thuật toán Lựa chọn Tính năng Dựa trên Tương quan**: AH, CL, TK, AT, Tmax, SD, NF, PF, và KF
- **Hệ số Lạm phát Phương sai**: AH, CL, TK, TW, OW, RainF, AT, Tmin, Tmax, và SR features (tính năng)
- **Hệ số Lạm phát Phương sai**: AH, CL, TK, TW, OW, RainF, AT, Tmin, Tmax, và R features (tính năng)
- **Độ quan trọng Biến RF**: AH, TK, OW, NF, PF, KF, và SD

Lấy **dự đoán phụ thuộc (PD)** làm tính năng phụ thuộc và **AH, OW, Tmax, TK, và CL** làm các tính năng độc lập, họ đã thực hiện **hồi quy tuyến tính đa biến**. Họ cũng đã sử dụng một **ANN**, lấy các tính năng độc lập làm lớp đầu vào và PD làm nơ-ron lớp đầu ra. **Độ chính xác của mô hình cuối cùng** được điều chỉnh bằng cách sử dụng **hệ số tương quan bình phương (R^2)** và đạt **85%** khi chỉ sử dụng các tính năng được chọn, trong khi khi sử dụng tất cả các tính năng, độ chính xác cuối cùng đạt **84%**. Điều này, do đó, có thể được sử dụng để kết luận rằng **thuật toán lựa chọn tính năng chuyển tiếp là tốt cho dự đoán tốt hơn**.

9.2.5 Tưới tiêu Chính xác

Bài báo này [18] đề cập đến việc đạt được **năng suất tối đa từ cây trồng** bằng cách sử dụng **công nghệ giữ nước dưới bề mặt (SWRT)**. Ở đây, chúng ta giải quyết quá trình **xác định năng suất cây trồng bằng cách sử dụng các thuật toán**. Chúng ta chủ yếu yêu cầu **hai yếu tố khác nhau** để xác định năng suất. Nghiên cứu này [18] được thực hiện do **mức độ ưu tiên cao** mà canh tác cây trồng bền vững có trong xã hội của chúng ta. Chúng ta cần sự **phối hợp tối ưu** của **thực phẩm, nước và năng lượng** để tiếp tục tiến lên. Vì nước đóng một vai trò rất lớn trong phát triển nông nghiệp, **việc sử dụng nước hiệu quả nhất** đóng một vai trò quan trọng trong việc **tối ưu hóa năng suất cây trồng**.

SWRT là một phương pháp được phát triển để **cải thiện khả năng giữ nước-đất** trong vùng rễ cây. Sử dụng **phần mềm HYDRUS-2D**, chúng ta tìm thấy **thiết kế màng và độ sâu lắp đặt thích hợp** trong điều kiện đất và thời tiết cụ thể trong **đất cát**. Thông qua các thử nghiệm khác nhau, người ta kết luận rằng **mô hình HYDRUS-2D có độ tin cậy cao và có độ chính xác đáng kể**. Mặc dù HYDRUS-2D có thể dự đoán sự **tích lũy nước và chất dinh dưỡng** tại vùng rễ cây, nó **không thể mô phỏng sự phát triển của cây trồng**. Để bù đắp cho thiếu sót này, chúng ta triển khai **phần mềm DSSAT** để cung cấp **thông tin chi tiết về năng suất cây trồng** từ hỗn hợp nước-đất cụ thể. Sử dụng mô hình toán học thích hợp và sử dụng đúng cả hai phần mềm, chúng ta có thể **thực hiện mô phỏng năng suất cây trồng dưới các màng SWRT khác nhau**. Các thử nghiệm và kết quả trong bài báo này [18] giúp chúng ta kết luận rằng việc sử dụng cả DSSAT và HYDRUS-2D, sẽ giúp **cắt giảm nỗ lực của con người trong việc tối ưu hóa các tham số nhất định**, điều này sẽ dẫn đến **tăng sản xuất cây trồng**.

9.3 PHƯƠNG PHÁP LUẬN

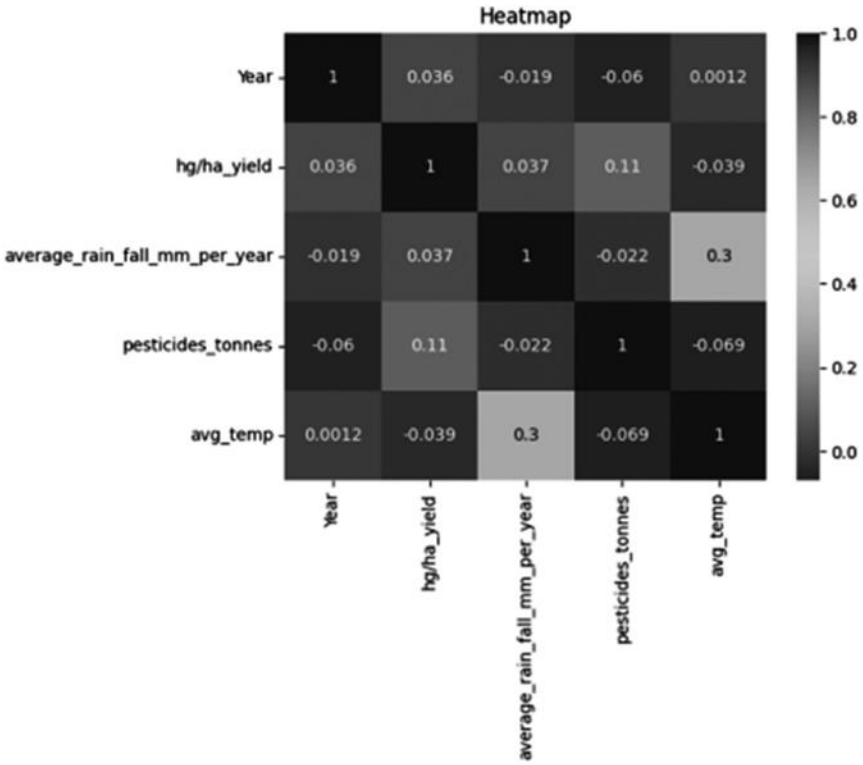
9.3.1 Tiền xử lý

Tiền xử lý đóng một vai trò quan trọng trong việc thiết kế một thuật toán ML, vì hầu hết các thuật toán yêu cầu dữ liệu để học hỏi và đưa ra dự đoán. Nếu dữ liệu không đạt yêu cầu, các dự đoán sẽ thực sự **không chính xác**.

Tiền xử lý chúng tôi đã thực hiện trong bộ dữ liệu được chọn bao gồm những điều sau đây:

1. Phân tích ngoại lai (Outlier Analysis)
2. Phân tích tương quan (Correlation Analysis)
3. Cập nhật giá trị bị thiếu (Updating Missing Values)
4. Mã hóa One-Hot (One-Hot Encoding)

Hình 9.1 là bản đồ nhiệt (heatmap) cho thấy **mối tương quan giữa tất cả các biến** trong bộ dữ liệu cuối cùng của chúng tôi.



Hình 9.1 Bản đồ nhiệt tương quan cho một tập hợp các thuộc tính đã cho.

Như chúng ta có thể thấy ở đây, chúng tôi đã lấy **năm biến** để phân tích, vì các biến khác đã bị loại bỏ vì không có đủ sự liên quan để mô hình được sử dụng. Vì tương quan nằm trong khoảng từ -1 đến 1 trong bản đồ nhiệt (**-1 cho thấy tương quan nghịch mạnh** và **1 cho thấy tương quan mạnh**), bỏ qua đường chéo trong ma trận, **thay đổi cao nhất xảy ra trong năng suất cây trồng tùy thuộc vào biến** $pesticides_t onnes$ **(0.11)**.

9.3.2 Hồi quy Tuyến tính

Hồi quy tuyến tính có thể được định nghĩa là mối liên kết của một biến phụ thuộc với **một hoặc nhiều biến độc lập** được xác định bằng thống kê. Dựa trên giá trị đầu vào của một biến khác, nó có thể được sử dụng để **dự báo giá trị của một biến**. Trong trường hợp đã đề cập trước đó, biến có giá trị được tìm thấy được gọi là **biến độc lập**. **Biến phụ thuộc** là biến được sử dụng để ước tính giá trị của biến độc lập.

Hồi quy tuyến tính nhằm mục đích tìm ra **đường khớp nhất** có thể bao gồm các giá trị được dự đoán và mô tả mối liên kết giữa biến độc lập và các biến phụ thuộc. Nó thường được sử dụng để **ước tính xu hướng trong dữ liệu**. Nó là một kỹ thuật thống kê hiệu quả được sử dụng trong ML cho **phân tích dự đoán**. Biến phụ thuộc và biến độc lập được chứng minh là có **mối quan hệ tuyến tính**. Thông thường, các giá trị của các biến phụ thuộc nằm trên trục y cùng với các giá trị của các biến độc lập. Mô hình hồi quy tuyến tính được gọi là **hồi quy tuyến tính đơn giản** khi chỉ có **một biến đầu vào**.

Đường khớp nhất được tính bằng cách sử dụng **công thức chặn dốc truyền thống**, được đưa ra như sau:

$$Y_i = \alpha_0 + \alpha_1 X_i \quad (9.1)$$

Trong **Phương trình 9.1**, Y_i biểu thị **biến phụ thuộc** (đã được vẽ trên trục y trước đó), và X_i biểu thị **biến độc lập** được vẽ trên trục x. Các hệ số α_0 và α_1 lần lượt đại diện cho **giá trị hằng số/điểm chặn** và **độ dốc của đường khớp nhất**.

9.3.3 Hồi quy Đa thức

Trong một số trường hợp nhất định, các điểm được vẽ trên biểu đồ hồi quy x-y có thể là **phi tuyến tính** và, do đó, một đường thẳng khớp nhất duy nhất có thể không bao gồm hoặc tính đến tất cả các điểm. Để điều chỉnh kịch bản này, chúng ta yêu cầu **việc thực hiện các mô hình hồi quy đa thức**. Đó là, để khắc phục các điều kiện **underfitting** hoặc **overfitting** do việc sử dụng một đường thẳng làm đường khớp nhất, **hồi quy đa thức** được sử dụng. Hồi quy đa thức giúp xác định **mối liên kết cong tuyến tính** giữa các biến phụ thuộc và độc lập. Trong hồi quy đa thức, mối liên kết giữa các biến phụ thuộc và độc lập được mô hình hóa dưới dạng một **hàm đa thức bậc p**. Chỉ trong các điều kiện này, hồi quy đa thức mới có thể được thực hiện. Ngoài ra, người ta kỳ vọng rằng **các lỗi là ngẫu nhiên, phân bố đều với giá trị trung bình bằng không và phương sai là hằng số**.

Một số đặc điểm của hồi quy đa thức là:

- **Bậc của hàm có thể được thay đổi** để xác định đường khớp nhất cho một tập hợp các điểm đã cho
- Mô hình **dễ bị ảnh hưởng bởi các ngoại lai**, có thể ảnh hưởng đến kết quả

Công thức tiêu chuẩn cho hồi quy đa thức có thể được đưa ra như trong **Phương trình 9.2**.

$$g(y) = d_0 + d_1 y + d_2 y^2 + \ldots + d_p y^p \quad (9.2)$$

Trong đó **p** là **bậc của đa thức** và **d** là **tập hợp các hệ số**.

Đối với bậc thấp hơn, mối quan hệ có tên cụ thể, tùy thuộc vào giá trị của p:

- Khi giá trị của **p là 2**, nó được gọi là **mô hình hồi quy bậc hai (quadratic regression model)**
- Tương tự, khi giá trị của **p là 3 và 4**, nó được gọi là **mô hình hồi quy bậc ba (cubic)** và **bậc bốn (quartic)**, tương ứng

Phương pháp **bình phương nhỏ nhất** thường được sử dụng để khớp các mô hình hồi quy đa thức, **giảm thiểu phương sai của các hệ số**. **Việc chọn đúng bậc (p)** cho một mô hình là **cần thiết** vì nó **ngăn chặn overfitting hoặc underfitting**.

9.3.4 XGBoost

XGBoost là viết tắt của **eXtreme Gradient Boosting**. Nó là một sản phẩm của **cây quyết định tăng cường gradient** có thể mang lại kết quả với **tốc độ và hiệu suất cao**. Nó hữu ích trong việc đạt được kết quả trên nhiều thách thức ML. Nó hoạt động phần lớn trên **gradient boosting**, là một **thuật toán học tổ hợp có giám sát**, trong đó nó cố gắng dự đoán giá trị bằng cách **kết hợp các ước tính của một tập hợp các mô hình đơn giản hơn, yếu hơn**.

Nó được ưa chuộng cao do khả năng **thao tác các bộ dữ liệu lớn đáng kể** và **hoạt động tốt trong các trường hợp liên quan đến hồi quy và phân loại**. Do khả năng **quản lý các giá trị bị thiếu mà không yêu cầu tiền xử lý đầu vào**, nó được yêu thích. Ngoài ra, nó bao gồm **chức năng xử lý song song tích hợp**, cho phép nó **đào tạo các mô hình nhanh chóng với các bộ dữ liệu lớn**.

Cây quyết định được xây dựng tuần tự trong thuật toán. **Trọng số** là một tham số quan trọng trong XGBoost. Trọng số được liên kết riêng lẻ với tất cả các biến độc lập; sau đó, chúng được đưa vào các cây quyết định, dự đoán kết quả. **Nhiều cây quyết định** được sử dụng để **tinh chỉnh các kết quả dự đoán** bằng cách đưa dữ liệu về phía trước; điều này được gọi là **học tổ hợp**. **Đạo hàm bậc nhất (gradient)** và **đạo hàm bậc hai (Hessian)** của hàm mất mát được tính cho mỗi điểm dữ liệu, như được mô tả trong **Phương trình 9.3 và 9.4**, tương ứng. Các giá trị này được sử dụng để **xây dựng các cây riêng lẻ và điều chỉnh mô hình**.

Gradient Hồi quy (g_i) cho MSE:

$$g_i = -2^*(y_i - y_i) \quad (9.3)$$

Hessian Hồi quy (h_i) cho MSE:

$$h_i = 2 \quad (9.4)$$

Quá trình điều chỉnh đệ quy được thuật toán áp dụng làm cho nó **hiệu quả trong việc nắm bắt các mối quan hệ phức tạp với dữ liệu**, do đó làm cho nó **ngày càng chính xác hơn trong việc nắm bắt các mô hình và tương tác phi tuyến tính**. Nó sử dụng một **giá trị điều chuẩn** trong hàm mục tiêu của nó. XGBoost bao gồm các **thuật ngữ điều chuẩn L1 (Lasso) và L2 (Ridge)** để **kiểm soát độ phức tạp của các cây riêng lẻ và ngăn chặn overfitting**.

$$\text{Mục tiêu Điều chuẩn} = Mục tiêu + Hình phạt$$

Điều này là cần thiết trong việc **ngăn chặn overfitting**, là một điều kiện trong đó mô hình ML trở nên **quá phù hợp với dữ liệu đào tạo** đến mức nó không thể thích nghi với một bộ dữ liệu mới. Trong XGBoost, kỹ thuật điều chuẩn hỗ trợ trong việc **đảm bảo một mối tương quan mạnh mẽ giữa kết quả được tạo ra bởi mô hình đối với bộ dữ liệu đào tạo và bộ dữ liệu thử nghiệm**. Cách tiếp cận tổ hợp được áp dụng cũng cho phép thuật toán **khai thác sức mạnh của nhiều mô hình** đồng thời **giảm thiểu điểm yếu của**

chúng. XGBoost được ưa chuộng cao, vì nó là **phần mềm mã nguồn mở** trải qua quá trình **phát triển liên tục** bởi các chuyên gia đóng góp trong lĩnh vực này.

9.3.5 KNN

K-nearest neighbors, thường được gọi là **KNN**, là kỹ thuật ML thường được sử dụng cho các **vấn đề phân loại và hồi quy**. Nó là một **thuật toán dựa trên trường hợp** mà, không giống như các thuật toán khác, **không xây dựng một thuật toán rõ ràng** trong giai đoạn đào tạo của nó. Nó là một thuật toán dựa trên **kỹ thuật học có giám sát**. Thuật toán KNN **ghi nhớ toàn bộ bộ dữ liệu đào tạo** và, để phản hồi một điểm dữ liệu không xác định, **xác định vị trí K điểm gần nhất** trong bộ dữ liệu đào tạo và **gán giá trị mới cho lớp hoặc nhãn** dựa trên **một cuộc bỏ phiếu đa số hoặc một giá trị trung bình của k hàng xóm**. Điều này được thực hiện bằng cách sử dụng **khoảng cách Euclidean** cho các tính năng liên tục và **khoảng cách Hamming** cho các tính năng phân loại.

Khoảng cách Euclidean giữa hai điểm p và q trong một không gian d -chiều được thể hiện trong **Phương trình 9.5**:

$$Khoảngca´chEuclidean(p,q) = \sqrt{\sum_{i=1}^{d}(P_i - q_i)^2} \quad (9.5)$$

Thuật toán có hai tham số - cụ thể là **K** và **độ đo khoảng cách**. **K** là **số lượng hàng xóm cần xem xét**. Nó là một **siêu tham số quan trọng** trong thuật toán, và việc **lựa chọn chính xác** của nó có thể **ảnh hưởng đáng kể đến hiệu suất** của thuật toán. **Độ đo khoảng cách** được sử dụng để tìm **sự giống nhau** giữa hai điểm dữ liệu đã cho. Mặc dù KNN là một thuật toán đơn giản, nó có một số hạn chế, chẳng hạn như **độ nhạy với giá trị của k, độ nhạy với việc lựa chọn độ đo khoảng cách, và sự kém hiệu quả về mặt tính toán với các bộ dữ liệu lớn**.

9.4 KẾT QUẢ VÀ THẢO LUẬN

Mục tiêu chính của phần này là trình bày các **kết quả của các thử nghiệm mô hình**. Sau khi các mô hình dự đoán khác nhau đã được đào tạo, chúng ta có thể sử dụng **Python 3.8.0** để chạy mô phỏng. Các kết quả nhất quán sẽ được tạo ra khi **số lượng thử nghiệm được tăng lên**. Kết quả là, chúng tôi sẽ đánh giá mức độ hiệu quả của các mô hình ML được nêu trong việc **dự đoán năng suất cây trồng nói chung** trong phần này.

9.4.1 Đánh giá Mô hình

- **Sai số Trung bình Bình phương (Mean Squared Error - MSE)**

MSE nổi lên như một **tham số quan trọng** làm sáng tỏ **hiệu quả dự đoán** của các mô hình ML được sử dụng trong nghiên cứu dự đoán sản lượng cây trồng này. Nó tính toán **sự khác biệt bình phương** giữa **năng suất cây trồng dự kiến** và **năng suất quan sát được** cho mỗi điểm dữ liệu trong bộ dữ liệu. Việc tính toán MSE bao gồm **tổng hợp tất**

cả các khác biệt bình phương này và sau đó **lấy giá trị trung bình** trên tất cả các điểm dữ liệu.

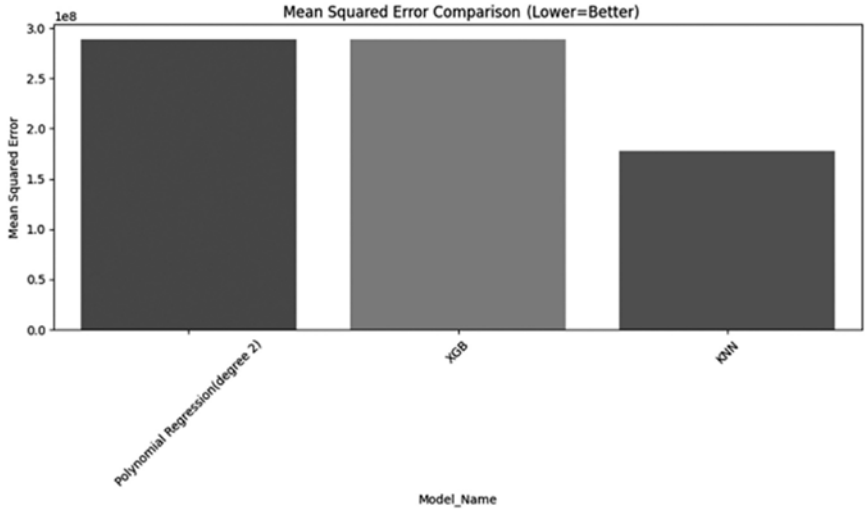
Về mặt toán học, quá trình này có thể được biểu thị như trong **Phương trình 9.6**:

$$MSE = \frac{1}{n} * \sum(năngsuâ´tthựctê´ - năngsuâ´tdựđoa´n)^2 \quad (9.6)$$

Trong ngữ cảnh này, biến **"n"** đại diện cho **tổng số điểm dữ liệu**.

Giá trị MSE thấp hơn cho thấy các mô hình - cụ thể là **XGBoost, hồi quy đa thức và KNN** - tạo ra các dự đoán **tương ứng chặt chẽ với năng suất cây trồng quan sát được**. MSE giảm cho thấy các mô hình **nắm bắt thành công các mô hình nội tại và sự biến động trong dữ liệu**, từ đó **tăng cường độ tin cậy tổng thể** của các dự đoán của chúng.

Như chúng ta có thể thấy trong **Hình 9.2**, trục x đại diện cho **tên của mô hình** mà chúng tôi đã sử dụng, và trục y đại diện cho **MSE tương ứng**. Các giá trị nằm trong khoảng từ **0.0 đến 3.0**, như được thấy trên trục y. Ở đây, **thanh càng thấp** cho mỗi mô hình, **hiệu suất của nó càng tốt**, vì lỗi càng thấp.



Hình 9.2 So sánh sai số trung bình bình phương.

- **Điểm R -squared (R^2 Score)**

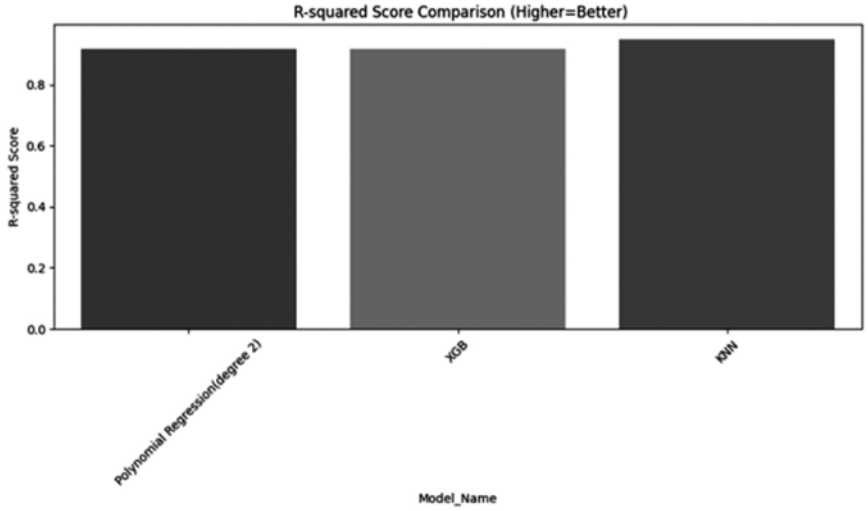
Trong quá trình đánh giá mức độ hiệu quả của các mô hình ML phù hợp với dữ liệu năng suất cây trồng quan sát được, **điểm R -squared (R^2) đóng một vai trò quan trọng**. Chỉ số này định lượng **tỷ lệ phương sai tổng thể** trong dữ liệu năng suất cây trồng mà các mô hình có khả năng giải thích. Việc sử dụng điểm R^2 cho phép **đánh giá hiệu suất của các mô hình XGBoost, hồi quy đa thức và KNN** liên quan đến một mô hình tham chiếu.

Giá trị **0 cho R^2** (nằm trong khoảng từ 0 đến 1) cho thấy rằng, giống như một mô hình trung bình cơ bản, các mô hình **không thể giải thích bất kỳ biến thể nào trong năng suất cây trồng**. Ngược lại, **điểm R^2 là 1** báo hiệu rằng các mô hình **có khả năng nắm**

bắt tất cả sự biến động hiện diện trong dữ liệu, dẫn đến các dự đoán **khớp chính xác với năng suất quan sát được**.

Trong nghiên cứu này, **điểm R^2 cao hơn** chứng minh **sự thành thạo của các mô hình trong việc phân biệt các mô hình và xu hướng quan trọng** trong dữ liệu năng suất cây trồng. Những kết quả này nhấn mạnh **tầm quan trọng và độ tin cậy của các dự đoán của mô hình**, vì chúng cho thấy một **phần đáng kể của sự biến động năng suất được nắm bắt chính xác bởi các mô hình**.

Như chúng ta có thể thấy trong **Hình 9.3**, trục x đại diện cho **tên của mô hình** mà chúng tôi đã sử dụng, và trục y đại diện cho **điểm R -squared tương ứng**. Các giá trị nằm trong khoảng từ **0.0 đến 0.8**, như được thấy trên trục y. Ở đây, **thanh càng cao** cho mỗi mô hình, **hiệu suất của nó càng tốt**, vì điểm càng cao.



Hình 9.3 So sánh lỗi R -square.

9.5 KẾT LUẬN

ML đã trở thành một **công cụ hỗ trợ quyết định thiết yếu** để **dự báo năng suất cây trồng** trong nông nghiệp, cho phép **các quyết định sáng suốt** về lựa chọn và quản lý cây trồng trong suốt mùa sinh trưởng. Để ước tính năng suất cây trồng, nghiên cứu này đã sử dụng một **phân tích so sánh với ba mô hình ML: hồi quy tuyến tính, hồi quy đa thức và KNN**. Để cải thiện lĩnh vực nông nghiệp, điều cần thiết là **dự đoán năng suất cây trồng dựa trên các biến này**, bao gồm **nhiệt độ, sử dụng thuốc trừ sâu, lượng mưa và điều kiện khí hậu**.

Bộ dữ liệu thu được đã trải qua quá trình **tiền xử lý rộng rãi** để loại bỏ dữ liệu dư thừa hoặc không chính xác trước khi đào tạo mô hình. Sau đó, bộ dữ liệu được **chia thành các tập hợp con đào tạo và thử nghiệm** để hiệu suất của mỗi mô hình có thể được đánh giá.

Chạy ba mô hình ML mà chúng tôi đã sử dụng, chúng tôi thấy rằng **KNN có cả MSE thấp nhất:** $1.776102e+08$ **và điểm** R^2 **cao nhất: 0.948888**. Mặc dù hoạt động tốt trong các số liệu này, **KNN nên được sử dụng cẩn thận, vì nó có thể có xu hướng overfitting dữ liệu**, và nếu không, **XGBoost sẽ cung cấp một kết quả tương tự trong hầu hết các trường hợp**.

Các mô hình này có thể được sử dụng để **cải thiện hiệu quả của việc canh tác** bằng cách giúp cung cấp **việc sử dụng vật liệu và tài nguyên hiệu quả**. Nghiên cứu này nhấn mạnh cách ML có thể **cải thiện năng suất nông nghiệp và việc ra quyết định**, qua đó hỗ trợ **sự phát triển bền vững của ngành nông nghiệp**. Để **tối ưu hóa sản lượng cây trồng và thích ứng với các điều kiện môi trường thay đổi**, nông dân và các nhà hoạch định chính sách có thể sử dụng ML để làm lợi thế của họ. Điều này sẽ **đảm bảo an ninh lương thực và tăng trưởng kinh tế** trong lĩnh vực nông nghiệp.

TÀI LIỆU THAM KHẢO

1. "Economic Survey 2022–23: Agri growth rate falls but sector still resilient amid pandemic shock," www.downtoearth.org.in. https://www.downtoearth.org.in/news/agriculture/economic-survey-2022-23-agri-growth-rate-falls-but-sector-still- resilient-amid-pandemic-shock-87406
2. N. Alex, C. C. Sobin, and J. Ali, "A comprehensive study on smart agriculture appli- cations in India," *Wireless Personal Communications*, vol. 129, no. 4, pp. 2345–2385, Mar. 2023. doi: 10.1007/s11277-023-10234-5
3. K. P. Kumar, A. Unal, V. J. Pillai, H. Murthy, and M. Niranjanamurthy, eds., *Data Engineering and Data Science: Concepts and Applications*. 2023. ISBN: 9781119841876.
4. A. Nigam, S. Garg, A. Agrawal, and P. Agrawal, "Crop yield prediction using machine learning algorithms," *2019 Fifth International Conference on Image Information Processing (ICIIP)*, Shimla, India, 2019, pp. 125–130. doi: 10.1109/ICIIP47207.2019.8985951
5. K. P. Kumar, H. Murthy, V. J. Pillai, and B. R. Prathap, "Blockchain-enabled model for minimizing post harvest losses," *ECS Transactions*, vol. 107, no. 1, p. 17475, 2022. doi: 10.1149/10701.17475ecst
6. I. A. Supro, "Rice yield prediction and optimization using association rules and neural network methods to enhance agribusiness," *Indian Journal of Science and Technology*, vol. 13, no. 13, pp. 1367–1379, Apr. 2020. doi: 10.17485/ijst/v13i13.79
7. P. S. S. Gopi and M. Karthikeyan, "Red fox optimization with ensemble recurrent neural network for crop recommendation and yield prediction model," *Multimedia Tools and Applications*, vol. 83, pp. 1–21, Jul. 2023.
8. S. Muthukumaran, P. Geetha, and E. Ramaraj, "Multi-objective optimization with artificial neural network based robust paddy yield prediction model," *Intelligent Automation & Soft Computing*, vol. 35, no. 1, pp. 215–230, 2023. doi: 10.32604/iasc.2023.027449

9. K. Vignesh, A. Askarunisa, and A. M. Abirami, "Optimized deep learning methods for crop yield prediction," *Computer Systems Science and Engineering*, vol. 44, no. 2, pp. 1051–1067, 2023. doi: 10.32604/csse.2023.024475
10. M. Yoosefzadeh-Najafabadi, D. Tulpan, and M. Eskandari, "Application of machine learning and genetic optimization algorithms for modeling and optimizing soybean yield using its component traits," *PLOS ONE*, vol. 16, no. 4, p. e0250665, Apr. 2021. doi: 10.1371/journal.pone.0250665
11. G. Sunitha et al., "Modeling of chaotic political optimizer for crop yield predic- tion," *Intelligent Automation & Soft Computing*, vol. 34, no. 1, pp. 423–437, 2022. doi: 10.32604/iasc.2022.024757
12. H. Dokoohaki, T. Rai, M. Kivi, P. Lewis, J. Gómez-Dans, and F. Yin, "Linking remote sensing with APSIM through emulation and Bayesian optimization to improve yield prediction," *Remote Sensing*, vol. 14, no. 21, pp. 5389, Oct. 2022. doi: 10.3390/rs14215389
13. C. Chen, X. Wang, H. Chen, C. Wu, M. Mafarja, and H. Turabieh, "Towards precision fertilization: Multi-strategy grey wolf optimizer based model evaluation and yield estimation," *Electronics*, vol. 10, no. 18, p. 2183, Sep. 2021. doi: 10.3390/electronics10182183
14. U. Bhimavarapu, G. Battineni, and N. Chintalapudi, "Improved optimization algo- rithm in LSTM to predict crop yield," *Computers*, vol. 12, no. 1, p. 10, Jan. 2023. doi: 10.3390/computers12010010
15. K. P. Kumar, H. Murthy, V. J. Pillai, B. R. Prathap, M. Moses, and Y. Urs, "Data analysis and machine learning observation on production losses in the food processing industry," *2023 IEEE International Conference on Contemporary Computing and Communications (InC4)*, Bangalore, India, 2023, pp. 1–4. doi: 10.1109/InC457730.2023.10263147
16. R. Barzin, R. Pathak, H. Lotfi, J. J. Varco, and G. C. Bora, "Use of UAS multispectral imagery at different physiological stages for yield prediction and input resource optimization in corn," *Remote Sensing*, vol. 12, no. 15, pp. 2392, Jul. 2020. doi: 10.3390/rs12152392
17. P. S. Maya Gopal and R. Bhargavi, "Selection of important features for optimizing crop yield prediction," *International Journal of Agricultural and Environmental Information Systems*, vol. 10, no. 3, pp. 54–71, Jul. 2019. doi: 10.4018/ijaeis.2019070104
18. P. C. Roy, A. Guber, M. Abouali, A. P. Nejadhashemi, K. Deb, and A. J. M. Smucker, "Crop yield simulation optimization using precision irrigation and subsurface water retention technology," *Environmental Modelling & Software*, vol. 119, pp. 433–444, Sep. 2019. doi: 10.1016/j.envsoft.2019.07.006

CHƯƠNG 10: CÁC NGUYÊN TẮC CƠ BẢN VỀ TRÍ TUỆ NHÂN TẠO VÀ HỌC MÁY CÙNG CÁC VÍ DỤ ỨNG DỤNG CỤ THỂ TRONG NÔNG NGHIỆP

Manoj Kumar Mahto, P. Laxmikanth, và V.S.S.P.L.N. Balaji Lanka Viện Công nghệ và Khoa học Vignan, Hyderabad, Ấn Độ

10.1 GIỚI THIỆU

Việc tích hợp các kỹ thuật trí tuệ nhân tạo (AI) và học máy (ML) đã mở ra một sự thay đổi mô hình trên nhiều lĩnh vực khác nhau, thúc đẩy các giải pháp sáng tạo định nghĩa lại các phương thức truyền thống. Trong bối cảnh chuyển đổi này, lĩnh vực nông nghiệp nổi bật lên, được hưởng lợi từ sức mạnh của AI và ML để giải quyết những thách thức phức tạp và nâng cao các phương pháp canh tác truyền thống. Chương này đi sâu vào những nguyên lý cốt lõi của AI và ML, đặt các nguyên tắc của chúng vào bối cảnh của lĩnh vực nông nghiệp. Bằng cách tìm hiểu các nền tảng lý thuyết và ứng dụng thực tiễn của những công nghệ này, người đọc sẽ có được sự hiểu biết toàn diện về cách AI và ML đang định hình lại bức tranh nông nghiệp. AI và ML, từng chỉ giới hạn trong lĩnh vực khoa học viễn tưởng, giờ đây đã trở thành những công cụ then chốt trong các ứng dụng thực tế. Trong nông nghiệp, nơi sự tương tác phức tạp của các kiểu thời tiết, điều kiện đất đai và sức khỏe cây trồng định hình kết quả, AI và ML mang lại một sự kết hợp mạnh mẽ. Chương này làm sáng tỏ các khái niệm nền tảng của AI và ML, cung cấp cái nhìn sâu sắc về cách thức hoạt động bên trong của chúng. AI, thường được gọi là sự mô phỏng các quá trình trí tuệ của con người, trao quyền cho máy tính thực hiện các tác vụ mà lẽ ra đòi hỏi trí thông minh của con người. ML, một tập hợp con của AI, trang bị cho máy tính khả năng học từ dữ liệu và không ngừng cải thiện hiệu suất của chúng. Cả hai công nghệ này đều phát triển mạnh nhờ dữ liệu, và trong nông nghiệp, nơi các biến số giàu dữ liệu định nghĩa kết quả, mối quan hệ cộng sinh này chiếm vị trí trung tâm. Một khía cạnh then chốt của AI và ML trong nông nghiệp là khả năng khai thác tiềm năng của dữ liệu để đưa ra các quyết định sáng suốt. Thu thập và tiền xử lý dữ liệu tạo thành nền tảng, đảm bảo rằng dữ liệu được đưa vào các mô hình AI và ML là chính xác, đáng tin cậy và có liên quan. Quá trình này liên quan đến việc thu thập các bộ dữ liệu đa dạng liên quan đến các kiểu thời tiết, thuộc tính đất, đặc điểm cây trồng và sản lượng lịch sử. Tiếp theo đó, trích xuất đặc trưng và kỹ thuật đặc trưng làm nổi bật nghệ thuật lựa chọn các thuộc tính phù hợp nhất từ dữ liệu và tinh chỉnh nó thành dạng có thể sử dụng để tối ưu hóa hiệu suất mô hình. Lựa chọn và đánh giá mô hình càng nhấn mạnh tầm quan trọng của các lựa chọn sáng suốt. Quá trình này đòi hỏi phải lựa chọn các thuật toán phù hợp với những phức tạp của vấn đề hiện tại. Các thuật toán này trải qua quá trình đánh giá nghiêm ngặt, đảm bảo rằng các dự đoán của mô hình là đáng tin cậy và có thể hành động được. Sự kết hợp của các giai đoạn này tạo ra các mô hình AI và ML sẵn sàng cách mạng hóa nông nghiệp.

Các ứng dụng của AI và ML trong nông nghiệp trải rộng trên một loạt các thách thức và cơ hội. Các lĩnh vực chính bao gồm dự đoán năng suất cây trồng, giúp nông dân tối ưu hóa phân bổ nguồn lực và năng suất, và phát hiện bệnh, tạo điều kiện chẩn đoán và can

thiệp nhanh chóng. Canh tác chính xác, cùng với các hệ thống hỗ trợ ra quyết định, nâng cao hiệu quả thông qua các thực hành thông minh. Các ví dụ thực tế làm nổi bật tác động của chúng, chẳng hạn như phát hiện bệnh cây trồng sử dụng mạng nơ-ron tích chập (CNN), nông nghiệp chính xác với Cây quyết định và thiết bị Internet vạn vật (IoT), và dự đoán năng suất thông qua các thuật toán hồi quy. Những ví dụ này nhấn mạnh sự chuyển đổi của AI và ML từ lý thuyết thành các tác nhân thay đổi thực tiễn trong nông nghiệp. Tuy nhiên, các mối quan ngại về đạo đức liên quan đến quyền riêng tư dữ liệu và tính minh bạch của thuật toán nảy sinh, đòi hỏi sự xem xét thận trọng. Ngoài ra, việc đảm bảo tiếp cận và lợi ích công bằng cho tất cả các bên liên quan trong nông nghiệp là rất quan trọng, xét đến tiềm năng chuyển đổi sâu sắc của các công nghệ này.

10.2 NGUYÊN LÝ CƠ BẢN CỦA AI VÀ ML

Các nguyên lý cơ bản của AI và ML bao gồm các khái niệm then chốt làm nền tảng cho các ứng dụng và sự tiến bộ của chúng trong các ngành công nghiệp khác nhau, bao gồm cả nông nghiệp. AI đề cập đến việc tạo ra các hệ thống thông minh có thể mô phỏng các hành vi giống con người, trong khi ML liên quan đến việc phát triển các thuật toán cho phép máy móc học từ dữ liệu và cải thiện hiệu suất của chúng theo thời gian.

10.2.1 AI

AI bao gồm một loạt các kỹ thuật và phương pháp nhằm tạo ra các máy móc hoặc hệ thống thể hiện trí thông minh giống con người. Các hệ thống này có thể thực hiện các nhiệm vụ như giải quyết vấn đề, ra quyết định, hiểu ngôn ngữ tự nhiên và nhận dạng các mẫu. Các kỹ thuật AI bao gồm hệ thống dựa trên quy tắc, hệ thống chuyên gia, mạng nơ-ron và xử lý ngôn ngữ tự nhiên (NLP).

10.2.1.1 AI trong Nông nghiệp

AI trong nông nghiệp đang dẫn đầu một sự chuyển đổi mang tính cách mạng trong cách chúng ta canh tác. Với sự tích hợp của các công nghệ tiên tiến như robot nông nghiệp và hệ thống phun thuốc thông minh, nông dân giờ đây có thể quản lý đồng ruộng một cách chính xác, tối ưu hóa năng suất cây trồng trong khi giảm tiêu thụ tài nguyên. Các giải pháp dẫn dắt bởi AI này cung cấp khả năng giám sát cây trồng và đất đai theo thời gian thực, cho phép phản ứng chủ động với các điều kiện thay đổi và tạo điều kiện cho những hiểu biết dự đoán về các kiểu thời tiết và sự bùng phát dịch hại. Ngoài ra, AI đóng một vai trò then chốt trong chẩn đoán bệnh, nhanh chóng xác định và giải quyết các mối đe dọa tiềm ẩn đối với sức khỏe cây trồng. Hơn nữa, các dự báo giá cả dựa trên AI cung cấp cho nông dân thông tin quý giá để ra quyết định chiến lược. Về bản chất, AI không chỉ cách mạng hóa nông nghiệp; nó đang mở đường cho một tương lai bền vững, hiệu quả và khả thi về kinh tế hơn cho ngành công nghiệp này. Hình 10.1 minh họa ứng dụng toàn diện của AI trong lĩnh vực nông nghiệp.

10.2.2 ML

ML là một tập hợp con của AI tập trung vào việc phát triển các thuật toán cho phép máy tính học từ dữ liệu và đưa ra dự đoán hoặc quyết định dựa trên việc học đó. Các thuật toán ML được phân loại thành học có giám sát, học không giám sát và học tăng cường, mỗi loại phục vụ cho các loại nhiệm vụ khác nhau. Học có giám sát liên quan đến việc đào tạo mô hình trên dữ liệu được gắn nhãn, học không giám sát liên quan đến việc tìm các mẫu trong dữ liệu không được gắn nhãn, và học tăng cường liên quan đến việc đào tạo các tác nhân thực hiện hành động để tối đa hóa phần thưởng.

10.2.2.1 ML trong Nông nghiệp

ML đang cách mạng hóa nông nghiệp bằng cách tối ưu hóa các khía cạnh khác nhau của ngành, bao gồm quản lý cây trồng, quản lý nước, quản lý đất,

Dự báo Năng suất và Giá Cây trồng

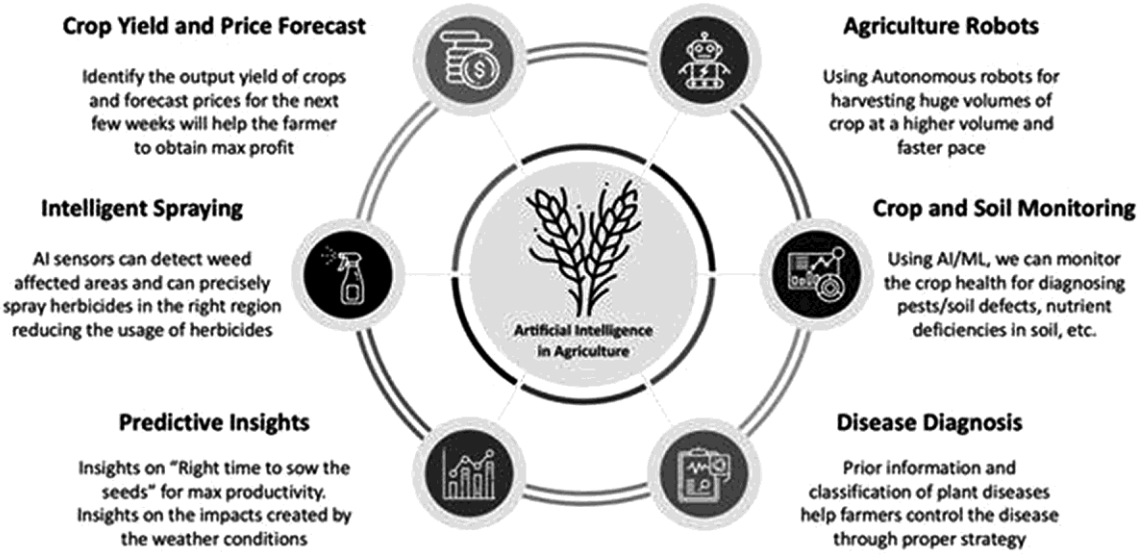
Xác định sản lượng đầu ra của cây trồng và dự báo giá cho vài tuần tới sẽ giúp nông dân thu được lợi nhuận tối đa.

Phun thuốc Thông minh

Các cảm biến AI có thể phát hiện các khu vực bị ảnh hưởng bởi cỏ dại và có thể phun thuốc diệt cỏ chính xác vào đúng khu vực, giảm việc sử dụng thuốc diệt cỏ.

Thông tin Dự đoán

Thông tin chi tiết về "Thời điểm thích hợp để gieo hạt" cho năng suất tối đa, thông tin chi tiết về các tác động được tạo ra bởi điều kiện thời tiết.



HÌNH 10.1 AI trong nông nghiệp.

Robot Nông nghiệp

Sử dụng robot tự động để thu hoạch khối lượng cây trồng lớn với khối lượng cao hơn và tốc độ nhanh hơn.

Giám sát Cây trồng và Đất đai

Sử dụng AI/ML, chúng ta có thể giám sát sức khỏe cây trồng để chẩn đoán sâu bệnh/khiếm khuyết đất, thiếu hụt chất dinh dưỡng trong đất, v.v.

Chẩn đoán Bệnh

Thông tin trước và phân loại bệnh cây trồng giúp nông dân kiểm soát bệnh thông qua chiến lược phù hợp.

Quản lý Cây trồng

• Danh mục này liên quan đến các nghiên cứu về:

• Dự đoán Năng suất, Phát hiện Bệnh, Phát hiện Cỏ dại, Nhận dạng Cây trồng và Chất lượng Cây trồng

Quản lý Nước

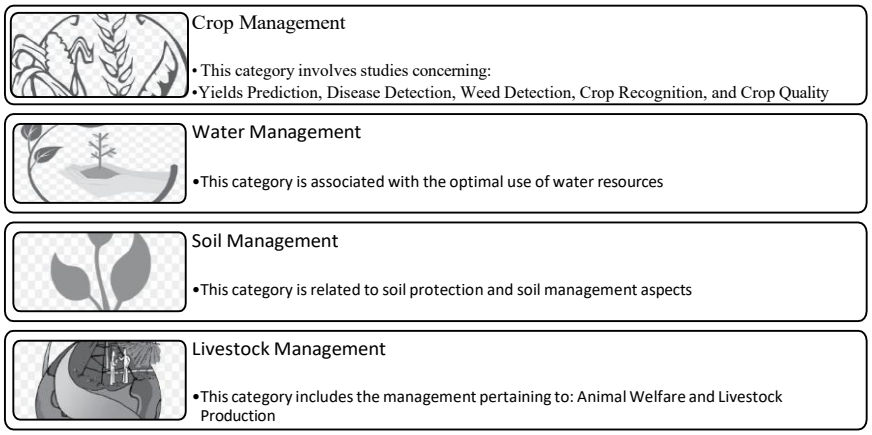
• Danh mục này liên quan đến việc sử dụng tối ưu tài nguyên nước

Quản lý Đất đai

• Danh mục này liên quan đến các khía cạnh bảo vệ và quản lý đất đai

Quản lý Vật nuôi

• Danh mục này bao gồm việc quản lý liên quan đến: Phúc lợi Động vật và Sản xuất Chăn nuôi



HÌNH 10.2 ML trong nông nghiệp.

và quản lý vật nuôi. Thông qua việc phân tích các bộ dữ liệu khổng lồ và dữ liệu cảm biến thời gian thực, các thuật toán ML trao quyền cho nông dân đưa ra các quyết định dựa trên dữ liệu. Trong quản lý cây trồng, ML dự đoán năng suất, sự bùng phát dịch bệnh và thời điểm trồng lý tưởng, đảm bảo năng suất tối đa và hiệu quả tài nguyên. Quản lý nước được hưởng lợi từ ML bằng cách xác định lịch trình tưới tiêu chính xác, bảo tồn tài nguyên nước và giảm thiểu rủi ro hạn hán. Quản lý đất được cải thiện, vì ML đánh giá sức khỏe đất và mức độ dinh dưỡng, cho phép lập kế hoạch bón phân phù hợp. Quản lý vật nuôi sử dụng ML để theo dõi sức khỏe động vật, tối ưu hóa phân phối thức ăn và nâng cao các chương trình nhân giống, cuối cùng làm tăng hiệu quả tổng thể và tính bền vững của nền nông nghiệp hiện đại. Hình 10.2 biểu diễn trực quan việc sử dụng ML trong lĩnh vực nông nghiệp.

10.2.2.2 Các Khái niệm AI và ML trong Nông nghiệp

Các khái niệm AI và ML đã mở ra một kỷ nguyên mới trong nông nghiệp, nơi sự kết hợp giữa công nghệ tiên tiến và thực hành nông nghiệp truyền thống đang tối ưu hóa hiệu quả và tính bền vững. Thông qua giám sát cây trồng và đất đai, các công nghệ này cung cấp thông tin chi tiết theo thời gian thực về sức khỏe đất và tình trạng cây trồng, giúp nông dân đưa ra quyết định sáng suốt. Bằng cách quan sát độ chín của cây trồng và giám sát sức khỏe vật nuôi, các hệ thống AI và ML cung cấp phản hồi kịp thời về sự phát triển của cây trồng và tình trạng sức khỏe của vật nuôi, cho phép can thiệp chính xác khi cần thiết. Các hệ thống phun thuốc thông minh và cơ chế cho ăn tự động tiếp tục nâng cao nông nghiệp chính xác, giảm lãng phí tài nguyên và đảm bảo sử dụng hợp lý phân bón và thuốc trừ sâu. Về bản chất, các khái niệm này đang cách mạng hóa ngành công nghiệp bằng cách thúc đẩy một cách tiếp cận nông nghiệp được trang bị thông tin tốt hơn, hiệu quả hơn và có ý thức sinh thái hơn.

Phun thuốc Thông minh

• UAV với thị giác máy tính AI để tự động hóa việc phun thuốc trừ sâu và phân bón đồng đều

Làm cỏ Tự động

• Robot làm cỏ để điều hướng và tiêu diệt cỏ dại hiện có mà không cần sử dụng thuốc diệt cỏ

Giám sát Sức khỏe Vật nuôi

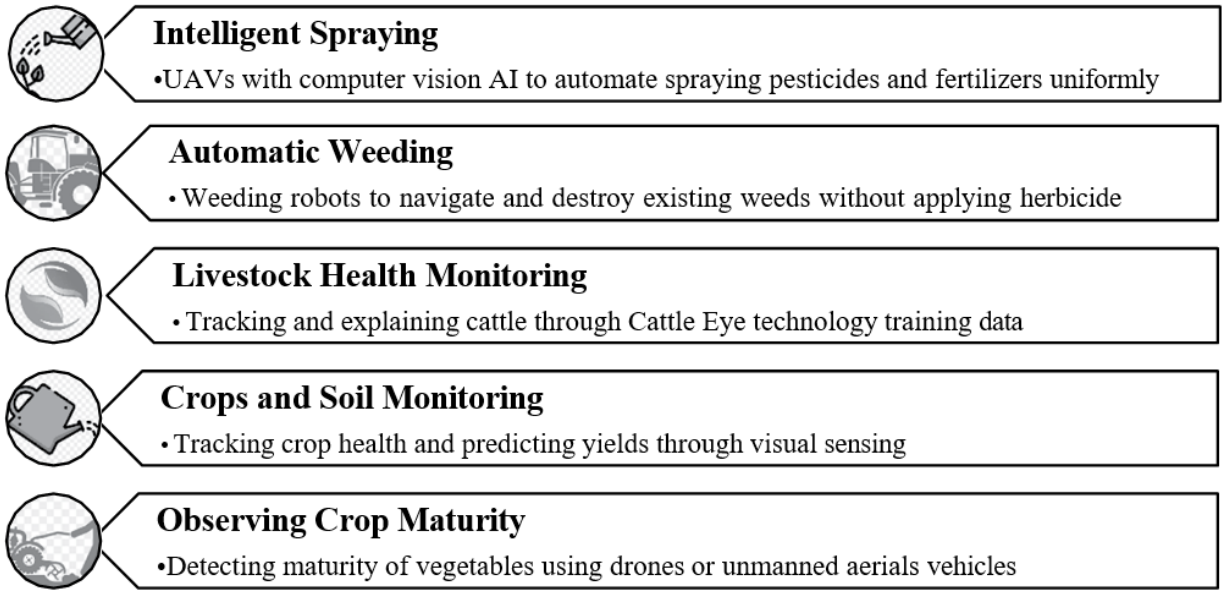
• Theo dõi và giải thích tình trạng gia súc thông qua dữ liệu đào tạo công nghệ Cattle Eye

Giám sát Cây trồng và Đất đai

• Theo dõi sức khỏe cây trồng và dự đoán năng suất thông qua cảm biến hình ảnh

Quan sát Độ chín Cây trồng

• Phát hiện độ chín của rau quả bằng máy bay không người lái hoặc phương tiện hàng không không người lái



HÌNH 10.3 Các khái niệm AI và ML trong nông nghiệp.

đến canh tác. Hình 10.3 trình bày tổng quan về các khái niệm AI và ML trong bối cảnh nông nghiệp.

10.2.3 Thu thập và Tiền xử lý Dữ liệu

Thu thập và tiền xử lý dữ liệu tạo thành các bước cơ bản trong việc tích hợp các kỹ thuật AI và ML. Quá trình này liên quan đến việc thu thập các bộ dữ liệu đa dạng liên quan đến các lĩnh vực cụ thể, đảm bảo tính chính xác, đầy đủ và tính liên quan của chúng cho các phân tích tiếp theo. Tiền xử lý dữ liệu, như một tiền đề quan trọng cho phân tích, bao gồm các hoạt động như làm sạch dữ liệu, chuyển đổi và trích xuất đặc trưng để tinh chỉnh dữ liệu thô thành dạng có thể sử dụng. Các giai đoạn này có vai trò then chốt trong việc nâng cao chất lượng của dữ liệu đầu vào, điều này trực tiếp ảnh hưởng đến hiệu suất và độ tin cậy của các mô hình AI và ML [1]. Bằng cách tập trung vào chất lượng và chuẩn bị dữ liệu, các tổ chức có thể đảm bảo rằng các quy trình AI và ML tiếp theo dựa trên thông tin chính xác và có ý nghĩa.

10.2.4 Trích xuất và Kỹ thuật Đặc trưng

Trích xuất và kỹ thuật đặc trưng đóng một vai trò trung tâm trong việc khai thác sức mạnh của các kỹ thuật AI và ML. Các quá trình này liên quan đến việc xác định và lựa chọn các thuộc tính hoặc đặc trưng có liên quan từ dữ liệu thô, góp phần vào khả năng dự đoán của các mô hình. Trích xuất đặc trưng tập trung vào việc chuyển đổi dữ liệu thành định dạng phù hợp hơn cho phân tích, thường liên quan đến các kỹ thuật như giảm chiều dữ liệu hoặc chuyển đổi.

Kỹ thuật đặc trưng, mặt khác, liên quan đến việc tạo ra các đặc trưng mới hoặc sửa đổi các đặc trưng hiện có để nâng cao hiệu suất của mô hình. Các quá trình này rất quan trọng để tối ưu hóa dữ liệu đầu vào mà các thuật toán AI và ML dựa vào, dẫn đến cải thiện độ chính xác và hiệu quả trong các dự đoán của mô hình [2]. Trích xuất và kỹ thuật đặc trưng hiệu quả cho phép các mô hình nắm bắt các mẫu cơ bản trong dữ liệu, cuối cùng nâng cao hiệu suất tổng thể và khả năng của các ứng dụng AI và ML.

10.2.5 Lựa chọn và Đánh giá Mô hình

Lựa chọn và đánh giá mô hình tạo thành các giai đoạn quan trọng trong việc tích hợp các kỹ thuật AI và ML. Các giai đoạn này có vai trò then chốt trong việc xác định các thuật toán phù hợp nhất với vấn đề hiện tại và đánh giá hiệu suất của chúng. Lựa chọn mô hình liên quan đến việc lựa chọn từ một loạt các thuật toán dựa trên tính phù hợp của chúng cho nhiệm vụ cụ thể, đặc điểm dữ liệu và mục tiêu. Tiếp theo, đánh giá mô hình liên quan đến việc kiểm tra các thuật toán đã chọn bằng cách sử dụng các bộ dữ liệu xác thực và kiểm tra, đo lường độ chính xác, độ chính xác, độ nhớ và các số liệu liên quan khác để đánh giá hiệu quả của chúng [3]. Lựa chọn và đánh giá mô hình hiệu quả là điều bắt buộc để đảm bảo rằng các mô hình AI và ML tạo ra các dự đoán và thông tin chi tiết đáng tin cậy, hướng dẫn các quy trình ra quyết định trong các lĩnh vực khác nhau.

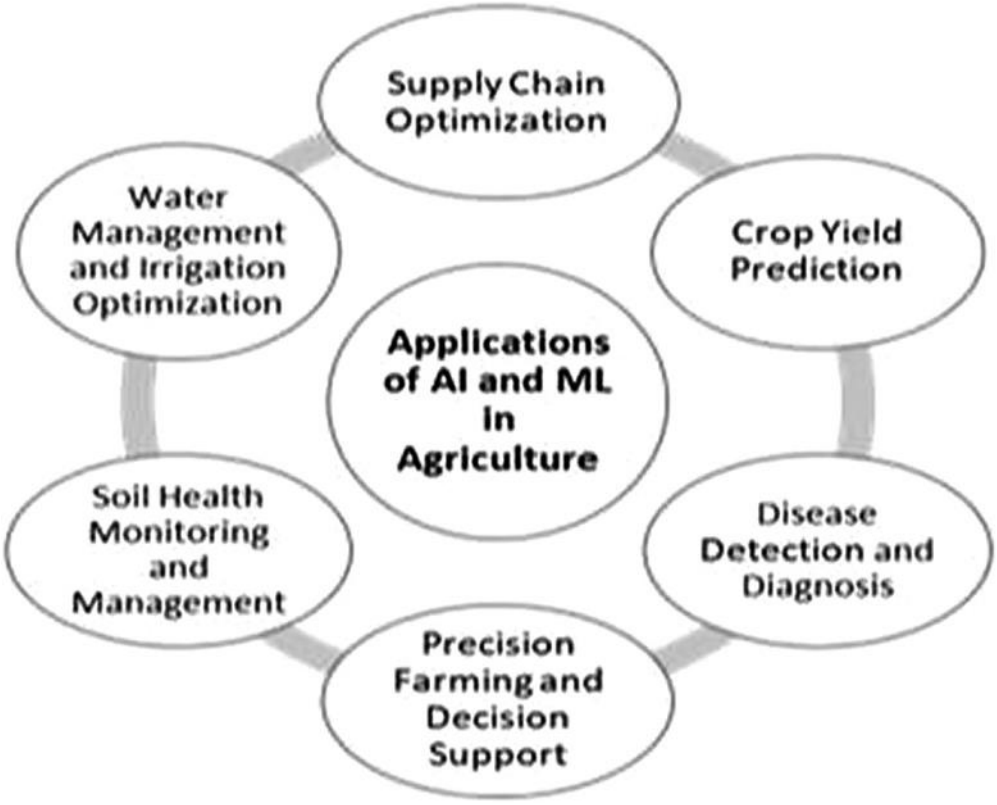
10.3 ỨNG DỤNG CỦA AI VÀ ML TRONG NÔNG NGHIỆP

Các ứng dụng của AI và ML trong nông nghiệp đã cách mạng hóa các phương pháp canh tác truyền thống bằng cách tận dụng các thông tin chi tiết dựa trên dữ liệu để giải quyết các thách thức phức tạp. Những công nghệ này có tiềm năng chuyển đổi các khía cạnh khác nhau của nông nghiệp, từ cải thiện dự đoán năng suất cây trồng đến nâng cao phát hiện và quản lý dịch bệnh. Ví dụ, các mô hình được cung cấp bởi AI có thể phân tích dữ liệu thời tiết lịch sử, đặc tính đất đai và các biến số khác để cung cấp các dự đoán chính xác về năng suất cây trồng, cho phép nông dân đưa ra quyết định sáng suốt về phân bổ nguồn lực và lập kế hoạch [4]. Ngoài ra, các thuật toán AI và ML có thể phát hiện và chẩn đoán bệnh cây trồng bằng cách phân tích hình ảnh của cây, lá hoặc quả, cho phép can thiệp kịp thời để giảm thiểu thiệt hại và tối ưu hóa sức khỏe cây trồng [5]. Việc tích hợp AI và ML vào nông nghiệp chính xác đã mở đường cho việc tối ưu hóa sử dụng tài nguyên thông qua tưới tiêu và bón phân có mục tiêu, dẫn đến hiệu quả và tính bền vững gia tăng. Những ứng dụng này nhấn mạnh tiềm năng chuyển đổi của AI và ML trong việc cách mạng hóa lĩnh vực nông nghiệp. Hình 10.4 minh họa trực quan các ứng dụng khác nhau của AI và ML trong lĩnh vực nông nghiệp.

10.3.1 Dự đoán Năng suất Cây trồng

Dự đoán năng suất cây trồng, một ứng dụng nền tảng trong lĩnh vực AI và ML trong nông nghiệp, đã thu hút sự quan tâm đáng kể do tiềm năng tối ưu hóa phân bổ nguồn lực và nâng cao an ninh lương thực. Cách tiếp cận dự đoán này dựa vào sự tích hợp của dữ liệu lịch sử và thời gian thực, bao gồm các yếu tố như các kiểu thời tiết, điều kiện đất đai và thực hành nông nghiệp. Bằng cách sử dụng các kỹ thuật hồi quy và ensemble tiên tiến,

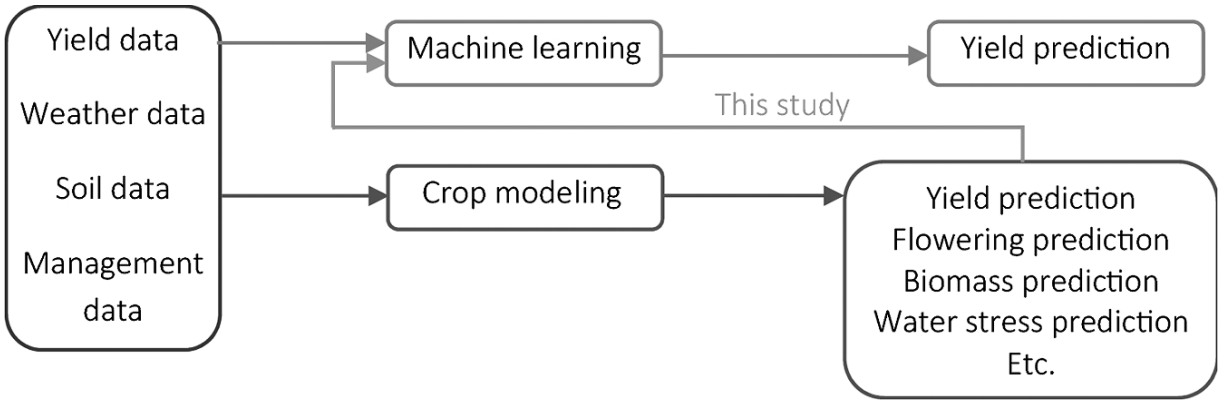
các mô hình AI và ML có thể giải mã các mối quan hệ phức tạp giữa các biến số này và dự đoán năng suất cây trồng trong tương lai với độ chính xác đáng kể [6]. Những dự đoán như vậy cung cấp thông tin chi tiết vô giá cho nông dân, cho phép họ đưa ra quyết định sáng suốt liên quan đến chiến lược trồng trọt, lập lịch trình tưới tiêu và lập kế hoạch thu hoạch. Cuối cùng, việc tích hợp AI và ML vào dự đoán năng suất cây trồng không chỉ cải thiện hiệu quả nông nghiệp mà còn góp phần vào các thực hành bền vững bằng cách giảm thiểu lãng phí tài nguyên và hỗ trợ các chuỗi cung ứng lương thực toàn cầu. Hình 10.5 mô tả quá trình dự đoán năng suất cây trồng.



HÌNH 10.4 Ứng dụng của AI và ML trong nông nghiệp.

Dữ liệu năng suất Dữ liệu thời tiết Dữ liệu đất đai Dữ liệu quản lý

Học máy Mô hình hóa cây trồng Nghiên cứu này Dự đoán năng suất Dự đoán đa dạng sinh học Dự đoán căng thẳng nước V.v.



HÌNH 10.5 Dự đoán năng suất cây trồng.

10.3.2 Phát hiện và Chẩn đoán Bệnh

Phát hiện và chẩn đoán bệnh trong nông nghiệp đã được chuyển đổi đáng kể nhờ sự tích hợp của các kỹ thuật AI và ML. Ứng dụng này đóng một vai trò then chốt trong việc xác định sớm và quản lý bệnh cây trồng, giảm thiểu thiệt hại năng suất và đảm bảo an ninh lương thực. Bằng cách sử dụng các thuật toán nhận dạng và phân loại hình ảnh, các mô hình AI và ML có thể phân tích hình ảnh của cây, lá hoặc quả để xác định và chẩn đoán chính xác các bệnh khác nhau [7]. Các mô hình này học từ các bộ dữ liệu hình ảnh lớn, cho phép chúng phân biệt các manh mối trực quan tinh tế mà mắt người có thể bỏ sót. Với việc phát hiện bệnh kịp thời và chính xác, nông dân có thể thực hiện các can thiệp mục tiêu như áp dụng thuốc trừ sâu chính xác hoặc cách ly cây bị nhiễm bệnh, giảm thiểu sự lây lan của bệnh trên các cây trồng [8]. Ứng dụng này cho thấy cách AI và ML đang thúc đẩy đổi mới trong nông nghiệp bằng cách khai thác sức mạnh của dữ liệu và tự động hóa để giải quyết các thách thức quan trọng trong quản lý dịch bệnh.

10.3.3 Canh tác Chính xác và Hỗ trợ Quyết định

Canh tác chính xác, cùng với các hệ thống hỗ trợ ra quyết định, đại diện cho một ứng dụng chuyển đổi của AI và ML trong nông nghiệp hiện đại. Cách tiếp cận này tận dụng các công nghệ tiên tiến để tối ưu hóa phân bổ nguồn lực, nâng cao hiệu quả và giảm thiểu tác động môi trường. Bằng cách tích hợp dữ liệu từ các nguồn khác nhau như vệ tinh, cảm biến và hồ sơ lịch sử, các mô hình AI và ML có thể cung cấp thông tin chi tiết theo thời gian thực về điều kiện đất đai, các kiểu thời tiết và sức khỏe cây trồng [9]. Những thông tin chi tiết này cho phép nông dân đưa ra quyết định sáng suốt về thời điểm và địa điểm áp dụng tưới tiêu, phân bón và thuốc trừ sâu, điều chỉnh các can thiệp cho các khu vực cụ thể cần thiết.

Điều này không chỉ làm tăng năng suất mà còn giảm lãng phí tài nguyên và ô nhiễm môi trường. Ngoài ra, các hệ thống hỗ trợ ra quyết định được trang bị thuật toán AI có thể tạo ra các khuyến nghị dựa trên phân tích dữ liệu phức tạp, hỗ trợ nông dân đưa ra các lựa chọn kịp thời và chiến lược để quản lý cây trồng tối ưu. Sự kết hợp giữa canh tác chính xác và hệ thống hỗ trợ ra quyết định làm nổi bật cách AI và ML đang cách mạng hóa các

thực hành nông nghiệp truyền thống bằng cách khai thác trí thông minh dựa trên dữ liệu cho các kết quả bền vững và hiệu quả.

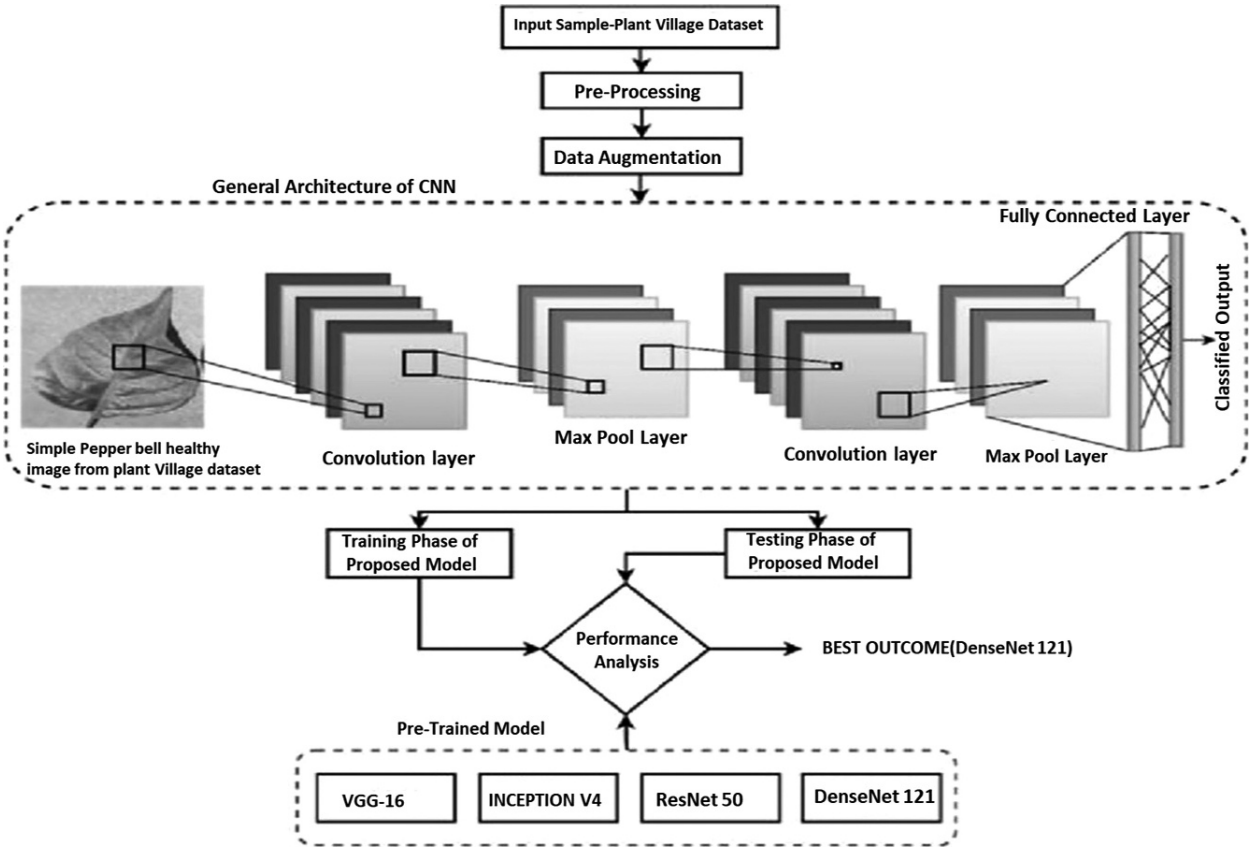
10.3.4 Giám sát và Quản lý Sức khỏe Đất đai

Giám sát và quản lý sức khỏe đất đai đã chứng kiến một sự thay đổi mô hình với sự tích hợp của các kỹ thuật AI và ML. Ứng dụng này cung cấp một cách tiếp cận dựa trên dữ liệu để đánh giá chất lượng đất, hàm lượng dinh dưỡng và rủi ro xói mòn, cung cấp thông tin chi tiết có giá trị cho quản lý đất đai bền vững. Bằng cách kết hợp dữ liệu cảm biến, hồ sơ lịch sử và các biến môi trường, các mô hình AI và ML có thể phân tích các mối quan hệ phức tạp trong hệ sinh thái đất 10. Các mô hình này có thể xác định các xu hướng và mẫu cho phép nông dân đưa ra quyết định sáng suốt về việc cải tạo đất, lịch trình tưới tiêu và các chiến lược kiểm soát xói mòn. Điều này không chỉ nâng cao năng suất cây trồng mà còn đóng góp vào bảo tồn tài nguyên đất và thực hành nông nghiệp bền vững. Ứng dụng này cho thấy cách AI và ML đang cách mạng hóa quản lý đất đai bằng cách khai thác sức mạnh của dữ liệu để tối ưu hóa sức khỏe đất và đảm bảo khả năng phục hồi lâu dài của hệ sinh thái nông nghiệp.

10.4 VÍ DỤ THỰC TẾ

10.4.1 Phát hiện Bệnh Cây trồng sử dụng CNN

Phát hiện bệnh cây trồng sử dụng CNN đã nổi lên như một công cụ mạnh mẽ trong nông nghiệp hiện đại, cung cấp một cách tiếp cận chính xác và hiệu quả để xác định và quản lý bệnh cây trồng. CNN, một loại mạng nơ-ron sâu chuyên về phân tích hình ảnh, có thể tự động học và trích xuất các đặc trưng có liên quan từ hình ảnh cây trồng, cho phép phân loại chính xác các bệnh khác nhau. Quá trình này bắt đầu bằng việc thu thập một bộ dữ liệu lớn gồm hình ảnh cây trồng khỏe mạnh và bị bệnh, đóng vai trò là dữ liệu đào tạo cho mô hình CNN. Mô hình này sau đó học cách nhận ra các mẫu và dấu hiệu trực quan liên quan đến các bệnh cụ thể, chẳng hạn như đốm trên lá, đổi màu hoặc biến dạng. Khi được đào tạo, CNN có thể phân tích hình ảnh mới và cung cấp dự đoán về sự hiện diện và loại bệnh. Ứng dụng này đã được triển khai thành công trong các tình huống thực tế, nơi nông dân có thể chụp ảnh cây trồng bằng điện thoại thông minh hoặc máy ảnh và nhận được chẩn đoán tức thì [11]. Bằng cách cho phép phát hiện bệnh sớm và can thiệp chính xác, CNN góp phần giảm thiểu thiệt hại năng suất, giảm sử dụng thuốc trừ sâu và thúc đẩy thực hành nông nghiệp bền vững. Hình 10.6 minh họa quá trình phát hiện bệnh cây trồng.



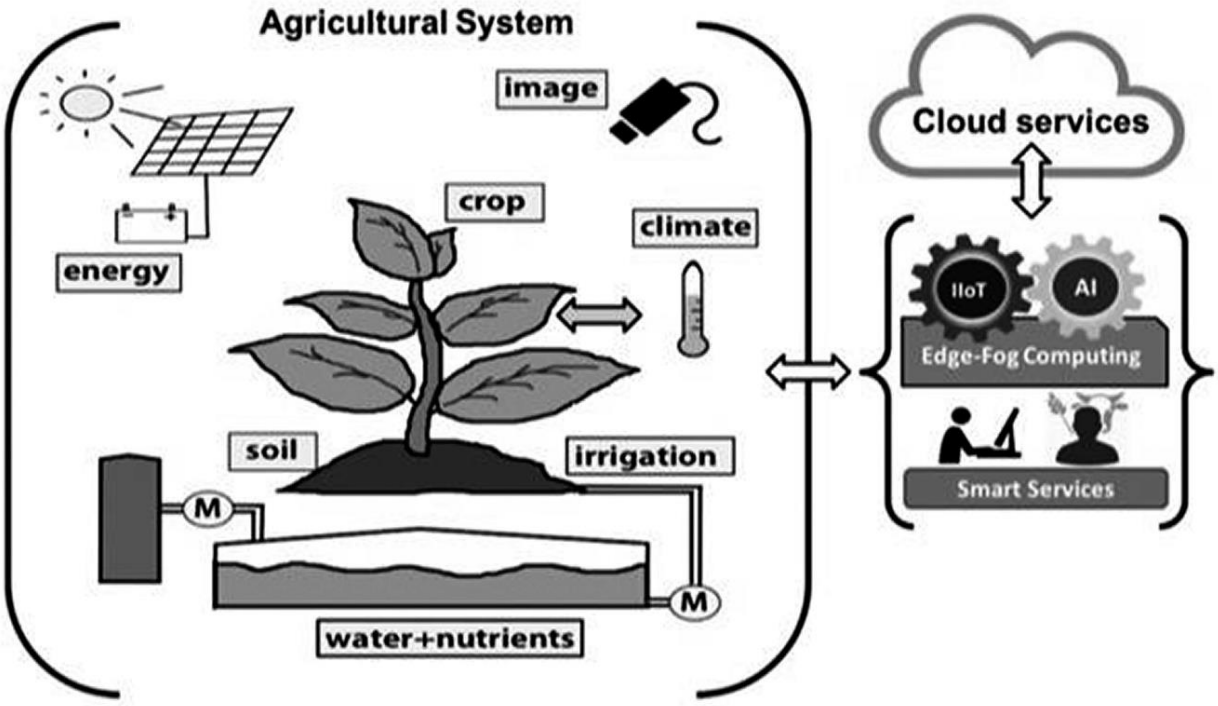
HÌNH 10.6 Phát hiện bệnh cây trồng.

10.4.2 Nông nghiệp Chính xác với Cây Quyết định và IoT

Nông nghiệp chính xác, được thúc đẩy bởi sự kết hợp của Cây Quyết định và IoT, đại diện cho một bước nhảy vọt trong việc tối ưu hóa nông nghiệp. Cây Quyết định, một thuật toán học máy, đóng vai trò là một công cụ ra quyết định bằng cách phân tích các biến đầu vào khác nhau như dữ liệu đất, điều kiện thời tiết và thực hành canh tác để đưa ra các khuyến nghị cho các hành động cụ thể. Khi được tích hợp với IoT, nơi các cảm biến và thiết bị thu thập dữ liệu thời gian thực từ các cánh đồng, Cây Quyết định có thể xử lý thông tin này để đưa ra các quyết định sáng suốt về tưới tiêu, bón phân và kiểm soát dịch hại [12]. Ví dụ, các cảm biến IoT có thể đo độ ẩm của đất, nhiệt độ và mức độ dinh dưỡng, và Cây Quyết định có thể diễn giải dữ liệu này để xác định thời điểm và lượng nước tưới hoặc phân bón cần thiết cho các khu vực cụ thể. Sự kết hợp này cho phép nông dân thực hiện các can thiệp có mục tiêu, giảm lãng phí tài nguyên và tối đa hóa năng suất cây trồng. Ngoài ra, việc tích hợp IoT cho phép giám sát và điều khiển từ xa, cho phép nông dân quản lý hoạt động nông trại của họ một cách hiệu quả. Ứng dụng này cho thấy cách Cây Quyết định và IoT cùng nhau cách mạng hóa nông nghiệp bằng cách khai thác sức mạnh của dữ liệu và tự động hóa để đạt được canh tác chính xác và bền vững. Hình 10.7 minh họa khái niệm về nông nghiệp chính xác.

10.4.3 Dự đoán Năng suất với Thuật toán Hồi quy

Dự đoán năng suất với thuật toán hồi quy đã trở thành một ứng dụng có giá trị trong nông nghiệp hiện đại, cung cấp cho nông dân những hiểu biết sâu sắc về sản lượng cây trồng tiềm năng dựa trên các yếu tố ảnh hưởng khác nhau. Các thuật toán hồi quy, một kỹ thuật học máy, phân tích các biến đầu vào như dữ liệu thời tiết lịch sử, đặc tính đất, thực hành canh tác và các yếu tố môi trường khác để xây dựng các mô hình dự đoán. Những mô hình này học từ dữ liệu lịch sử để xác định các mối quan hệ và mẫu giữa các biến đầu vào và năng suất cây trồng thực tế. Khi được đào tạo, các thuật toán hồi quy có thể đưa ra dự đoán về năng suất cây trồng trong tương lai dựa trên các điều kiện hiện tại hoặc dự kiến [13]. Ví dụ, bằng cách xem xét các yếu tố như lượng mưa, nhiệt độ, loại đất và lịch sử bón phân, mô hình hồi quy có thể ước tính sản lượng cây trồng sắp tới. Những dự đoán này cho phép nông dân đưa ra quyết định sáng suốt về phân bổ nguồn lực, lập kế hoạch thu hoạch và quản lý thị trường. Hơn nữa, dự đoán năng suất hỗ trợ các nhà hoạch định chính sách trong việc dự báo sản lượng lương thực và đảm bảo an ninh lương thực. Ứng dụng này cho thấy cách các thuật toán hồi quy, được hỗ trợ bởi dữ liệu và học máy, đang cách mạng hóa nông nghiệp bằng cách cung cấp các công cụ dự đoán để tối ưu hóa năng suất cây trồng và quản lý tài nguyên. Hình 10.8 minh họa quá trình dự đoán năng suất.

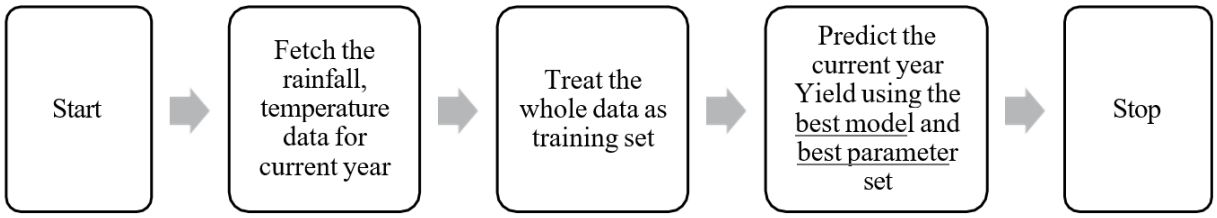


HÌNH 10.7 Nông nghiệp chính xác.

10.5 THÁCH THỨC VÀ ĐỊNH HƯỚNG TƯƠNG LAI

Việc tích hợp các khái niệm AI và ML trong nông nghiệp mang đến cả cơ hội và thách thức cần được xem xét. Mặc dù AI và ML mang lại tiềm năng thay đổi to lớn, một số

thách thức cần phải được giải quyết để đảm bảo việc triển khai hiệu quả và tác động bền vững của chúng trong nông nghiệp. Chất lượng và tính sẵn có của dữ liệu vẫn là một mối quan ngại đáng kể, vì các bộ dữ liệu đáng tin cậy và toàn diện là điều cần thiết để huấn luyện các mô hình chính xác [16].



HÌNH 10.8 Dự đoán năng suất bằng thuật toán hồi quy. (Bắt đầu → Lấy dữ liệu lượng mưa, nhiệt độ cho năm hiện tại → Coi toàn bộ dữ liệu là tập huấn luyện → Dự đoán Năng suất năm hiện tại bằng mô hình tốt nhất và bộ tham số tốt nhất → Dừng)

Các vấn đề về quyền riêng tư và bảo mật cũng xuất hiện, đặc biệt là khi dữ liệu nông nghiệp thường liên quan đến thông tin nhạy cảm về thực hành canh tác và quản lý đất đai. Đảm bảo việc sử dụng các công nghệ AI và ML một cách có đạo đức và trách nhiệm là điều tối quan trọng để xây dựng lòng tin giữa các bên liên quan [4].

10.5.1 Thách thức

Hơn nữa, khả năng diễn giải và giải thích của các mô hình AI và ML đặt ra những thách thức trong việc hiểu rõ cách thức ra quyết định. Các mô hình hộp đen (Black-box) có thể cản trở việc áp dụng các công nghệ này, đặc biệt là trong các lĩnh vực như nông nghiệp, nơi mà tính minh bạch là rất quan trọng [17]. Thu hẹp khoảng cách giữa các chuyên gia kỹ thuật và nông dân chuyên biệt về lĩnh vực là một thách thức khác. Giao tiếp và giáo dục hiệu quả là cần thiết để giúp nông dân hiểu, tin tưởng và sử dụng các giải pháp dựa trên AI [7].

10.5.1.1 Chất lượng và tính sẵn có của dữ liệu

Không thể phóng đại tầm quan trọng của các bộ dữ liệu đáng tin cậy và toàn diện để huấn luyện các mô hình AI và ML chính xác trong lĩnh vực nông nghiệp. Trong bối cảnh này, chất lượng và thành phần của dữ liệu có tác động trực tiếp đến hiệu suất và độ tin cậy của các mô hình. Dữ liệu không nhất quán, không đầy đủ hoặc thiên vị có thể cản trở đáng kể hiệu quả của các mô hình dự đoán và quy trình ra quyết định [18]. Độ chính xác của các dự đoán và độ tin cậy của các thông tin chi tiết phụ thuộc vào tính toàn vẹn của dữ liệu đầu vào, khiến việc đảm bảo chất lượng dữ liệu trở thành một mối quan tâm hàng đầu. Đảm bảo rằng các bộ dữ liệu bao gồm một loạt các điều kiện, kịch bản và biến số đa dạng là điều cần thiết để tránh các kết quả mô hình bị thiên vị hoặc sai lệch. Giải quyết những thách thức liên quan đến dữ liệu này là mấu chốt để khai thác toàn bộ tiềm năng của AI và ML trong việc cải thiện các thực hành và kết quả nông nghiệp.

10.5.1.2 Quyền riêng tư và Bảo mật

Dữ liệu nông nghiệp thường xuyên bao gồm vô số thông tin nhạy cảm liên quan đến thực hành canh tác, chiến lược quản lý đất đai, và thậm chí cả thông tin cá nhân của nông dân. Sự phong phú của dữ liệu cá nhân và độc quyền này nhấn mạnh tầm quan trọng hàng đầu của việc đảm bảo các cơ chế bảo mật và quyền riêng tư dữ liệu mạnh mẽ trong bối cảnh ứng dụng AI và ML trong nông nghiệp. Do đó, việc bảo vệ dữ liệu này trở nên tối quan trọng không chỉ để tuân thủ các yêu cầu quy định mà còn để thúc đẩy lòng tin và sự hợp tác giữa nông dân, các bên liên quan và các nhà phát triển công nghệ [19]. Các kỹ thuật mã hóa dữ liệu, kiểm soát truy cập và ẩn danh hóa hiệu quả là điều cần thiết để bảo vệ thông tin bí mật khỏi sự truy cập hoặc vi phạm trái phép. Bằng cách ưu tiên quyền riêng tư và bảo mật dữ liệu, ngành nông nghiệp có thể tạo ra một môi trường nơi các bên liên quan tin tưởng vào việc sử dụng có trách nhiệm các công nghệ AI và ML để tăng cường năng suất và tính bền vững.

10.5.1.3 Khả năng diễn giải và giải thích

Tính mờ đục vốn có trong các mô hình AI và ML hộp đen có thể cản trở đáng kể việc hiểu các cơ chế ra quyết định, một mối lo ngại thậm chí còn có ý nghĩa lớn hơn trong lĩnh vực nông nghiệp, nơi tính minh bạch có tầm quan trọng hàng đầu [17]. Việc không thể nhận thức rõ lý do đằng sau các dự đoán và khuyến nghị đã cản trở việc áp dụng các công nghệ này trong số các bên liên quan. Do tính chất phức tạp và rủi ro cao của các thực hành nông nghiệp, nhu cầu về các mô hình có thể diễn giải được ngày càng trở nên rõ ràng. Để thiết lập lòng tin và thúc đẩy sự chấp nhận rộng rãi hơn, các nỗ lực đang hướng tới việc phát triển các mô hình AI và ML với khả năng diễn giải nâng cao. Bằng cách sử dụng các kỹ thuật cho phép mô hình cung cấp giải thích cho các quyết định của chúng, các bên liên quan có thể hiểu rõ hơn về các yếu tố ảnh hưởng đến kết quả. Các mô hình minh bạch như vậy không chỉ tạo điều kiện cho việc ra quyết định sáng suốt mà còn hỗ trợ xác định các thiên vị, lỗi hoặc thiếu sót tiềm ẩn, góp phần vào việc triển khai AI có trách nhiệm trong nông nghiệp.

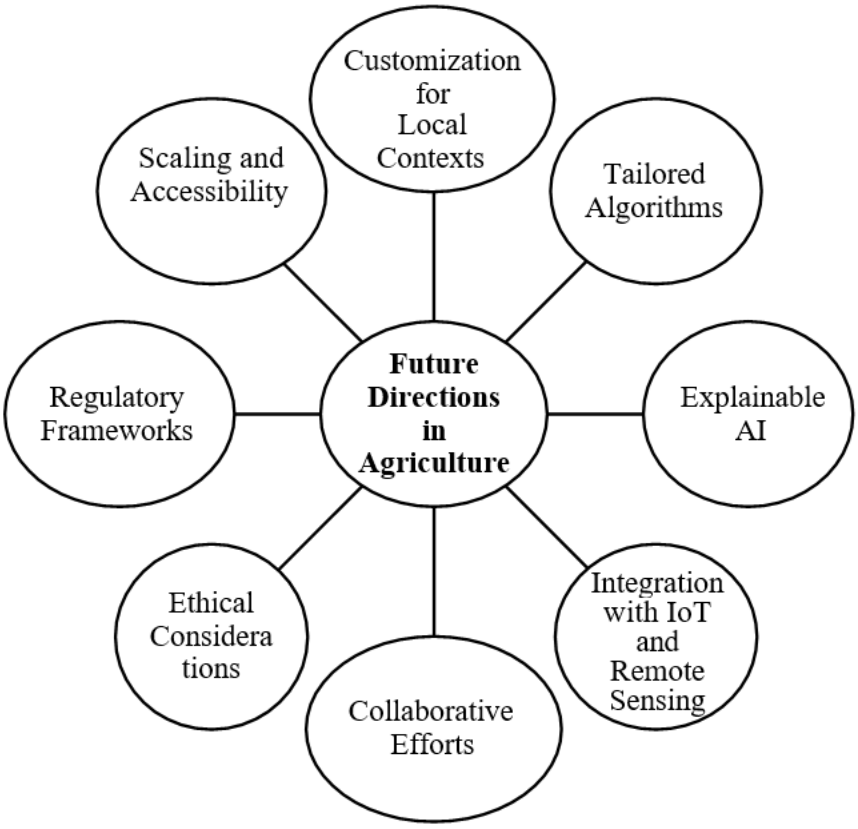
10.5.1.4 Giao tiếp và Giáo dục

Thu hẹp khoảng cách giữa các chuyên gia kỹ thuật tham gia phát triển giải pháp AI và người dùng cuối, thường là nông dân, đặt ra một thách thức lớn. Thách thức này bắt nguồn từ nền tảng, thuật ngữ và quan điểm khác biệt của hai nhóm này. Giao tiếp và giáo dục hiệu quả nổi lên như những thành phần then chốt để bắc cầu cho khoảng cách này và tạo điều kiện cho việc áp dụng thành công các giải pháp dựa trên AI trong nông nghiệp [7]. Bằng cách dịch các khái niệm kỹ thuật phức tạp sang ngôn ngữ dễ tiếp cận và các kịch bản dễ liên hệ, các chuyên gia có thể truyền đạt giá trị và lợi ích của AI cho nông dân. Ngoài ra, các sáng kiến giáo dục có thể trao quyền cho nông dân với kiến thức cần thiết để hiểu các ứng dụng tiềm năng, hạn chế và tác động của AI trong thực tiễn của họ. Các sáng kiến như vậy thúc đẩy một môi trường nơi nông dân có thể đưa ra quyết định sáng suốt, tin tưởng vào công nghệ và tích hợp liền mạch các giải pháp dựa trên AI vào quy trình nông nghiệp của họ.

10.5.2 Định hướng Tương lai

Về các định hướng tương lai, việc tinh chỉnh các thuật toán AI và ML được thiết kế riêng cho các thách thức nông nghiệp hứa hẹn nhiều tiềm năng. Những phát triển trong AI có thể giải thích (XAI) có thể giải quyết mối lo ngại về tính minh bạch, cung cấp các mô hình dễ diễn giải hơn cho phép các bên liên quan hiểu rõ các quy trình ra quyết định. Tích hợp AI với các công nghệ khác, như thiết bị IoT, viễn thám và robot, có thể tăng cường hơn nữa hệ thống thu thập dữ liệu và hỗ trợ quyết định. Nỗ lực hợp tác giữa các nhà nghiên cứu, chuyên gia nông nghiệp và các nhà hoạch định chính sách là điều cần thiết để tạo ra các khuôn khổ khuyến khích triển khai AI có trách nhiệm, giải quyết các thách thức và thúc đẩy khả năng tiếp cận công bằng với các lợi ích của AI. Hình 10.9 phác thảo các định hướng tương lai tiềm năng trong lĩnh vực nông nghiệp.

[Sơ đồ gồm các nhánh: Tùy chỉnh cho Bối cảnh Địa phương , Thuật toán tùy chỉnh , AI có thể giải thích , Tích hợp với IoT và Viễn thám , Nỗ lực Hợp tác , Cân nhắc Đạo đức , Khung pháp lý , Mở rộng và Khả năng tiếp cận. Tất cả đều xoay quanh trung tâm: Định hướng Tương lai trong Nông nghiệp.]



HÌNH 10.9 Các định hướng tương lai trong nông nghiệp.

10.5.2.1 Thuật toán tùy chỉnh

Việc tùy chỉnh các thuật toán AI và ML để giải quyết hiệu quả các thách thức đặc thù trong nông nghiệp có tiềm năng khuếch đại đáng kể độ chính xác và khả năng ứng dụng của các công nghệ này trong bối cảnh canh tác. Cách tiếp cận này bao gồm việc hiểu rõ sự phức tạp của các hệ thống nông nghiệp, như mô hình tăng trưởng cây trồng, đặc điểm đất đai, động thái thời tiết và hành vi sâu bệnh, và thiết kế các thuật toán tận dụng kiến thức chuyên biệt của lĩnh vực này [20]. Bằng cách tùy chỉnh các thuật toán để phù hợp với các sắc thái của nông nghiệp, các mô hình kết quả có thể cung cấp thông tin chi tiết phù hợp và có thể hành động hơn cho nông dân. Khả năng thích ứng này không chỉ tăng cường sức mạnh dự đoán của AI mà còn tăng tiện ích thực tế của nó trong các kịch bản nông nghiệp ngoài đời thực.

10.5.2.2 AI có thể giải thích (Explainable AI)

Tiến bộ trong XAI có tiềm năng thúc đẩy sự phát triển của các mô hình vốn dĩ dễ diễn giải hơn, cung cấp giải pháp cho thách thức hiểu được lý do đằng sau các quyết định dựa trên AI. Tiến bộ này trở nên đặc biệt có giá trị trong nông nghiệp, nơi các quy trình ra quyết định minh bạch là rất quan trọng để xây dựng lòng tin giữa nông dân, các bên liên quan và người dùng cuối [17]. Bằng cách sử dụng các kỹ thuật cung cấp giải thích rõ ràng cho các kết quả do mô hình AI tạo ra, các bên liên quan có thể hiểu rõ hơn về các yếu tố và đặc điểm ảnh hưởng đến kết quả. Khả năng diễn giải nâng cao này giúp nông dân hiểu được lý do đằng sau các khuyến nghị và dự đoán do AI điều khiển, góp phần vào sự chấp nhận và ra quyết định sáng suốt của họ. Những tiến bộ trong XAI đại diện cho một bước tiến quan trọng hướng tới việc tạo ra các mô hình AI minh bạch và đáng tin cậy hơn, phù hợp với nhu cầu và mong đợi của cộng đồng nông nghiệp.

10.5.2.3 Tích hợp với IoT và Viễn thám

Sự hội tụ của AI với các thiết bị IoT, công nghệ viễn thám và robot có tiềm năng tạo ra các giải pháp sức mạnh tổng hợp, cách mạng hóa việc thu thập dữ liệu, giám sát và hỗ trợ quyết định trong lĩnh vực nông nghiệp [21]. Bằng cách kết hợp sức mạnh phân tích của AI với các luồng dữ liệu được tạo ra bởi các thiết bị IoT và cảm biến từ xa, nông dân có thể truy cập thông tin thời gian thực về điều kiện đất đai, mô hình thời tiết, sức khỏe cây trồng và hoạt động của máy móc [22]. Hệ sinh thái dữ liệu động này giúp nông dân đưa ra quyết định kịp thời và sáng suốt, cho phép các can thiệp chủ động để giải quyết các thách thức như quản lý tưới tiêu, bùng phát dịch hại và tối ưu hóa năng suất. Hơn nữa, việc tích hợp robot giúp khuếch đại thêm những khả năng này, tạo điều kiện cho các hành động chính xác và tự động như phun thuốc trừ sâu có mục tiêu hoặc thu hoạch cây trồng [23]. Cách tiếp cận toàn diện này tận dụng khả năng xử lý dữ liệu phức tạp của AI, tạo ra sự hợp nhất liền mạch của các công nghệ giúp tăng cường năng suất, tính bền vững và khả năng phục hồi của nông nghiệp.

10.5.2.4 Nỗ lực Hợp tác

Sự hợp tác hiệu quả giữa các nhà nghiên cứu, chuyên gia nông nghiệp, nhà hoạch định chính sách và nhà phát triển công nghệ nổi lên như một điều kiện tiên quyết cơ bản cho sự tích hợp thành công của AI trong nông nghiệp. Cách tiếp cận hợp tác này là bắt buộc do tính chất đa chiều của các thách thức và cơ hội do việc triển khai AI mang lại [24]. Bằng cách thúc đẩy đối thoại liên ngành, các bên liên quan có thể cùng nhau xây dựng các khuôn khổ không chỉ tạo điều kiện cho việc triển khai AI một cách có trách nhiệm và đạo đức mà còn giải quyết các vấn đề phức tạp liên quan đến quyền riêng tư dữ liệu, giảm thiểu thiên vị và tiếp cận công bằng các lợi ích công nghệ. Những nỗ lực hợp tác này đỉnh điểm là sự phát triển của các hướng dẫn và quy định thúc đẩy việc áp dụng AI một cách minh bạch và công bằng, cuối cùng góp phần tạo ra một hệ sinh thái nông nghiệp toàn diện và bền vững.

10.5.2.5 Tùy chỉnh cho Bối cảnh Địa phương

Việc điều chỉnh các giải pháp AI để phù hợp với các thực hành nông nghiệp địa phương cụ thể, điều kiện khí hậu đa dạng và các yếu tố kinh tế xã hội phức tạp là điều bắt buộc để khai thác toàn bộ tiềm năng của các công nghệ này và đảm bảo hiệu quả của chúng. Hệ thống nông nghiệp rất khác nhau giữa các vùng, và cách tiếp cận một kích cỡ cho tất cả (one-size-fits-all) có thể không mang lại kết quả tối ưu [25]. Bằng cách tùy chỉnh các giải pháp AI để phù hợp với các sắc thái địa phương, chẳng hạn như chu kỳ cây trồng, loại đất và tính sẵn có của tài nguyên, công nghệ có thể được tối ưu hóa để mang lại những hiểu biết sâu sắc có thể hành động, phù hợp với nhu cầu riêng của nông dân. Hơn nữa, việc tính đến các yếu tố kinh tế xã hội đảm bảo rằng việc áp dụng các giải pháp AI là phù hợp và có lợi cho cộng đồng địa phương, thúc đẩy sự tham gia và cam kết bền vững. Khả năng thích ứng này giúp tăng cường hiệu quả tổng thể của các ứng dụng AI trong nông nghiệp, thúc đẩy các kết quả tích cực vượt ra ngoài lợi ích về năng suất.

10.5.2.6 Cân nhắc Đạo đức

Giải quyết các cân nhắc đạo đức liên quan đến việc triển khai AI trong nông nghiệp có ý nghĩa then chốt, bao gồm các mệnh lệnh như tiếp cận công nghệ công bằng, giảm thiểu thiên vị và bảo vệ phúc lợi của người lao động nông nghiệp. Những lo ngại này nhấn mạnh sự cần thiết của một cách tiếp cận toàn diện và có trách nhiệm đối với việc triển khai AI trong lĩnh vực nông nghiệp. Đảm bảo quyền tiếp cận công bằng với công nghệ AI trở nên quan trọng để ngăn chặn khoảng cách số và cho phép tất cả nông dân, bất kể nguồn lực hay vị trí của họ, đều được hưởng lợi từ những tiến bộ công nghệ [26]. Khía cạnh quan trọng của việc giảm thiểu thiên vị trong các hệ thống AI là rất quan trọng để ngăn chặn các kết quả phân biệt đối xử và đảm bảo việc ra quyết định công bằng, đặc biệt là trong các quy trình như dự đoán năng suất cây trồng hoặc chẩn đoán bệnh. Cuối cùng, việc duy trì phúc lợi của người lao động nông nghiệp là điều tối quan trọng, vì tự động hóa và tích hợp AI có thể định hình lại động lực lao động, đòi hỏi phải lập kế hoạch và các biện pháp chu đáo để ngăn chặn bất kỳ tác động bất lợi nào đến sinh kế [27]. Tuân

thủ những cân nhắc đạo đức này là điều không thể thiếu để thúc đẩy một sự chuyển đổi AI bền vững và công bằng trong nông nghiệp.

10.5.2.7 Khung pháp lý

Xây dựng các quy định và chính sách phù hợp cho việc sử dụng các ứng dụng AI trong lĩnh vực nông nghiệp có tiềm năng đáng kể để thiết lập một khuôn khổ hướng dẫn việc tích hợp an toàn và có trách nhiệm các công nghệ này. Bản chất đa diện của tác động của AI đòi hỏi sự quản trị bao gồm các khía cạnh như quyền riêng tư dữ liệu, bảo mật, cân nhắc đạo đức và tuân thủ các tiêu chuẩn ngành [28]. Bằng cách đưa ra các quy định giải quyết những lo ngại này, các nhà hoạch định chính sách có thể tạo điều kiện cho việc triển khai AI một cách có đạo đức đồng thời duy trì một sân chơi công bằng và bình đẳng cho tất cả các bên liên quan. Các quy định này đóng vai trò như một biện pháp bảo vệ chống lại các rủi ro tiềm ẩn và giúp xây dựng một môi trường thuận lợi nơi việc áp dụng AI được đặc trưng bởi tính minh bạch, trách nhiệm giải trình và tuân thủ các thông lệ tốt nhất.

10.5.2.8 Mở rộng và Khả năng tiếp cận

Đảm bảo khả năng tiếp cận các giải pháp AI và ML cho nông dân quy mô nhỏ và các vùng sâu vùng xa là một mệnh lệnh then chốt để đạt được tác động phổ rộng và giảm bớt chênh lệch trong việc áp dụng công nghệ nông nghiệp. Ở nhiều khu vực, nông dân quy mô nhỏ là xương sống của ngành nông nghiệp , và việc mở rộng lợi ích của AI và ML cho họ là rất quan trọng cho sự tăng trưởng bao trùm [29]. Ngoài ra, việc tiếp cận các vùng sâu vùng xa với kết nối và nguồn lực hạn chế đòi hỏi các giải pháp sáng tạo để thu hẹp khoảng cách số và mang lại lợi thế của AI cho những người cần chúng nhất. Bằng cách ưu tiên khả năng tiếp cận, các nhà hoạch định chính sách, nhà phát triển công nghệ và các bên liên quan góp phần vào việc dân chủ hóa các tiến bộ nông nghiệp, trao quyền cho nông dân ở các quy mô và bối cảnh địa lý khác nhau.

Mặc dù AI và ML đã cho thấy tiềm năng lớn trong việc chuyển đổi nông nghiệp, một số thách thức cần được giải quyết để đảm bảo sự tích hợp thành công của chúng. Giải quyết chất lượng dữ liệu, quyền riêng tư, cân nhắc đạo đức và khả năng diễn giải là những bước quan trọng. Nhìn về phía trước, việc tinh chỉnh các thuật toán, đón nhận XAI và thúc đẩy các hệ sinh thái hợp tác có thể thúc đẩy vai trò của AI trong việc tái định hình nông nghiệp cho một tương lai bền vững và kiên cường hơn.

10.6 KẾT LUẬN

Sự kết hợp giữa AI và ML với nông nghiệp hứa hẹn vô cùng to lớn, mang lại tiềm năng chuyển đổi trên nhiều khía cạnh khác nhau của ngành. Nghiên cứu toàn diện này đã làm sáng tỏ các khái niệm cơ bản của AI và ML, bản chất dựa trên dữ liệu, trích xuất đặc trưng, lựa chọn mô hình và đánh giá. Các ứng dụng được thảo luận, từ dự đoán năng suất cây trồng đến phát hiện bệnh và nông nghiệp chính xác, nhấn mạnh cách thức các công

nghệ này đang định hình lại các thực hành truyền thống để nâng cao năng suất, tính bền vững và tối ưu hóa tài nguyên.

Hơn nữa, những thách thức và cân nhắc xung quanh chất lượng dữ liệu, quyền riêng tư, tính minh bạch và sự hợp tác của các bên liên quan nhấn mạnh sự cần thiết của việc triển khai có trách nhiệm và đạo đức. Khi các giải pháp dựa trên AI tiếp tục phát triển, sự tích hợp của XAI và sự hợp tác giữa các chuyên gia và nông dân được kỳ vọng sẽ tăng cường tính minh bạch và sự chấp nhận.

Bối cảnh phát triển của AI trong nông nghiệp đòi hỏi phải phát triển các khuôn khổ giải quyết các mối quan tâm về đạo đức, quy định và khả năng tiếp cận. Những nỗ lực này rất quan trọng để đảm bảo rằng các công nghệ AI và ML không chỉ có thể tiếp cận được mà còn góp phần thu hẹp sự chênh lệch trong việc áp dụng công nghệ giữa các bên liên quan khác nhau trong nông nghiệp.

Cuối cùng, sự tích hợp này mang đến một quỹ đạo thú vị hướng tới một tương lai nông nghiệp kiên cường, năng suất và bền vững hơn, nơi công nghệ tăng cường chuyên môn của con người vì lợi ích chung của nông dân, cộng đồng và nguồn cung cấp lương thực toàn cầu.

TÀI LIỆU THAM KHẢO

[1] H. Witten, E. Frank, and M. A. Hall, *Data Mining: Practical Machine Learning Tools and Techniques* (ấn bản 4), Morgan Kaufmann, 2016.

[2] I. Guyon and A. Elisseeff, "An Introduction to Variable and Feature Selection," *Journal of Machine Learning Research*, tập 3, trang 1157-1182, 2003.

[3] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (ấn bản 2), Springer, 2009.

[4] A. Kamilaris, F. X. Prenafeta-Boldú, and A. Likas, "A Review on the Practice of Big Data Analysis in Agriculture," *Computers and Electronics in Agriculture*, tập 143, trang 23-37, 2017.

[5] S. P. Mohanty, D. P. Hughes, and M. Salathé, "Using Deep Learning for Image-Based Plant Disease Detection," *Frontiers in Plant Science*, tập 7, trang 1-10, 2016.

[6] Y. Ruiz-García and E. Gómez-Plaza, "Elicitors: A Tool for Improving Fruit Phenolic Content," *Agriculture*, tập 3, số 1, trang 33-52, 2013.

[7] A. Kamilaris, A. Kartakoullis, and F. X. Prenafeta-Boldú, "A Review on the Use of Artificial Intelligence in Crop Disease Detection," *Precision Agriculture*, tập 19, số 5, trang 881-905, 2018.

[8] D. Mitra, S. Gupta, D. Srivastava, and S. Sani, “Plant Disease Identification Using Convolution Neural Networks,” trong D. Srivastava, N. Sharma, D. Sinwar, J. H. Yousif, H. P. Gupta (eds) *Intelligent Internet of Things for Smart Healthcare Systems*, CRC Press, 2023, trang 203-215.

[9] A. Srinivasan, K. Seetharam, and S. Singh, “Precision Agriculture: An Overview and Advances in Data Analytics for Site-Specific Crop Management,” *Computers and Electronics in Agriculture*, tập 172, 2020.

[10] Y. Zheng, X. Zhang, Q. Cheng, and X. Xu, “A Review on the Applications of Artificial Intelligence in Soil Monitoring and Management,” *Journal of Integrative Agriculture*, tập 20, số 4, trang 865-875, 2021.

[11] E. Hassanpour Adeh, F. Abbasi, and H. R. Maier, “A Review of Data-Driven Approaches for Enhancing Water Management and Crop Yield for Irrigation Systems,” *Journal of Hydrology*, tập 568, trang 285-310, 2019.

[12] A. Mousavi, M. Gharakhani, and A. Mosavi, “Machine Learning in Agriculture: A Review,” *Computers and Electronics in Agriculture*, tập 170, 2020.

[13] A. Fuentes, S. Yoon, and D. S. Park, “A Deep Learning Framework for Groundnut Leaf Disease Identification and Severity Estimation,” *Computers and Electronics in Agriculture*, tập 161, trang 272-282, 2018.

[14] S. K. Pathan, M. A. Mohammed, and M. H. Anisi, “Internet of Things (IoT) Applications in Precision Agriculture,” *Computers and Electronics in Agriculture*, tập 173, 2020.

[15] S. Shakya, D. Murthy, and M. Kumar, “Crop Yield Prediction Using Machine Learning: A Review,” *Computers and Electronics in Agriculture*, tập 184, 2021.

[16] T. N. N. Lam, V. T. Truong, D. C. Nguyen, D. Q. Le, and T. D. Nguyen, “Applications of Machine Learning in Agriculture: A Survey,” *Computers and Electronics in Agriculture*, tập 175, 2020.

[17] R. Guidotti et al., “A Survey of Methods for Explaining Black Box Models,” *ACM Computing Surveys*, tập 51, số 5, trang 1-42, 2018.

[18] I. Lopes and F. Bacao, “A Review on Data Quality Assessment Methods for Machine Learning,” *Data & Knowledge Engineering*, tập 134, 2021.

[19] M. Rabbi, M. A. Rahman, D. R. Kowalski, E. M. Berke, D. B. Flora, and L. C. Brewer, “Protecting Confidentiality of Personal Health Information in Small Health Data Sets,” *Journal of Medical Internet Research*, tập 21, số 7, 2019.

[20] A. M. Rady and Y. M. Neinaa, “Predicting Yield of Summer Maize Crop using Artificial Neural Networks (ANNs) and Multiple Linear Regression (MLR) Models,” *Computers and Electronics in Agriculture*, tập 186, 2021.

[21] M. Goyal and D. Srivastava, “A Behaviour-Based Authentication to Internet of Things Using Machine Learning,” trong S. L. Tripathi, D. K. Singh, S. Padmanaban, and P. Raja (eds) *Design and Development of Efficient Energy Systems*, 2022, trang 245-263.

[22] N. Zhang, R. Wang, and Y. Huang, “Smart Agriculture: An Integrated IoT Framework for Agricultural Decision Making,” *IEEE Internet of Things Journal*, tập 8, số 3, trang 1705-1715, 2021.

[23] E. Guzmán, D. Megías, and M. Torres-Torriti, “A Review on Robotics in Agriculture,” *Precision Agriculture*, tập 20, số 4, trang 693-719, 2019.

[24] P. Capper, T. Beck, G. Robinson, and J. Arthur, “Agricultural Development and Environmental Policy: A Case for Collaboration in Meeting 21st Century Challenges,” *Journal of Environmental Quality*, tập 47, số 4, trang 644-653, 2018.

[25] A. Kamilaris, A. Kartakoullis, and F. X. Prenafeta-Boldú, “A Review on the Use of AI in Agriculture,” *Information Processing in Agriculture*, tập 7, số 4, trang 528-550, 2020.

[26] D. G. Tadesse, G. Caramanna, A. Ploeger, A. Kessler, R. Strahan, and K. Naveed, “Artificial Intelligence in Agriculture: A Brief Introduction and Review,” *IEEE Access*, tập 9, trang 18669-18684, 2021.

[27] S. Fountas et al., “Agricultural Robotics in Support of a Sustainable Rural Development,” *Sustainability*, tập 11, số 5, 2019.

[28] H. Lütkepohl and M. Schomaker, “Responsible AI for the Food and Agriculture Sector: Overview, Challenges, and Perspectives,” *European Journal of Operational Research*, tập 295, số 2, trang 465-475, 2021.

[29] A. Buckwell, J. Mills, J. Ingram, J. Dwyer, and N. Powell, “A Review of Evidence for the Relationship between Farm Business Management Practices and Farm Performance,” *Land Use Policy*, tập 97, 2020.

CHƯƠNG 11: TƯƠNG LAI NÔNG NGHIỆP: TẬN DỤNG NGÔN NGỮ MÁY ĐỂ DỰ BÁO BỆNH TRÊN LÁ KHOAI TÂY VÀ TỐI ƯU HÓA NĂNG SUẤT

A. Vijayalakshmi, A. Nidin, và Deepthi Das CHRIST (Deemed to be University), Bangalore, Ấn Độ

11.1 GIỚI THIỆU

Sự giao thoa giữa nông nghiệp và công nghệ không phải là một hiện tượng mới; trong suốt lịch sử, những tiến bộ trong thực hành canh tác đã liên kết chặt chẽ với các đổi mới công nghệ. Tuy nhiên, sự ra đời của trí tuệ nhân tạo (AI) và học máy (ML) đã giới thiệu một làn sóng chuyển đổi trong nông nghiệp, hứa hẹn cách mạng hóa cách chúng ta canh tác, quản lý và tối ưu hóa sản xuất cây trồng. Theo truyền thống, nông nghiệp được định hình bởi vô số yếu tố, bao gồm điều kiện thời tiết, chất lượng đất, sự sẵn có của nước, và sự bùng phát của sâu bệnh. Những yếu tố này góp phần vào những bất ổn và thách thức cố hữu mà nông dân phải đối mặt, thường dẫn đến lãng phí tài nguyên và giảm năng suất.

Dự đoán năng suất cây trồng là một khía cạnh quan trọng của nông nghiệp hiện đại, cần thiết để đảm bảo an ninh lương thực, tối ưu hóa phân bổ tài nguyên và đưa ra các quyết định sáng suốt khi đối mặt với các điều kiện môi trường năng động. Với dân số thế giới tăng đều đặn và biến đổi khí hậu mang đến sự không chắc chắn lớn hơn cho các hoạt động canh tác, khả năng ước tính chính xác năng suất cây trồng đã trở nên quan trọng hơn bao giờ hết. Dự đoán năng suất cây trồng tận dụng sự kết hợp của kiến thức nông nghiệp truyền thống, công nghệ tiên tiến và phân tích dựa trên dữ liệu để dự báo sản lượng thu hoạch có thể có của các loại cây trồng khác nhau, bao gồm các mặt hàng chủ lực như lúa mì, gạo, ngô và các loại cây trồng đặc sản như trái cây và rau quả. Khả năng dự đoán này trao quyền cho nông dân, các nhà hoạch định chính sách và toàn bộ ngành nông nghiệp để lập kế hoạch hiệu quả, quản lý tài nguyên hiệu quả, và chủ động ứng phó với các thách thức như sâu bệnh, dịch bệnh, và các sự kiện thời tiết bất lợi. Khi nông nghiệp ngày càng giao thoa với khoa học dữ liệu, ML, và công nghệ viễn thám, độ chính xác và sự tinh vi của các mô hình dự đoán năng suất cây trồng tiếp tục phát triển, hứa hẹn tiềm năng cách mạng hóa sản xuất lương thực toàn cầu và thúc đẩy các thực hành canh tác bền vững.

11.2 TỔNG QUAN TÀI LIỆU

Với sự phát triển của công nghệ dữ liệu lớn và máy tính hiệu suất cao, ML đã mở ra những khả năng mới cho khoa học thâm dụng dữ liệu trong lĩnh vực đa ngành của công nghệ nông nghiệp [1]. API Watson ML của IBM phân tích dữ liệu thời tiết, dữ liệu cảm biến Internet vạn vật (IoT), và các nguồn khác để cung cấp cho nông dân các khuyến nghị phù hợp về trồng trọt, thu hoạch và tưới tiêu. Công nghệ này đã được sử dụng ở nhiều khu vực khác nhau để tăng cường thực hành nông nghiệp [2]. Google Earth Engine sử dụng hình ảnh vệ tinh và ML để giám sát nạn phá rừng, theo dõi thay đổi sử dụng đất, và đánh giá sức khỏe cây trồng trên toàn thế giới, hỗ trợ giám sát nông nghiệp và môi trường [3]. Các tác giả ở đây đã tiến hành một đánh giá về các ứng dụng ML trong hệ thống sản

xuất nông nghiệp. Nghiên cứu chứng minh cách các công nghệ ML sẽ hỗ trợ nông nghiệp. Các tác giả trong [4] đã tiến hành một tổng quan tài liệu kỹ lưỡng và phân tích các thuật toán ML khác nhau để dự đoán bệnh thực vật. Các kỹ thuật tiền xử lý khác nhau trên hình ảnh cũng được thảo luận trong công trình này, chứng minh cách phát hiện tự động có thể giúp tăng năng suất cây trồng. Một công trình được thực hiện bởi [5] đã đề xuất một phương pháp học thích ứng, cho độ chính xác 99.2% trong việc phân loại bệnh lá cây trồng đối với dữ liệu cây trồng không đồng nhất của cây lúa. Các tác giả đã so sánh kết quả với các kỹ thuật khác - cụ thể là mạng nơ-ron truyền ngược (BPNN), mạng nơ-ron tích chập (CNN), và máy vector hỗ trợ (SVM) và thấy rằng công trình đề xuất cho độ chính xác tốt hơn. Phân tích được thực hiện trên dữ liệu năng suất 40 năm từ 351 hạt của Đức bởi các tác giả trong [6] để xác định các đặc điểm thủy văn đất và khí tượng chiếm ưu thế trên bốn loại cây trồng. Kết quả của nghiên cứu chứng minh các yếu tố khí hậu quan trọng hơn độ ẩm của đất. Một tổng quan tài liệu được thực hiện trên các nghiên cứu dự đoán năng suất cây trồng bằng thuật toán học máy [7] chứng minh rằng các thuật toán ML có khả năng xác định các mẫu và trích xuất thông tin từ cả dữ liệu có cấu trúc và phi cấu trúc. Khảo sát cũng kết luận rằng các thuật toán ML tiên tiến, như các phương pháp học sâu, đã cho thấy chúng tốt nhất trong việc xử lý lượng lớn dữ liệu. Các tác giả trong [8] đã đề xuất một biến thể bán tham số của mạng nơ-ron sâu cho dữ liệu về năng suất ngô từ vùng Trung Tây Hoa Kỳ. Kết quả của mô hình cho thấy các tác động tiêu cực của biến đổi khí hậu đối với năng suất ngô. Trong [9], các tác giả nói rằng có rất nhiều mô hình phân loại cây trồng dựa trên thời tiết, bệnh cây trồng, giai đoạn sinh trưởng, v.v. Các tác giả đã làm một đánh giá về các phương pháp luận khác nhau và độ chính xác mà chúng cung cấp để dự đoán năng suất nông nghiệp bằng kỹ thuật AI.

Tổng quan toàn diện về tài liệu được trình bày ở trên nêu bật rõ ràng vai trò công cụ của các thuật toán ML trong lĩnh vực dự đoán năng suất cây trồng và tác động chuyển đổi của chúng đối với ngành nông nghiệp. Thông qua vô số các nghiên cứu và nỗ lực nghiên cứu, rõ ràng rằng các thuật toán ML đóng vai trò là công cụ mạnh mẽ có khả năng khai thác tiềm năng của thông tin chi tiết dựa trên dữ liệu để cách mạng hóa các thực hành canh tác. Những thuật toán này đã chứng minh khả năng giải mã các mẫu phức tạp, dự đoán năng suất cây trồng với độ chính xác đáng kể, và cung cấp hỗ trợ vô giá cho nông dân trong việc đưa ra các quyết định sáng suốt liên quan đến trồng trọt, canh tác, và phân bổ tài nguyên. Hơn nữa, khả năng phát hiện và quản lý bệnh cây trồng, tối ưu hóa việc sử dụng tài nguyên, và thích ứng với các điều kiện môi trường thay đổi nhấn mạnh tầm quan trọng của chúng trong việc đảm bảo an ninh lương thực và tính bền vững trong nông nghiệp. Về bản chất, sự kết hợp giữa ML và nông nghiệp mang đến một con đường đầy hứa hẹn cho tương lai, nơi công nghệ được tận dụng để nâng cao năng suất, giảm thiểu rủi ro, và thúc đẩy ngành nông nghiệp hướng tới hiệu quả và khả năng phục hồi cao hơn.

11.3 MỤC TIÊU VÀ CẤU TRÚC CỦA CHƯƠNG

Khoai tây là một loại cây lương thực chủ lực trên toàn cầu, cung cấp một phần đáng kể lượng calo trong chế độ ăn uống của thế giới. Tuy nhiên, chúng rất dễ bị nhiễm các bệnh khác nhau, chẳng hạn như bệnh mốc sương (late blight) và bệnh đốm vòng (early blight),

có thể tàn phá năng suất nếu không được kiểm soát. Phát hiện bệnh trên lá khoai tây có tầm quan trọng tối cao để đạt được năng suất cây trồng tăng lên và đảm bảo an ninh lương thực. Phát hiện bệnh kịp thời cho phép nông dân thực hiện các biện pháp chủ động, chẳng hạn như áp dụng thuốc trừ sâu có mục tiêu hoặc loại bỏ cây bị nhiễm bệnh, để ngăn chặn sự lây lan của bệnh trên khắp cánh đồng. Bằng cách xác định và giải quyết bệnh sớm, nông dân có thể giảm thiểu tổn thất năng suất, giảm chi phí sản xuất, và duy trì chất lượng của khoai tây thu hoạch. Hơn nữa, các công nghệ phát hiện bệnh và phân tích hình ảnh cho phép giám sát và quản lý chính xác cây khoai tây, góp phần vào nông nghiệp bền vững và tăng cường sản xuất lương thực toàn cầu.

Trong nghiên cứu này, trọng tâm chính xoay quanh việc phân loại các bệnh trên lá khoai tây. Với những thách thức ngày càng tăng trong nông nghiệp và nhu cầu cấp thiết phải nâng cao năng suất cây trồng và an ninh lương thực, việc xác định và phân loại chính xác các bệnh ảnh hưởng đến lá khoai tây có tầm quan trọng hàng đầu. Thông qua việc sử dụng các kỹ thuật tiên tiến trong phân tích hình ảnh và ML, chúng tôi mong muốn phát triển một hệ thống phân loại mạnh mẽ có khả năng phân biệt các bệnh khác nhau trên lá khoai tây. Nghiên cứu này không chỉ góp phần phát hiện bệnh sớm mà còn tạo điều kiện cho việc ra quyết định sáng suốt cho nông dân, cho phép can thiệp kịp thời và các chiến lược quản lý chính xác, cuối cùng là tăng cường sức khỏe và năng suất cây trồng.

11.4 KHOAI TÂY LÀ CÂY LƯƠNG THỰC CHỦ LỰC

Khoai tây, tên khoa học là Solanum tuberosum, có ý nghĩa to lớn như một cây lương thực chủ lực trên toàn thế giới do giá trị dinh dưỡng, tính linh hoạt trong các ứng dụng ẩm thực, và khả năng phát triển mạnh ở các vùng khí hậu đa dạng. Hiểu biết về sản xuất khoai tây toàn cầu và tính nhạy cảm của chúng đối với các bệnh như mốc sương và đốm vòng là rất quan trọng để đảm bảo an ninh lương thực và giải quyết các thách thức mà nghề trồng khoai tây phải đối mặt. Khoai tây là một nguồn giàu carbohydrate, chất xơ, vitamin (đặc biệt là vitamin C và một số vitamin B), và các khoáng chất thiết yếu như kali và magiê. Chúng cung cấp một phần đáng kể lượng calo hàng ngày cho hàng triệu người trên thế giới. Trong nghiên cứu này, chúng tôi đã xem xét hình ảnh lá khoai tây bị ảnh hưởng bởi các bệnh như mốc sương và đốm vòng, và sử dụng mô hình học sâu, chúng tôi đã dự đoán sự xuất hiện của bệnh trên lá.

- **Bệnh Mốc sương (Late Blight):** Bệnh mốc sương là một trong những bệnh khoai tây có sức tàn phá lớn nhất. Nó biểu hiện dưới dạng các tổn thương màu xanh đậm đến đen trên lá, thường được bao quanh bởi một lớp nấm mốc trắng, mịn như lông tơ ở mặt dưới, như trong Hình 11.1. Cây bị nhiễm bệnh suy giảm nhanh chóng, và bệnh có thể lây lan nhanh trong điều kiện mát mẻ, ẩm ướt. Việc xác định chính xác bệnh mốc sương là rất quan trọng vì nó rất dễ lây lan và có thể dẫn đến tổn thất năng suất đáng kể nếu không được giải quyết kịp thời.



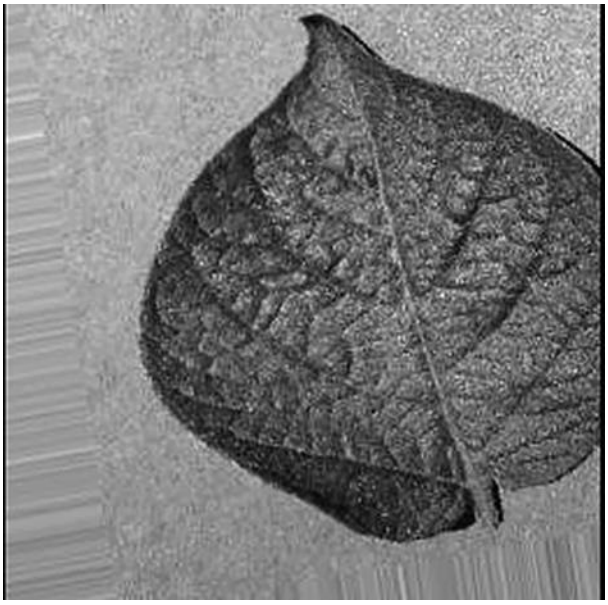
Hình 11.1 Bệnh mốc sương (late blight) trên lá khoai tây.

- **Bệnh Đốm vòng (Early Blight):** Bệnh đốm vòng chủ yếu ảnh hưởng đến các lá phía dưới của cây khoai tây. Nó biểu hiện dưới dạng các tổn thương hình tròn đến không đều với tâm sẫm màu và quầng vàng, như trong Hình 11.2. Những tổn thương này có thể hợp nhất và dẫn đến rụng lá trên diện rộng, làm giảm khả năng quang hợp và chất lượng củ. Phân loại đúng bệnh đốm vòng giúp nông dân thực hiện các biện pháp kiểm soát có mục tiêu, bao gồm thuốc diệt nấm và cắt tỉa lá bị ảnh hưởng, để hạn chế tác động của bệnh đối với năng suất và chất lượng củ khoai tây.
- **Lá khỏe mạnh:** Một lá khoai tây khỏe mạnh phải có màu xanh rực rỡ mà không có bất kỳ vết nâu, đốm, hoặc tổn thương đáng kể nào, như trong Hình 11.3. Bề mặt lá phải nhẵn và không có các khối u hoặc sự đổi màu bất thường.

Tóm lại, phân loại bệnh chính xác trong cây khoai tây là một khía cạnh cơ bản của nông nghiệp bền vững, cho phép nông dân bảo vệ năng suất, tối ưu hóa việc sử dụng tài nguyên, và góp phần vào an ninh lương thực toàn cầu. Nông dân và các nhà nghiên cứu liên tục làm việc để phát triển các giống khoai tây kháng bệnh và thực hiện các kỹ thuật canh tác bền vững để giảm thiểu tác động của những bệnh này và đảm bảo sự ổn định của khoai tây như một cây trồng chủ lực toàn cầu.



Hình 11.2 Bệnh đốm vòng (early blight) trên lá khoai tây.

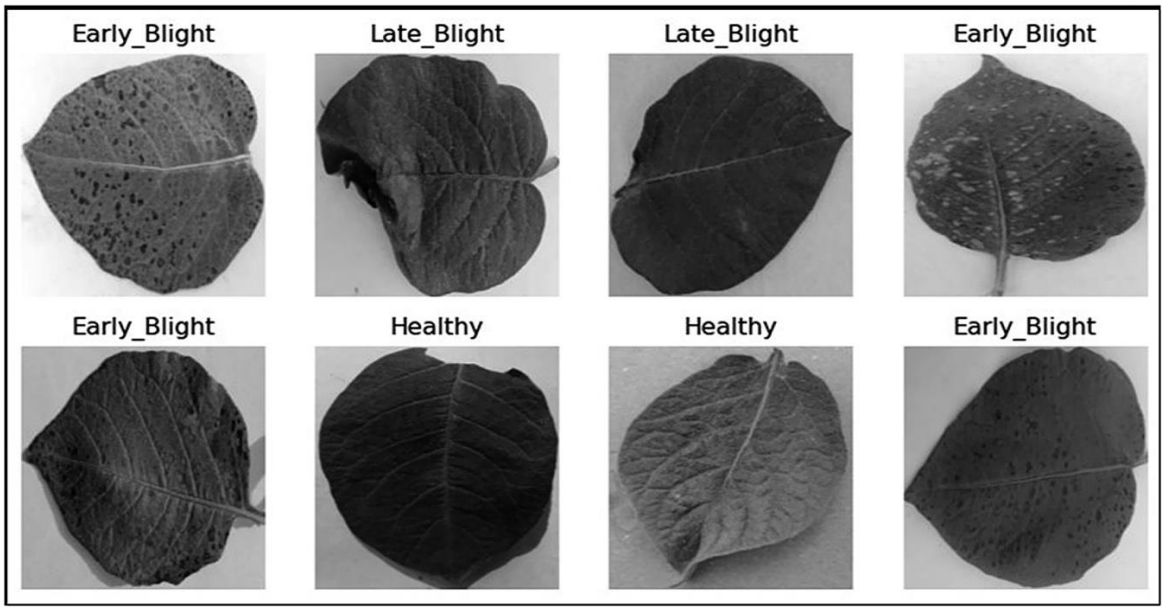


Hình 11.3 Lá khoai tây khỏe mạnh.

11.5 THU THẬP VÀ TĂNG CƯỜNG DỮ LIỆU

Khoai tây là một trong những cây trồng được canh tác rộng rãi nhất trên thế giới, nhưng nó dễ bị nhiễm các bệnh khác nhau có thể làm giảm đáng kể năng suất cây trồng. Phát hiện sớm và chẩn đoán chính xác các bệnh này là rất quan trọng để quản lý bệnh hiệu quả. Trong chương này, chúng tôi đã xem xét một trường hợp bệnh lá khoai tây rất phổ biến trong nông nghiệp. Chúng tôi mong muốn phân loại lá khoai tây bằng kỹ thuật học sâu để phát hiện bệnh. Chúng tôi đã sử dụng tập dữ liệu hình ảnh lá khoai tây và áp dụng CNN để phân loại.

Một mẫu hình ảnh từ tập dữ liệu của mỗi danh mục được thể hiện trong Hình 11.4.



Hình 11.4 Hình ảnh mẫu từ tập dữ liệu. (Hình ảnh hiển thị 8 lá khoai tây với các nhãn: Early_Blight, Late_Blight, Late_Blight, Early_Blight, Early_Blight, Healthy, Healthy, Early_Blight)

Các quá trình tăng cường (augmentation) khác nhau được thực hiện cho các hình ảnh. Ban đầu, các hình ảnh được điều chỉnh tỷ lệ về phạm vi [0, 1]. Hơn nữa, các hình ảnh được xoay trong phạm vi 30 độ. Biến dạng cắt (Shearing) và phạm vi thu phóng (zoom) được thực hiện 20%. Dịch chuyển theo chiều rộng và chiều cao được thực hiện 5%. Không gian được tạo ra bởi tất cả các phép biến đổi này được lấp đầy bằng phương pháp láng giềng gần nhất (nearest neighbor).

11.6 CÁC MÔ HÌNH ML

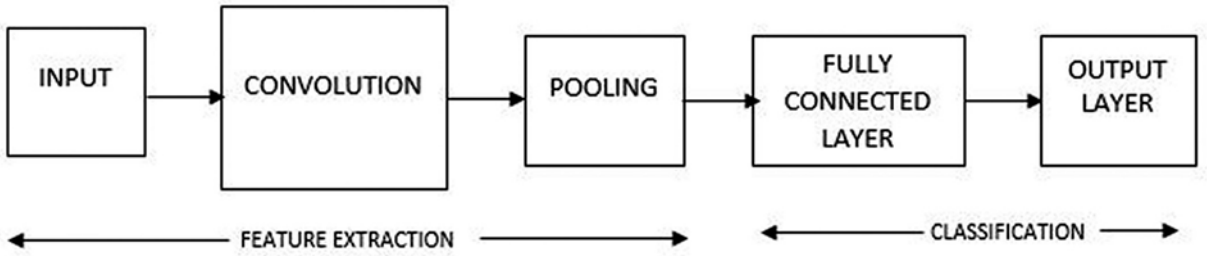
Dự đoán năng suất cây trồng là một thành phần quan trọng của nông nghiệp hiện đại, mang lại tiềm năng nâng cao an ninh lương thực, tối ưu hóa phân bổ tài nguyên, và giảm thiểu tác động của biến đổi khí hậu. Học sâu, một tập hợp con của ML, đã nổi lên như một công cụ mạnh mẽ trong lĩnh vực này, có khả năng thay đổi cách chúng ta dự báo năng suất cây trồng. Không giống như các mô hình thống kê truyền thống, các mô hình học sâu có thể tự động học và trích xuất các mẫu phức tạp từ các tập dữ liệu nông nghiệp rộng lớn và đa dạng, bao gồm các yếu tố như thời tiết, đất đai, và hồ sơ năng suất lịch sử. Bảng 11.1 liệt kê các mô hình ML khác nhau và các thuộc tính của chúng [10-13]. Bằng cách tận dụng các mạng nơ-ron sâu với nhiều lớp, các mô hình này có thể nắm bắt các mối quan hệ phức tạp và sự phụ thuộc không gian-thời gian trong dữ liệu, dẫn đến các dự đoán chính xác và đáng tin cậy hơn. Trong thời đại nhu cầu sản xuất lương thực và tính bền vững ngày càng tăng này, các mô hình học sâu để dự đoán năng suất cây trồng đại diện cho một con đường hứa hẹn để cách mạng hóa các thực hành nông nghiệp và đảm bảo an ninh lương thực toàn cầu.

BẢNG 11.1 Danh sách các Mô hình ML trong Dự đoán Năng suất Cây trồng

Thuật toán	Ưu điểm	Nhược điểm
Hồi quy Tuyến tính (Linear Regression)	Đơn giản và dễ diễn giải, hoạt động tốt với các mối quan hệ tuyến tính	Bị giới hạn trong dữ liệu tuyến tính, nhạy cảm với các điểm ngoại lệ và đa cộng tuyến
Hồi quy Logistic (Logistic Regression)	Phù hợp để phân loại nhị phân. Cung cấp các ước tính xác suất	Giả định ranh giới quyết định tuyến tính. Có thể không xử lý tốt các mối quan hệ phức tạp
Cây Quyết định (Decision Trees)	Rất dễ diễn giải. Xử lý cả dữ liệu số và dữ liệu hạng mục	Dễ bị quá khớp (overfitting) nếu không cắt tỉa. Nhạy cảm với các thay đổi nhỏ của dữ liệu
Rừng Ngẫu nhiên (Random Forest)	Giảm quá khớp thông qua học tập hợp thành (ensemble learning). Xử lý dữ liệu nhiều chiều	Có thể tốn kém về mặt tính toán. Ít diễn giải hơn một cây quyết định đơn lẻ
Máy Vector Hỗ trợ (Support Vector Machines)	Hiệu quả trong không gian nhiều chiều. Có thể xử lý dữ liệu phi tuyến tính bằng thủ thuật kernel (kernel trick)	Nhạy cảm với việc lựa chọn kernel. Có thể tốn kém về mặt tính toán cho các tập dữ liệu lớn
K-Láng giềng Gần nhất (K-Nearest Neighbors)	Đơn giản và dễ thực hiện. Phi tham số (không có giả định về phân phối dữ liệu)	Tốn kém về mặt tính toán cho các tập dữ liệu lớn. Nhạy cảm với việc lựa chọn k
Naive Bayes	Hiệu quả và phù hợp để phân loại văn bản. Hoạt động tốt với dữ liệu nhiều chiều	Giả định tính độc lập giữa các đặc trưng (giả định ngây thơ). Có thể không nắm bắt được các phụ thuộc phức tạp
Mạng Nơ-ron (Neural Networks)	Khả năng học các mẫu phức tạp cao. Phù hợp cho các tác vụ học sâu	Để huấn luyện mạng nơ-ron, cần dữ liệu khổng lồ. Điều này có thể tốn kém về mặt tính toán
Phân cụm K-Means (K-Means Clustering)	Đơn giản và hiệu quả cho phân cụm không giám sát. Mở rộng tốt cho các tập dữ liệu lớn	Yêu cầu đặc tả số lượng cụm (k). Nhạy cảm với các tâm cụm ban đầu

11.6.1 Mạng Nơ-ron Tích chập (CNN)

CNN, còn được gọi là ConvNet, là một kiến trúc học sâu được thiết kế đặc biệt cho các nhiệm vụ liên quan đến phân tích, nhận dạng và xử lý hình ảnh. CNN đã cách mạng hóa thị giác máy tính và là công cụ trong nhiều ứng dụng, từ phân loại hình ảnh đến phát hiện đối tượng. CNN nổi bật như một kiến trúc chiếm ưu thế vì nhiều lý do. Khả năng tự động trích xuất các đặc trưng phân cấp từ dữ liệu đảm bảo chúng vượt trội trong việc nhận dạng các mẫu và đối tượng trong hình ảnh [14]. CNN chia sẻ các tham số một cách hiệu quả trên toàn bộ hình ảnh, làm cho chúng hiệu quả về mặt tính toán, đặc biệt là với các tập dữ liệu lớn. Thuộc tính bất biến qua phép dịch (translation-invariant), cùng với việc bao gồm các lớp gộp (pooling), hỗ trợ nhận dạng các đối tượng bất kể vị trí của chúng trong hình ảnh. Kết hợp với tăng cường dữ liệu và khả năng mở rộng, CNN đã củng cố danh tiếng của chúng như là các kiến trúc vượt trội trong phân loại hình ảnh [15, 16].



Hình 11.5 mô tả kiến trúc cơ bản của CNN. Các lớp khác nhau trong CNN được giải thích ở đây. (Sơ đồ khối: ĐẦU VÀO -> TÍCH CHẬP -> GỘP -> LỚP KẾT NỐI ĐẦY ĐỦ -> LỚP ĐẦU RA. Nhóm bên dưới: TRÍCH XUẤT ĐẶC TRƯNG bao gồm TÍCH CHẬP và GỘP. Nhóm PHÂN LOẠI bao gồm LỚP KẾT NỐI ĐẦY ĐỦ và LỚP ĐẦU RA)

- **Lớp Đầu vào (Input Layer):** Lớp đầu vào của CNN nhận các giá trị pixel thô của hình ảnh làm đầu vào. Hình ảnh đầu vào điển hình là các mảng 2D với ba kênh màu (Đỏ, Lục, và Lam).
- **Lớp Tích chập (Convolutional Layers):** Các lớp tích chập là các khối xây dựng cốt lõi của CNN. Chúng bao gồm nhiều bộ lọc (còn gọi là hạt nhân - kernel) trượt qua hình ảnh đầu vào để trích xuất các đặc trưng cục bộ.
- **Hàm Kích hoạt (Activation Function):** Một hàm kích hoạt phi tuyến, chẳng hạn như ReLU (Đơn vị Tuyến tính Chỉnh lưu), được áp dụng theo từng phần tử sau mỗi quá trình tích chập để thêm tính phi tuyến vào mô hình. ReLU chuyển đổi tất cả các giá trị âm thành không, hỗ trợ khả năng của mạng trong việc học các đặc trưng phức tạp, phân cấp.
- **Lớp Gộp (Pooling Layers):** Mục tiêu của lớp gộp là giảm chiều rộng và chiều cao của bản đồ đặc trưng (feature map) trong khi vẫn bảo toàn thông tin quan trọng. Trong một kỹ thuật gộp điển hình gọi là gộp cực đại (max pooling), giá trị tối đa trong một vùng cụ thể của bản đồ đặc trưng được giữ lại trong khi các giá trị còn lại bị loại bỏ.

- **Lớp Kết nối Đầy đủ (Fully Connected Layers):** Sau một số lớp tích chập và gộp, mạng thường kết thúc bằng một hoặc nhiều lớp kết nối đầy đủ. Các lớp này được kết nối dày đặc, nghĩa là mỗi nơ-ron trong một lớp được kết nối với mọi nơ-ron trong lớp tiếp theo. Các lớp kết nối đầy đủ học các đặc trưng cấp cao và các mối quan hệ giữa các đặc trưng được trích xuất bởi các lớp trước đó.
- **Lớp Đầu ra (Output Layer):** Lớp đầu ra của CNN phụ thuộc vào nhiệm vụ cụ thể. Đối với phân loại hình ảnh, lớp này thường bao gồm một nơ-ron cho mỗi lớp, theo sau là hàm kích hoạt SoftMax để chuyển đổi đầu ra của mạng thành xác suất của các lớp.
- **Dropout:** Dropout là một kỹ thuật chính quy hóa (regularization) thường được áp dụng cho các lớp kết nối đầy đủ để ngăn ngừa hiện tượng quá khớp (overfitting). Trong quá trình huấn luyện, một tập hợp con ngẫu nhiên các nơ-ron bị "loại bỏ" (dropped out), nghĩa là đầu ra của chúng được đặt thành không, điều này giúp ngăn ngừa sự đồng thích ứng (co-adaptation) của các nơ-ron.
- **Hàm Mất mát (Loss Function):** Lựa chọn hàm mất mát phụ thuộc vào vấn đề đang được giải quyết. Đối với các tác vụ phân loại, hàm mất mát cross-entropy thường được sử dụng, trong khi các tác vụ như hồi quy có thể sử dụng lỗi bình phương trung bình (mean squared error).
- **Lan truyền Ngược (Back Propagation) và Tối ưu hóa:** CNN được huấn luyện bằng cách sử dụng lan truyền ngược và các thuật toán tối ưu hóa như stochastic gradient descent (SGD) hoặc các biến thể của nó (ví dụ: Adam, RMSprop). Mạng cập nhật các trọng số và độ lệch (biases) của nó trong quá trình huấn luyện để giảm thiểu hàm mất mát đã chọn.

11.7 PHÂN TÍCH MÔ HÌNH

Hiểu được tóm tắt về mô hình của chúng tôi là rất quan trọng vì nó cung cấp những hiểu biết quan trọng về kiến trúc, các tham số, và hành vi của mô hình mà chúng tôi đã phát triển. Bằng cách phân tích tóm tắt mô hình, chúng tôi có được sự hiểu biết sâu sắc về cách dữ liệu chảy qua mạng, số lượng tham số có thể huấn luyện, và các lớp liên quan. Kiến thức này là cần thiết để khắc phục sự cố và tinh chỉnh hiệu suất của mô hình, chẩn đoán các vấn đề như quá khớp hoặc thiếu khớp (underfitting), và đưa ra các quyết định sáng suốt về các kỹ thuật tối ưu hóa. Ngoài ra, tóm tắt mô hình giúp ích trong giao tiếp và hợp tác trong nhóm hoặc khi chia sẻ kết quả nghiên cứu, đảm bảo rằng những người khác có thể sao chép, đánh giá, và xây dựng dựa trên công việc của chúng tôi một cách hiệu quả. Bảng 11.2 mô tả tóm tắt của mô hình.

BẢNG 11.2 Tóm tắt Mô hình CNN trên Tập dữ liệu Lá Khoai tây

Lớp (Loại)	Hình dạng Đầu ra	Số Tham số #
conv2d (Conv2D)	(None, 254, 254, 32)	896
max_pooling2d (MaxPooling2D)	(None, 127, 127, 32)	0
dropout (Dropout)	(None, 127, 127, 32)	0

Lớp (Loại)	Hình dạng Đầu ra	Số Tham số #
conv2d_1 (Conv2D)	(None, 127, 127, 64)	18496
max_pooling2d_1 (MaxPooling2D)	(None, 63, 63, 64)	0
dropout_1 (Dropout)	(None, 63, 63, 64)	0
conv2d_2 (Conv2D)	(None, 63, 63, 64)	36928
max_pooling2d_2 (MaxPooling2D)	(None, 31, 31, 64)	0
conv2d_3 (Conv2D)	(None, 31, 31, 64)	36928
max_pooling2d_3 (MaxPooling2D)	(None, 15, 15, 64)	0
conv2d_4 (Conv2D)	(None, 15, 15, 64)	36928
max_pooling2d_4 (MaxPooling2D)	(None, 7, 7, 64)	0
conv2d_5 (Conv2D)	(None, 7, 7, 64)	36928
max_pooling2d_5 (MaxPooling2D)	(None, 3, 3, 64)	0
flatten (Flatten)	(None, 576)	0
dense (Dense)	(None, 32)	18464
dense_1 (Dense)	(None, 3)	99
Tổng số tham số: 185,667 (725.26 KB)		
Tham số có thể huấn luyện: 185,667 (725.26 KB)		
Tham số không thể huấn luyện: 0 (0.00 Byte)		

- **Lớp Conv2D:** Mô hình bắt đầu với lớp Conv2D với 32 bộ lọc, tạo ra hình dạng đầu ra là (none, 254, 254, 32). Tiếp theo là ba lớp Conv2D nữa, mỗi lớp có 64 bộ lọc. Các lớp này dần dần làm giảm kích thước không gian.
- **Lớp Gộp Cực đại (Max-Pooling):** Các lớp gộp cực đại theo sau mỗi lớp tích chập, làm giảm một nửa kích thước không gian. Chúng giúp giảm lấy mẫu không gian (spatial downsampling) và giảm độ phức tạp tính toán.
- **Lớp Dropout:** Các lớp Dropout được sử dụng sau các lớp gộp cực đại. Chúng giúp ngăn ngừa quá khớp bằng cách loại bỏ ngẫu nhiên một phần các đơn vị đầu vào trong quá trình huấn luyện.
- **Lớp Làm phẳng (Flatten):** Sau lớp tích chập cuối cùng, có một lớp làm phẳng, giúp định hình lại tensor đầu ra 3D thành một vector 1D. Điều này là cần thiết để kết nối các lớp tích chập với các lớp dày đặc (dense layers).
- **Lớp Dày đặc (Dense Layers):** Hai lớp dày đặc theo sau lớp làm phẳng. Lớp dày đặc đầu tiên có 32 đơn vị, và lớp dày đặc thứ hai, đóng vai trò là lớp đầu ra, có 3 đơn vị, cho thấy đây là một tác vụ phân loại đa lớp.

- **Tổng số Tham số:** Mô hình có tổng cộng 185,667 tham số, tất cả đều có thể huấn luyện được. Số lượng tham số cho biết năng lực của mô hình trong việc học và biểu diễn các mẫu phức tạp trong dữ liệu.
- **Năng lực Mô hình:** Năng lực của mô hình có vẻ đủ cho một tập dữ liệu kích thước vừa phải với ba lớp đầu ra. 32 đơn vị trong lớp dày đặc đầu tiên cung cấp một mức độ phức tạp hợp lý.

Kiến trúc CNN này được sử dụng cho một tác vụ phân loại đa lớp với ba lớp. Nó có số lượng tham số hợp lý và bao gồm các thành phần thiết yếu như các lớp tích chập, các lớp gộp cực đại, dropout để chính quy hóa, và các lớp dày đặc để phân loại.

11.8 KẾT QUẢ VÀ THẢO LUẬN

Trong phần này, chúng tôi trình bày kết quả của nghiên cứu về phân loại bệnh lá khoai tây bằng CNN. Các kết quả của các thí nghiệm của chúng tôi không chỉ xác thực hiệu quả của phương pháp tiếp cận ML này mà còn làm sáng tỏ tiềm năng của nó trong việc cách mạng hóa lĩnh vực quản lý bệnh nông nghiệp. Thông qua thử nghiệm và phân tích nghiêm ngặt, chúng tôi đã phát hiện ra những hiểu biết có giá trị nhấn mạnh tầm quan trọng của nghiên cứu của chúng tôi trong việc tăng cường dự đoán năng suất cây trồng và, rộng hơn, trong việc giải quyết các thách thức quan trọng trong nông nghiệp.

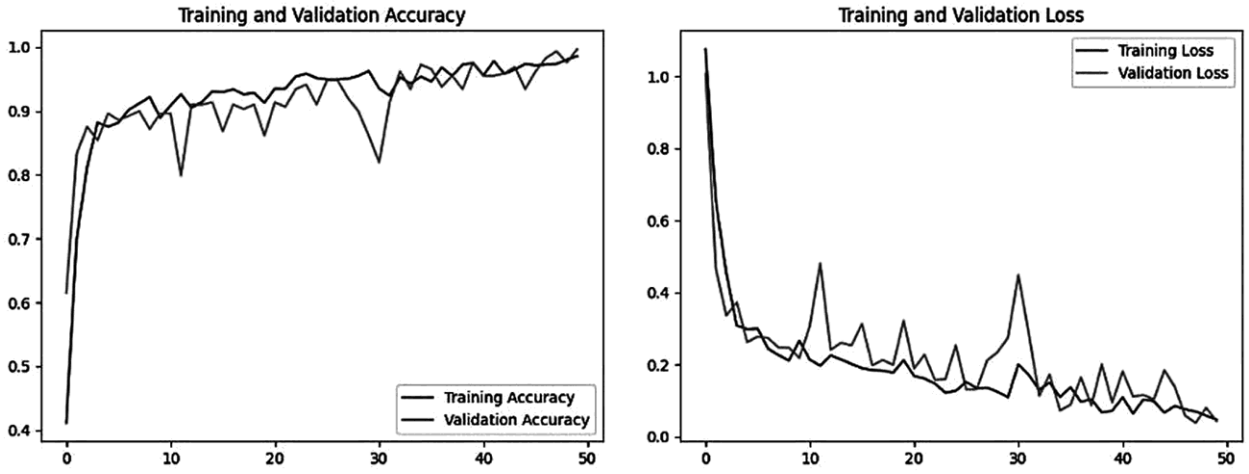
Tập dữ liệu được nghiên cứu bao gồm ba thư mục cho mỗi mục đích huấn luyện, thử nghiệm, và xác thực. Mỗi thư mục bao gồm hình ảnh lá khoai tây thuộc cả ba loại - cụ thể là, bệnh đốm vòng, bệnh mốc sương, và lá khỏe mạnh. Để huấn luyện, chúng tôi đã xem xét 300 hình ảnh của lá khoai tây bị bệnh đốm vòng, khỏe mạnh, và bị bệnh mốc sương. Một trăm hình ảnh để thử nghiệm và 100 để xác thực. Bảng 11.3 cho thấy độ mất mát và độ chính xác của mô hình.

BẢNG 11.3 Độ Mất mát và Độ Chính xác của Mô hình

Mất mát Huấn luyện	Độ chính xác Huấn luyện	Mất mát Xác thực	Độ chính xác Xác thực	Mất mát Thử nghiệm	Độ chính xác Thử nghiệm
0.0470	0.9856	0.0433	0.9965	0.0757	0.9741

Các đồ thị về độ chính xác và độ mất mát khi huấn luyện và xác thực, được mô tả trong

Hình 11.6, đóng vai trò là các biểu diễn trực quan quan trọng về hiệu suất của mô hình của chúng tôi trong suốt quá trình huấn luyện.



Hình 11.6 Đồ thị huấn luyện và xác thực. (Biểu đồ bên trái: "Độ chính xác Huấn luyện và Xác thực", cho thấy cả "Độ chính xác Huấn luyện" và "Độ chính xác Xác thực" đều tăng lên và hội tụ gần mức 1.0 sau 50 epoch. Biểu đồ bên phải: "Độ mất mát Huấn luyện và Xác thực", cho thấy cả "Độ mất mát Huấn luyện" và "Độ mất mát Xác thực" đều giảm nhanh và hội tụ gần mức 0.0 sau 50 epoch.)

Độ chính xác huấn luyện, 0.9856, đại diện cho tỷ lệ phần trăm các trường hợp được phân loại chính xác trong tập dữ liệu huấn luyện khi mô hình học và thích ứng. Đồng thời, độ mất mát huấn luyện, 0.0470, biểu thị mức độ sai sót của mô hình trong quá trình huấn luyện. Các giá trị thấp hơn có nghĩa là các dự đoán của mô hình phù hợp hơn với các nhãn thực tế (ground truth).

Về phía xác thực, chúng ta thấy các xu hướng tương tự. Độ chính xác xác thực, 0.9965, cho thấy mô hình của chúng tôi tổng quát hóa tốt như thế nào đối với dữ liệu chưa từng thấy, cụ thể là tập dữ liệu xác thực. Song song đó, độ mất mát xác thực, 0.0433, phản ánh hiệu suất của mô hình trên tập dữ liệu riêng biệt này. Giống như độ mất mát huấn luyện, chúng tôi mong muốn giá trị này giảm trong quá trình huấn luyện, cho thấy mô hình không bị quá khớp với dữ liệu huấn luyện mà đang học cách đưa ra các dự đoán chính xác hơn trên dữ liệu mới, chưa từng thấy trước đây.

Các kết quả thử nghiệm được cung cấp, bao gồm độ mất mát thử nghiệm là 0.0757 và độ chính xác thử nghiệm là khoảng 97.42%, cung cấp những hiểu biết có giá trị về hiệu suất của mô hình CNN.

1. **Độ mất mát Thử nghiệm (0.0757):** Độ mất mát thử nghiệm là một chỉ số quan trọng để đánh giá độ chính xác dự đoán của mô hình. Trong trường hợp này, độ mất mát thử nghiệm đặc biệt thấp, cho thấy các dự đoán của mô hình rất gần với các giá trị thực tế trong tập dữ liệu thử nghiệm. Độ mất mát thử nghiệm thấp cho thấy mô hình đã học hiệu quả các mẫu và đặc trưng cơ bản trong dữ liệu, cho phép nó đưa ra các dự đoán chính xác.
2. **Độ chính xác Thử nghiệm (97.42%):** Độ chính xác thử nghiệm đo lường tỷ lệ các ví dụ được phân loại chính xác trong tập dữ liệu thử nghiệm. Với độ chính xác

khoảng 97.42%, mô hình đang hoạt động đặc biệt tốt. Tỷ lệ chính xác trên 97% cho thấy mô hình rất phù hợp với tác vụ phân loại hiện tại.

3. **Khả năng Tổng quát hóa của Mô hình:** Độ chính xác thử nghiệm ấn tượng và độ mất mát thử nghiệm thấp phản ánh khả năng tổng quát hóa mạnh mẽ của mô hình. Nó không bị quá khớp với dữ liệu huấn luyện, vì nó có thể đưa ra các dự đoán chính xác trên các mẫu mới, chưa từng thấy.
4. **Độ tin cậy của Mô hình:** Độ chính xác thử nghiệm cao và độ mất mát thử nghiệm thấp cho thấy mô hình đáng tin cậy và nhất quán trong các dự đoán của nó.

Các kết quả thử nghiệm của mô hình, với độ mất mát thử nghiệm là 0.0757 và độ chính xác thử nghiệm là khoảng 97.42%, chứng minh rằng mô hình đã học và tổng quát hóa thành công các mẫu từ dữ liệu huấn luyện. Những kết quả này cho thấy mô hình rất phù hợp với tác vụ phân loại mà nó được thiết kế.

11.9 KẾT LUẬN

Tóm lại, nghiên cứu này đã chứng minh tính hiệu quả của CNN trong việc phân loại bệnh lá khoai tây, đạt được kết quả đáng kể với độ mất mát thử nghiệm là 0.0757 và độ chính xác thử nghiệm là 0.9741. Những phát hiện này nhấn mạnh tiềm năng của các kỹ thuật ML trong các ứng dụng nông nghiệp, cụ thể là trong việc phát hiện và quản lý sớm các bệnh thực vật. Bằng cách khai thác sức mạnh của CNN, chúng tôi đã mở đường cho việc xác định các bệnh lá khoai tây chính xác và kịp thời hơn, cho phép nông dân thực hiện các biện pháp chủ động để bảo vệ cây trồng và tối ưu hóa năng suất. Nghiên cứu này không chỉ góp phần vào lĩnh vực nông nghiệp chính xác mà còn hứa hẹn giải quyết các thách thức an ninh lương thực toàn cầu bằng cách cải thiện việc giám sát và quản lý sức khỏe cây trồng. Khi công nghệ tiếp tục phát triển, những tiến bộ hơn nữa trong ML có thể dẫn đến các công cụ mạnh mẽ hơn nữa cho tính bền vững và năng suất nông nghiệp.

TÀI LIỆU THAM KHẢO

[1] Liakos, Konstantinos G., và cộng sự. “Học máy trong nông nghiệp: Một bài đánh giá.” Sensors 18.8 (2018): 2674.

[2] Jain, Ashriti, và cộng sự. “Ngập lụt nông nghiệp (Agro-inundation) để tối đa hóa năng suất cây trồng và hiệu quả sử dụng nước.” SSGM Journal of Science and Engineering 1.1 (2023): 10-14.

[3] Shelestov, Andrii, và cộng sự. “Khám phá nền tảng Google Earth Engine để xử lý dữ liệu lớn: Phân loại hình ảnh vệ tinh đa thời gian để lập bản đồ cây trồng.” Frontiers in Earth Science 5 (2017): 17.

[4] Ushadevi, G. “Một khảo sát về dự đoán bệnh thực vật bằng kỹ thuật học máy và học sâu.” Inteligencia Artificial 23.65 (2020): 136-154.

[5] Patel, Bharati, và Aakanksha Sharaff. “Dự đoán bệnh cây lúa bằng kỹ thuật học máy.” International Journal of Agricultural and Environmental Information Systems (IJAEIS) 12.4 (2021): 1-15.

[6] Lischeid, Gunnar, và cộng sự. “Học máy trong lập mô hình năng suất cây trồng: Một công cụ mạnh mẽ, nhưng không thể thay thế cho khoa học.” Agricultural and Forest Meteorology 312 (2022): 108698.

[7] Bali, Nishu, và Anshu Singla. “Các xu hướng mới nổi trong học máy để dự đoán năng suất cây trồng và nghiên cứu các yếu tố ảnh hưởng của nó: Một khảo sát.” Archives of Computational Methods in Engineering 29 (2022): 1-18.

[8] Crane-Droesch, Andrew. “Các phương pháp học máy để dự đoán năng suất cây trồng và đánh giá tác động của biến đổi khí hậu trong nông nghiệp.” Environmental Research Letters 13.11 (2018): 114003.

[9] Reddy, D. Jayanarayana, và M. Rudra Kumar. “Dự đoán năng suất cây trồng bằng thuật toán học máy.” 2021 5th International Conference on Intelligent Computing and Control Systems (ICICCS). IEEE, 2021.

[10] Alzubi, Jafar, Anand Nayyar, và Akshi Kumar. “Học máy từ lý thuyết đến thuật toán: Một cái nhìn tổng quan.” Journal of physics: Conference Series. Tập 1142. IOP Publishing, 2018.

[11] Kaur, Sunpreet, và Sonika Jindal. “Một khảo sát về các thuật toán học máy.” International Journal of Innovative Research in Advanced Engineering (IJIRAE) 3.11 (2016): 2349-2763.

[12] Das, Kajaree, và Rabi Narayan Behera. “Một khảo sát về học máy: Khái niệm, thuật toán và ứng dụng.” International Journal of Innovative Research in Computer and Communication Engineering 5.2 (2017): 1301-1309.

[13] Mahesh, Batta. “Các thuật toán học máy - Một bài đánh giá. International Journal of Science and Research (IJSR) 9.1 (2020): 381-386.

[14] Li, Zewen, và cộng sự.”Một khảo sát về mạng nơ-ron tích chập: Phân tích, ứng dụng và triển vọng.” IEEE Transactions on Neural Networks and Learning Systems 33 (2021): 1-21.

[15] O’Shea, Keiron, và Ryan Nash. “Giới thiệu về mạng nơ-ron tích chập.” arXiv preprint arXiv:1511.08458 (2015).

[16] Albawi, Saad, Tareq Abed Mohammed, và Saad Al-Zawi. “Tìm hiểu về mạng nơ-ron tích chập.” 2017 International Conference on Engineering and Technology (ICET). IEEE, 2017.

CHƯƠNG 12: PHÂN LOẠI CÁC TRANG TRẠI ĐỂ KHUYẾN NGHỊ TRỒNG LÚA SỬ DỤNG NAIVE BAYES VÀ SVM: MỘT NGHIÊN CỨU ĐIỂN HÌNH

Qurat-ul-ain, Uzma Hameed, và Hamira Mehraj Trường Cao đẳng Nữ, Đại học Cluster, Srinagar, Ấn Độ

12.1 GIỚI THIỆU

Dân số thế giới hiện tại khoảng 7,6 tỷ người, và ước tính sẽ đạt khoảng 9,8 tỷ người vào cuối năm 2050. Do đó, nhu cầu lương thực chắc chắn sẽ tăng lên, nhưng ngược lại, đất nông nghiệp đang giảm sút nghiêm trọng mỗi ngày do quản lý yếu kém trong canh tác, quy hoạch không hợp lý, điều kiện thời tiết không thể đoán trước, và quá trình đô thị hóa. Trong thời đại ngày nay, nông nghiệp chính xác đã trở nên vô cùng phổ biến trong ngành nông nghiệp với những kết quả lạc quan, và nó đã giúp ích rất nhiều trong các lĩnh vực khác nhau của nông nghiệp như tưới tiêu không đều, phát hiện bệnh cây trồng, đếm cây, khuyến nghị cây trồng, ước tính năng suất, thu hoạch chọn lọc, kiểm soát sâu bệnh, và phát hiện cỏ dại, cũng như nhiều lĩnh vực khác của nông nghiệp.

Nông nghiệp chính xác là một chiến lược quản lý thu thập, xử lý và phân tích dữ liệu thời gian, không gian và cá nhân, đồng thời kết hợp nó với thông tin khác để hỗ trợ các quyết định quản lý theo sự biến đổi ước tính nhằm cải thiện hiệu quả sử dụng tài nguyên, năng suất, chất lượng, lợi nhuận và tính bền vững của sản xuất nông nghiệp. Để hiểu rõ hơn về dữ liệu được truy xuất từ nông nghiệp chính xác, các kỹ thuật học máy (ML) rất được khuyến khích và sử dụng trong lĩnh vực này. Với việc triển khai các công cụ ML, chúng ta có thể tối ưu hóa quy trình và giảm sai sót trong dữ liệu, các dự đoán trở nên dễ dàng hơn, và việc diễn giải dữ liệu hình ảnh trở nên nhanh chóng và đơn giản. “Học máy là một nhánh của khoa học máy tính, nói rộng ra là nhằm mục đích cho phép máy tính ‘học’ mà không cần được lập trình trực tiếp”.

“Một cỗ máy hoặc một chương trình máy tính thông minh học và trích xuất kiến thức từ dữ liệu; kiến thức được trích xuất sau đó xây dựng một khuôn khổ giúp đưa ra các dự đoán hoặc quyết định thông minh. Do đó, quy trình ML được chia thành ba phần chính - tức là, nhập dữ liệu, xây dựng mô hình, và tổng quát hóa”. “Tổng quát hóa là quá trình dự đoán đầu ra cho các đầu vào mà thuật toán chưa được huấn luyện trước đó”. Các thuật toán ML có thể được sử dụng để xây dựng mô hình phân loại nhằm phát hiện chất lượng đất để canh tác cây trồng phù hợp. Trong chương này, chúng ta sẽ tìm hiểu một chủ đề tương tự như một nghiên cứu điển hình. Để triển khai một mô hình dự đoán, chúng ta hãy lấy một tập dữ liệu gồm 2.200 mẫu và sửa đổi nó theo việc trồng lúa và triển khai hai mô hình dự đoán ML - tức là, Naive Bayes và máy vector hỗ trợ (SVM) để dự đoán trang trại trồng lúa. Chúng ta cũng sẽ thực hiện một nghiên cứu so sánh hai mô hình này dựa trên các thước đo độ chính xác khác nhau.

12.2 TỔNG QUAN TÀI LIỆU

Lúa, như chúng ta đã biết, là một trong những cây trồng được tiêu thụ nhiều nhất trên toàn cầu. Nông dân phải đối mặt với rất nhiều khó khăn khi đưa ra quyết định để đạt được năng suất và cây trồng bền vững trong điều kiện khí hậu thay đổi. "Các kỹ thuật Học máy có thể được sử dụng để cải thiện dự đoán năng suất cây trồng dưới các điều kiện khí hậu khác nhau". Một số lượng lớn các nhà nghiên cứu đã áp dụng các thuật toán ML để phát hiện bệnh lúa. Jian và Wei đã áp dụng SVM để nhận dạng bệnh trên lá dưa chuột. Kết quả của họ đã cho thấy phương pháp SVM dựa trên hàm nhân (kernel) radial basis function (RBF) cho hiệu suất tốt nhất để phân loại bệnh của dưa chuột so với các hàm nhân đa thức và sigmoid. Sethy, Barpanda, Rath, và Behera đã làm việc về phát hiện bệnh lá lúa dựa trên đặc trưng sâu (deep feature) bằng CNN và SVM.

Gandhi, Petkar, và Armstrong đã sử dụng mạng nơ-ron để dự đoán năng suất sản xuất lúa và để điều tra các yếu tố ảnh hưởng đến "năng suất lúa cho các quận khác nhau của bang Maharashtra ở Ấn Độ". Các thông số được các nhà nghiên cứu này xem xét khi thực hiện nghiên cứu của họ là "lượng mưa, nhiệt độ tối thiểu, nhiệt độ trung bình, nhiệt độ tối đa và lượng bốc hơi nước tham chiếu của cây trồng (reference crop evapotranspiration), diện tích, sản lượng và năng suất cho vụ Kharif (tháng 6 đến tháng 11) trong các năm từ 1998 đến 2002." Singha và cộng sự đã sử dụng "kỹ thuật trí tuệ nhân tạo (AI) cho mô hình dự đoán năng suất lúa và khoai tây ở khu vực Tarakeswar, Quận Hooghly, Tây Bengal." Các biến được sử dụng chủ yếu trong nghiên cứu là "các yếu tố khí hậu, các thông số đất tĩnh, dinh dưỡng có sẵn trong đất, các thông số thực hành nông nghiệp, cơ giới hóa nông nghiệp, phân bố địa hình và các điều kiện kinh tế-xã hội." Họ đã sử dụng "mạng nơ-ron nhân tạo, Máy vector hỗ trợ và Mạng nơ-ron sâu" trong nghiên cứu của mình.

Nghiên cứu của Hasan và cộng sự đã giới thiệu một kiến trúc CNN mới có kích thước tương đối nhỏ và hiệu suất khá hứa hẹn để dự đoán bệnh lá lúa với độ chính xác vừa phải và độ phức tạp thời gian thấp hơn. Patil và Kumar đã đề xuất một khung hợp nhất dữ liệu đa phương thức (multimodality data fusion framework) để phát hiện bệnh lúa.

Khung Rice-Fusion ban đầu trích xuất các đặc trưng số từ dữ liệu khí tượng nông nghiệp (agro-meteorological) thu thập từ các cảm biến. Tiếp theo, nó trích xuất các đặc trưng trực quan từ hình ảnh lúa được chụp. Các đặc trưng được trích xuất này sau đó được hợp nhất bằng cách sử dụng một lớp ghép nối (concatenation layer) theo sau là một lớp dày đặc (dense layer), cung cấp đầu ra duy nhất để chẩn đoán bệnh lúa.

Kumar, Singh, Kumar, và P. Singh đã đề xuất một phương pháp có tên là Phương pháp Chọn Cây trồng (CSM) để giải quyết vấn đề lựa chọn cây trồng và tối đa hóa tỷ lệ năng suất ròng của cây trồng qua một mùa vụ và sau đó đạt được tăng trưởng kinh tế tối đa cho đất nước. Son và cộng sự đã phát triển một phương pháp ML để dự đoán năng suất lúa ở Đài Loan bằng cách sử dụng dữ liệu Chuỗi thời gian của Máy đo phổ hình ảnh độ phân giải trung bình (MODIS). Rừng ngẫu nhiên (RF) và SVM đã được sử dụng để xây dựng các mô hình dự đoán.

12.3 PHƯƠNG PHÁP LUẬN

Tập dữ liệu được sử dụng cho nghiên cứu đã được xử lý bằng công cụ WEKA. "WEKA (Môi trường Waikato để Phân tích Kiến thức) , là công cụ khai thác dữ liệu mã nguồn mở và miễn phí, có sẵn theo Giấy phép Công cộng GNU." Công cụ này được phát triển tại Đại học Waikato, New Zealand, và được triển khai lần đầu tiên ở dạng hiện đại vào năm 1997. Ngoài định dạng tệp dữ liệu arff, công cụ WEKA cũng hỗ trợ định dạng tệp dữ liệu .csv, giúp thuận tiện cho việc xuất dữ liệu sang các ứng dụng bảng tính khác nhau. Chúng tôi đã sử dụng WEKA phiên bản 3.8.6 để thực hiện các thí nghiệm cho mục đích giải thích.

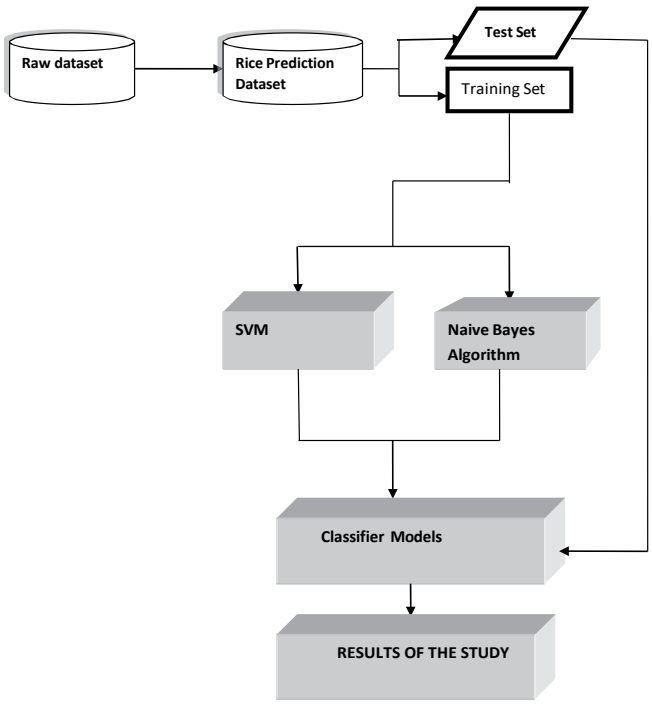
Tập dữ liệu đã được sử dụng làm đầu vào cho các bộ phân loại có sẵn trên kho lưu trữ Kaggle. Tên của tập dữ liệu này là tập dữ liệu "khuyến nghị cây trồng". Đây là một tập dữ liệu đa biến với 2.200 mẫu và kích thước của nó là 65 KB. Tổng số thuộc tính trong tập dữ liệu này là tám, bao gồm cả thuộc tính nhãn mục tiêu. Tập dữ liệu này được phân loại cho các loại cây trồng khác nhau, nhưng chúng tôi đã chuyển đổi thuộc tính nhãn của tập dữ liệu thành có/không (yes/no) theo các khuyến nghị trồng lúa. Các thuộc tính được chọn của tập dữ liệu đang nghiên cứu được định nghĩa trong Bảng 12.1.

BẢNG 12.1: Mô tả các Thuộc tính

STT.	Thuộc tính được sử dụng trong Tập dữ liệu	Loại Thuộc tính	Mô tả
1	N	Số	Tỷ lệ hàm lượng nitơ trong đất
2	P	Số	Tỷ lệ hàm lượng phốt pho trong đất
3	K	Số	Tỷ lệ hàm lượng kali trong đất
4	Temperature	Số	Nhiệt độ tính bằng độ C
5	Humidity	Số	Độ ẩm tương đối tính bằng phần trăm
6	Ph	Số	Giá trị Ph của đất
7	Rainfall	Số	Lượng mưa tính bằng mm
8	Label	Chuỗi	Có/Không

12.3.1 Quy trình làm việc

Tập dữ liệu đầu vào được xử lý bằng hai bộ phân loại ML - Naive Bayes và SVM. Các bộ phân loại này được huấn luyện và kiểm tra độ chính xác bằng cùng một tập dữ liệu. Dựa trên các kết quả thí nghiệm thu thập được, thuật toán hoạt động tốt nhất sẽ được xác định, giúp dự đoán cây lúa để trồng trên một trang trại cụ thể dựa trên các thông số được mô tả trong Hình 12.1.



HÌNH 12.1 Lưu đồ của phương pháp đề xuất. “Raw dataset” flows to “Rice Prediction Dataset”. This splits into “Test Set” and “Training Set”. The “Training Set” flows to both “SVM” and “Naive Bayes Algorithm”. Both “SVM” and “Naive Bayes Algorithm” flow to “Classifier Models”. The “Test Set” also flows to “Classifier Models”. Finally, “Classifier Models” flows to “RESULTS OF THE STUDY”.]

12.3.2 Thủ tục

Quy trình sau đây đã được tuân thủ khi xây dựng các bộ phân loại và tính toán độ chính xác của các thuật toán bằng công cụ WEKA.

1. Công cụ chọn WEKA GUI cho phép linh hoạt lựa chọn giữa Simple CLI, Knowledge Explorer, Experimenter, và Explorer CUI. Thí nghiệm được thực hiện bằng giao diện WEKA Explorer.
2. Tải tập dữ liệu đầu vào về khuyến nghị trồng lúa trong công cụ WEKA.
3. Chọn thuật toán ML là Naive Bayes hoặc SVM Tối ưu hóa Tối thiểu Tuần tự (SMO).
4. Kiểm tra chéo (Cross-validation) đã được chọn làm tùy chọn kiểm tra, được đặt mặc định là 10 lần (ten folds).
5. Kiểm tra mô hình phân loại cho thuật toán đã chọn.
6. Thực hiện so sánh các kết quả thu được từ các thuật toán.

12.4 GIẢI THÍCH VỀ CÁC BỘ PHÂN LOẠI

12.4.1 Naive Bayes

Naive Bayes là một bộ phân loại học có giám sát hoạt động dựa trên nguyên tắc xác suất có điều kiện. Với nhiều đầu vào $(x1, x2, x3, x4 \ldots xn)$, lớp kết quả (Y) sử dụng phương trình Naive Bayes có thể được tính là:

$$P(Y = K \mid X_1 \ldots . X_n) = \frac{\left(\begin{array}{l} P(X_1 \mid Y = K) * P(X_2 \mid Y = K) * P(X_3 \mid Y = K) \\ * \ldots * P(X_n \mid Y = K) * P\left(Y = K\right) \end{array} \right)}{\left(P\left(X_1\right) * P\left(X_2\right) * P\left(X_3\right) \ldots P\left(X_n\right)\right)}. \qquad (12.1)$$

Trong tập dữ liệu đang nghiên cứu, bộ phân loại Naive Bayes (12.1) được áp dụng cho các thuộc tính sau:

$X = (N, P, K$, Temperature, Humidity, Ph, rainfall) và lớp kết quả Y được phân loại là $Y =$ (Yes, No).

Có nhiều loại ma trận đánh giá khác nhau trong ML (ví dụ: "Độ chính xác Phân loại, Mất mát Logarit, Ma trận Nhầm lẫn, Diện tích dưới Đường cong, Điểm F1, Lỗi Tuyệt đối Trung bình, và Lỗi Bình phương Trung bình"). Trong nghiên cứu điển hình này, chúng tôi đã xem xét các thước đo đánh giá Ma trận Nhầm lẫn, Độ chính xác Phân loại, và Diện tích dưới Đường cong (AUC) để thực hiện phân tích so sánh các thuật toán.

12.4.1.1 Ma trận Nhầm lẫn Naive Bayes

Bảng 12.2 cho thấy Ma trận Nhầm lẫn thu được bằng cách sử dụng bộ phân loại Naive Bayes.

Do đó, theo bộ phân loại này, các giá trị là **Dương tính Thật = 100**, **Âm tính Sai = 0**, **Dương tính Sai = 43**, và **Âm tính Thật = 2057**.

BẢNG 12.2: Ma trận Nhầm lẫn Thu được bằng cách sử dụng Naive Bayes

		Lớp Dự đoán	
Lớp Thực tế		**Dương tính**	**Âm tính**
	Dương tính	100	0
	Âm tính	43	2057

12.4.2 Máy Vector Hỗ trợ (Support Vector Machines - SVM)

SVM là một thuật toán học có giám sát, thường được sử dụng cho các bài toán dựa trên phân loại và hồi quy. Khái niệm chính của SVM, ban đầu được phát triển để giải quyết các vấn đề liên quan đến phân loại nhị phân, là sử dụng các siêu phẳng (hyperplanes) để

xác định ranh giới quyết định giữa các điểm dữ liệu thuộc các lớp khác nhau. SVM có thể xử lý cả các tác vụ phân loại đơn giản và tuyến tính, đồng thời cũng có thể giúp xử lý các bài toán phân loại phức tạp hơn - tức là, phi tuyến. Cả hai bài toán có thể phân tách (separable) và không thể phân tách (nonseparable) đều có thể được xử lý tốt bởi SVM trong các trường hợp tuyến tính và phi tuyến. Ý tưởng đằng sau SVM là ánh xạ các điểm dữ liệu gốc từ không gian đầu vào sang một không gian đặc trưng có số chiều cao, hoặc thậm chí vô hạn, sao cho bài toán phân loại trở nên đơn giản hơn trong không gian đặc trưng. Việc ánh xạ được thực hiện bằng một lựa chọn phù hợp của hàm nhân (kernel function). Trong WEKA, chúng tôi đã sử dụng thuật toán SMO để huấn luyện một bộ phân loại vector hỗ trợ bằng cách sử dụng nhân tuyến tính (linear kernel) trên tập dữ liệu đã cho để xây dựng mô hình phân loại.

$K(x, y) =< x, y >$ và bộ phân loại cho lớp Đúng, Sai

12.4.2.1 Ma trận Nhầm lẫn Vector Hỗ trợ

Bảng 12.3 cho thấy Ma trận Nhầm lẫn thu được bằng cách sử dụng bộ phân loại vector hỗ trợ. Do đó, theo bộ phân loại này, các giá trị là **Dương tính Thật = 64**, **Âm tính Sai = 36**, **Dương tính Sai = 3**, và **Âm tính Thật = 2097**

BẢNG 12.3: Ma trận Nhầm lẫn Thu được bằng cách sử dụng SVM

		Lớp Dự đoán	
Lớp Thực tế		**Dương tính**	**Âm tính**
	Dương tính	64	36
	Âm tính	3	2097

BẢNG 12.4: Kết quả Độ chính xác cho các Bộ phân loại

Thuật toán	Thời gian Xây dựng Mô hình (giây)	Giá trị Độ chính xác (%)
Naive Bayes	0.01	98.0455
SVM sử dụng công cụ WEKA	0.11	98.2273

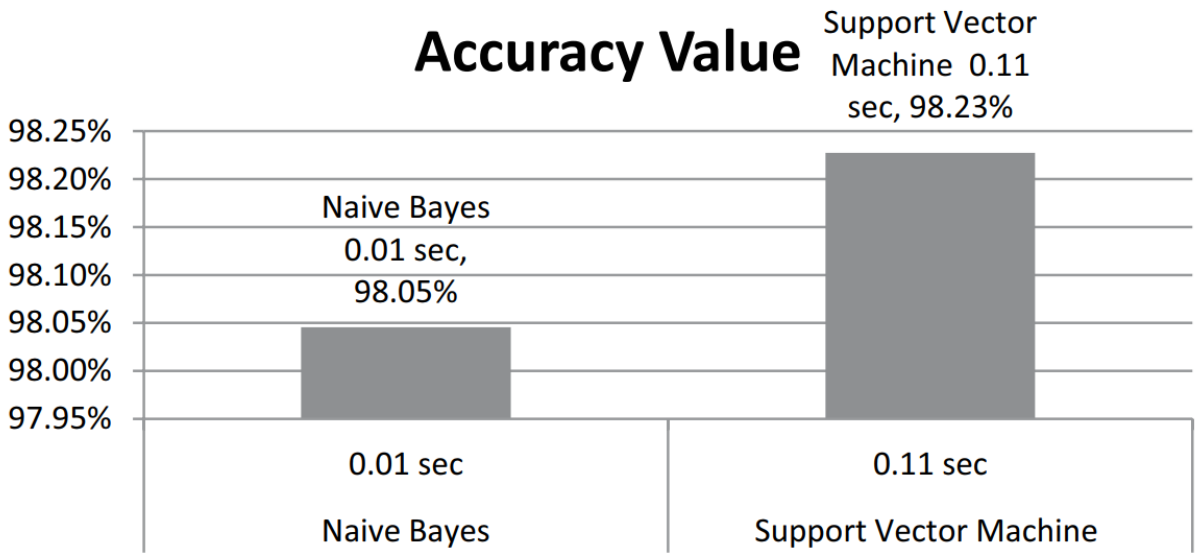
12.5 ĐỘ CHÍNH XÁC (ACCURACY)

Độ chính xác (Accuracy) là một ma trận đánh giá hiệu suất khác cho các mô hình phân loại (Bảng 12.4). Nó được tính bằng tổng số mẫu được dự đoán đúng chia cho tổng số mẫu có trong tập dữ liệu.

$$\text{Độ chính xác} = (TP + TN)/(TP + TN + FP + FN), \quad (12.2)$$

trong đó ở (12.2) TP = Dương tính Thật, TN = Âm tính Thật, FP = Dương tính Sai, FN = Âm tính Sai.

Hình 12.2 mô tả đồ họa các kết quả độ chính xác cho các bộ phân loại, trong đó hiển thị thời gian xây dựng mô hình và các giá trị độ chính xác.



HÌNH 12.2 Biểu diễn đồ họa của kết quả độ chính xác. The Naive Bayes bar shows "0.01 sec, 98.05%". The Support Vector Machine bar is higher, showing "0.11 sec, 98.23%". The Y-axis represents "Accuracy Value" ranging from 97.95% to 98.25%.]

12.6 DIỆN TÍCH DƯỚI ĐƯỜNG CONG (AREA UNDER CURVE - AUC)

AUC (Diện tích dưới Đường cong) là một cách khác để đo lường hiệu suất của mô hình ML. AUC càng cao, hiệu suất của mô hình trong việc phân biệt giữa các lớp dương tính và âm tính càng tốt. Sau đây là các giá trị đo lường độ chính xác của bộ phân loại:

I. Tỷ lệ Dương tính Thật (True-Positive Rate): Nó mô tả phần nào của lớp dương tính được phân loại chính xác. Nó được tính là:

$$\text{TruePostive} - \text{Rate} = \frac{TruePosive}{(TruePositive + FalseNegative)} \quad (12.3)$$

II. Tỷ lệ Dương tính Sai (False-Positive Rate): Nó mô tả phần nào của dữ liệu được phân loại là bất thường, mà thực sự là bình thường.

FalsePositive - Rate = FalsePositive / (FalsePositive + TrueNegative) (12.4)

III. Độ chuẩn xác (Precision): Nó mô tả số lượng dự đoán dương tính chính xác được thực hiện. Nó được tính là:

$$\text{Precision} = \frac{TruePositive}{(TruePositive + FalsePositive)} \quad (12.5)$$

IV. Độ phủ (Recall): Nó mô tả số lượng dự đoán dương tính chính xác được thực hiện trong tất cả các dự đoán dương tính có thể đã được thực hiện. Nó được tính là:

$$\text{Recall} = \frac{TruePositive}{(TruePositive+FalseNegative)} \quad (12.6)$$

V. Chỉ số F (F-Measure): Nó mô tả hiệu suất tổng thể của bộ phân loại. Nó được tính là:

F-Measure = 2* (Precision * Recall) / (Precision + Recall). (12.7)

BẢNG 12.5: Các chỉ số AUC của các Thuật toán

Thuật toán	Tỷ lệ TP	Tỷ lệ FP	Độ chuẩn xác	Độ phủ	Chỉ số F
Naive Bayes	0.980	0.001	0.986	0.980	0.982
SVM	0.982	0.344	0.982	0.982	0.981

Bảng 12.5 trình bày các chỉ số AUC (12.3)-(12.7) của các thuật toán này thu được sau khi xây dựng các bộ phân loại trên tập dữ liệu trong công cụ WEKA.

12.7 KẾT LUẬN

Trong chương này, một mô hình dự đoán dựa trên các bộ phân loại Naive Bayes và SVM đã được sử dụng để dự đoán liệu một trang trại cụ thể có thể được khuyến nghị để trồng lúa hay không. Tập dữ liệu được sử dụng để thực hiện nghiên cứu dự đoán các trang trại được lấy từ kho lưu trữ Kaggle, chứa các thuộc tính khác nhau về đất và hành vi môi trường. Các bộ phân loại Naive Bayes và SVM đã được xây dựng bằng công cụ WEKA. Do đó, các bộ phân loại này đã được so sánh dựa trên các thước đo độ chính xác khác nhau để kiểm tra hiệu suất bằng cách sử dụng cùng một tập dữ liệu trên hai mô hình khác nhau. Nghiên cứu đã dẫn đến kết luận rằng Tỷ lệ TP (TP Ratify Rate) và Độ phủ (Recall) của SVM cao hơn so với Naive Bayes. Tuy nhiên, độ chuẩn xác (precision) và chỉ số F (F-measure) của Naive Bayes cao hơn so với SVM. Giá trị độ chính xác của SVM là 98.2273%, cao hơn một chút so với bộ phân loại Naive Bayes. Tuy nhiên, thời gian xây dựng mô hình trong Naive Bayes là 0.01 giây, ít hơn so với thời gian sử dụng SVM. Vì chúng ta nên quan tâm chủ yếu đến độ chính xác của mô hình hơn là thời gian xây dựng mô hình, SVM là lựa chọn tốt nhất được thiết lập bởi nghiên cứu so sánh hiện tại. Trong tương lai, chúng ta có thể so sánh các mô hình dự đoán khác như hồi quy logistic, cây quyết định hỗ trợ, rừng ngẫu nhiên, và mạng nơ-ron với SVM để thiết lập các mô hình dự đoán tốt hơn cho tập dữ liệu hiện tại. Hơn nữa, bộ thuộc tính cũng có thể được tăng cường dựa trên các yếu tố môi trường khác nhau để thiết lập kết quả chính xác hơn, để chúng ta có thể chọn đúng trang trại để trồng lúa.

TÀI LIỆU THAM KHẢO

[1] A. Sharma, A. Jain, P. Gupta, và V. Chowdary, "Ứng dụng Học máy cho Nông nghiệp Chính xác: Một Đánh giá Toàn diện," IEEE Access, tập 9, trang 4843-4873, tháng 1 năm 2021. doi: 10.1109/access.2020.3048415

[2] Hiệp hội Nông nghiệp Chính xác Quốc tế, "Định nghĩa Nông nghiệp Chính xác (Precision AG) Hiệp hội Nông nghiệp Chính xác Quốc tế." https://www.ispag.org/about/definition

[3] A. L. Samuel, "Một số Nghiên cứu về Học máy Sử dụng Trò chơi Cờ đam," Tạp chí Nghiên cứu và Phát triển của IBM, tập 3, số 3, trang 210-229, tháng 7 năm 1959. doi: 10.1147/rd.33.0210

[4] N. Gandhi, L. J. Armstrong, O. Petkar, và A. K. Tripathy, "Dự đoán Năng suất Lúa ở Ấn Độ Sử dụng Máy Vector Hỗ trợ," trong 2016 13th International Joint Conference on Computer Science and Software Engineering (JCSSE), KhonKaen, Thái Lan, 2016, trang 1-5. doi:10.1109/JCSSE.2016.7748856

[5] Z. Jian và Z. Wei, "Máy Vector Hỗ trợ để Nhận dạng Bệnh lá Dưa chuột," trong 2010 2nd International Conference on Advanced Computer Control, Thẩm Dương, 2010, trang 264-266. doi: 10.1109/ICACC.2010.5487242

[6] P. K. Sethy, N. K. Barpanda, A. K. Rath, và S. K. Behera, "Nhận dạng Bệnh lá Lúa dựa trên Đặc trưng Sâu Sử dụng Máy Vector Hỗ trợ," Computers and Electronics in Agriculture, tập 175, trang 105527, tháng 8 năm 2020. doi: 10.1016/j.compag.2020.105527

[7] N. Gandhi, O. Petkar, và L. Armstrong, "Dự đoán Năng suất Lúa Sử dụng Mạng Nơ-ron Nhân tạo," trong 2016 IEEE Technological Innovations in ICT for Agriculture and Rural Development (TIAR), Chennai, Ấn Độ, 2016, trang 105-110. doi: 10.1109/tiar.2016.7801222

[8] C. Singha và K. C. Swain, "Dự đoán Năng suất Lúa và Khoai tây Sử dụng Kỹ thuật Trí tuệ Nhân tạo," trong Studies in Big Data, 2021, trang 185-199. doi: 10.1007/978-981-16-6210-2_9

[9] M. M. Hasan và cộng sự, "Nâng cao Quản lý Cây lúa: Phân loại Bệnh bằng Mạng Nơ-ron Tích chập và Tích hợp Ứng dụng Di động," Agriculture, tập 13, số 8, trang 1549, tháng 8 năm 2023. doi: 10.3390/agriculture13081549

[10] R. R. Patil và S. Kumar, "Rice-Fusion: Một Khung Hợp nhất Dữ liệu Đa phương thức để Chẩn đoán Bệnh lúa," IEEE Access, tập 10, trang 5207-5222, tháng 1 năm 2022. doi: 10.1109/access.2022.3140815

[11] R. Kumar, M. P. Singh, P. Kumar và J. P. Singh, "Phương pháp Lựa chọn Cây trồng để Tối đa hóa Tỷ lệ Năng suất Cây trồng Sử dụng Kỹ thuật Học máy," trong 2015

International Conference on Smart Technologies and Management for Computing, Communication, Controls, Energy and Materials (ICSTM), Avadi, Ấn Độ, 2015, trang 138-145. doi: 10.1109/ICSTM.2015.7225403

[12] N. T. Son và cộng sự, "Các Phương pháp Học máy để Dự đoán Năng suất Lúa Sử dụng Dữ liệu Vệ tinh Chuỗi thời gian ở Đài Loan," International Journal of Remote Sensing, tập 41, số 20, trang 7868-7888, tháng 8 năm 2020. doi: 10.1080/01431161.2020.1766148

[13] "Weka 3 Data Mining with Open Source Machine Learning Software in Java." https://www.cs.waikato.ac.nz/ml/weka/index.html

[14] J. Luts, F. Ojeda, R. Van De Plas, B. De Moor, S. Van Huffel, và J.A.K. Suykens, "Hướng dẫn về các Phương pháp dựa trên Máy Vector Hỗ trợ cho các Bài toán Phân loại trong Đo lường Hóa học (Chemometrics)," Analytica Chimica Acta, tập 665, số 2, trang 129-145, tháng 4 năm 2010. doi: 10.1016/j.aca.2010.03.030

Chương 13: Mạng Nơ-ron để Phát hiện Bệnh Cây trồng

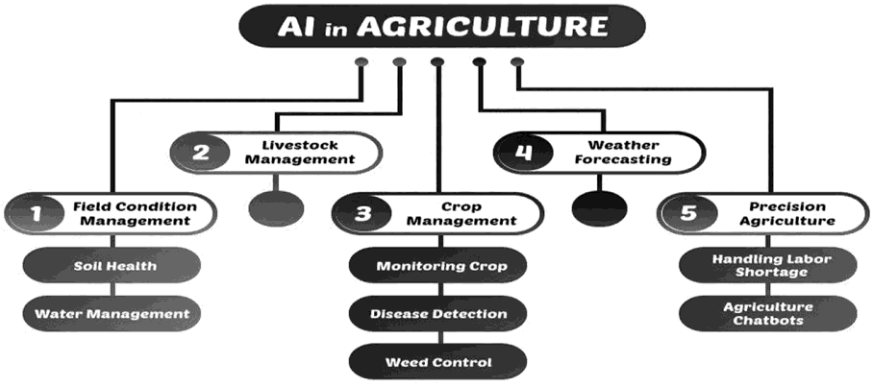
Mohammad Ubaidullah Bokhari, Gaurav Yadav, và Md. Zeyauddin Đại học Hồi giáo Aligarh, Aligarh, Ấn Độ

13.1 GIỚI THIỆU

Bệnh cây trồng là một thách thức nghiêm trọng và dai dẳng, có ảnh hưởng sâu rộng đến sản xuất lương thực trên quy mô toàn cầu. Khi dân số thế giới tiếp tục tăng, nhu cầu về lương thực cũng tăng theo, đòi hỏi sản lượng nông nghiệp phải tăng lên. Tuy nhiên, mối đe dọa âm thầm của bệnh cây trồng luôn hiện hữu, liên tục làm suy yếu các nỗ lực đảm bảo an ninh lương thực. Những bệnh này là một đối thủ đáng gờm, có khả năng gây ra tổn thất năng suất đáng kể, giảm chất lượng cây trồng và tàn phá kinh tế cho nông dân cũng như các quốc gia. Chúng tấn công không phân biệt, ảnh hưởng đến nhiều loại cây trồng, từ các loại ngũ cốc chủ lực như lúa, lúa mì, ngô đến các cây công nghiệp như cà phê và ca cao. Hậu quả của việc không kiểm soát được bệnh cây trồng lan rộng khắp chuỗi cung ứng thực phẩm, từ giảm nguồn cung cây trồng, tăng giá lương thực đến nguy cơ thiếu hụt lương thực ở các khu vực dễ bị tổn thương.

Trong một thế giới vốn đã vật lộn với những thách thức đa dạng của biến đổi khí hậu, khan hiếm tài nguyên và suy thoái môi trường, tác động của bệnh cây trồng càng làm trầm trọng thêm tình hình vốn đã bấp bênh. Hình 13.1 minh họa vai trò của trí tuệ nhân tạo (AI) trong nông nghiệp.

Trong bối cảnh này, nhu cầu phát hiện bệnh nhanh chóng và chính xác trong nông nghiệp trở nên rõ ràng hơn bao giờ hết. Các phương pháp xác định bệnh truyền thống, dựa vào sự quan sát của con người và thường yêu cầu xét nghiệm trong phòng thí nghiệm, rất tốn thời gian và nguồn lực. Vào thời điểm một đợt bùng phát dịch bệnh được xác nhận, nó có thể đã gây ra thiệt hại đáng kể. Sự chậm trễ trong phát hiện này có thể cản trở hiệu quả của các chiến lược quản lý bệnh và dẫn đến những tổn thất có thể phòng ngừa được. Việc phát hiện bệnh nhanh chóng và chính xác, được hỗ trợ bởi các công nghệ tiên tiến như AI và viễn thám, mang đến một giải pháp mang tính chuyển đổi cho thách thức cấp bách này. Những công nghệ này trao quyền cho nông dân khả năng nhanh chóng xác định và ứng phó với các đợt bùng phát dịch bệnh, cho phép can thiệp kịp thời như áp dụng thuốc trừ sâu có mục tiêu hoặc luân canh cây trồng. Hơn nữa, việc phát hiện bệnh chính xác cho phép thực hành nông nghiệp chính xác, giảm thiểu việc sử dụng tài nguyên không cần thiết và giảm tác động môi trường của nông nghiệp.

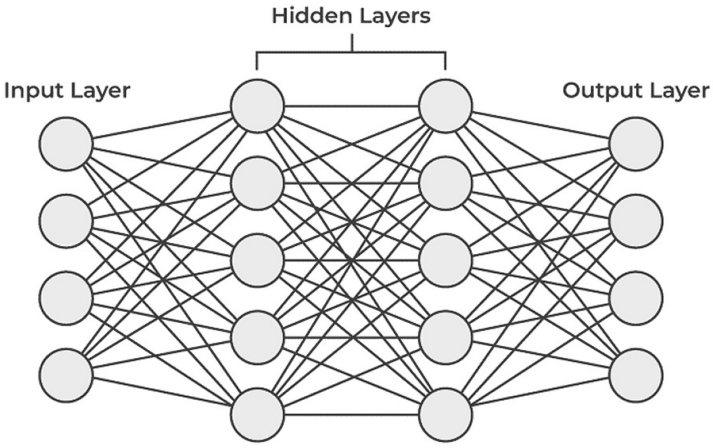


[Hình 13.1 Vai trò của AI trong nông nghiệp. Sơ đồ này cho thấy AI trong nông nghiệp được chia thành 5 lĩnh vực chính: 1. Quản lý điều kiện đồng ruộng (Sức khỏe đất, Quản lý nước), 2. Quản lý vật nuôi, 3. Quản lý cây trồng (Giám sát cây trồng, Phát hiện bệnh, Kiểm soát cỏ dại), 4. Dự báo thời tiết, và 5. Nông nghiệp chính xác (Xử lý thiếu hụt lao động, Chatbots nông nghiệp).]

13.2 GIỚI THIỆU VỀ MẠNG NƠ-RON

"Mạng nơ-ron" là một loại mô hình máy tính mô phỏng thiết kế và chức năng của mạng nơ-ron sinh học, chẳng hạn như bộ não con người. Nó bao gồm các nơ-ron, là các đơn vị xử lý được kết nối với nhau, hoạt động cùng nhau để đánh giá dữ liệu và đưa ra các phán đoán. Mạng nơ-ron đã tìm thấy ứng dụng quan trọng trong nhiều ứng dụng học máy và AI, bao gồm nhận dạng hình ảnh, xử lý ngôn ngữ tự nhiên và các lĩnh vực khác. Điều này có thể được hiểu tương tự từ minh họa trong Hình 13.2.

Sau đây là một vài loại mạng nơ-ron được mô tả sâu với các hình ảnh minh họa:



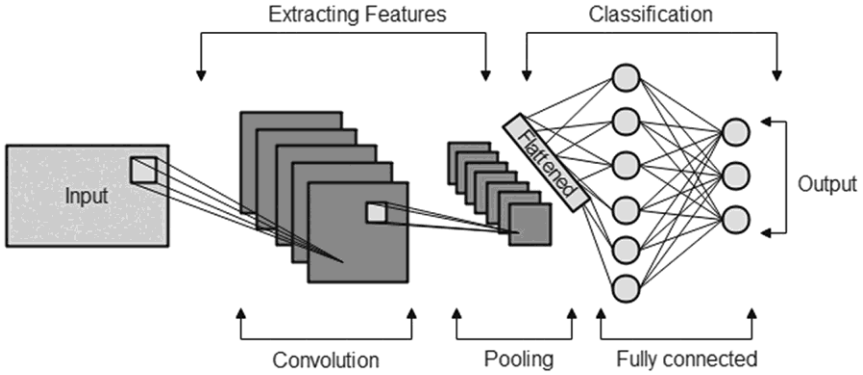
[Hình 13.2 Hoạt động của mạng nơ-ron. Sơ đồ cho thấy một mạng nơ-ron với Lớp đầu vào (Input Layer), nhiều Lớp ẩn (Hidden Layers) ở giữa và Lớp đầu ra (Output Layer). Các nơ-ron (vòng tròn) trong mỗi lớp được kết nối với các nơ-ron ở lớp tiếp theo.]

1. **Mạng Nơ-ron Truyền thẳng (Feedforward Neural Network - FNN):** Đây là loại mạng nơ-ron đơn giản nhất vì không có vòng phản hồi (feedback loops) và

thông tin chỉ di chuyển theo một chiều từ lớp đầu vào đến lớp đầu ra. Ví dụ, các tác vụ phân loại nhị phân như phát hiện thư rác email có thể được thực hiện bằng một FNN đơn giản. Lớp đầu vào nhận các đặc điểm của email; các lớp ẩn phân tích chúng, và lớp đầu ra xác định xem email đó có phải là thư rác hay không.

- FNN là dạng cơ bản nhất của mạng nơ-ron.
- Chúng bao gồm một lớp đầu vào, một hoặc nhiều lớp ẩn, và một lớp đầu ra.
- Thông tin đi qua chúng theo một đường duy nhất, từ lớp đầu vào qua các lớp ẩn đến lớp đầu ra.
- Thường được sử dụng cho các tác vụ hồi quy và phân loại.

2. **Mạng Nơ-ron Tích chập (CNN - Convolutional Neural Networks):** Mạng nơ-ron tích chập (CNN) được tạo ra đặc biệt cho các công việc xử lý hình ảnh. Để tự động trích xuất thông tin phân cấp từ ảnh đầu vào, chúng sử dụng các lớp tích chập.
   - **Minh họa:** Một CNN có thể được sử dụng để nhận diện các đối tượng trong ảnh, chẳng hạn như mèo hoặc chó, trong phân loại hình ảnh. Hình 13.3 cho thấy kiến trúc của CNN.
   - CNN sử dụng các lớp tích chập để tự động học các hệ thống phân cấp không gian của các đặc trưng.
   - Chúng phân tích đầu vào dạng lưới, chẳng hạn như ảnh và video.
   - CNN đã rất thành công trong các tác vụ nhận dạng hình ảnh.

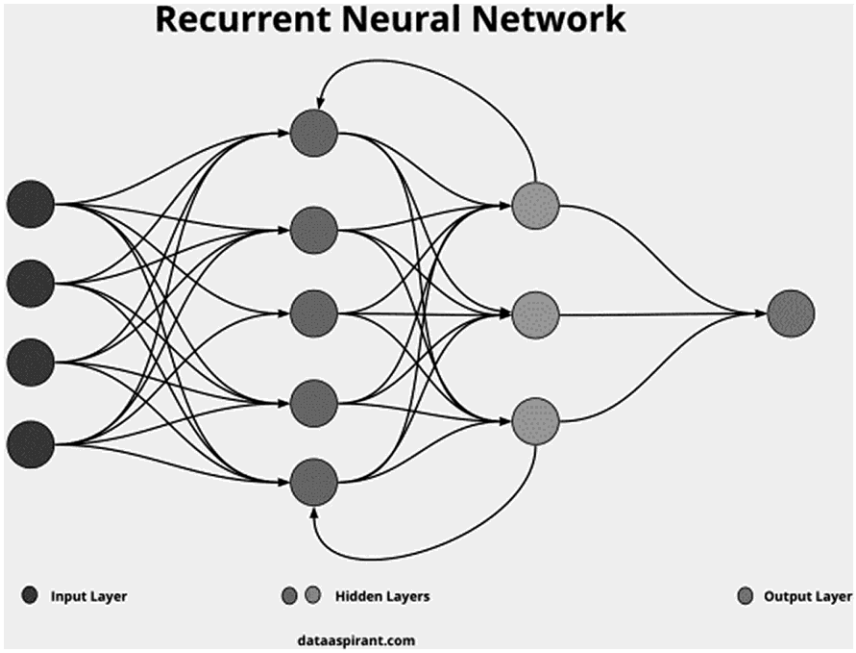


[Hình 13.3 Kiến trúc CNN. Sơ đồ mô tả quy trình của CNN, bắt đầu từ 'Đầu vào' (Input), qua phần 'Trích xuất Đặc trưng' (Extracting Features) bao gồm các lớp 'Tích chập' (Convolution) và 'Gộp' (Pooling), sau đó được 'Làm phẳng' (Flattened) và đi vào phần 'Phân loại' (Classification) gồm các lớp 'Kết nối đầy đủ' (Fully connected) để tạo ra 'Đầu ra' (Output).]

3. **Mạng Nơ-ron Hồi quy (RNN - Recurrent Neural Network):** RNN được sử dụng để xử lý dữ liệu tuần tự, và chúng có các vòng phản hồi cho phép dữ liệu chảy từ một giai đoạn trong chuỗi sang giai đoạn tiếp theo.
   - **Minh họa:** Bởi vì RNN có thể duy trì ngữ cảnh giữa các từ trong một cụm từ, chúng có lợi cho các tác vụ liên quan đến xử lý ngôn ngữ tự nhiên, bao

gồm tạo văn bản, dịch máy và phân tích tình cảm. Hình 13.4 cho thấy kiến trúc của RNN.

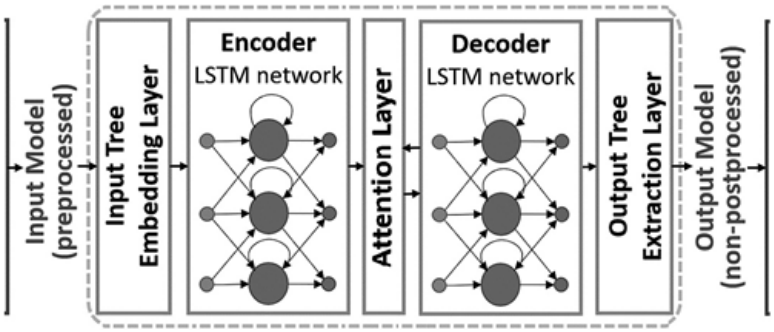
- RNN bao gồm các kết nối hồi quy, cho phép thông tin được truyền từ một bước trong chuỗi sang bước tiếp theo.
- Chúng chuyên biệt cho dữ liệu tuần tự, chẳng hạn như chuỗi thời gian hoặc ngôn ngữ tự nhiên.
- RNN được sử dụng trong các tác vụ như tạo văn bản, nhận dạng giọng nói và dịch máy.



[Hình 13.4 Mạng nơ-ron RNN. Sơ đồ của Mạng nơ-ron Hồi quy (Recurrent Neural Network) hiển thị 'Lớp đầu vào' (Input Layer), 'Các lớp ẩn' (Hidden Layers) với các vòng lặp phản hồi (biểu thị kết nối hồi quy) và 'Lớp đầu ra' (Output Layer).]

4. **Mạng Bộ nhớ Dài-Ngắn hạn (LSTM - Long Short-Term Memory Network):** LSTM là một loại RNN cụ thể được thiết kế để giải quyết vấn đề tiêu biến gradient (vanishing gradient). Để lập mô hình các chuỗi có sự phụ thuộc dài hạn, chúng hoạt động đặc biệt tốt.
    - **Minh họa:** Các hệ thống nhận dạng giọng nói có thể sử dụng LSTM để dịch đầu vào âm thanh thành văn bản. Hình 13.5 cho thấy kiến trúc của LSTM.
    - Các chuỗi dài rất phù hợp với LSTM, một loại RNN giải quyết vấn đề tiêu biến gradient.
    - Chúng phù hợp hơn để xử lý ngữ cảnh vì chúng chứa các ô nhớ (memory cells) có thể lưu trữ và truy xuất thông tin qua các chuỗi dài.

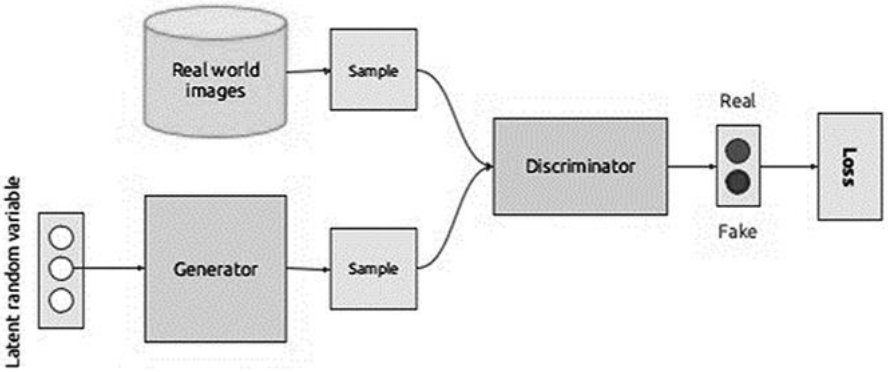
- LSTM thường được sử dụng trong nhận dạng giọng nói, tạo văn bản và lập mô hình ngôn ngữ.



[Hình 13.5 Mạng nơ-ron LSTM. Sơ đồ kiến trúc phức tạp cho thấy luồng dữ liệu đi từ 'Mô hình đầu vào (đã tiền xử lý)' qua 'Lớp nhúng cây đầu vào', sau đó vào 'Mạng LSTM Bộ mã hóa (Encoder)', qua 'Lớp chú ý (Attention Layer)', vào 'Mạng LSTM Bộ giải mã (Decoder)', qua 'Lớp trích xuất cây đầu ra', và cuối cùng đến 'Mô hình đầu ra (chưa hậu xử lý)'.]

5. **Đơn vị Hồi quy có Cổng (GRU - Gated Recurrent Unit):** GRU, hiệu quả về mặt tính toán hơn LSTM, được thiết kế để nắm bắt các mối quan hệ dài hạn trong dữ liệu tuần tự.
    - GRU có thể nhận ra các mẫu và sự kiện trong các luồng video và được sử dụng trong các ứng dụng như phân tích video.
    - GRU là một loại RNN khác tương tự như LSTM nhưng có kiến trúc đơn giản hơn.
    - Chúng có ít tham số hơn và thường huấn luyện nhanh hơn LSTM trong khi hoạt động tương tự trong nhiều tác vụ.
6. **Bộ Tự mã hóa (Auto-Encoder):** Loại mạng nơ-ron này được sử dụng để giảm chiều dữ liệu và học không giám sát. Chúng bao gồm một bộ giải mã (decoder) và một bộ mã hóa (encoder).
    - **Ví dụ:** Các bộ tự mã hóa có thể được huấn luyện để phản ánh các mẫu dữ liệu điển hình nhằm phát hiện bất thường. Bất kỳ sự sai lệch nào so với các xu hướng đã thiết lập đều có thể là một sự bất thường.
    - Một bộ giải mã tái tạo lại đầu vào từ mã hóa, trong khi một bộ mã hóa dịch dữ liệu đầu vào sang một biểu diễn chiều thấp hơn (mã hóa).
    - Các bộ tự mã hóa được sử dụng cho học không giám sát và học đặc trưng (feature learning).
    - Nén dữ liệu, khử nhiễu và phát hiện bất thường là các ứng dụng của bộ tự mã hóa.
7. **Mạng Đối nghịch Tạo sinh (GAN - Generative Adversarial Network):** Một bộ phân biệt (discriminator) và một bộ tạo sinh (generator) là hai mạng nơ-ron tạo nên GAN, và chúng cạnh tranh với nhau. Bộ tạo sinh tạo ra dữ liệu tưởng tượng, trong khi bộ phân biệt cố gắng phân biệt giữa dữ liệu thật và giả.

- Trong Hình 13.6, GAN được sử dụng trong việc tạo ra các bức ảnh trông giống thật, cũng như trong việc chuyển giao các phong cách sáng tạo từ hình ảnh này sang hình ảnh khác.
- GAN bao gồm hai mạng nơ-ron được huấn luyện đối nghịch: một bộ phân biệt và một bộ tạo sinh.
- Bộ tạo sinh tạo ra dữ liệu giả, trong khi bộ phân biệt cố gắng phân biệt giữa dữ liệu thật và giả.
- Ảnh, video và các loại dữ liệu khác trông giống thật có thể được tạo ra bằng GAN.



[Hình 13.6 Mạng nơ-ron GAN. Sơ đồ cho thấy kiến trúc GAN. 'Biến ngẫu nhiên tiềm ẩn' (Latent random variable) đi vào 'Bộ tạo sinh' (Generator) để tạo ra 'Mẫu' (Sample) giả. 'Hình ảnh thế giới thực' (Real world images) cung cấp 'Mẫu' (Sample) thật. Cả hai mẫu thật và giả đều đi vào 'Bộ phân biệt' (Discriminator). Bộ phân biệt sau đó xác định chúng là 'Thật' (Real) hay 'Giả' (Fake), dẫn đến một giá trị 'Mất mát' (Loss) được sử dụng để huấn luyện cả hai mạng.]

Các thiết kế mạng nơ-ron sau đây chỉ là một vài ví dụ. Do khả năng thích ứng to lớn của chúng, mạng nơ-ron có thể được huấn luyện trên các loại dữ liệu phù hợp và được sử dụng cho nhiều tác vụ và lĩnh vực khác nhau.

13.3 KỊCH BẢN ĐƯƠNG ĐẠI CỦA MẠNG NƠ-RON TRONG PHÁT HIỆN CÂY TRỒNG

Kịch bản đương đại của mạng nơ-ron trong phát hiện cây trồng đại diện cho sự hội tụ đột phá của công nghệ và nông nghiệp, giải quyết nhu cầu ngày càng tăng về sản xuất lương thực bền vững khi đối mặt với những thách thức toàn cầu ngày càng gia tăng. Các nghiên cứu trước đây trong lĩnh vực này đã mở đường cho những phát triển mang tính chuyển đổi. Ví dụ, CNN đã nổi lên như một nhân tố thay đổi cuộc chơi trong phát hiện bệnh cây trồng. Các mô hình học sâu này đã chứng tỏ khả năng phi thường trong việc nhận ra các dấu hiệu và mẫu hình ảnh tinh vi liên quan đến các bệnh cây trồng khác nhau. Bằng cách phân tích hình ảnh của lá, quả hoặc toàn bộ cây trồng, CNN có thể nhanh chóng và chính

xác xác định các dấu hiệu nhiễm trùng hoặc căng thẳng, cho phép can thiệp kịp thời và giảm tổn thất cây trồng.

Hơn nữa, các mạng nơ-ron hồi quy (RNN) và các biến thể của chúng đã được chứng minh là công cụ trong phân tích dữ liệu chuỗi thời gian, cần thiết cho việc theo dõi sức khỏe cây trồng trong thời gian dài. Chúng đã được áp dụng trong dự đoán bùng phát dịch bệnh dựa trên dữ liệu lịch sử về thời tiết và tỷ lệ mắc bệnh, hỗ trợ nông dân tối ưu hóa các chiến lược quản lý bệnh của họ. Ngoài ra, GAN đã cách mạng hóa việc tạo ra các hình ảnh bệnh cây trồng tổng hợp, khi kết hợp với dữ liệu thực, giúp tăng cường sự mạnh mẽ của các mô hình mạng nơ-ron bằng cách cho chúng tiếp xúc với một phổ rộng hơn các biểu hiện bệnh.

Có một số nhà nghiên cứu đã thực hiện rất nhiều công việc trong lĩnh vực phát hiện bệnh cây trồng trong lĩnh vực AI, bao gồm học máy, học sâu và mạng nơ-ron. Ví dụ, một nghiên cứu của Shahi và cộng sự [5] nhằm phân tích các phát triển hiện tại trong chẩn đoán bệnh nông nghiệp với trọng tâm là các phương pháp học máy và học sâu sử dụng viễn thám dựa trên phương tiện bay không người lái (UAV). Đầu tiên, chúng tôi thảo luận về cách các cảm biến và phương pháp xử lý hình ảnh khác nhau là cần thiết để tăng cường phát hiện bệnh cây trồng bằng dữ liệu UAV. Điều thứ hai chúng tôi đề xuất là một hệ thống phân loại để biên soạn và phân loại các nghiên cứu đã được thực hiện về nhận dạng bệnh nông nghiệp bằng ảnh chụp từ UAV. Hiệu quả của một số kỹ thuật học máy và học sâu trong phát hiện bệnh nông nghiệp sau đó được điều tra và tóm tắt. Cuối cùng, chúng tôi nhấn mạnh những khó khăn, triển vọng và các lĩnh vực nghiên cứu tương lai của viễn thám dựa trên UAV để nhận dạng bệnh nông nghiệp.

Trong một nghiên cứu, Putra và cộng sự [6] đã đề xuất một phương pháp dựa trên học chuyển giao (transfer learning) để giải quyết các vấn đề như vậy. Quy trình của chúng tôi bao gồm nhiều giai đoạn. Lá lúa được tiền xử lý trong giai đoạn đầu tiên. Thứ hai, trọng số lớp cân bằng (balanced class weighting) đã được sử dụng do sự mất cân bằng trong dữ liệu. Thứ ba, ba lớp tích chập đã được thêm vào mô hình học chuyển giao để tăng cường hiệu suất mạng. Sử dụng kỹ thuật dựa trên bandit, các tham số của các lớp kết nối đầy đủ đã được tối ưu hóa. Lá được chia thành chín nhóm trong giai đoạn cuối cùng. Chúng tôi đối chiếu phương pháp của mình với các nỗ lực tiên tiến nhất (SOTA) gần đây. Khi so sánh với các SOTA khác, mô hình của chúng tôi có độ chính xác cao nhất (98%).

Ngoài ra, Jain và Ramesh [7] đã đề xuất công trình trong đó các ưu điểm của CNN và LSTM được kết hợp trong mô hình đề xuất, có tên là hybrid CNN-LSTM. Đây là một mô hình dự đoán theo khu vực cụ thể, dự báo dữ liệu sâu bệnh trong một tháng dựa trên dữ liệu thời tiết và sâu bệnh của ba tháng trước đó. Mạng CNN và LSTM được sử dụng để so sánh hiệu suất của mô hình đề xuất. Điều này chứng tỏ việc sử dụng hybrid CNN-LSTM đã cải thiện hiệu suất như thế nào. Ngược lại, nghiên cứu này cũng cung cấp một mô hình phân loại tổng quát bằng cách kết hợp thông tin từ mọi khu vực. Sử dụng thông tin từ dữ liệu sâu bệnh và thời tiết của ngày hôm trước, mô hình dự báo mức độ nghiêm trọng của bệnh cho ngày hôm sau. Để phân loại mức độ nghiêm trọng của bệnh, phương

pháp mã hóa đầu ra sửa lỗi (ECOC) sử dụng bộ phân loại máy vector hỗ trợ (SVM) được sử dụng.

Việc tích hợp các công nghệ viễn thám, như vệ tinh và máy bay không người lái, với mạng nơ-ron đã mở ra một kỷ nguyên nông nghiệp chính xác. Những công nghệ này cung cấp lượng lớn dữ liệu có độ phân giải cao, mà mạng nơ-ron có thể xử lý để theo dõi điều kiện cây trồng, phát hiện các điểm bất thường và đánh giá tác động của các yếu tố môi trường đối với sức khỏe cây trồng.

Trong nghiên cứu của họ, Fenu và Malloci [8] phân tích và phân loại các bài báo nghiên cứu trong mười năm qua dự đoán sự xuất hiện của bệnh ở giai đoạn sớm hoặc tiền triệu chứng (tức là các triệu chứng không rõ ràng đối với mắt người). Chúng tôi xem xét các kỹ thuật và phương pháp cụ thể được sử dụng, dữ liệu và phương pháp tiền xử lý được sử dụng, các chỉ số hiệu suất và kết quả dự kiến, nhấn mạnh các vấn đề được phát hiện. Kết quả của nghiên cứu cho thấy thực hành này vẫn còn sơ khai và vẫn còn nhiều trở ngại cần giải quyết. Trong nghiên cứu của Annabel và Muthulakshmi [9], người ta đề xuất sử dụng một phương pháp độc đáo để phát hiện bệnh lá cà chua bao gồm bốn bước: tiền xử lý ảnh, phân đoạn, trích xuất đặc trưng và phân loại hình ảnh. Các phương pháp khác nhau được sử dụng để thực hiện kỹ thuật đề xuất bao gồm phân ngưỡng (thresholding), Ma trận Đồng xuất hiện Mức xám (GLCM), bộ phân loại rừng ngẫu nhiên (random forest classifier) và chuyển đổi Đỏ-Lục-Lam (RGB) sang thang xám. Các phát hiện cho thấy kỹ thuật được đề xuất chẩn đoán chính xác các bệnh với độ chính xác 94.1%.

Zhong và Zhao [10] đã đề xuất một nghiên cứu về bệnh lá táo, gây ra tổn thất kinh tế hàng năm đáng kể và là yếu tố chính ảnh hưởng đến sản lượng táo. Do đó, việc nghiên cứu chẩn đoán bệnh lá táo là rất quan trọng. Ba kỹ thuật để xác định bệnh lá táo đã được phát triển, bao gồm phân loại đa nhãn (multi-label classification), hàm mất mát tập trung (focus loss function) và hồi quy, tất cả đều dựa trên mạng tích chập sâu DenseNet-121. Lập mô hình dữ liệu và đánh giá kỹ thuật trong nghiên cứu này được thực hiện bằng cách sử dụng bộ dữ liệu hình ảnh lá táo, bao gồm 2,462 ảnh của 6 bệnh lá táo khác nhau. So với phương pháp đa phân loại thông thường dựa trên hàm mất mát cross-entropy, có độ chính xác là 92.29%, độ chính xác của các phương pháp được đề xuất trên bộ dữ liệu thử nghiệm lần lượt là 93.51%, 93.31% và 93.71%.

Cách tiếp cận toàn diện này để phát hiện cây trồng không chỉ cải thiện việc quản lý bệnh mà còn thúc đẩy các hoạt động canh tác sử dụng tài nguyên hiệu quả. Tuy nhiên, các thách thức đương đại vẫn tồn tại, bao gồm nhu cầu về các bộ dữ liệu lớn và đa dạng, khả năng diễn giải mô hình và việc áp dụng các giải pháp dựa trên AI của nông dân trên toàn thế giới.

Ahsan và cộng sự [11] đưa ra một đánh giá hiện tại về nghiên cứu đã được thực hiện trong mười năm qua để xác định các bệnh nông nghiệp bằng cách sử dụng học máy, học sâu, các phương pháp xử lý hình ảnh, Internet vạn vật và phân tích hình ảnh siêu phổ. Ngoài ra, một nghiên cứu so sánh về một số phương pháp được sử dụng để tìm bệnh cây trồng đã được thực hiện. Bài luận này cũng đưa ra các giải pháp tiềm năng cho nhiều khó

khăn khác nhau cần được giải quyết. Các giải pháp cho những vấn đề này sau đó được đưa ra trong một số khuyến nghị. Nghiên cứu cũng cung cấp một cái nhìn về tương lai, có thể chứng tỏ là một công cụ rất quan trọng và hữu ích cho những người nghiên cứu nhận dạng bệnh cây trồng.

Tuy nhiên, kịch bản đương đại của mạng nơ-ron trong phát hiện cây trồng là không thể phủ nhận đầy hứa hẹn, cung cấp một bộ công cụ mạnh mẽ để bảo vệ an ninh lương thực toàn cầu, giảm thiểu rủi ro bệnh cây trồng và cuối cùng góp phần vào một bối cảnh nông nghiệp bền vững và kiên cường hơn. Khi nghiên cứu đang diễn ra tiếp tục tinh chỉnh và mở rộng khả năng của mạng nơ-ron trong nông nghiệp, tiềm năng tăng cường phát hiện và quản lý cây trồng vẫn gần như vô hạn.

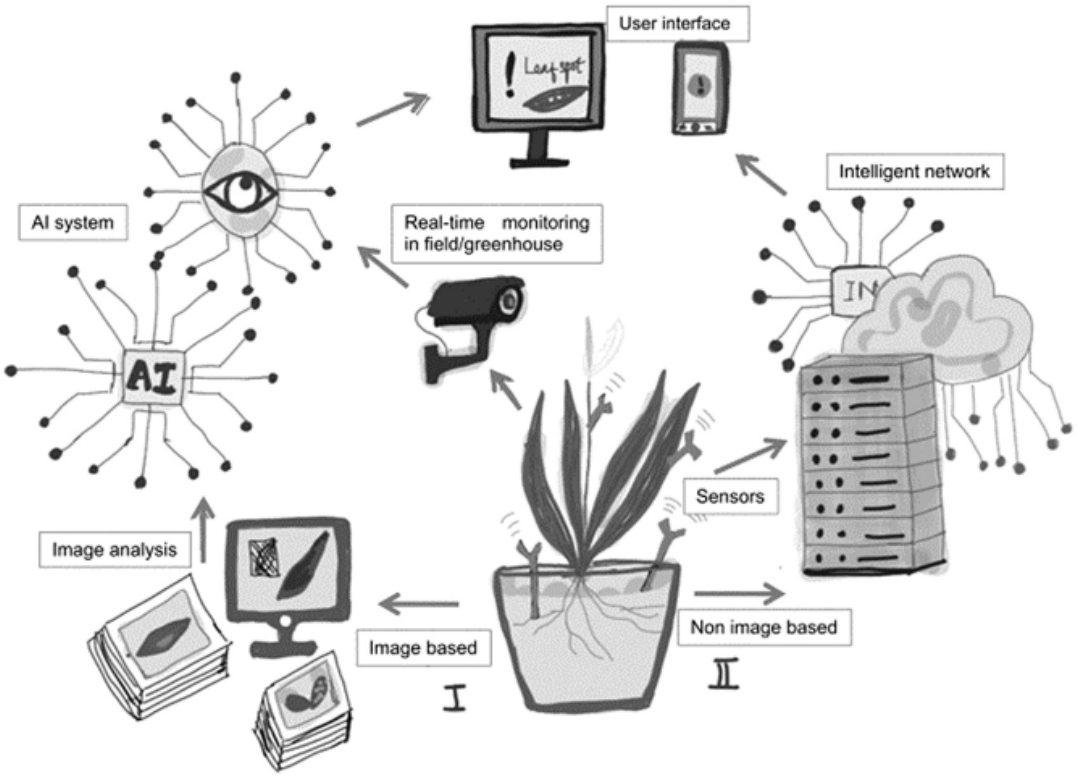
13.4 TẦM QUAN TRỌNG CỦA MẠNG NƠ-RON TRONG PHÁT HIỆN BỆNH CÂY TRỒNG

Tầm quan trọng của mạng nơ-ron trong phát hiện cây trồng là rất sâu sắc, vì chúng có tiềm năng cách mạng hóa nông nghiệp bằng cách tăng cường giám sát cây trồng, phát hiện bệnh và dự đoán năng suất. Mạng nơ-ron mang lại một số lợi thế cho lĩnh vực này, như được chứng minh bằng các ví dụ nghiên cứu trước đây:

- **Cải thiện Độ chính xác:** Việc xác định các bệnh nông nghiệp có thể được thực hiện chính xác hơn đáng kể bằng cách sử dụng mạng nơ-ron. Ví dụ, CNN đã được sử dụng trong một nghiên cứu được công bố trên tạp chí Computers and Electronics in Agriculture để chẩn đoán bệnh cây có múi từ ảnh chụp lá. Mô hình của họ vượt trội so với các phương pháp thông thường với tỷ lệ chính xác trên 99%. Nông dân sử dụng mức độ chính xác này có thể xác định bệnh sớm và hành động kịp thời để giảm tổn thất cây trồng.
- **Phát hiện Bệnh sớm:** Mạng nơ-ron vượt trội trong việc phát hiện bệnh sớm, điều này rất quan trọng để ngăn chặn sự lây lan của bệnh và giảm thiểu thiệt hại cây trồng. Trong một nghiên cứu khác, một nhóm các nhà nghiên cứu đã sử dụng RNN để dự đoán bệnh gỉ sắt trên lá lúa mì. Mô hình của họ có thể dự đoán sự xuất hiện của bệnh trước khi nó biểu hiện rõ ràng bằng mắt thường, cho phép can thiệp có mục tiêu và giảm nhu cầu sử dụng thuốc trừ sâu.
- **Nông nghiệp Chính xác:** Mạng nơ-ron cho phép nông nghiệp chính xác bằng cách cung cấp thông tin chi tiết về sức khỏe cây trồng. Ví dụ, nghiên cứu được công bố trên Precision Agriculture đã sử dụng kết hợp CNN và hình ảnh quang phổ để phát hiện mức nitơ trong cây lúa mì. Điều này cho phép áp dụng nitơ chính xác, giảm sử dụng phân bón trong khi vẫn duy trì năng suất cây trồng.
- **Tự động hóa và Khả năng Mở rộng:** Mạng nơ-ron có thể tự động hóa việc giám sát các cánh đồng nông nghiệp rộng lớn. Trong một nghiên cứu tình huống do một công ty công nghệ thực hiện, máy bay không người lái được trang bị các thuật toán học sâu đã được sử dụng để xác định bệnh cây trồng và sâu bệnh trong một

cánh đồng đậu tương lớn. Việc tự động hóa này không chỉ tiết kiệm thời gian mà còn cho phép can thiệp sớm, dẫn đến tăng năng suất. Hình 13.7 cho thấy sự tự động hóa của AI trong phát hiện bệnh cây trồng.

- **Khả năng Thích ứng:** Mạng nơ-ron có thể thích ứng với các loại cây trồng và bệnh khác nhau. Ví dụ, một nghiên cứu trên Tạp chí Bệnh học Thực vật (Journal of Plant Pathology) đã sử dụng các mô hình học sâu để phát hiện nhiều bệnh trên các loài cây trồng khác nhau, bao gồm cà chua, đậu tương và nho. Khả năng thích ứng của mạng nơ-ron làm cho chúng trở thành công cụ có giá trị cho các môi trường nông nghiệp đa dạng.
- **Ra quyết định dựa trên Dữ liệu:** Mạng nơ-ron tạo điều kiện cho việc ra quyết định dựa trên dữ liệu cho nông dân. Bằng cách phân tích dữ liệu lịch sử về sức khỏe cây trồng và các điều kiện môi trường, mạng nơ-ron có thể cung cấp thông tin chi tiết về thời điểm trồng trọt tối ưu, lịch trình tưới tiêu và các chiến lược quản lý bệnh, cuối cùng là cải thiện năng suất cây trồng và sử dụng tài nguyên.
- **Giảm Tác động Môi trường:** Nông nghiệp chính xác dựa trên mạng nơ-ron có thể dẫn đến giảm tác động môi trường. Bằng cách tối ưu hóa việc sử dụng tài nguyên, chẳng hạn như nước, thuốc trừ sâu và phân bón, các hệ thống này góp phần vào các hoạt động canh tác bền vững hơn, phù hợp với mục tiêu toàn cầu là giảm dấu chân sinh thái của nông nghiệp.



[Hình 13.7 Tầm quan trọng của mạng nơ-ron trong phát hiện bệnh cây trồng. Sơ đồ minh họa một hệ thống tự động: Một cây trồng trong chậu có ‘Cảm biến’ (Sensors) gửi dữ liệu (cả ‘Dựa trên hình ảnh’ - Image based và ‘Không dựa trên hình ảnh’ - Non image based).

Dữ liệu hình ảnh đi đến ‘Phân tích hình ảnh’ (Image analysis) rồi đến ‘Hệ thống AI’ (AI system). Dữ liệu không dựa trên hình ảnh đi đến ‘Mạng thông minh’ (Intelligent network) (máy chủ/đám mây). ‘Giám sát thời gian thực tại đồng/nhà kính’ (Real-time monitoring) cũng gửi dữ liệu đến hệ thống AI. Hệ thống AI sau đó hiển thị kết quả trên ‘Giao diện người dùng’ (User interface) (máy tính/điện thoại thông minh).]

Mạng nơ-ron đã chứng minh tầm quan trọng của chúng trong phát hiện cây trồng thông qua các ví dụ nghiên cứu trước đây bằng cách nâng cao độ chính xác, cho phép phát hiện bệnh sớm, hỗ trợ nông nghiệp chính xác, tự động hóa giám sát, thích ứng với các loại cây trồng đa dạng, tạo điều kiện ra quyết định dựa trên dữ liệu và thúc đẩy các thực hành bền vững với môi trường. Những tiến bộ này có tiềm năng cải thiện năng suất cây trồng, an ninh lương thực và tính bền vững của nông nghiệp trong một thế giới đang đối mặt với nhiều thách thức ngày càng tăng.

Hơn nữa, ở đây chúng tôi đang cung cấp thuật toán từng bước để phát hiện bệnh trên cây trồng trong Bảng 13.1.

BẢNG 13.1

Thuật toán Phát hiện Bệnh Cây trồng

Quy trình Từng bước để Phát hiện Bệnh Cây trồng bằng Mạng Nơ-ron
1. Thu thập Dữ liệu:
Thu thập một tập dữ liệu hình ảnh chứa cây trồng khỏe mạnh và cây trồng bị ảnh hưởng bởi các bệnh khác nhau
Tập dữ liệu phải đa dạng, mang tính đại diện và được dán nhãn chính xác.
2. Tiền xử lý Dữ liệu:
Thay đổi kích thước và chuẩn hóa hình ảnh về một kích thước đồng nhất.
Tăng số lượng và sự đa dạng của tập dữ liệu bằng cách thêm các thay đổi như xoay, lật và điều chỉnh độ sáng (tăng cường dữ liệu).
Chia tập dữ liệu thành các tập huấn luyện, xác thực và thử nghiệm (thường là 70%-80% để huấn luyện, 10%-15% để xác thực và 10%-15% để thử nghiệm).
3. Xây dựng Mạng Nơ-ron:
Chọn một thiết kế mạng nơ-ron phù hợp để phân loại hình ảnh. CNN thường được sử dụng cho mục đích này.
Thiết kế kiến trúc với một lớp đầu vào, nhiều lớp tích chập, lớp gộp và các lớp kết nối đầy đủ.
Sử dụng các hàm kích hoạt như Đơn vị Tuyến tính Chỉnh lưu (ReLU) và xem xét sử dụng các lớp dropout để ngăn ngừa quá khớp (overfitting).
Chọn một hàm mất mát thích hợp, chẳng hạn như categorical cross-entropy, và một thuật toán tối ưu hóa như Adam.

Quy trình Từng bước để Phát hiện Bệnh Cây trồng bằng Mạng Nơ-ron
4. Huấn luyện Mô hình:
Đưa dữ liệu huấn luyện vào mạng nơ-ron và bắt đầu huấn luyện mô hình.
Theo dõi các chỉ số huấn luyện (ví dụ: mất mát và độ chính xác) trên cả tập dữ liệu huấn luyện và xác thực.
Thực hiện dừng sớm (early stopping) để ngăn ngừa quá khớp.
5. Tinh chỉnh Siêu tham số:
Thử nghiệm với các siêu tham số khác nhau - ví dụ: kích thước lô (batch size), tốc độ học (learning rate) và kiến trúc mạng.
Sử dụng các kỹ thuật như tìm kiếm lưới (grid search) hoặc tìm kiếm ngẫu nhiên (random search) để tìm các siêu tham số tốt nhất.
6. Đánh giá:
Sau khi huấn luyện, đánh giá hiệu suất của mô hình trên tập dữ liệu thử nghiệm.
Tính toán các chỉ số như độ chính xác (accuracy), độ chuẩn xác (precision), độ phủ (recall), điểm F1 (F1-score) và ma trận nhầm lẫn (confusion matrix) để đánh giá hiệu quả của nó trong phát hiện bệnh.
(Tiếp theo)

BẢNG 13.1 (TIẾP THEO)

Quy trình Từng bước để Phát hiện Bệnh Cây trồng bằng Mạng Nơ-ron
7. Tinh chỉnh Mô hình:
Nếu kết quả ban đầu không thỏa đáng, hãy tinh chỉnh mô hình bằng cách điều chỉnh các siêu tham số hoặc sửa đổi kiến trúc.
8. Khả năng Diễn giải:
Xem xét các kỹ thuật để diễn giải mô hình, chẳng hạn như trực quan hóa các bản đồ đặc trưng (feature maps) để hiểu mô hình đang tập trung vào phần nào của hình ảnh để phát hiện bệnh.
9. Triển khai:
Khi bạn hài lòng với hiệu suất của mô hình, hãy triển khai nó trên thực địa.
Tạo giao diện thân thiện với người dùng để nông dân hoặc các chuyên gia nông nghiệp tải hình ảnh lên để chẩn đoán bệnh.
Đảm bảo rằng mô hình được triển khai có thể xử lý dữ liệu mới và chưa từng thấy một cách hiệu quả.
10. Giám sát và Cập nhật Liên tục:
Thường xuyên đánh giá cách mô hình được triển khai đang hoạt động và thay đổi nó khi cần thiết bằng thông tin mới hoặc các thuật toán nâng cao.

Quy trình Từng bước để Phát hiện Bệnh Cây trồng bằng Mạng Nơ-ron
Luôn cập nhật thông tin về các phát triển mới trong phát hiện bệnh cây trồng và mạng nơ-ron để giữ cho giải pháp của bạn luôn cập nhật.

13.5 VAI TRÒ CỦA MẠNG NƠ-RON TRONG PHÁT HIỆN BỆNH CÂY TRỒNG

Mạng nơ-ron cung cấp một phương pháp mạnh mẽ và có khả năng thích ứng để tự động hóa việc chẩn đoán và điều trị bệnh thực vật, đây là một đóng góp lớn cho việc phát hiện bệnh trong nông nghiệp. Những điểm sau đây nêu bật cách mạng nơ-ron giúp xử lý thách thức nông nghiệp quan trọng này:

- **Nhận dạng Bệnh chính xác:** Mạng nơ-ron, đặc biệt là CNN, rất xuất sắc trong các công việc đòi hỏi nhận dạng trực quan. CNN có thể phát hiện một cách đáng tin cậy sự hiện diện của bệnh trong các mẫu cây trồng bằng cách phân tích ảnh chụp các cây bị ảnh hưởng. Chúng có được khả năng nhìn thấy những bất thường và các mẫu hình ảnh tinh vi trong mô quả, thân và lá mà mắt người có thể khó nhận thấy.
- **Phát hiện Sớm:** Mạng nơ-ron có khả năng cho phép phát hiện bệnh sớm, cho phép nông dân hành động kịp thời để ngăn chặn sự lây lan của bệnh. Nông dân có thể ngăn chặn bệnh ở giai đoạn đầu, giảm thiểu tổn thất cây trồng, bằng cách thường xuyên quét các cánh đồng bằng máy ảnh hoặc máy bay không người lái được trang bị các thuật toán phát hiện bệnh dựa trên mạng nơ-ron.
- **Sàng lọc Thông lượng cao:** Mạng nơ-ron có thể phân tích nhanh chóng một lượng lớn ảnh chụp, giúp cho việc sàng lọc cây trồng theo cách thức thông lượng cao (high-throughput) trở nên khả thi. Việc giám sát hiệu quả và tiết kiệm chi phí các cánh đồng nông nghiệp lớn phụ thuộc vào kỹ năng này.
- **Nông nghiệp Chính xác:** Bằng cách hỗ trợ nông dân trong các nỗ lực kiểm soát bệnh chính xác hơn, mạng nơ-ron cho phép nông nghiệp chính xác. Nông dân có thể sử dụng thông tin chi tiết từ mạng nơ-ron để thực hiện các biện pháp can thiệp chỉ ở những nơi cần thiết, giảm việc sử dụng hóa chất và các tác động tiêu cực của chúng đối với môi trường. Đây là một giải pháp thay thế cho việc phun thuốc trừ sâu hoặc các phương pháp điều trị đồng đều trên toàn bộ cánh đồng.
- **Viễn thám:** Mạng nơ-ron có thể được sử dụng với công nghệ viễn thám, chẳng hạn như máy bay không người lái hoặc vệ tinh, để giám sát cây trồng trên các vùng địa lý rộng lớn. Ở những khu vực khan hiếm chuyên gia nông nghiệp, việc giám sát từ xa này cung cấp thông tin hữu ích để nhận dạng và kiểm soát bệnh.
- **Học tập Liên tục:** Khi các dạng bệnh phát triển, mạng nơ-ron có thể được huấn luyện và huấn luyện lại bằng dữ liệu mới. Nhờ khả năng thích ứng này, các thuật toán phát hiện bệnh có thể liên tục học hỏi và trở nên tốt hơn theo thời gian, điều này giúp nâng cao độ chính xác và hiệu quả của kết quả.

- **Phân tích Dữ liệu:** Mạng nơ-ron có thể được sử dụng như một phần của quy trình phân tích dữ liệu rộng hơn, kết hợp thông tin từ nhiều nguồn khác nhau, bao gồm thời tiết, chất lượng đất và các xu hướng bệnh trong quá khứ. Nông dân có thể hiểu biết thấu đáo về các rủi ro bệnh tật và các biện pháp phòng ngừa khả thi từ phương pháp tiếp cận toàn diện này.
- **Mở rộng Kiến thức:** Mạng nơ-ron cung cấp khả năng mở rộng kiến thức và kỹ năng trong chẩn đoán bệnh. Công nghệ nông nghiệp tiên tiến giờ đây có thể được phổ biến rộng rãi hơn nhờ việc chia sẻ và triển khai các mô hình đã được huấn luyện trên dữ liệu chuyên gia.
- **Giảm Chi phí Lao động:** Mạng nơ-ron có thể loại bỏ nhu cầu lao động thủ công trong kiểm tra cây trồng và chẩn đoán bệnh, tiết kiệm thời gian và tiền bạc cho nông dân.

Các giải pháp chính xác, hiệu quả và có thể mở rộng được cung cấp bởi mạng nơ-ron đã cách mạng hóa việc phát hiện bệnh trong nông nghiệp. Chúng cho phép nông dân và các bên liên quan khác trong ngành nông nghiệp đưa ra các lựa chọn dựa trên dữ liệu, giảm tổn thất cây trồng và thúc đẩy sự phát triển của các loại cây trồng khỏe mạnh và năng suất hơn, tất cả đều góp phần cải thiện an ninh lương thực toàn cầu. Một sự tiến bộ đáng kể trong nông nghiệp hiệu quả và bền vững có thể được nhìn thấy trong kỹ thuật này.

13.6 KẾT LUẬN

Tóm lại, chương về vai trò của mạng nơ-ron trong phát hiện bệnh cây trồng đã làm sáng tỏ một định hướng tương lai quan trọng cho nông nghiệp đương đại. Không thể phóng đại tầm quan trọng của bệnh cây trồng như một mối đe dọa toàn cầu đối với an ninh lương thực, và việc sử dụng mạng nơ-ron để phát hiện bệnh là một tia hy vọng. Với khả năng phi thường trong nhận dạng hình ảnh, phân tích chuỗi và ra quyết định dựa trên dữ liệu, mạng nơ-ron đã được chứng minh là công cụ rất hữu ích cho cả các nhà khoa học và nông dân.

Qua lăng kính của chương này, chúng ta đã khám phá sự phức tạp của các thiết kế mạng nơ-ron, ngạc nhiên trước khả năng đáng chú ý của chúng trong việc phát hiện bệnh cây trồng một cách nhanh chóng và đáng tin cậy, thường là ở giai đoạn đầu. Hiệu quả của CNN trong phát hiện dựa trên hình ảnh, nhận thức về bối cảnh của RNN trong xử lý dữ liệu tuần tự, và tiềm năng học tập và thích ứng liên tục trong cuộc chiến luôn thay đổi chống lại bệnh cây trồng đều đã được kiểm tra.

Một kỷ nguyên mới của nông nghiệp chính xác cũng đã được mở ra nhờ sự hội tụ của mạng nơ-ron với công nghệ tiên tiến như viễn thám, máy bay không người lái và phân tích dữ liệu. Sự tích hợp này cho phép thực hiện chính xác các liệu pháp điều trị, giảm tác động môi trường và tăng hiệu quả sử dụng tài nguyên, bên cạnh việc phát hiện sớm và chính xác các rối loạn. Việc sử dụng mạng nơ-ron trong phát hiện bệnh nông nghiệp dự kiến sẽ tiếp tục phát triển trong tương lai. Công nghệ và kiến thức sẽ tiếp tục trở nên dễ

tiếp cận hơn, mang đến cho nông dân trên toàn cầu quyền truy cập vào các công cụ hiệu quả này và cải thiện an ninh lương thực toàn cầu.

Chương này đã nhấn mạnh tiềm năng to lớn để các nhà khoa học, chuyên gia nông nghiệp và công nghệ làm việc cùng nhau nhằm thúc đẩy các giới hạn của những gì có thể thực hiện được để bảo vệ cây trồng của chúng ta và đảm bảo một tương lai bền vững và kiên cường. Chúng mở ra một chương mới trong lịch sử nông nghiệp, một chương được đặc trưng bởi sự đổi mới, trao quyền và lạc quan. Chúng đại diện cho nhiều hơn là chỉ một chương trong biên niên sử về phát hiện bệnh cây trồng. Chương này cho chúng ta hy vọng về tương lai bởi vì nó cho thấy mạng nơ-ron đã tiến xa như thế nào và chúng ta được trang bị tốt như thế nào để bảo vệ cây trồng, nuôi sống người dân và tạo ra một thế giới giàu có và bền vững hơn.

TÀI LIỆU THAM KHẢO

[1] https://www.edrawsoft.com/article/neural-network-diagram.html

[2] https://dataaspirant.com/how-recurrent-neural-network-rnn-works/

[3] https://modeling-languages.com/lstm-neural-network-model-transformations/

[4] https://medium.com/fnplus/what-is-all-about-generative-adversarial-networks-gans-33faa7b78363

[5] Shahi, T. B., Xu, C. Y., Neupane, A., & Guo, W. (2023). Những tiến bộ gần đây trong phát hiện bệnh cây trồng sử dụng UAV và kỹ thuật học sâu. Remote Sensing, 15(9), 2450.

[6] Putra, O. V., Trisnaningrum, N., Puspitasari, N. S., Wibowo, A. T., & Rachmawaty, E. (2022, tháng 8). Phân loại bệnh lá lúa được tối ưu hóa bằng học chuyển giao và phân phối trọng số lớp cân bằng dựa trên phương pháp Bandit. Trong 2022 5th International Conference on Information and Communications Technology (ICOIACT) (trang 417-422). IEEE.

[7] Jain, S., & Ramesh, D. (2021, tháng 7). Mô hình Hybrid CNN-LSTM dựa trên AI để dự đoán bệnh cây trồng: Một sự ra đời của ML cho cây lúa. Trong 2021 12th International Conference on Computing Communication and Networking Technologies (ICCCNT) (trang 1-7). IEEE.

[8] Fenu, G., & Malloci, F. M. (2021). Dự báo bệnh thực vật và cây trồng: Một nghiên cứu khám phá về các thuật toán hiện tại. Big Data and Cognitive Computing, 5(1), 2.

[9] Annabel, L. S. P., & Muthulakshmi, V. (2019, tháng 12). Phát hiện bệnh lá cà chua dựa trên hình ảnh được hỗ trợ bởi AI. Trong 2019 Third International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC) (trang 506-511). IEEE.

[10] Zhong, Y., & Zhao, M. (2020). Nghiên cứu về học sâu trong nhận dạng bệnh lá táo. Computers and Electronics in Agriculture, 168, 105146.

[11] Ahsan, T., Khan, M., Ahmed, M., Zafar, T., & Javeed, A. (2022). Ứng dụng của trí tuệ nhân tạo trong chẩn đoán và quản lý bệnh cây trồng. International Journal of Scientific Engineering and Research, 13, 1000-1015.

CHƯƠNG 14: DỰ BÁO THỜI TIẾT NGẮN HẠN CHO NÔNG NGHIỆP CHÍNH XÁC Ở JAMMU VÀ KASHMIR: PHƯƠNG PHÁP TIẾP CẬN HỌC SÂU

Syed Nisar Hussain Bukhari và Sana Farooq Pandit Viện Công nghệ Thông tin và Điện tử Quốc gia (NIELIT), Srinagar, Ấn Độ

14.1 GIỚI THIỆU

Sản xuất nông nghiệp đóng vai trò là nguồn phát triển kinh tế chính ở bất kỳ quốc gia nào, và dự báo thời tiết (WF) ảnh hưởng trực tiếp hoặc gián tiếp đến lợi nhuận hoặc thua lỗ hàng năm của sản xuất nông nghiệp. WF cho phép nông dân dự đoán và ngăn ngừa các thiệt hại tiềm ẩn gây ra bởi các hiện tượng thời tiết khắc nghiệt, bao gồm giảm năng suất, tưới tiêu sai, lựa chọn cây trồng không phù hợp và thời điểm thu hoạch không chính xác. Những thay đổi thời tiết không thể đoán trước có thể cản trở đáng kể tiến bộ nông nghiệp trong một thời gian dài. Khả năng dự đoán tuyết rơi, mưa, sóng nhiệt và lũ lụt sắp xảy ra giúp nông dân lập chiến lược và giảm thiểu các tác động tàn phá của các sự kiện đó.

Với sự tiến bộ của trí tuệ nhân tạo (AI) trong WF, độ tin cậy và độ chính xác của các dự đoán đã được cải thiện đáng kể. Các thuật toán AI dựa trên dữ liệu như mạng nơ-ron (NN) có thể được sử dụng để phân tích dữ liệu thời tiết lịch sử và dự báo các xu hướng cũng như các kiểu mẫu thời tiết trong tương lai. Các mô hình này cũng cải thiện độ chính xác của các dự đoán thời tiết ngắn hạn, giúp các nhà nông nghiệp đưa ra các quyết định sáng suốt. Ngược lại, hiệu suất của các kỹ thuật thống kê như Trung bình Trượt Tự hồi quy (ARMA) và các biến thể của nó phụ thuộc vào cả chất lượng dữ liệu và khả năng biểu diễn chính xác dữ liệu chuỗi thời gian (TS) thể hiện các mẫu không dừng (non-stationary) qua các mùa khác nhau.

Các hệ thống lập mô hình dựa trên dữ liệu có thể được sử dụng để giảm yêu cầu tính toán của Dự báo Thời tiết Số trị (NWP) đồng thời tính đến sự không chắc chắn có trong các quan sát và nhiễu hệ thống. Điều này có thể là do khả năng của các mô hình dựa trên dữ liệu trong việc ước tính các mẫu và động lực nội tại của dữ liệu TS, ngay cả khi không có kiến thức trước về các tham số.

Cụ thể, Mạng Nơ-ron Nhân tạo (ANN) có thể được sử dụng cho mục tiêu này nhờ vào các đặc tính thích ứng và khả năng học hỏi từ kiến thức trước đó. Những đặc điểm này làm cho ANN trở nên hấp dẫn trong các lĩnh vực đa dạng, đặc biệt là khi xử lý các hiện tượng phi tuyến phức tạp có trong các bộ dữ liệu như bộ dữ liệu thời tiết. Các loại NN khác nhau, chẳng hạn như NN truyền thẳng (feedforward NN), NN sử dụng lan truyền ngược (back propagation), Mạng Nơ-ron Hồi quy (RNN), và Bộ nhớ Dài-Ngắn hạn (LSTM), áp dụng một cách tiếp cận dự đoán riêng biệt, mỗi loại cung cấp một phương pháp độc đáo để đạt được kết quả chính xác.

Để xử lý hiệu quả dữ liệu thời tiết, các mô hình RNN và LSTM được coi là những lựa chọn vượt trội do khả năng xử lý hiệu quả dữ liệu TS. Các NN thông thường thiếu sức mạnh cần thiết để nắm bắt các phụ thuộc dài hạn. Khi số lượng lớp tăng lên, chúng dễ gặp phải vấn đề tiêu biến gradient (vanishing gradient). Mặt khác, Mạng Nơ-ron Hồi quy (RNN) rất phù hợp để xử lý dữ liệu TS với các thang thời gian đa dạng, cho phép chúng lưu trữ thông tin dài hạn.

Để huấn luyện RNN, một bộ dữ liệu TS bao gồm các bản ghi hàng ngày về nhiệt độ tối thiểu (min temp), nhiệt độ tối đa (max temp) và giá trị lượng mưa đã được thu thập từ Cục Khí tượng Ấn Độ (IMD). Nghiên cứu này nhằm mục đích thiết lập một khung mô hình dự đoán cho WF ngắn hạn nhằm hỗ trợ nông dân quản lý tài nguyên nông nghiệp hiệu quả và lập kế hoạch cho các hoạt động canh tác của họ trước thời hạn. Mô hình sẽ sử dụng các giá trị trong quá khứ trong một bước thời gian xác định làm đầu vào để dự báo các giá trị nhiệt độ tối thiểu, nhiệt độ tối đa và lượng mưa trong số ngày ngắn hơn.

14.1.1 Đóng góp

Những đóng góp chính của nghiên cứu này được tóm tắt như sau:

- Giảm gánh nặng kinh tế trực tiếp và gián tiếp gây ra do sự phụ thuộc của nông dân vào các dự đoán thời tiết sai lầm.
- Chủ động giảm thiểu các thiệt hại tiềm ẩn trong ngành nông nghiệp do các tình huống thời tiết khắc nghiệt gây ra.
- Xây dựng một mô hình học sâu (DL) được thiết kế đặc biệt cho WF ngắn hạn sử dụng dữ liệu TS.
- Tạo ra các dự đoán thời tiết chính xác trong một khung thời gian giới hạn bằng cách sử dụng dữ liệu thời tiết địa phương hóa.
- Xây dựng một mô hình WF thể hiện khả năng thích ứng mạnh mẽ với các xu hướng đang thay đổi trong dữ liệu thời tiết và xử lý hiệu quả các sự kiện thời tiết khắc nghiệt trong khi vẫn duy trì hiệu suất nhất quán.

14.2 CÁC CÔNG TRÌNH LIÊN QUAN

Nhiều kỹ thuật khác nhau dựa trên cả phương pháp thống kê và mô hình dựa trên dữ liệu đã được thiết kế theo thời gian để dự báo các điều kiện thời tiết bằng cách dự đoán một hoặc nhiều tham số liên quan đến thời tiết. Các nhà nghiên cứu [6] đã tiến hành một nghiên cứu để dự đoán cường độ mưa bằng cách sử dụng nhiệt độ hàng ngày, độ ẩm, hướng gió, tốc độ gió và tốc độ mây. Các mô hình dự đoán được xây dựng bằng Cây Quyết định (DT), Hồi quy Vector Hỗ trợ (SVR), và Rừng Ngẫu nhiên (RF), đạt được điểm R^2 lần lượt là 0.806, 0.900, và 0.980.

Trong một nghiên cứu khác, các nhà nghiên cứu [7] đã huấn luyện các mô hình học máy khác nhau để dự đoán lượng mưa nhằm hỗ trợ nông nghiệp chính xác ở Sri Lanka. Các mô hình được huấn luyện bằng cách sử dụng các thuộc tính như máy đo mưa, độ ẩm

tương đối, nhiệt độ trung bình, tốc độ gió, hướng gió, bức xạ mặt trời và nồng độ ozone đặc trưng cho khu vực Sri Lanka. Người ta quan sát thấy rằng RF hoạt động tốt nhất với độ chính xác 89.16%.

Trong công trình của mình, các nhà nghiên cứu [8] đã kết hợp các kỹ thuật học máy với các kỹ thuật khai thác dữ liệu để phát triển một mô hình dự đoán lượng mưa, và người ta quan sát thấy rằng các mô hình Trung bình Trượt Tích hợp Tự hồi quy (ARIMA) và NN cung cấp độ chính xác tốt nhất là 70.5%.

Trong thập kỷ qua, RNN đã thu hút sự chú ý đáng kể và chứng kiến sự tiến bộ đáng kể vì khả năng lập mô hình mạnh mẽ và có ảnh hưởng của chúng. Trong một nghiên cứu, các nhà nghiên cứu [10] đã sử dụng lưu lượng và lượng mưa hàng ngày để dự báo lũ lụt. Các kết quả nghiên cứu cho thấy tiềm năng sử dụng LSTM, một biến thể của RNN, để phát triển và quản lý các hệ thống cảnh báo lũ lụt thời gian thực.

Trong nghiên cứu thực nghiệm của mình, các nhà nghiên cứu [1] đã kết luận rằng mô hình LSTM vượt trội hơn mô hình ARIMA trong việc dự đoán nhiệt độ tối thiểu và tối đa với điểm lỗi bình phương trung bình gốc (RMSE) là 1.04. Nghiên cứu được thực hiện bởi Gumaste và Kadam [11] đã sử dụng Thuật toán Di truyền (GA) và Biến đổi Fourier Nhanh (FFT) để dự đoán thời tiết trong tương lai bằng cách sử dụng dữ liệu hiện tại. Các mô hình sau đó đã được triển khai thông qua các ứng dụng di động để hỗ trợ nông dân lập kế hoạch cho các công việc trước và sau nông nghiệp của họ.

Để đạt được các dự báo thời tiết chính xác cho làng Dellangu của Indonesia, các nhà nghiên cứu đã phát triển một mô hình dự đoán thời tiết ngắn hạn sử dụng ANN để giúp nông dân giải quyết các vấn đề đồng lúa của họ. Một nghiên cứu khác đã tiến hành phân tích so sánh giữa mười mô hình hồi quy học máy cơ sở và một mô hình tập hợp (ensemble model). Phân tích cho thấy mô hình tập hợp hoạt động tốt hơn các mô hình cơ sở trong việc dự đoán lượng mưa, độ ẩm tương đối, nhiệt độ tối đa và tối thiểu.

Để giảm chi phí thiệt hại nông nghiệp do sương giá, các nhà nghiên cứu đã huấn luyện các mô hình học máy như mạng nơ-ron tích chập, mạng nơ-ron sâu, và RF để dự đoán các sự kiện sương giá. Nghiên cứu đã xác định rằng nhiệt độ đất là một yếu tố quan trọng khi đưa ra dự đoán ngoài 24 giờ, trong khi đối với các dự báo ngắn hạn hơn, hầu hết các thông tin liên quan được lấy từ các tham số liên quan đến nhiệt độ khác.

14.3 CÔNG TRÌNH ĐỀ XUẤT

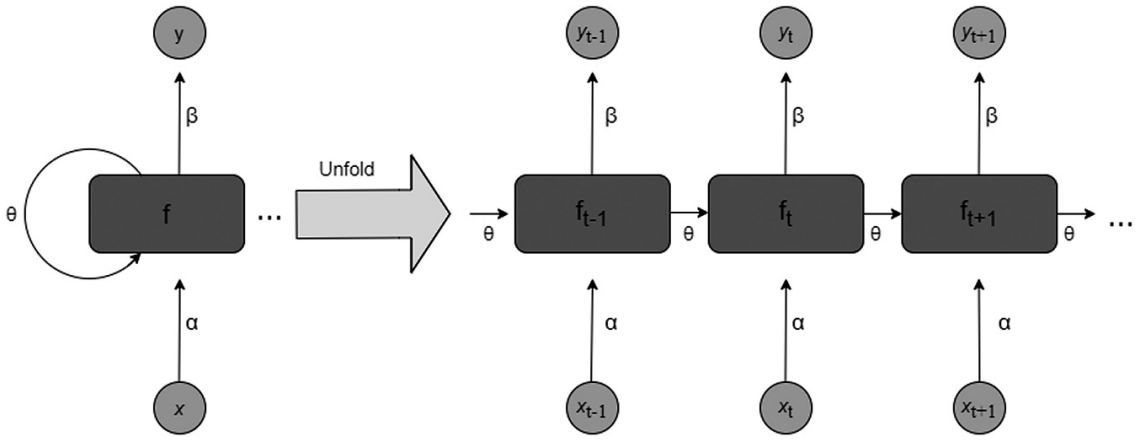
Nghiên cứu này trình bày một mô hình WF sáng tạo và gọn nhẹ (lightweight) được thiết kế đặc biệt để dự đoán ngắn hạn chính xác về nhiệt độ và lượng mưa ở Jammu và Kashmir (J&K). Mô hình được thiết kế để tương thích với các máy tính cá nhân độc lập và có thể dễ dàng triển khai trong khu vực địa lý J&K. Hệ thống đề xuất sử dụng một kỹ thuật DL tiên tiến được gọi là RNN, phù hợp với dữ liệu tuần tự và có thể nâng cao độ

chính xác của các dự đoán. Phần dưới đây cung cấp một giải thích chi tiết về mô hình RNN.

14.3.1 Mạng Nơ-ron Hồi quy

Một RNN truyền thống [15] có thể được coi là một biến thể của NN truyền thẳng sở hữu một thành phần bộ nhớ trong để xử lý các chuỗi đầu vào. RNN có khả năng học các phụ thuộc từ các thuật ngữ trước đó và dự đoán các thước đo tích lũy từ các chuỗi có độ dài thay đổi, bao gồm cả thành phần thời gian. RNN đặc biệt hữu ích để phát triển các mô hình dự đoán bằng cách sử dụng các bộ dữ liệu TS dài hạn, điều này có thể hữu ích trong WF.

Không giống như các NN sâu truyền thống giả định đầu vào và đầu ra không liên quan đến nhau, RNN tạo ra các đầu ra bị ảnh hưởng bởi các yếu tố trước đó trong chuỗi. Đối với điều đó, RNN sử dụng các vòng lặp phản hồi để tận dụng đầu ra từ một bước thời gian làm đầu vào cho bước tiếp theo. Bằng cách duy trì thông tin một cách tuần tự, đầu vào của RNN tại mỗi bước thời gian kết hợp cả dữ liệu từ bước thời gian hiện tại trong chuỗi và thông tin trước đó được truyền qua vòng lặp phản hồi. Bản chất hồi quy của RNN xuất phát từ việc áp dụng nhất quán cùng một hàm để tính toán đầu ra cho mỗi đầu vào, với đầu ra bị ảnh hưởng bởi các tính toán trước đó.



HÌNH 14.1 Hoạt động của RNN.

Hình 14.1 minh họa một kiến trúc RNN cơ bản trong đó x_t đến x_{t+1} đại diện cho các đầu vào cho mỗi chuỗi, và y_t đến y_{t+1} đại diện cho các đầu ra tương ứng được tạo ra cho mỗi chuỗi. Rõ ràng là tất cả các đầu vào được kết nối với nhau, với mỗi kết nối được ký hiệu bằng một ô RNN duy nhất. Các thuật ngữ f_{t-1} đến f_{t+1} đề cập đến các trạng thái ẩn, và θ đại diện cho trọng số của các trạng thái ẩn; α biểu thị trọng số của trạng thái đầu vào hiện tại; β đại diện cho trọng số tại trạng thái đầu ra.

Trái ngược với các NN truyền thẳng truyền thống nơi các trọng số là riêng biệt cho mỗi nút, RNN sử dụng các tham số được chia sẻ qua các lớp, ngụ ý rằng trong mỗi lớp của RNN, cùng một tham số trọng số được áp dụng. Tuy nhiên, các trọng số được chia sẻ này

vẫn được cập nhật trong quá trình lan truyền ngược và giảm gradient để cho phép học tăng cường hiệu quả.

Hoạt động của RNN có thể được giải thích qua các bước sau:

Đối với một chuỗi các điểm dữ liệu x, được ký hiệu là $x = [x_{t-1}, x_t, x_{t+1} \dots]$ trong đó x_t đại diện cho đầu vào tại một bước thời gian "t" cụ thể trong chuỗi:

- Trạng thái ẩn tại bước thời gian "t", ký hiệu là f_t được tính toán bằng cách kết hợp đầu vào hiện tại x_t với trạng thái ẩn trước đó f_{t-1} . Phép tính này được biểu thị là: $f_t = \sigma(\alpha x_t + \theta f_{t-1})$, trong đó σ đại diện cho hàm kích hoạt được áp dụng cho tổng của các đầu vào có trọng số; α đại diện cho ma trận trọng số cho các kết nối từ đầu vào đến trạng thái ẩn; θ đại diện cho ma trận trọng số cho các kết nối trong trạng thái ẩn.
- Đầu ra y_t tại bước thời gian "t" có thể được tính toán bằng cách sử dụng trạng thái ẩn: $y_t = \sigma(\beta f_t)$ trong đó β là ma trận trọng số cho các kết nối từ ẩn đến đầu ra.

Hàm kích hoạt là một phép toán học được sử dụng để kết hợp tính phi tuyến vào NN, cho phép chúng học hiệu quả các mẫu dữ liệu phức tạp và thực hiện các thay đổi phi tuyến đối với dữ liệu đầu vào. Trong RNN, hàm kích hoạt chỉ được áp dụng cho các lớp ẩn vì lớp đầu vào chỉ chứa dữ liệu đầu vào và không trải qua bất kỳ phép tính nào.

Ngoài ra, đầu ra của RNN, đại diện cho dự đoán của mạng hoặc đầu ra được tạo ra tại mỗi bước thời gian, cũng có thể trải qua một hàm kích hoạt để chuyển đổi đầu ra thô thành một phạm vi hoặc định dạng ưu tiên dựa trên nhiệm vụ hoặc vấn đề cụ thể đang được giải quyết. Nếu không có sự hiện diện của các hàm kích hoạt phi tuyến, một mạng nơ-ron có nhiều lớp ẩn về cơ bản sẽ giống như một mô hình hồi quy tuyến tính quy mô lớn và sẽ không thể học hiệu quả các mẫu phức tạp và phức tạp từ dữ liệu thế giới thực. Các hàm kích hoạt thường được sử dụng là Rectified Linear Unit (ReLU), tanh, Sigmoid, và Softmax.

14.3.1.1 Lan truyền ngược Theo Thời gian (BPTT)

BPTT [16] là một phương pháp huấn luyện lặp đi lặp lại được sử dụng đặc biệt cho RNN. Nó mở rộng thuật toán lan truyền ngược tiêu chuẩn, thường được sử dụng để huấn luyện NN truyền thẳng, và kết hợp khía cạnh thời gian của RNN bằng cách cho phép các gradient lan truyền ngược theo thời gian, xem xét bản chất tuần tự của dữ liệu TS.

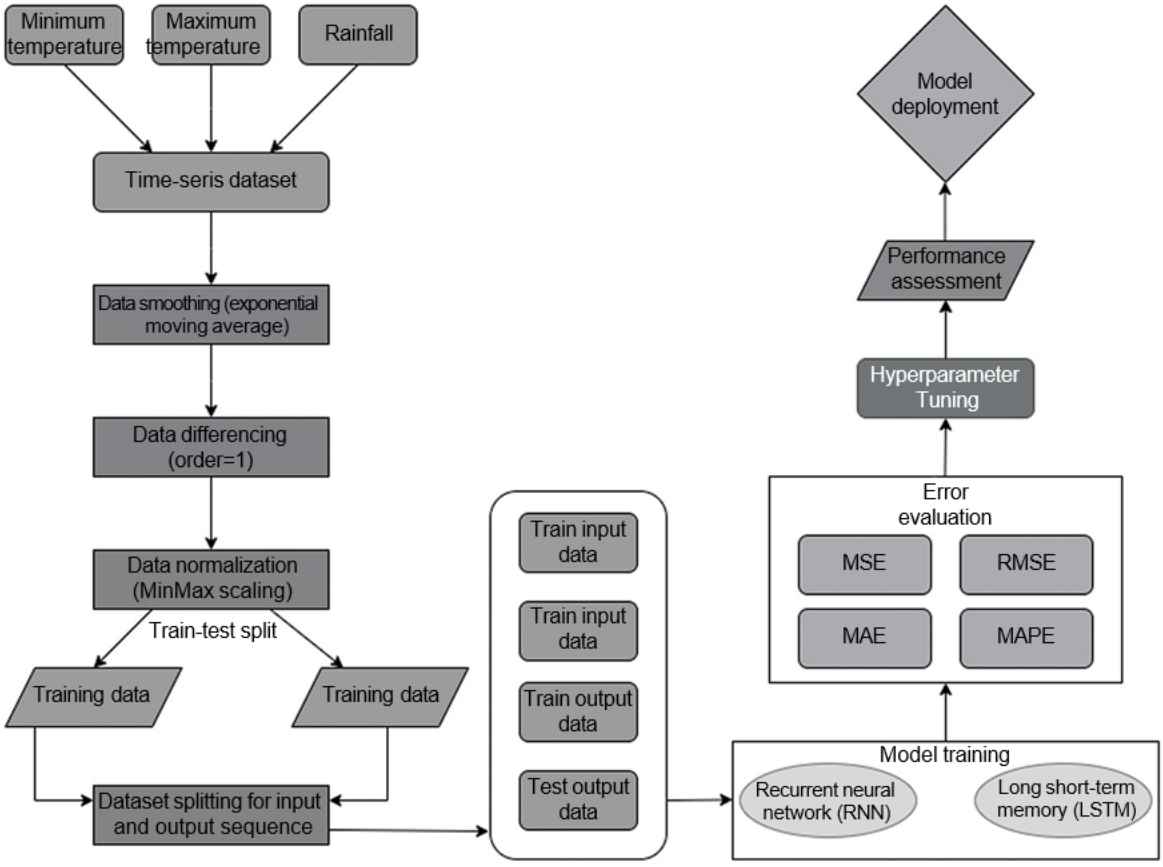
Trong RNN, trạng thái ẩn của mạng tại mỗi bước thời gian bị ảnh hưởng bởi cả đầu vào hiện tại và đầu ra từ trạng thái ẩn trước đó. Điều này làm phát sinh một chuỗi các phụ thuộc kéo dài ngược thời gian, cho phép BPTT mở rộng RNN theo thời gian. Một phân tích đơn giản về các bước liên quan đến BPTT được đưa ra tiếp theo:

Đối với một chuỗi các điểm dữ liệu x, được ký hiệu là $x = [x_{t-1}, x_t, x_{t+1} \dots]$, trong đó x_t đại diện cho đầu vào tại một bước thời gian "t" cụ thể trong chuỗi.

- Trạng thái ẩn tại bước thời gian "t", ký hiệu là f_t , được tính toán bằng cách kết hợp đầu vào hiện tại x_t với trạng thái ẩn trước đó f_{t-1} . Phép tính này được biểu thị là: $f_t = \sigma(\alpha x_t + \theta f_{t-1})$, Trong đó σ , α , và θ có ý nghĩa như thường lệ.
- Hàm mất mát, chẳng hạn như lỗi bình phương trung bình (MSE) hoặc mất mát cross-entropy, được áp dụng để tính toán mất mát tại mỗi bước thời gian. Chúng ta có thể biểu thị mất mát tại một bước thời gian "t" cụ thể là l_t .
- Các gradient của mất mát đối với các tham số của mạng được tính toán từ bước thời gian cuối cùng. Sau đó, các gradient này được lan truyền theo hướng ngược lại qua các bước thời gian trước đó. Gradient tại bước thời gian "t", biểu thị tác động của mất mát lên trạng thái ẩn tại "t" có thể được biểu thị là: $\frac{\partial l_t}{\partial f_t}$
- Các gradient được tích lũy tại mỗi bước khi chúng lan truyền theo thời gian, đảm bảo rằng các phụ thuộc giữa các bước thời gian khác nhau được nắm bắt một cách hiệu quả. Các gradient tích lũy được biểu thị như sau: $\frac{\partial l}{\partial f_t}$
- Các tham số của mạng được cập nhật bằng cách sử dụng các thuật toán tối ưu hóa như Adam, SGD và RMSprop. Cập nhật tham số cho mỗi trọng số có thể được tính là: $\Delta w = -\eta * \Sigma \frac{\partial l}{\partial w}$. trong đó Δw là cập nhật trọng số, và η là tốc độ học.

14.4 CÁC THÍ NGHIỆM

Hình 14.2 minh họa chi tiết quy trình lập mô hình toàn diện. Thí nghiệm bắt đầu với giai đoạn thu thập dữ liệu và tiền xử lý dữ liệu, được trình bày chi tiết trong phần tiếp theo. Sau đó, quy trình bao gồm cấu hình, huấn luyện, so sánh và đánh giá mô hình. Bước cuối cùng của thí nghiệm bao gồm việc đánh giá và đối chiếu hiệu suất của các mô hình đã được huấn luyện.



HÌNH 14.2 Minh họa về lập mô hình.

14.4.1 Thu thập Dữ liệu

Nghiên cứu này sử dụng dữ liệu khí tượng thực tế thu được từ trang web của IMD [17], cụ thể là từ các trạm thời tiết ở Jammu, Srinagar, và Leh. Bộ dữ liệu cho mỗi trạm thời tiết bao gồm một TS hàng ngày bao gồm 8.401 điểm dữ liệu, kéo dài từ ngày 1 tháng 1 năm 2010 đến ngày 31 tháng 12 năm 2022. Bộ dữ liệu bao gồm các biến thời tiết khác nhau, bao gồm lượng mưa, nhiệt độ tối thiểu và nhiệt độ tối đa. Giá trị lượng mưa được đo bằng milimét (mm), trong khi các biến nhiệt độ được ghi bằng độ C.

Các đặc trưng khí tượng cụ thể này được chọn vì chúng cung cấp những hiểu biết có giá trị về điều kiện thời tiết hiện tại tại một địa điểm và thời gian cụ thể. Việc lựa chọn các đặc trưng này nhằm mục đích nắm bắt chính xác trạng thái của thời tiết. Trong nghiên cứu này, ba đặc trưng khí tượng này được sử dụng làm biến đầu vào để dự đoán nhiệt độ.

14.4.2 Tiền xử lý Dữ liệu

Thí nghiệm được tiến hành trên dữ liệu thực tế đòi hỏi một số bước tiền xử lý để phản ánh chính xác hiệu suất của mô hình. Ban đầu, việc làm mịn dữ liệu đã được thực hiện để giảm nhiễu và biến động, đồng thời làm cho các mẫu và xu hướng cơ bản trở nên rõ ràng hơn. Dữ liệu đã được làm mịn bằng kỹ thuật Trung bình Trượt Lũy thừa (EMA).

EMA [18] là giá trị trung bình có trọng số trong đó các trọng số được giảm dần sao cho tầm quan trọng được trao nhiều hơn cho các điểm dữ liệu gần đây so với các điểm dữ liệu lịch sử, hoặc ngược lại. EMA thay đổi với tốc độ nhanh hơn và nhạy cảm hơn với các điểm dữ liệu. Về mặt toán học, EMA của một điểm dữ liệu có thể được tính bằng Phương trình 14.1:

$$\text{EMA}, = x_0 t = 0$$

$$\alpha x_t + (1 - \alpha) EMA_{t-1} \text{ (14.1)}$$

trong đó α là một yếu tố làm mịn, và giá trị của nó nằm trong khoảng từ 0 đến 1. Nó đại diện cho trọng số được áp dụng cho giai đoạn rất gần đây. Đối với nghiên cứu này, giá trị của α đã được giữ ở mức 0.5.

Để làm cho TS dừng (stationary), phép sai phân (differencing) bậc một đã được thực hiện trên bộ dữ liệu thời tiết. Phép sai phân đòi hỏi tính toán sự khác biệt giữa các quan sát liên tiếp bằng cách trừ giá trị trước đó khỏi giá trị hiện tại. Mục đích của phép sai phân là để loại bỏ xu hướng cơ bản và cô lập các thay đổi hoặc biến động cụ thể có trong dữ liệu.

Đối với giai đoạn cuối cùng của tiền xử lý, dữ liệu đã được chuẩn hóa bằng kỹ thuật co giãn MinMax (MinMax scaling) vì các giá trị của các biến khác nhau trong bộ dữ liệu có các đơn vị khác nhau và nằm trong nhiều phạm vi. Về mặt toán học, co giãn MinMax được biểu thị bằng Phương trình 14.2:

$$X_t = \frac{X_t - X_{min}}{X_{max} - X_{min}}, \text{ (14.2)}$$

trong đó X_t đại diện cho điểm dữ liệu tại thời điểm "t" trong TS và X_{max} và X_{min} lần lượt đại diện cho các điểm dữ liệu tối đa và tối thiểu trong chuỗi.

Dữ liệu được chuẩn hóa cho phép các mô hình tổng quát hóa tốt trên dữ liệu mới và chưa từng thấy. Ngoài ra, các hàm kích hoạt trong các nơ-ron RNN và LSTM hoạt động hiệu quả hơn trên dữ liệu được chuẩn hóa. Bộ dữ liệu đã được chia thành một tập huấn luyện và một tập kiểm tra, với tỷ lệ lần lượt là 0.8 và 0.2. Tập dữ liệu huấn luyện của mỗi trạm thời tiết bao gồm 6.720 hàng chứa dữ liệu thời tiết từ ngày 1 tháng 1 năm 2000 đến ngày 25 tháng 5 năm 2018, trong khi tập dữ liệu kiểm tra chứa 1.680 hàng kéo dài từ ngày 26 tháng 5 năm 2018 đến ngày 31 tháng 12 năm 2022. Các chuỗi đầu vào và đầu ra đã được thu thập bằng thuật toán cửa sổ trượt (moving window) và kích thước cửa sổ là bảy. Cả chuỗi đầu vào và đầu ra đều chứa ba đặc trưng.

14.4.3 Cấu hình và Huấn luyện Mô hình

Các mô hình đề xuất đã được huấn luyện bằng hai cấu hình riêng biệt: Đầu vào Đơn Đầu ra Đơn (SISO) và Đầu vào Nhiều Đầu ra Nhiều (MIMO). SISO là một sắp xếp dự báo trong đó một biến đầu vào duy nhất được đưa vào mạng để dự báo các giá trị tương lai của cùng một biến đó làm đầu ra. Mặt khác, trong MIMO, nhiều biến được đưa vào mạng để dự đoán các biến tương tự làm đầu ra.

Sử dụng cấu hình này, chỉ cần một mô hình cho mỗi trạm thời tiết để dự đoán tất cả các giá trị trong tương lai, trong khi ở SISO, cần ba mô hình khác nhau cho mỗi trạm thời tiết để dự báo ba tham số thời tiết. Do đó, ba mô hình RNN đã được huấn luyện và đánh giá bằng cách sử dụng cấu hình MIMO cho ba trạm thời tiết riêng biệt. Ngoài ra, tổng cộng chín mô hình RNN đã được cả huấn luyện và kiểm tra trong cấu hình SISO để dự báo ba biến nhiệt độ trên ba trạm thời tiết.

Cả hai cấu hình đã được huấn luyện trên các bộ siêu tham số khác nhau của RNN. Siêu tham số (Hyperparameters) là các giá trị cụ thể phải được xác định trước khi huấn luyện mô hình và không phải học hoặc điều chỉnh trong quá trình huấn luyện mô hình. Các siêu tham số được tinh chỉnh trong nghiên cứu này bao gồm số lượng epoch, kích thước lô (batch size), thuật toán tối ưu hóa, và các hàm kích hoạt.

Kỹ thuật được chọn để tinh chỉnh siêu tham số là GridSearchCV, tự động hóa quá trình thử các cấu hình siêu tham số khác nhau. Nó khám phá kỹ lưỡng một lưới các giá trị siêu tham số được xác định trước để xác định sự kết hợp tạo ra hiệu suất mô hình cao nhất.

Đối với mô hình RNN, số lượng epoch xác định số lần mô hình sẽ được huấn luyện trên toàn bộ bộ dữ liệu. Trong mỗi epoch, mô hình trải qua một lượt truyền xuôi (từ đầu vào đến đầu ra) và một lượt truyền ngược (điều chỉnh trọng số dựa trên gradient) cho tất cả các mẫu huấn luyện. Sử dụng số lượng epoch nhỏ hơn dẫn đến tăng mất mát lỗi, trong khi số lượng epoch lớn hơn có thể gây ra hiện tượng quá khớp (overfitting). Các mô hình đã được huấn luyện trong khoảng 50-300 epoch.

Kích thước lô đề cập đến số lượng mẫu huấn luyện được mô hình xử lý cùng nhau trong một lượt truyền xuôi và ngược, cho phép mô hình cập nhật trọng số sau khi xử lý một nhóm mẫu. Sử dụng kích thước lô lớn hơn trong quá trình huấn luyện mô hình đi kèm với chi phí tính toán cao hơn, trong khi kích thước lô nhỏ hơn gây ra nhiễu trong mô hình. Do đó, các thí nghiệm huấn luyện đã được tiến hành với các kích thước lô là 16, 32, 64, và 128 để tìm ra cấu hình tối ưu.

Việc lựa chọn thuật toán tối ưu hóa ảnh hưởng đến cả tốc độ mô hình đạt được giải pháp tối ưu và khả năng tổng quát hóa hiệu quả đối với dữ liệu chưa từng thấy. Để xác định thuật toán tối ưu hóa phù hợp nhất, các mô hình đã trải qua quá trình huấn luyện bằng cách sử dụng các trình tối ưu hóa Adam, SGD, và RMSprop. Để lựa chọn hàm kích hoạt tối ưu, các mô hình đã được huấn luyện trên các hàm kích hoạt tanh, ReLU, và sigmoid.

14.4.4 Đánh giá Mô hình

Các mô hình đã được huấn luyện lặp đi lặp lại trên dữ liệu huấn luyện và được đánh giá trên dữ liệu kiểm tra. Để đánh giá các mô hình hồi quy TS, các số liệu thường được sử dụng là lỗi tuyệt đối trung bình (MAE), MSE, RMSE, và lỗi phần trăm tuyệt đối trung bình (MAPE), được tính bằng các Phương trình 14.3-14.6:

$$MAE = \sum_{t=1}^{N} | y_t - \dot{y}_t | \quad (14.3)$$

$$MSE = \sum_{t=1}^{N}(y_t - \dot{y}_t)^2 \text{ (14.4)}$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \mid \sum_{i=1}^{N}(y_t - \dot{y}_t)^2} \text{ (14.5)}$$

$$\text{MAPE} = \frac{100}{N}\sum_{i=1}^{N} \mid \frac{y_t - \hat{y}_t}{y_t} \mid \text{ (14.6)}$$

trong đó y_t và $\hat{y}_t$ là các giá trị thực tế và dự đoán của các biến nhiệt độ tại bước thời gian "t".

14.5 KẾT QUẢ VÀ THẢO LUẬN

Như đã đề cập trong Mục 14.3, mô hình RNN đã được huấn luyện bằng cách sử dụng các bộ siêu tham số khác nhau và được kiểm tra bằng các số liệu đánh giá khác nhau. Đối với mỗi trạm, người ta đã quan sát thấy rằng mô hình RNN hoạt động tốt hơn đáng kể trong cấu hình SISO so với cấu hình MIMO. Các giá trị của các số liệu độ chính xác khác nhau cho các mô hình RNN được liệt kê trong Bảng 14.1 cho tất cả các trạm thời tiết. Bảng 14.2-14.4 liệt kê các số liệu độ chính xác của mô hình RNN trong cấu hình SISO cho Jammu, Srinagar, và Leh.

Những phát hiện này chỉ ra rằng các biến có trong dữ liệu thời tiết là tương đối đơn biến (univariate) và không có các phụ thuộc lẫn nhau mạnh mẽ giữa chúng. Các mối quan hệ như vậy có thể được biểu diễn đầy đủ bằng cách sử dụng một biến đầu vào duy nhất để dự báo một biến đầu ra duy nhất.

BẢNG 14.1: Hiệu suất Mô hình trong Cấu hình MIMO cho tất cả các Trạm

Số liệu	Giá trị Tương ứng cho Trạm Jammu	Giá trị Tương ứng cho Trạm Srinagar	Giá trị Tương ứng cho Trạm Leh
MAE	0.0636	0.1048	0.8543
MSE	0.0401	0.0455	0.0411
RMSE	0.1011	0.1555	0.1344
MAPE	0.3990	0.4398	0.3229
[cite: 1208]			

BẢNG 14.2: Hiệu suất Mô hình trong Cấu hình SISO cho Trạm Jammu

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAE	0.0751	0.0690	0.0124
MSE	0.0095	0.0095	0.0257
RMSE	0.0977	0.0091	0.0006

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAPE	0.1863	0.1683	0.1229

BẢNG 14.3: Hiệu suất Mô hình trong Cấu hình SISO cho Trạm Srinagar

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAE	0.0658	0.0696	0.0210
MSE	0.0073	0.0926	0.0018
RMSE	0.0854	0.0085	0.0429
MAPE	0.1436	0.1696	0.1368

BẢNG 14.4: Hiệu suất Mô hình trong Cấu hình SISO cho Trạm Leh

Biến Nhiệt độ	T_{min}	T_{max}	Lượng mưa
MAE	0.0666	0.0085	0.0640
MSE	0.0075	0.0015	0.0078
RMSE	0.0866	0.0393	0.0887
MAPE	0.1547	0.0588	0.1623

14.6 KẾT LUẬN VÀ PHẠM VI TƯƠNG LAI

Nghiên cứu này nhấn mạnh tầm quan trọng của việc lựa chọn dữ liệu khu vực trong việc xây dựng một mô hình WF đáng tin cậy và giải quyết vấn đề WF bằng cách tập trung vào việc đạt được các dự báo chính xác mà không yêu cầu tài nguyên tính toán đáng kể, trái ngược với các phương pháp NWP. Để giải quyết vấn đề này, một mô hình dự đoán dựa trên DL gọn nhẹ đã được đề xuất để đảm bảo WF ngắn hạn chính xác. Mô hình được đề xuất có khả năng hoạt động độc lập trên một đơn vị máy tính duy nhất và có thể dễ dàng triển khai trong khu vực địa lý của J&K.

Trong tương lai, nhiều biến hơn như tốc độ gió, độ ẩm, và áp suất có thể được tích hợp vào quá trình huấn luyện mô hình để cung cấp một dự báo thời tiết đa dạng hơn. Các kết quả cũng cho thấy SISO hoạt động tốt hơn các cấu hình MIMO ; tuy nhiên, điều đó sẽ đòi hỏi ba mô hình khác nhau để dự đoán ba tham số thời tiết làm đầu ra. Trong các thí nghiệm tương lai, các cấu hình MIMO có thể được tối ưu hóa hơn nữa để tăng cường cả hiệu suất và hiệu quả đồng thời.

TÀI LIỆU THAM KHẢO

[1] Z. Prathyusha, T. Savya, N. Alex, and C. Sobin, “A Method for Weather Forecasting Using Machine Learning,” in *2021 5th Conference on Information and Communication Technology, CICT 2021*, Institute of Electrical and Electronics Engineers Inc., 2021. doi: 10.1109/CICT53865.2020.9672403

[2] S. Poornima, and M. Pushpalatha, "Prediction of Rainfall Using Intensified LSTM Based Recurrent Neural Network with Weighted Linear Units," *Atmosphere (Basel)*, vol. 10, no. 11, Nov. 2019. doi: 10.3390/atmos10110668

[3] M. Hayati, and Z. Mohebi, "Application of Artificial Neural Networks for Temperature Forecasting", *International Science Index, Electrical and Computer Engineering*, vol. 1, no. 4, pp. 662–666, 2007.

[4] F. Kratzert, D. Klotz, C. Brenner, K. Schulz, and M. Herrnegger, "Rainfall-Runoff Modelling Using Long Short-Term Memory (LSTM) Networks," *Hydrology and Earth System Sciences*, vol. 22, no. 11, pp. 6005–6022, Nov. 2018. doi: 10.5194/hess-22-6005-2018

[5] T. Kashiwao, K. Nakayama, S. Ando, K. Ikeda, M. Lee, and A. Bahadori, "A Neural Network-Based Local Rainfall Prediction System Using Meteorological Data on the Internet: A Case Study Using Data from the Japan Meteorological Agency," *Applied Soft Computing Journal*, vol. 56, pp. 317–330, Jul. 2017. doi: 10.1016/j.asoc.2017.03.015

[6] V. P. Tharun, R. Prakash, and S. R. Devi, "Prediction of Rainfall Using Data Mining Techniques," in *Proceedings of the International Conference on Inventive Communication and Computational Technologies, ICICCT 2018*, Institute of Electrical and Electronics Engineers Inc., Sep. 2018, pp. 1507–1512. doi: 10.1109/ICICCT.2018.8473177

[7] J. S. A. N. W. Premachandra, and P. P. N. V. Kumara, "A Novel Approach for Weather Prediction for Agriculture in Sri Lanka Using Machine Learning Techniques," in *Proceedings - International Research Conference on Smart Computing and Systems Engineering, SCSE 2021*, Institute of Electrical and Electronics Engineers Inc., Sep. 2021, pp. 182–189. doi: 10.1109/SCSE53661.2021.9568319

[8] U. Shah, S. Garg, N. Sisodiya, N. Dube, and S. Sharma, "Rainfall Prediction: Accuracy Enhancement Using Machine Learning and Forecasting Techniques," in *PDGC 2018 - 2018 5th International Conference on Parallel, Distributed and Grid Computing*, Institute of Electrical and Electronics Engineers Inc., Dec. 2018, pp. 776–782. doi: 10.1109/PDGC.2018.8745763

[9] L. C. Jain and L. R. Medsker, *Recurrent Neural Networks*, 1999. doi: 10.1201/9781420049176

[10] X. H. Le, H. V. Ho, G. Lee, and S. Jung, "Application of Long Short-Term Memory (LSTM) Neural Network for Flood Forecasting," *Water (Switzerland)*, vol. 11, no. 7, 2019. doi: 10.3390/w11071387

[11] S. S. Gumaste and A. J. Kadam, "Future Weather Prediction Using Genetic Algorithm and FFT for Smart Farming." *2016 International Conference on Computing Communication Control and automation (ICCUBEA)*, Pune, India, 2016, pp. 1–6. doi: 10.1109/ICCUBEA.2016.7860028

[12] F. Najib and I. W. Mustika, "Weather Forecasting Using Artificial Neural Network for Rice Farming in Delanggu Village," in *IOP Conference Series: Earth and Environmental Science*, Institute of Physics, 2022. doi: 10.1088/1755-1315/1030/1/012002

[13] C. Nyasulu, A. Diattara, A. Traore, A. Deme, and C. Ba, "Towards Resilient Agriculture to Hostile Climate Change in the Sahel Region: A Case Study of Machine Learning- Based

Weather Prediction in Senegal," *Agriculture (Switzerland)*, vol. 12, no. 9, Sep. 2022. doi: 10.3390/agriculture12091473

[14] H. Kerner, M. Alamaniotis, and C. J. Talsma, "Frost Prediction Using Machine Learning and Deep Neural Network Models."

[15] S. Hochreiter, and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780. 1997. doi: 10.1162/neco.1997.9.8.1735

[16] P. J. Werbos, "Generalization of Backpropagation with Application to a Recurrent Gas Market Model," *Neural Networks*, vol. 1, no. 4, pp. 339–356, 1988. doi: 10.1016/0893-6080(88)90007-X

[17] Home. (n.d.). Accessed: Aug. 07, 2023. https://data.gov.in/catalog/climatology-data-important-cities-0

[18] "Welles Wilder - New Concepts in Technical Trading Systems | PDF | Algorithmic Trading | Financial Economics." Accessed: Aug. 09, 2023. [Online]. Available: https://www.scribd.com/doc/53093880/Welles-Wilder-New-Concepts-in- Technical-Trading-Systems#

[19] F. K. Oduro-Gyimah, and K. O. Boateng, "Forecasting Abilities of MIMO and SISO Neural Networks: A Comparative Study Using Telecommunication Traffic Data," in *Proceedings - 2019 International Conference on Computing, Computational Modelling and Applications, ICCMA 2019*, Institute of Electrical and Electronics Engineers Inc., Mar. 2019, pp. 81–86. doi: 10.1109/ICCMA.2019.00020

[20] S. N. H. Bukhari, J. Webber, and A. Mehbodniya, "Decision Tree Based Ensemble Machine Learning Model for the Prediction of Zika Virus T-Cell Epitopes as Potential Vaccine Candidates," *Scientific Reports*, vol. 12, pp. 7810, 2022. doi: 10.1038/s41598-022-11731-6

[21] G. S. Raghavendra, S. Shyni Carmel Mary, Purnendu Bikash Acharjee, V. L. Varun, Syed Nisar Hussain Bukhari, Chiranjit Dutta, and Issah Abubakari Samori, "An Empirical Investigation in Analysing the Critical Factors of Artificial Intelligence in Influencing the Food Processing Industry: A Multivariate Analysis of Variance (MANOVA) Approach," *Journal of Food Quality*, vol. 2022, Article ID 2197717, 7 pages, 2022. doi: 10.1155/2022/2197717

[22] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, and J. Webber, "Ensemble Machine Learning Model to Predict SARS-CoV-2 T-Cell Epitopes as Potential Vaccine Targets," *Diagnostics*, vol. 11, no. 11, 1990. MDPI AG. Retrieved from doi: 10.3390/diagnostics11111990

[23] Sunil L. Bangare, Deepali Virmani, Girija Rani Karetla, Pankaj Chaudhary, Harveen Kaur, Syed Nisar Hussain Bukhari, and Shahajan Miah, "Forecasting the Applied Deep Learning Tools in Enhancing Food Quality for Heart Related Diseases Effectively: A Study Using Structural Equation Model Analysis," *Journal of Food Quality*, vol. 2022, Article ID 6987569, 8 pages, 2022. doi: 10.1155/2022/6987569

[24] C. M. Anoruo, S. N. H. Bukhari, and O. K. Nwofor, "Modeling and Spatial Characterization of Aerosols at Middle East AERONET Stations," *Theoretical and Applied Climatology*, vol. 152, pp. 617–625, 2023. doi: 10.1007/s00704-023-04384-6

[25] F. Masoodi, M. Quasim, S. Bukhari, S. Dixit, and S. Alam, *Applications of Machine Learning and Deep Learning on Biological Data*, CRC Press, 2023.

[26] S. N. H. Bukhari, A. Jain, and E. Haq, "A Novel Ensemble Machine Learning Model for Prediction of Zika Virus T-Cell Epitopes," in Gupta, D., Polkowski, Z., Khanna, A., Bhattacharyya, S., and Castillo, O. (Eds.), *Proceedings of Data Analytics and Management. Lecture Notes on Data Engineering and Communications Technologies*, vol 91. Springer, Singapore, 2022. doi: 10.1007/978-981-16-6285-0_23

[27] S. N. H. Bukhari, F. Masoodi, M. A. Dar, N. I. Wani, A. Sajad, and G. Hussain, "Prediction of Erythemato-Squamous Diseases Using Machine Learning" in *Auerbach Publications eBooks*, pp. 87–96, 2023. doi: 10.1201/9781003328780-6

[28] S. N. H. Bukhari, A. Jain, E. Haq, A. Mehbodniya, & J. Webber, "Machine Learning Techniques for the Prediction of B-Cell and T-Cell Epitopes as Potential Vaccine Targets with a Specific Focus on SARS-CoV-2 Pathogen: A Review," *Pathogens*, vol. 11, no. 2, p. 146, 2022. MDPI AG. doi: 10.3390/pathogens11020146

[29] S. Nisar, H. Bukhari, and M. A. Dar, "Using Random Forest to Predict T-Cell Epitopes of Dengue Virus," *Advances and Applications in Mathematical Sciences*, vol. 20, no. 11, pp. 2543–2547, 2021

CHƯƠNG 15: HỌC TĂNG CƯỜNG SÂU CHO TƯỚI TIÊU THÔNG MINH

Aakansha Khanna Đại học Chandigarh, Ludhiana, Ấn Độ

Inzimam Ul Hassan Đại học Toàn cầu Vivekananda, Jaipur, Ấn Độ

15.1 GIỚI THIỆU

Canh tác dựa trên dữ liệu là một ý tưởng đột phá được sinh ra từ sự kết hợp giữa công nghệ tiên tiến với các phương pháp canh tác truyền thống nhằm theo đuổi nền nông nghiệp bền vững và quản lý tài nguyên hiệu quả. Cốt lõi của sự thay đổi này là việc kết hợp các công cụ Trí tuệ nhân tạo (AI) và Học máy (ML) vào các hoạt động canh tác thông thường.

Trong cuốn sách *Canh tác dựa trên dữ liệu: Khai thác sức mạnh của AI và Học máy trong Nông nghiệp*, chúng tôi khám phá nhiều cách mà AI và ML đang cách mạng hóa nông nghiệp, và trong chương này, chúng tôi xem xét một trong những ứng dụng hứa hẹn nhất của nó: Học tăng cường sâu cho Tưới tiêu Thông minh.

Tình trạng khan hiếm nước là một vấn đề nghiêm trọng ảnh hưởng đến toàn thế giới, đặc biệt là ngành nông nghiệp. Khi dân số thế giới mở rộng, nhu cầu về lương thực tăng lên, đặt gánh nặng lớn lên nguồn cung cấp nước vốn đã hạn chế của hành tinh. Tìm kiếm sự cân bằng giữa yêu cầu duy trì sản xuất cây trồng và sử dụng nước một cách có đạo đức là một thách thức. Các phương pháp tưới tiêu thông thường, thường dựa trên lịch trình định trước hoặc trực giác của con người, có thể cực kỳ kém hiệu quả, gây lãng phí nước, tăng chi phí và có khả năng làm giảm năng suất cây trồng.

Trong tình huống này, Học tăng cường sâu (DRL), một nhánh của ML, cung cấp một câu trả lời mang tính cách mạng. DRL cho phép các hệ thống tưới tiêu thông minh đưa ra các quyết định dựa trên dữ liệu trong thời gian thực bằng cách cho phép các hệ thống học hỏi và thích ứng với các điều kiện môi trường thay đổi. Chương này giải thích cách DRL có khả năng tối ưu hóa các hệ thống tưới tiêu, góp phần rất lớn vào sự thay đổi mô hình trong nông nghiệp theo hướng bảo tồn tài nguyên và canh tác chính xác.

Chúng tôi bắt đầu bằng cách đưa ra một cái nhìn tổng quan kỹ lưỡng về những khó khăn do các kỹ thuật tưới tiêu thông thường đặt ra và các hậu quả tiềm ẩn của việc quản lý nguồn nước kém. Sau đó, các nguyên tắc cơ bản của DRL được thảo luận, cho thấy cách nó cho phép máy móc khám phá các hệ thống tưới tiêu tốt nhất thông qua thử và sai, đồng thời tính đến một loạt các đặc điểm môi trường như giống cây trồng, độ ẩm của đất và các kiểu thời tiết.

Chương này sẽ xem xét các nghiên cứu điển hình trong thế giới thực và các minh họa về việc cài đặt hệ thống tưới tiêu thông minh dựa trên DRL thành công để chứng minh các lợi ích thực tế mà các hệ thống này mang lại cho nông dân, môi trường và bối cảnh nông

nghiệp toàn cầu. Những khó khăn và các yếu tố cần được xem xét khi triển khai các hệ thống như vậy trên quy mô rộng, chẳng hạn như thu thập dữ liệu, công nghệ cảm biến và các rào cản chấp nhận, sẽ được đề cập.

Chúng tôi hy vọng sẽ giới thiệu không chỉ lời hứa của AI và ML trong nông nghiệp mà còn cả vai trò quan trọng của chúng trong việc giải quyết một số vấn đề quan trọng nhất mà hành tinh của chúng ta đang phải đối mặt khi chúng ta bắt đầu hành trình vào thế giới Học tăng cường sâu cho Tưới tiêu Thông minh. Chúng tôi mở đường cho một tương lai bền vững, hiệu quả và năng suất hơn bằng cách sử dụng sức mạnh của dữ liệu và công nghệ.

DRL có tiềm năng đáng kể trong lĩnh vực nông nghiệp. DRL có thể được sử dụng để tối đa hóa năng suất cây trồng. Nó có thể giúp tự động hóa nhiều tác vụ/tác vụ phụ để canh tác bền vững và dẫn đường cho các giải pháp nông nghiệp có thể mở rộng. Các giải pháp AI dựa trên DRL có thể được sử dụng để phát hiện sản phẩm cây trồng. Các khung được thiết kế có thể được sử dụng để tự động hóa và kiểm soát các quy trình canh tác dựa trên nhà kính. Để phát triển một con đường hướng tới nền nông nghiệp bền vững, các loài thực vật mới đang được phát triển với sự trợ giúp của DRL. Những thiết kế mới này có thể có tác động sâu rộng đến năng suất nông nghiệp và môi trường.

Mô hình học sâu (DL) có giá trị ứng dụng quan trọng trong phân loại, phát hiện, đếm cây trồng và ước tính năng suất trong nông nghiệp. So với ML truyền thống, công nghệ DL đã cải thiện hiệu suất của phân tích hình ảnh siêu phổ (hyperspectral).

Dưới đây là một số lý do chính tại sao DRL quan trọng trong nông nghiệp:

- **Tối ưu hóa Quản lý Tài nguyên:** DRL có thể tối ưu hóa việc phân bổ các nguồn tài nguyên quan trọng trong nông nghiệp, chẳng hạn như nước, phân bón và thuốc trừ sâu. Bằng cách tự động điều chỉnh việc tưới tiêu và cung cấp chất dinh dưỡng dựa trên dữ liệu thời gian thực, DRL giúp giảm thiểu lãng phí, giảm chi phí và tối đa hóa việc sử dụng tài nguyên.
- **Nông nghiệp Chính xác:** DRL cho phép canh tác chính xác bằng cách điều chỉnh các hành động cho phù hợp với các điều kiện cụ thể trên đồng ruộng. Nó xem xét các biến số như độ ẩm của đất, các kiểu thời tiết, sức khỏe cây trồng và dữ liệu lịch sử để đưa ra các quyết định sáng suốt, cuối cùng dẫn đến năng suất và chất lượng cây trồng cao hơn.
- **Bảo tồn Nước:** Các hệ thống tưới tiêu dựa trên DRL đảm bảo rằng nước được áp dụng chính xác khi nào và ở đâu cần thiết, giúp giảm tiêu thụ nước và tác động môi trường của việc canh tác.
- **Tác động Môi trường:** DRL góp phần giảm dấu chân môi trường của nông nghiệp. Việc sử dụng các đầu vào được tối ưu hóa và giảm thiểu dòng chảy hóa chất, dẫn đến các phương pháp canh tác thân thiện với môi trường và bền vững hơn.

- **Có thể Tăng năng suất Cây trồng:** Sử dụng DRL để tối ưu hóa tưới tiêu, bón phân và quản lý côn trùng có thể tăng năng suất cây trồng. DRL hỗ trợ nông dân sản xuất nhiều hơn với chi phí ít hơn bằng cách đảm bảo rằng cây trồng nhận được nguồn cung cấp thích hợp vào đúng thời điểm.
- **Ra quyết định trong Thời gian thực:** Từ các kiểu thời tiết đến dịch hại bùng phát, các điều kiện nông nghiệp luôn thay đổi. Các hệ thống DRL cho phép nông dân phản ứng nhanh chóng và thành công với những thay đổi này bằng cách đưa ra quyết định trong thời gian thực.
- **Tiết kiệm Lao động:** Tự động hóa dựa trên DRL có thể làm giảm nhu cầu lao động thủ công trong nông nghiệp. Ví dụ, sử dụng máy bay không người lái tự hành với các thuật toán DRL có thể giám sát và quản lý cây trồng đồng thời tiết kiệm chi phí lao động liên quan đến các phương pháp canh tác thông thường.
- **Thông tin chi tiết dựa trên Dữ liệu:** DRL tạo ra một lượng lớn dữ liệu, có thể được kiểm tra để tìm hiểu thông tin quan trọng về sức khỏe của đất, phát hiện bệnh tật và hiệu suất cây trồng. Các hoạt động canh tác dài hạn và việc ra quyết định có thể bị ảnh hưởng bởi những hiểu biết này.
- **Thích ứng với Biến đổi Khí hậu:** Các tác động của biến đổi khí hậu, chẳng hạn như các kiểu thời tiết thất thường và thay đổi mùa sinh trưởng, đặc biệt gây hại cho nông nghiệp. Bằng cách điều chỉnh các phương pháp canh tác cho phù hợp với các điều kiện thay đổi, DRL có thể hỗ trợ nông dân điều chỉnh theo những thay đổi này.

15.1.1 Các phương pháp Tưới tiêu Truyền thống và Hạn chế

Các kỹ thuật tưới tiêu truyền thống đã là trụ cột của nông nghiệp trong nhiều thiên niên kỷ, hỗ trợ các nền văn minh và nuôi sống dân số thế giới. Những kỹ thuật truyền thống này, được xây dựng dựa trên kiến thức của các thế hệ nông dân đi trước, đã làm dịu cơn khát của cây trồng, biến những đồng bằng khô cằn thành những ốc đảo phong phú và những cánh đồng xanh tươi. Các kỹ thuật tưới tiêu truyền thống đã ảnh hưởng đến cảnh quan và các nền văn minh trên toàn cầu của chúng ta theo những cách cơ bản như chính lớp đất nằm dưới chân chúng ta. Tuy nhiên, chúng có những nhược điểm có thể cản trở hiệu quả và tính bền vững của chúng.

Tưới tiêu theo lịch cố định và ra quyết định tưới tiêu theo trực giác là hai kỹ thuật tưới tiêu truyền thống phổ biến:

- **Tưới tiêu theo Lịch cố định:** Sử dụng phương pháp tưới tiêu theo lịch cố định, nông dân tưới nước cho cây trồng của họ theo lịch hoặc thời gian biểu đã được thiết lập trước. Thay vì sử dụng dữ liệu thời gian thực, phương pháp này thường dựa trên các quy ước và giả định trước đây. Dưới đây là một vài nhược điểm của nó:

    - Lịch cố định không hiệu quả vì chúng không tính đến những thay đổi về độ ẩm của đất, thời tiết hoặc yêu cầu về nước của cây trồng. Điều này có thể dẫn đến việc sử dụng nước lãng phí và thiệt hại tiềm ẩn cho sức khỏe cây trồng do tưới quá nhiều hoặc quá ít.
    - Tưới quá nhiều có thể dẫn đến sử dụng nước quá mức, làm tăng chi phí vận hành và có tác động tiêu cực đến môi trường, chẳng hạn như xói mòn đất và rửa trôi chất dinh dưỡng.
    - Mặt khác, tưới quá ít có thể gây căng thẳng cho cây trồng, giảm năng suất và ảnh hưởng đến chất lượng cây trồng nói chung.
    - Lịch cố định không thích ứng với các điều kiện thay đổi, chẳng hạn như mưa đột ngột hoặc biến động nhiệt độ bất ngờ. Sự thiếu thích ứng này có thể dẫn đến các quyết định tưới tiêu kém.
- **Ra quyết định Tưới tiêu theo Trực giác:** Để quyết định khi nào và bao nhiêu nước để tưới, nông dân sử dụng phương pháp ra quyết định tưới tiêu theo trực giác, dựa trên kinh nghiệm, kiến thức và phán đoán của họ. Mặc dù những người nông dân có kiến thức thường hiểu thấu đáo về cây trồng và địa hình của họ, chiến lược này có những hạn chế:
    - Các phán đoán trực quan của nông dân là cá nhân và dễ thay đổi. Các yêu cầu chính xác của cây trồng hoặc dữ liệu khoa học có thể không phải lúc nào cũng thống nhất với nó.
    - Nông dân đôi khi có thể đưa ra các phán đoán kém về lượng độ ẩm của đất hiện có hoặc không tính đến các kiểu thời tiết thay đổi.
    - Chỉ dựa vào phán đoán của con người có thể tốn thời gian vì nó đòi hỏi phải kiểm tra đồng ruộng liên tục và điều chỉnh thủ công các hệ thống tưới tiêu.

Trong lĩnh vực thực hành tưới tiêu truyền thống, một nghịch lý đang diễn ra: Mặc dù các phương pháp này đã nuôi dưỡng cây trồng và các nền văn minh trong nhiều thế kỷ, chúng không phải là không có những kém hiệu quả cố hữu và những thách thức hậu quả. Trong phần này, chúng ta sẽ đi sâu vào sự phức tạp của những sự kém hiệu quả này và những hậu quả sâu rộng mà chúng áp đặt lên nông nghiệp và môi trường.

15.1.2 Tìm hiểu về Học tăng cường sâu

Trong lĩnh vực AI và ML, DRL đứng như một ngọn hải đăng của sự đổi mới, cung cấp một con đường để máy móc không chỉ học hỏi từ dữ liệu mà còn tương tác và thích ứng với các môi trường phức tạp. Bắt nguồn từ sự kết hợp của các nguyên tắc học tăng cường (RL) và mạng nơ-ron sâu, DRL đại diện cho một bước nhảy vọt đáng gờm trong nỗ lực truyền cho máy móc khả năng đưa ra các quyết định tuần tự, giải quyết các nhiệm vụ phức tạp và đạt được kết quả tối ưu trong vô số lĩnh vực.

DRL về cơ bản là một phương pháp học bằng cách làm. Nó sử dụng cùng một ý tưởng thử và sai, vốn từ lâu đã là cơ sở của việc học tập của con người. Một thực thể thông minh giống như nhà thám hiểm kỹ thuật số được thả lỏng trong một thế giới đầy cơ hội và trở ngại. Mục đích của nó? Thực hiện các hành động, theo dõi kết quả, và, thông qua một quá trình cải tiến liên tục, xác định các kỹ thuật tối ưu hóa phần thưởng để điều hướng địa hình này. Những lợi ích này hoạt động như một la bàn chỉ cho tác nhân (agent) đi đúng hướng đến mục tiêu cuối cùng của nó.

Một số thành phần chính của DRL:

- **Tác nhân (Agent):** Một thực thể có thể nhận thức/khám phá môi trường và hành động dựa trên nó.
- **Môi trường (Environment):** Thế giới mà tác nhân di chuyển qua và là nơi tác nhân nhận được phản hồi.
- **Hành động (Actions):** Các bước mà tác nhân thực hiện khi di chuyển trong môi trường.
- **Phần thưởng (Rewards):** Phản hồi mà tác nhân nhận được do kết quả của các hành động của mình. Phản hồi tích cực được đưa ra cho các hành động tốt, và phản hồi tiêu cực hoặc hình phạt được đưa ra cho các hành động xấu.
- **Chính sách (Policy):** Chiến lược mà tác nhân sử dụng để xác định hành động tiếp theo dựa trên trạng thái hiện tại.
- **Hàm Giá trị (Value Function):** Một dự đoán về các phần thưởng trong tương lai. Nó được sử dụng để đánh giá mỗi trạng thái về mức độ tốt cho tác nhân khi ở trạng thái đó.
- **Hàm Q hoặc Hàm Giá trị-Hành động (Q-function or Action-Value Function):** Tương tự như hàm giá trị nhưng có thêm một tham số, hành động hiện tại. Hàm Q đưa ra phần thưởng tương lai dự kiến cho hành động đó được thực hiện ở trạng thái hiện tại.

15.1.2.1 Giới thiệu về Học sâu

Một nhánh của ML được gọi là "học sâu" (DL) đã vươn lên dẫn đầu trong lĩnh vực AI, thay đổi cách thức phân tích dữ liệu, phát hiện mẫu và ra quyết định được thực hiện. DL về cơ bản là một tập hợp các phương pháp và thuật toán được rút ra từ cấu trúc và hoạt động của bộ não con người, đặc biệt là mạng nơ-ron. Nó vượt trội trong việc xử lý các tập dữ liệu lớn, phức tạp, cho phép máy tính xác định các mẫu, dự đoán kết quả và thực hiện các tác vụ trước đây được cho là không thể.

Đặc điểm nổi bật của DL là việc sử dụng các mạng nơ-ron sâu, bao gồm nhiều lớp nơ-ron nhân tạo được kết nối với nhau. Các mạng này đã chứng tỏ sức mạnh đáng kể trong các lĩnh vực khác nhau, bao gồm nhận dạng hình ảnh và giọng nói, xử lý ngôn ngữ tự nhiên, xe tự hành và chẩn đoán y tế. Dấu hiệu đặc trưng của mạng nơ-ron sâu là khả năng tự động học các đặc trưng và biểu diễn phức tạp từ dữ liệu thô, loại bỏ sự cần thiết của việc thiết kế đặc trưng thủ công (hand-crafted feature engineering).

15.1.2.2 Kết hợp Học sâu và Học tăng cường

Sự kết hợp giữa DL và RL nổi lên như một sự kết hợp mạnh mẽ và có khả năng thích ứng trong bức tranh thảm rộng lớn của AI, nơi các vấn đề khác nhau đòi hỏi các câu trả lời linh hoạt. Cơ sở để lĩnh hội và hiển thị các mẫu phức tạp trong dữ liệu thô được cung cấp bởi DL. Các mạng nơ-ron sâu của nó đặc biệt tốt trong các tác vụ liên quan đến nhận thức, bao gồm xác định các đối tượng trong ảnh hoặc giải mã văn bản. DL rất quan trọng trong các giai đoạn đầu của việc ra quyết định vì khả năng xử lý đầu vào cảm quan.

Mặt khác, RL bổ sung cho DL bằng cách tập trung vào việc ra quyết định tuần tự trong các môi trường động. Nó giới thiệu khái niệm về một tác nhân tương tác với môi trường để học các hành động tối ưu thông qua thử và sai. Các thuật toán RL nhằm mục đích tối đa hóa tín hiệu phần thưởng tích lũy theo thời gian, khiến chúng rất phù hợp cho các tác vụ đòi hỏi một chuỗi các hành động hoặc chiến lược.

Khi DL và RL kết hợp lực lượng, chúng tạo ra một mối quan hệ cộng sinh tận dụng điểm mạnh của cả hai mô hình:

- **Trích xuất Đặc trưng:** DL có thể được sử dụng để tiền xử lý dữ liệu cảm biến thô (ví dụ: hình ảnh, âm thanh và văn bản) và trích xuất các biểu diễn có ý nghĩa. Những biểu diễn này đóng vai trò là đầu vào có giá trị cho các tác nhân RL, nâng cao khả năng diễn giải và điều hướng các môi trường phức tạp của chúng.
- **Xấp xỉ Chính sách:** Mạng nơ-ron sâu có thể được sử dụng để xấp xỉ hàm chính sách trong RL. Điều này cho phép các tác nhân RL học các không gian hành động liên tục, có chiều cao một cách hiệu quả, cho phép chúng giải quyết các tác vụ liên quan đến kiểm soát chi tiết hoặc các hành động phức tạp.
- **Xấp xỉ Hàm Giá trị:** DL hỗ trợ xấp xỉ các hàm giá trị trong RL, ước tính các phần thưởng tích lũy dự kiến. Mạng Q-Sâu (DQN) và các biến thể như Double DQN tận dụng mạng nơ-ron sâu để xử lý các không gian trạng thái có chiều cao.
- **Học tập Từ đầu đến cuối (End-to-End Learning):** Sự kết hợp giữa DL và RL cho phép học tập từ đầu đến cuối, trong đó toàn bộ quy trình ra quyết định, từ nhận thức đến hành động, được học trực tiếp từ dữ liệu. Phương pháp này đã tìm thấy thành công trong các ứng dụng như robot và xe tự hành.
- **Học chuyển giao (Transfer Learning):** Các mô hình DL được đào tạo trước trên các bộ dữ liệu lớn có thể được tinh chỉnh cho các tác vụ RL, cho phép các tác nhân hưởng lợi từ các biểu diễn phong phú đã học được trên các lĩnh vực khác nhau. Kỹ thuật này, được gọi là học chuyển giao, giúp tăng tốc đào tạo RL và nâng cao hiệu suất của nó.

15.1.3 Học tăng cường sâu cho Tưới tiêu Thông minh

Trong lĩnh vực nông nghiệp không ngừng phát triển, việc tìm kiếm các phương pháp tưới tiêu hiệu quả và bền vững đã mang một tầm quan trọng mới. Với dân số toàn cầu ngày

càng tăng và các thách thức môi trường ngày càng gia tăng, nhu cầu tối ưu hóa việc sử dụng tài nguyên nước trong canh tác chưa bao giờ lớn hơn. Hãy tham gia DRL, một công nghệ tiên tiến có tiềm năng cách mạng hóa cách chúng ta tiếp cận tưới tiêu thông minh.

Tưới tiêu thông minh vượt qua các phương pháp truyền thống bằng cách nắm bắt sức mạnh của việc ra quyết định dựa trên dữ liệu. Nó tận dụng DRL, một tập hợp con của AI, để biến việc tưới tiêu thành một quy trình động và thông minh. Về bản chất, DRL cho tưới tiêu thông minh đại diện cho sự hội tụ của các thuật toán tinh vi, dữ liệu thời gian thực và chuyên môn nông nghiệp, tất cả hoạt động hài hòa để đạt được các mục tiêu kép là hiệu quả tài nguyên và năng suất cây trồng.

- **Phân bổ Tài nguyên:** Về cốt lõi, tưới tiêu thông minh được kích hoạt bởi DRL nhằm mục đích tối ưu hóa chính xác việc phân phối các nguồn tài nguyên vô giá như nước và chất dinh dưỡng. Các hệ thống hỗ trợ DRL đưa ra các quyết định thông minh, dựa trên dữ liệu bằng cách tính đến các biến số bao gồm mức độ ẩm của đất, các kiểu thời tiết và sức khỏe cây trồng trong thời gian thực.
- **Bảo tồn Nước:** Các hệ thống tưới tiêu dựa trên DRL nổi lên như một tia hy vọng trong thời điểm mà các mối lo ngại về khan hiếm nước đang gia tăng. Chúng giảm lãng phí nước, giảm tác động môi trường và hỗ trợ bảo tồn nước có trách nhiệm trong nông nghiệp bằng cách cung cấp nước chính xác ở đâu và khi nào cần thiết.
- **Tăng năng suất Cây trồng:** Tưới tiêu dựa trên DRL vượt qua các kỹ thuật truyền thống. Nó điều phối một bản giao hưởng tăng trưởng lý tưởng ngoài việc giữ cho cây trồng ngậm nước. Nó thúc đẩy cây trồng khỏe mạnh hơn, năng suất cao hơn và chất lượng cây trồng cao hơn bằng cách đảm bảo rằng cây trồng nhận được các vật liệu thích hợp với số lượng thích hợp.
- **Thích ứng Thời gian thực:** Trong thế giới nông nghiệp, mọi thứ có thể thay đổi nhanh chóng, từ thay đổi nhiệt độ bất ngờ đến các cơn mưa rào không liên tục. Nông dân có thể di chuyển nhanh chóng, chính xác và nhanh nhẹn qua những cảnh quan thay đổi này nhờ khả năng đặc biệt của DRL là đưa ra các phán đoán trong thời gian thực.

15.1.3.1 Điều chỉnh DRL cho Nông nghiệp

Việc áp dụng DRL vào nông nghiệp đại diện cho một sự kết hợp thành công của sự đổi mới vào một lĩnh vực chứa đầy các truyền thống lâu đời chứ không chỉ đơn thuần là chuyển giao công nghệ. Quá trình thích ứng này là một hành trình đầy trở ngại, cơ hội và các kết quả biến đổi.

- **Chuyên môn về Lĩnh vực:** Việc điều chỉnh DRL cho nông nghiệp đòi hỏi kiến thức thấu đáo về các nguyên tắc nông học, phương pháp canh tác và hệ sinh thái. Để thu hẹp khoảng cách giữa lý thuyết và thực hành, sự hợp tác giữa các chuyên gia về lĩnh vực và các nhà nghiên cứu Al trở nên quan trọng.
- **Hợp nhất Dữ liệu:** Nông nghiệp tạo ra một lượng lớn dữ liệu, bao gồm các phép đo chất lượng đất, dự đoán thời tiết và đánh giá sức khỏe cây trồng. Việc sử dụng

sự đa dạng của dữ liệu này và kết hợp nó thành những hiểu biết sâu sắc có thể được đưa vào sử dụng để hướng dẫn các phương pháp tưới tiêu là một phần của việc điều chỉnh DRL.

- **Công nghệ Cảm biến:** Việc triển khai công nghệ cảm biến là một mấu chốt trong quá trình thích ứng. Dữ liệu chính xác và kịp thời từ các cảm biến độ ẩm của đất, trạm thời tiết và các hệ thống hình ảnh từ xa trao quyền cho các thuật toán DRL để đưa ra các quyết định sáng suốt.
- **Khả năng mở rộng:** Nông nghiệp bao gồm các quy mô đa dạng, từ các trang trại gia đình nhỏ đến các doanh nghiệp nông nghiệp rộng lớn. Điều chỉnh DRL liên quan đến việc thiết kế các hệ thống có thể mở rộng liền mạch để đáp ứng các nhu cầu riêng biệt của mỗi hoạt động canh tác.
- **Tích hợp với các Phương pháp Canh tác:** Sự thích ứng thành công của DRL phụ thuộc vào sự tích hợp của nó vào các phương pháp canh tác hiện có. Nó phải bổ sung cho sự khôn ngoan của những người nông dân có kinh nghiệm, tăng cường khả năng ra quyết định của họ thay vì thay thế nó.

15.1.3.2 Học các Chiến lược Tưới tiêu Tối ưu

Học các chiến lược tưới tiêu tối ưu thông qua DRL đại diện cho đỉnh cao tiềm năng của Al trong nông nghiệp. Đó là một hành trình hướng tới sự chính xác, hiệu quả và bền vững trong canh tác cây trồng.

- **Ra quyết định dựa trên Dữ liệu:** Các hệ thống DRL học hỏi từ các kinh nghiệm dựa trên dữ liệu, liên tục tối ưu hóa các chiến lược tưới tiêu dựa trên thông tin thời gian thực. Phương pháp này thay thế trực giác bằng bằng chứng thực nghiệm, dẫn đến việc ra quyết định vượt trội.
- **Phân bổ Tài nguyên Phù hợp:** Việc tìm kiếm tưới tiêu tối ưu liên quan đến việc phân bổ hợp lý các nguồn tài nguyên. DRL tính toán lượng nước, chất dinh dưỡng và các đầu vào khác cần thiết một cách chính xác cho từng khu vực của cánh đồng, đảm bảo hiệu quả tài nguyên và tiết kiệm chi phí.
- **Phương pháp tiếp cận Lấy Cây trồng làm Trung tâm:** Các chiến lược tưới tiêu tối ưu ưu tiên sức khỏe và sự phát triển của cây trồng. DRL đảm bảo rằng các quyết định tưới tiêu phù hợp với các nhu cầu riêng biệt của từng loại cây trồng, giai đoạn sinh trưởng và điều kiện môi trường.
- **Khả năng phục hồi và Thích ứng:** Quá trình học tập không tĩnh; nó thích ứng với các điều kiện thay đổi. Các hệ thống DRL được trang bị để ứng phó với sự thay đổi thời tiết đột ngột, dịch hại bùng phát hoặc thay đổi điều kiện đất đai, đảm bảo khả năng phục hồi của cây trồng và ổn định năng suất.

15.1.3.3 Các Yếu tố được Xem xét khi Ra quyết định cho Tưới tiêu Thông minh

Trong bối cảnh nông nghiệp hiện đại, nghệ thuật tưới tiêu đã phát triển thành một khoa học, được hướng dẫn không chỉ bởi sự khôn ngoan của những người nông dân có kinh nghiệm mà còn bởi sự giàu có của những hiểu biết dựa trên dữ liệu. Tưới tiêu thông

minh, được củng cố bởi các công nghệ tiên tiến và các thuật toán ra quyết định, đại diện cho một sự thay đổi mô hình trong cách chúng ta nuôi dưỡng cây trồng, bảo tồn tài nguyên và thúc đẩy tính bền vững.

Tại trung tâm của cuộc cách mạng nông nghiệp này là mạng lưới phức tạp của các yếu tố được xem xét khi ra quyết định cho tưới tiêu thông minh. Những yếu tố này là các điểm la bàn hướng dẫn các chiến lược tưới tiêu, biến những gì đã từng là một thực hành thủ công, dựa trên trực giác thành một kỷ luật chính xác, dựa trên dữ liệu.

- **Mức độ Ẩm của Đất:** Giám sát độ ẩm của đất là nền tảng cho tưới tiêu thông minh. Các cảm biến được nhúng trong đất cung cấp dữ liệu thời gian thực về hàm lượng độ ẩm, cho phép người ra quyết định xác định xem có cần tưới tiêu hay không và khi nào.
- **Điều kiện Thời tiết:** Dữ liệu thời tiết, bao gồm nhiệt độ, độ ẩm, tốc độ gió và dự báo lượng mưa, đóng một vai trò quan trọng trong các quyết định tưới tiêu. Ví dụ, dự đoán mưa có thể dẫn đến việc điều chỉnh tưới tiêu để tránh tưới quá nhiều.
- **Loại Cây trồng và Giai đoạn Sinh trưởng:** Các loại cây trồng khác nhau có yêu cầu nước khác nhau ở các giai đoạn sinh trưởng khác nhau. Việc ra quyết định xem xét các nhu cầu cụ thể của từng loại cây trồng để tối ưu hóa lịch trình tưới tiêu.
- **Điều kiện Môi trường:** Các yếu tố như tỷ lệ thoát hơi nước (sự mất nước từ đất và thực vật), bức xạ mặt trời và gió ảnh hưởng đến nhu cầu nước và phải được tính đến trong các quyết định tưới tiêu.
- **Địa hình và Loại Đất:** Địa hình và loại đất của cánh đồng ảnh hưởng đến sự phân phối nước. Việc ra quyết định tính đến các yếu tố này để đảm bảo tưới tiêu đồng đều trên toàn bộ diện tích.
- **Nguồn nước và Tính sẵn có:** Nguồn nước, có thể là nước ngầm, nước mặt, hoặc kênh tưới, ảnh hưởng đến tính sẵn có và chi phí. Người ra quyết định xem xét tính bền vững của nguồn nước và các chi phí liên quan.
- **Quy định Địa phương:** Các hoạt động nông nghiệp thường phải tuân theo các quy định của địa phương về việc sử dụng nước. Việc tuân thủ các quy định này là điều cần thiết trong việc ra quyết định.
- **Phân tích Chi phí:** Các cân nhắc về kinh tế là rất quan trọng. Người ra quyết định đánh giá chi phí nước, năng lượng để bơm và bảo trì thiết bị tưới tiêu để tối ưu hóa việc phân bổ tài nguyên.
- **Dữ liệu Lịch sử:** Các thực hành tưới tiêu trong quá khứ và dữ liệu hiệu suất cây trồng cung cấp những hiểu biết có giá trị cho việc ra quyết định trong tương lai. Dữ liệu lịch sử giúp tinh chỉnh các chiến lược tưới tiêu.
- **Giám sát Sức khỏe Cây trồng:** Dữ liệu thời gian thực về sức khỏe cây trồng, chẳng hạn như phát hiện bệnh và mức độ căng thẳng, có thể kích hoạt các điều chỉnh tưới tiêu để giải quyết kịp thời các nhu cầu của thực vật.

15.1.3.4 Dữ liệu Thời gian thực và Công nghệ Cảm biến

Trong lĩnh vực nông nghiệp, nơi mọi khoảnh khắc đều có giá trị và mọi nguồn lực đều quý giá, sức mạnh của dữ liệu thời gian thực và các công nghệ cảm biến đã nổi lên như một ngọn hải đăng của sự đổi mới. Trong quá khứ không xa, canh tác dựa vào truyền thống và kinh nghiệm, nhưng ngày nay, nó được nâng tầm bởi một dàn nhạc của các cảm biến, vệ tinh và các thiết bị được kết nối với nhau, thổi sức sống vào các cánh đồng. Hãy tưởng tượng một thế giới nơi mỗi mẫu đất, mỗi cái cây, và mỗi giọt nước nói lên ngôn ngữ độc đáo của riêng mình thông qua dữ liệu.

Bản giao hưởng thông tin này, được điều phối bởi một mạng lưới các cảm biến và các công nghệ tiên tiến, vượt qua ranh giới nhận thức của con người, cung cấp những hiểu biết chưa từng có về thế giới tự nhiên. Dữ liệu thời gian thực và các công nghệ cảm biến là kiến trúc sư của sự chuyển đổi này. Chúng phục vụ như tai mắt của nông nghiệp hiện đại, thu thập và chuyển tiếp một luồng thông tin liên tục về môi trường, cây trồng và điều kiện đất đai.

Bằng cách đó, chúng trao quyền cho nông dân và những người quản lý đất đai với kiến thức cần thiết để đưa ra các quyết định sáng suốt trong một bối cảnh nông nghiệp năng động và luôn thay đổi. Trong các trang tiếp theo, chúng ta bắt đầu một cuộc hành trình vào trung tâm của dữ liệu thời gian thực và các công nghệ cảm biến. Chúng ta khám phá các cảm biến thăm dò độ sâu của đất, các vệ tinh nhìn chằm chằm vào hành tinh của chúng ta từ trên cao, và các phân tích dữ liệu thổi trí thông minh vào thông tin thô. Cùng nhau, chúng ta khám phá ra một thế giới nơi dữ liệu không chỉ là một nguồn tài nguyên mà còn là một huyết mạch - một huyết mạch nuôi dưỡng cây trồng, bảo tồn tài nguyên, và vạch ra con đường hướng tới một tương lai bền vững và thịnh vượng cho nông nghiệp.

- **Cảm biến Độ ẩm của Đất:** Các cảm biến này được nhúng trong đất để liên tục theo dõi độ ẩm ở các độ sâu khác nhau. Dữ liệu thời gian thực từ các cảm biến này hướng dẫn các quyết định về thời điểm và lượng nước tưới.
- **Trạm Thời tiết:** Các trạm thời tiết thu thập dữ liệu về nhiệt độ, độ ẩm, tốc độ gió và lượng mưa. Dữ liệu này rất quan trọng để hiểu các điều kiện thời tiết hiện tại và dự đoán các xu hướng trong tương lai.
- **Vệ tinh và Viễn thám:** Hình ảnh vệ tinh và các công nghệ viễn thám cung cấp một cái nhìn bao quát về sức khỏe cây trồng, độ ẩm và các chỉ số thảm thực vật trên các khu vực rộng lớn. Chúng cung cấp những hiểu biết sâu sắc về điều kiện chung của cánh đồng.
- **Thiết bị IoT (Internet of Things):** Các thiết bị IoT, bao gồm các cảm biến thời tiết được kết nối, màn hình theo dõi đất và máy bay không người lái, cung cấp một mạng lưới các nguồn dữ liệu thời gian thực cho phép người ra quyết định thực hiện các điều chỉnh chính xác.
- **Phân tích Dữ liệu và AI:** Các kỹ thuật phân tích dữ liệu tiên tiến và AI xử lý các luồng dữ liệu thời gian thực từ các cảm biến để tạo ra những hiểu biết có thể hành động và tối ưu hóa các quyết định tưới tiêu.

- **Ứng dụng Di động và Bảng điều khiển:** Người ra quyết định thường truy cập dữ liệu thời gian thực thông qua các ứng dụng di động và bảng điều khiển dựa trên web. Những công cụ này cung cấp một giao diện thân thiện với người dùng để giám sát và điều chỉnh tưới tiêu từ xa.
- **Hệ thống Tự động hóa và Điều khiển:** Các hệ thống tưới tiêu thông minh thường được trang bị các hệ thống tự động hóa và điều khiển có thể hành động dựa trên dữ liệu thời gian thực, điều chỉnh các van tưới và máy bơm khi cần thiết mà không cần can thiệp thủ công.
- **Mạng Truyền thông:** Các mạng truyền thông đáng tin cậy, bao gồm không dây và di động, đảm bảo rằng dữ liệu thời gian thực được truyền từ các cảm biến đến người ra quyết định và các hệ thống điều khiển một cách liền mạch.

15.1.4 Áp dụng DRL vào Tưới tiêu Thông minh

Học tăng cường sâu (DRL) đã cho thấy tiềm năng đáng kể trong việc cải thiện lịch trình tưới tiêu trong các hệ thống canh tác khác nhau. Mục tiêu là khám phá ra một quy tắc quyết định thông minh xử lý thông tin có sẵn cho người trồng và đưa ra lượng nước tưới hợp lý. Ví dụ, một hệ thống gọi là Học tăng cường sâu để Kiểm soát Tưới tiêu (DRLIC) sử dụng mạng nơ-ron (tác nhân kiểm soát DRL) để học một chính sách kiểm soát tối ưu, có tính đến cả phép đo độ ẩm đất hiện tại và sự mất độ ẩm đất trong tương lai.

Trong một nghiên cứu khác, một hệ thống tưới tiêu dựa trên IoT đã được đề xuất, bao gồm hai thành phần chính: một mạng không dây IoT gồm các nút cảm biến và truyền động, và một thuật toán kiểm soát dựa trên DRL. Với dữ liệu độ ẩm của đất và dữ liệu thời tiết được thu thập, thuật toán dựa trên DRL sẽ tìm ra một lịch trình tưới tiêu tối ưu sử dụng lượng nước tối thiểu để đảm bảo hàm lượng nước trong đất trên mức yêu cầu trước chu kỳ tưới tiếp theo.

Các hệ thống này đã chứng minh được hiệu quả của chúng trong các kịch bản thế giới thực. Ví dụ, hệ thống dựa trên IoT đã được triển khai trong một khu vực thử nghiệm bao gồm sáu cây hạnh nhân. Qua một thí nghiệm thực địa kéo dài 12 ngày, người ta thấy rằng hệ thống được đề xuất có thể tiết kiệm tới 7.8% nước so với một chế độ tưới tiêu được sử dụng rộng rãi.

Tóm lại, DRL có thể được áp dụng hiệu quả cho các hệ thống tưới tiêu thông minh để tối ưu hóa việc sử dụng nước và cải thiện hiệu quả nông nghiệp.

15.1.4.1 Hiểu biết về Môi trường: Đất, Thời tiết, Loại Cây trồng

Tưới tiêu phụ thuộc nhiều vào ba yếu tố chính: đất, thời tiết và loại cây trồng.

- **Đất:** Loại đất đóng một vai trò quan trọng trong tưới tiêu, vì các loại đất khác nhau có khả năng giữ nước khác nhau. Các cảm biến dựa trên đất có thể thu thập dữ liệu liên quan về hàm lượng nước theo thể tích, độ mặn, độ dẫn điện và các

thông số quan trọng khác. Hiểu các thông số này có thể giúp xác định lượng nước tối ưu cần thiết cho tưới tiêu.

- **Thời tiết:** Các điều kiện thời tiết ảnh hưởng đáng kể đến các tiêu chí lập lịch tưới tiêu. Các yếu tố như lượng mưa, nhiệt độ, độ ẩm, tốc độ gió và bức xạ mặt trời ảnh hưởng đến tốc độ thoát hơi nước (tổng của sự bốc hơi và thoát hơi nước của thực vật). Giám sát các điều kiện thời tiết này có thể giúp điều chỉnh lịch trình tưới tiêu để đảm bảo cây trồng nhận được lượng nước phù hợp vào đúng thời điểm.
- **Loại Cây trồng:** Các loại cây trồng khác nhau có yêu cầu nước khác nhau. Loại cây trồng quyết định tỷ lệ tưới và bón phân. Một số loại cây trồng có thể chịu hạn tốt hơn những loại khác và có thể cần tưới nước ít thường xuyên hơn. Hiểu rõ nhu cầu nước cụ thể của từng loại cây trồng có thể dẫn đến việc sử dụng nước hiệu quả hơn.

Các hệ thống tưới tiêu thông minh tính đến các yếu tố này để đưa ra các quyết định tưới tiêu tốt hơn. Chúng sử dụng các kỹ thuật AI để xử lý dữ liệu từ các cảm biến đất, thời tiết và thực vật để tối ưu hóa việc sử dụng nước.

15.1.4.2 Xác định các Trạng thái, Hành động và Phần thưởng

- **Trạng thái (State)** trong bối cảnh này đại diện cho tình trạng hiện tại của cánh đồng cần được tưới. Điều này có thể bao gồm các yếu tố như độ ẩm hiện tại của đất, điều kiện thời tiết (như nhiệt độ, độ ẩm, tốc độ gió và bức xạ mặt trời), và loại cây trồng đang được trồng. Những yếu tố này có thể được đo bằng cách sử dụng các cảm biến khác nhau và dữ liệu dự báo thời tiết.
- **Hành động (Action)** trong bối cảnh này là lượng nước được áp dụng cho cánh đồng tại một thời điểm nhất định. Điều này có thể bao gồm từ không tưới nước (trong trường hợp đủ độ ẩm của đất hoặc dự kiến có mưa) đến tưới nhiều nước (trong trường hợp đất khô và tỷ lệ thoát hơi nước cao). Hành động thường được xác định bởi một tác nhân DRL dựa trên trạng thái hiện tại và chính sách đã học.
- **Phần thưởng (Reward)** trong bối cảnh này là một thước đo về mức độ hành động được thực hiện tốt như thế nào trong việc đạt được mục tiêu tưới tiêu tối ưu. Một hàm phần thưởng đơn giản có thể là sự khác biệt giữa độ ẩm mong muốn của đất và độ ẩm thực tế của đất sau khi tưới. Nếu độ ẩm của đất gần với mức mong muốn, một phần thưởng tích cực sẽ được trao. Nếu quá khô hoặc quá ướt, một phần thưởng tiêu cực sẽ được trao. Mục đích của tác nhân DRL là tối đa hóa tổng phần thưởng theo thời gian, dẫn đến một lịch trình tưới tiêu tối ưu.

15.1.4.3 Thiết kế Tác nhân DRL

Thiết kế một tác nhân DRL cho tưới tiêu thông minh bao gồm một số bước:

- **Công thức hóa Vấn đề:** Bước đầu tiên là công thức hóa vấn đề tưới tiêu dưới dạng Quy trình Quyết định Markov (MDP). Điều này liên quan đến việc xác định các trạng thái, hành động và phần thưởng. Như đã thảo luận trước đó, các trạng thái có thể bao gồm độ ẩm của đất, điều kiện thời tiết và các loại cây trồng. Các

hành động có thể là lượng nước cần áp dụng, và phần thưởng có thể dựa trên mức độ đạt được mục tiêu tưới tiêu.

- **Lựa chọn Mô hình DRL:** Chọn một mô hình DRL thích hợp cho vấn đề. Đây có thể là Q-Learning, DQN, Policy Gradients, hoặc bất kỳ mô hình phù hợp nào khác. Việc lựa chọn mô hình phụ thuộc vào các đặc điểm của vấn đề và dữ liệu có sẵn.
- **Trích xuất Đặc trưng:** Trích xuất các đặc trưng liên quan từ các biểu diễn trạng thái. Điều này có thể liên quan đến việc xử lý dữ liệu cảm biến để thu được thông tin hữu ích về điều kiện đất và thời tiết.
- **Thiết kế Kiến trúc Mạng:** Thiết kế kiến trúc mạng nơ-ron cho mô hình DRL. Điều này liên quan đến việc chọn số lượng lớp, số lượng nơ-ron trong mỗi lớp, các hàm kích hoạt, v.v..
- **Huấn luyện:** Huấn luyện tác nhân DRL bằng cách sử dụng dữ liệu lịch sử. Tác nhân học bằng cách tương tác với môi trường (cánh đồng), thực hiện các hành động (áp dụng nước), và nhận phần thưởng (phản hồi về hiệu quả tưới tiêu). Mục tiêu của việc huấn luyện là học một chính sách tối đa hóa tổng phần thưởng theo thời gian.
- **Thử nghiệm và Triển khai:** Sau khi huấn luyện, thử nghiệm tác nhân DRL trong môi trường mô phỏng hoặc thực tế để đánh giá hiệu suất của nó. Nếu hiệu suất đạt yêu cầu, hãy triển khai tác nhân để sử dụng thực tế.

Hãy nhớ rằng việc thiết kế một tác nhân DRL đòi hỏi chuyên môn về RL và DL. Đó cũng là một quá trình lặp đi lặp lại bao gồm rất nhiều thử và sai.

15.1.5 Các Ứng dụng Thành công của DRL trong Tưới tiêu Thông minh

Một hệ thống tưới tiêu dựa trên IoT đã được đề xuất bao gồm hai thành phần chính: một mạng không dây IoT gồm các nút cảm biến và truyền động và một thuật toán kiểm soát dựa trên DRL. Với dữ liệu độ ẩm của đất và dữ liệu thời tiết được thu thập, thuật toán dựa trên DRL sẽ tìm ra một lịch trình tưới tiêu tối ưu sử dụng lượng nước tối thiểu để đảm bảo hàm lượng nước trong đất trên mức yêu cầu trước chu kỳ tưới tiếp theo. Hệ thống đã được triển khai trong một khu vực thử nghiệm bao gồm sáu cây hạnh nhân. Qua một thí nghiệm thực địa kéo dài 12 ngày, người ta thấy rằng hệ thống được đề xuất có thể tiết kiệm tới 7.8% nước so với một chế độ tưới tiêu được sử dụng rộng rãi.

DRL có tiềm năng đáng kể để cải thiện lịch trình tưới tiêu trong nhiều hệ thống canh tác bằng cách áp dụng lượng nước thích ứng dựa trên các phép đo khác nhau theo thời gian. Mục tiêu là khám phá ra một quy tắc quyết định thông minh xử lý thông tin có sẵn cho người trồng và đưa ra lượng nước tưới hợp lý cho các bước thời gian được xem xét. Hiệu quả của khung này đã được chứng minh bằng một nghiên cứu điển hình về lúa mì được tưới tiêu trồng ở một vùng sản xuất của Úc, nơi lợi nhuận được tối đa hóa.

DRLIC là một hệ thống tưới tiêu tinh vi sử dụng DRL để tối ưu hóa hiệu suất của nó. Hệ thống sử dụng một mạng nơ-ron được gọi là tác nhân kiểm soát DRL, học một chính sách kiểm soát tối ưu có xem xét cả phép đo độ ẩm đất hiện tại và sự mất độ ẩm đất trong tương lai.

15.1.5.1 Các Phương pháp Hiện tại trong Tưới tiêu Thông minh

Các hệ thống tưới tiêu thông minh là sự kết hợp của nhiều công nghệ khác nhau, chẳng hạn như công nghệ cảm biến, công nghệ điều khiển tự động và công nghệ máy tính. Chúng được thiết kế để tối ưu hóa hiệu quả sử dụng tài nguyên nước nông nghiệp.

- **AI và ML:** Các kỹ thuật này được sử dụng trong cả nông nghiệp đô thị và nông thôn cho cây trồng trên đất để xác định các hệ thống hiện đang được sử dụng hoặc có thể được điều chỉnh cho nông nghiệp đô thị.
- **IoT:** IoT cho phép thu thập nhiều dữ liệu hơn và mức độ tự động hóa cao hơn. Các công nghệ như IoT, công cụ điện thoại thông minh và cảm biến cho phép nông dân hiểu rõ hơn về các điều kiện chính xác của các cánh đồng của họ, bao gồm nhiệt độ đất, chất dinh dưỡng, yêu cầu nước, điều kiện thời tiết, và nhiều hơn nữa.
- **Dữ liệu lớn (Big Data):** Các hoạt động nông nghiệp hiện đại tạo ra dữ liệu từ nhiều loại cảm biến để hiểu rõ hơn về các yếu tố môi trường và cây trồng, cho phép ra quyết định chính xác và hiệu quả hơn về các thực hành canh tác.
- **Công nghệ Cảm biến:** Điều này bao gồm các loại hệ thống tưới tiêu khác nhau có thể được tăng cường bằng phần mềm tưới tiêu thông minh. Phổ biến nhất là các hệ thống tưới ngập, tưới phun, tưới trục trung tâm (center pivot), tưới nhỏ giọt và tưới vi mô (microirrigation).
- **Công nghệ Điều khiển Tự động:** Điều này được kết hợp với các phương pháp tưới tiêu sân vườn, chẳng hạn như tưới phun và tưới nhỏ giọt.

15.1.5.2 Hạn chế của các Phương pháp Hiện tại

Mặc dù các hệ thống tưới tiêu thông minh có tiềm năng cách mạng hóa nông nghiệp, chúng cũng có những hạn chế nhất định. Bất lợi chính liên quan đến một hệ thống tưới tiêu thông minh là chi phí. Các hệ thống này có thể khá tốn kém, tùy thuộc vào quy mô của tài sản. Hơn nữa, các phần của bãi cỏ sẽ phải được đào lên để lắp đặt đường ống và gắn nó vào hệ thống ống nước của nhà.

- **Khó khăn Kỹ thuật:** Mặc dù lợi ích đã được chứng minh của mạng cảm biến không dây trong việc tiết kiệm nước, vẫn còn một số khó khăn kỹ thuật, đặc biệt là trong các chiến lược giám sát và kiểm soát tưới tiêu thông minh. Ngay cả những hệ thống thông minh hiệu quả nhất cũng có thể có những cạm bẫy của chúng. Gió có thể tàn phá các vòi phun nước, hướng nước đi sai hướng. Các loài gây hại dưới lòng đất có thể làm hỏng các hệ thống cung cấp nước, dẫn đến đọng nước hoặc các bộ phận bị hỏng.
- **Khả năng mở rộng Hạn chế:** Các nghiên cứu về hệ thống tưới tiêu cho đến nay không hiệu quả lắm, vì vậy chúng không thể được triển khai trên các hệ thống quy

mô lớn và có hiệu quả kém hơn do các cảm biến bị quá tải cho tất cả dữ liệu cảm biến.

- **Khả năng chi trả cho Nông dân Hộ nhỏ:** Chi phí công nghệ tưới tiêu thường nằm ngoài khả năng chi trả của nông dân hộ nhỏ như một khoản chi phí tự trả.

15.1.5.3 Cơ hội Cải tiến

Có một số cơ hội để cải tiến trong tưới tiêu thông minh:

- **Hệ thống Trục tưới Tự hành:** Các hệ thống này tạo ra các cơ hội mới cho tưới tiêu thông minh. Toàn bộ hệ thống tưới tiêu là tự hành, và công nhân nông nghiệp có thể chạy máy từ máy tính, cho phép nó dừng và bắt đầu hoặc thay đổi dòng nước.
- **Đầu tư vào Tưới tiêu Quy mô Nhỏ:** Các chương trình tưới tiêu quy mô nhỏ thường hoạt động tốt, mặc dù chúng phải được lên kế hoạch cẩn thận ngay từ đầu để chúng không bị quá tải bởi các sắp xếp vật lý và quản lý phức tạp. Tưới tiêu quy mô nhỏ thành công được xây dựng trên cơ sở hạ tầng hiệu quả, thông minh với khí hậu, kiên cường và bền vững về mặt tài chính.
- **Sáng kiến của Chính phủ:** Tương lai của thị trường tưới tiêu thông minh có vẻ hứa hẹn, với các cơ hội trong các ngành công nghiệp tưới tiêu nông nghiệp và phi nông nghiệp. Các động lực chính cho thị trường này là tăng cường các sáng kiến của chính phủ để thúc đẩy bảo tồn nước, tăng trưởng trong các thành phố thông minh và tăng nhu cầu về các hệ thống tưới tiêu hiệu quả.
- **Thích ứng với Biến đổi Khí hậu và Cải thiện An ninh Lương thực:** Những cải tiến trong các hệ thống giám sát và quản lý tưới tiêu thông minh có thể được sử dụng để giải quyết các vấn đề về khí hậu, lương thực và dân số.
- **Các Dự án Sáng tạo:** Có rất nhiều dự án sáng tạo có thể được sinh viên xây dựng để phát triển kinh nghiệm thực hành trong các lĩnh vực liên quan đến/sử dụng tưới tiêu thông minh.

15.1.6 Các định hướng Tương lai

DRL có tiềm năng cải thiện lịch trình tưới tiêu trong nhiều hệ thống canh tác bằng cách áp dụng lượng nước thích ứng dựa trên các phép đo khác nhau theo thời gian. Mục tiêu là khám phá ra một quy tắc quyết định thông minh xử lý thông tin có sẵn cho người trồng và đưa ra lượng nước tưới hợp lý cho các bước thời gian được xem xét.

Nghiên cứu về kỹ thuật này vẫn còn thưa thớt và không thực tế do tính mới mẻ về mặt kỹ thuật của nó. Để đẩy nhanh tiến độ, các nhà nghiên cứu đề xuất một khuôn khổ chung và quy trình có thể hành động cho phép các nhà nghiên cứu công thức hóa các vấn đề tối ưu hóa của riêng họ và triển khai các thuật toán giải pháp dựa trên DRL.

Nước ngọt đang trở thành một nguồn tài nguyên khan hiếm ở nhiều nơi trên thế giới, và việc sử dụng nó trong nông nghiệp ngày càng cần được tối ưu hóa. Mặc dù có một số

phương pháp tiếp cận để tối ưu hóa tưới tiêu, lập lịch tưới tiêu bằng các công nghệ cảm biến tiên tiến có tiềm năng đáng kể để áp dụng đúng lượng nước vào đúng thời điểm dựa trên các điều kiện được giám sát của thực vật, đất và khí quyển.

Các khung được đề xuất là chung chung và áp dụng được cho một loạt các hệ thống canh tác với các vấn đề tối ưu hóa thực tế. Điều này có nghĩa là DRL có thể được sử dụng không chỉ cho các loại cây trồng truyền thống mà còn cho các hệ thống nông nghiệp phức tạp và đa dạng hơn.

15.1.6.1 Các Cải tiến Tiềm năng trong DRL cho Tưới tiêu Thông minh

DRL đã cho thấy tiềm năng đáng kể trong việc cải thiện lịch trình tưới tiêu trong nhiều hệ thống canh tác bằng cách áp dụng lượng nước thích ứng dựa trên các phép đo khác nhau theo thời gian. Nghiên cứu hiện tại về DRL cho tưới tiêu vẫn còn thưa thớt và không thực tế do tính mới mẻ về mặt kỹ thuật của nó. Các cải tiến có thể được thực hiện trong việc xử lý phản hồi cảm biến có chiều cao, bao gồm xử lý thông tin có sẵn cho người trồng và đưa ra lượng nước tưới hợp lý cho các bước thời gian được xem xét.

Một phương pháp lập lịch tưới tiêu dựa trên RL sâu có thể được tăng cường để tối ưu hóa lợi nhuận kinh tế trong các ứng dụng tưới tiêu. Phương pháp này liên quan đến việc tính toán lượng nước tưới cho mỗi bước trong khi xem xét sự thoát hơi nước (ET), độ ẩm của đất, xác suất mưa trong tương lai và giai đoạn sinh trưởng hiện tại của cây trồng.

Khung cho DRL trong tưới tiêu là chung chung và áp dụng được cho một loạt các hệ thống canh tác với các vấn đề tối ưu hóa thực tế. Tuy nhiên, cần nhiều nghiên cứu hơn để điều chỉnh và tinh chỉnh các mô hình này cho các loại cây trồng và điều kiện môi trường khác nhau.

15.1.6.2 Các Xu hướng Mới nổi trong DRL và Nông nghiệp

DRL đang phát triển nhanh chóng và đã được áp dụng cho các thách thức quản lý tài nguyên nông nghiệp và tự nhiên khác nhau. DRL đang được sử dụng để giải quyết các vấn đề quan trọng như tối đa hóa năng suất cây trồng. Mục tiêu là tận dụng kiến thức có sẵn trong dữ liệu và xác định các cách thức mà qua đó nhiều tác vụ/tác vụ phụ để canh tác bền vững có thể được tự động hóa, dẫn đến các giải pháp nông nghiệp có thể mở rộng.

DRL đang được sử dụng để lập kế hoạch tầm nhìn tốt nhất tiếp theo (next-best-view) trong các ứng dụng nông nghiệp. Ví dụ, một phương pháp DRL mới đã được phát triển để xác định tầm nhìn tốt nhất tiếp theo cho việc khám phá tự động các môi trường 3D bằng một cánh tay robot được trang bị camera RGB-D. Phương pháp này cải thiện thông tin về các vùng quan tâm (ROI), chẳng hạn như trái cây, có thể bị che khuất hoàn toàn hoặc một phần bởi lá.

Các giải pháp dựa trên DRL đang được tích hợp với các mạng không dây IoT gồm các nút cảm biến và truyền động và đang được triển khai trên cơ sở hạ tầng đám mây sẵn

sàng sản xuất. Điều này làm cho các giải pháp trở nên thực tế và có thể mở rộng hơn. Những xu hướng này chỉ ra rằng DRL sẽ tiếp tục đóng một vai trò quan trọng trong việc thúc đẩy các thực hành nông nghiệp, góp phần vào việc canh tác hiệu quả hơn và các thực hành nông nghiệp bền vững.

15.2 KẾT LUẬN

Trong lĩnh vực nông nghiệp, chương "Học tăng cường sâu cho Tưới tiêu Thông minh" cung cấp bằng chứng về cách công nghệ có thể mang tính cách mạng trong việc giải quyết một số vấn đề quan trọng nhất mà nông dân đương đại phải đối mặt. Chúng ta xem xét các tác động đáng kể mà sự kết hợp của tưới tiêu chính xác và DRL có đối với nông nghiệp khi chúng ta kết thúc chương này.

Tưới tiêu thông minh đại diện cho một chiến lược toàn diện để canh tác cây trồng và quản lý tài nguyên được điều khiển bởi trí thông minh của các thuật toán DRL. Đó là bằng chứng về cách AI và chuyên môn của con người hoạt động tốt cùng nhau, với các lựa chọn dựa trên dữ liệu nâng cao kiến thức đã được trau dồi qua nhiều thế hệ canh tác.

Chúng ta đã xem xét các biến số được xem xét khi đưa ra quyết định về tưới tiêu thông minh trong suốt chương này, làm nổi bật tầm quan trọng của các loại cây trồng, thời tiết, độ ẩm của đất và tính bền vững. Chúng ta cũng đã khám phá vai trò quan trọng mà dữ liệu thời gian thực và các công nghệ cảm biến - từ vệ tinh đến cảm biến độ ẩm của đất - đóng vai trò trong việc thu thập và sử dụng dữ liệu cần thiết để đưa ra các quyết định này một cách chính xác.

Sự kết hợp của DRL với tưới tiêu thông minh trong nông nghiệp đã mang lại năng suất cây trồng tăng lên, hiệu quả tài nguyên và tính bền vững. Nó đã định hình lại ranh giới của canh tác, cho phép chúng ta bảo tồn tài nguyên của hành tinh đồng thời thúc đẩy sự phong phú của nó. Đó là một câu chuyện về sự sáng tạo, thích ứng và tiến bộ ngày càng tốt hơn qua mỗi mùa vụ trôi qua.

Việc áp dụng DRL trong nông nghiệp tiếp tục có những khả năng vô hạn. Để cải thiện và mở rộng các khả năng của tưới tiêu thông minh, các nhà khoa học, nông dân và các nhà công nghệ đang làm việc cùng nhau để tiếp tục hành trình khám phá và phát minh này. Câu chuyện DRL cho tưới tiêu thông minh là một tượng đài cho sự cống hiến của chúng ta trong việc chăm sóc đất đai và nuôi sống thế giới, không chỉ là một trong những thống kê và thuật toán.

TÀI LIỆU THAM KHẢO

1 Altalak, M., Ammad Uddin, M., Alajmi, A., & Rizg, A. (2022). Smart agriculture applications using deep learning technologies: A survey. *Applied Sciences*, 12(12),

5919.
2 Coulibaly, S., Kamsu-Foguem, B., Kamissoko, D., & Traore, D. (2022). Deep learning for precision agriculture: A bibliometric analysis. *Intelligent Systems with Applications*, 16, 200102.
3 Bhatt, S. (2019, April 19). Reinforcement learning 101. *Medium*. https://towardsdata science.com/reinforcement-learning-101-e24b50e1d292

4 Bu, F., & Wang, X. (2019). A smart agriculture IoT system based on deep reinforcement learning. *Future Generation Computer Systems*, 99, 500–507
5 Zhou, N. (2020, August). Intelligent control of agricultural irrigation based on reinforcement learning. *Journal of Physics: Conference Series*, 1601(5), 052031. IOP Publishing.
6 Yang, Y., Hu, J., Porter, D., Marek, T., Heflin, K., & Kong, H. (2020). Deep reinforcement learning-based irrigation scheduling. *Transactions of the ASABE*, 63(3), 549–556.
7 Alibabaei, K., Gaspar, P. D., Assunção, E., Alirezazadeh, S., & Lima, T. M. (2022). Irrigation optimization with a deep reinforcement learning model: Case study on a site in Portugal. *Agricultural Water Management*, 263, 107480.
8 Debnath, S., Adamala, S., & Palakuru, M. (2020). An overview of Indian traditional irrigation systems for sustainable agricultural practices. *International Journal of Modern Agriculture*, 9, 12–22.
9 Ding, X., & Du, W. (2022, May). Smart irrigation control using deep reinforcement learning. In *2022 21st ACM/IEEE International Conference on Information Processing in Sensor Networks (IPSN)* (pp. 539–540). IEEE.
10 IBM, E. team. (2018). What is deep learning? https://www.ibm.com/topics/deep-learning
11 Fu, Y., Li, C., Yu, F. R., Luan, T. H., & Zhang, Y. (Aug. 2022). Hybrid autonomous driving guidance strategy combining deep reinforcement learning and expert sys- tem. *IEEE Transactions on Intelligent Transportation Systems*, 23(8), 11273–11286. doi: 10.1109/TITS.2021.3102432
12 Ganatra, N., & Patel, A. (2021). Deep learning methods and applications for precision agriculture. In *Machine Learning for Predictive Analysis: Proceedings of ICTIS 2020*, pp. 515–527.

13 Kavitha, A. (2021). Deep learning for smart agriculture. *International Journal of Engineering Research & Technology (IJERT) ICRADL*, 09(05), 2021.
14 Attri, I., Awasthi, L. K., Sharma, T. P., & Rathee, P. (2023). A review of deep learning techniques used in agriculture. *Ecological Informatics*, 77, 102217.
15 Sami, M., Khan, S. Q., Khurram, M., Farooq, M. U., Anjum, R., Aziz, S., & Sadak, F. (2022). A deep learning-based sensor modeling for smart irrigation system.

Agronomy, 12(1), 212.

16 Sun, L., Yang, Y., Hu, J., Porter, D., Marek, T., & Hillyer, C. (2017, December). Reinforcement learning control for water-efficient agricultural irrigation. In *2017*

IEEE International Symposium on Parallel and Distributed Processing with Applications and 2017 IEEE International Conference on Ubiquitous Computing and Communications (ISPA/IUCC), IEEE, pp. 1334–1341.

17 Gao, H., Zhangzhong, L., Zheng, W., & Chen, G. (2023). How can agricultural water production be promoted? A review on machine learning for irrigation. *Journal of Cleaner Production*, 414, 137687.

18 Çetin, M., & Beyhan, S. (2022). Smart irrigation systems using machine learning and control theory. In *The Digital Agricultural Revolution: Innovations and Challenges in Agriculture through Technology Disruptions*, pp. 57–85.

19 Pallathadka, H., Mustafa, M., Sanchez, D. T., Sajja, G. S., Gour, S., & Naved, M. (2023). Impact of machine learning on management, healthcare and agriculture. *Materials Today: Proceedings*, 80, 2803–2806.

20 Vianny, D. M. M., John, A., Mohan, S. K., Sarlan, A., & Ahmadian, A. (2022). Water optimization technique for precision irrigation system using IoT and machine learning. *Sustainable Energy Technologies and Assessments*, 52, 102307.

21 Bukhari, S. N. H., Webber, J., & Mehbodniya, A. (2022). Decision tree based ensem- ble machine learning model for the prediction of Zika virus T-cell epitopes as poten- tial vaccine candidates. *Scientific Reports*, 12, 7810. doi: 10.1038/s41598-022-11731-6

22 Raghavendra, G. S., Shyni Carmel Mary, S., Bikash Acharjee, P., Varun, V. L., Bukhari, S. N. H., Dutta, C., & Samori, I. A. (2022). An empirical investigation in analysing the critical factors of artificial intelligence in influencing the food processing industry: A Multivariate Analysis of Variance (MANOVA) approach. *Journal of Food Quality*, 2022, Article ID 2197717, 7 pages. doi: 10.1155/2022/2197717

23 Bukhari, S. N. H., Jain, A., Haq, E., Mehbodniya, A., & Webber, J. (2021). Ensemble machine learning model to predict SARS-CoV-2 T-cell epitopes as potential vaccine targets. *Diagnostics*, 11(11) 1990. MDPI AG. doi: 10.3390/diagnostics11111990

24 Bangare, S. L., Virmani, D., Karetla, G. R., Chaudhary, P., Kaur, H., Bukhari, S. N. H., & Miah, S. (2022). Forecasting the applied deep learning tools in enhancing food quality for heart related diseases effectively: A study using structural equa- tion model analysis. *Journal of Food Quality*, 2022, Article ID 6987569, 8 pages. doi: 10.1155/2022/6987569

25 Anoruo, C. M., Bukhari, S. N. H., & Nwofor, O. K. (2023). Modeling and spatial char- acterization of aerosols at Middle East AERONET stations. *Theoretical and Applied Climatology*, 152, 617–625. doi: 10.1007/s00704-023-04384-6

26 Masoodi, F., Quasim, M., Bukhari, S., Dixit, S., & Alam, S. (2023). *Applications of Machine Learning and Deep Learning on Biological Data*. CRC Press.

27 Bukhari, S. N. H., Jain, A., & Haq, E. (2022). A novel ensemble machine learn- ing model for prediction of Zika virus T-cell epitopes. In Gupta, D., Polkowski, Z., Khanna, A., Bhattacharyya, S., ans Castillo, O. (Eds.), *Proceedings of Data Analytics and Management. Lecture Notes on Data Engineering and Communications Technologies*, vol 91. Springer, Singapore. doi: 10.1007/978-981-16-6285-0_23

28 Bukhari, S. N. H., Masoodi, F., Dar, M. A., Wani, N. I., Sajad, A. et al. (2023). Prediction of erythemato-squamous diseases using machine learning. In *Applications of Machine Learning and Deep Learning on Biological Data*. CRC Press.

29 Bukhari, S. N. H., Jain, A., Haq, E., Mehbodniya, A., & Webber, J. (2022). Machine learning techniques for the prediction of B-cell and T-cell epitopes as potential vac- cine targets with a specific focus on SARS-CoV-2 pathogen: A review. *Pathogens*, 11(2), 146. MDPI AG. doi: 10.3390/pathogens11020146

30 Nisar, S., Bukhari, H., & Dar, M. A. (2021). Using Random Forest to predict T-cell epitopes of Dengue virus. *Advances and Applications in Mathematical Sciences*, 20(11), 2543–2547.