AI ỨNG DỤNG TRONG NÔNG NGHIỆP

Buổi 3 | Chương 3: Học Sâu (Deep Learning) & Mạng Nơ-ron
Phần 1: Từ Bệnh Cây Trồng Đến Nền Tảng Lý Thuyết

NotebookLM

THÁCH THỨC TOÀN CẦU ĐỐI VỚI AN NINH LƯƠNG THỰC

Bệnh cây trồng là một vấn đề lớn trong nông nghiệp, làm giảm chất lượng và năng suất cây trồng, gây ra chi phí tài chính cao và ảnh hưởng nghiêm trọng đến nền kinh tế, đặc biệt ở các nước đang phát triển.

"Hầu hết các trang trại trên thế giới là nhỏ và thuộc sở hữu gia đình... họ cung cấp lương thực cho một tỷ lệ đáng kể dân số hành tinh, nhưng lại rất dễ bị tổn thương và khả năng tiếp cận dịch vụ còn hạn chế."

— Tổ chức Lương thực và Nông nghiệp Liên Hợp Quốc (FAO)

NotebookLM

VÌ SAO PHƯƠNG PHÁP TRUYỀN THỐNG KHÔNG CÒN HIỆU QUẢ?

CHẬM & TỐN KÉM

Các phương pháp chẩn đoán truyền thống tốn nhiều thời gian, công sức và chi phí, đặc biệt là các kỹ thuật sinh học phân tử.

DỄ SAI SÓT

Chẩn đoán bằng mắt thường thiếu độ tin cậy, thường không chính xác và phụ thuộc nhiều vào kinh nghiệm của chuyên gia.

YÊU CẦU CHUYÊN MÔN SÂU

Tai hỏi kiến thức chuyên môn
Đòi hỏi kiến thức chuyên môn sâu rộng, khiến nhiều nông dân, đặc biệt ở các trang trại nhỏ, khó tiếp cận.

GÂY THIỆT HẠI LỚN HƠN

Việc chẩn đoán chậm và không chính xác dẫn đến sử dụng thuốc trừ sâu không phù hợp, trở thành gánh nặng kinh tế và môi trường.

NotebookLM

GIẢI PHÁP TỪ TƯƠNG LAI: TỰ ĐỘNG HÓA VỚI HỌC SÂU

Phương pháp thủ công

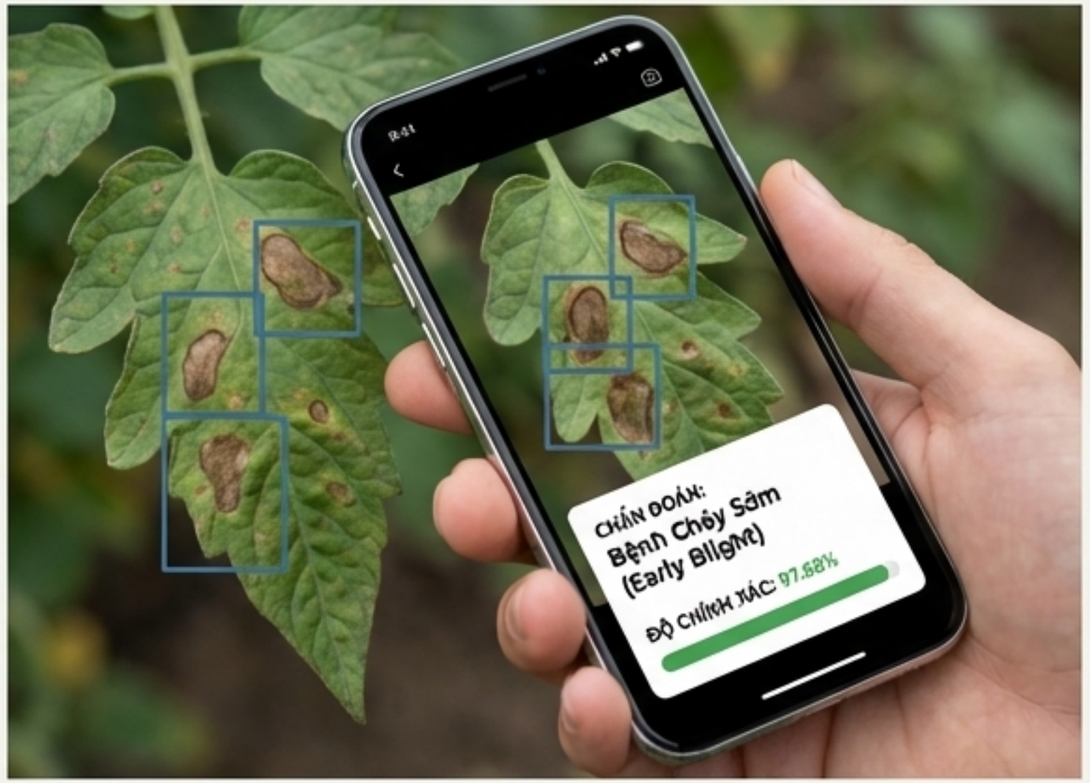

Chẩn đoán bằng AI

Học Sâu (Deep Learning), một lĩnh vực của Trí tuệ Nhân tạo, cho phép máy tính 'nhìn' và phân tích hình ảnh lá cây để chẩn đoán bệnh tức thì với độ chính xác vượt trội.

- **Tức thì:** Nhận kết quả trong vài giây.
- **Chính xác:** Vượt qua khả năng của mắt người.
- **Phổ cập:** Dễ dàng triển khai trên các thiết bị di động.

NotebookLM

NGUỒN CẢM HỨNG VƯỢT THỜI GIAN: BỘ NÃO CON NGƯỜI

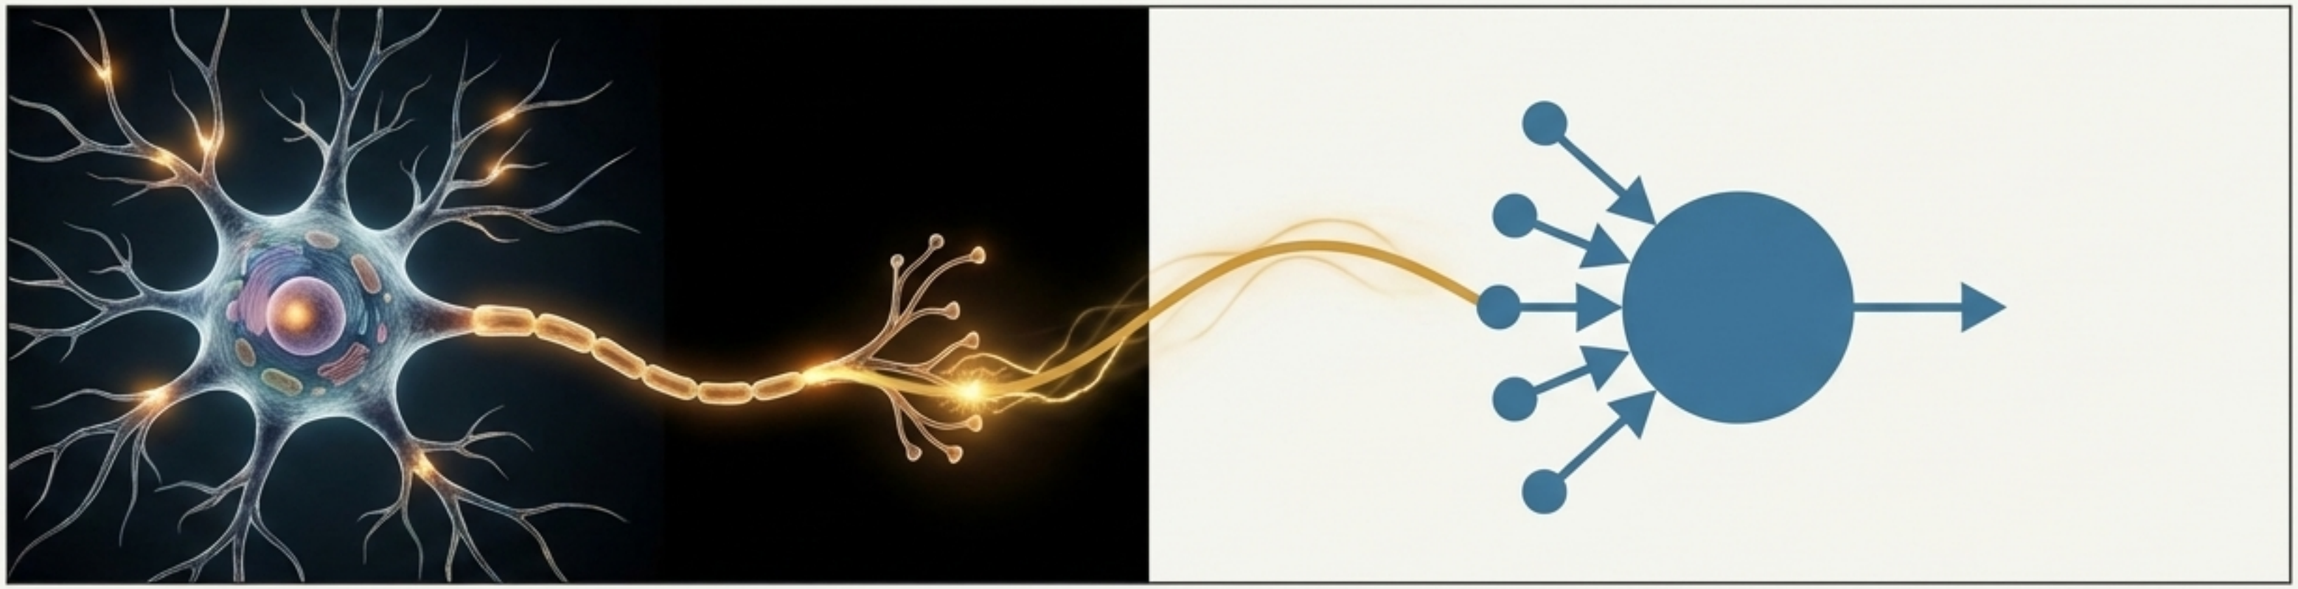

Nền tảng của **Học Sâu** là **Mạng Nơ-ron Nhân tạo (Artificial Neural Networks - ANN)**, một kiến trúc tính toán lấy cảm hứng từ mạng lưới nơ-ron sinh học phức tạp trong não bộ.

> **Ý tưởng cốt lõi:** Các ANN cố gắng mô phỏng cách bộ não hoạt động, cho phép máy tính học hỏi từ dữ liệu theo cách tương tự. Nếu bộ não có thể học, tại sao máy tính lại không?

NotebookLM

GIẢI PHẪU MỘT “TẾ 'TẾ BÀ' NÃO” NHÂN TẠO

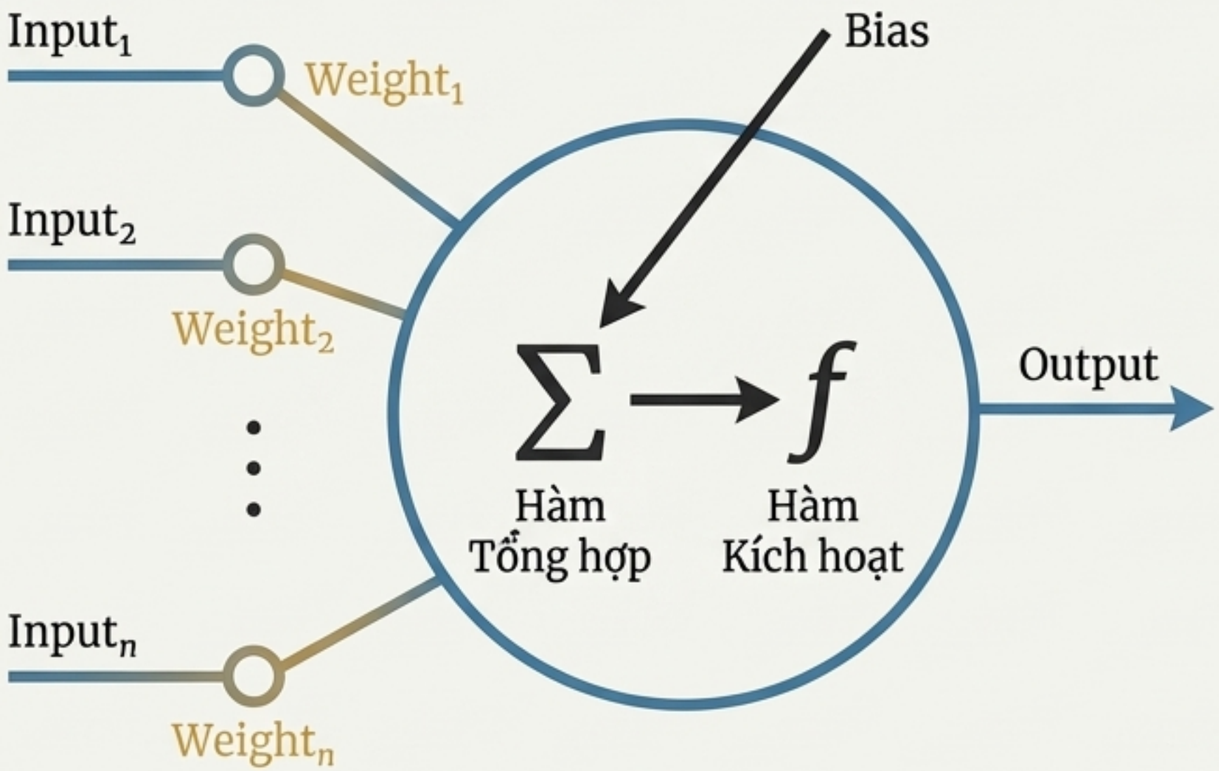

Quy trình xử lý thông tin trong một nơ-ron:

1. **Đầu vào (Inputs):** Nhận tín hiệu từ dữ liệu gốc (ví dụ: các pixel của ảnh) hoặc từ các nơ-ron khác.

2. **Trọng số (Weights):** Mỗi đầu vào được nhân với một 'trọng số' để biểu thị tầm quan trọng của nó. Đây là tham số mà mạng sẽ học.

3. **Hàm Tổng hợp:** Tính tổng có trọng số của các đầu vào và cộng thêm một giá trị **Độ lệch (Bias)**.

```
Tổng hợp = (Input₁ × Weight₁) + ... + Bias
```

4. **Hàm Kích hoạt (Activation Function):** Một hàm phi tuyến quyết định tín hiệu đầu ra của nơ-ron, cho phép mạng học các mẫu phức tạp.

```
Output = ActivationFunction(Tổng hợp)
```

NotebookLM

SỨC MẠNH CỦA TẬP THỂ: MẠNG PERCEPTRON ĐA LỚP (MLP)

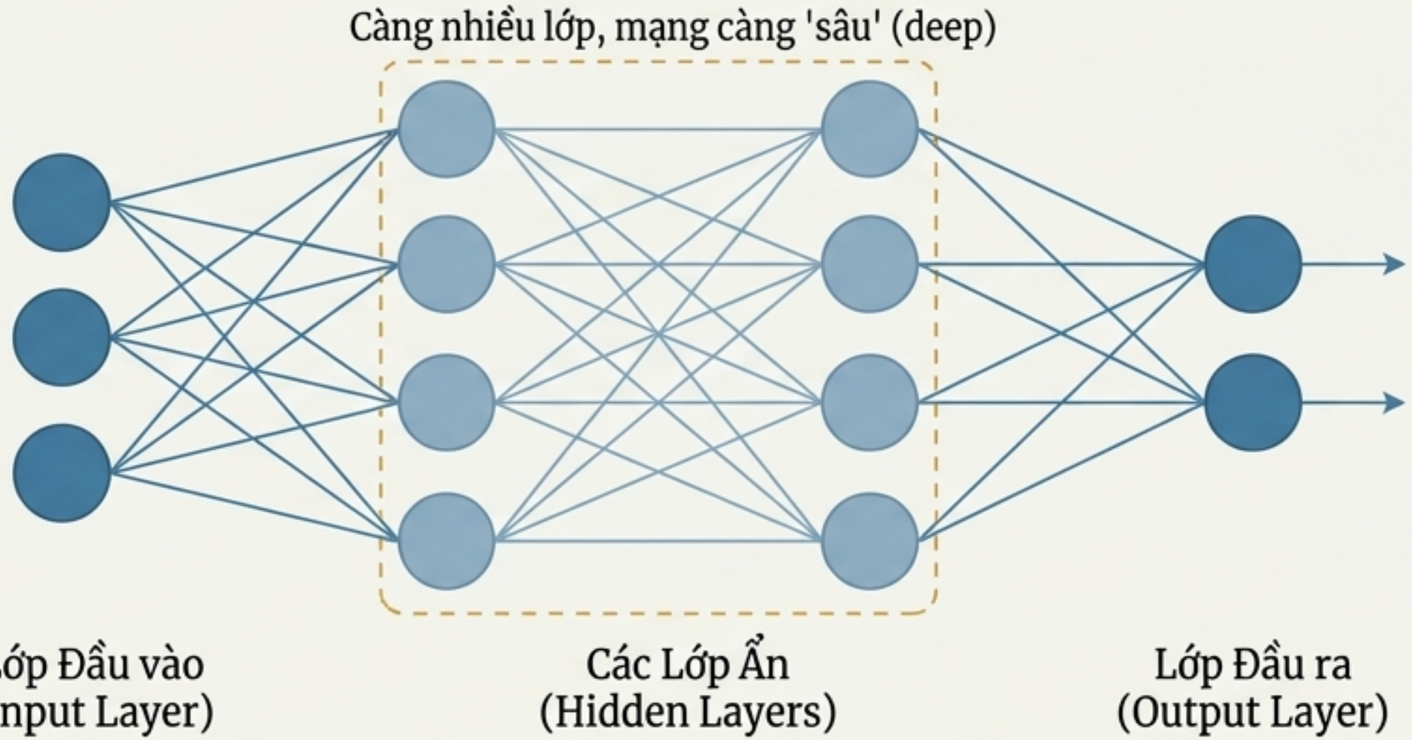

Kiến trúc:

Một nơ-ron đơn lẻ là chưa đủ. Bằng cách kết nối và xếp chồng chúng thành nhiều lớp, chúng ta tạo ra một MLP.

* **Lớp Đầu vào (Input Layer):** Tiếp nhận dữ liệu thô.
* **Các Lớp Ẩn** (Hidden Layers): 'Bộ não' của mạng, nơi các đặc trưng trừu tượng được học. Mạng có một chồng sâu các lớp ẩn được gọi là **Mạng Nơ-ron Sâu** (Deep Neural Network - DNN).
* **Lớp Đầu ra** (Output Layer): Đưa ra dự đoán cuối cùng (ví dụ: loại bệnh).

Khi tất cả các nơ-ron trong một lớp được kết nối với mọi nơ-ron của lớp tiếp theo, nó được gọi là một lớp kết nối đầy đủ (fully connected) hoặc lớp dày đặc (dense).

NotebookLM

CỖ MÁY HỌC TẬP: SAI, SỬA VÀ HOÀN THIỆN

1. Gradient Descent (Hạ Gradient)

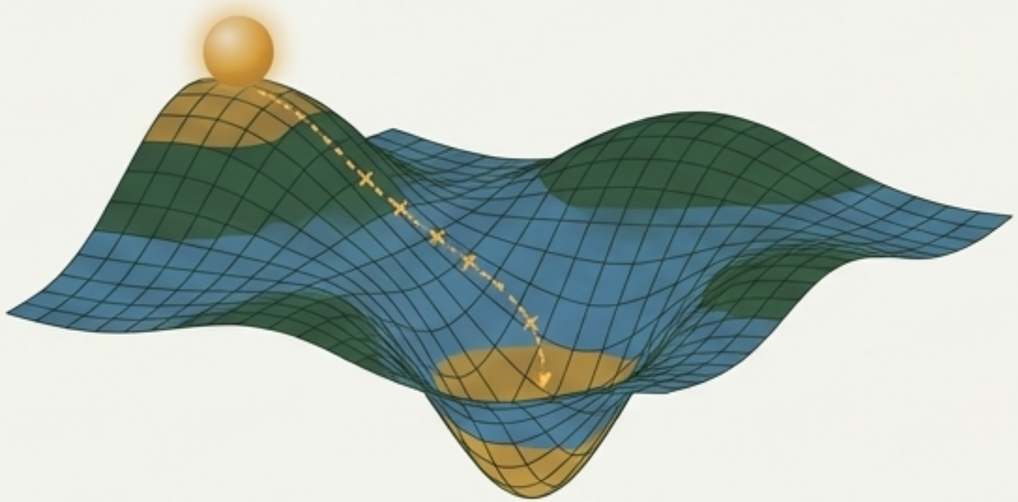

Là thuật toán tối ưu hóa nhằm tìm ra bộ trọng số (weights) giúp **giảm thiểu sai số** (loss/cost function) của mô hình.

Phép loại suy: Tưởng tượng việc tìm đường xuống điểm thấp nhất trong một thung lũng bằng cách đi từng bước theo hướng dốc nhất.

2. Backpropagation (Lan truyền ngược)

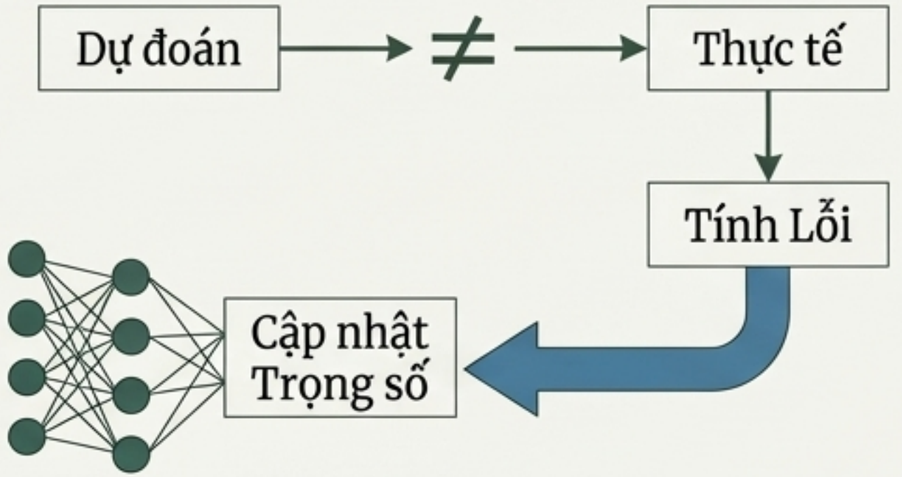

Là thuật toán tính toán hiệu quả gradient của hàm sai số đối với mọi tham số trong mạng.

Tín hiệu lỗi được lan truyền ngược từ lớp đầu ra về lớp đầu vào, cho phép thuật toán biết cách điều chỉnh từng trọng số để giảm sai số.

Cặp đôi này là động cơ cốt lõi giúp mạng nơ-ron trở nên thông minh hơn qua mỗi lần lặp.

NotebookLM

SỰ TRỖI DẬY CỦA MỘT Ý TƯỞNG LÂU ĐỜI

1957

Perceptron

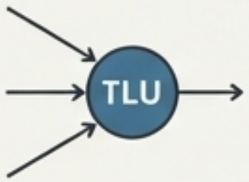

Mô hình nơ-ron tính toán đầu tiên được Frank Rosenblatt phát minh, đặt nền móng cho lĩnh vực.

1980s-2000s

"Mùa đông AI"

Những hạn chế về lý thuyết, thiếu dữ liệu và năng lực tính toán khiến nghiên cứu về ANN chững lại.

2012-Nay

Cách Mạng Học Sâu

Sự hội tụ của 3 yếu tố đã tạo nên cú nổ lớn:

Dữ liệu lớn (Big Data): Nguồn "nhiên liệu" dồi dào cho các mô hình.

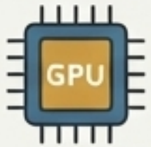

GPU mạnh mẽ: Cung cấp sức mạnh tính toán song song cần thiết.

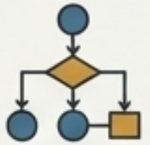

Thuật toán cải tiến: Các kiến trúc và kỹ thuật huấn luyện hiệu quả hơn.

NotebookLM

HỌC SÂU (DL) KHÁC GÌ HỌC MÁY (ML) TRUYỀN THỐNG?

Tiêu chí	Học Máy Cổ Điển (Classical Machine Learning)	Học Sâu (Deep Learning)
Trích xuất Đặc trưng	Thủ công. Con người phải lựa chọn và định nghĩa các đặc trưng (ví dụ: màu sắc, hình dạng, kết cấu của đốm bệnh).	Tự động. Mạng nơ-ron tự học các đặc trưng quan trọng trực tiếp từ dữ liệu thô (ảnh pixel).
Phụ thuộc Dữ liệu	Hiệu quả với tập dữ liệu nhỏ và vừa.	Yêu cầu lượng dữ liệu khổng lồ để đạt hiệu suất cao nhất.
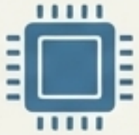 **Phần cứng** 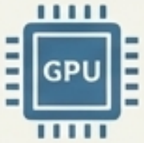	Có thể chạy tốt trên CPU thông thường.	Yêu cầu phần cứng mạnh, đặc biệt là GPU, để tăng tốc quá trình huấn luyện.
Giải quyết Vấn đề	Chia nhỏ bài toán thành các phần (tiền xử lý, trích xuất đặc trưng, phân loại).	Tiếp cận "End-to-End", học trực tiếp từ đầu vào đến đầu ra.

NotebookLM

ƯU THẾ QUYẾT ĐỊNH: KHẢ NĂNG TỰ HỌC ĐẶC TRƯNG

Với Học Máy truyền thống:

Bạn phải "chỉ" cho máy tính biết cần nhìn vào đâu.

"Hãy tìm các đốm màu nâu, hình tròn, có viền vàng..."

Với Học Sâu:

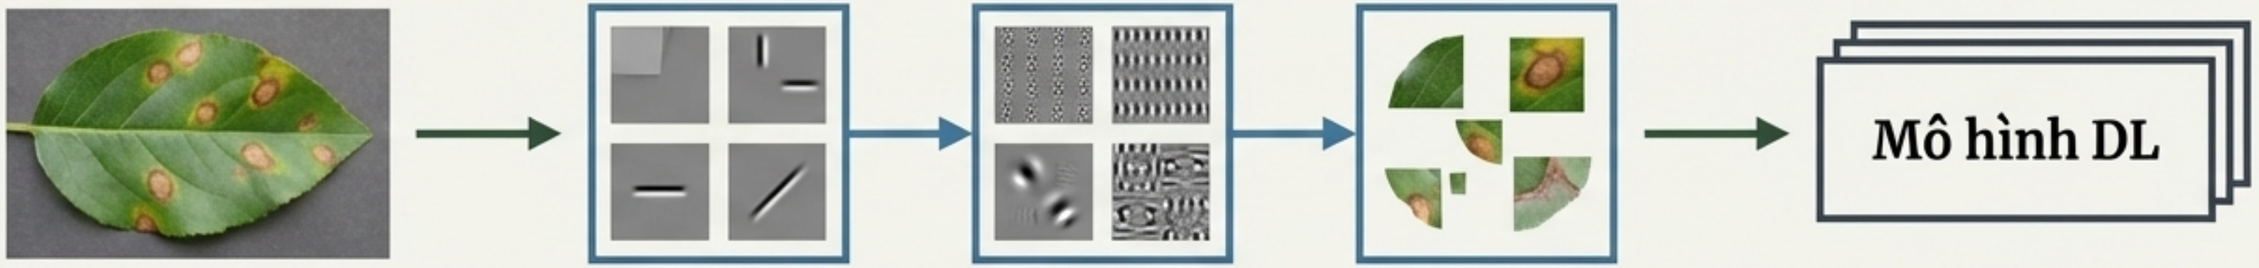

Bạn chỉ cần "cho" máy tính xem. Nó sẽ tự học cần nhìn vào đâu.

"Mạng nơ-ron sẽ tự động nhận diện các đặc trưng từ cấp thấp (cạnh, góc) đến cấp cao (hoa văn, kết cấu của đốm bệnh)."

Đây là lý do Học Sâu thống trị các bài toán về dữ liệu phi cấu trúc như hình ảnh, làm cho nó trở thành giải pháp lý tưởng cho việc nhận diện bệnh cây trồng."

NotebookLM

TÓM TẮT NHỮNG Ý CHÍNH (PHẦN 1)

- **Bối cảnh:** Bệnh cây trồng là một bài toán thực tiễn, cấp bách, đòi hỏi một giải pháp tự động hóa hiệu quả.
- **Nền tảng:** Mạng Nơ-ron Nhân tạo, lấy cảm hứng từ bộ não, là công nghệ cốt lõi. Chúng học hỏi thông qua các thuật toán như Gradient Descent và Backpropagation.
- **Bước tiến:** Học Sâu là một dạng của Học Máy, vượt trội nhờ khả năng tự động học các đặc trưng phức tạp trực tiếp từ dữ liệu thô, đặc biệt là hình ảnh.

Chuẩn bị cho Phần 2:
Trong phần tiếp theo, chúng ta sẽ khám phá **Mạng Nơ-ron Tích chập (CNN)** *- kiến trúc chuyên dụng cho xử lý hình ảnh - và phân tích các nghiên cứu điển hình trong nông nghiệp.*

NotebookLM

PHẦN 2: CÔNG NGHỆ CỐT LÕI (CNN), THỰC TIỄN & CÔNG CỤ

Từ Kiến trúc Xử lý Ảnh đến Hệ sinh thái Lập trình

Trong phần này, chúng ta sẽ đi sâu vào:

1. **Công nghệ cốt lõi:** Khám phá Mạng Nơ-ron Tích chập (CNN) - "vũ khí" chuyên dụng cho các bài toán thị giác máy tính.
2. **Bằng chứng thực tiễn:** Phân tích các nghiên cứu điển hình về việc áp dụng CNN để phát hiện bệnh trên lá khoai tây và táo.
3. **Công cụ trong tay bạn:** Làm quen với hệ sinh thái Keras & TensorFlow để tự xây dựng, huấn luyện và tối ưu hóa các mô hình học sâu.

NotebookLM

Mạng Nơ-ron Tích chập (CNN): "Vũ khí" cho Thị giác Máy tính

Thách thức của ANN thông thường với hình ảnh:

- **Mất thông tin không gian:** Việc 'làm phẳng' (flatten) ảnh thành vector 1D phá vỡ mối quan hệ giữa các pixel lân cận, làm mất đi các đặc trưng như cạnh, góc, hoa văn.
- **Bùng nổ tham số:** Khi kích thước ảnh tăng, số lượng tham số có thể huấn luyện tăng lên đáng kể, dẫn đến mô hình quá lớn, dễ bị quá khớp (overfitting) và tốn kém tài nguyên.

Giải pháp của CNN:

- **Lớp Tích chập (Convolutional Layer):** Sử dụng các 'bộ lọc' (filter/kernel) để quét qua ảnh, tự động học và trích xuất các đặc trưng không gian.
- **Lớp Gộp (Pooling Layer):** Giảm kích thước của bản đồ đặc trưng một cách thông minh, giữ lại những thông tin quan trọng nhất, giúp mô hình khái quát hóa tốt hơn và giảm chi phí tính toán.

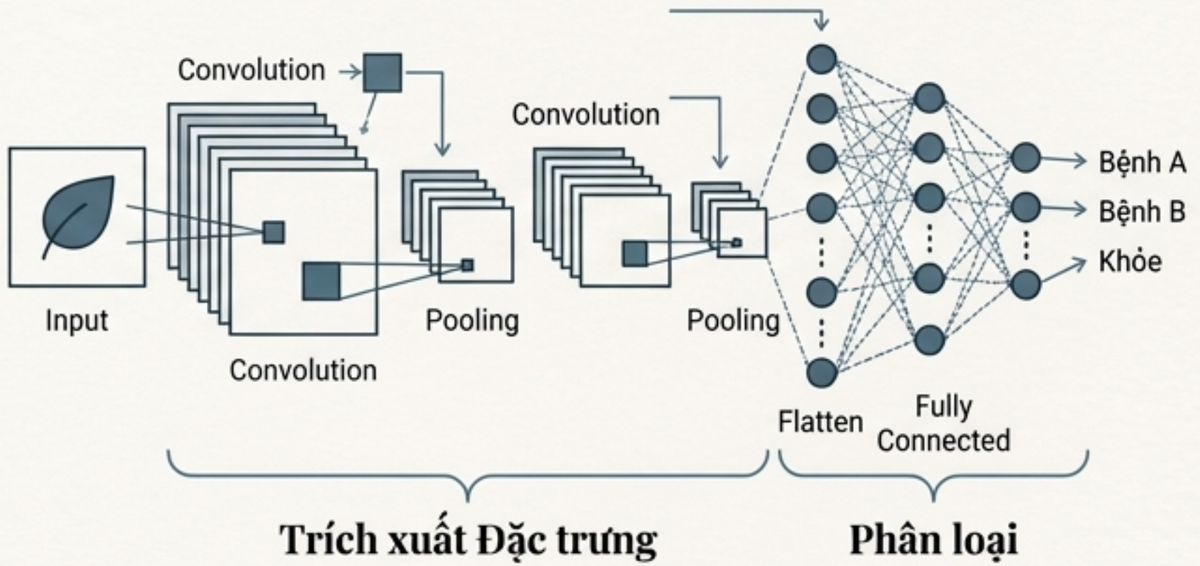

NotebookLM

Nghiên cứi Thực tiễn

CNN đã chứng minh hiệu quả trong việc phát hiện bệnh cây trồng như thế nào?

Chúng ta sẽ phân tích hai trường hợp ứng dụng tiêu biểu để thấy rõ sức mạnh của CNN:
1. **Phân loại bệnh trên lá Khoai tây:** Xây dựng một mô hình CNN từ đầu để giải quyết một bài toán cụ thể với độ chính xác cao.
2. **Phân loại bệnh trên lá Táo:* So sánh hiệu quả giữa mô hình tự xây và các kiến trúc CNN danh tiếng có sẵn để rút ra bài học quan trọng về chiến lược xây dựng mô hình.

NotebookLM

Case Study 1: Bệnh trên lá Khoai tây (Dataset: Plant Village)

- **Bài toán:** Phân loại ảnh lá khoai tây thành 3 lớp:
  - Khỏe (Healthy)
  - Bệnh Cháy sớm (Early Blight)
  - Bệnh Cháy muộn (Late Blight)
- **Phương pháp:** Xây dựng một mô hình CNN tuần tự (Sequential) đơn giản bằng Keras.
- **Kiến trúc Mẫu (trích đoạn code):**

```
model = Sequential([
    # Đầu vào là ảnh 256x256x3
    BatchNormalization(input_shape=(256,256,3)),
    Convolution2D(32, (3,3), activation='relu'),
    MaxPooling2D((3,3)),
    Convolution2D(64, (3,3), activation='relu'),
    MaxPooling2D((3,3)),
    Flatten(),
    Dense(200, activation='relu'),
    Dense(3, activation='softmax') # 3 lớp đầu ra
])
```

Kết quả:

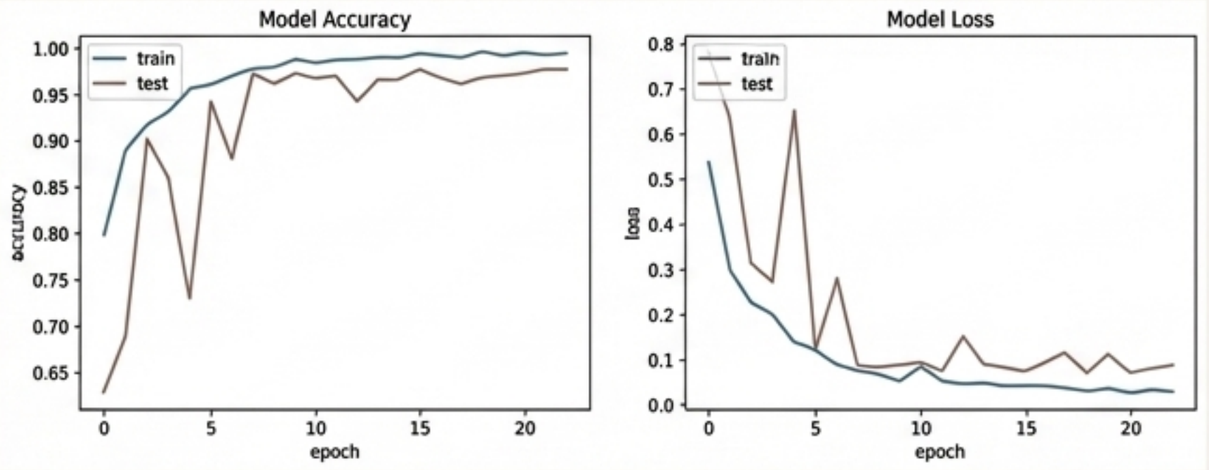

- **Thành tựu:** Độ chính xác trên tập kiểm tra (validation accuracy) đạt **97.68%**.
- **Nhận xét:** Một mô hình CNN đơn giản có thể đạt hiệu quả rất cao cho một bài toán được xác định rõ ràng.

NotebookLM

Case Study 2: Bệnh trên lá Táo & Bài học về 'Học chuyển giao'

- **Bài toán:** Phân loại 4 lớp bệnh trên lá táo, một bài toán phức tạp hơn (Dataset: Kashmir).
- **Phương pháp:** So sánh hiệu năng giữa mô hình tự xây (Custom CNN) và 3 kiến trúc nổi tiếng được huấn luyện trước (pre-trained): VGG16, ResNet-50, InceptionV3.

Bảng Kết quả So sánh:

Thuật toán	Độ chính xác (%)	Độ chuẩn xác (Precision)	Độ phủ (Recall)	Điểm F1
Custom CNN	80	0.78	0.77	0.77
VGG16	**85**	**0.82**	**0.81**	**0.81**
ResNet-50	81	0.79	0.77	0.78
InceptionV3	83	0.80	0.78	0.79

Bài học then chốt:

'Không cần phát minh lại bánh xe.'

Tận dụng các kiến trúc đã được chứng minh hiệu quả (kỹ thuật **Học chuyển giao - Transfer Learning**) thường mang lại kết quả tốt hơn và nhanh hơn so với việc tự xây dựng từ đầu, đặc biệt với dữ liệu phức tạp hoặc hạn chế.

NotebookLM

Hệ sinh thái Công cụ: Keras & TensorFlow

Các API, công cụ hỗ trợ và kỹ thuật tối ưu hóa để bạn bắt đầu hành trình của mình.

- Chúng ta sẽ khám phá ba khía cạnh chính của hệ sinh thái này:

* **3 API Xây dựng Mô hiih:** Lựa chọn công cụ phù hợp với độ phức tạp của bài toán.

* **Công cụ Hỗ trợ Huấn luyện:** Các ‘trợ lý’ thông minh giúp quá trình huấn luyện hiệu quả hơn.

* **Tối ưu hóa Tự động:** Các kỹ thuật để máy tính tự tìm ra cấu hình mô hình tốt nhất.

NotebookLM

3 API Xây dựng Mô hình: Từ Đơn giản đến Tùy biến sâu

Sequential API

Mô tả: Xếp chồng các lớp theo một chuỗi duy nhất, như một chuỗi lego.

Khi nào dùng: Các mô hình CNN, MLP đơn giản. Dễ nhất để bắt đầu.

Độ khó: Dễ

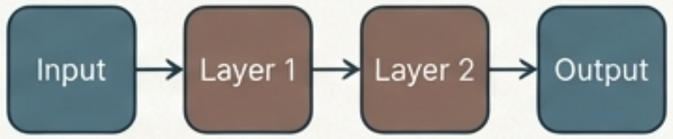

Functional API

Mô tả: Xây dựng các đồ thị lớp phức tạp, linh hoạt.

Khi nào dùng: Các kiến trúc có nhiều đầu vào/ra, các nhánh rẽ (ví dụ: Wide & Deep, ResNet).

Độ khó: Trung bình

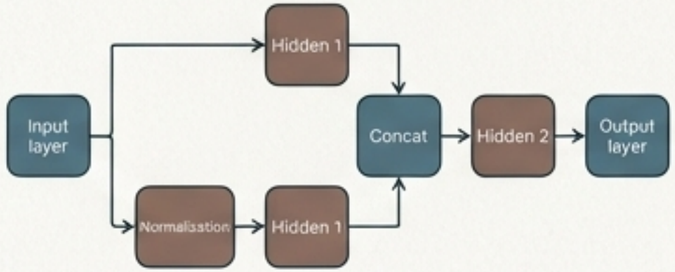

Subclassing API

Mô tả: Định nghĩa mô hình như một lớp (class) Python.

Khi nào dùng: Cần toàn quyền kiểm soát logic, phù hợp cho nghiên cứu và thử nghiệm các kiến trúc mới lạ.

Độ khó: Khó

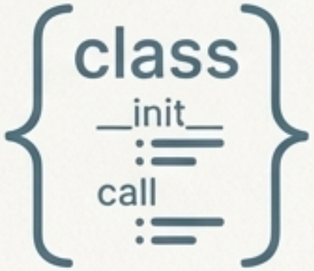

NotebookLM

Huấn luyện Thông minh hơn: Callbacks & TensorBoard

Công cụ Hỗ trợ Quá trình Huấn luyện (Callbacks)

Callbacks là các 'trợ lý' tự động được gọi trong lúc `model.fit()`. Chúng giúp bạn giám sát và hành động dựa trên trạng thái của mô hình.

Ví dụ quan trọng:

- **`ModelCheckpoint`**: Tự động lưu lại mô hình tốt nhất (dựa trên `val_loss` hoặc `val_accuracy`). Không bao giờ làm mất mô hình tốt nhất của bạn.
- **`EarlyStopping`**: Dừng huấn luyện sớm khi mô hình không còn cải thiện, giúp tiết kiệm thời gian và chống overfitting hiệu quả.

Mục tiêu: Tự động hóa việc giám sát, giúp bạn tập trung vào thử nghiệm.

Trực quan hóa với TensorBoard

TensorBoard là một dashboard giúp bạn 'nhìn thấu' và phân tích quá trình học của mô hình một cách trực quan.

Tính năng chính:

📈 Theo dõi trực tiếp đường cong học tập (**Loss**, **Accuracy**) để xem mô hình có đang học tốt hay không.

🔬 So sánh hiệu quả giữa các lần chạy với siêu tham số khác nhau để tìm ra phương án tối ưu.

Mục tiêu: Hiểu sâu hơn về hành vi của mô hình, giúp gỡ lỗi và tối ưu hóa.

NotebookLM

Tối ưu hóa Siêu tham số: Từ 'Đoán mò' đến Tự động

Vấn đề: Làm sao để chọn được số lớp, số nơ-ron, tốc độ học (learning rate) tối ưu?

- Thử và sai thủ công: Tốn thời gian, không hiệu quả, dễ bỏ lỡ cấu hình tốt nhất. Quá trình này không có tính hệ thống và khó tái tạo.

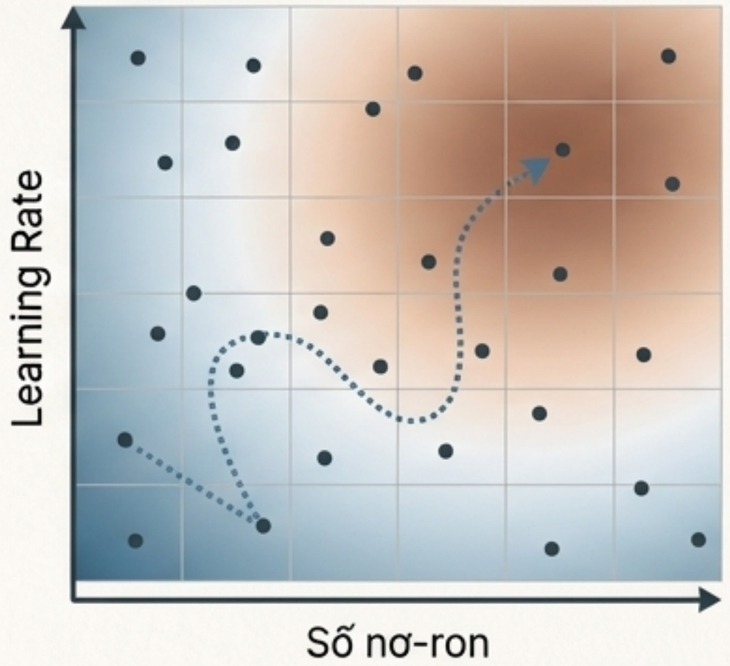

Giải pháp: Keras Tuner: Một thư viện giúp tự động hóa quá trình tìm kiếm không gian siêu siêu tham số để tìm ra kiến trúc và cấu hình hiệu quả nhất cho bài toán của bạn.

Các chiến lược tìm kiếm phổ biến:

- **RandomSearch:** Thử ngẫu nhiên các kết hợp. Nhanh và đơn giản.
- **Hyperband:** Một thuật toán thông minh hơn, loại bỏ sớm các thử nghiệm kém hiệu quả để tập trung tài nguyên vào những “ứng viên” hứa hẹn nhất.
- **BayesianOptimization:** Dần dần học về các vùng siêu tham số tiềm năng để hội tụ nhanh hơn đến giải pháp tối ưu.

NotebookLM

Tóm tắt Phần 2 & Gợi ý Tiếp theo

Những gì chúng ta đã học:

1. **CNN là kiến trúc chủ lực** cho các bài toán thị giác máy tính nhờ khả năng học các đặc trưng không gian, vượt trội hơn ANN thông thường trong việc xử lý hình ảnh.

2. **Thực tiễn đã chứng minh** CNN có thể đạt độ chính xác rất cao trong việc phát hiện bệnh cây trồng. Việc sử dụng các kiến trúc có sẵn (Transfer Learning) là một chiến lược hiệu quả và tiết kiệm thời gian.

3. **Hệ sinh thái Keras/TensorFlow** cung cấp một bộ công cụ mạnh mẽ và toàn diện, từ việc xây dựng, huấn luyện, giám sát đến tối ưu hóa mô hình một cách chuyên nghiệp.

Hoạt động Gợi ý:

- **Live Demo:** Với nền tảng IT của lớp, chúng ta có thể xem một đoạn code Python mẫu (sử dụng Keras) để minh họa cho việc xây dựng mô hình CNN phát hiện bệnh trên lá khoai tây từ Case Study 1.
- **Hỏi & Đáp**

NotebookLM